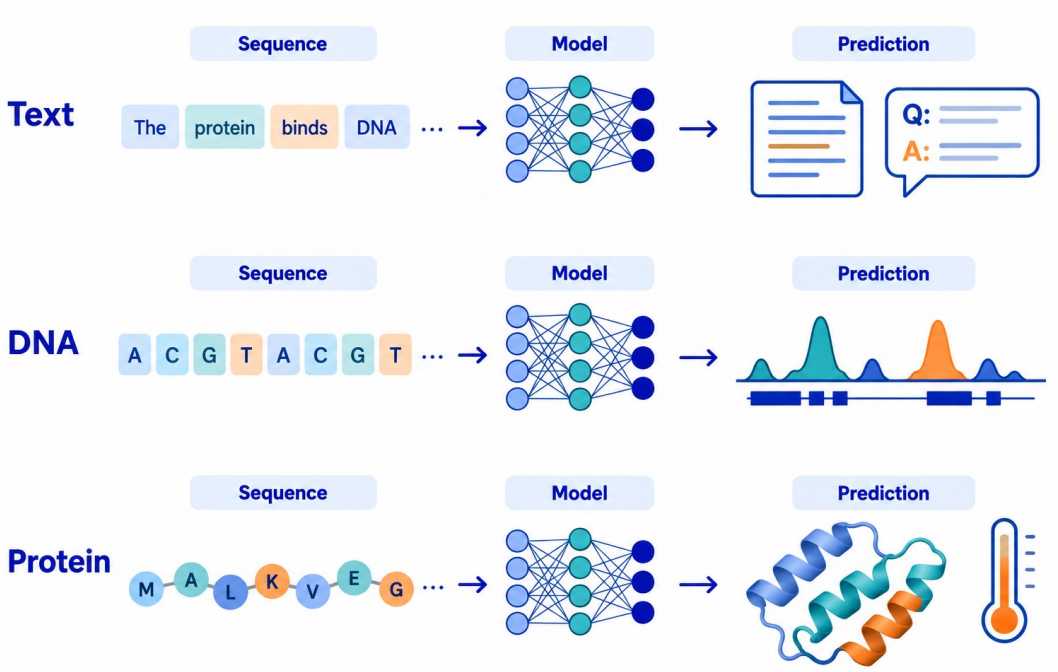
生命情報工学特論　第04回

生命科学の言語モデル

配列から何を予測するか
全体像から内部の計算へ



概念図：自然言語・DNA・タンパク質の配列をモデルで扱う。

松永 康佑

埼玉大学 大学院理工学研究科
理化学研究所 計算科学研究センター ｜ 2026年10月26日

この回の目標

配列から、何を予測・生成できるか

入力は配列。目指すのは、次の三つの使い方。

1　文字の候補を予測する

… I E N [MASK] K A …

↓

候補アミノ酸と確率

変異前後の確率を比べ、
機能への影響を調べる。

2　配列の性質を予測する

タンパク質・DNAの配列

↓

構造・融解温度・発現

配列の特徴と実測値から、
目的の性質を予測する。

3　新しい配列を生成する

配列の先頭部分

↓

続きの文字 → 候補配列

次の文字を選ぶ操作を繰り返す。
機能は別に確かめる。

講義の流れ

目的からモデル全体へ、全体から内部の計算へ

01　入力と出力を決める

隠した文字・次の文字の予測が、生物学のどんな課題につながるか。

02　モデル全体を見る

配列 → 初期ベクトル → 文脈を取り込む処理 → 確率や性質の予測。

03　Transformerの中へ入る

ブロックの役割を見てから、埋め込み・アテンション・学習を説明する。

04　タンパク質に使う

ESM-2の穴埋めから、コンタクト・立体構造・物性の予測へ。

05　DNAへ広げる

長い文脈を扱うEvo 2と、変異・発現・配列生成への応用。

配列が読めても、その働きはすぐには分からない

集めやすいデータ：配列

… A C G T A G C T …

… A C G T G G C T …

… A T G T A G C T …

実験が必要

知りたい量：条件ごとの働き

DNA：細胞ごとに、遺伝子がどれだけ読み出されるか。

タンパク質：変異後の機能と安定性。

自己教師あり学習：元の配列から予測問題と正解を作る

… A C [MASK] T … → G

… A C G → 次の文字 T

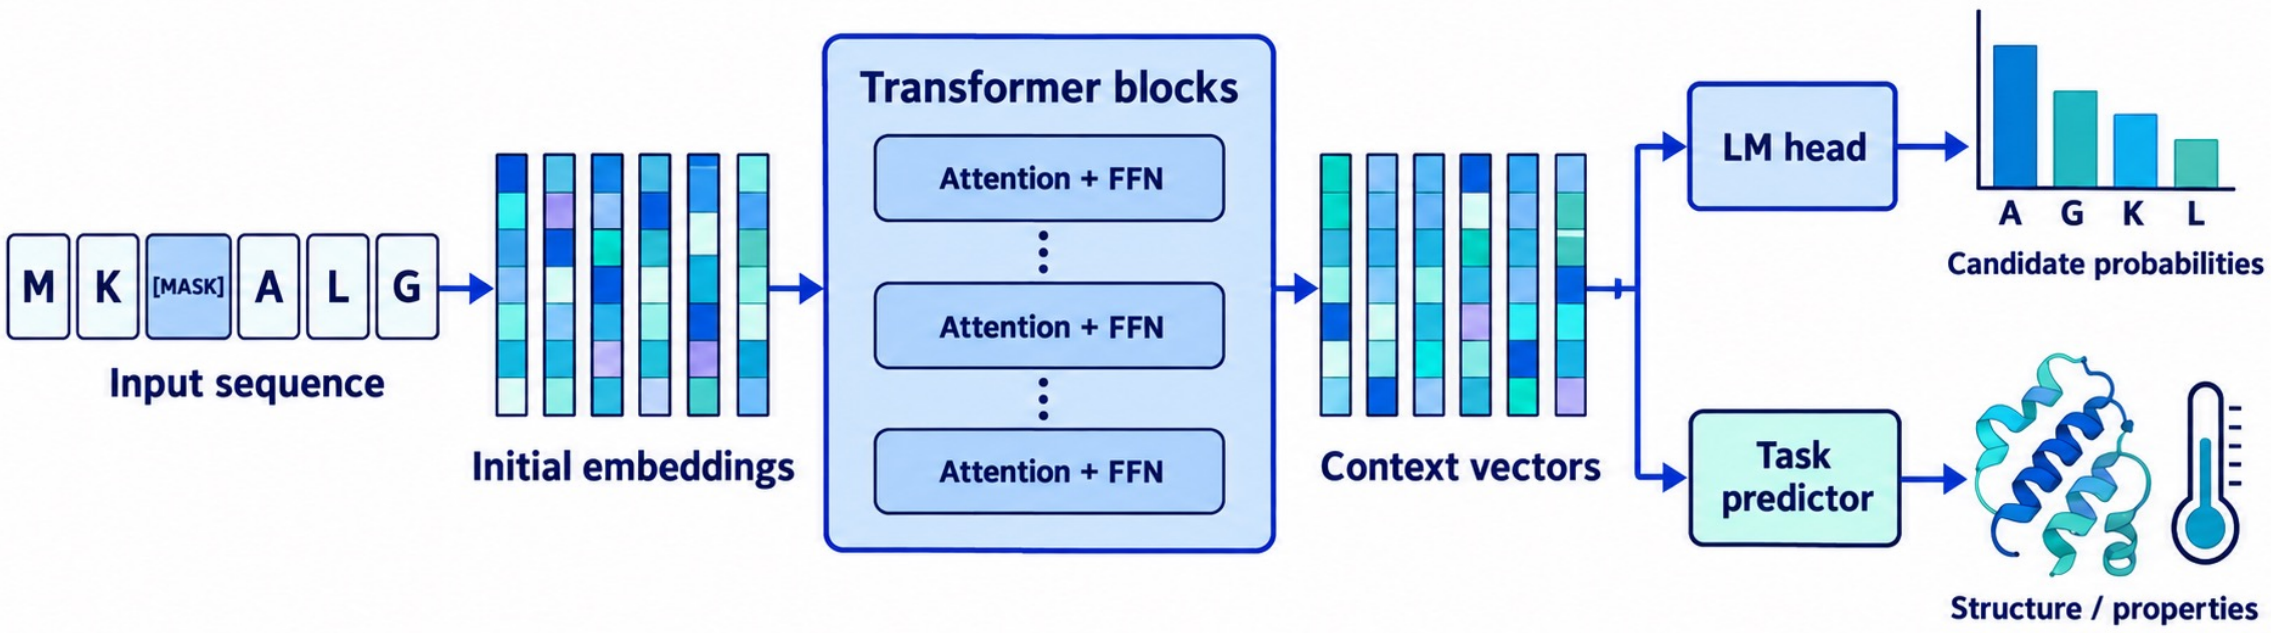
事前学習で配列の規則を学び、その表現を実測値の予測へ使う。

機能ラベルなしで学べることと、機能を直接学習したことは異なる。

参考：田宮元『実験医学』44(4), 453–458 (2026)。図は説明用の模式図。

配列の文脈をベクトルにまとめ、目的に応じて読み出す

配列 → 初期ベクトル → Transformerを重ねる → 文脈を含むベクトル



文字の予測：候補スコアを確率へ変える。
自己回帰型では、選んだ文字を入力へ戻す。

性質を調べる出口：目的の予測器を接続。
構造・物性などの実測ラベルで別に学習する。

模式図：Transformer型言語モデルの流れ。Evo 2では中央に畳み込みも組み合わせる。

内部のベクトルと、最終的な予測値を区別する

途中の計算：位置ごとの特徴ベクトル

$$x \longrightarrow H = (h_1, \ldots, h_L)^T \in \mathbb{R}^{L \times d}$$

L：配列長。d：特徴の次元数。
各行h_iは、位置iと周囲を表すd個の数。
各成分は候補文字の確率ではない。

性質の予測へ：表現を別の予測器に渡す

$$\bar{h} = \frac{1}{L} \sum_{i=1}^{L} h_i, \qquad \hat{y} = g_\phi(\bar{h})$$

例：平均表現から融解温度を予測。
予測器の重みφは、実測値で学ぶ。

文字の予測へ：語彙方向のスコアと確率

$$z_i = g_{\text{out}}(h_i) \in \mathbb{R}^{|V|}$$

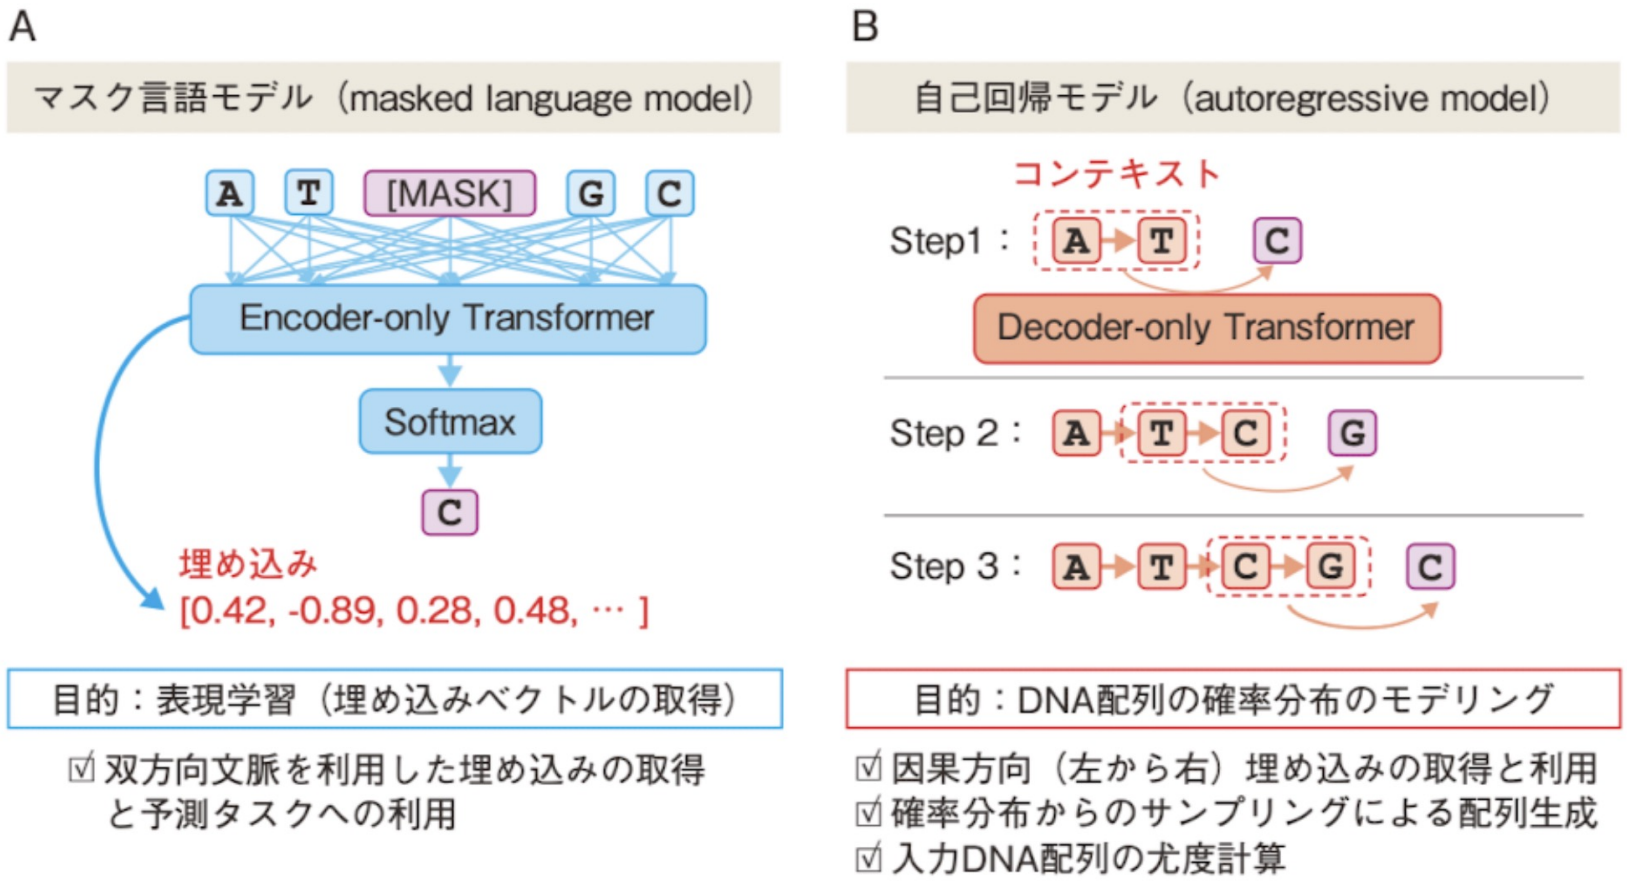
$$p_i(a) = \frac{\exp(z_{i,a})}{\sum_{b \in V} \exp(z_{i,b})}$$

V：候補となる文字などの語彙。
出力ヘッドgoutが候補のスコアz_iを計算。
softmaxで、和が1の確率に変える。
この出口で「どの文字が入るか」を予測する。

穴埋め型なら隠した位置、自己回帰型なら次の位置を予測する。

模式式。配列全体を平均する場合は特殊トークン・パディングを除く。出力ヘッドはモデルにより異なる。

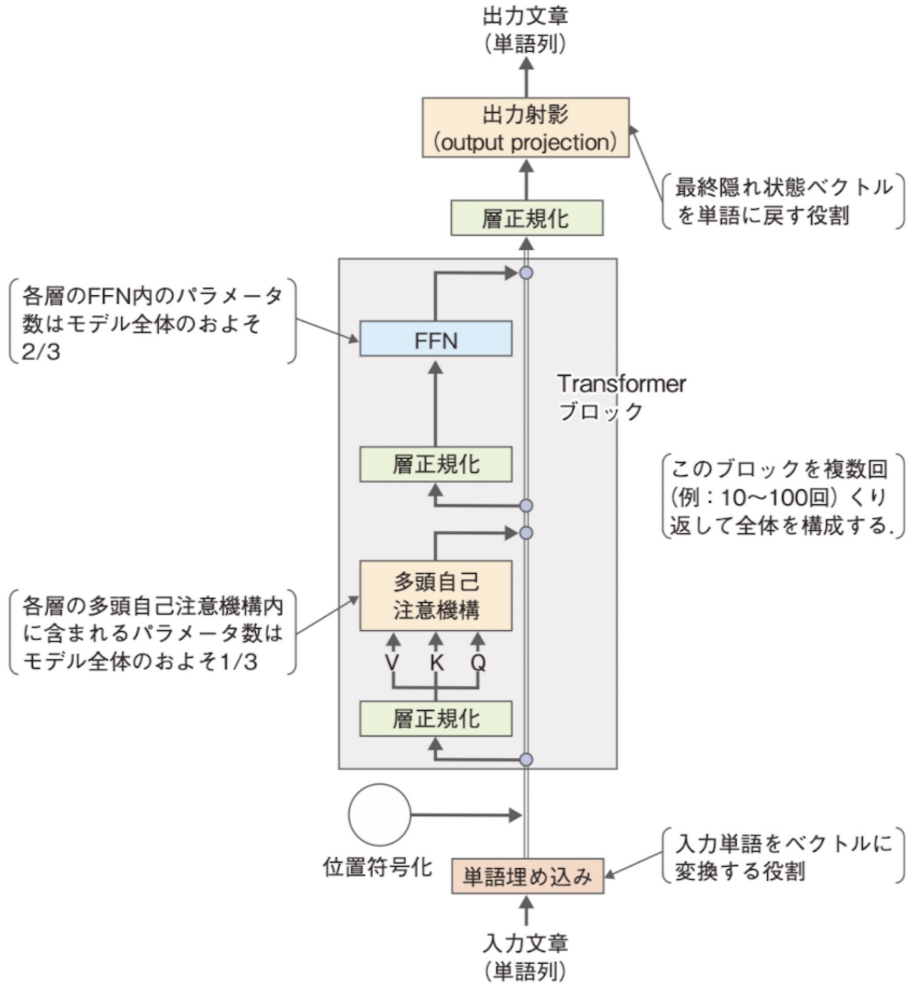
何を隠し、どの文字を当てるかを決める



左は穴埋め、右は次塩基予測。Evo 2は右の学習目標を使い、畳み込みとAttentionを組み合わせる。

東光一『実験医学』44(4), p.467, 図2 (2026) より抜粋。

Transformerを開くと、情報交換と特徴の更新がある



図の下から上へ読む（pre-norm型）

$$U = H + \mathrm{Attn}(\mathrm{LN}(H))$$

Attention：位置間の情報を混ぜる。
残差接続：入力Hを足し、情報を残す。

$$H_{\mathrm{next}} = U + \mathrm{FFN}(\mathrm{LN}(U))$$

FFN：各位置に同じ非線形変換を施す。
LN：各位置の特徴方向を正規化する。

複数層を通した表現 → 語彙のスコア → softmax → 候補の確率。

図のパラメータ比率は構成によって異なる。

鈴木潤『実験医学』44(4), p.463, 図3 (2026) より抜粋。右の式と補足は本教材による。

記号をベクトルに変換して計算する

入力は記号のID、計算は実数ベクトル

$$E \in \mathbb{R}^{|\mathcal{V}| \times d}, \qquad h_i^{(0)} = E[x_i] + P_i$$

Eの1行を記号IDで選ぶ。dは埋め込みの次元。P_iは加算型の位置情報の例。

$$H^{(0)} \in \mathbb{R}^{L \times d}$$

同じ記号は同じ初期埋め込みを持つが、各層で周囲の情報が加わり、位置ごとに異なる表現になる。

対象ごとに、語彙が変わる

自然言語：サブワードなど
DNA：A・C・G・T、または複数塩基
タンパク質：20種類の標準アミノ酸＋特殊記号

単純な行選択の例

$$E[A] = (0.2, -0.1), \quad E[C] = (0.7, 0.3)$$

$$x = (A, C, A) \Rightarrow H = \begin{pmatrix} 0.2 & -0.1 \\ 0.7 & 0.3 \\ 0.2 & -0.1 \end{pmatrix}$$

上の数値は説明用。位置情報を加える前の表現。

Vaswani et al., NeurIPS (2017), Figs. 1–2, arXiv:1706.03762 ／ BERT原著 §3

すべての語の組を、行と列で見る

太郎は花子に本を渡した。彼女はそれを読んだ。

行＝情報を集める位置（Query）　列＝参照する位置（Key・Value）　濃いマスほど重みが大きい

Query ↓	太郎は	花子に	本を	渡した。	彼女は	それを	読んだ。
太郎は	0.35	0.10	0.05	0.35	0.05	0.05	0.05
花子に	0.10	0.35	0.10	0.25	0.10	0.05	0.05
本を	0.05	0.10	0.35	0.25	0.05	0.10	0.10
渡した。	0.25	0.25	0.25	0.10	0.05	0.05	0.05
彼女は	0.05	**0.65**	0.05	0.05	0.10	0.05	0.05
それを	0.05	0.10	**0.60**	0.05	0.05	0.10	0.05
読んだ。	0.05	0.05	0.10	0.05	0.30	0.35	0.10

1マス＝位置の組

「彼女は」の行
×「花子に」の列
→ 重み 0.65

「それを」の行
×「本を」の列
→ 重み 0.60

各行の和は1。
行と列を交換しても
同じ値とは限らない。

各組のQとKからスコア → 行ごとのsoftmaxで重み → 各列のVを重み付きで足し合わせる。

説明用に手設定した1ヘッド・双方向の模式例。文節を単位とし、実モデルのトークン分割・実測値とは異なる。

アテンションは、位置ごとの情報を重み付きで集める

入力Hから、異なる三つの表を作る

$$Q = HW_Q, \quad K = HW_K, \quad V = HW_V$$

Q：探す情報　K：参照先の特徴　V：集める情報

d_k：QueryとKeyの次元数。

WQ・WK・WVは学習する重み。全位置で共有する。

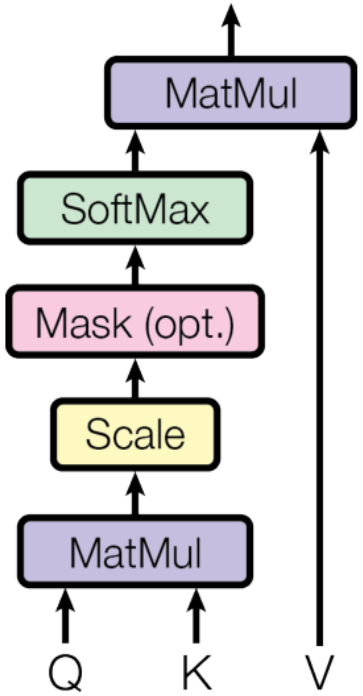
$$s_{ij} = \frac{q_i \cdot k_j}{\sqrt{d_k}}, \quad \alpha_{ij} = \frac{e^{s_{ij}}}{\sum_{r=1}^{L} e^{s_{ir}}}$$

$$o_i = \sum_{j=1}^{L} \alpha_{ij} v_j$$

α_{ij}は「どの位置から集めるか」の重み。

候補文字の確率とは、正規化する軸が異なる。

Scaled Dot-Product Attention



原著の計算図：下から上へ読む。Maskは必要な場合に加える。

Vaswani et al., NeurIPS (2017), Figs. 1–2, arXiv:1706.03762（Fig. 2左を切り出し）

3か所への重みを計算し、Valueを足す

位置1と、三つのKeyの一致度を比べる

$$s = (0.707,\ 0,\ 0.707)$$

$$Z = e^{0.707} + e^{0} + e^{0.707} \simeq 5.056$$

$$\alpha = \frac{(e^{0.707},\ 1,\ e^{0.707})}{Z} \simeq (0.401,\ 0.198,\ 0.401)$$

$$o_1 = 0.401(1, 0) + 0.198(0, 2) + 0.401(2, 1)$$

$$o_1 \simeq (1.203,\ 0.797)$$

出力は新しい特徴ベクトル。
まだ候補アミノ酸の確率には変換していない。

3つの位置から、情報を集める

$$q = (1, 0), \quad K = \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{pmatrix}$$

$$s = qK^T/\sqrt{2} = (0.707, 0, 0.707)$$

$$\alpha = \mathrm{softmax}(s) = (0.401, 0.198, 0.401)$$

$$V = \begin{pmatrix} 1 & 0 \\ 0 & 2 \\ 2 & 1 \end{pmatrix}, \quad o = \alpha V = (1.203, 0.797)$$

内積 → 確率の重み → Valueの加重和

Vaswani et al., NeurIPS (2017), Figs. 1–2, arXiv:1706.03762 ／ 数値例とアニメーション：教材用に計算

因果マスクはsoftmaxの前に加える

$$A = \mathrm{softmax}_{\mathrm{row}}\left(QK^T/\sqrt{d_k} + M\right), \quad M_{ij} = \begin{cases} 0 & j \le i \\ -\infty & j > i \end{cases}$$

$s = (0, 0.7071, 0.7071)$

$s + M = (0, 0.7071, -\infty)$

$\alpha_{\mathrm{both}} = (0.1978, 0.4011, 0.4011)$

$\alpha_{\mathrm{causal}} = (0.3302, 0.6698, 0)$

穴埋め型：対象の文字を[MASK]に替え、左右を参照する。BERT・ESM-2で使う。

自己回帰型：位置iから次の文字を予測する。未来は因果マスクで参照を止める。GPT・Evo 2で使う。

複数の関係と、配列の順番を表す

異なる射影で関係を並列に捉える

$$\mathrm{head}_r = \mathrm{Attn}(HW_Q^r, HW_K^r, HW_V^r)$$

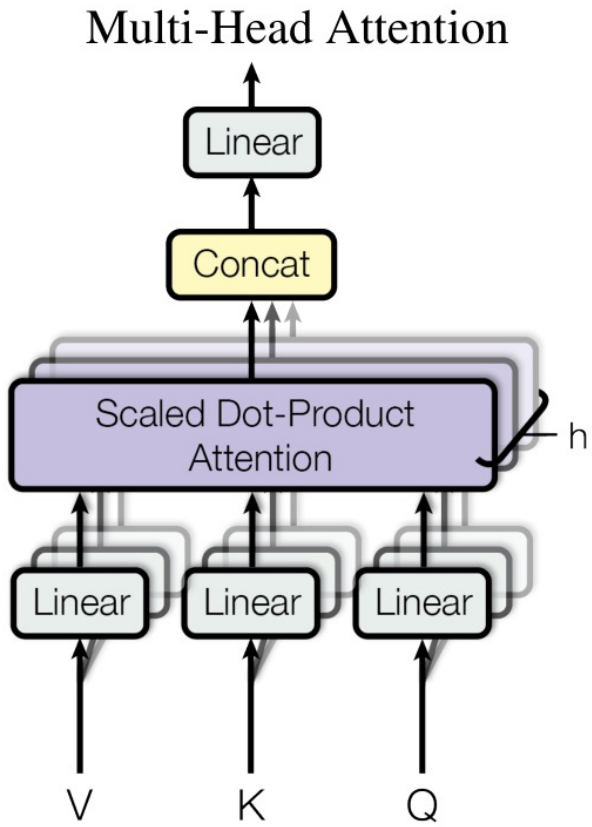
$$\mathrm{MHA}(H) = \mathrm{Concat}(\mathrm{head}_1, \ldots, \mathrm{head}_m)W_O$$

各ヘッドの重みは独立に学習する。役割は人間があらかじめ割り当てない。

位置がなければ、順序を区別しにくい

$$\tilde{q}_i = R_i q_i, \quad \tilde{k}_j = R_j k_j$$

回転型位置表現では、内積に相対位置が反映される。ESM-2でも使用。



複数ヘッドの出力を連結して、線形変換する。

Vaswani et al., NeurIPS (2017), Figs. 1–2, arXiv:1706.03762（Fig. 2右）／ Su et al., Neurocomputing (2024), doi:10.1016/j.neucom.2023.127063

予測が正解に近づくよう、モデルの重みを学習する

穴埋め型：隠した位置を当てる

見せる入力：… I E N [MASK] K A …

正解：隠す前の文字

$$\mathcal{L}_{\text{mask}}(\theta) = -\sum_{i \in M} \log p_\theta(x_i \mid \tilde{x})$$

Mは隠した位置、x̃は一部を隠した配列。

左右の文脈を使って正解を予測する。

各位置の穴埋め確率の積を、そのまま

同じ意味の配列確率とは呼ばない。

自己回帰型：次の位置を当てる

見せる入力：$x_1, \cdots, x_{i-1}$

正解：次の文字x_i（未来は見せない）

$$p_\theta(x) = \prod_{i=1}^{L} p_\theta(x_i \mid x_{<i})$$

$$\mathcal{L}_{\text{AR}}(\theta) = -\sum_{i=1}^{L} \log p_\theta(x_i \mid x_{<i})$$

条件付き確率の積で配列全体の確率を表す。

正解は元の配列自身から得られる。

正解の確率が0.1 → 0.8になると、損失−log pは2.30 → 0.22へ低下する。

Devlin et al. (2019); Radford et al. (2018)。θ：埋め込み・Attention・FFN・出力ヘッドなどの学習する重み。

確率から1文字を選び、次の入力へ加える

学習と生成で、同じ条件付き確率を使う

$$\mathcal{L}_{AR} = -\sum_i \log p_\theta(x_i \mid x_{<i})$$

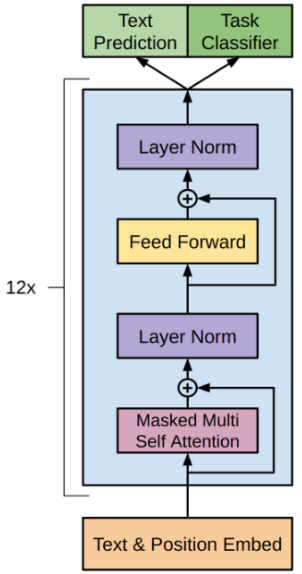
学習：正解の接頭辞と因果マスクで並列計算。
生成：出力を次の入力へ足し、逐次計算。

$$x_{t+1} \sim p_\theta(\cdot \mid x_{1:t})$$

温度は生成時の分布を変える

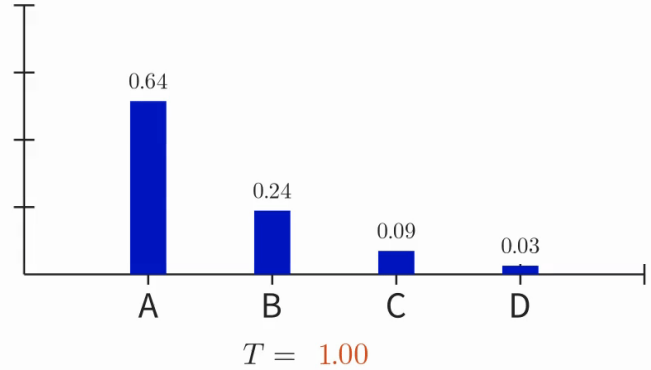
$$p_j(T) = \frac{\exp(a_j/T)}{\sum_k \exp(a_k/T)}$$

Tを下げると高スコア候補へ集中する。学習済みの重みは変えない。



温度で候補の確率が変わる

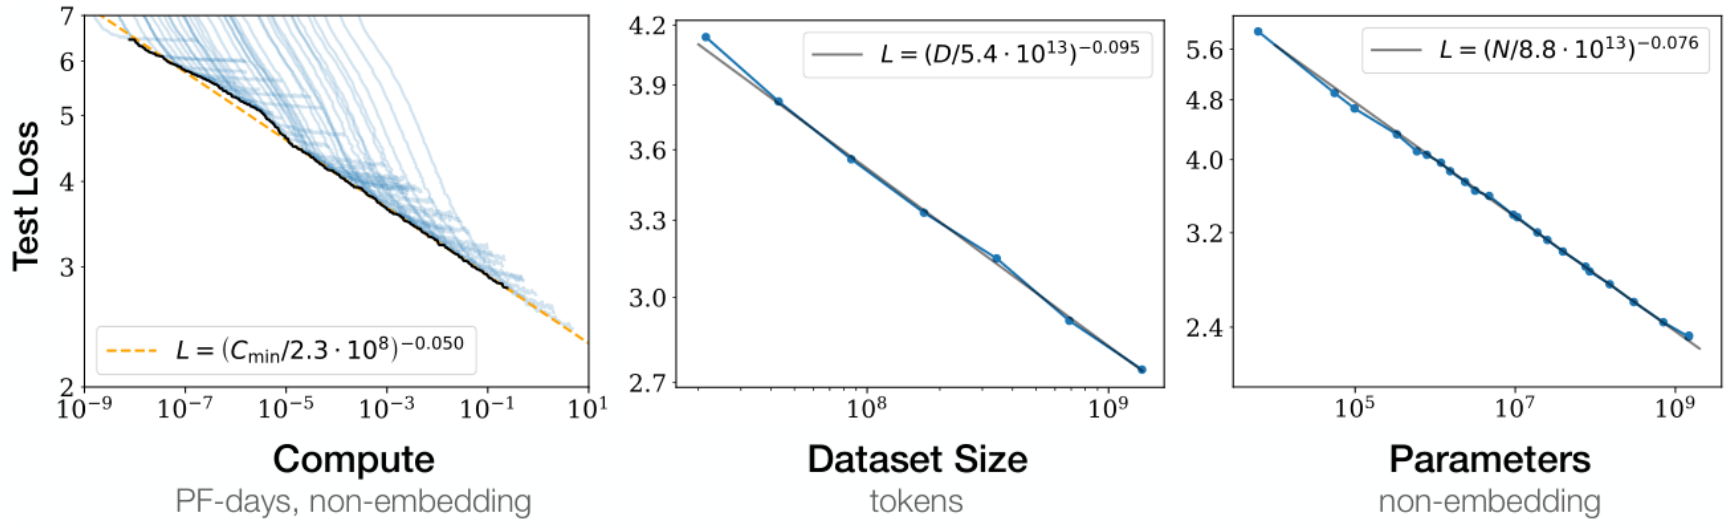
$$p_i(T) = \frac{\exp(z_i/T)}{\sum_j \exp(z_j/T)},\ z = (2, 1, 0, -1)$$



模式例：低温では高スコアの候補に集中する

Radford et al. (2018), Fig. 1, Improving Language Understanding by Generative Pre-Training（Fig. 1左）／確率分布は説明用の計算例

規模を増やすと予測損失はどう変わるか

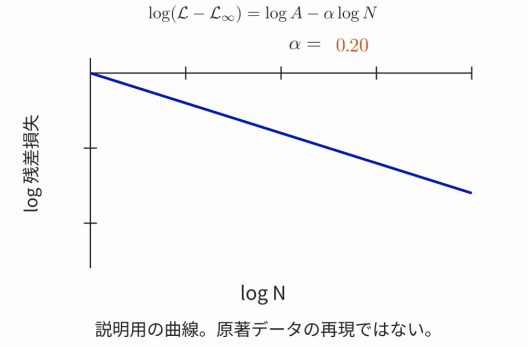


$$\mathcal{L}(N) \simeq \mathcal{L}_\infty + AN^{-\alpha} \qquad \log(\mathcal{L} - \mathcal{L}_\infty) \simeq \log A - \alpha \log N$$

N：パラメータ数。A：係数、α：減少の指数、L∞：損失の漸近値。条件を限った経験則で、データ量・計算量も性能を制約する。

文字の予測が改善すると、生物学に何が使えるか。ESM-2で、確率・構造・物性の予測へ進む。

両対数軸では、べき則の指数が傾きになる



説明用の曲線。原著データの再現ではない。

Kaplan et al. (2020), Fig. 1, arXiv:2001.08361 ／ Hoffmann et al. (2022), arXiv:2203.15556

隠した位置の出力から、候補の確率を得る

ESM-2：大量のタンパク質配列で穴埋めを学習。演習では6層・約800万パラメータのモデルを使う。

入力トークン

<cls>, M, Q, I, …
23番目I → <mask>

→

6層のESM-2

全位置でAttention＋FFN
各位置320次元

→

出力層

位置23のlogits
語彙方向にsoftmax

$$p(a \mid \tilde{x}) = \frac{\exp z_{23,a}}{\sum_{b \in \mathcal{V}} \exp z_{23,b}}$$

演習はesm2_t6_8M_UR50D（約800万パラメータ）。候補は全語彙で正規化した上位5個を表示し、5個だけで再正規化しない。特殊トークンを含む語彙と20種類のアミノ酸は別である。

配列表現から、残基間の接触を予測する

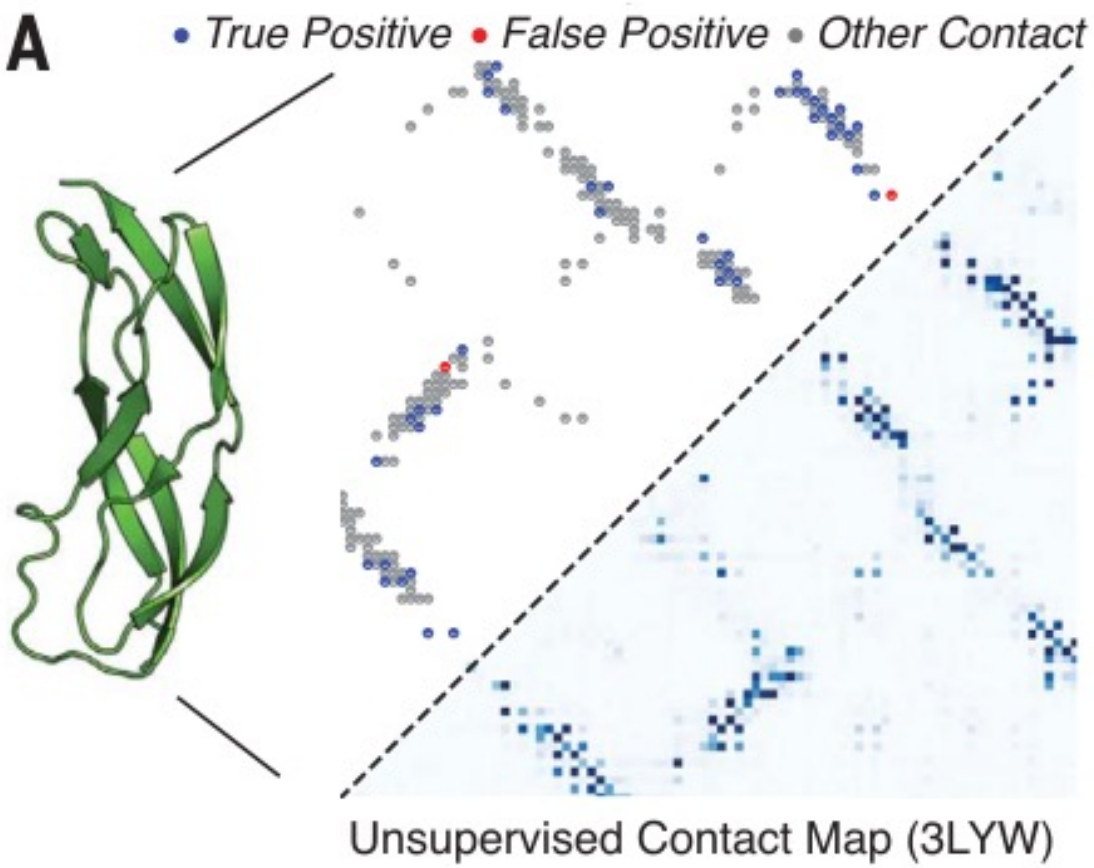
Attentionを組み合わせて接触を読み出す

$$\hat{c}_{ij} = \sigma\left(b + \sum_{\ell,r} w_{\ell r} \tilde{A}_{ij}^{\ell r}\right)$$

複数層・ヘッドのAttentionを対称化・補正し、接触予測用の読み出しに用いる。Attention自体が距離や接触確率を表すわけではない。

右図：予測と実際の接触を残基対ごとに比較。青は正しく予測した接触、赤は誤った予測。

配列による事前学習と、接触を読み出すための学習・評価は区別する。



Lin et al., Science 379, 1123–1130 (2023), doi:10.1126/science.ade2574（Fig. 1A）

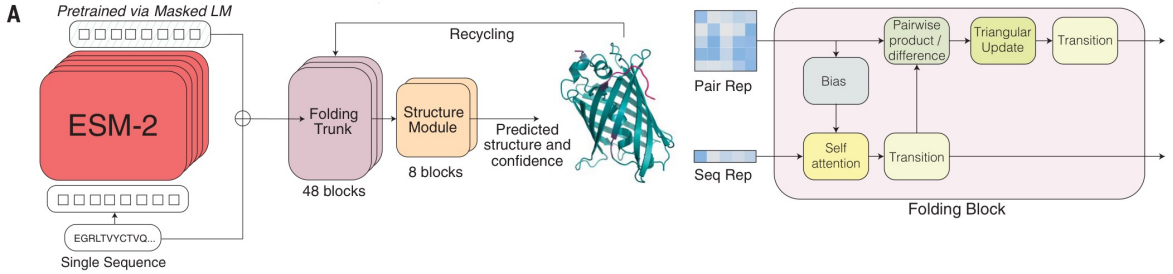
ESMFoldはESM-2の表現から座標を予測する

単一配列から構造へ

ESM-2 → 配列・残基対の表現 → folding trunk → 構造モジュール → 原子座標と信頼度。

多数の近縁配列の整列（MSA）を入力として要求しない。構造予測部は、構造データを使って学習する。

pLDDT：局所的な構造の信頼度の予測。
実際の正確さや、溶液中の揺らぎそのものではない。



成功と失敗の両方を見る

原著のT1057：ESMFoldのTM-score 0.98。
T1074：0.64、AlphaFold 2は0.93。

TM-scoreは正解構造との一致を測る。モデルが返す信頼度とは異なる。

ESM Metagenomic Atlasでは、メタゲノム由来の大量の配列へ展開された。

Lin et al., Science 379, 1123–1130 (2023), doi:10.1126/science.ade2574（Fig. 2A、Fig. 2D/Eの数値）

物性の回帰と、変異の確率スコアは異なる

実測値を学習する：例は融解温度

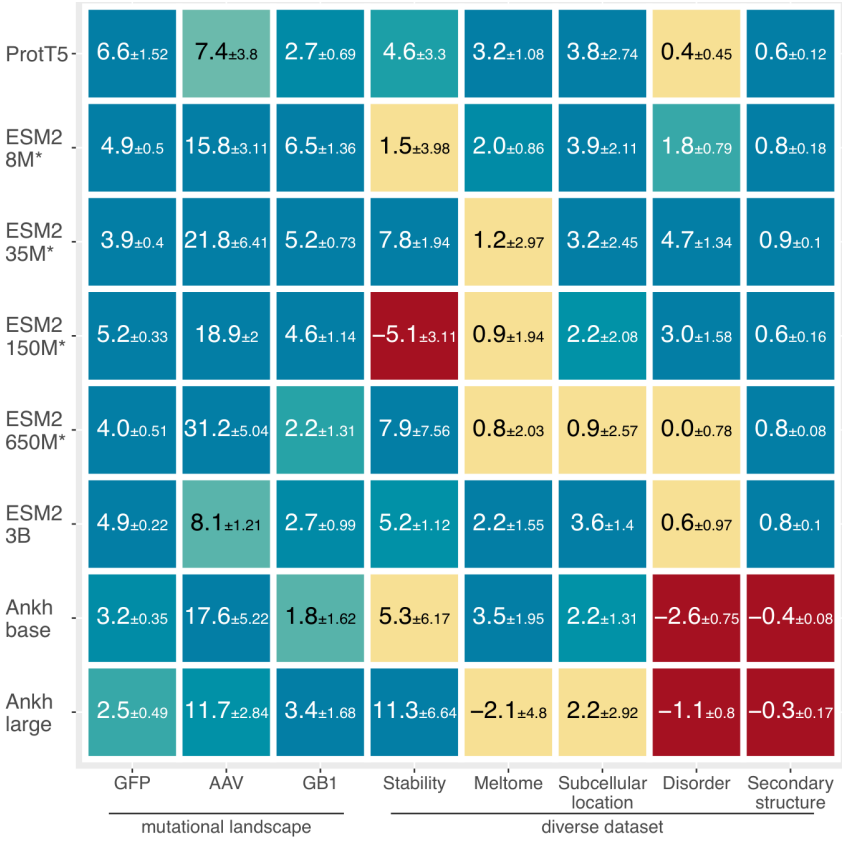
$$\bar{h} = \frac{1}{L}\sum_i h_i, \qquad \hat{T}_m = g_\phi(\bar{h})$$

ESMを固定して予測器φを学ぶ方法と、
ESM本体も更新する追加学習を区別する。

実測ラベルを使わず、確率を比べる

$$s_i = \log \frac{p_\theta(x_i^{\mathrm{mut}} \mid x_{\setminus i})}{p_\theta(x_i^{\mathrm{wt}} \mid x_{\setminus i})}$$

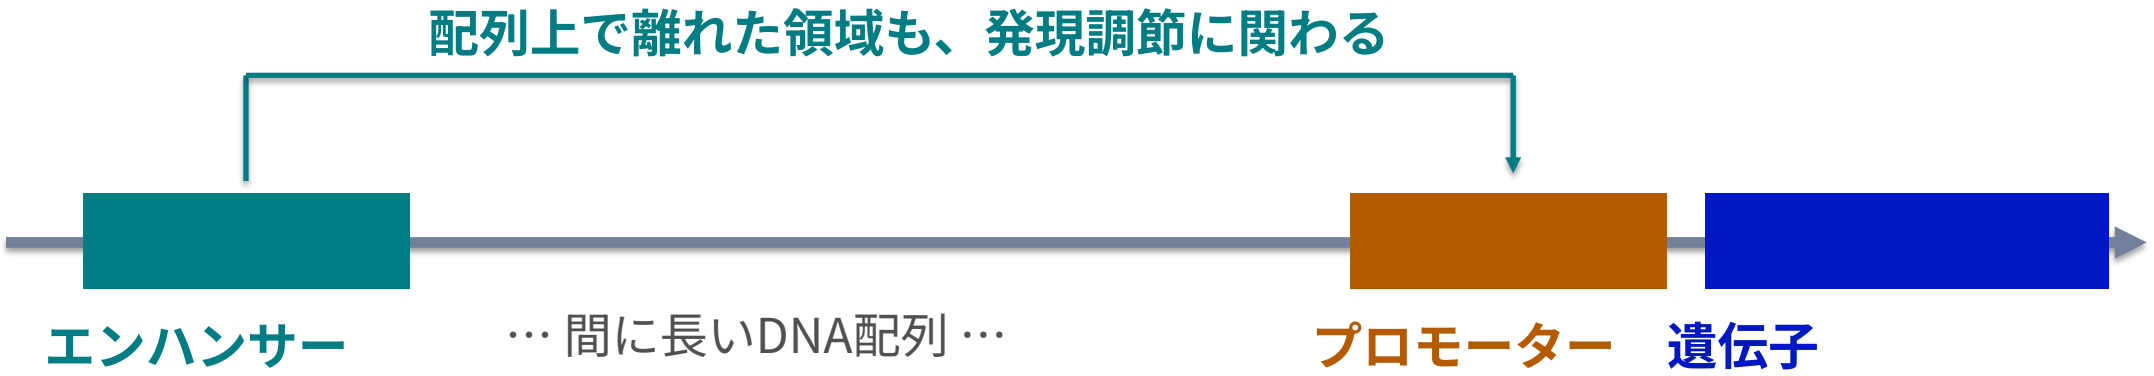
同じ位置を隠して比較する無次元のスコア。
TmやΔΔGとは別の量で、実験と照合する。



各セルは追加学習による性能の差。列ごとに指標が異なる。

Schmirler et al., Nat Commun (2024), Fig. 1, doi:10.1038/s41467-024-51844-2 ／ Meier et al., NeurIPS (2021)

DNAでは、遠くの配列も発現の調節に関わる



用語と役割

転写：DNAの情報からRNAを作る。
プロモーター：転写が始まる付近の領域。
エンハンサー：発現の調節に関わる領域。

DNAで長い文脈を使う理由

近くの短い並びだけでは、調節に関わる配列を見落とすことがある。
同じ配列でも、細胞の種類や状態によって働きが変わる。

DNAは細胞内で折り畳まれ、配列上で遠い領域同士が空間で近づくこともある。

参考：田宮元・東光一『実験医学』44(4), 453–458, 465–471 (2026)。図は位置関係の模式図で、縮尺は一定ではない。

Evo 2は多様な生物の配列を学習する

一塩基を一つのトークンとして扱う

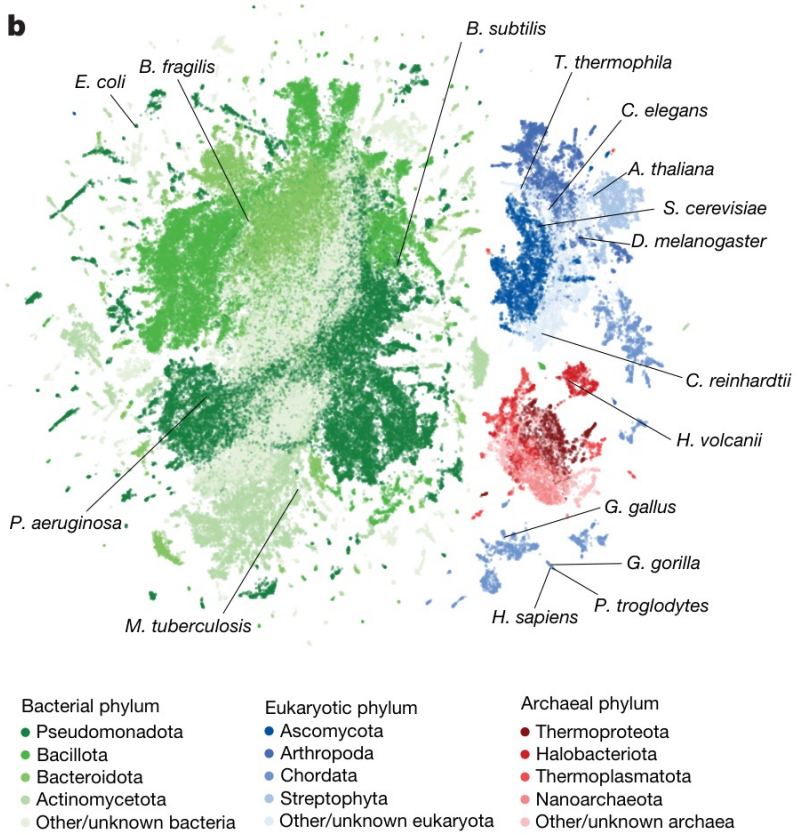
OpenGenome2：細菌・古細菌・真核生物・バクテリオファージ等のDNA。約8.8兆塩基を超えるデータを整理。

7B／40Bモデル：Bは10億パラメータ。40B版では学習中に約9.3兆トークンを使用。データ量と延べ学習量は別。

$$p_\theta(x_i \mid x_{<i}), \quad x_i \in \{A, C, G, T, ...\}$$

最大約100万塩基から長距離の関係も学ぶ。

真核生物に感染するウイルスは学習から除外。



点はゲノム。短い塩基並びの頻度に基づくUMAPで、モデル内部表現ではない。

Brixi et al., Nature 652, 1349–1361 (2026), doi:10.1038/s41586-026-10176-5（Fig. 1b）

Evo 2は畳み込みとAttentionを組み合わせる

長い配列を扱う計算上の工夫

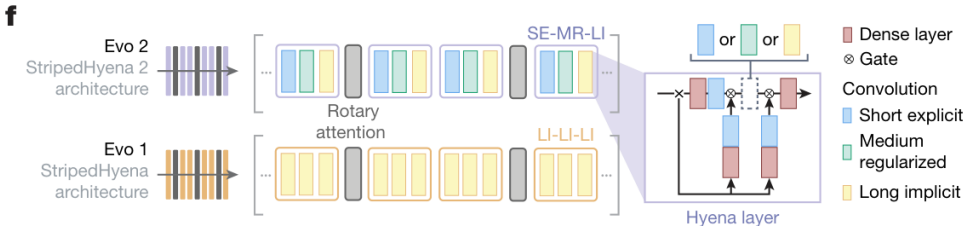
Attention: $QK^T \in \mathbb{R}^{L\times L}$

すべての位置の組を扱うAttentionの計算は配列長Lの二乗で増える。

$$u_t = b_t \odot v_t, \quad y_t = g_t \odot \sum_{\tau=0}^{t} h_\tau u_{t-\tau}$$

b,v,gは入力から作る。⊙は要素ごとの積、hτは遅れτのフィルタ係数。ゲート付き畳み込みの模式形。

短距離（明示的）・中距離（正則化）・長距離（暗黙的）のフィルタをAttentionと組み合わせる。



畳み込み：近傍を同じ重みで集める

$$y_t = 0.5u_t + 0.3u_{t-1} + 0.2u_{t-2}$$

入力 u | 1 | 0 | 2 | 1 | 3

$t = 0:\quad 0.5 \times 1 = 0.5$

出力 y

模式例：左端の外側は0。Hyenaの一部を単純化。

$$y = (0.5,\ 0.3,\ 1.2,\ 1.1,\ 2.2)$$

Brixi et al., Nature 652, 1349–1361 (2026), doi:10.1038/s41586-026-10176-5（Fig. 1f）／Ku et al. (2025)，§2, arXiv:2503.01868

Evo 2の確率から変異の影響を推定する

進化の制約に反する変異は低確率か

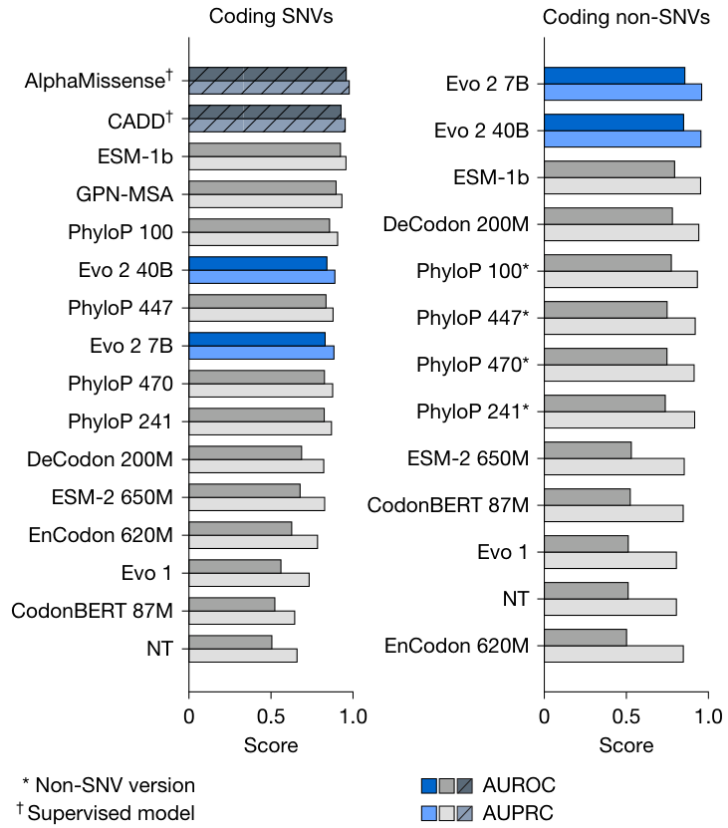
$$\ell(x) = \sum_i \log p_\theta(x_i \mid x_{<i})$$

$$\Delta\ell = \ell(x_{alt}) - \ell(x_{ref})$$

負の値は変異配列がモデルにとって起こりにくいことを示す。実際の評価では、評価する領域・配列長・文脈に応じてスコアの集約方法を選ぶ。

追加の変異ラベルで重みを学習せずに予測する方法をzero-shotと呼ぶ。

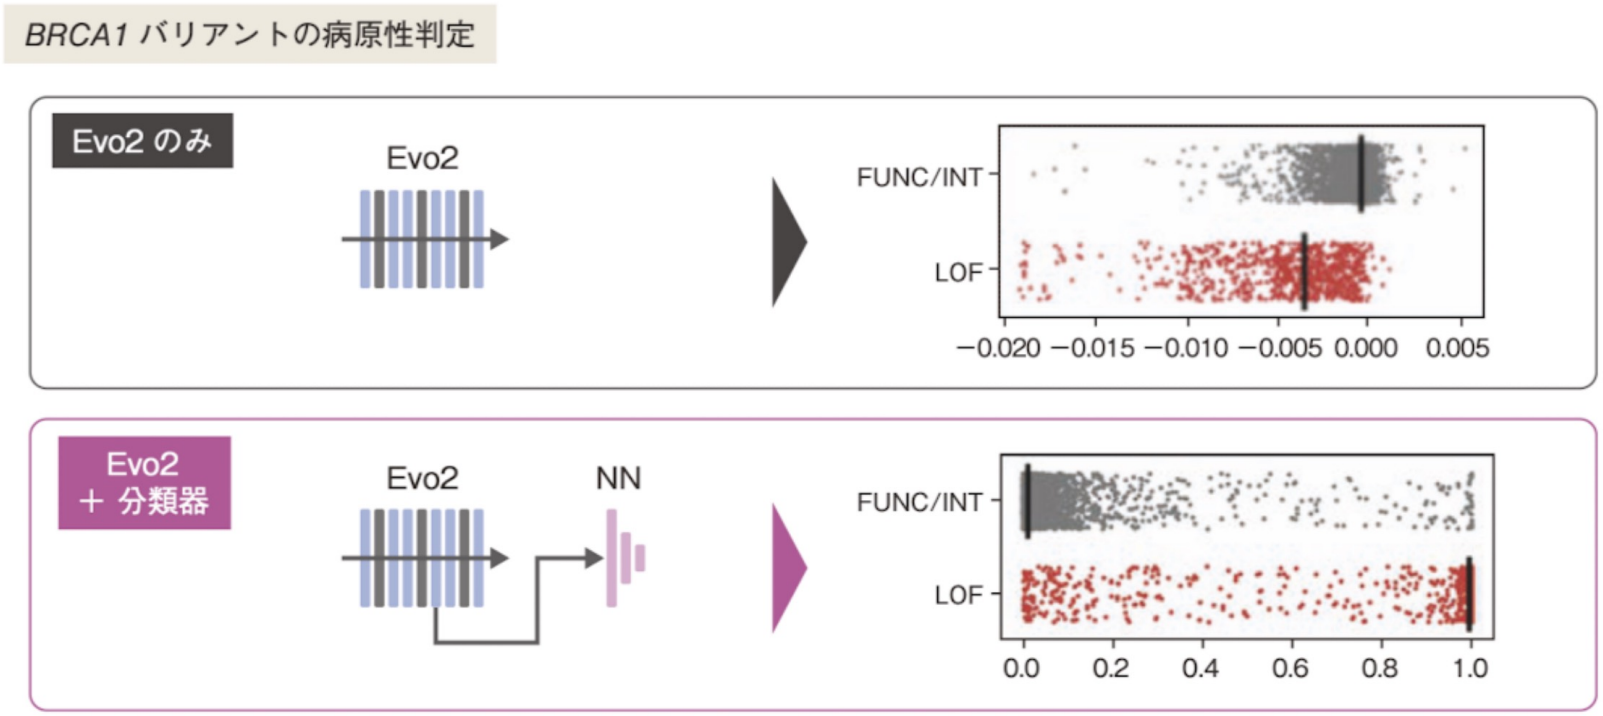
変異の評価は実測ラベルとの対応で確かめる。配列尤度は病原性や自由エネルギーそのものではない。



分類性能を比較した原著図。青はEvo 2、灰は比較手法。

Brixi et al., Nature 652, 1349–1361 (2026), doi:10.1038/s41586-026-10176-5（Fig. 3bの結果を切り出し）

配列のスコアと、分類器の出力を区別する



上段と下段は異なる尺度。下段の0〜1は配列尤度ではない。

実験で測った機能の分類と、患者で病原性を判断することは区別する。

小針靖子・高山順『実験医学』44(4), p.482, 図3 (2026) より抜粋。

BRCA1の変異

DNA修復に関わる遺伝子。
機能保持／中間（FUNC/INT）と機能喪失（LOF）を分類。

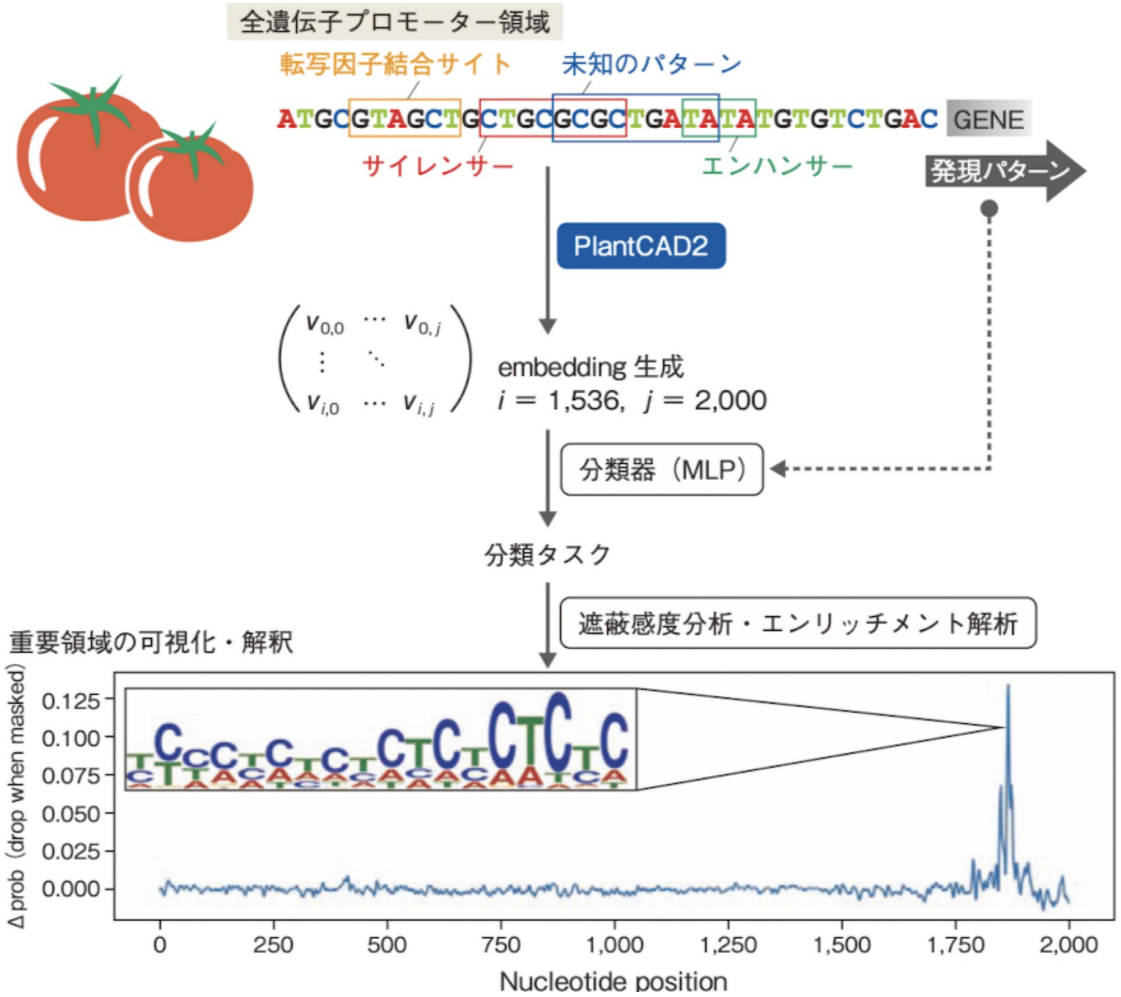
上：配列のスコア

変異のラベルを使う
追加学習なしで比較する。

下：分類器の出力

変異のラベルで分類器を学ぶ。
独立したデータで評価する。

植物でも、埋め込みを発現の分類に使える



① 入力と事前学習

植物のDNAで学んだモデルへ、
遺伝子の前の調節配列を入れる。
図は2,000塩基 × 1,536次元の表現。

② 発現の分類

各位置の埋め込みを取り出す。
実測した発現パターンで分類器を学ぶ。

③ 予測の根拠を調べる

一部を隠したときの予測の変化を見る。
ピークは、モデルが依存する領域を示す。

重要領域の候補は、実験で確かめる。

赤木剛士『実験医学』44(4), p.499, 図1 (2026) より抜粋。図中のMLPは多層のニューラルネットワーク。

AlphaGenomeはDNAから分子特性を予測する

約100万塩基から、多種類の測定値へ

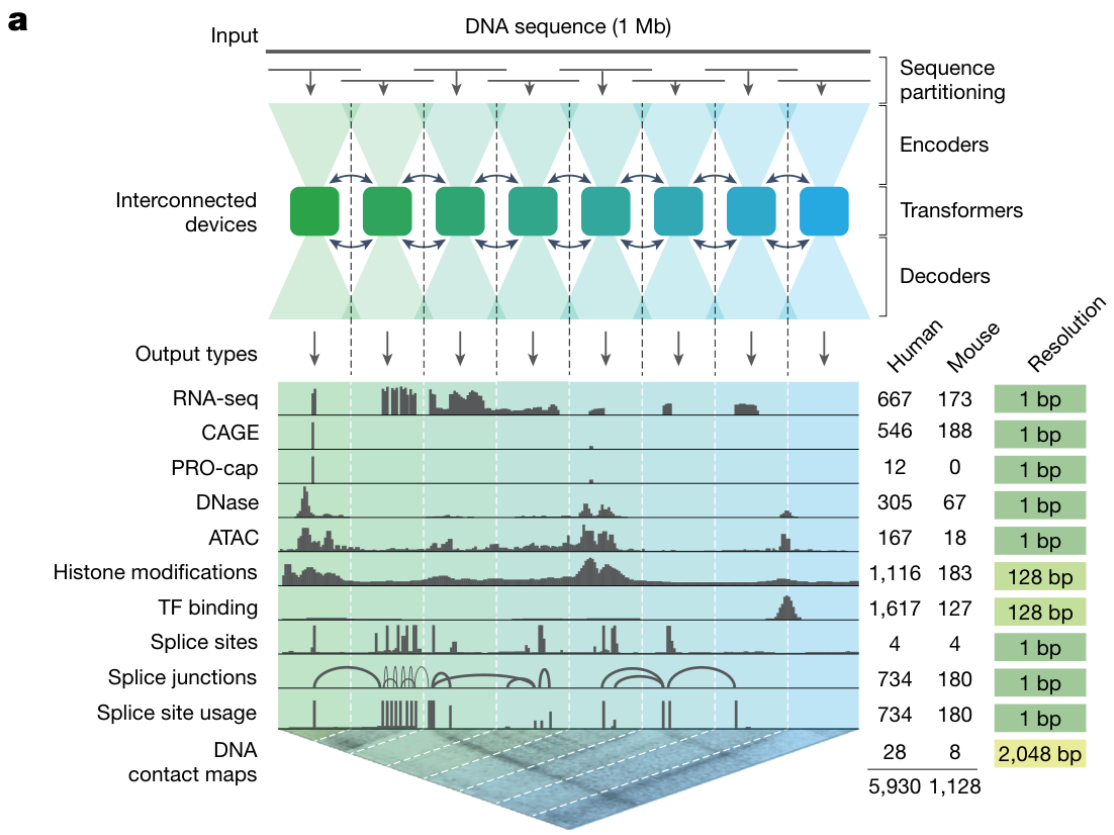
ヒト・マウスの配列から、発現、クロマチンの開きやすさ、転写因子結合、スプライシング、接触などを予測する。

畳み込みで圧縮 → Transformerで遠距離の情報を交換 → 解像度を戻し、測定項目別の出力へ。

$$\hat{y}_k = f_{\theta,k}(x), \quad \mathcal{L} = \sum_k \lambda_k \mathcal{L}_k(\hat{y}_k, y_k)$$

$$\Delta f_k = f_{\theta,k}(x_{alt}) - f_{\theta,k}(x_{ref})$$

同じ周辺配列で変異前後を比較する。次の塩基を生成するための損失ではない。



原著Fig. 1a。出力ごとに対象と解像度が異なる。

Avsec et al., Nature 649, 1206–1218 (2026), Fig. 1a, doi:10.1038/s41586-025-10014-0

生成ゲノムから、機能するファージが得られた

研究の問い：ゲノム全体でも機能するか

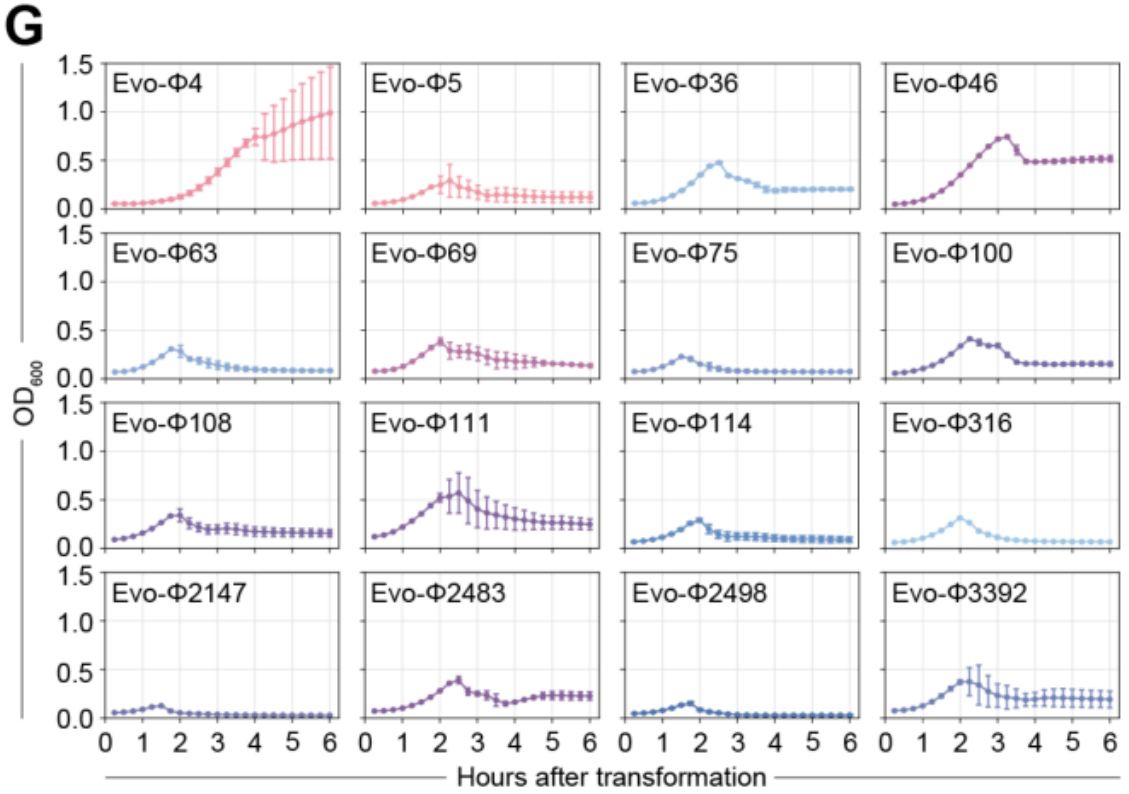
KingらはEvo 1・Evo 2で候補ゲノムを生成。
選抜302候補 → 試験285候補 → 機能した16候補。

右図：細菌の増殖曲線。濁度（OD600）の低下や増加の抑制からファージの機能を評価する。

この結果から分かる範囲

試験した候補の16/285 ≈ 5.6%が機能した。
選抜後の割合で、無作為生成の成功率ではない。

ゲノムを生成できることと、機能することは別。
図は2025年preprint版（2026年Science掲載）。



縦軸は細菌培養液の濁度。ファージの個体数や競争割合ではない。

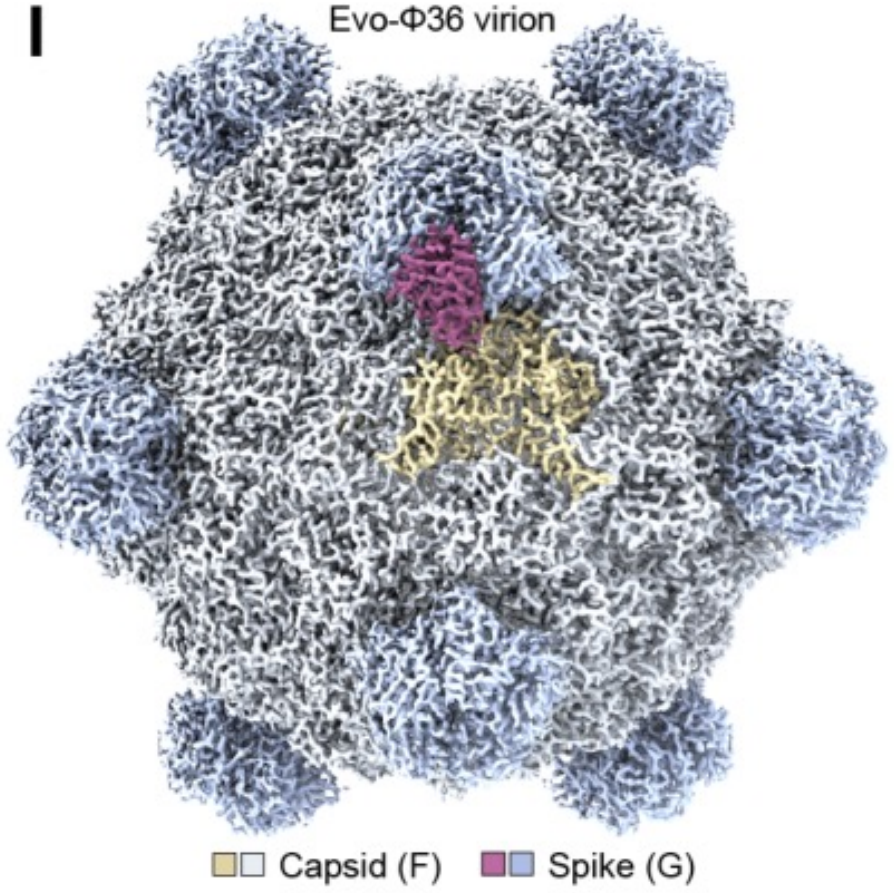
King et al., bioRxiv v1 (2025), Fig. 3G, doi:10.1101/2025.09.12.675911 ／ Science (2026), doi:10.1126/science.aec2657

生成したゲノムから、ファージ粒子ができた

生成したゲノムから得られた
ファージ粒子の一例：Evo-Φ36。

cryo-EMで再構成した粒子の密度図。
殻（カプシドF）と
突起（スパイクG）が見える。

前ページ：細菌への感染機能を確認。
このページ：粒子の立体構造を確認。



King et al., bioRxiv v1 (2025), Fig. 4I · doi:10.1101/2025.09.12.675911

モデルの予測と、実験で確かめた結果を区別する

例：あるDNA領域が、遺伝子の発現量に関係するかを調べる。

① アテンションを見る

重みが大きい位置ほど、
その計算で情報を強く集める。
細胞での働きは別に調べる。

0.1	0.6	0.3
0.4	0.2	0.4
0.2	0.3	0.5

② 入力を変えて計算する

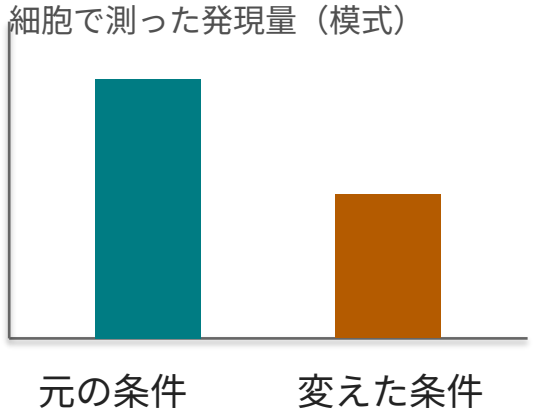
注目した領域を隠すと、
予測した発現量が低下した。
モデルがその領域に依存する。



棒の長さ：モデルが予測した発現量

③ 実験で確かめる

その領域を変えた条件と
元の条件で発現量を測る。
細胞で起こる変化と照合する。



①は内部の計算、②は予測の依存先、③は実際の生物の変化を示す。

参考：中根孝文『実験医学』44(4), 472–478 (2026)。図と数値は説明用で、実測ではない。

まとめ｜冒頭の三つの目標への答え

同じ配列表現を、三つの目的へ使い分ける

共通の計算：配列 → 各位置のベクトル → 周囲の情報を含むベクトル

Transformerでは、アテンションで他の位置から情報を集め、FFNで各位置の特徴を変換する。

1　隠した文字・次の文字を予測する

… I E N [MASK] K A … → 候補ごとのスコア → アミノ酸候補と確率

出力ヘッドとsoftmaxを使う。ESM-2演習で、この穴埋めを確かめる。

2　配列の性質を予測する

元の配列・変異配列 → 内部ベクトル → 分類器 → 機能喪失の予測

BRCA1の例：実験で得た機能ラベルを、分類器の正解として学習する。

3　新しい配列を生成する

先頭の配列 → 次の文字の確率 → 文字を一つ選ぶ → 末尾へ追加

自己回帰型で繰り返すと候補配列ができる。生成後の機能は実験で確かめる。

ベクトルを計算する目的は、候補の予測・性質の予測・配列の生成につなげること。

観察・演習

操作する値と、変化を見る場所を対応させる

演習の目的：周囲の情報が、内部の計算と穴埋め予測をどう変えるかを見る。

1　アテンションの模型：情報の集め方を見る

操作：Query・温度・因果マスク・Valueを、一つずつ変える。

表示：位置どうしの重みの表と、Valueを足した出力ベクトル。

重みが同じでも、Valueを変えると出力は変わる。模型のQ・K・Vは手設定。

2　ESM-2の穴埋め：文字の候補を見る

操作：隠す残基番号を12・23・44・66から選ぶ。

表示：Pythonで再計算した候補アミノ酸と、その確率。

ここで比べるのは文字の候補確率。模型のアテンションの重みとは別の値。

3　周囲の配列を比較：文脈の影響を見る

比較：元の配列と、周囲だけを並べ替えた配列を同じ位置で予測する。

表示：隠す前の文字とアミノ酸組成を保ち、候補の順位・確率を比べる。

材料の種類と数が同じでも、並ぶ順序が変わると予測が変わり得る。

WebClass「04_演習」→ Colabで全セルを実行。20分・採点／提出なし。

モデル取得が難しいときは、同じ画面の「保存済みの実計算」を選ぶ。

本編で気になった点から、補足を読む

計算の仕組みを確かめたい

35–36ページ：FFN・LayerNormと、原著Transformer。
各位置の特徴をどう変換するか、値の大きさをどう整えるかを式で確認。
37–40ページ：自然言語への応用、計算量、タンパク質モデル、Evo 2の学習。

内部ベクトルに何が表れているか知りたい

41–43ページ：SAE・InterPLM・ナノボディの熱安定性。
SAEは内部ベクトルを少数の特徴に分解するモデル。
どの残基や構造で特徴が強くなるかを、生物学的な情報と照合する。

研究結果と出典を詳しく確かめたい

44–45ページ：生成ファージの配列確認と、自然配列との違い。
46–50ページ：原著論文、ESM-2の規模と損失、今回使った書籍の出典。
本編の結果が、どの図・比較・文献に基づくかをたどれる。

位置の情報交換と、特徴の変換を分ける

FFN：各位置で同じ非線形変換

$$\mathrm{FFN}(h_i) = \phi(h_i W_1 + b_1)W_2 + b_2$$

W1はd×dff、W2はdff×d。中間次元で非線形変換し、残差加算のためd次元へ戻す。

LayerNorm：1位置の特徴成分を正規化

$$\mu_i = \frac{1}{d}\sum_{a=1}^{d} h_{ia}, \quad \sigma_i^2 = \frac{1}{d}\sum_{a=1}^{d}(h_{ia} - \mu_i)^2$$

$$\mathrm{LN}(h_i)_a = \gamma_a \frac{h_{ia} - \mu_i}{\sqrt{\sigma_i^2 + \epsilon}} + \beta_a$$

位置ごとに独立した計算

位置 1	→	同じFFN	→	出力 1
位置 2	→	同じFFN	→	出力 2
位置 3	→	同じFFN	→	出力 3

φ：原著はReLU、ESM-2はGELU

LNも各行のd成分から平均と分散を求める。配列の全位置をまとめて平均する操作ではない。

γ・β：学習する係数
ε：数値を安定させる小さな定数

ESM-2のpre-norm：u＝H＋Attention(LN(H))、Hnext＝u＋FFN(LN(u))。位置間で情報を混ぜるのはAttention。

Transformerは情報の交換と変換を重ねる

原著のEncoder：post-normの形

$$U = \mathrm{LN}\big(H + \mathrm{MHA}(H)\big)$$

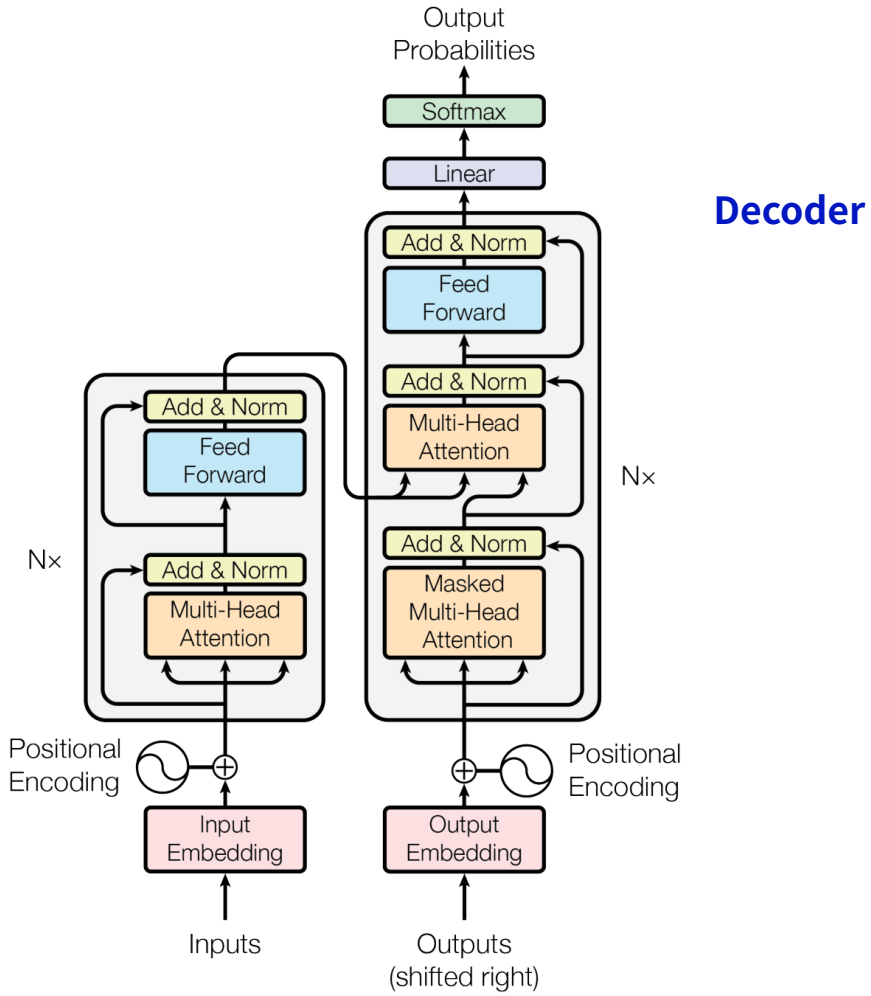
$$H' = \mathrm{LN}\big(U + \mathrm{FFN}(U)\big)$$

$$\mathrm{FFN}(u) = \sigma(uW_1 + b_1)W_2 + b_2$$

Attention：位置間で情報を交換。
FFN：各位置の特徴を非線形に変換。
残差接続：元の情報を足して残す。

LNは特徴方向の平均・分散を使う正規化。実装によって正規化の順序や活性化関数が異なる。

原著は翻訳用のEncoder–Decoder。BERT・GPTは一部の構成を使う。



Vaswani et al., NeurIPS (2017), Figs. 1–2, arXiv:1706.03762（Fig. 1を転載）

自然言語では、学習した表現を課題へ適応する

用途と適応方法を分けて考える

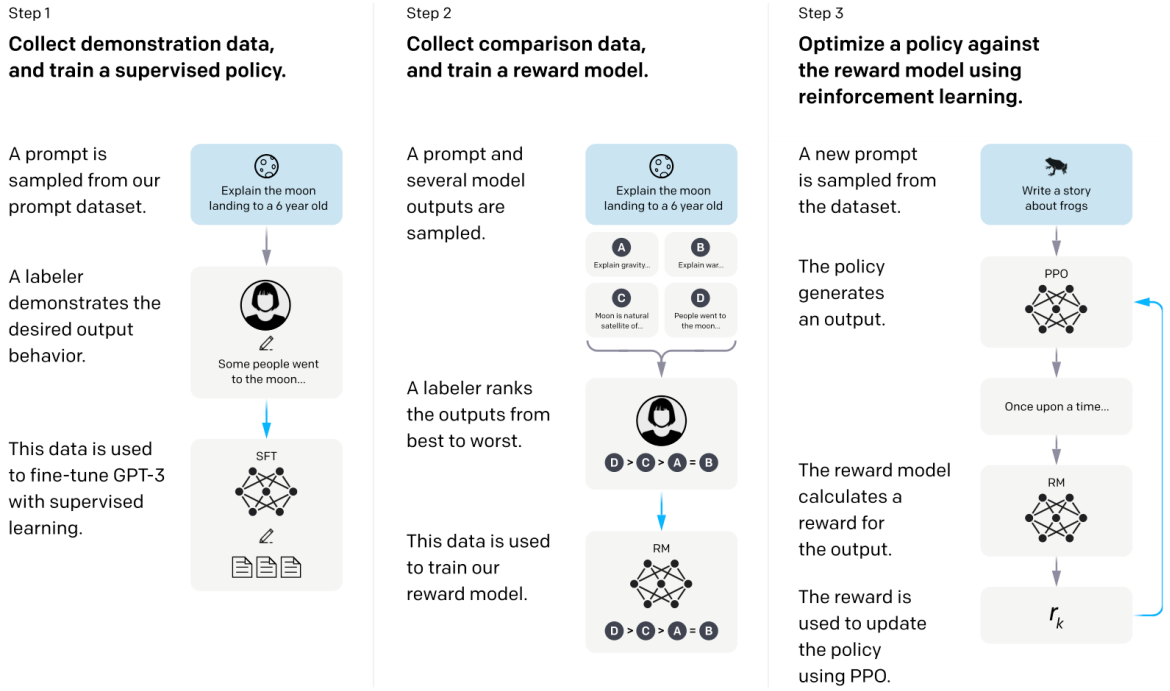
BERT型：文分類、検索、固有表現抽出、質問応答。
GPT型：文章生成、要約、翻訳、対話。

文脈内学習：入力に例を示す。重みは更新しない。
追加学習：課題のデータで重みを更新する。

大規模言語モデルの学習段階

事前学習 → 指示と回答例による学習 →
人間の好みを反映する学習。

原著図はInstructGPTの例。モデルによって手順は異なる。



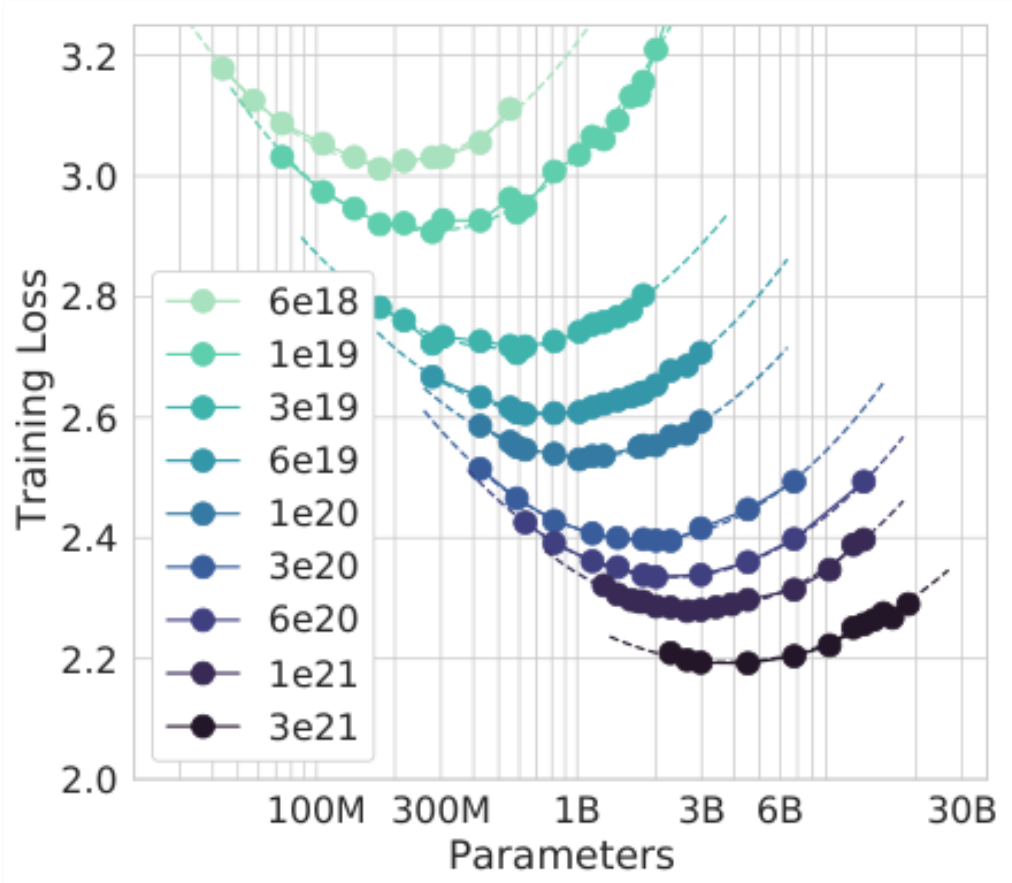
Ouyang et al., NeurIPS (2022), Fig. 2, arXiv:2203.02155 ／ Brown et al., NeurIPS (2020), arXiv:2005.14165

計算量が同じなら最大モデルが最良か

Hoffmann ら（2022）：同じ計算量の下でモデルサイズを変えて比較。

横軸はパラメータ数、縦軸は損失。各曲線の最小点が、その計算量で損失を最小にするパラメータ数。

最大のモデルが最良とは限らない。同じ計算量では、モデルを大きくすると学習できるトークン数が減る。



Hoffmann et al. (2022), Fig. 3 左・arXiv:2203.15556

タンパク質言語モデルを学習目標で整理する

モデル	入力・学習目標	主な用途
ESM-1b / ESM-2	配列のマスク予測 双方向Transformer	残基・配列の表現、変異評価 ESMFoldの入力
ProtBERT / ProtT5	配列のマスク・破損の復元 BERT型 / T5型	埋め込みから構造・機能・物性へ
ProGen / ProGen2	次のアミノ酸を予測 自己回帰型	条件付き／無条件の配列生成
ESM3	配列・構造・機能の 複数の情報をマスクして予測	複数の条件を用いる タンパク質の生成・補完

本講義はESM-2に注目する。「ESM-2」という配列表現モデルと、「ESMFold」という構造予測器は区別する。

Rives et al. (2021)／Elnaggar et al. (2022)／Madani et al. (2023)／Nijkamp et al. (2023)／Hayes et al. (2025)・完全書誌は章末

文脈を伸ばす学習が、長距離の予測を支える

短い配列から段階的に伸ばす

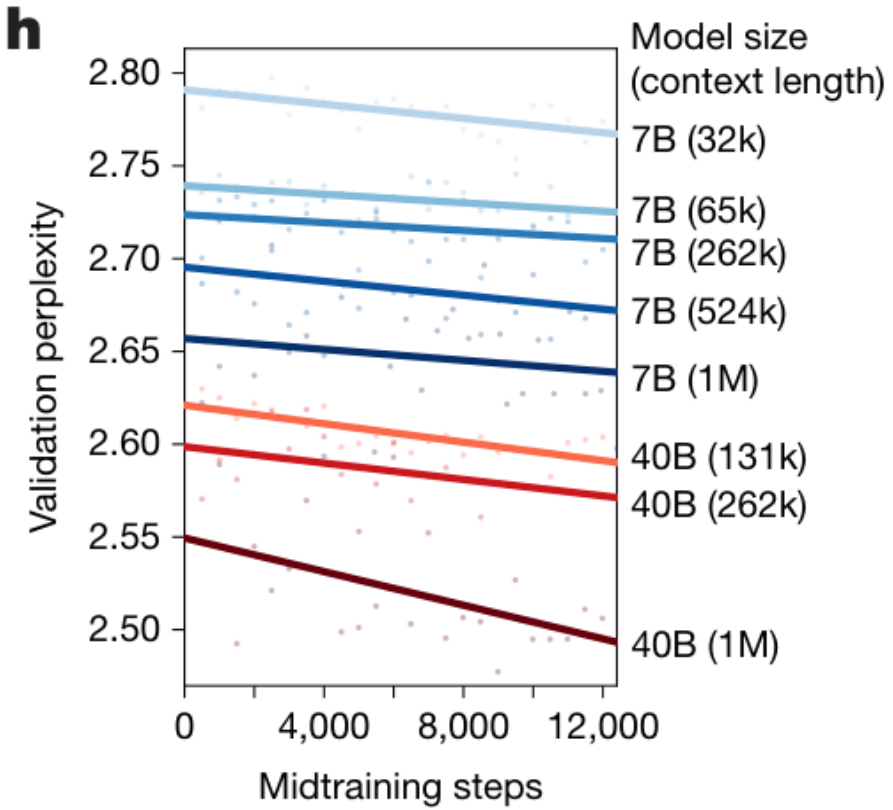
初期は8,192トークンで学習。その後、段階的に最大約100万トークンへ文脈を拡張する。

$$\mathrm{PPL} = \exp\left[-\frac{1}{L}\sum_i \log p_\theta(x_i \mid x_{<i})\right]$$

PPL（perplexity）：予測の不確かさを表す指標。小さいほど観測配列に高い確率を与える。

右：横軸は長文脈学習のステップ数。線の条件がモデル規模と文脈長。

長い文脈の利用能力は、別途、遠くに埋めた情報を取り出す課題でも検証する。



原著Fig. 1h：文脈長とモデル規模の両方で性能が変わる。

Brixi et al., Nature 652, 1349–1361 (2026), doi:10.1038/s41586-026-10176-5（Fig. 1h）

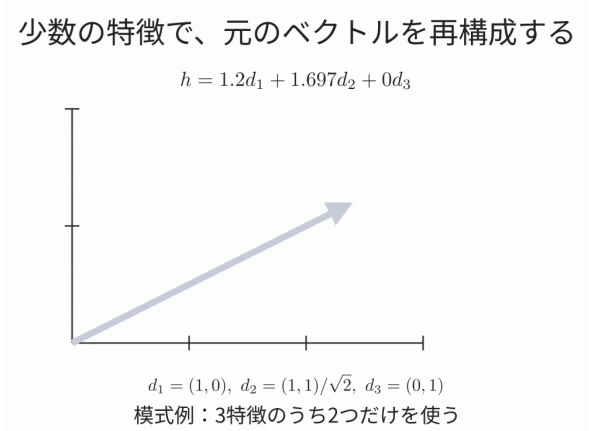
SAEは密な表現を少数の特徴へ分解する

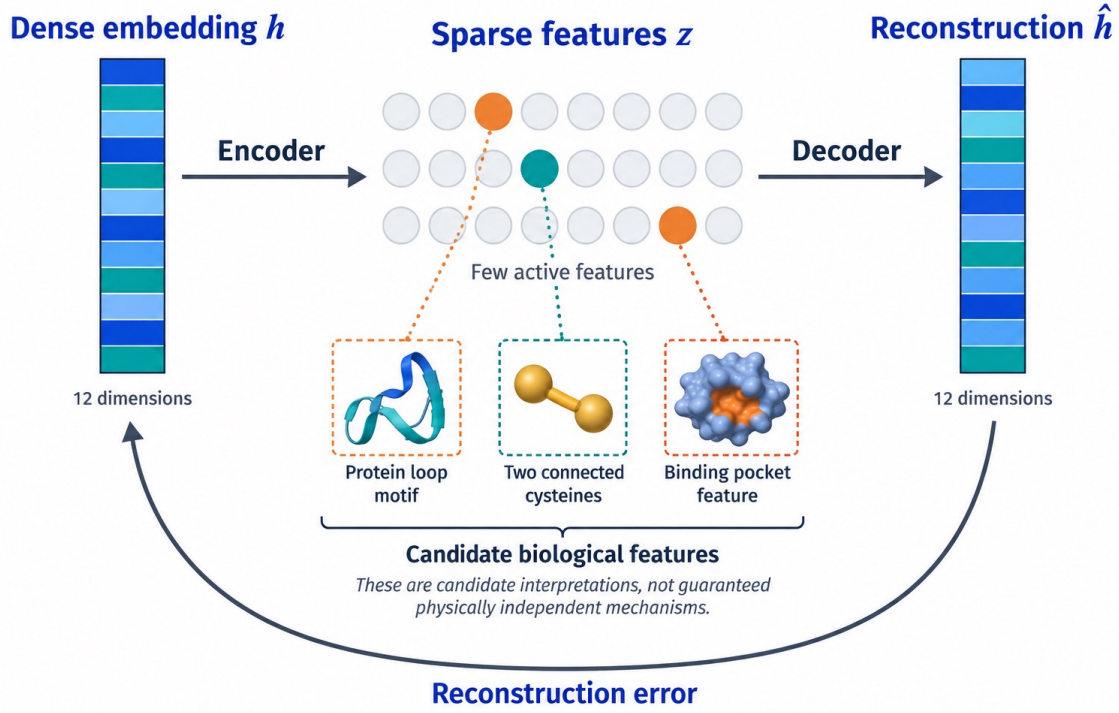
$$z = \mathrm{ReLU}(W_e h + b_e), \quad \hat{h} = W_d z + b_d$$

$$\mathcal{L}_{SAE} = \|h - \hat{h}\|_2^2 + \lambda \|z\|_1$$

h：d次元の埋め込み。z：m次元の特徴の活性。通常$m>d$で、多くを0に近づける。

再構成の正確さと、使う特徴の少なさを両立する。





模式図：特徴の生物学的な意味は学習後に調べる。

Simon & Zou, InterPLM, arXiv:2412.12101（図は取得したpreprint版） ／概念図：ChatGPT Image、ベクトル例：Manim

SAEの特徴を、生物学的な注釈と照合する

特徴が活性化する残基を調べる

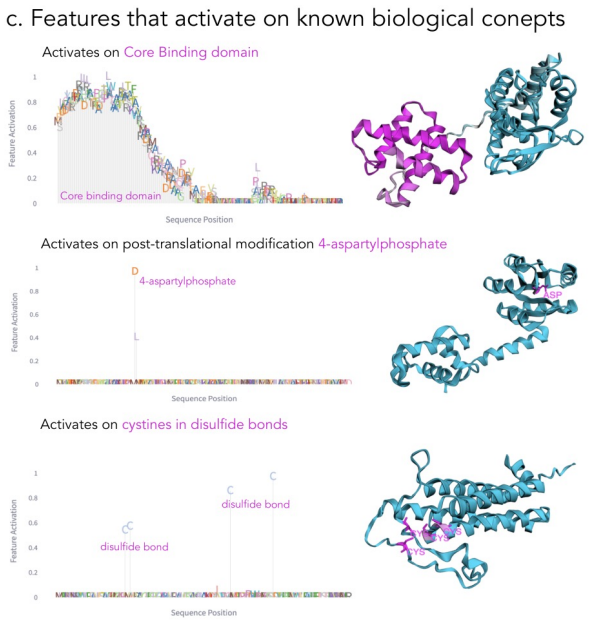
InterPLMはESM-2の内部表現にSAEを適用し、構造モチーフ、結合部位、ドメインなどとの対応を調べた。

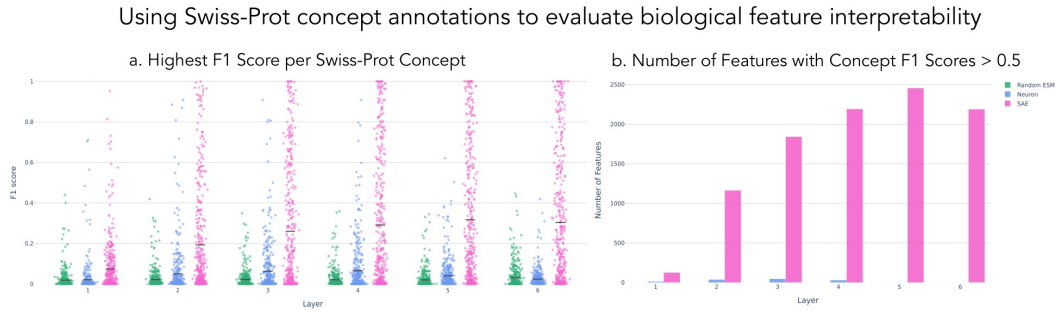
$$\text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN}$$

$$F_1 = \frac{2PR}{P + R}$$

Swiss-Protの注釈との対応を定量化し、元のニューロンと比較する。

相関が高いこと、特徴を操作するとモデル出力が変わること、生物学的因果の証明は別の段階。





Simon & Zou, InterPLM, arXiv:2412.12101（図は取得したpreprint版）（Figs. 1c / 3）／掲載版：Nat Methods (2025), doi:10.1038/s41592-025-02836-7

熱安定性の予測から、検証できる仮説へ

ESM-2を実験値へ適応し、SAEで調べる

Murakamiら：ナノボディの融解温度をESM-2で予測。追加学習後の表現をSAEへ入力し、活性と温度の関係を線形モデルで読む。

$$\hat{T}_m = b + \sum_k w_k \bar{z}_k$$

図：特徴が強く反応する残基を構造に配置。Tyr 104やMet 41などの局所環境に着目する（番号はAHo方式）。

自由エネルギー計算でも安定化・不安定化の方向を検証。物理的な仮説を絞る手掛かりであり、一般的な因果法則の確定ではない。

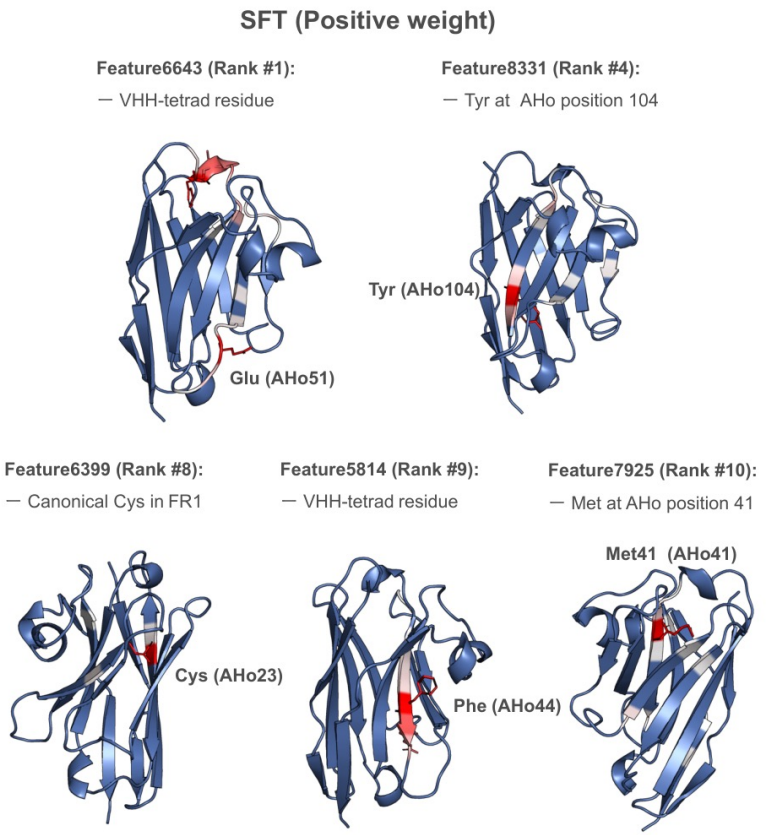


Fig. 6の正の重みの特徴を切り出し。構造中の赤い領域が活性位置。

Murakami, Hashidate & Matsunaga, Bioinformatics 42, btag685 (2026), Fig. 6（著者原稿）, doi:10.1093/bioinformatics/btag685

生成した配列がそのまま残ったか

16 個のうち 9 個は、配列確認で新たな変化が見つからなかった。

残り 7 個では、生成配列から一塩基変化や欠失が見つかった。

生成案と、実験後に確認した配列を区別する。

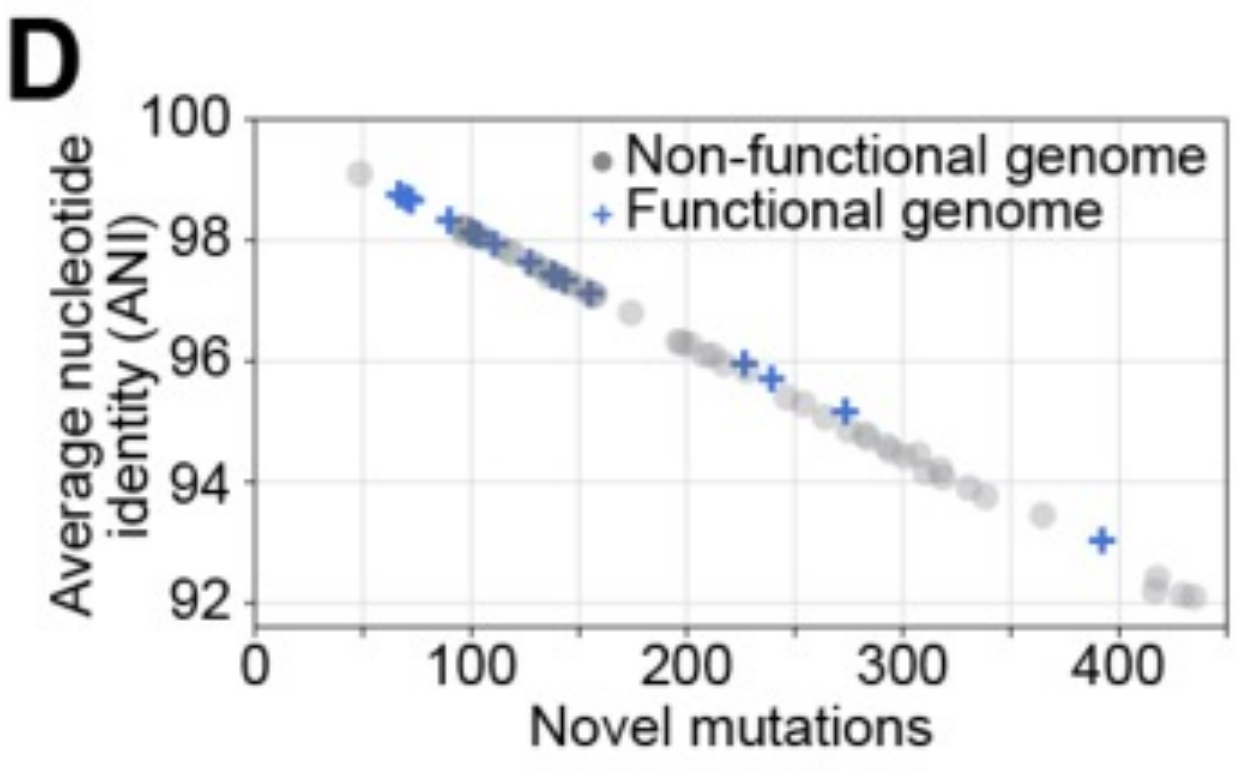
King et al., bioRxiv v1 (2025) · doi:10.1101/2025.09.12.675911

どれくらい自然配列から離れたか

Fig. 4D：横軸は既知配列からの変化数、縦軸は配列一致率。

機能した候補の最近縁配列との一致率は 93.0〜98.8%。

青は機能あり、灰は機能未確認の候補。変化数だけで機能は決まらない。



King et al., bioRxiv v1 (2025), Fig. 4D · doi:10.1101/2025.09.12.675911

参考文献：言語モデルの原理

Vaswani et al. (2017). Attention Is All You Need. NeurIPS 30.

Devlin et al. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. NAACL, 4171–4186.

Radford et al. (2018). Improving Language Understanding by Generative Pre-Training. OpenAI.

Brown et al. (2020). Language Models are Few-Shot Learners. NeurIPS 33.

Ouyang et al. (2022). Training language models to follow instructions with human feedback. NeurIPS 35.

Kaplan et al. (2020). Scaling Laws for Neural Language Models.

Hoffmann et al. (2022). Training Compute-Optimal Large Language Models. NeurIPS 35.

Su et al. (2024). RoFormer: Enhanced transformer with Rotary Position Embedding. Neurocomputing 568, 127063.

参考文献：ゲノムの予測と設計

Zhou et al. (2024). DNABERT-2: Efficient Foundation Model and Benchmark for Multi-Species Genome. ICLR.

Dalla-Torre et al. (2025). Nucleotide Transformer: building and evaluating robust foundation models for human genomics. Nature Methods 22, 287–297.

Avsec et al. (2026). Advancing regulatory variant effect prediction with AlphaGenome. Nature 649, 1206–1218.

Brixi et al. (2026). Genome modelling and design across all domains of life with Evo 2. Nature 652, 1349–1361.

Ku et al. (2025). Systems and Algorithms for Convolutional Multi-Hybrid Language Models at Scale.

King et al. (2025). Generative design of novel bacteriophages with genome language models. bioRxiv v1（図の出典）.

King et al. (2026). Generative design of bacteriophages with genome language models. Science 393, eaec2657（掲載版）.

参考文献：タンパク質の予測と解釈

Lin et al. (2023). Evolutionary-scale prediction of atomic-level protein structure with a language model. Science 379, 1123–1130.

Rives et al. (2021). Biological structure and function emerge from scaling unsupervised learning to 250 million protein sequences. PNAS.

Elnaggar et al. (2022). ProtTrans. IEEE TPAMI.

Madani et al. (2023). Large language models generate functional protein sequences across diverse families. Nature Biotechnology.

Nijkamp et al. (2023). ProGen2: Exploring the boundaries of protein language models. Cell Systems.

Hayes et al. (2025). Simulating 500 million years of evolution with a language model. Science.

Meier et al. (2021). Language models enable zero-shot prediction of the effects of mutations on protein function. NeurIPS.

Schmirler, Heinzinger & Rost (2024). Fine-tuning protein language models boosts predictions across diverse tasks. Nat Commun 15, 7407.

Simon & Zou (2025). InterPLM: discovering interpretable features in protein language models via sparse autoencoders. Nat Methods.

Murakami, Hashidate & Matsunaga (2026). Mechanistic interpretability of fine-tuned protein language models for nanobody thermostability prediction. Bioinformatics 42, btag685.

配列予測と構造精度は同じ量か

同じ270,000学習ステップ：perplexityは10.45（8M）から6.37（15B）へ低下。
perplexity＝exp(平均損失)。配列の予測と、個々の構造の正確さは別々に評価する。

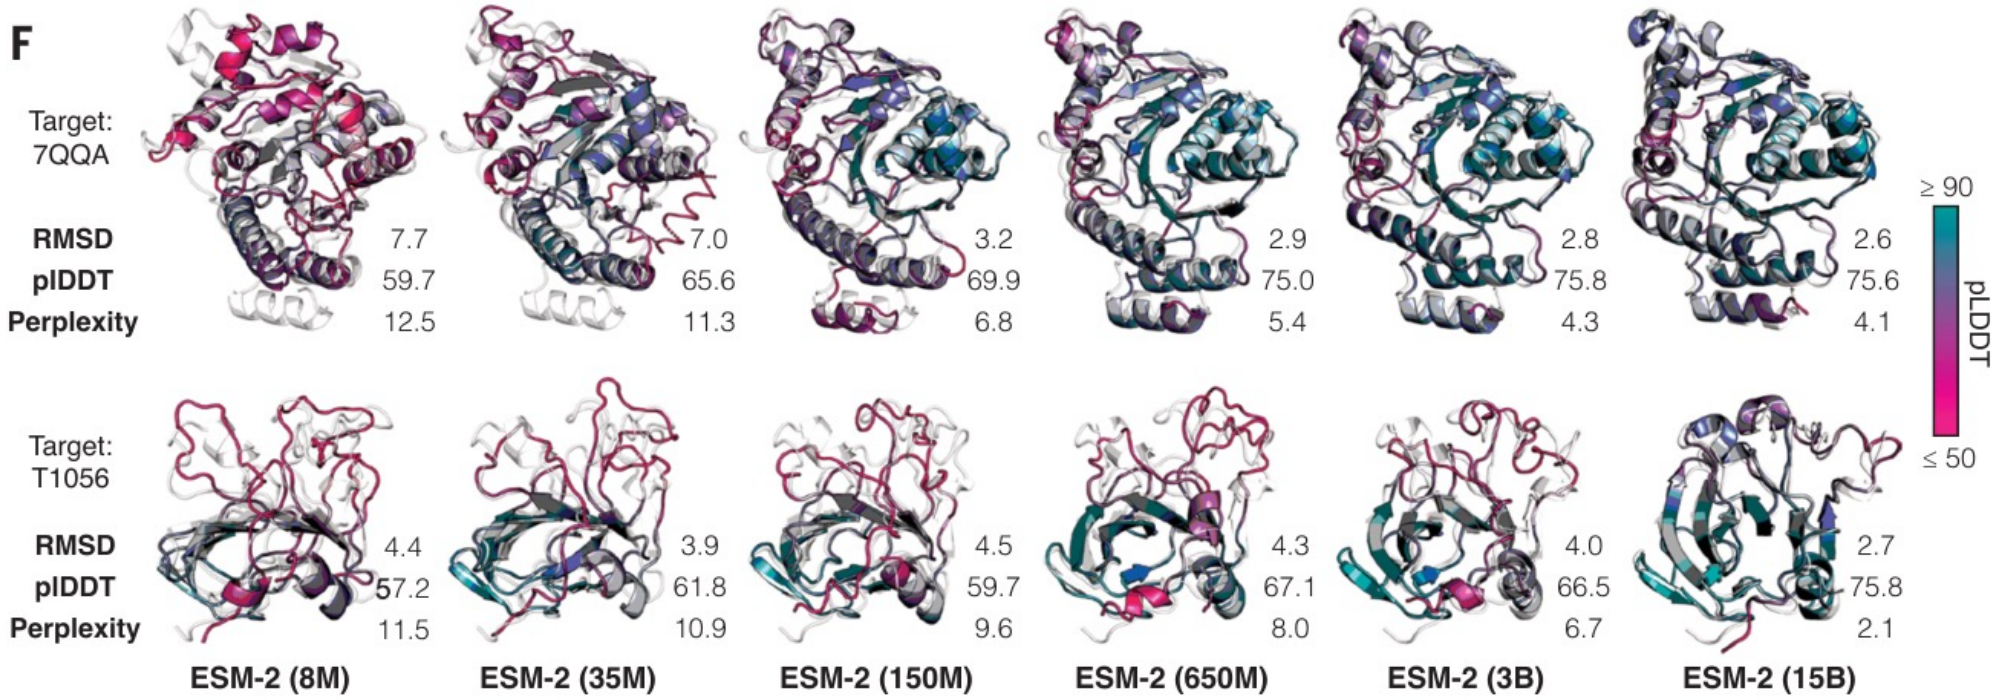


Fig. 1F：左からモデル規模が増大。構造精度の改善は一様ではなく、急に改善する例もある。

Lin et al., Science (2023), Fig. 1F · doi:10.1126/science.ade2574

図と説明の出典：実験医学2026年3月号

『実験医学』44巻4号：ゲノム言語モデルを使う！

企画：田宮元・鈴木忍、羊土社（2026）。ISBN 978-4-7581-2601-4。

田宮元	453–458	背景：配列の学習と機能理解
鈴木潤	459–464	図1：次語予測／図3：Transformer
東光一	465–471	図2：穴埋めと自己回帰、長距離の文脈
中根孝文	472–478	Attention・予測の寄与・作用機序の区別
小針靖子・高山順	479–485	図3：変異スコアと追加分類器
渥美友哉	492–496	図2：測定データの予測と配列生成
赤木剛士	497–502	図1：植物の発現分類と重要領域

掲載図は各記事から抜粋。説明・図の読み方・数式との対応を本教材で補った。