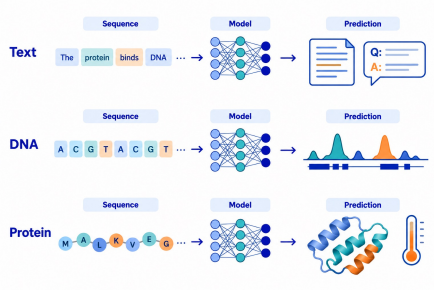
生命情報工学特論　第04回

生命科学の言語モデル

Attentionの計算から
タンパク質・DNA配列の予測へ

松永 康佑

埼玉大学 大学院理工学研究科
理化学研究所 計算科学研究センター ｜ 2026年10月26日



概念図：自然言語・DNA・タンパク質の配列をモデルで扱う。

今日の内容

配列の予測から、文脈を含む表現を学ぶ

入力
ユビキチンの配列
…TIENVK…

→

文脈を計算
AttentionとFFN
位置ごとの表現

→

予測
隠したアミノ酸の
候補と確率

周囲の順番が変わると、同じ位置の予測も変わる。配列を予測するための学習から、構造や機能に関係する特徴も内部表現に学習される。

この回で説明すること：確率を計算する仕組み、その表現の使い方、実験で確かめる必要があること。

講義の流れ

仕組みを追い、タンパク質とDNAへつなぐ

配列の確率・Attention・Transformer
トークン → Q・K・V → 内積とsoftmax → 情報の混合 → 残差接続・正規化・FFN。

ESM-2と予測の使い方
穴埋め予測、残基ごとの表現、構造予測、追加学習。高確率と高機能を区別する。

Evo 2と研究例・まとめ
次塩基予測、長い文脈、変異の評価。生成された配列の機能は別に検証する。

演習20分：Attentionの模型 → 実際のESM-2。詳しい研究結果と文献は付録へ。

原理｜確率と学習

言語モデルは配列に確率を与える

連鎖則で、長い配列を条件付き確率に分ける

$$p_\theta(x_{1:L}) = \prod_{i=1}^{L} p_\theta(x_i \mid x_{<i})$$

x_i：位置iの記号、L：配列長、θ：学習する重み。
連鎖則自体は近似ではない。

$$\mathcal{L}_{AR} = -\sum_{x\in\mathcal{D}}\sum_{i=1}^{L} \log p_\theta(x_i \mid x_{<i})$$

観測された配列に高い確率を与えるよう、負の対数尤度を最小化する。

1位置の計算例

$$-\log 0.1 \simeq 2.30, \quad -\log 0.8 \simeq 0.22$$

正解記号の確率を高くすると損失が下がる。

分類としての次トークン予測

$$p_j = \frac{\exp(a_j)}{\sum_{k\in\mathcal{V}} \exp(a_k)}$$

a_j：候補jのスコア。語彙 $\mathcal{V}$全体で確率の和は1。

事前学習の正解は配列自身から得られる。人手の機能ラベルは必須ではない。

Radford et al. (2018), Fig. 1, Improving Language Understanding by Generative Pre-Training

原理｜トークンと埋め込み

記号をベクトルに変換して計算する

入力は記号のID、計算は実数ベクトル

$$E \in \mathbb{R}^{|\mathcal{V}| \times d}, \qquad h_i^{(0)} = E[x_i] + P_i$$

Eの1行を記号IDで選ぶ。dは埋め込みの次元。P_iは加算型の位置情報の例。

$$H^{(0)} \in \mathbb{R}^{L \times d}$$

同じ記号は同じ初期埋め込みを持つが、各層で周囲の情報が加わり、位置ごとに異なる表現になる。

対象ごとに、語彙が変わる

自然言語：サブワードなど
DNA：A・C・G・T、または複数塩基
タンパク質：20種類の標準アミノ酸＋特殊記号

単純な行選択の例

$$E[A] = (0.2, -0.1), \quad E[C] = (0.7, 0.3)$$

$$x = (A, C, A) \Rightarrow H = \begin{pmatrix} 0.2 & -0.1 \\ 0.7 & 0.3 \\ 0.2 & -0.1 \end{pmatrix}$$

上の数値は説明用。位置情報を加える前の表現。

Vaswani et al., NeurIPS (2017), Figs. 1–2, arXiv:1706.03762 ／ BERT原著 §3

Attention｜自然言語の動作例

すべての語の組を、行と列で見る

太郎は花子に本を渡した。彼女はそれを読んだ。

行＝情報を集める位置（Query）　列＝参照する位置（Key・Value）　濃いマスほど重みが大きい

Query ↓	太郎は	花子に	本を	渡した。	彼女は	それを	読んだ。
太郎は	0.35	0.10	0.05	0.35	0.05	0.05	0.05
花子に	0.10	0.35	0.10	0.25	0.10	0.05	0.05
本を	0.05	0.10	0.35	0.25	0.05	0.10	0.10
渡した。	0.25	0.25	0.25	0.10	0.05	0.05	0.05
彼女は	0.05	**0.65**	0.05	0.05	0.10	0.05	0.05
それを	0.05	0.10	**0.60**	0.05	0.05	0.10	0.05
読んだ。	0.05	0.05	0.10	0.05	0.30	0.35	0.10

1マス＝位置の組

「彼女は」の行 ×「花子に」の列 → 重み 0.65

「それを」の行 ×「本を」の列 → 重み 0.60

各行の和は1。
行と列を交換しても同じ値とは限らない。

各組のQとKからスコア → 行ごとのsoftmaxで重み → 各列のVを重み付きで足し合わせる。

説明用に手設定した1ヘッド・双方向の模式例。文節を単位とし、実モデルのトークン分割・実測値とは異なる。

原理｜Attention

Attentionは関連する情報を集める

質問と手掛かりの一致度から重みを作る

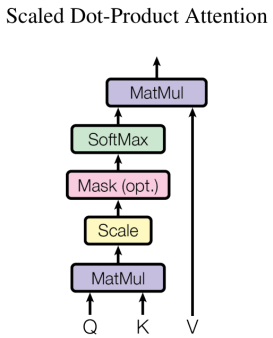
$$s_{ij} = \frac{q_i^T k_j}{\sqrt{d_k}}$$

$$\alpha_{ij} = \frac{\exp(s_{ij})}{\sum_m \exp(s_{im})}, \quad \sum_j \alpha_{ij} = 1$$

$$o_i = \sum_j \alpha_{ij} v_j$$

Query q_iは情報を探す方向、Key k_iは参照先の特徴、Value v_iは集める情報。

$1/\sqrt{(d_k)}$は内積の大きさを調整する。



原著の計算図：下から上へ読む。Maskは必要な場合に加える。

Vaswani et al., NeurIPS (2017), Figs. 1–2, arXiv:1706.03762（Fig. 2左を切り出し）

Attention｜入力からQ・K・Vへ

同じ入力を、三つの重み行列で変換する

$$H = I_3, \quad W_Q = W_K = \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{pmatrix} \qquad W_V = \begin{pmatrix} 1 & 0 \\ 0 & 2 \\ 2 & 1 \end{pmatrix}, \quad V = HW_V = W_V$$

$$Q = HW_Q = W_Q, \quad K = HW_K = W_K$$

Hの各行が1位置の表現。L＝3位置、入力次元d＝3、Query・Keyの次元dk＝2。WQ・WK・WVは全位置で共有するが、互いに異なる役割を学習する。

この例ではHを単位行列にしたので、各位置のQ・K・Vは対応する重み行列の行になる。次ページはこのQ・K・Vの位置1を使い、出力まで計算する。実モデルではこれらの重みを学習する。

原理｜小さな数値例

Self-attentionの計算を追う

同じ入力からQ・K・Vを作る

$$Q = HW_Q, \quad K = HW_K, \quad V = HW_V$$

$$O = \mathrm{softmax}_{row}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

Q,Kは$L\times d_k$、Vは$L\times d_v$。重み行列は$L\times L$。

右の計算例の読み方

位置1から3か所を見る。Keyとの一致度が高い位置1と3に、約0.40ずつ重みが付く。

出力は入力Valueの平均を、文脈に応じて変えたものになる。

3つの位置から、情報を集める

$$q = (1,0), \quad K = \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{pmatrix}$$

$$s = qK^T/\sqrt{2} = (0.707, 0, 0.707)$$

$$\alpha = \mathrm{softmax}(s) = (0.401, 0.198, 0.401)$$

$$V = \begin{pmatrix} 1 & 0 \\ 0 & 2 \\ 2 & 1 \end{pmatrix}, \quad o = \alpha V = (1.203, 0.797)$$

内積 → 確率の重み → Valueの加重和

Vaswani et al., NeurIPS (2017), Figs. 1–2, arXiv:1706.03762 ／ 数値例とアニメーション：教材用に計算

Attention｜計算の途中式

内積を重みに変え、Valueを足し合わせる

$$s = (1,0,1)/\sqrt{2} = (0.7071, 0, 0.7071)$$

$$\alpha = \frac{(e^{0.7071}, 1, e^{0.7071})}{2e^{0.7071}+1} = (0.4011, 0.1978, 0.4011)$$

各位置のValueを重み付きで足す

位置	重みα	Vへの寄与
1	0.4011	(0.4011, 0)
2	0.1978	(0, 0.3956)
3	0.4011	(0.8022, 0.4011)

$$o = 0.4011(1,0) + 0.1978(0,2) + 0.4011(2,1) = (1.2033, 0.7967)$$

αの和は1。出力oはdv次元の特徴ベクトルであり、アミノ酸の予測確率ではない。

$$\mathrm{Var}(q\cdot k) = d_k \quad \Rightarrow \quad \mathrm{Var}\left(\frac{q\cdot k}{\sqrt{d_k}}\right) = 1$$

内積を$\sqrt{}$dkで割り、次元による分散の増大を抑える。
成分が独立・平均0・分散1という説明用の仮定。
実際の特徴が厳密に満たすとは限らない。

Attention｜参照できる範囲

因果マスクはsoftmaxの前に加える

$$A = \mathrm{softmax}_{\mathrm{row}}\left(QK^T/\sqrt{d_k} + M\right), \quad M_{ij} = \begin{cases} 0 & j \le i \\ -\infty & j > i \end{cases}$$

$s = (0, 0.7071, 0.7071)$

$s + M = (0, 0.7071, -\infty)$

$\alpha_{\mathrm{both}} = (0.1978, 0.4011, 0.4011)$

$\alpha_{\mathrm{causal}} = (0.3302, 0.6698, 0)$

双方向：入力として与えた左右の位置を参照できる。ESM-2では予測対象のアミノ酸を[MASK]へ置き換える。

自己回帰：位置iの出力で次の記号を予測する。学習時も未来の正解は参照させない。

原理｜Multi-headと位置情報

複数の関係と、配列の順番を表す

異なる射影で関係を並列に捉える

$$\mathrm{head}_r = \mathrm{Attn}(HW_Q^r, HW_K^r, HW_V^r)$$

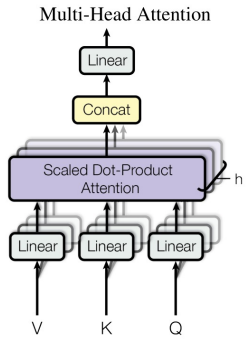
$$\mathrm{MHA}(H) = \mathrm{Concat}(\mathrm{head}_1, \ldots, \mathrm{head}_m)W_O$$

各ヘッドの重みは独立に学習する。役割は人間があらかじめ割り当てない。

位置がなければ、順序を区別しにくい

$$\tilde{q}_i = R_i q_i, \quad \tilde{k}_j = R_j k_j$$

回転型位置表現では、内積に相対位置が反映される。ESM-2でも使用。



複数ヘッドの出力を連結して、線形変換する。

Vaswani et al., NeurIPS (2017), Figs. 1–2, arXiv:1706.03762（Fig. 2右） ／ Su et al., Neurocomputing (2024), doi:10.1016/j.neucom.2023.127063

原理｜Transformerの1層

Transformerは情報の交換と変換を重ねる

原著のEncoder：post-normの形

$$U = \mathrm{LN}\big(H + \mathrm{MHA}(H)\big)$$

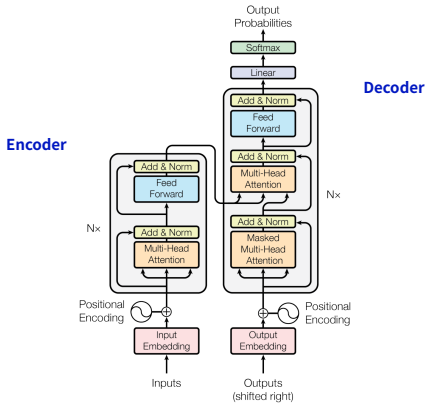
$$H' = \mathrm{LN}\big(U + \mathrm{FFN}(U)\big)$$

$$\mathrm{FFN}(u) = \sigma(uW_1 + b_1)W_2 + b_2$$

Attention：位置間で情報を交換。
FFN：各位置の特徴を非線形に変換。
残差接続：元の情報を足して残す。

LNは特徴方向の平均・分散を使う正規化。実装によって正規化の順序や活性化関数が異なる。

原著は翻訳用のEncoder–Decoder。以下では各部分を分けて使う。



Vaswani et al., NeurIPS (2017), Figs. 1–2, arXiv:1706.03762（Fig. 1を転載）

Transformer｜各部分の役割

位置の情報交換と、特徴の変換を分ける

FFN：各位置で同じ非線形変換

$$\mathrm{FFN}(h_i) = \phi(h_i W_1 + b_1)W_2 + b_2$$

W1はd×dff、W2はdff×d。中間次元で非線形変換し、残差加算のためd次元へ戻す。

LayerNorm：1位置の特徴成分を正規化

$$\mu_i = \frac{1}{d}\sum_{a=1}^{d} h_{ia}, \quad \sigma_i^2 = \frac{1}{d}\sum_{a=1}^{d}(h_{ia} - \mu_i)^2$$

$$\mathrm{LN}(h_i)_a = \gamma_a \frac{h_{ia} - \mu_i}{\sqrt{\sigma_i^2 + \epsilon}} + \beta_a$$

位置ごとに独立した計算

位置 1 → 同じFFN → 出力 1
位置 2 → 同じFFN → 出力 2
位置 3 → 同じFFN → 出力 3

ϕ：原著はReLU、ESM-2はGELU

LNも各行のd成分から平均と分散を求める。配列の全位置をまとめて平均する操作ではない。

γ・β：学習する係数
ε：数値を安定させる小さな定数

ESM-2のpre-norm：u＝H＋Attention(LN(H))、Hnext＝u＋FFN(LN(u))。位置間で情報を混ぜるのはAttention。

自然言語｜BERT

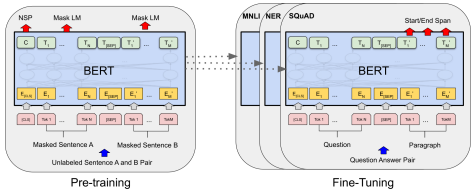
BERTは両側の文脈から穴埋めする

隠した位置の正解を予測する

$$\mathcal{L}_{MLM} = -\mathbb{E}_M \sum_{i \in M} \log p_\theta(x_i \mid \tilde{x})$$

M：予測対象の位置、$\tilde{x}$：一部を壊した入力。原著では15%を選び、そのうち80%を[MASK]に置換する。

事前学習したEncoderに出力層を追加し、分類や質問応答へ適応する。原著は文間関係の学習も併用。
双方向：予測位置の左右を参照できる。
対比：GPTでは未来の位置を隠す。





Devlin et al., NAACL (2019), Fig. 1, doi:10.18653/v1/N19-1423 ／下の因果マスクは教材用アニメーション

自然言語｜GPT

GPTは次のトークンを逐次生成する

学習と生成で、同じ条件付き確率を使う

$$\mathcal{L}_{AR} = -\sum_i \log p_\theta(x_i \mid x_{<i})$$

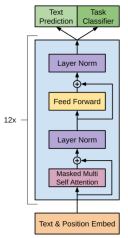
学習：正解の接頭辞と因果マスクで並列計算。
生成：出力を次の入力へ足し、逐次計算。

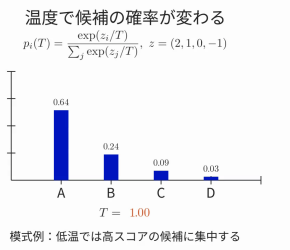
$$x_{t+1} \sim p_\theta(\cdot \mid x_{1:t})$$

温度は生成時の分布を変える

$$p_j(T) = \frac{\exp(a_j/T)}{\sum_k \exp(a_k/T)}$$

Tを下げると高スコア候補へ集中する。学習済みの重みは変えない。





模式例：低温では高スコアの候補に集中する

Radford et al. (2018), Fig. 1, Improving Language Understanding by Generative Pre-Training（Fig. 1左）／確率分布は説明用の計算例

自然言語｜応用

自然言語では、学習した表現を課題へ適応する

用途と適応方法を分けて考える

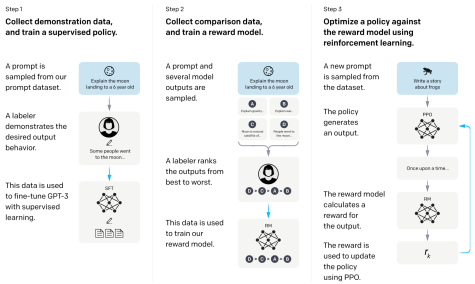
BERT型：文分類、検索、固有表現抽出、質問応答。
GPT型：文章生成、要約、翻訳、対話。

文脈内学習：入力に例を示す。重みは更新しない。
追加学習：課題のデータで重みを更新する。

大規模言語モデルの学習段階

事前学習 → 指示と回答例による学習 →
人間の好みを反映する学習。

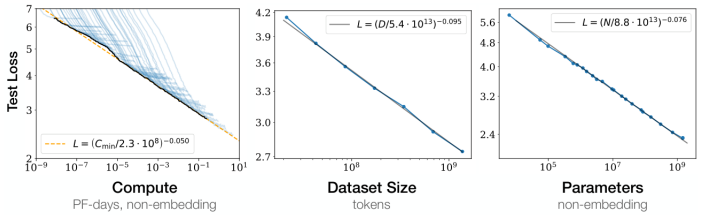
原著図はInstructGPTの例。モデルによって手順は異なる。



Ouyang et al., NeurIPS (2022), Fig. 2, arXiv:2203.02155 ／ Brown et al., NeurIPS (2020), arXiv:2005.14165

自然言語｜スケーリング

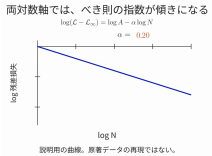
規模を増やすと予測損失はどう変わるか



$$\mathcal{L}(N) \simeq \mathcal{L}_\infty + AN^{-\alpha} \qquad \log(\mathcal{L} - \mathcal{L}_\infty) \simeq \log A - \alpha \log N$$

N：パラメータ数。A：係数、α：減少の指数、L∞：損失の漸近値。条件を限った経験則で、データ量・計算量も性能を制約する。

生物配列でも、損失の低下が構造・機能の予測改善と対応するかを検証する必要がある。



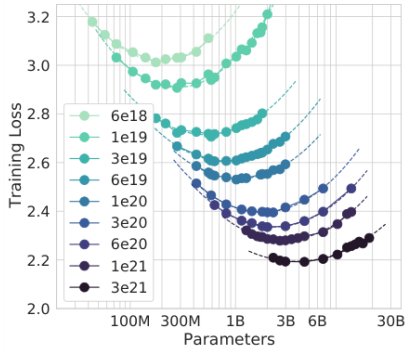
Kaplan et al. (2020), Fig. 1, arXiv:2001.08361 ／ Hoffmann et al. (2022), arXiv:2203.15556

自然言語のスケーリング

計算量が同じなら最大モデルが最良か

Hoffmann ら（2022）：同じ計算量の下でモデルサイズを変えて比較。

横軸はパラメータ数、縦軸は損失。各曲線の最小点が、その計算量で損失を最小にするパラメータ数。
パラメータ数を増やすと、同じ計算量で学習できるトークン数は減る。



Hoffmann et al. (2022), Fig. 3 左 · arXiv:2203.15556

タンパク質｜全体像

タンパク質言語モデルを学習目標で整理する

モデル	入力・学習目標	主な用途
ESM-1b / ESM-2	配列のマスク予測 双方向Transformer	残基・配列の表現、変異評価 ESMFoldの入力
ProtBERT / ProtT5	配列のマスク・破損の復元 BERT型 / T5型	埋め込みから構造・機能・物性へ
ProGen / ProGen2	次のアミノ酸を予測 自己回帰型	条件付き／無条件の配列生成
ESM3	配列・構造・機能の 複数の情報をマスクして予測	複数の条件を用いる タンパク質の生成・補完

本講義はESM-2に注目する。「ESM-2」という配列表現モデルと、「ESMFold」という構造予測器は区別する。

Rives et al. (2021)／Elnaggar et al. (2022)／Madani et al. (2023)／Nijkamp et al. (2023)／Hayes et al. (2025)・完全書誌は章末

タンパク質｜ESM-2

ESM-2はアミノ酸の穴埋めを学習する

BERT型の学習をタンパク質へ

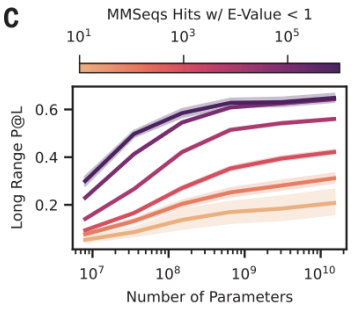
$$\mathcal{L} = -\mathbb{E}_M \sum_{i \in M} \log p_\theta(x_i \mid \tilde{x})$$

UniRef由来の配列を用い、クラスタを考慮してサンプリング。学習中に約6,500万の異なる配列を参照。

8M、35M、150M、650M、3B、15Bの6規模。Mは100万、Bは10億パラメータ。

構造ラベルを与えずに、配列に現れる構造・機能の制約を学習する。

右：接触予測の改善は、近縁配列の多さでも異なる。



横軸：モデル規模。P@L：上位L個の予測の適合率（Lは配列長）。

Lin et al., Science 379, 1123–1130 (2023), doi:10.1126/science.ade2574（Fig. 1C）

タンパク質｜入力から出力へ

ESM-2の出力は残基ごとの文脈表現

残基ごとのベクトルを得る

$$x_{1:L} \xrightarrow{\text{ESM–2}} H^{(K)} \in \mathbb{R}^{L \times d}$$

K層目の各行hiは、その残基と周囲の文脈を含む表現。特殊トークンや長さをそろえるためのパディングは集約から除く。

$$p_\theta(x_i \mid \tilde{x}) = \mathrm{softmax}\big(g_{LM}(h_i)\big)$$

g_{LM}は語彙のスコアへ変換する出力ヘッド。内部表現とアミノ酸の予測確率は別の量。

配列全体と残基ごとの予測を使い分ける

$$\bar{h} = \frac{1}{L}\sum_{i=1}^{L} h_i$$

配列全体：平均表現から熱安定性や機能を予測。
残基単位：h_iから二次構造や無秩序を予測。

穴埋めの推論

例：M–K–[MASK]–A–…を入力。
出力はその位置の候補アミノ酸の確率。
元の残基を見せたまま得る確率とは条件が違う。

ESM-2の埋め込みを取り出す操作と、実験値で追加学習する操作は分ける。

Lin et al., Science 379, 1123–1130 (2023), doi:10.1126/science.ade2574 ／ ESM公開実装のLM headは線形層だけではない

ESM-2｜演習との対応

隠した位置の出力から、候補の確率を得る

入力トークン
<cls>, M, Q, I, …
23番目I → <mask>

→

6層のESM-2
全位置でAttention＋FFN
各位置320次元

→

出力層
位置23のlogits
語彙方向にsoftmax

$$p(a \mid \tilde{x}) = \frac{\exp z_{23,a}}{\sum_{b \in \mathcal{V}} \exp z_{23,b}}$$

演習はesm2_t6_8M_UR50D（約800万パラメータ）。候補は全語彙で正規化した上位5個を表示し、5個だけで再正規化しない。特殊トークンを含む語彙と20種類のアミノ酸は別である。

タンパク質｜ESM-2の原著結果

配列表現から、残基間の接触を予測する

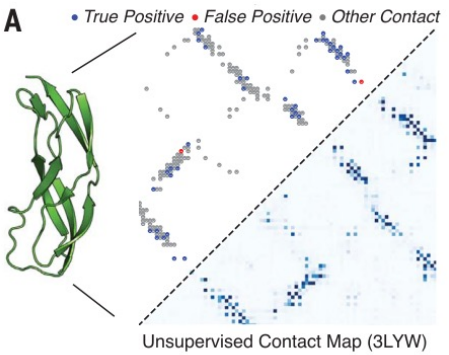
Attentionを組み合わせて接触を読み出す

$$\hat{c}_{ij} = \sigma\left(b + \sum_{\ell,r} w_{\ell r} \tilde{A}_{ij}^{\ell r}\right)$$

複数層・ヘッドのAttentionを対称化・補正し、接触予測用の読み出しに用いる。Attention自体が距離や接触確率を表すわけではない。

右図：予測と実際の接触を残基対ごとに比較。青は正しく予測した接触、赤は誤った予測。

配列による事前学習と、接触を読み出すための学習・評価は区別する。



Lin et al., Science 379, 1123–1130 (2023), doi:10.1126/science.ade2574（Fig. 1A）

タンパク質｜構造予測

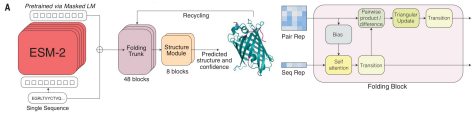
ESMFoldはESM-2の表現から座標を予測する

単一配列から構造へ

ESM-2 → 配列・残基対の表現 → folding trunk → 構造モジュール → 原子座標と信頼度。

多数の近縁配列の整列（MSA）を入力として要求しない。構造予測部は、構造データを使って学習する。

pLDDT：局所的な構造の信頼度の予測。
実際の正確さや、溶液中の揺らぎそのものではない。



成功と失敗の両方を見る

原著のT1057：ESMFoldのTM-score 0.98。
T1074：0.64、AlphaFold 2は0.93。

TM-scoreは正解構造との一致を測る。モデルが返す信頼度とは異なる。

ESM Metagenomic Atlasでは、メタゲノム由来の大量の配列へ展開された。

Lin et al., Science 379, 1123–1130 (2023), doi:10.1126/science.ade2574（Fig. 2A、Fig. 2D/Eの数値）

タンパク質｜下流課題の学習

埋め込みを、構造・機能・物性の予測へ使う

予測器を付ける方法は二つ

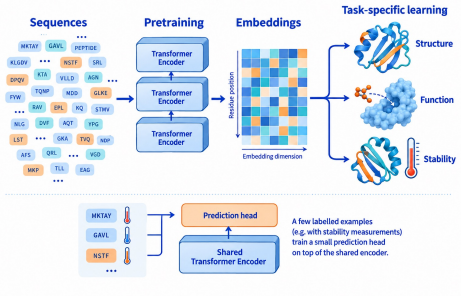
$$\hat{y} = g_\phi(\bar{h}_\theta(x))$$

① ESM-2を固定：φだけ学習。
② 追加学習：θも課題に合わせて更新。

$$\mathcal{L}_{reg} = \frac{1}{n}\sum_{a=1}^{n}(\hat{y}_a - y_a)^2$$

平均表現は配列全体の物性の回帰に使う。残基ごとの分類では平均せず各位置のhiを使う。

配列が似すぎたまま訓練・評価へ分かれると、未知配列への性能を過大評価しやすい。



Schmirler et al., Nat Commun 15, 7407 (2024), doi:10.1038/s41467-024-51844-2 ／概念図：ChatGPT Image

タンパク質｜応用と評価

物性の回帰と、変異の確率スコアは異なる

実験値を学習する回帰

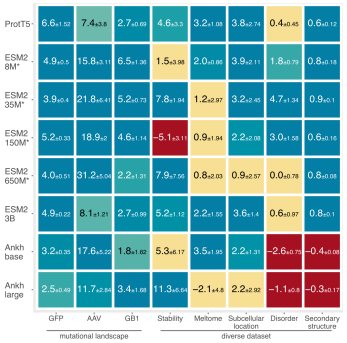
右図：追加学習前後の性能差。青は改善、赤は低下。熱安定性、融解温度、無秩序など、課題によって効果が異なる。

ラベルを使わない変異スコア

$$s_i = \log \frac{p_\theta(a_{mut} \mid x_{\setminus i})}{p_\theta(a_{wt} \mid x_{\setminus i})}$$

同じ位置を隠した文脈で、変異残基と元の残基の確率を比較する。

siは無次元。融解温度Tmや自由エネルギー差ΔΔGそのものではなく、実験との対応を検証する。



各セルは追加学習による性能の差。列ごとに指標が異なる。

Schmirler et al., Nat Commun (2024), Fig. 1, doi:10.1038/s41467-024-51844-2 ／ Meier et al., NeurIPS (2021)

ゲノム｜問いとモデル

DNAでは、離れた領域の関係も重要になる

コード領域だけが機能を決めるわけではない

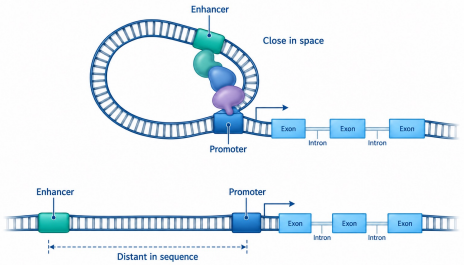
プロモーターは転写開始、エンハンサーは発現調節に関わる。RNAのつなぎ替えはスプライシングという。遠い配列領域も空間では近づき得る。

DNAモデルにも複数の学習目標がある

DNABERT-2・Nucleotide Transformer：
隠した配列の予測から表現を学ぶ。

Evo 2：次の塩基を予測する。
AlphaGenome：実験測定値を予測する。

ここで扱うのはDNA配列モデル。遺伝子発現量を入力する単一細胞モデルとは対象が異なる。



ChatGPT Imageによる概念図。長距離の制御関係を模式的に示す。

Zhou et al., DNABERT-2 (ICLR 2024), arXiv:2306.15006 ／ Dalla-Torre et al., Nat Methods (2025), doi:10.1038/s41592-024-02523-z

ゲノム｜AlphaGenome

AlphaGenomeはDNAから分子特性を予測する

約100万塩基から、多種類の測定値へ

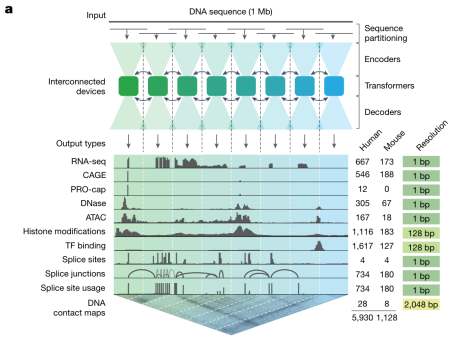
ヒト・マウスの配列から、発現、クロマチンの開きやすさ、転写因子結合、スプライシング、接触などを予測する。

畳み込みで圧縮 → Transformerで遠距離の情報を交換 → 解像度を戻し、測定項目別の出力へ。

$$\hat{y}_k = f_{\theta,k}(x), \quad \mathcal{L} = \sum_k \lambda_k \mathcal{L}_k(\hat{y}_k, y_k)$$

$$\Delta f_k = f_{\theta,k}(x_{alt}) - f_{\theta,k}(x_{ref})$$

同じ周辺配列で変異前後を比較する。次の塩基を生成するための損失ではない。



原著Fig. 1a。出力ごとに対象と解像度が異なる。

Avsec et al., Nature 649, 1206–1218 (2026), Fig. 1a, doi:10.1038/s41586-025-10014-0

ゲノム｜Evo 2の入力と学習

Evo 2は多様な生物の配列を学習する

一塩基を一つのトークンとして扱う

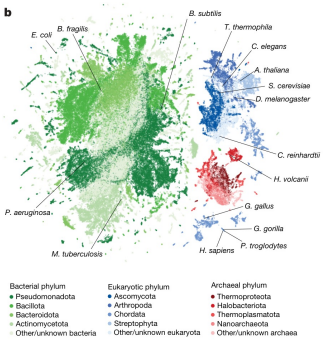
OpenGenome2：細菌・古細菌・真核生物・バクテリオファージ等のDNA。約8.8兆塩基を超えるデータを整理。

7B／40Bモデル：Bは10億パラメータ。40B版では学習中に約9.3兆トークンを使用。データ量と延べ学習量は別。

$$p_\theta(x_i \mid x_{<i}), \quad x_i \in \{A, C, G, T, ...\}$$

最大約100万塩基から長距離の関係も学ぶ。

真核生物に感染するウイルスは学習から除外。



点はゲノム。短い塩基並びの頻度に基づくUMAPで、モデル内部表現ではない。

Brixi et al., Nature 652, 1349–1361 (2026), doi:10.1038/s41586-026-10176-5（Fig. 1b）

ゲノム｜StripedHyena 2

Evo 2は畳み込みとAttentionを組み合わせる

長い配列を扱う計算上の工夫

Attention: $QK^T \in \mathbb{R}^{L \times L}$

すべての位置の組を扱うAttentionの計算は配列長Lの二乗で増える。

$$u_t = b_t \odot v_t, \quad y_t = g_t \odot \sum_{\tau=0}^{t} h_\tau u_{t-\tau}$$

b,v,gは入力から作る。⊙は要素ごとの積、hτは遅れτのフィルタ係数。ゲート付き畳み込みの模式形。

短距離（明示的）・中距離（正則化）・長距離（暗黙的）のフィルタをAttentionと組み合わせる。



畳み込み：近傍を同じ重みで集める

$$y_t = 0.5u_t + 0.3u_{t-1} + 0.2u_{t-2}$$

入力 u	1	0	2	1	3

$t = 0: \quad 0.5 \times 1 = 0.5$

出力 y

模式例：左端の外側は0。Hyenaの一部を単純化。

$$y = (0.5,\ 0.3,\ 1.2,\ 1.1,\ 2.2)$$

Brixi et al., Nature 652, 1349–1361 (2026), doi:10.1038/s41586-026-10176-5（Fig. 1f）／Poli et al. (2025), § 2, arXiv:2503.01868

ゲノム｜Evo 2の評価

文脈を伸ばす学習が、長距離の予測を支える

短い配列から段階的に伸ばす

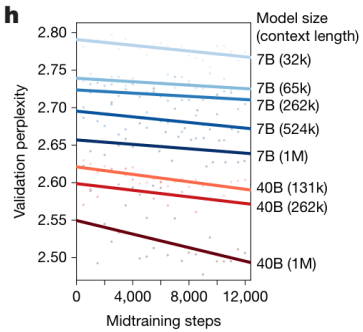
初期は8,192トークンで学習。その後、段階的に最大約100万トークンへ文脈を拡張する。

$$\mathrm{PPL} = \exp\left[-\frac{1}{L}\sum_i \log p_\theta(x_i \mid x_{<i})\right]$$

PPL（perplexity）：予測の不確かさを表す指標。小さいほど観測配列に高い確率を与える。

右：横軸は長文脈学習のステップ数。線の条件がモデル規模と文脈長。

長い文脈の利用能力は、別途、遠くに埋めた情報を取り出す課題でも検証する。



原著Fig. 1h：文脈長とモデル規模の両方で性能が変わる。

Brixi et al., Nature 652, 1349–1361 (2026), doi:10.1038/s41586-026-10176-5（Fig. 1h）

ゲノム｜下流課題

Evo 2の確率から変異の影響を推定する

進化の制約に反する変異は低確率か

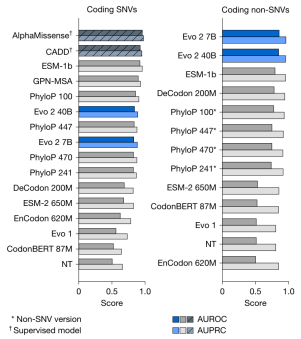
$$\ell(x) = \sum_i \log p_\theta(x_i \mid x_{<i})$$

$$\Delta\ell = \ell(x_{alt}) - \ell(x_{ref})$$

負の値は変異配列がモデルにとって起こりにくいことを示す。実際の評価では、評価する領域・配列長・文脈に応じてスコアの集約方法を選ぶ。

追加の変異ラベルで重みを学習せずに予測する方法をzero-shotと呼ぶ。

変異の評価は実測ラベルとの対応で確かめる。配列尤度は病原性や自由エネルギーそのものではない。



分類性能を比較した原著図。青はEvo 2、灰は比較手法。

Brixi et al., Nature 652, 1349–1361 (2026), doi:10.1038/s41586-026-10176-5（Fig. 3bの結果を切り出し）

ゲノム｜ファージ研究

配列の生成と、実際の機能は分けて検証する

研究の問い：ゲノム全体でも機能するか

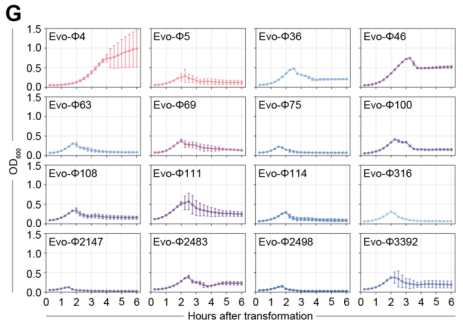
KingらはEvo 1とEvo 2でファージのゲノムを設計し、16種類の生存可能なファージを得たと報告。

右図：細菌の増殖曲線。濁度（OD600）の低下や増加の抑制からファージの機能を評価する。

この結果から分かる範囲

ゲノム全体の生成物が機能し得る例。任意の生成配列の機能を保証する結果ではない。

図は2025年preprint版。2026年8月にScienceへ掲載。



縦軸は細菌培養液の濁度。ファージの個体数や競争割合ではない。

King et al., bioRxiv v1 (2025), Fig. 3G, doi:10.1101/2025.09.12.675911 ／ Science (2026), doi:10.1126/science.aec2657

結果

候補数と実験数を区別する

302：計算上の条件から選んだ候補。

285：実際に合成・組立でき、機能を調べた候補。

16：機能が確認された候補。16/285 ≈ 5.6%。

これは選別済み候補での割合。無作為な生成配列の成功率ではない。

King et al., bioRxiv v1 (2025) · doi:10.1101/2025.09.12.675911

まとめ

計算・予測対象・検証を対応づける

計算	学習目標	確かめる対象
$QK^T \rightarrow$ softmax $\rightarrow AV$ FFN・残差接続・LN	ESM-2：穴埋め Evo 2：次塩基予測	予測損失と課題性能 機能・安定性は実験

冒頭の例：同じアミノ酸を隠しても、周囲の順序が変われば内部表現と候補確率が変わる。Attentionはこの文脈の計算の一部を担う。

大きなAttention重み ≠ 接触確率。高い配列確率 ≠ 高い機能。低い学習損失 ≠ あらゆる課題で高性能。

観察・演習

Attentionの模型から、実際のESM-2へ

1　Attentionの計算を動かす

講義と同じQ・K・V。Queryの位置と因果マスクを変更し、スコア・重み・出力を順に見る。

2　ESM-2で隠す位置を変える

ユビキチンの12・23・44・66番を切り替える。実モデルの上位候補と確率を見る。

3　周囲の並びを変えて比べる

対象位置の元の文字と組成は固定。周囲を並べ替え、元の配列での予測と比較する。

採点・記述提出なし。WebClassの「04_演習」からColabを開く。準備が止まったら「計算済み出力.html」を使う。

付録

詳しい研究結果と参考文献

付録2–4　ESM-2の表現をSAEで解釈する研究例
付録5–7　ファージ研究：配列確認・新規性・構造
付録8–10　自然言語・ゲノム・タンパク質の参考文献
付録11　ESM-2の規模と予測損失

解釈｜Sparse Autoencoder

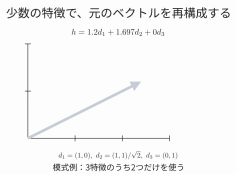
SAEは密な表現を少数の特徴へ分解する

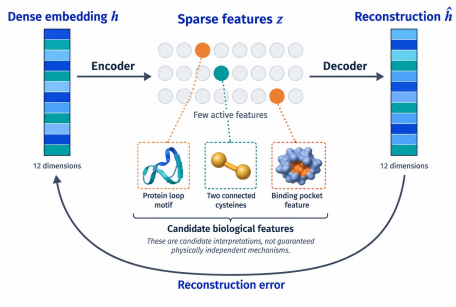
$$z = \mathrm{ReLU}(W_e h + b_e), \quad \hat{h} = W_d z + b_d$$

$$\mathcal{L}_{SAE} = \|h - \hat{h}\|_2^2 + \lambda \|z\|_1$$

h：d次元の埋め込み。z：m次元の特徴の活性。通常$m>d$で、多くを0に近づける。

再構成の正確さと、使う特徴の少なさを両立する。





模式図：特徴の生物学的な意味は学習後に調べる。

Simon & Zou, InterPLM, arXiv:2412.12101（図は取得したpreprint版）／概念図：ChatGPT Image、ベクトル例：Manim

解釈｜InterPLMの応用

SAEの特徴を、生物学的な注釈と照合する

特徴が活性化する残基を調べる

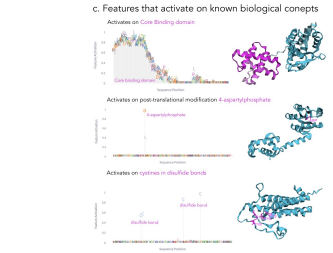
InterPLMはESM-2の内部表現にSAEを適用し、構造モチーフ、結合部位、ドメインなどとの対応を調べた。

$$\mathrm{Precision} = \frac{TP}{TP + FP}, \quad \mathrm{Recall} = \frac{TP}{TP + FN}$$

$$F_1 = \frac{2PR}{P + R}$$

Swiss-Protの注釈との対応を定量化し、元のニューロンと比較する。

相関が高いこと、特徴を操作するとモデル出力が変わること、生物学的因果の証明は別の段階。



Simon & Zou, InterPLM, arXiv:2412.12101（図は取得したpreprint版）（Figs. 1c / 3）／掲載版：Nat Methods (2025), doi:10.1038/s41592-025-02836-7

解釈｜ナノボディの応用例

熱安定性の予測から、検証できる仮説へ

ESM-2を実験値へ適応し、SAEで調べる

Murakamiら：ナノボディの融解温度をESM-2で予測。追加学習後の表現をSAEへ入力し、活性と温度の関係を線形モデルで読む。

$$\hat{T}_m = b + \sum_k w_k \bar{z}_k$$

図：特徴が強く反応する残基を構造に配置。Tyr 104やMet 41などの局所環境に着目する（番号はAHo方式）。

自由エネルギー計算でも安定化・不安定化の方向を検証。物理的な仮説を絞る手掛かりであり、一般的な因果法則の確定ではない。

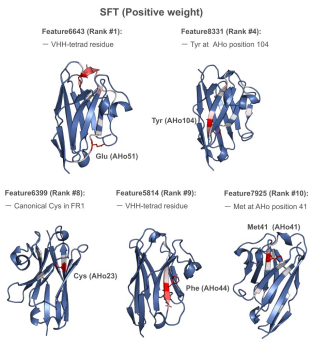


Fig. 6の正の重みの特徴を切り出し。構造中の赤い領域が活性位置。

Murakami, Hashidate & Matsunaga, Bioinformatics 42, btag685 (2026), Fig. 6（著者原稿）, doi:10.1093/bioinformatics/btag685

結果

生成した配列がそのまま残ったか

16 個のうち 9 個は、配列確認で新たな変化が見つからなかった。

残り 7 個では、生成配列から一塩基変化や欠失が見つかった。

生成案と、実験後に確認した配列を区別する。

King et al., bioRxiv v1 (2025) · doi:10.1101/2025.09.12.675911

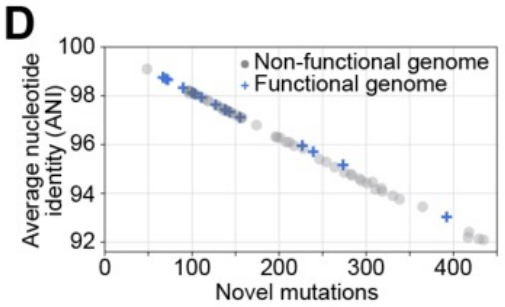
新規性

どれくらい自然配列から離れたか

Fig. 4D：横軸は既知配列からの変化数、縦軸は配列一致率。

機能した候補の最近縁配列との一致率は 93.0〜98.8%。

青は機能あり、灰は機能未確認の候補。変化数だけで機能は決まらない。



King et al., bioRxiv v1 (2025), Fig. 4D · doi:10.1101/2025.09.12.675911

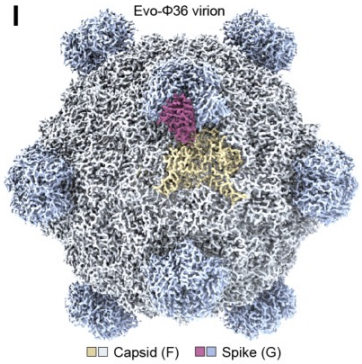
構造とのつながり

構造を調べると何が加わるか

Fig. 4I：生成された候補の粒子をcryo-EM で観察した密度図。

配列比較だけでなく、タンパク質どうしの構造的な整合性を調べられる。

密度が見えない領域を「存在しない」とは断定できない。



King et al., bioRxiv v1 (2025), Fig. 4I · doi:10.1101/2025.09.12.675911

付録｜参考文献

参考文献：言語モデルの原理

Vaswani et al. (2017). Attention Is All You Need. NeurIPS 30.

Devlin et al. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. NAACL, 4171–4186.

Radford et al. (2018). Improving Language Understanding by Generative Pre-Training. OpenAI.

Brown et al. (2020). Language Models are Few-Shot Learners. NeurIPS 33.

Ouyang et al. (2022). Training language models to follow instructions with human feedback. NeurIPS 35.

Kaplan et al. (2020). Scaling Laws for Neural Language Models.

Hoffmann et al. (2022). Training Compute-Optimal Large Language Models. NeurIPS 35.

Su et al. (2024). RoFormer: Enhanced transformer with Rotary Position Embedding. Neurocomputing 568, 127063.

付録｜参考文献

参考文献：ゲノムの予測と設計

Zhou et al. (2024). DNABERT-2: Efficient Foundation Model and Benchmark for Multi-Species Genome. ICLR.

Dalla-Torre et al. (2025). Nucleotide Transformer: building and evaluating robust foundation models for human genomics. Nature Methods 22, 287–297.

Avsec et al. (2026). Advancing regulatory variant effect prediction with AlphaGenome. Nature 649, 1206–1218.

Brixi et al. (2026). Genome modelling and design across all domains of life with Evo 2. Nature 652, 1349–1361.

Poli et al. (2025). Systems and Algorithms for Convolutional Multi-Hybrid Language Models at Scale.

King et al. (2025). Generative design of novel bacteriophages with genome language models. bioRxiv v1（図の出典）.

King et al. (2026). Generative design of bacteriophages with genome language models. Science 393, eaec2657（掲載版）.

付録｜参考文献

参考文献：タンパク質の予測と解釈

Lin et al. (2023). Evolutionary-scale prediction of atomic-level protein structure with a language model. Science 379, 1123–1130.

Rives et al. (2021). Biological structure and function emerge from scaling unsupervised learning to 250 million protein sequences. PNAS.

Elnaggar et al. (2022). ProtTrans. IEEE TPAMI.

Madani et al. (2023). Large language models generate functional protein sequences across diverse families. Nature Biotechnology.

Nijkamp et al. (2023). ProGen2: Exploring the boundaries of protein language models. Cell Systems.

Hayes et al. (2025). Simulating 500 million years of evolution with a language model. Science.

Meier et al. (2021). Language models enable zero-shot prediction of the effects of mutations on protein function. NeurIPS.

Schmirler, Heinzinger & Rost (2024). Fine-tuning protein language models boosts predictions across diverse tasks. Nat Commun 15, 7407.

Simon & Zou (2025). InterPLM: discovering interpretable features in protein language models via sparse autoencoders. Nat Methods.

Murakami, Hashidate & Matsunaga (2026). Mechanistic interpretability of fine-tuned protein language models for nanobody thermostability prediction. Bioinformatics 42, btag685.

ESM2 のスケーリング

配列予測と構造精度は同じ量か

同じ270,000学習ステップ：perplexityは10.45（8M）から6.37（15B）へ低下。
perplexity＝exp(平均損失)。配列の予測と、個々の構造の正確さは別々に評価する。

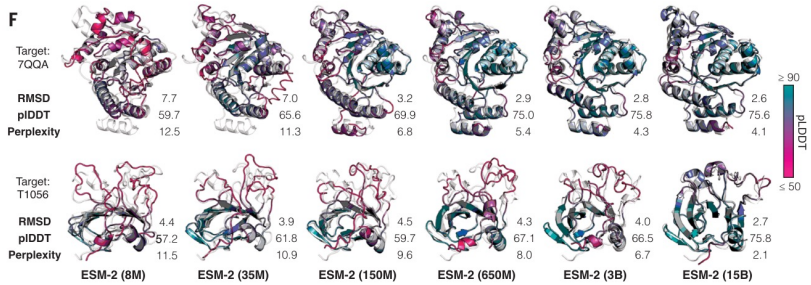


Fig. 1F：左からモデル規模が増大。構造精度の改善は一様ではなく、急に改善する例もある。

Lin et al., Science (2023), Fig. 1F · doi:10.1126/science.ade2574