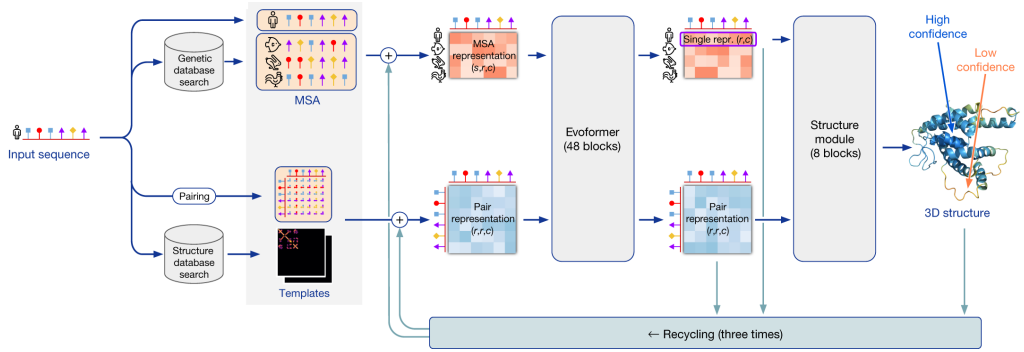
生命情報工学特論　第05回

AlphaFold 2 による構造予測

アミノ酸配列から立体構造を予測する
構造表現・予測の仕組み・ColabFold演習



図：Jumper ら, Nature 596:583 (2021) Fig. 1e を切り出し（CC BY 4.0）

松永 康佑

埼玉大学 大学院理工学研究科
理化学研究所 計算科学研究センター ｜ 2026年10月31日（オンデマンド）

今日の内容

配列の情報を、三次元の配置へ変換する

AlphaFold 2 は、既知の配列・構造から学んだ関係と、三次元幾何の性質を組み合わせる。

配列とMSA

相同配列の保存・変異

→

Evoformer

MSA表現とペア表現を更新

→

Structure Module

局所フレームから原子座標

MSA：進化的に関係のある複数の配列を、対応する位置が同じ列になるように整列した表。
出力：原子座標と予測の信頼度。折り畳みの時間経過を計算するものではない。

第03回の構造観察 → 第04回のAttention → 今回の構造予測。
演習では、同じユビキチンを配列から予測して、構造と信頼度を対応させる。

講義の流れ

表現の更新から構造生成までを追う

構造予測の出発点｜12分

座標・距離行列、相同配列と共進化、AF1からAF2への変化。

Evoformer｜20分

MSA表現とペア表現、行と列のAttention、外積の平均、三角形の更新。

Structure Module｜20分

二面角・局所座標系、IPA、学習時の誤差、リサイクリング。

信頼度とまとめ｜8分

pLDDT・PAE、予測で分かることと分からないこと。

配列はわかっても、構造はわかっていない

構造を知りたい理由

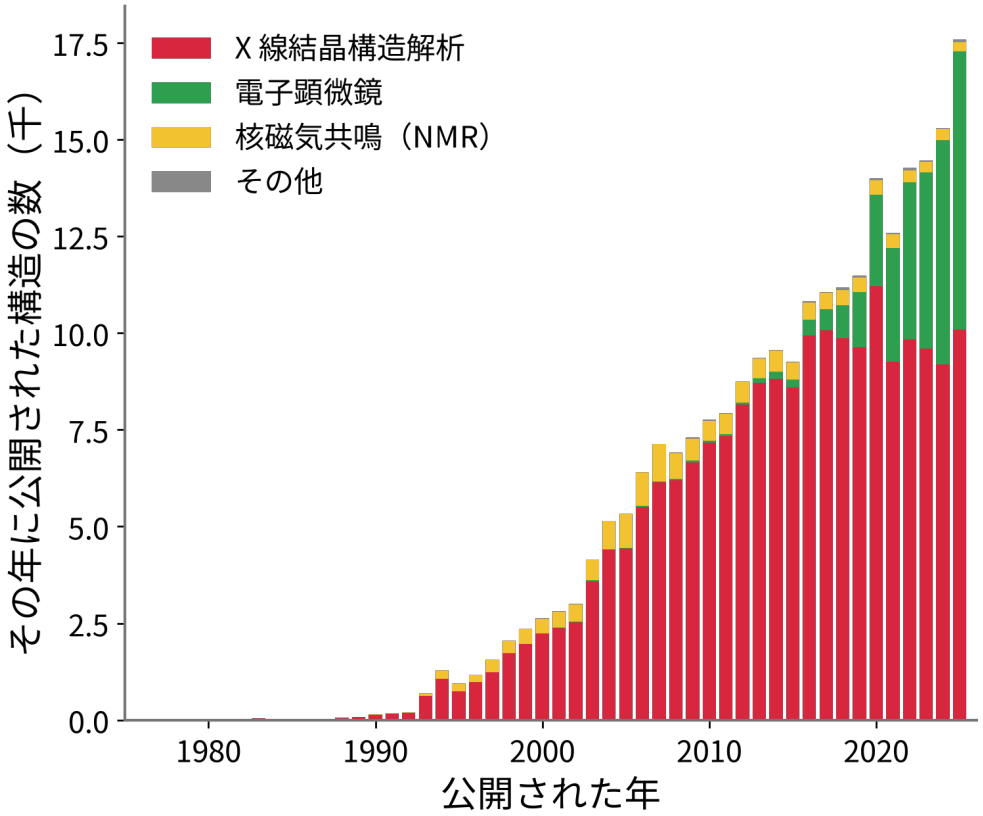
構造は、タンパク質の動き、結合する相手、はたらくしくみ、薬の設計を考える出発点になる。

配列と構造のギャップ

配列が分かっていても、実験構造がまだ決まっていないタンパク質は多い。

構造を実験で決めるには時間と費用がかかる。計算で予測できれば、このギャップを埋められる。

PDB（Protein Data Bank）：実験で決めた立体構造を集めた公開データベース



その年に PDB で公開された構造の数（RCSB PDB の集計、2025 年まで）

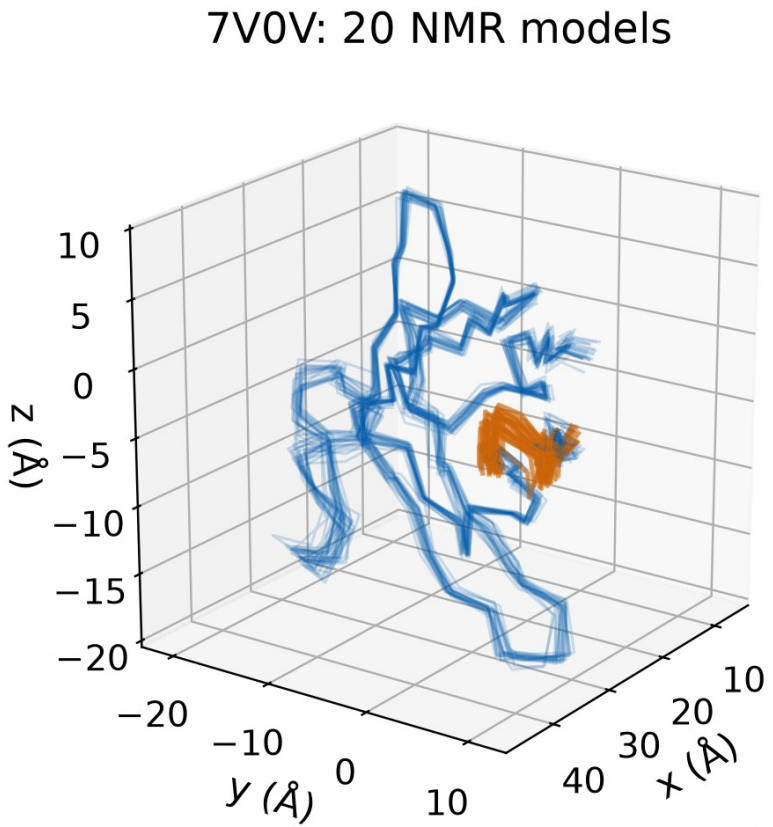
全原子・主鎖・Cαは異なる解像度

全原子は側鎖の向きや衝突まで評価できますが、水素の付加や命名の違いを処理する必要があります。主鎖N–Cα–C–Oはペプチド面の向きも残します。

Cαだけなら原子対応が簡単で高速です。一方、同じCα配置から複数の側鎖配置が生じ、ペプチド面や水素結合を一意には決められません。

入力がCαだけの生成モデルを全原子へ復元した場合、復元器の誤差も最終指標に含まれます。生成器と復元器を分けて評価します。

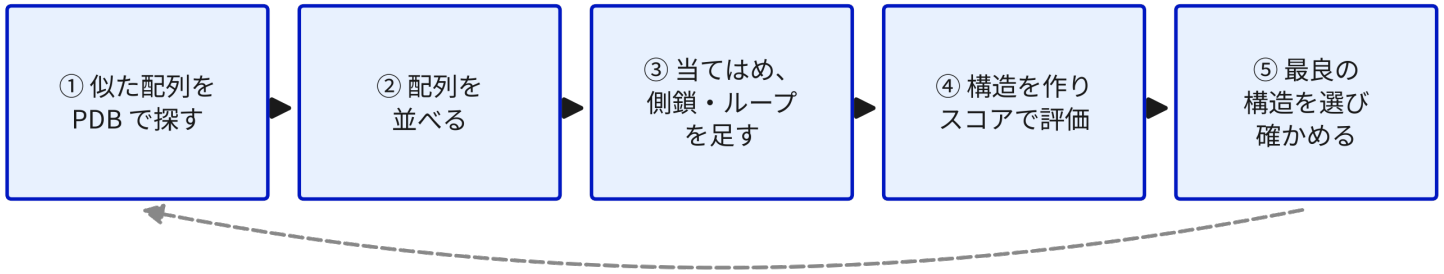
$$d_{ij} = \|x_i - x_j\|_2, \qquad 1\ \mathrm{nm} = 10\ \text{Å}$$



Framework-fit Cα traces; orange: author residues 99–108
Submitted NMR models are not equilibrium samples.

出典：RCSB PDB / wwPDB

ホモロジーモデリングの手順



ホモロジーモデリングの手順（模式図）

天然らしさの評価には、物理的な自由エネルギーか、PDB から作る統計的ポテンシャル（後で説明）を使う。

手順

① PDB で似た配列を探す（BLAST）

② テンプレートと配列を並べる（アラインメント）

③ 当てはめて、側鎖・ループの原子を足す

④ 構造をたくさん作り、エネルギーやスコアで評価する

⑤ 最良の構造を選び、精密化する

⑥ 要件を満たさなければ、別のテンプレートでやり直す

距離行列は回転と並進を取り除く

全原子対の距離を並べると、構造を重ね合わせなくても比較できます。回転は長さを保ち、並進は差を取ると消えるためです。

$$\|(Rx_i + t) - (Rx_j + t)\|^2 = (x_i - x_j)^T R^T R (x_i - x_j) = d_{ij}^2$$

$$C_{ij} = \mathbf{1}[d_{ij} < r_c], \quad V = \det[x_2 - x_1, x_3 - x_1, x_4 - x_1]$$

$$J = I - \frac{1}{N}\mathbf{1}\mathbf{1}^T, \quad B = -\frac{1}{2} J (D \circ D) J = X_c X_c^T$$

$$D_{ij}^2 = B_{ii} + B_{jj} - 2B_{ij}, \quad B \succeq 0, \quad \operatorname{rank} B \le 3$$

$$\det[r_2 - r_1, r_3 - r_1, r_4 - r_1] \mapsto \det(R) \det[r_2 - r_1, r_3 - r_1, r_4 - r_1]$$

距離行列はN×Nですが、成分は独立ではありません。三角不等式や三次元へ埋め込める条件があり、任意の対称行列が分子構造になるわけではありません。

距離は鏡映でも変わりません。キラリティを保つには、符号付き体積や二面角など向きの情報を加えます。接触マップはさらに閾値化するので情報を失います。

出典：Mariani et al. (2013)

共進化：同時の変異が接触の手掛かりになる

MSA（マルチプルシーケンスアライメント）

ターゲットに似た、進化的に関係のある配列をたくさん並べたもの。

共変異（共進化）

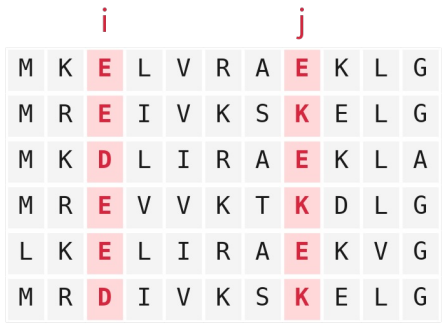
列 i でアミノ酸が変わるとき、列 j でも変わる。

なぜ起こるか

i と j が接していると、i が大きくなる変異は j が小さくなる変異といっしょに起こりやすい。

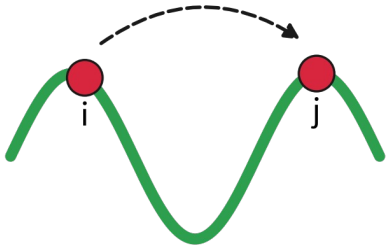
使い方

共変異する対を接触の候補とみなし、構造を組み立てる制約に使う（EVfold）。テンプレートがない膜タンパク質にも使える。

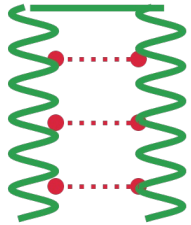


(A) 似た配列を並べ、いっしょに変わる列 i と j を見つける

（i が E なら j は K、i が K なら j は E）



(B) i と j は構造の中で接している、と推測する



(C) 推測した接触（赤の点線）を制約にして、構造を組み立てる

EVfold の考え方（模式図）

直接の相関と間接の相関

相互情報量（MI）

列 i と列 j の相関をそのまま測る。

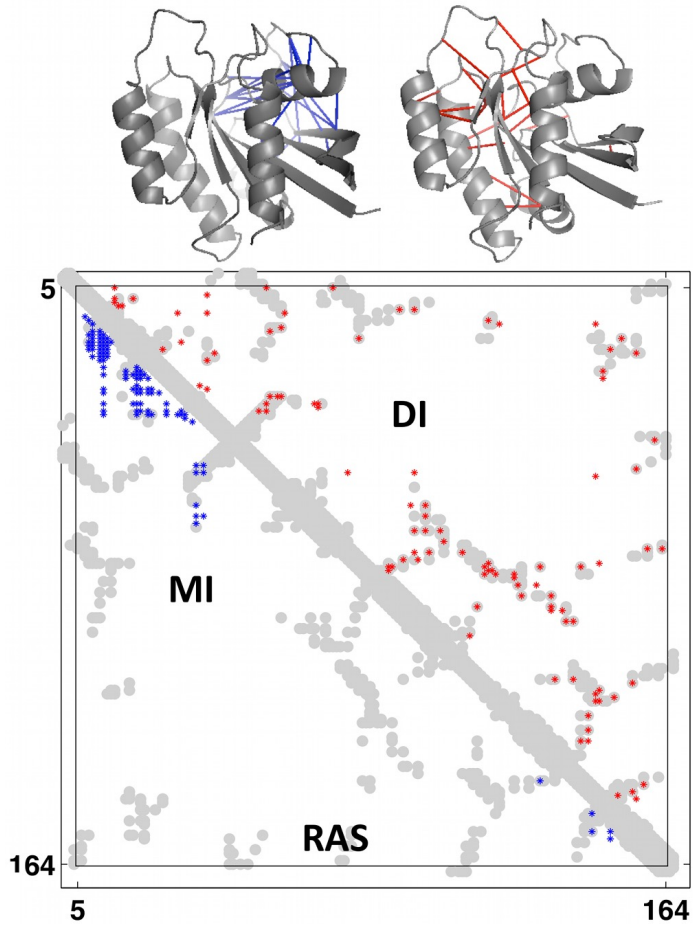
$$\mathrm{MI}_{ij} = \sum_{a,b} f_{ij}(a,b) \ln \frac{f_{ij}(a,b)}{f_i(a)\, f_j(b)}$$

$f_i(a)$：列 i にアミノ酸 a が現れる頻度、$f_{ij}(a,b)$：対の頻度（第 8 章）

直接結合分析（DCA）

i–k、k–j の接触から生じる i–j の見かけの相関（間接的な相関）を取り除き、直接の結合だけを取り出す。

どちらも、似た配列が十分な数ないとうまくいかない。



Ras の接触予測。灰：正解、青：MI、赤：DI（DCA）（Marks ら, PLoS One 6:e28766 (2011) Fig. 3 の右半分を切り出し、CC BY）

教師あり学習で共進化を見分ける

統計の方法（MI・DCA）の限界

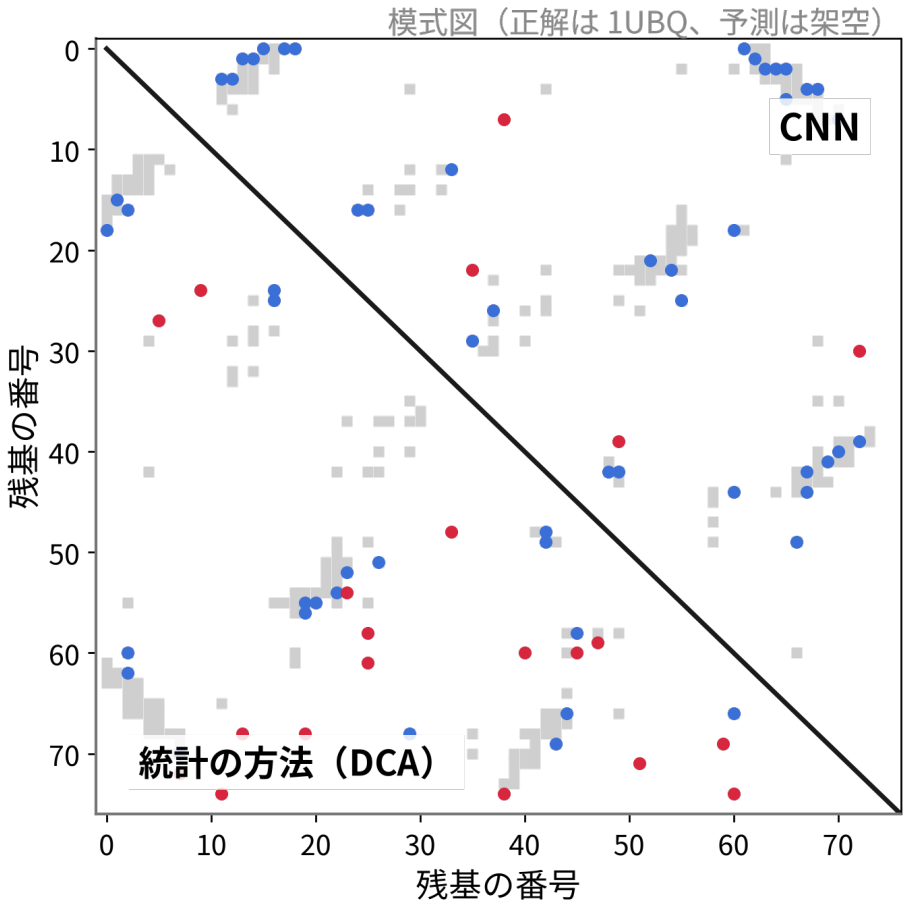
配列の数が有限なための揺らぎや、進化の中で偶然に起きた変異が混ざる。

教師あり学習

正解のついたデータでモデルを前もって学習させる方法。

既知の構造から作った正解の接触マップと、MSA から予測した接触マップを比べ、偽陽性と見落とし（偽陰性）を学ばせる。

代表例は、畳み込みニューラルネットワーク（CNN）を使った方法。



左下：統計の方法（DCA）、右上：CNN。青：正解、赤：偽陽性、灰：見落とし（模式図）

AlphaFold 1：距離の分布を予測する

AlphaFold 1（2018 年、CASP13 で 1 位）

ネットワーク：CNN の層を深く重ねられるようにした ResNet

出力：残基間の距離分布（Cβ 原子間、Gly は Cα）と主鎖の二面角の分布

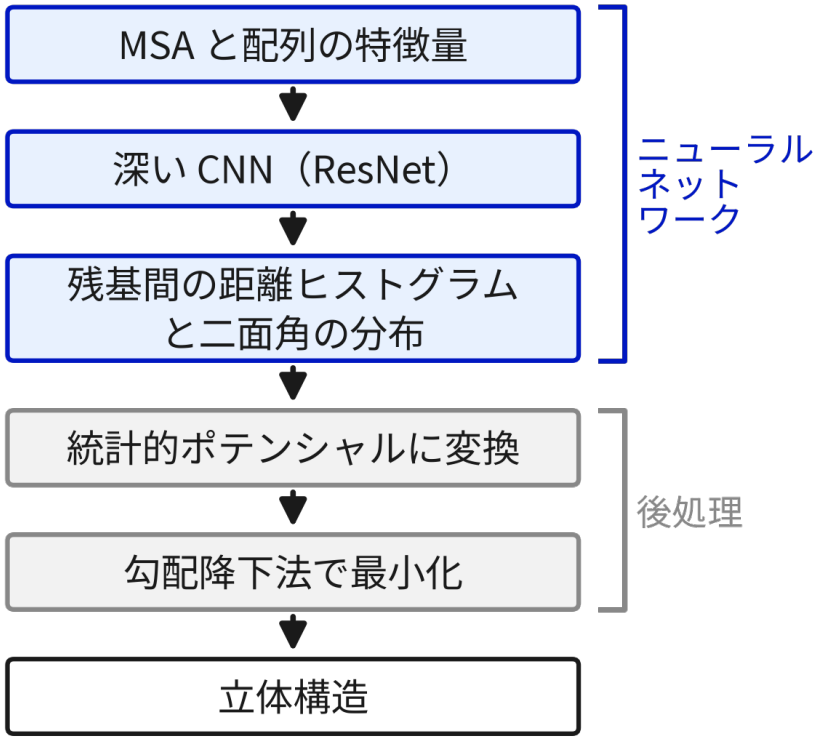
学習：PDB の構造（重複を除いたもの）で教師あり学習

補足：後処理の考え方（簡略化）

$$V(\mathbf{x}) = -\sum_{i<j} \ln p_{ij}\left(d_{ij}(\mathbf{x})\right) - \sum_{i} \ln p_i\left(\phi_i, \psi_i\right)$$

$$\mathbf{x} \leftarrow \mathbf{x} - \eta \nabla V(\mathbf{x})$$

予測した分布を統計的ポテンシャルに直し、勾配降下法で最小化する。



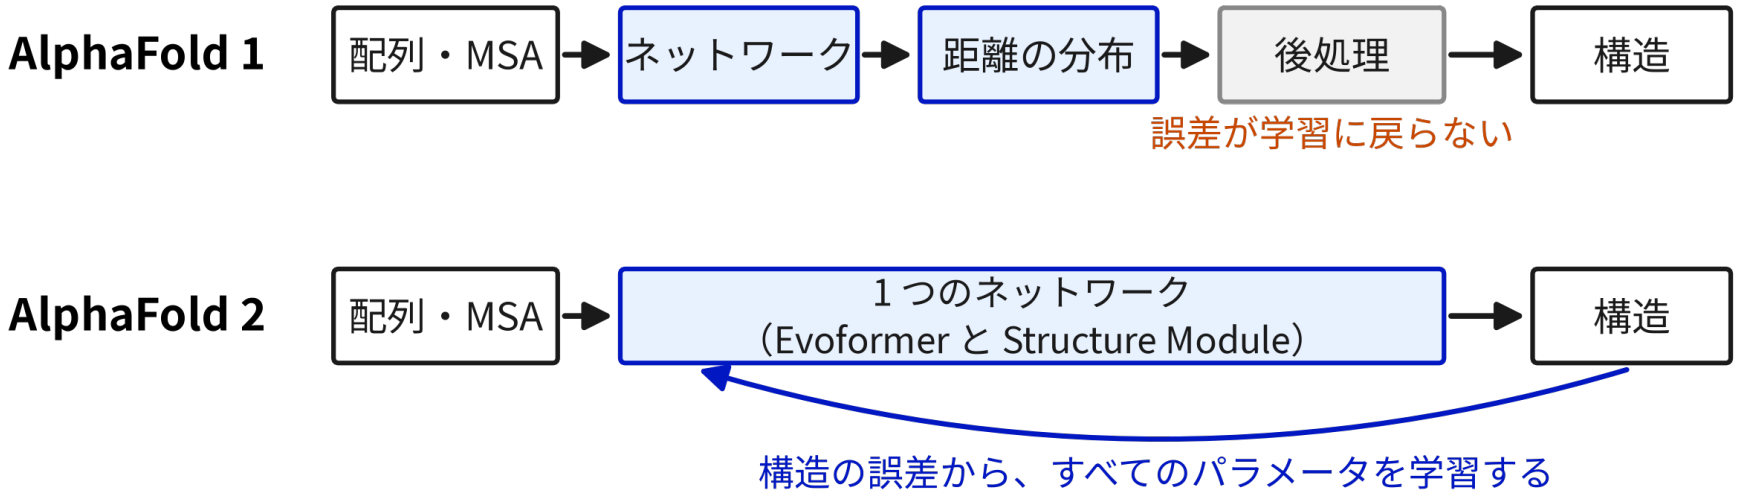
AlphaFold 1 の 2 つの限界

① CNN の局所性

小さなフィルタを積み重ねて少しずつ広く見るので、配列上で遠く離れた残基の関係は間接的にしか捉えられない。

② エンドツーエンドでない

距離の分布から構造を作る後処理が、ネットワークの外にある。構造の誤差が学習に戻らない。



帰納バイアス：前もって組み込む仮定

帰納バイアス（inductive bias）

モデルに前もって組み込んでおく仮定。データから学ばなくてよい性質を、しくみとして持たせる。AlphaFold 2 は、注意機構（トランスフォーマー）に、タンパク質の構造が満たすべき性質を組み込んだ。

しくみ	組み込んだ仮定
CNN の畳み込み	模様が平行移動しても同じように見つかる（並進同変性）
Evoformer の行方向の注意	残基対の学習済み特徴を、注意の重みへ反映する
外積の平均	MSA の列どうしの相関（共進化）が、残基の対の関係を表す
三角形の更新	3 残基の関係を同時に使い、幾何学的な整合性を学びやすくする
Invariant Point Attention	タンパク質全体を回転・並進しても、相対的な位置関係は変わらない

注意機構の計算

① 重みを決める

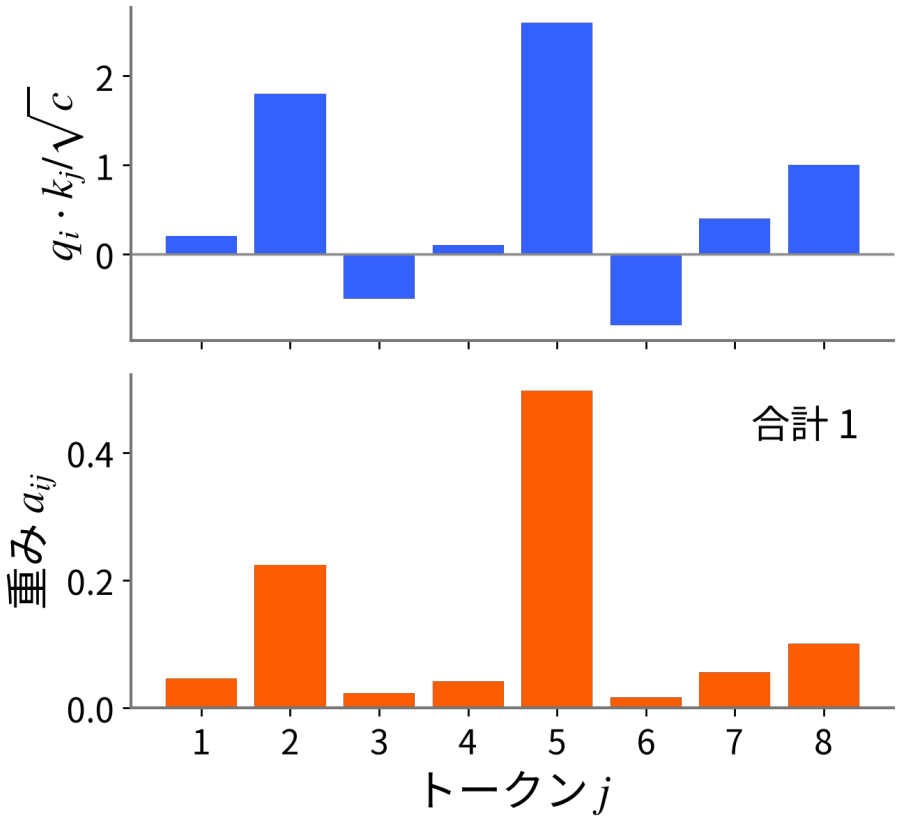
$$a_{ij} = \mathrm{softmax}_j\left(\frac{\mathbf{q}_i \cdot \mathbf{k}_j}{\sqrt{c}}\right), \qquad \mathrm{softmax}_j(g_j) = \frac{e^{g_j}}{\sum_k e^{g_k}}$$

c：キーの次元。重みは正で、jについて合計が 1。

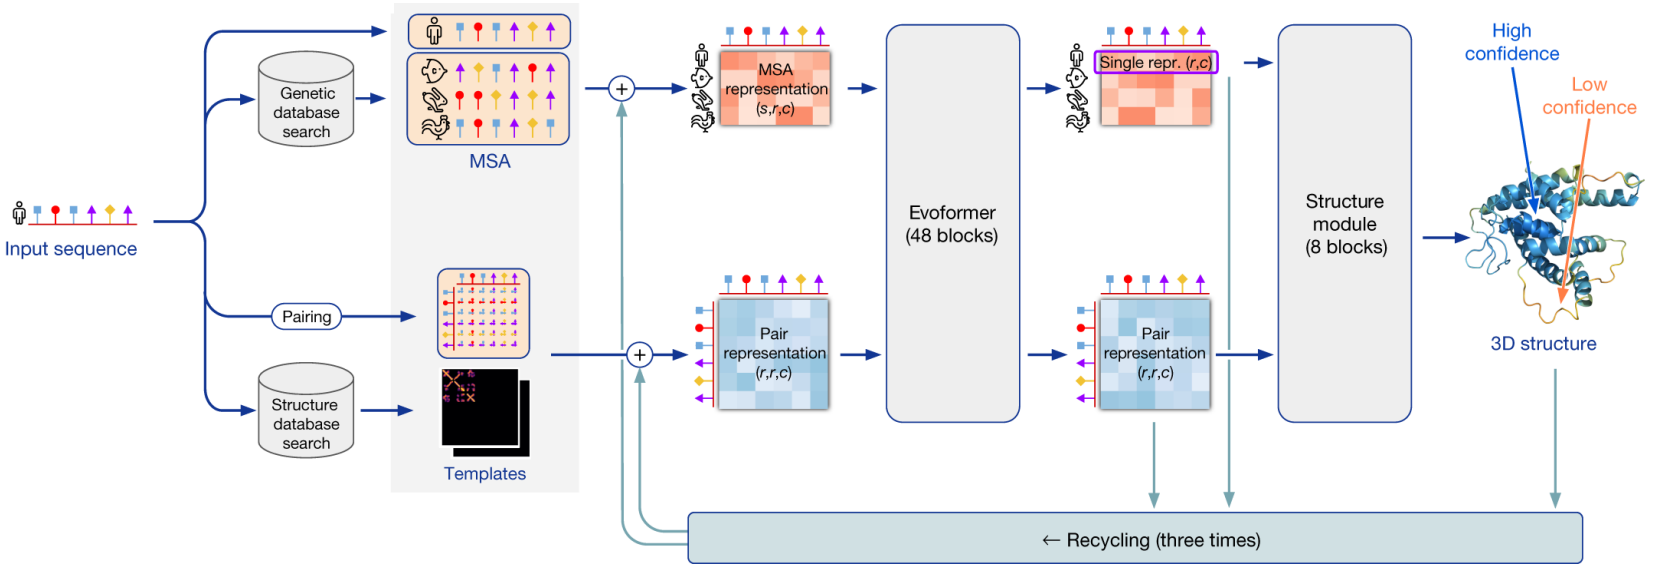
② バリューの重み付き和

$$\tilde{\mathbf{z}}_i = \sum_j a_{ij}\,\mathbf{v}_j$$

模式図



AlphaFold 2 の全体像



AlphaFold 2 のネットワーク（Jumper ら, Nature 596:583 (2021) Fig. 1e を切り出し、CC BY 4.0）

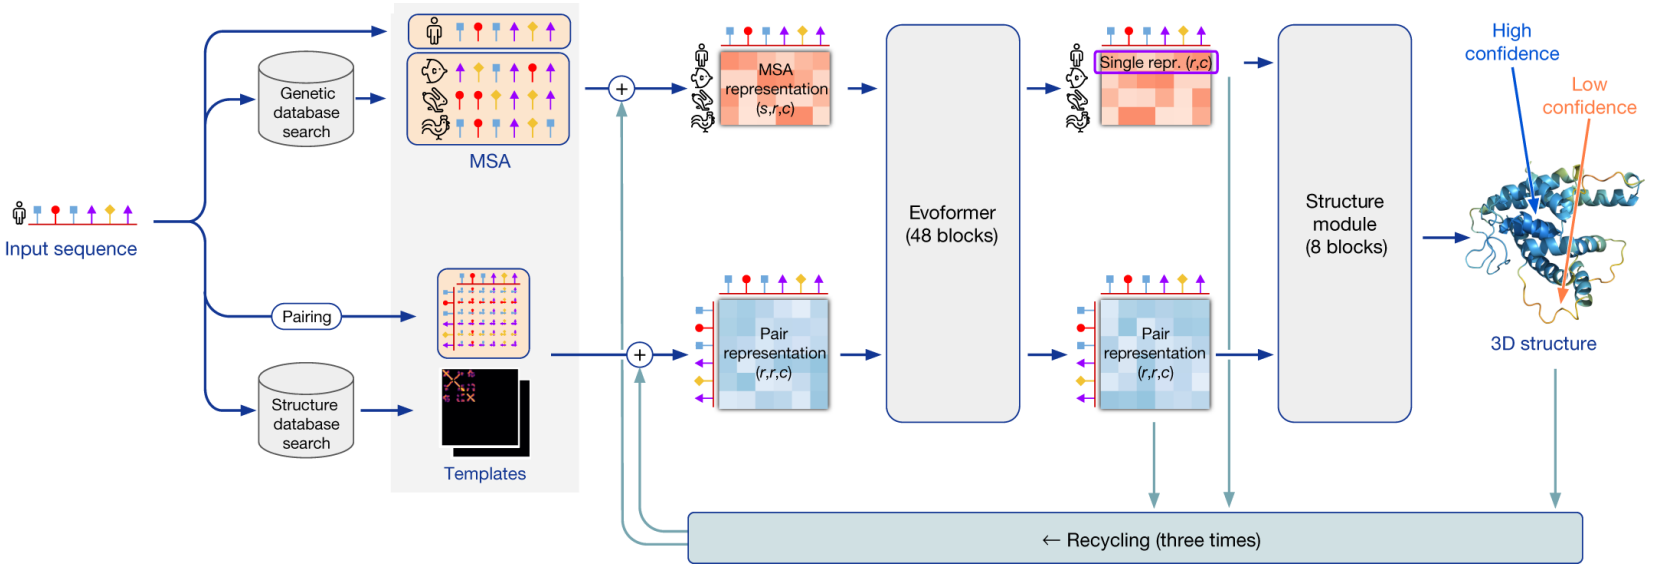
2 つの表現

MSA 表現 M：Nseq × L × cM。各マスは特徴ベクトル

ペア表現 P：L × L × cP。距離そのものではない

入力：クエリ配列、配列データベースから作る MSA、構造データベースから探すテンプレート（なくても動く）

AlphaFold 2 の全体像



AlphaFold 2 のネットワーク（Jumper ら, Nature 596:583 (2021) Fig. 1e を切り出し、CC BY 4.0）

入力：クエリ配列、配列データベースから作る MSA、構造データベースから探すテンプレート（なくても動く）

2 つの部分

Evoformer（48 ブロック）：M と P をやりとりさせて更新する（エンコーダー）

Structure Module（8 ブロック）：立体構造を作る（デコーダー）

リサイクリング：出力を入力へ戻す。回数は設定で変わる

ペア表現の1マスにも、ベクトルを置く

距離行列 D

座標から決まる1つの実数
単位は Å、対称、対角は0

0	4	8	12
4	0	4	8
8	4	0	4
12	8	4	0

$$D_{ij} = \|\mathbf{x}_i - \mathbf{x}_j\|$$

模式例：4残基。色は実測値を表さない。

ペア表現 P

対ごとの特徴ベクトル
各成分の意味は学習で決まる

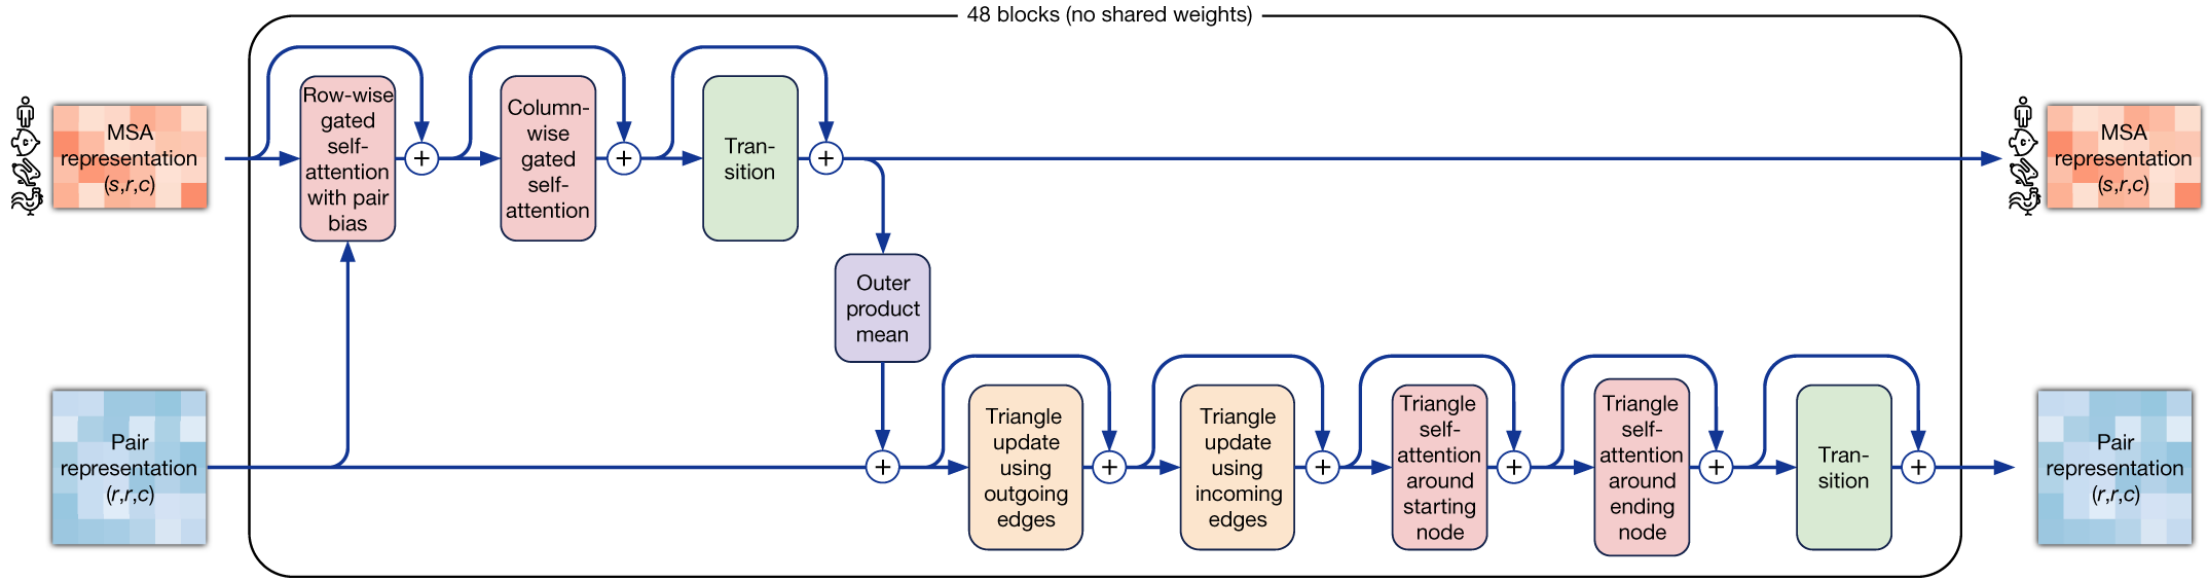
p11	p12	p13	p14
p21	p22	p23	p24
p31	p32	p33	p34
p41	p42	p43	p44

$$\mathbf{p}_{ij} \in \mathbb{R}^{c_P}$$

例：cP = 128
128個の特徴量
（AF2原著）

模式例：4残基。色は実測値を表さない。

Evoformer ブロックの中身



Evoformer ブロックの中の処理（Jumper ら, Nature 596:583 (2021) Fig. 3a を切り出し、CC BY 4.0）

前半：MSA 表現の更新

行方向の自己注意（ペア表現からのバイアスつき）→ 列方向の自己注意 → 変換

後半：ペア表現の更新

外積の平均（MSA → ペア）→ 三角乗法更新 → 三角自己注意 → 変換。48 ブロック重ねる（パラメータは別々）

MSA 表現の更新：行と列に分けた注意

行方向の自己注意：配列 s の中の残基どうし

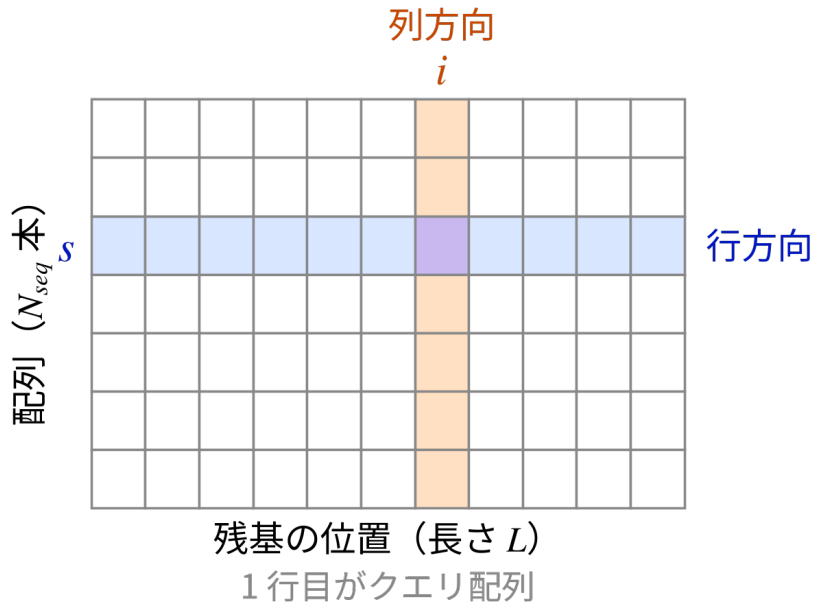
$$a_{sij} = \mathrm{softmax}_j\left(\frac{\mathbf{q}_{si} \cdot \mathbf{k}_{sj}}{\sqrt{c}} + b_{ij}\right)$$

bij：ペア表現の要素 $\mathbf{pij}$ から作るバイアス。学習した対の特徴で注意のスコアを調節する。

列方向の自己注意：同じ残基位置を配列どうしで比べる

保存・変異のパターン（進化の情報）を取り出す。ふつうの自己注意。

行と列に分けるのは、全部のマスどうしで注意をとると計算量とメモリが大きすぎるため（軸方向の注意、axial attention）。



外積の平均：共進化をペア表現へ

外積の平均（outer product mean）

$$\mathbf{a}_{si} \otimes \mathbf{b}_{sj} = \mathbf{a}_{si}\,\mathbf{b}_{sj}^{T}$$

$$\mathbf{o}_{ij} = \frac{1}{N_{seq}} \sum_{s} \mathbf{a}_{si}\,\mathbf{b}_{sj}^{T}$$

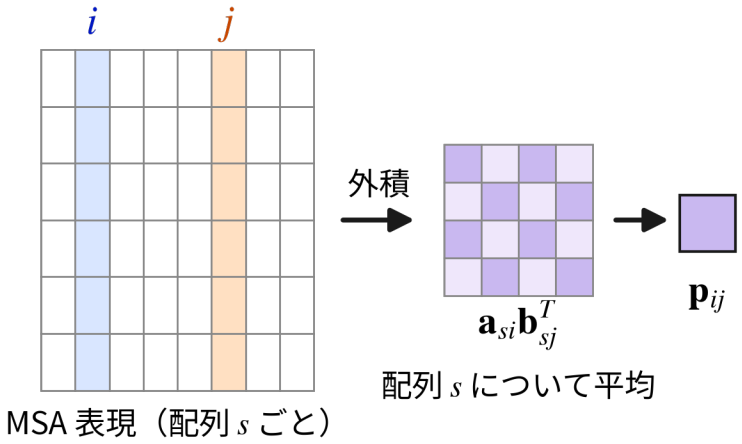
$\mathbf{a}_{si}$, $\mathbf{b}_{sj}$：配列 s の i・j 番目の特徴ベクトルを線形変換した縦ベクトル。$\mathbf{o}_{ij}$ をペア表現 $\mathbf{p}_{ij}$ に足す。

補足：DCA とのつながり

$\mathbf{a}_{si}$、$\mathbf{b}_{sj}$ をアミノ酸の種類を表す 1-hot ベクトルにすると、外積の平均は対の頻度 $f_{ij}(a,b)$ になる。

$$C_{ij}(a,b) = f_{ij}(a,b) - f_i(a)\,f_j(b)$$

DCA が使う共分散。AlphaFold 2 はこれを学習で一般化している。



三角形の整合性：3 残基の関係

三角不等式

$$d_{ij} \le d_{ik} + d_{jk}$$

三角自己注意（starting node）

$$a_{ijk} = \mathrm{softmax}_k\left(\frac{\mathbf{q}_{ij} \cdot \mathbf{k}_{ik}}{\sqrt{c}} + b_{jk}\right)$$

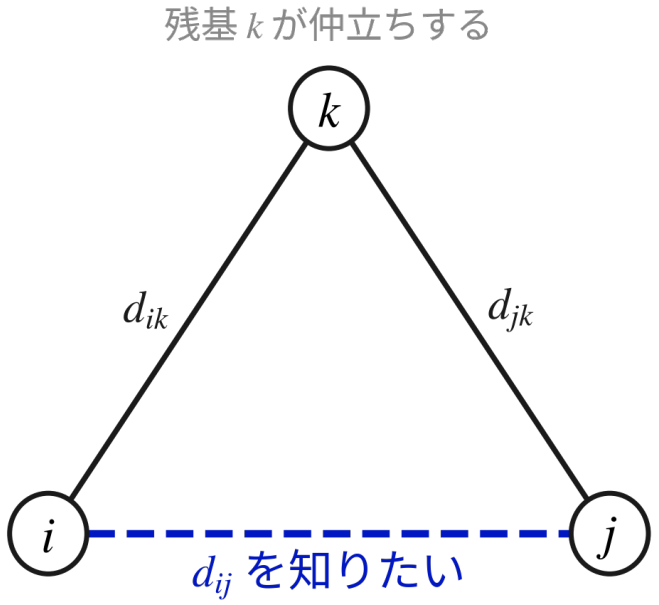
対 (i,j) のクエリと対 (i,k) のキーを比べるとき、残りの辺 (j,k) のバイアスを足す。逆向きの ending node の計算も行う。

補足：三角乗法更新（簡略化）

$$\mathbf{p}_{ij} \leftarrow \mathbf{p}_{ij} + \sum_k \mathbf{a}_{ik} \odot \mathbf{b}_{jk}$$

⊙：成分ごとの積。辺 (i,k) と (j,k) の情報を、k について集めて (i,j) に足す。

三角不等式を厳密に課す処理ではなく、三残基の関係を使って学習する仕組み。



内部座標は結合に沿って構造を表す

三次元座標の代わりに、結合長、結合角、二面角を使います。主鎖ではφがN–Cα、ψがCα–C、ωがペプチド結合周りの回転を表します。

$$X = \mathcal{F}(\{\ell_i\},\{\alpha_i\},\{\theta_i\}), \qquad \mathcal{F}_{\text{end}}(\theta) = X_{\text{anchor}}$$

$$\ell_i = \|r_{i+1} - r_i\|, \quad \alpha_i = \cos^{-1}\frac{(r_{i-1}-r_i)\cdot(r_{i+1}-r_i)}{\ell_{i-1}\ell_i}$$

$$e_1 = \frac{r_i - r_{i-1}}{\|r_i - r_{i-1}\|}, \quad b = r_{i-2} - r_{i-1}, \quad v = b - (b\cdot e_1)e_1$$

$$e_2 = v/\|v\|, \quad e_3 = e_1 \times e_2, \quad [e_1\ e_2\ e_3] \in SO(3)$$

$$r_{i+1} = r_i + \ell_i[-\cos\alpha_i\, e_1 + \sin\alpha_i(\cos\theta_i\, e_2 + \sin\theta_i\, e_3)]$$

結合長と結合角を固定する近似では、主な自由度を二面角へ集中できます。ただし自由度を減らすことと、実際の振動が存在しないことは異なります。

ループでは両端が骨格に結び付いています。角度を独立にサンプリングすると、最後の残基が終端へ戻らないことがあります。閉鎖条件は位置と向きの制約です。

ここでθのゼロ方向は、前の三原子から作るe2です。e3=e1×e2で右手系を固定すると、この基底に対する符号付き二面角を定義できます。三原子が一直線、または結合長がゼロならこの基底は定義できません。

出典：Jumper et al. (2021)

残基の局所座標系を作る

Cαを原点、C方向を第1軸にします。N方向から第1軸成分を除いて第2軸を作り、外積で右手系の第3軸を作ります。

$$e_1 = \frac{C - C_\alpha}{\|C - C_\alpha\|}, \quad v = N - C_\alpha - [(N - C_\alpha) \cdot e_1]e_1$$

$$e_2 = v/\|v\|, \quad e_3 = e_1 \times e_2, \quad Q = [e_1\ e_2\ e_3]$$

$$z_{ij} = Q_i^T(x_j - C_{\alpha,i})$$

$$Q_i^T Q_i = I, \quad \det Q_i = 1, \quad x_j = t_i + Q_i z_{ij}$$

$$\widetilde{Q}_i = RQ_i, \quad \widetilde{t}_i = Rt_i + t, \quad \widetilde{x}_j = Rx_j + t$$

$$\widetilde{Q}_i^T(\widetilde{x}_j - \widetilde{t}_i) = Q_i^T R^T R(x_j - t_i) = z_{ij}$$

全体の座標が回転しても、同じ残基の座標系で見た相対位置は変わりません。局所座標系を使う誤差は、骨格のどこから相手を見ているかを保持できます。

N、Cα、Cが一直線に近いと基底が不安定になります。入力の結合形状を先に検査し、欠損原子のある残基はマスクします。

出典：Jumper et al. (2021)

不変性と同変性を使い分ける

不変な表現は全体の回転・並進を無視します。比較用の距離やスカラーの性質予測に便利です。同変な出力は、入力を回すと同じように回ります。

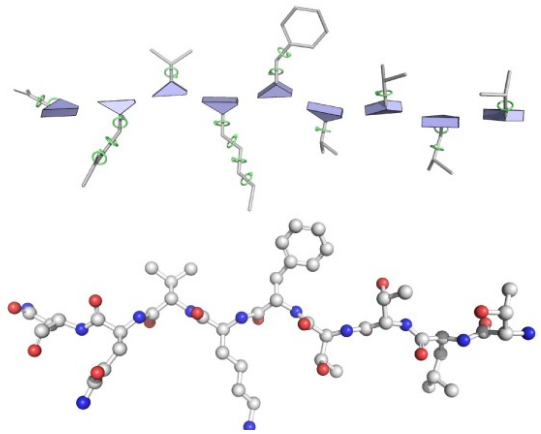
$$f(XR^T + \mathbf{1}t^T) = f(X) \quad \text{(invariant)}$$
$$g(XR^T + \mathbf{1}t^T) = g(X)R^T + \mathbf{1}t^T \quad \text{(coordinate equivariant)}$$
$$SO(3) = \{R : R^TR = I, \det R = 1\}, \quad SE(3) = SO(3) \ltimes \mathbb{R}^3$$
$$\|Rx_i + t - (Rx_j + t)\| = \|x_i - x_j\|$$
$$(Rx_i + t) - (Rx_j + t) = R(x_i - x_j)$$

回転を無視することと、内部変形を無視することは違います。例えばループを骨格に対して回すと内部配置が変わるので、検出すべき変化です。

左右の鏡像まで同じとするO(3)不変量か、正しい回転だけを除くSO(3)/SE(3)かを明示します。タンパク質ではキラリティを区別する必要があります。

出典：Jumper et al. (2021) / Sverrisson et al. (2021)

Structure Module：残基ガスで主鎖を表す



残基ガス。上：残基ごとの剛体（三角形）、下：原子の構造（Jumper ら, Nature 596:583 (2021) Fig. 3e を切り出し、CC BY 4.0）

局所フレーム

$$T_i = (R_i, \mathbf{t}_i), \qquad T_i \circ \mathbf{x} = R_i\,\mathbf{x} + \mathbf{t}_i$$

各残基の N–Cα–C を 1 つの剛体（三角形）とみなし、回転 R_i と並進 $\mathbf{t}_i$ で置く。

特徴

初めは全残基を原点に置く（ブラックホール初期化）。ペプチド結合の束縛はかけず、つながることは学習で身につける。二面角で表すときのような、鎖に沿った誤差の積み重ねがない。

Invariant Point Attention（IPA）

IPA の重み

$$a_{ij}^{h} = \mathrm{softmax}_j\left(w_L \left(\frac{\mathbf{q}_i^h \cdot \mathbf{k}_j^h}{\sqrt{c}} + b_{ij}^h - \frac{\gamma^h w_C}{2} \sum_p \left\| T_i \circ \mathbf{q}_i^{hp} - T_j \circ \mathbf{k}_j^{hp} \right\|^2 \right) \right)$$

前半：シングル表現とペア表現からの重み。後半：各残基から作った 3 次元の点 $\mathbf{q}_i^{hp}, \mathbf{k}_j^{hp}$（$p = 1, \cdots, 4$）を局所フレームで動かし、その距離で重みを下げる。h：ヘッド、w_L, w_C：スケールの係数、γ^h：学習で決まる。

補足：全体を回転・並進 $T_g = (R_g, \mathbf{t}_g)$ しても重みが変わらない理由

$$\left\| T_g \circ \mathbf{u} - T_g \circ \mathbf{w} \right\| = \left\| R_g \left(\mathbf{u} - \mathbf{w} \right) \right\| = \left\| \mathbf{u} - \mathbf{w} \right\|$$

並進は差で消え、回転は長さを変えない。だから「向きや位置を変えても同じ構造」をデータから学ぶ必要がない。

FAPEは局所座標系で位置誤差を測る

残基iの座標系で原子jを表し、予測構造と参照構造で比較します。分子全体を同じように回しても値は変わりません。

$$z_{ij} = Q_i^T(x_j - t_i), \quad \hat{z}_{ij} = \hat{Q}_i^T(\hat{x}_j - \hat{t}_i)$$

$$L_{\mathrm{FAPE}} = \frac{1}{|\mathcal{J}|} \sum_{(i,j)\in\mathcal{J}} \frac{\min(d_{\max}, \|\hat{z}_{ij} - z_{ij}\|)}{d_{\mathrm{scale}}}$$

$$T_i = (Q_i, t_i), \quad T_i^{-1}(x_j) = Q_i^T(x_j - t_i)$$

$$(GT_i)^{-1}(Gx_j) = T_i^{-1}(x_j), \quad G \in SE(3)$$

$$e_{ij} = \|T_i^{-1}(x_j) - \hat{T}_i^{-1}(\hat{x}_j)\|, \quad \rho(e) = \min(e, d_{\max})$$

フレームの向き自体も評価に入るため、Cαの位置だけの距離とは異なる情報を持ちます。遠い誤差の影響を制限するクランプが使われることがあります。

下の式はFAPEの考え方を示す簡略形です。AlphaFoldの損失では適用するフレーム・原子・マスクなどの仕様も重要で、構造評価へ使う場合は定義を固定します。

出典：Jumper et al. (2021)

座標の生成、pLDDT、リサイクリング

Structure Module の 1 ブロック

① IPA でシングル表現を更新する

② 局所フレーム $T_i = (R_i, \mathbf{t}_i)$ を更新する

③ 浅い ResNet で主鎖と側鎖の二面角を予測する

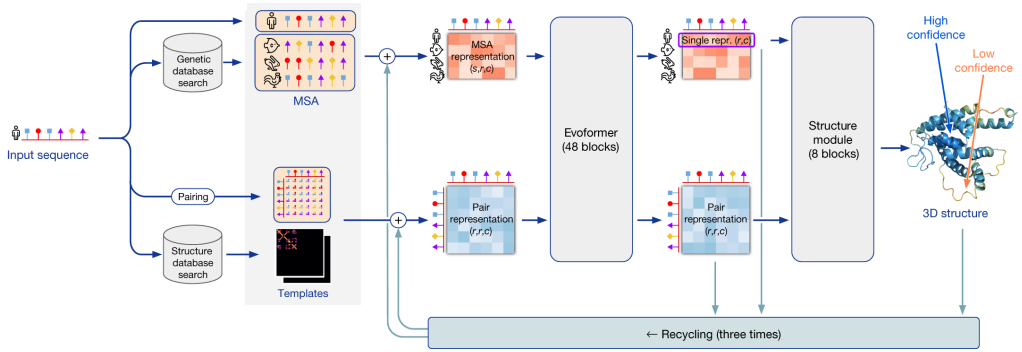
8 ブロック繰り返す（パラメータは共有）。最後に重原子の座標を計算する。

pLDDT：残基ごとの予測の信頼度

構造のどの部分に自信があるかを表す。

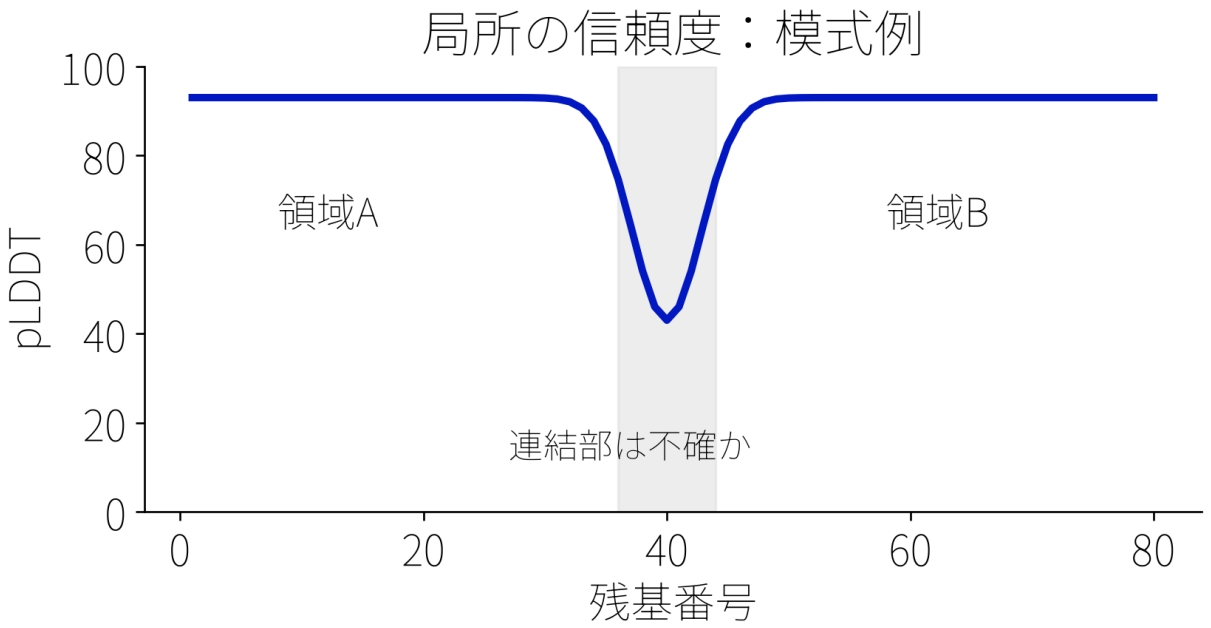
リサイクリング

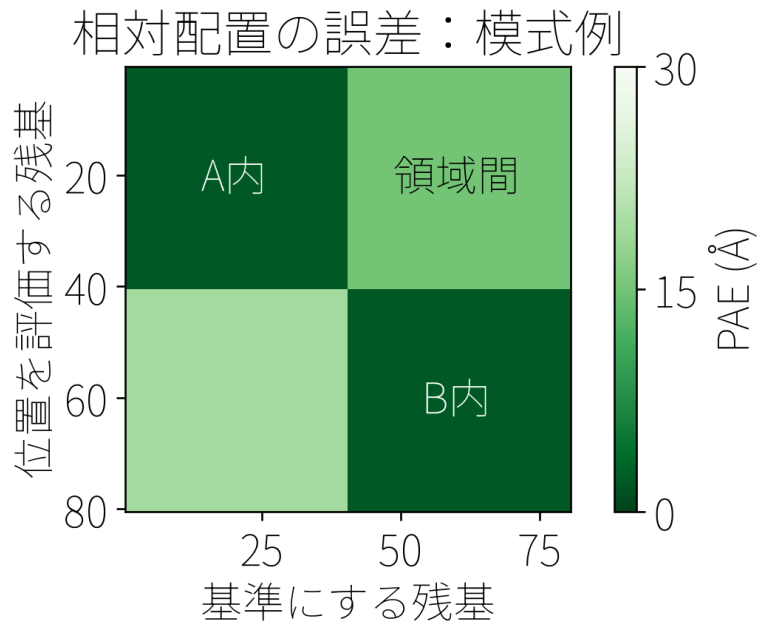
予測した構造を Evoformer の入力に戻して、全体を再計算する（演習では初回の後に3回）。



右端の構造の色が信頼度。下の矢印がリサイクリング（Jumper ら (2021) Fig. 1e を切り出し、CC BY 4.0）

pLDDTとPAEは、別の不確かさを表す





pLDDT：各残基の局所的な信頼度（0–100）。
高いほど信頼できると予測。
正解確率・結合の強さ・安定性ではない。

PAE：相対配置の予測誤差（Å）。
小さいほど信頼できると予測。
距離行列ではなく、一般に非対称。

Jumper et al. (2021), Supplementary Methods 1.9.6–1.9.7／模式図：本教材で作成

その後

AlphaFold 2 の限界

影響

予測構造のデータベース AlphaFold DB（DeepMind と EMBL-EBI）を無償で公開。ソースコードも Apache 2.0 ライセンスで公開され、世界中で使われ改良されている。

限界	内容
① MSA への依存	似た配列が少ないと精度が下がる。MSA を作る計算にも時間がかかる
② 原著の単量体モデル	複合体は別モデルのAlphaFold-MultimerやAF3で扱う
③ 1 つの静的な構造	構造変化や揺らぎなど、機能に欠かせない動きを捉えにくい。状態の存在確率や時間発展を直接は予測しない
④ その他	変異の影響の精密な予測、翻訳後修飾をもつタンパク質の扱い

その後

AlphaFold 2 のあとの発展

名前	何をしたか
AlphaFold-Multimer	タンパク質複合体の構造を高い精度で予測する
ColabFold	高速な配列検索（MMseqs2）とクラウド（Google Colaboratory）で、手軽に速く予測する
RoseTTAFold	配列・残基対・3次元構造を連携させる3トラックのモデル
ESMFold	タンパク質言語モデルを使い、MSA なしで 1 本の配列から予測する。速いが精度は MSA を使う方法に及ばないことも
MSA の間引き・クラスタリング	入力する MSA を変えて、複数の構造（構造の多様性）を出させる
AlphaFold 3	DNA・RNA・低分子・イオンとの複合体まで予測する。構造の生成に拡散モデルを使う

拡散モデル：原子のランダムな配置（ノイズ）から出発し、少しずつノイズを取り除いて正しい構造へ近づける生成のしかた。

まとめ

構造予測とは

配列と構造のギャップを計算で埋める。ホモロジーモデリング、スレッディング、統計的ポテンシャル、共進化（MSA と DCA）が土台。

AlphaFold 1

共進化の情報を深い CNN で読み、接触ではなく距離の分布を予測した。遠い距離の情報まで含まれていた。

AlphaFold 2

注意機構で MSA 表現とペア表現をやりとりさせる。三角形の整合性と、回転・並進で変わらない性質を帰納バイアスとして組み込み、配列から構造までを 1 つのネットワークで予測する。

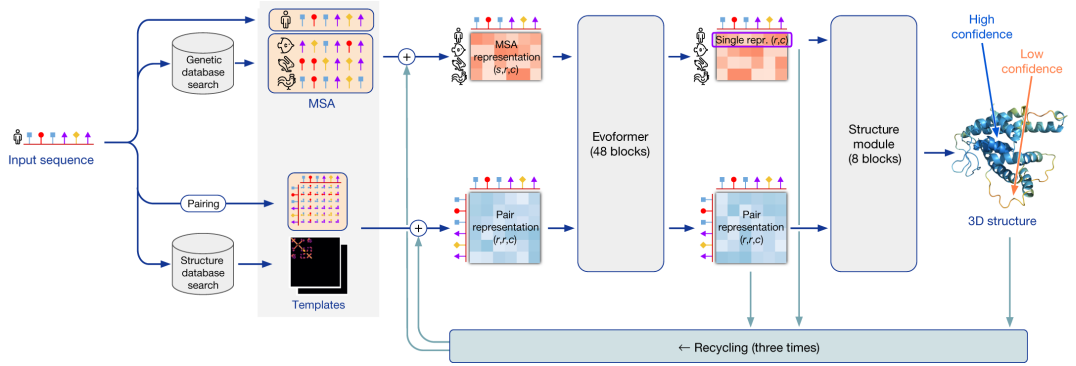
その後

信頼度は実験の代わりではない。複合体は第06回、配列設計は第07回、構造の分布と動きは後半の回へつなぐ。

ユビキチンを配列から予測する

授業リポジトリ →「Colabで開く」

1. Googleアカウントでログイン
2. ランタイムのタイプ：T4 GPU
3. 「すべてのセルを実行」
4. 構造と信頼度の図を観察



入力：ユビキチン76残基。MSA検索あり・テンプレートなし・3回recycle・Amber緩和なし。

演習20分、採点・提出なし。初回準備と計算待ちは環境に依存する。
入力配列は公開MSA検索サーバーへ送られる。今回は公開配列だけを使う。

構造と信頼度を同じ残基番号で読む

立体構造

ドラッグして回転。color = rainbow で配列順、lDDT で信頼度。設定変更後は表示セルだけ再実行。

pLDDT と PAE

局所の信頼度と相対配置の予測誤差を区別。PAEの対角だけでなく、離れた領域間も読む。

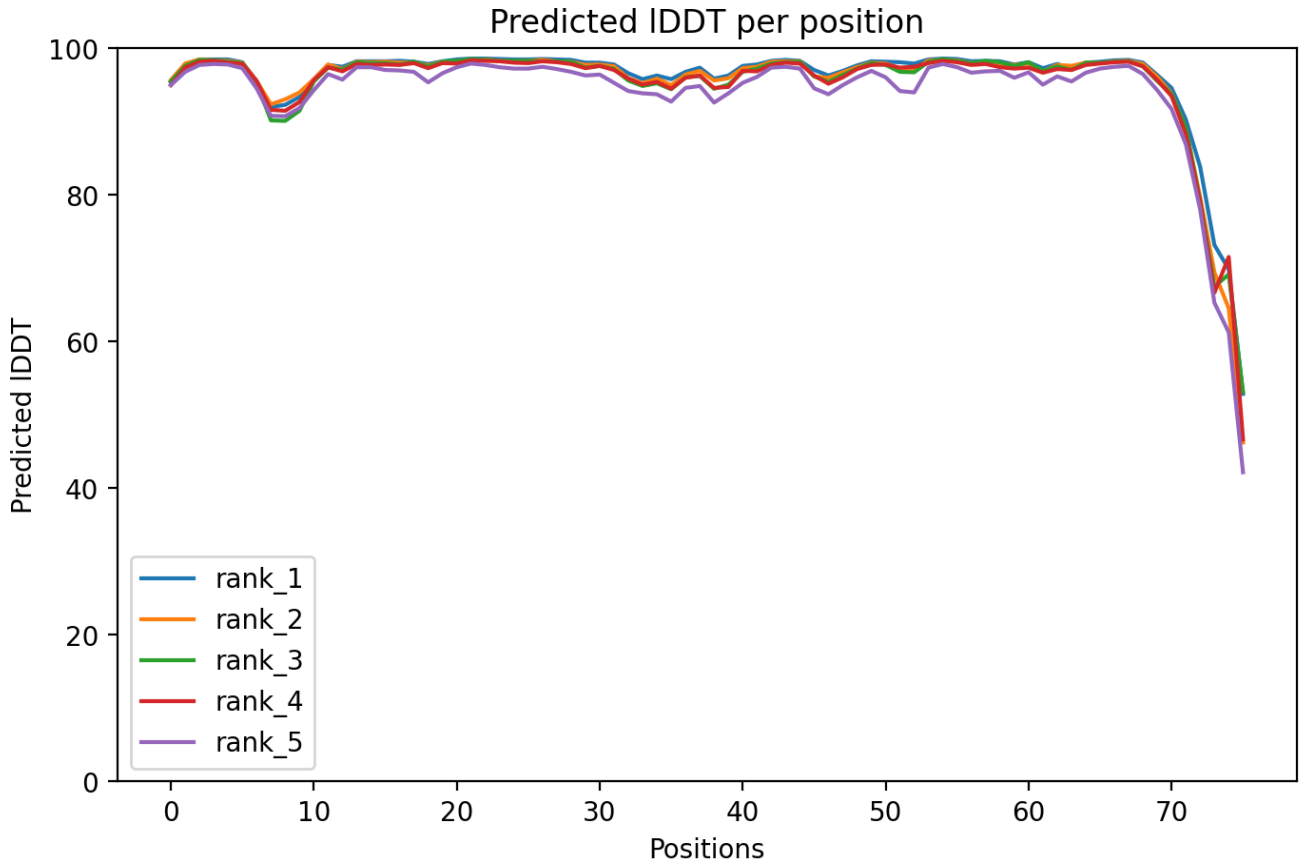
MSA と 5モデル

MSA coverage の偏りを確認。rank_num を変えて構造を比較し、信頼度による順位だと確認。

結果の保存

ZIPのPDB・MSA・scores JSON・logを保存。予測結果の解釈には入力条件も残す。

平均値だけでなく、末端の信頼度を見る



実行結果の読み方

5モデルとも、多くの残基で高い信頼度。

rank 1：平均95.9
最後の76番残基：52.9

平均が高くても、末端まで確かとは限らない。

2026-10-11実行：ユビキチン76残基、T4、5モデル、3 recycle。図のPositionsは0始まり（0が第1残基）。

付録｜従来法・Attention・設計の補足

従来法：用語、配列同一性、二次構造、断片、スレッディング、統計的ポテンシャル、物理計算、CASP。
Attention：Q・K・V、行列による計算、複数ヘッド。
設計：ColabDesignへの接続。

本編では、EvoformerとStructure Moduleを中心に扱う。
付録は授業60分に追加して説明する前提ではない。

付録｜構造予測で使う言葉

用語	意味
ターゲット	構造を予測したいタンパク質
クエリ配列	ターゲットのアミノ酸配列
テンプレート	構造がわかっていて、ターゲットに配列が似たタンパク質
ホモロジーモデリング	テンプレートの構造をもとにターゲットの構造を組み立てる（相同性モデリング）
スレッディング	似た配列がないとき、配列を既知の折り畳みに当てはめ、最も合うものを選ぶ
分子シミュレーション	物理法則にしたがって一から折り畳ませる（今は小さなタンパク質だけ）

基本の考え方：2 つのタンパク質の配列が似ていれば、ふつうは構造も似ている。

付録｜配列同一性は信頼性を考える目安

成功に必要な 4 つのこと

(i) 関連するテンプレートを見つける

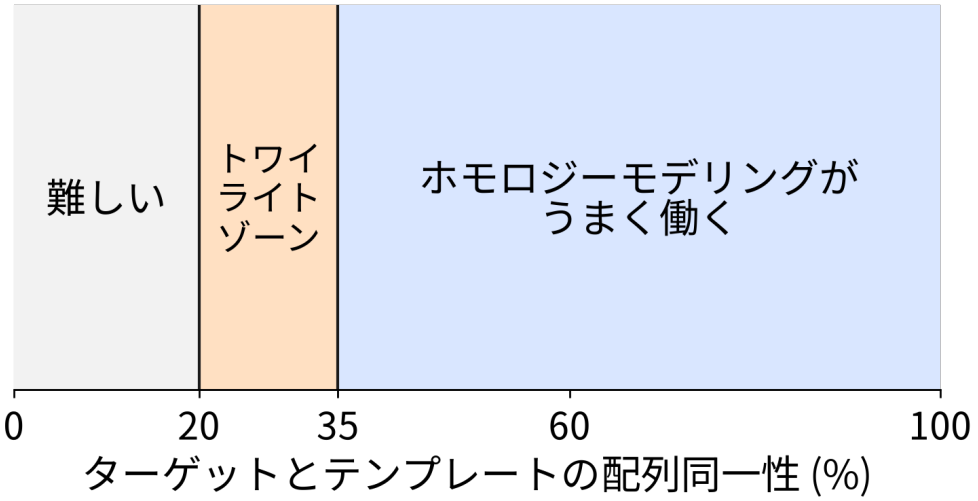
(ii) 良い配列アラインメントを得る

(iii) 天然に近い構造を見分けるスコア関数を用意する

(iv) 天然に近い構造に届くまで、十分に構造を探す

配列同一性とは

2 つの配列を並べたとき、同じアミノ酸が並ぶ位置の割合。



35% 以上：構造を推定しやすいことが多い

20〜35%：トワイライトゾーン。信頼性が下がる

配列長・整列の質・対象にも依存し、絶対的な境界ではない

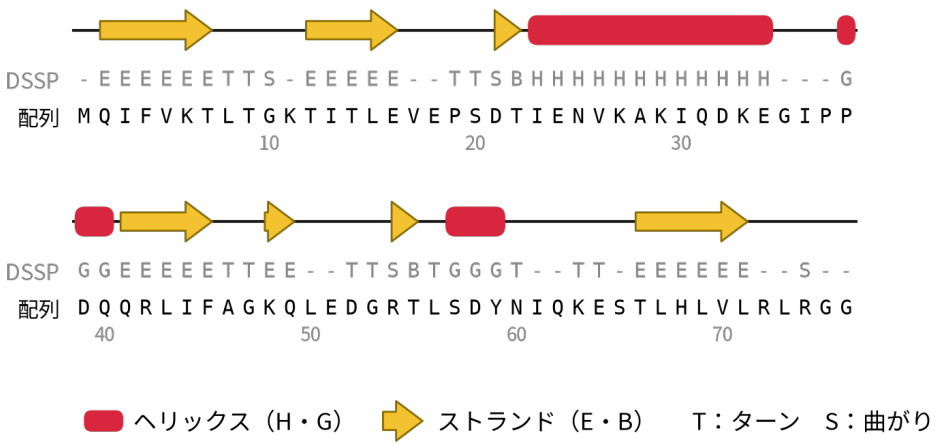
付録｜二次構造を決める・予測する

構造がわかっているとき：DSSP

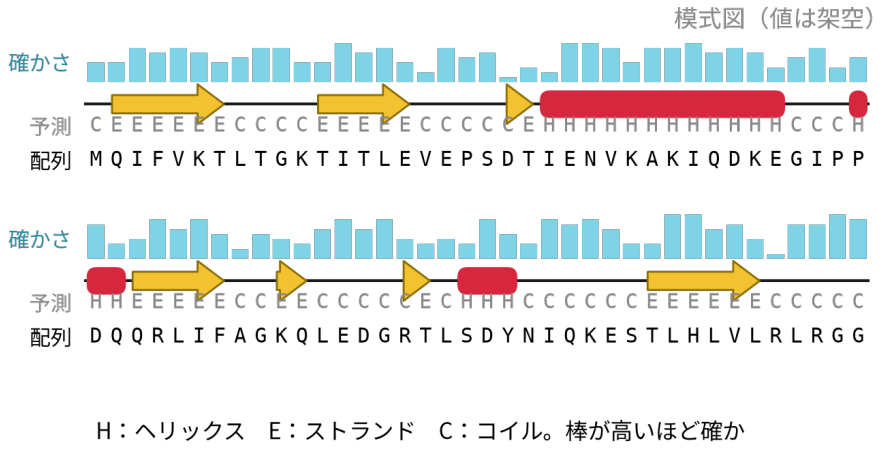
水素結合のパターンから二次構造を割り当てる。8 種類の文字列で表す（H：α ヘリックス、E：β ストランド、G：3_{10} ヘリックス、T：ターン など）。

構造がわからないとき：PSIPRED

配列から二次構造を予測するサーバー。ニューラルネットワークを使う。似た配列の情報も使うと正解率は最大 80% ほど。



DSSP の出力の例：ユビキチン（PDB 1UBQ）



PSIPRED の出力の形（模式図、値は架空）

付録｜9 残基の断片で組み立てる

フラグメント組み立て法

① ターゲットを 9 残基ずつ、ずらしながら区切る

② 各断片で PDB を検索し、似た断片の主鎖の角度 (φ, ψ) を借りる

③ 断片をつなぎ替えながら構造を探し、スコアで評価する

背景

D. Baker らが開発し、予測プログラム Rosetta の中心になった。Baker は 2024 年のノーベル化学賞を AlphaFold の開発者と共に受賞。



9 残基ずつ区切り、PDB の似た断片の
主鎖の角度 (ϕ, ψ) を借りる

→ 断片をつないで、スコアで評価しながら構造を探す

模式図

付録｜スレッディング：既知の折り畳みに当てはめる

手順

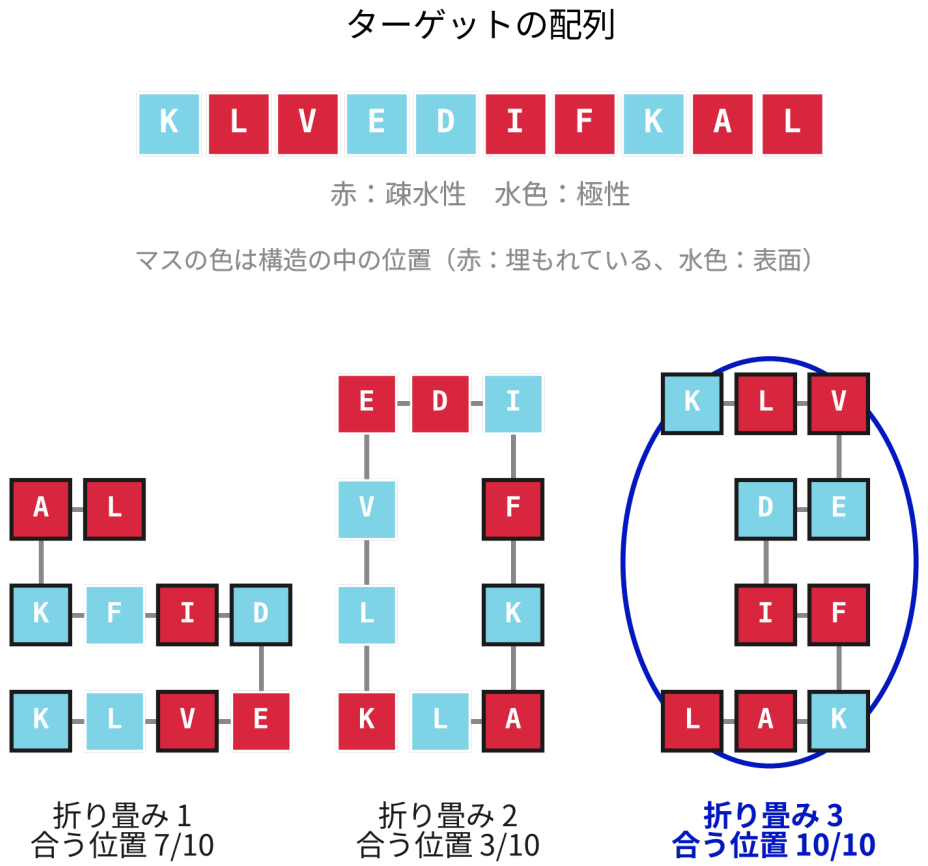
① ターゲットがとりそうな折り畳みを PDB から選ぶ（「動物園」）

② 配列を各構造に当てはめる（アミノ酸を置き換える）

③ 合い方をスコアで比べ、最も合う折り畳みを選ぶ

限界

正しい折り畳みが「動物園」に入っていないと当たらない。挿入・欠失の扱いと、スコア関数の良し悪しにも左右される。



疎水性の残基が埋もれた位置に合う、折り畳み 3 が最適（模式図）

付録｜統計的ポテンシャル：頻度をエネルギーへ

PDB で数えた頻度から確率を作る

$$p_i = \frac{m_i}{M}, \qquad M = \sum_i m_i$$

m_i：二面角が i 番目のビンに入った数

確率をエネルギーに直す　式 (11.1)

$$\frac{\Delta U(i)}{RT} = -\ln \frac{p_i}{p_i^0}$$

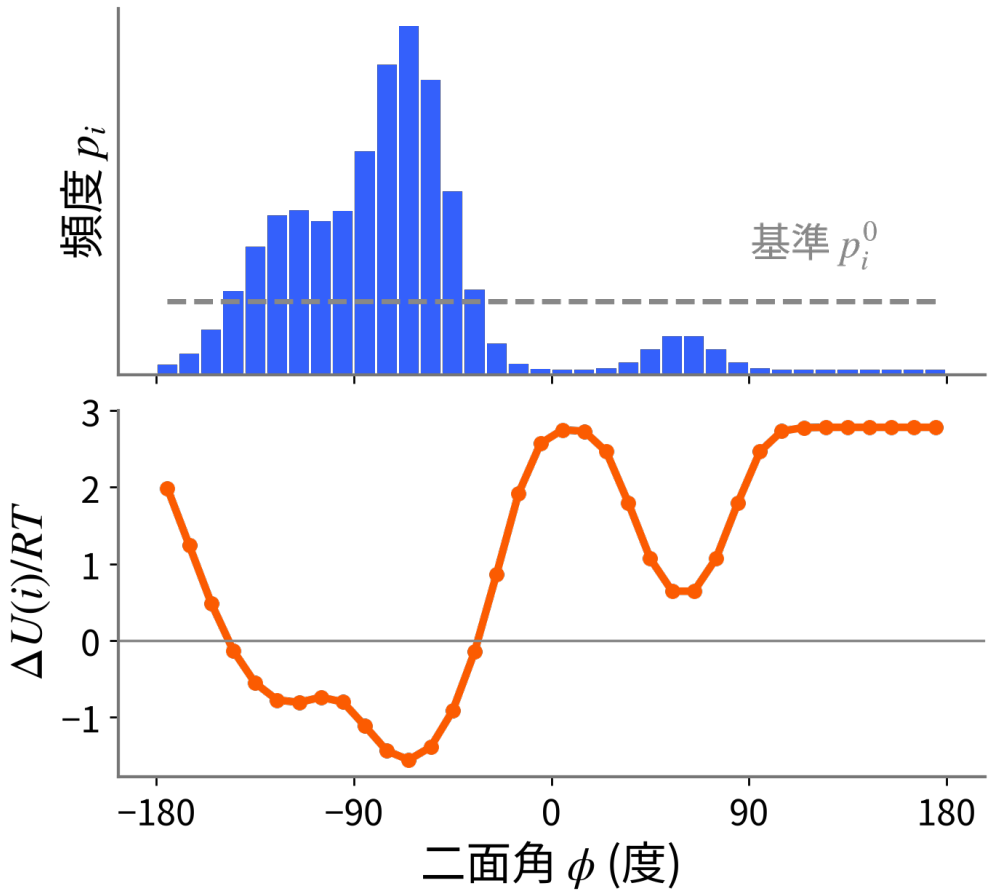
p_i^0：ランダムな分布（基準状態）の確率

補足：なぜ対数か（ボルツマン分布を逆に解く）

$$p_i \propto e^{-U_i/RT} \;\Rightarrow\; U_i = -RT \ln p_i + \text{const.}$$

基準状態との比をとると、定数が消える。

模式図



付録｜接触ポテンシャル：アミノ酸の対の好み

対の好みをエネルギーで表す　式 (11.2)(11.3)

$$\Delta\Delta U = \Delta U_{AC} - \Delta U_{AB} = -RT \ln \frac{p(AC)}{p(AB)}$$

$$\Delta U_{ij} = U_{ij} - U_{ij}^{0} = -RT \ln \frac{p_{ij}}{p_{ij}^{0}}$$

20 × 20 の対称な表（210 種類の対）を、PDB の接触の数で埋める。側鎖の中心間が 6.8 Å 以下を接触とする。

対数をとると、エネルギーとして足し算できる（局所と非局所の寄与を同じ単位で合わせられる）。

統計的ポテンシャルは本当の自由エネルギーではない。RT はほかの項との釣り合いを調整するパラメータとして扱う。

接触ポテンシャル U_{ij}（単位 RT、表 11.A.1 の一部）

	F	L	I	K	E
F	−7.26	−7.28	−6.84	−3.36	−3.56
L	−7.28	−7.37	−7.04	−3.37	−3.59
I	−6.84	−7.04	−6.54	−3.01	−3.27
K	−3.36	−3.37	−3.01	−0.12	−1.80
E	−3.56	−3.59	−3.27	−1.80	−0.91

F・L・I：疎水性（フェニルアラニン・ロイシン・イソロイシン）、K・E：電荷をもつ（リシン・グルタミン酸）

付録｜物理シミュレーションで折り畳む

物理シミュレーションの良いところ

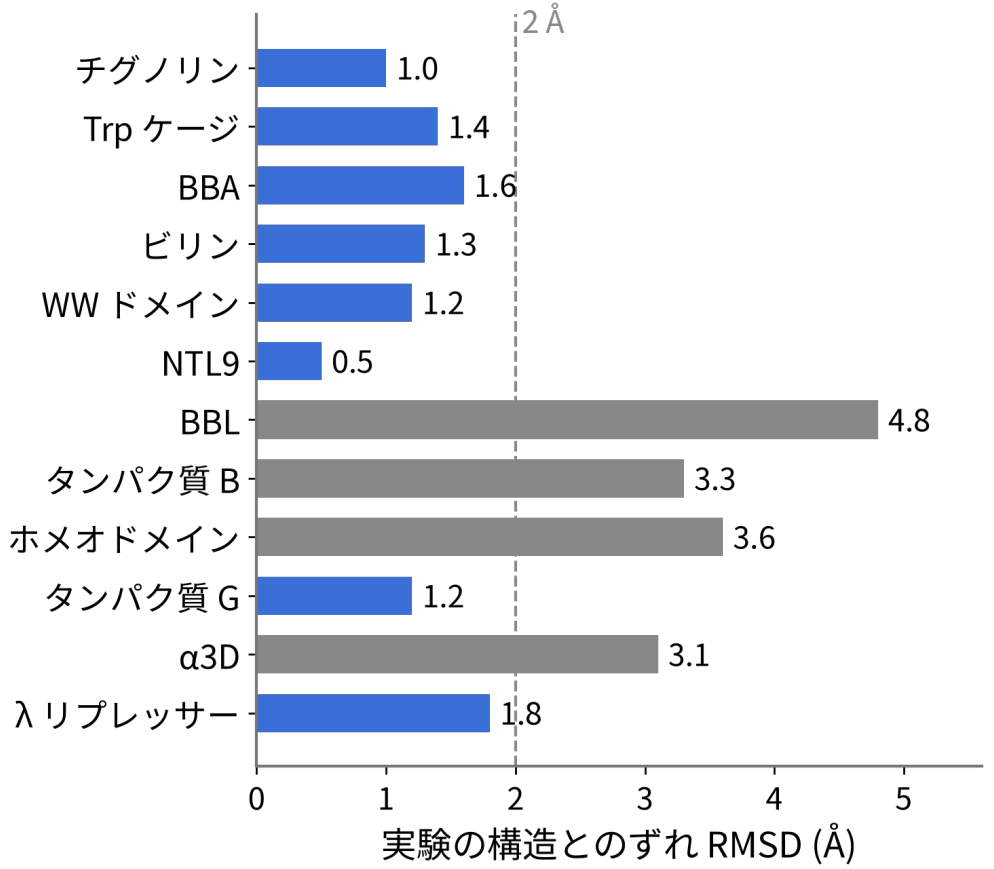
① データベースに頼らない（膜タンパク質など、データが少ないものにも使える）

② 配列アラインメントが要らない

③ 構造だけでなく、動き、構造変化、結合のしかた、自由エネルギーもわかる

現状

計算にとても時間がかかる。専用計算機 Anton による分子動力学（MD）シミュレーションで、小さなタンパク質を天然に近い形に折り畳ませることができた。



Anton で折り畳んだ構造と実験の構造のずれ（Lindorff-Larsen ら, Science 334:517 (2011) の値）

付録｜CASP：答えを伏せた予測コンテスト

CASP（Critical Assessment of Structure Prediction）

1994 年に J. Moult が始めた予測コンテスト。2 年ごとに開かれる。

① 構造が未公開のタンパク質の配列を出題する

② 参加者が構造を予測する

③ 実験の構造が公開されたあと、予測を評価する

第 11 章の時点で正確に予測できたもの

小さく、水溶性で、単一ドメインで、良いテンプレートがあるタンパク質。AlphaFold 2・3 の登場で状況は一変した（訳注）。

- 1994 CASP 開始
- 2011 直接結合分析（DCA）
- 2012 EVfold
- 2017 メタゲノム配列で予測
- 2018 AlphaFold 1（CASP13）
- 2020 AlphaFold 2（CASP14）
- 2021 論文・コード公開
- 2022 ColabFold
- 2024 AlphaFold 3・ノーベル化学賞

付録｜誤った接触は構造を壊す

共進化から構造を作る流れ

MSA → 共変異する対を見つける → 対に接触の束縛をかける → MD・モンテカルロ法・フラグメント組み立てで最適化

問題：偽陽性の対

本当は共変異していないのに、共変異していると判定した対。これに接触の束縛をかけると構造が壊れ、精度が一気に下がる。

問い：似た配列は何本あれば十分か

Ovchinnikov ら（2017）：有効配列数 N_f が予測精度とよく相関する。

$$N_f = \frac{N_{80}}{\sqrt{L}}$$

N_{80}：配列同一性 80% 以上のものを 1 本とまとめて数えた配列の数、L：クエリ配列の長さ

結果

メタゲノム解析（環境中の微生物の DNA をまとめて読む）で配列を増やして N_f を上げ、構造が未知の 1297 ファミリーを高精度に予測した。

付録｜畳み込みニューラルネットワーク（CNN）

畳み込み層

$$(I * K)(i, j) = \sum_m \sum_n I(i+m,\ j+n)\, K(m, n)$$

フィルタ Kを入力 Iの上でずらしながら積和をとる。模様が似た場所で値が大きい。Kは学習で決まる。

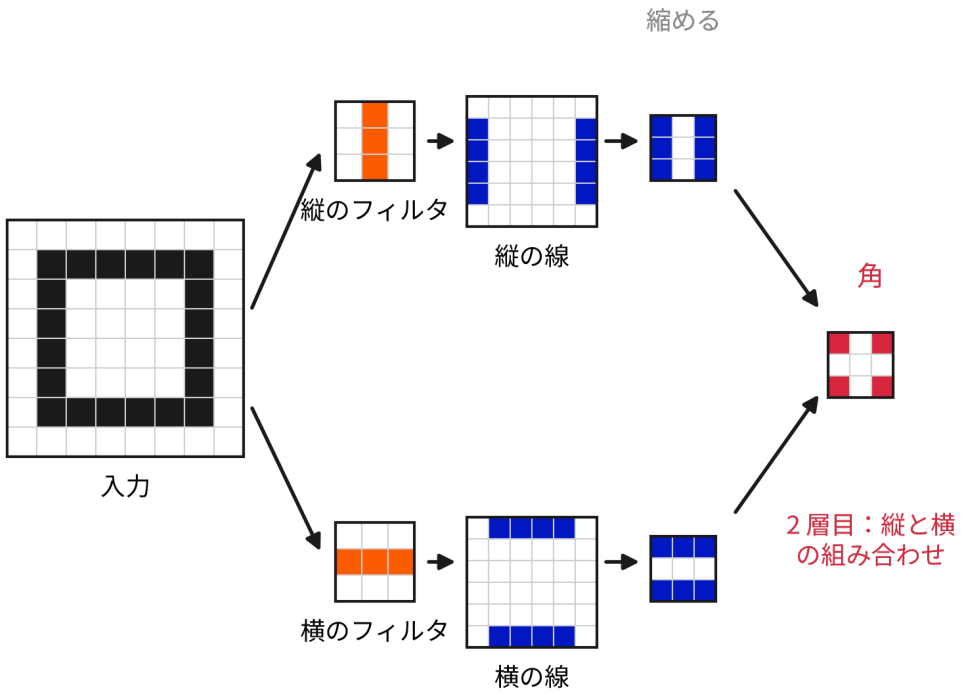
1 つのフィルタを使い回す（パラメータ共有）ので学習が効率的。模様がどこにあっても見つかる（並進同変性）。

プーリング層

小さな領域の最大値だけを残して縮める。位置の小さなずれに強くなる。

構造予測での使い方

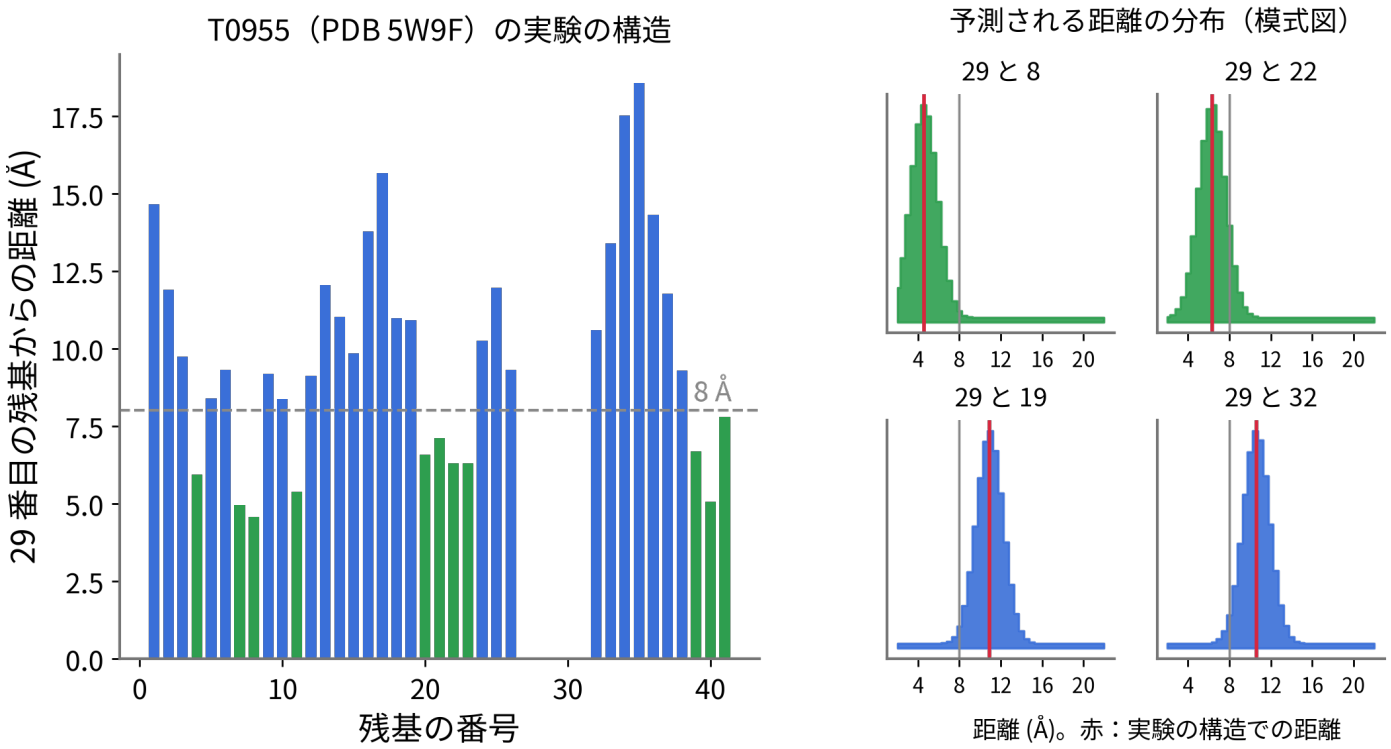
MSA などの特徴量を 2 次元の「画像」にして入力し、接触マップを 2 次元で出力する。



1 層目：縦・横の短い線を見つける

1 層目で縦・横の線、2 層目でその組み合わせ（角）を捉える（模式図）

付録｜共進化は遠い距離の情報も含んでいた



T0955 の 29 番目の残基からの距離（左）と、予測される距離の分布の形（右、模式図）

図の見方

左：実験の構造での距離。緑：接している対（8 Å 以内）、青：接していない対

右：予測の形（模式図）。赤線：実験の構造での距離。灰色の縦線：8 Å

論文の結果

19・24・32・33・36 番は接していないのに、予測の山が正しい距離と一致した（Senior ら, Nature 577:706 (2020)）。

共進化には、接触だけでなく遠い距離の情報も含まれている。接触の「決め打ち」が要らず、偽陽性の害も避けられる。

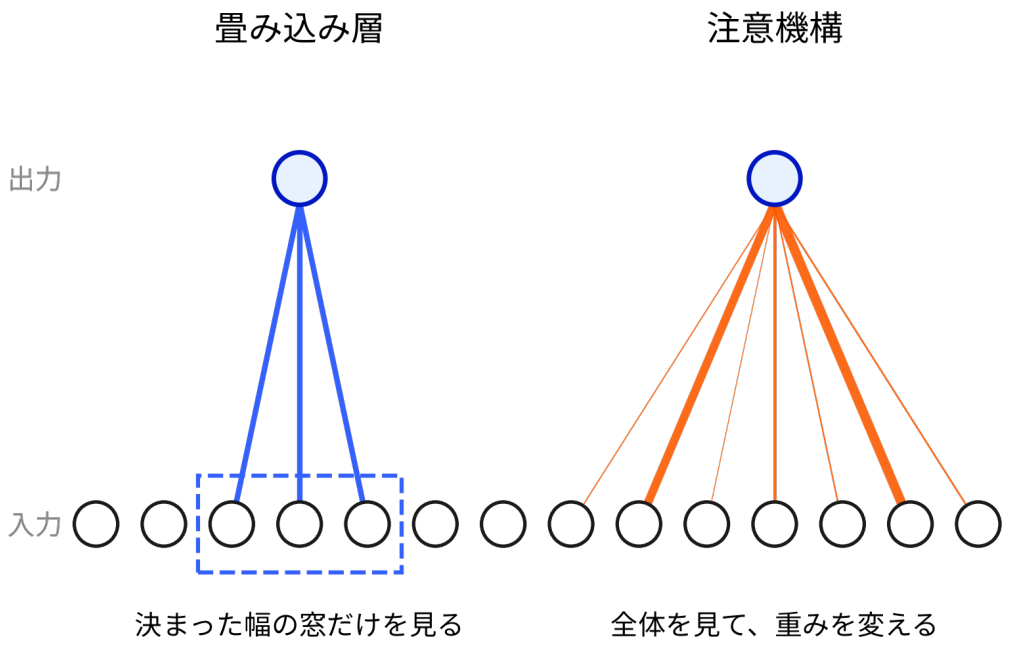
付録｜注意機構：クエリ・キー・バリュー

3 つのベクトルを作る

$$\mathbf{q}_i = \mathbf{x}_i W_Q, \quad \mathbf{k}_i = \mathbf{x}_i W_K, \quad \mathbf{v}_i = \mathbf{x}_i W_V$$

$\mathbf{x}_i$：i番目のトークン（横ベクトル）。W_Q, W_K, W_Vは学習で決まる行列。

	役割	静電相互作用のたとえ
クエリ	主役が出す「質問」	正電荷の残基「負電荷の相手はどこ？」
キー	質問に答える「索引」	負電荷の残基のキーが反応する
バリュー	受け取る中身	安定化のエネルギーの情報



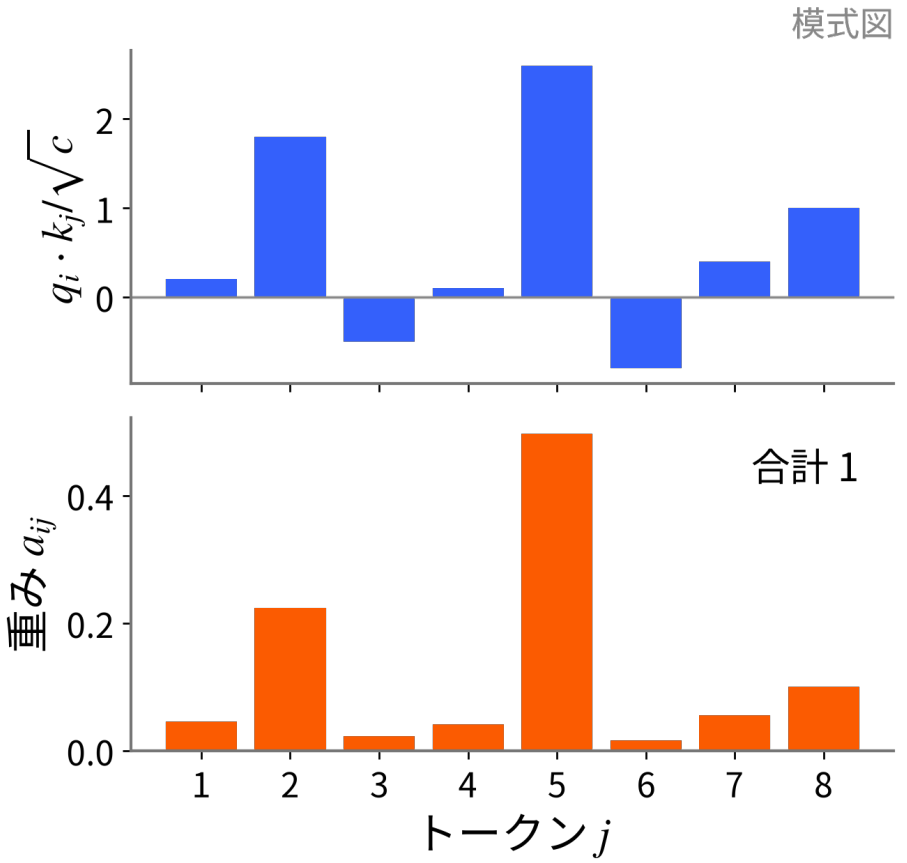
左：畳み込み層は局所を見る。右：注意機構は全体を見渡す（模式図）

付録｜注意機構の計算

③ 行列でまとめて書く

$$\mathrm{Attention}(Q,K,V)=\mathrm{softmax}\left(\frac{QK^T}{\sqrt{c}}\right)V$$

補足：$\sqrt{c}$で割るのは、次元 cが大きいと内積のばらつきが大きくなり、softmax が 1 つの要素に偏るのを防ぐため。



付録｜マルチヘッドと層の積み重ね

マルチヘッドアテンション

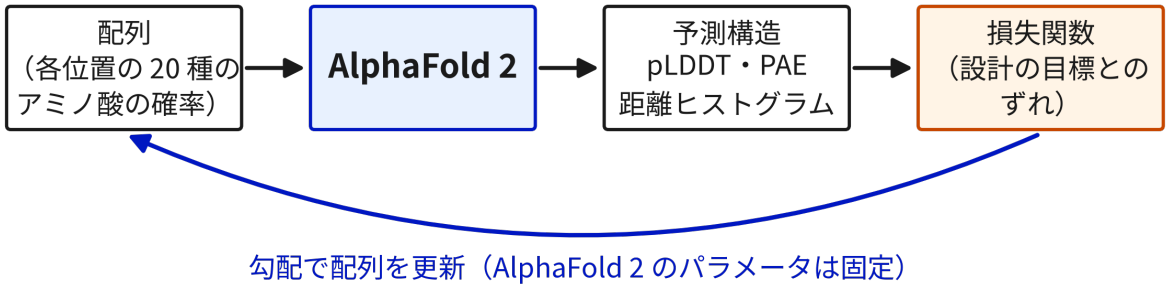
複数の注意機構（ヘッド）を並べて同時に計算する。ヘッドごとに異なる射影を使い、多様な関係を学べる。各ヘッドが特定の物理相互作用に対応するとは限らない。

層を重ねる

注意機構を含むブロックを何層も重ねて、複雑な依存関係を表す。計算は並列にしやすく、GPU で行う。

	CNN（畳み込み）	注意機構
入力	格子状のデータ（画像）	ベクトルの系列
見る範囲	決まった大きさの局所	系列の全体
遠い要素の関係	層を重ねて間接的に	1 つの層で直接
計算量	小さい	大きい（系列の長さの 2 乗）

付録｜補足：ColabDesign は AlphaFold 2 をどう使うか



考え方（構造予測の逆）

配列を「各位置の 20 種のアミノ酸の確率」という連続な表で表し、AlphaFold 2 に入れる。損失の勾配を配列まで逆にたどり、配列を更新する。

使い方の例：骨格を固定した配列設計、目標なしで折り畳まる配列を作る（ハルシネーション）、標的に結合するタンパク質の設計

損失に使う出力

pLDDT：残基ごとの信頼度（高くしたい）

PAE（predicted aligned error）：残基 i の位置に合わせたときの残基 j の位置の予測誤差（小さくしたい）

距離ヒストグラム：目標の構造との違い

教科書にない内容（補足）