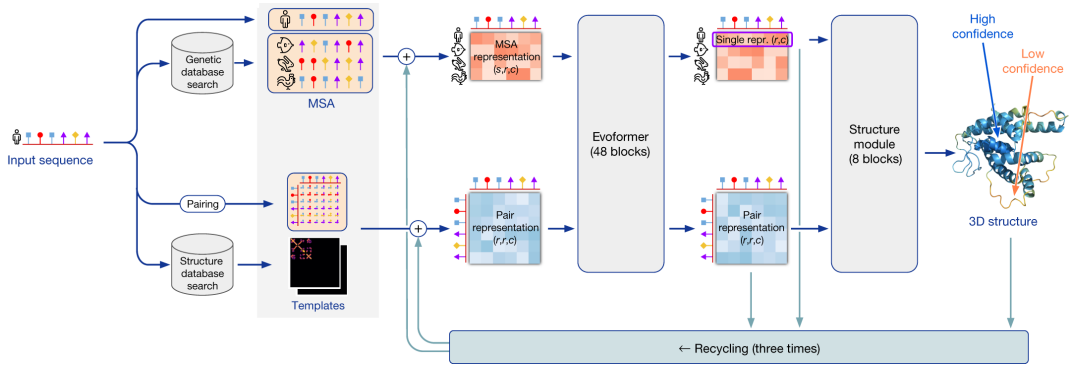
生命情報工学特論　第05回

AlphaFold 2 による構造予測

アミノ酸配列から立体構造を予測する
構造表現・予測の仕組み・ColabFold演習



図：Jumper ら, Nature 596:583 (2021) Fig. 1e を切り出し（CC BY 4.0）

松永 康佑

埼玉大学 大学院理工学研究科
理化学研究所 計算科学研究センター ｜ 2026年10月31日（オンデマンド）

今日の内容

配列の情報を、三次元の配置へ変換する

AlphaFold 2 は、既知の配列・構造から学んだ関係と三次元幾何を使う。

配列とMSA
相同配列の保存・変異

→

Evoformer
MSA表現とペア表現を更新

→

Structure Module
局所フレームから原子座標

MSA：相同配列を、対応する位置が同じ列になるように整列した表。
出力：原子座標と予測の信頼度。折り畳みの時間経過を計算するものではない。

第03回の構造観察 → 第04回のAttention → 今回の構造予測。
演習では、同じユビキチンを配列から予測して、構造と信頼度を対応させる。

講義の流れ

表現の更新から構造生成までを追う

構造予測の出発点

座標・距離行列、相同配列と共進化、AF1からAF2への変化。

Evoformer

MSA表現とペア表現、行と列のAttention、外積の平均、三角形の更新。

Structure Module

二面角・局所座標系、IPA、学習時の誤差、リサイクリング。

信頼度とまとめ

pLDDT・PAE、予測で分かることと分からないこと。

配列はわかっても、構造はわかっていない

構造を知りたい理由

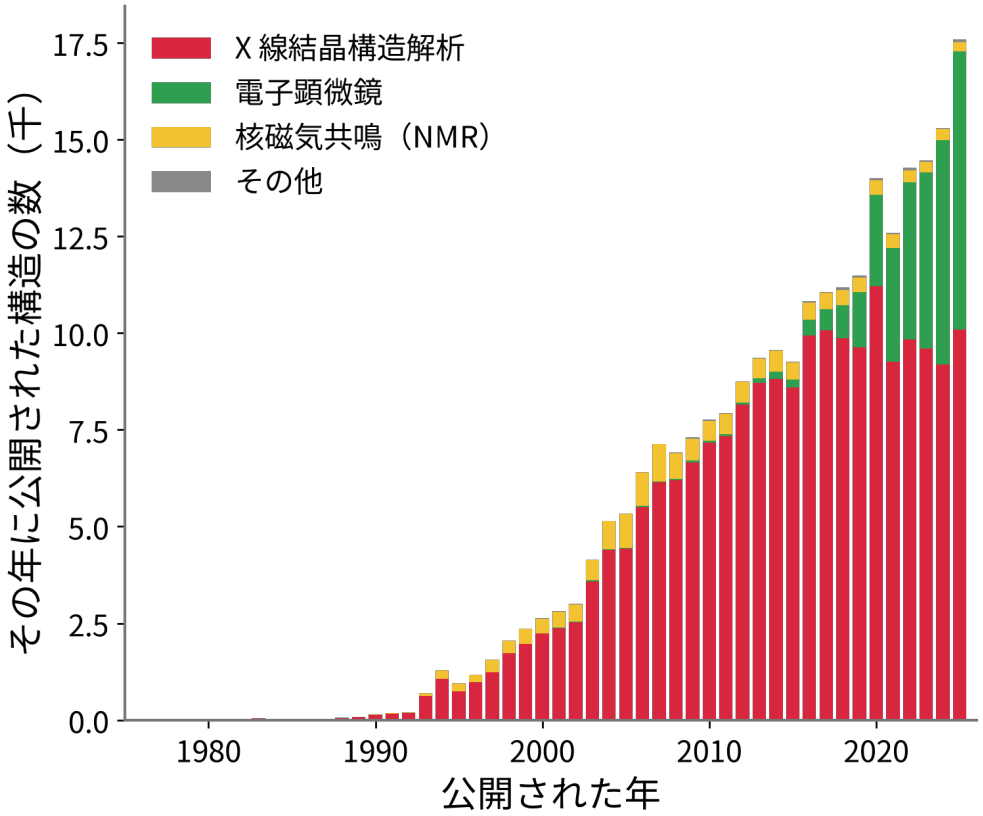
構造は、タンパク質の動き、結合する相手、はたらくしくみ、薬の設計を考える出発点になる。

配列と構造のギャップ

配列が分かっていても、実験構造がまだ決まっていないタンパク質は多い。

構造を実験で決めるには時間と費用がかかる。計算で予測できれば、このギャップを埋められる。

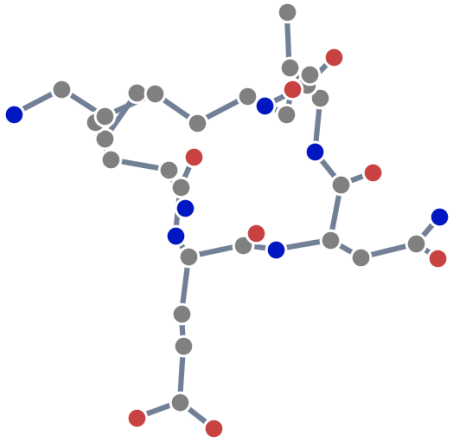
PDB（Protein Data Bank）：実験で決めた立体構造を集めた公開データベース



その年に PDB で公開された構造の数（RCSB PDB の集計、2025 年まで）

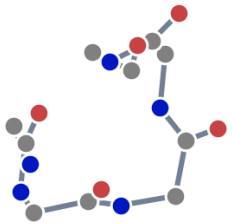
全原子・主鎖・Cαでは残す情報が違う

全原子表示



このPDBの重原子を表示（水素は未収録）

主鎖 N–Cα–C–O



側鎖を省略し、ペプチド面を残す

Cα のみ



一残基を一点で表し、順につなぐ

全原子では側鎖の向きや衝突まで調べられる。図の1UBQには水素は収録されていない。水素を含む評価には付加処理が必要になる。
主鎖N–Cα–C–Oは、ペプチド面の向きを残す。

Cαだけなら残基の対応を取りやすい。ただし、側鎖や水素結合の配置は一意に決まらない。
Cαから重原子座標を復元するときは、復元処理による誤差も考慮する。

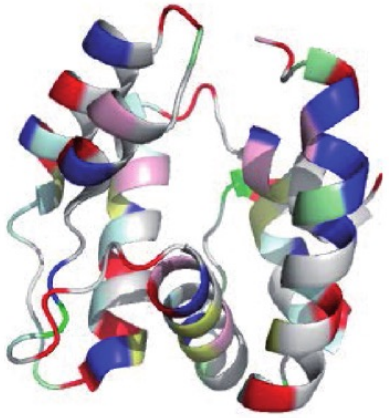
図：PDB 1UBQ、鎖Aの残基23–27。同じ座標・向き・縮尺で表示。距離の単位：1 nm = 10 Å。

ホモロジーモデリングの手順

1 PDB 構造の配列に対して配列アラインメントを行い，適切なターゲット構造を見つける

```
                280       290       300       310       320
template GANFGRD-YAVFEPGSRHVGLDIKGQNVANPTAMILSSTLMLNHLGLNEY
target   SGNIGANGVAIFES-VHGTAPDIAGKDMANPTALLLSAVMMLRHMGLHGH
```

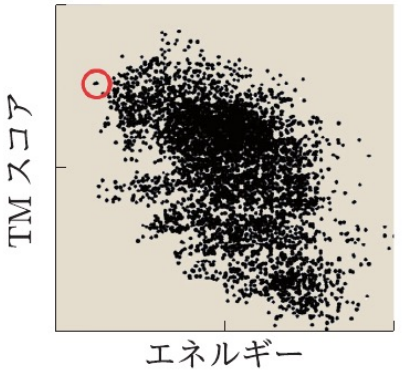
2 テンプレート構造を得る



3 テンプレート構造に
ターゲット配列を当てはめ，
構造を精密化する
（色はアミノ酸残基の種類を示す）



4 立体配座のサンプルを生成し，
それぞれのエネルギーを評価して，
低エネルギーかつ高スコアの最良
の構造を特定する



5 さらに精密化を行う



6 モデルは求められている要請を満たすか？そうでなければ繰り返せ．

TMスコアには参照構造が必要。正解構造が未知の予測では、利用可能なモデル評価のスコアで候補を選ぶ。

出典：Bahar・Jernigan・Dill『タンパク質の動きと機能』（共立出版, 2026）図11.1。旧AlphaFold 2解説教材より再利用。

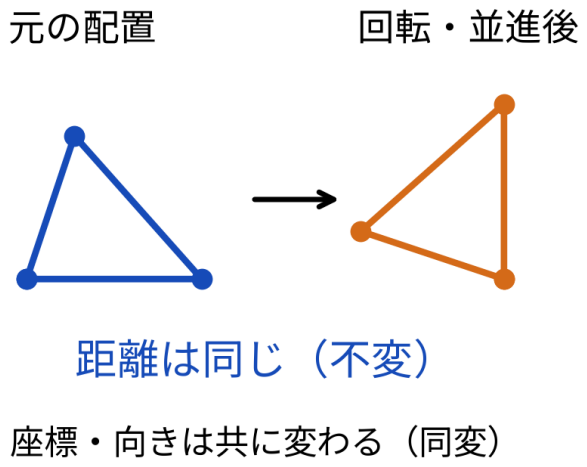
距離行列は回転と並進を取り除く

全原子対の距離を並べると、構造を重ね合わせなくても比較できます。回転は長さを保ち、並進は差を取ると消えるためです。

$$\|(Rx_i + t) - (Rx_j + t)\|^2 = (x_i - x_j)^T R^T R (x_i - x_j) = d_{ij}^2$$

$$C_{ij} = \mathbf{1}[d_{ij} < r_c], \quad V = \det[x_2 - x_1, x_3 - x_1, x_4 - x_1]$$

$$\det[r_2 - r_1, r_3 - r_1, r_4 - r_1] \mapsto \det(R) \det[r_2 - r_1, r_3 - r_1, r_4 - r_1]$$



Dは原子間距離、Cは閾値rc以下を1とする接触マップ。距離を閾値化すると情報が失われる。任意の対称行列が三次元構造に対応するわけではない（付録で補足）。

距離は鏡映でも変わらない。一方、4点から作る符号付き体積Vは、鏡映（det R = −1）で符号が変わる。二面角などとともに、キラリティを区別する手掛かりになる。

出典：Mariani et al. (2013)

MSA：相同配列の対応する位置をそろえる

MSA（Multiple Sequence Alignment、多重配列アライメント）は、共通祖先に由来する相同配列を集め、対応すると推定される残基が同じ列になるように整列した表。

相同配列を集める

予測対象	MKTAYIAKQG
相同配列1	MKSAYVAKQG
相同配列2	MRTGAYIVRQG
相同配列3	MKTGAFVVRQG
相同配列4	MRSAFIAKQG

整列 →

対応する位置を、同じ列へ整列する

列：対応すると推定した位置

	1	2	3	4	5	6	7	8	9	10	11
予測対象	M	K	T	-	**A**	**Y**	I	A	K	Q	G
相同配列1	M	K	S	-	**A**	**Y**	V	A	K	Q	G
相同配列2	M	R	T	**G**	**A**	**Y**	I	V	R	Q	G
相同配列3	M	K	T	**G**	**A**	**F**	V	V	R	Q	G
相同配列4	M	R	S	-	**A**	**F**	I	A	K	Q	G

行：1本の配列

4列目：ギャップ　5列目：保存　6列目：置換

ギャップ「–」

挿入・欠失に対応する空所。
アミノ酸ではない。

保存された列

例：5列目はすべてA。
この位置は変わりにくい。

置換のある列

例：6列目はYまたはF。
同じ列でも文字は変わりうる。

模式例（架空の配列）。列番号と元の残基番号は異なる場合がある。参考：EMBL-EBI, Multiple sequence alignment

共進化：共変異を接触予測の手掛かりにする

MSA（マルチプルシーケンスアラインメント）

ターゲットに似た、進化的に関係のある配列をたくさん並べたもの。

共変異（共進化）

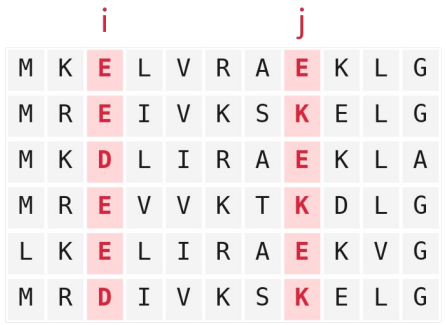
列 i と列 j のアミノ酸の組み合わせに統計的な関係がある。

なぜ起こるか

接触を保つため、一方の変異を他方が補うことがある。ただし系統関係などでも相関は生じる。

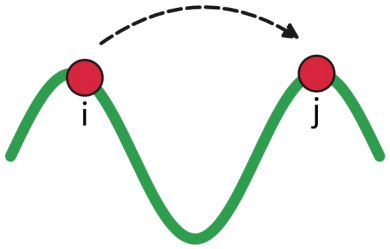
使い方

共変異する対を接触の候補とみなし、構造を組み立てる制約に使う（EVfold）。テンプレートがない膜タンパク質にも使える。

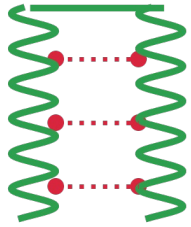


(A) 似た配列を並べ、いっしょに変わる列 i と j を見つける

（i が E なら j は K、i が K なら j は E）



(B) i と j は構造の中で接している、と推測する



(C) 推測した接触（赤の点線）を制約にして、構造を組み立てる

EVfold の考え方（模式図）

直接の相関と間接の相関

相互情報量（MI）

列 i と列 j の相関をそのまま測る。

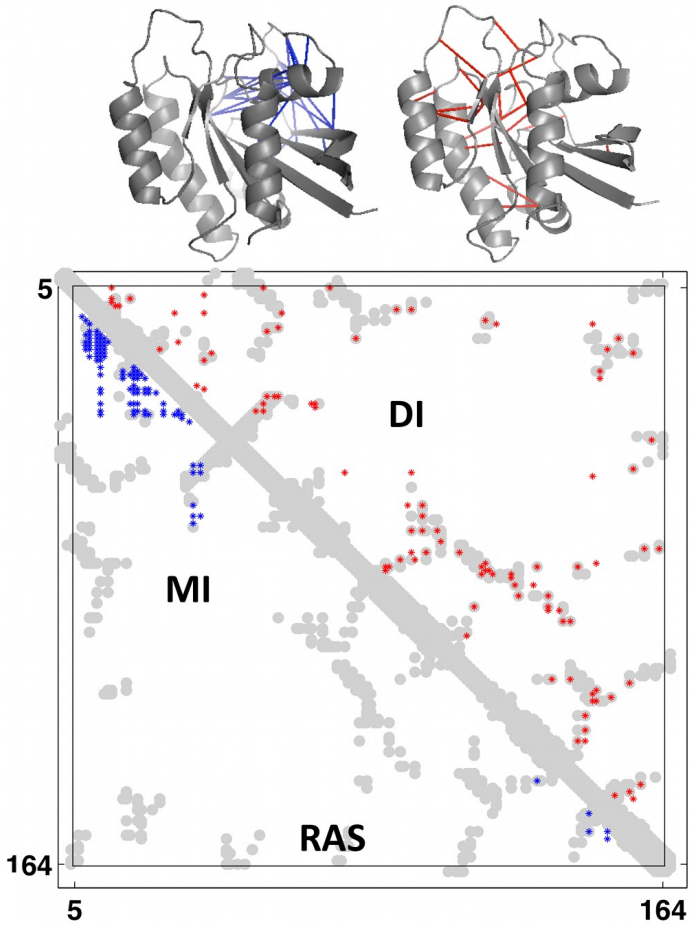
$$\mathrm{MI}_{ij} = \sum_{a,b} f_{ij}(a,b) \ln \frac{f_{ij}(a,b)}{f_i(a)\, f_j(b)}$$

fi(a)：列 i にアミノ酸 a が現れる頻度、fij(a,b)：対の頻度

直接結合分析（DCA）

他の位置を介した間接相関を抑え、残基対の直接的な統計的関係を推定する。物理的な接触そのものを測る方法ではない。

推定の精度は、相同配列の数と多様性、整列の質に依存する。



Ras の接触予測。灰：正解、青：MI、赤：DI（DCA）（Marks ら, PLoS One 6:e28766 (2011) Fig. 3 の右半分を切り出し、CC BY）

教師あり学習で接触を予測する

統計の方法（MI・DCA）の限界

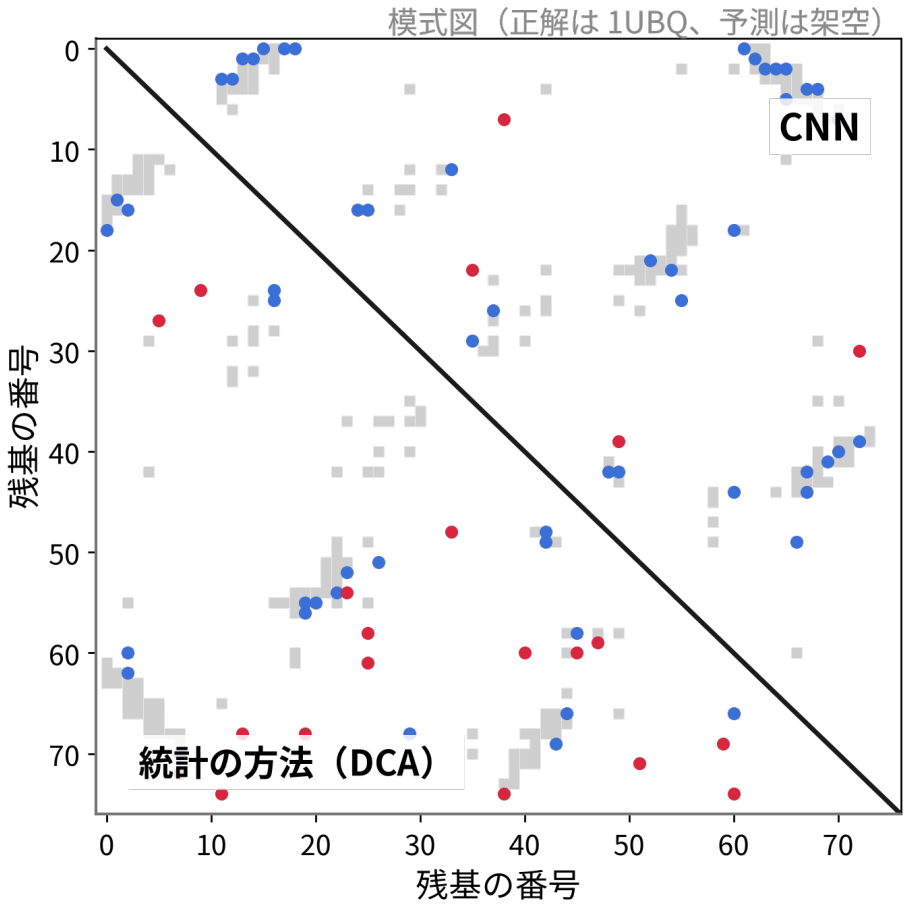
配列の数が有限なための揺らぎや、進化の中で偶然に起きた変異が混ざる。

教師あり学習

正解のついたデータでモデルを前もって学習させる方法。

既知の構造から接触の正解ラベルを作る。MSAを入力とする予測との誤差を使い、偽陽性と見落としが減るよう学習する。

代表例は、畳み込みニューラルネットワーク（CNN）を使った方法。



左下：統計の方法（DCA）、右上：CNN。青：正解、赤：偽陽性、灰：見落とし（模式図）

AlphaFold 1：距離の分布を予測する

AlphaFold 1（2018 年、CASP13 で 1 位）

ネットワーク：CNN の層を深く重ねられるようにした ResNet

出力：残基間の距離分布（Cβ 原子間、Gly は Cα）と主鎖の二面角の分布

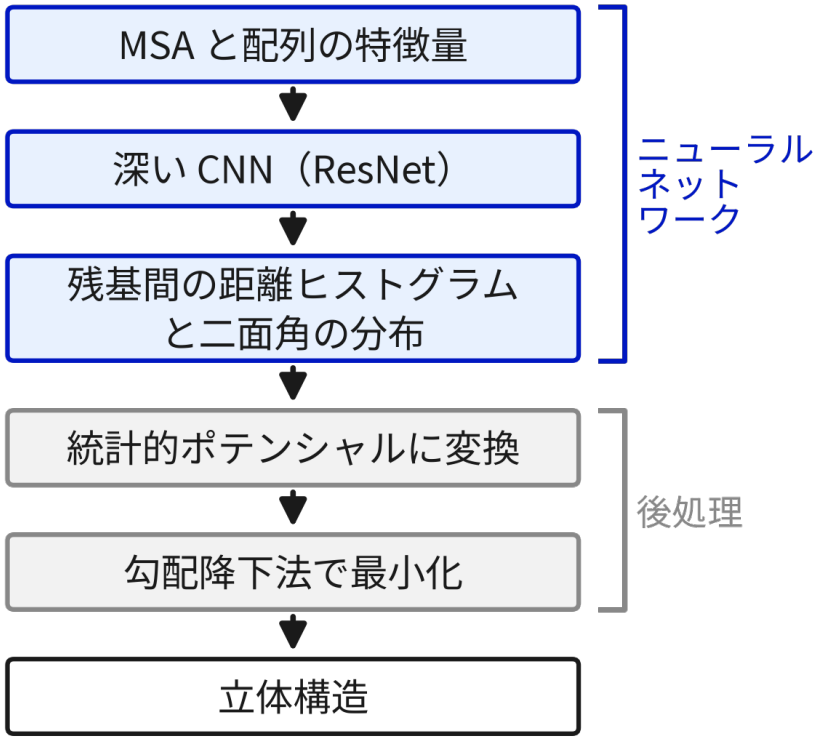
学習：PDB の構造（重複を除いたもの）で教師あり学習

補足：後処理の考え方（簡略化）

$$V(\mathbf{x}) = -\sum_{i<j} \ln p_{ij}\left(d_{ij}(\mathbf{x})\right) - \sum_{i} \ln p_i\left(\phi_i, \psi_i\right)$$

$$\mathbf{x} \leftarrow \mathbf{x} - \eta \nabla V(\mathbf{x})$$

予測した分布を統計的ポテンシャルに直し、勾配降下法で最小化する。



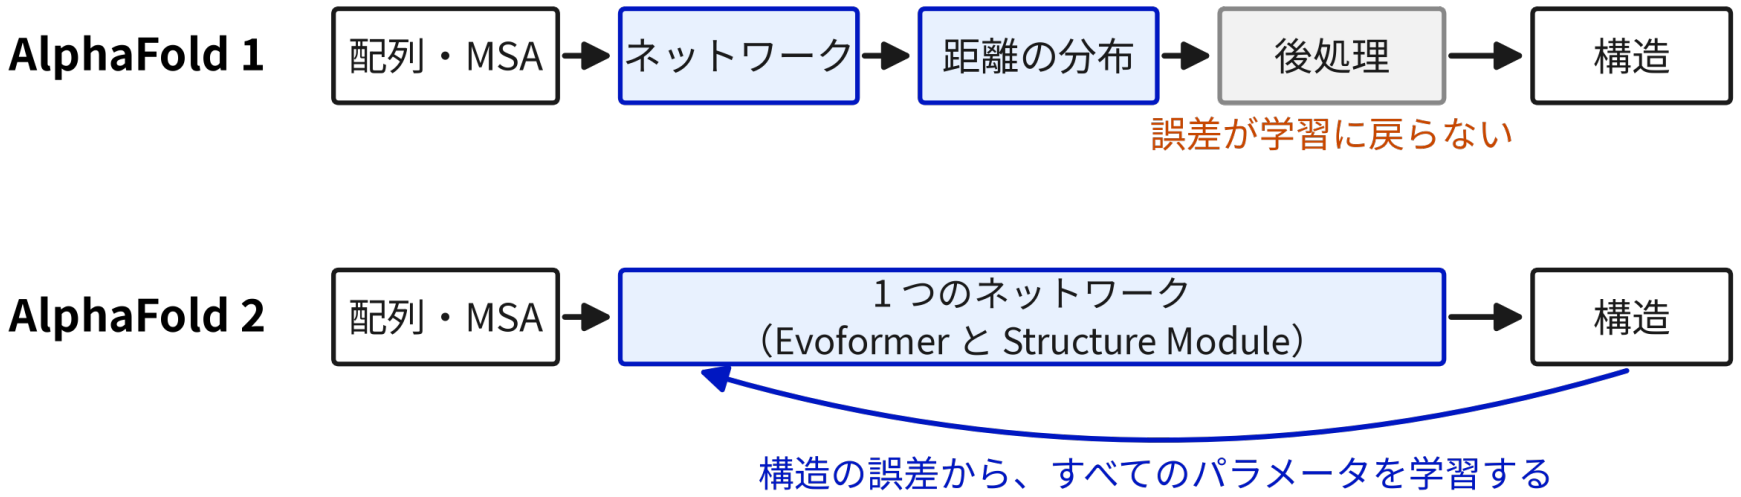
AlphaFold 1 の 2 つの限界

① CNN の局所性

小さなフィルタを積み重ねて少しずつ広く見るので、配列上で遠く離れた残基の関係は間接的にしか捉えられない。

② エンドツーエンドでない

距離の分布から構造を作る後処理が、ネットワークの外にある。構造の誤差が学習に戻らない。



帰納バイアス：前もって組み込む仮定

帰納バイアス（inductive bias）

モデルが学びやすい関係や満たすべき対称性を、計算の構造に組み込むこと。AlphaFold 2では、残基対・三残基の関係を使う更新と、回転・並進に依存しない注意の計算を取り入れている。

しくみ	組み込んだ仮定
CNN の畳み込み	模様が平行移動しても同じように見つかる（並進同変性）
Evoformer の行方向の注意	残基対の学習済み特徴を、注意の重みへ反映する
外積の平均	MSAの列の組み合わせから、残基対の特徴を学ぶ
三角形の更新	3 残基の関係を同時に使い、幾何学的な整合性を学びやすくする
Invariant Point Attention	タンパク質全体を回転・並進しても、相対的な位置関係は変わらない

注意機構の計算

① 重みを決める

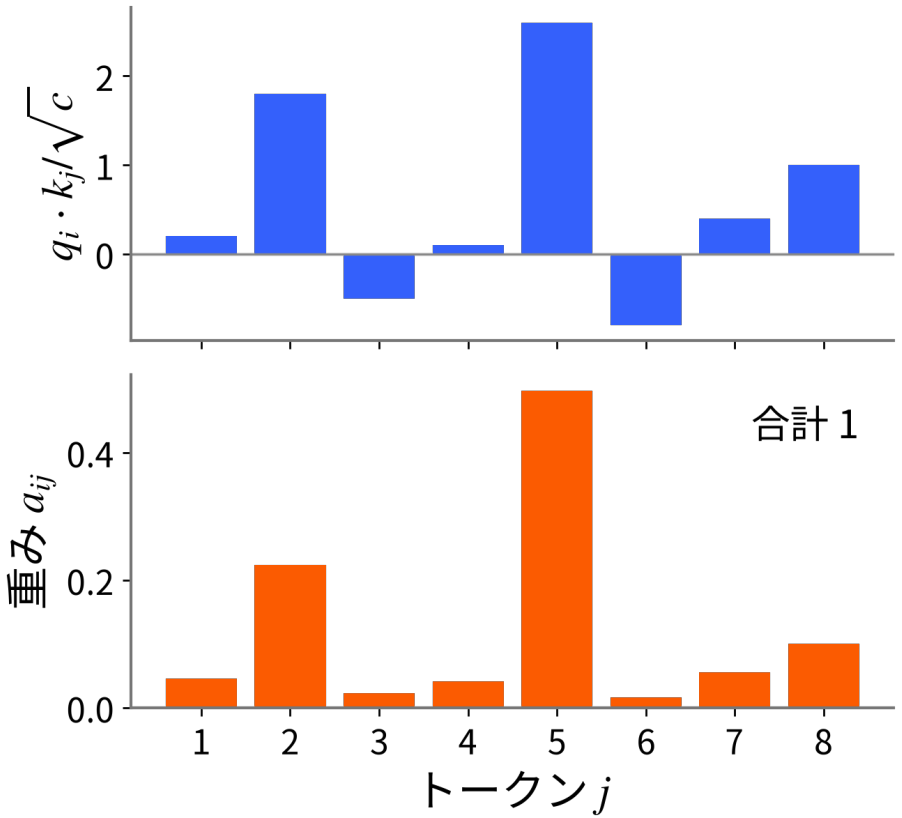
$$a_{ij} = \mathrm{softmax}_j\left(\frac{\mathbf{q}_i \cdot \mathbf{k}_j}{\sqrt{c}}\right), \qquad \mathrm{softmax}_j(g_j) = \frac{e^{g_j}}{\sum_k e^{g_k}}$$

c：キーの次元。重みは正で、jについて合計が 1。

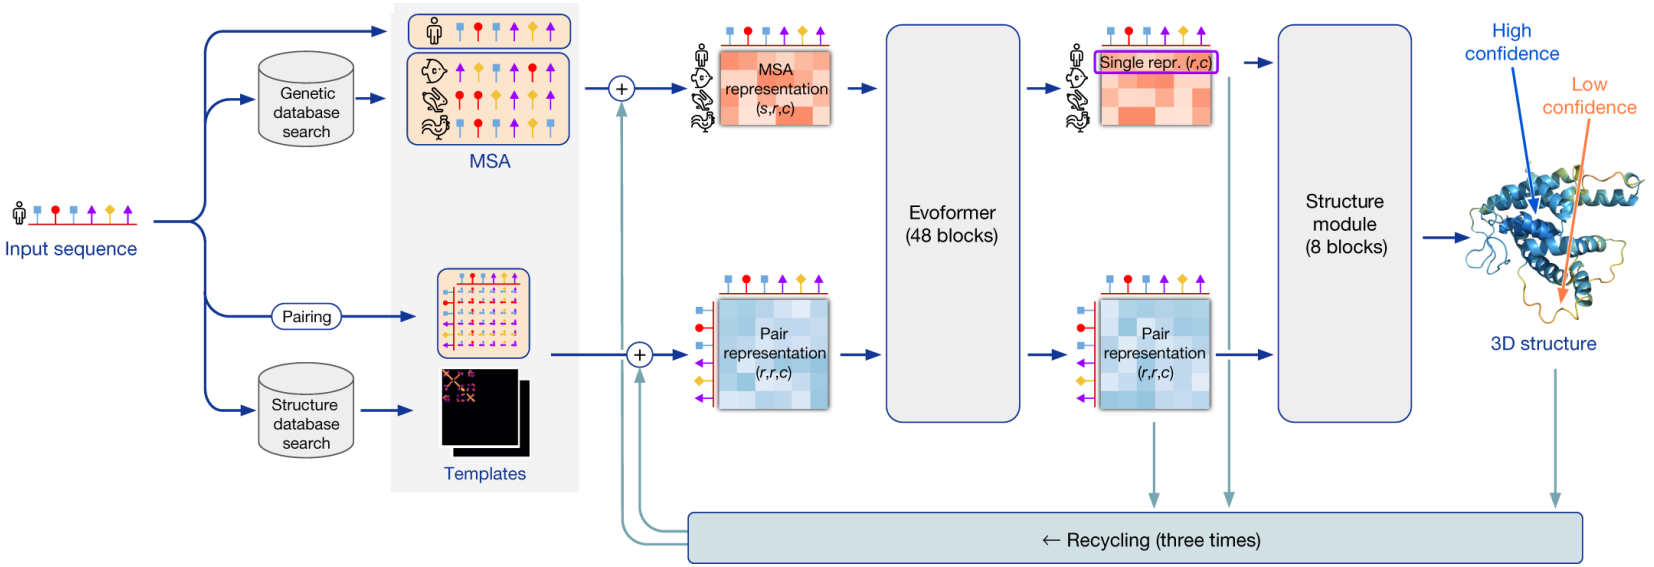
② バリューの重み付き和

$$\tilde{\mathbf{z}}_i = \sum_j a_{ij}\,\mathbf{v}_j$$

模式図



AlphaFold 2 の全体像



AlphaFold 2 のネットワーク（Jumper ら, Nature 596:583 (2021) Fig. 1e を切り出し、CC BY 4.0）

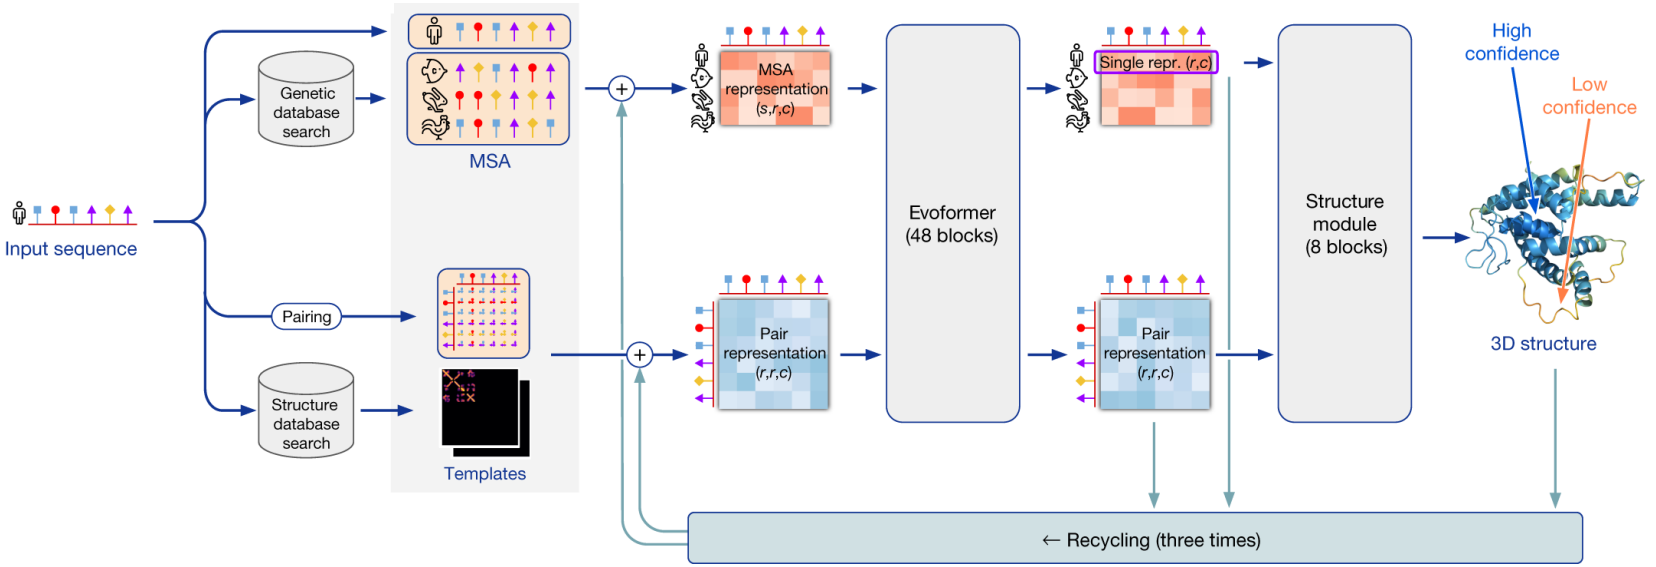
2 つの表現

MSA 表現 M：Nseq × L × cM。各マスは特徴ベクトル

ペア表現 P：L × L × cP。距離そのものではない

入力：クエリ配列、配列データベースから作る MSA、構造データベースから探すテンプレート（なくても動く）

AlphaFold 2 の全体像



AlphaFold 2 のネットワーク（Jumper ら, Nature 596:583 (2021) Fig. 1e を切り出し、CC BY 4.0）

入力：クエリ配列、配列データベースから作る MSA、構造データベースから探すテンプレート（なくても動く）

2 つの部分

Evoformer（48 ブロック）：M と P をやりとりさせて更新する（エンコーダー）

Structure Module（8 ブロック）：立体構造を作る（デコーダー）

リサイクリング：出力を入力へ戻す。回数は設定で変わる

ペア表現の1マスにも、ベクトルを置く

距離行列 D

座標から決まる1つの実数
単位は Å、対称、対角は0

0	4	8	12
4	0	4	8
8	4	0	4
12	8	4	0

$$D_{ij} = \|\mathbf{x}_i - \mathbf{x}_j\|$$

模式例：4残基。色は実測値を表さない。

ペア表現 P

対ごとの特徴ベクトル
各成分の意味は学習で決まる

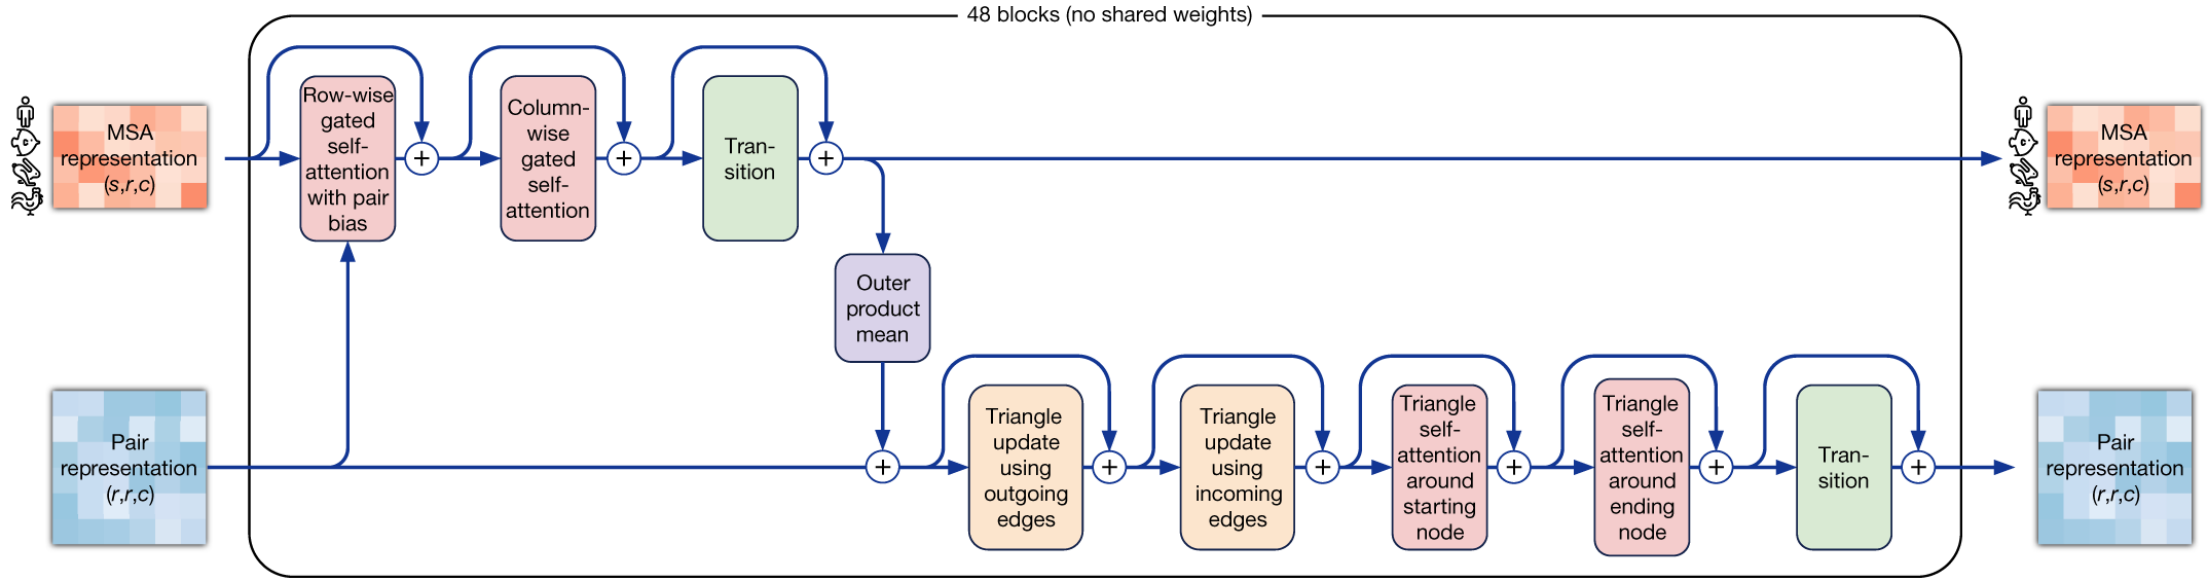
p11	p12	p13	p14
p21	p22	p23	p24
p31	p32	p33	p34
p41	p42	p43	p44

$$\mathbf{p}_{ij} \in \mathbb{R}^{c_P}$$

例：cP = 128
128個の特徴量
（AF2原著）

模式例：4残基。色は実測値を表さない。

Evoformer ブロックの中身



Evoformer ブロックの中の処理（Jumper ら, Nature 596:583 (2021) Fig. 3a を切り出し、CC BY 4.0）

前半：MSA 表現の更新

行方向の自己注意（ペア表現からのバイアスつき）→ 列方向の自己注意 → 変換

後半：ペア表現の更新

外積の平均（MSA → ペア）→ 三角乗法更新 → 三角自己注意 → 変換。48 ブロック重ねる（パラメータは別々）

MSA 表現の更新：行と列に分けた注意

行方向の自己注意：配列 s の中の残基どうし

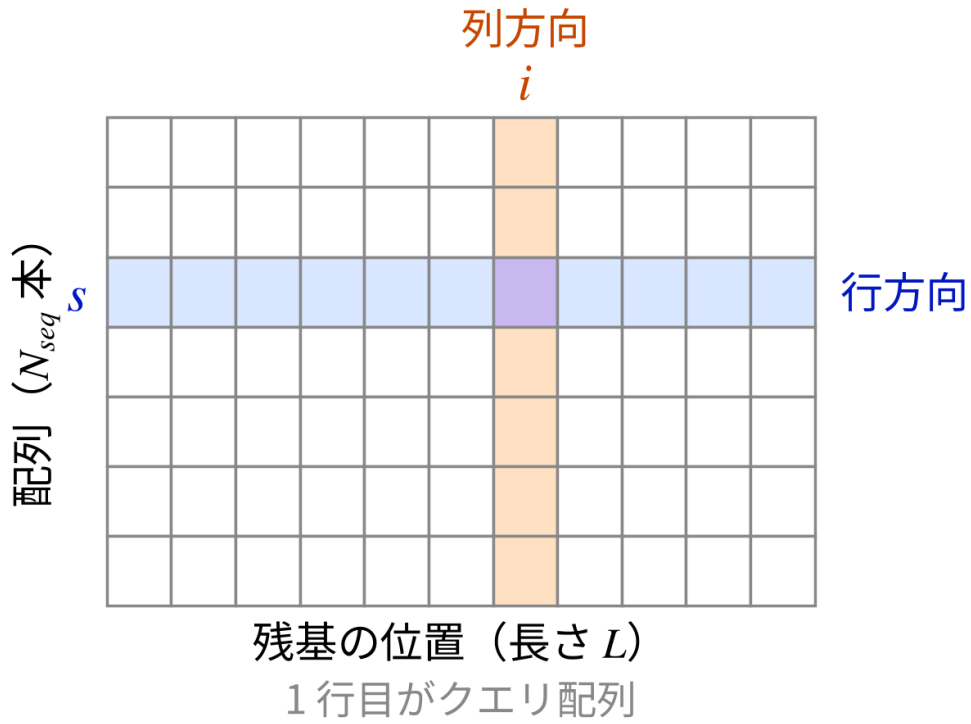
$$a_{sij} = \mathrm{softmax}_j\left(\frac{\mathbf{q}_{si} \cdot \mathbf{k}_{sj}}{\sqrt{c}} + b_{ij}\right)$$

bij：ペア表現の要素 **p**ij から作るバイアス。学習した対の特徴で注意のスコアを調節する。

列方向の自己注意：同じ残基位置を配列どうしで比べる

保存・変異のパターン（進化の情報）を取り出す。ふつうの自己注意。

行と列に分けるのは、全部のマスどうしで注意をとると計算量とメモリが大きすぎるため（軸方向の注意、axial attention）。



外積の平均：共進化をペア表現へ

外積の平均（outer product mean）

$$\mathbf{a}_{si} \otimes \mathbf{b}_{sj} = \mathbf{a}_{si}\,\mathbf{b}_{sj}^{T}$$

$$\mathbf{o}_{ij} = \frac{1}{N_{seq}} \sum_{s} \mathbf{a}_{si}\,\mathbf{b}_{sj}^{T}$$

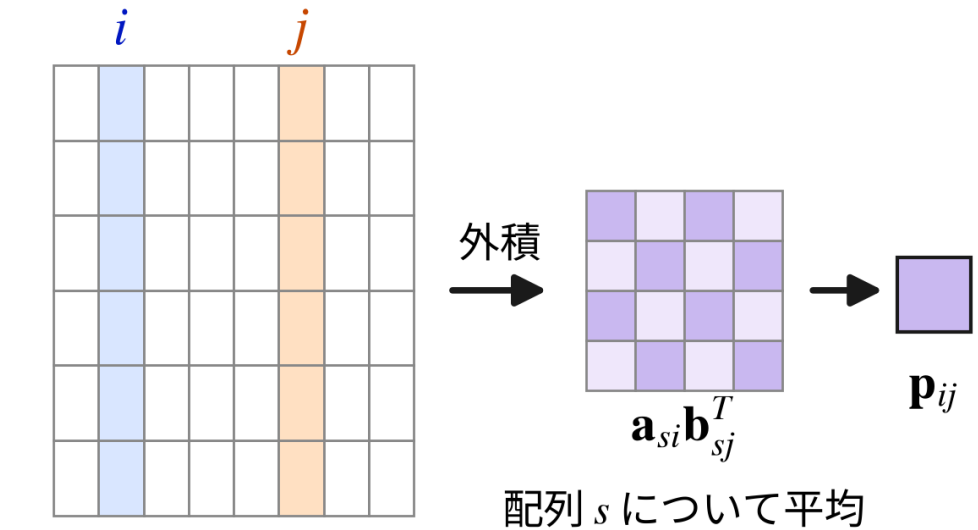
asi, bsj：配列 s の i・j 番目の特徴ベクトルを線形変換した縦ベクトル。
行列oijを平坦化・線形変換して、ペア表現pijに足す（図の矢印）。

補足：DCA とのつながり

$\mathbf{a}_{si}$、$\mathbf{b}_{sj}$ をアミノ酸の種類を表す 1-hot ベクトルにすると、外積の平均は対の頻度 $f_{ij}(a,b)$ になる。

$$C_{ij}(a,b) = f_{ij}(a,b) - f_i(a)\,f_j(b)$$

下式はDCAでも使う共分散。AF2は学習した特徴の外積を使うが、DCAをそのまま実行するわけではない。



三角形の整合性：3 残基の関係

三角不等式

$$d_{ij} \le d_{ik} + d_{jk}$$

三角自己注意（starting node）

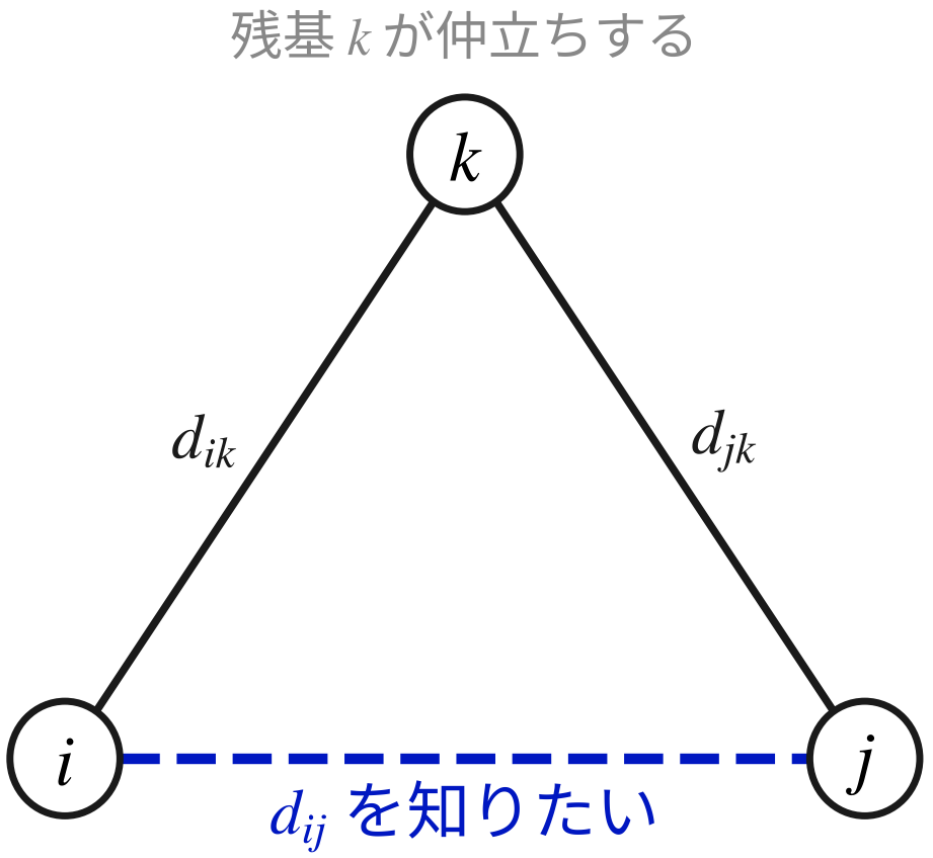
$$a_{ijk} = \mathrm{softmax}_k\left(\frac{\mathbf{q}_{ij} \cdot \mathbf{k}_{ik}}{\sqrt{c}} + b_{jk}\right)$$

対 (i,j) のクエリと対 (i,k) のキーを比べるとき、残りの辺 (j,k) のバイアスを足す。逆向きの ending node の計算も行う。

補足：三角乗法更新（簡略化）

$$\mathbf{p}_{ij} \leftarrow \mathbf{p}_{ij} + \sum_k \mathbf{a}_{ik} \odot \mathbf{b}_{jk}$$

⊙：成分ごとの積。辺 (i,k) と (j,k) の情報を、k について集めて (i,j) に足す。



三角不等式を厳密に課す処理ではなく、三残基の関係を使って学習する仕組み。

内部座標は結合に沿って構造を表す

三次元座標の代わりに、結合長、結合角、二面角を使います。主鎖ではφがN–Cα、ψがCα–C、ωがペプチド結合周りの回転を表します。

$$X = \mathcal{F}(\{\ell_i\},\{\alpha_i\},\{\theta_i\}), \qquad \mathcal{F}_{\text{end}}(\theta) = X_{\text{anchor}}$$

$$\ell_i = \|r_{i+1} - r_i\|, \quad \alpha_i = \cos^{-1}\frac{(r_{i-1}-r_i)\cdot(r_{i+1}-r_i)}{\ell_{i-1}\ell_i}$$

$$e_1 = \frac{r_i - r_{i-1}}{\|r_i - r_{i-1}\|}, \quad b = r_{i-2} - r_{i-1}, \quad v = b - (b\cdot e_1)e_1$$

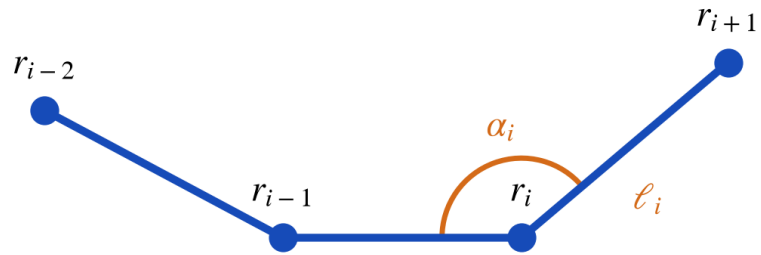
$$e_2 = v/\|v\|, \quad e_3 = e_1 \times e_2, \quad [e_1\ e_2\ e_3] \in SO(3)$$

$$r_{i+1} = r_i + \ell_i[-\cos\alpha_i\, e_1 + \sin\alpha_i(\cos\theta_i\, e_2 + \sin\theta_i\, e_3)]$$

結合長と結合角を固定する近似では、主な自由度を二面角へ集中できます。ただし自由度を減らすことと、実際の振動が存在しないことは異なります。

ループでは両端が骨格に結び付いています。角度を独立にサンプリングすると、最後の残基が終端へ戻らないことがあります。閉鎖条件は位置と向きの制約です。

結合長・結合角・二面角で次の原子を置く



中央の結合を軸に回す → 二面角 θ

ここでθのゼロ方向は、前の三原子から作るe2です。e3=e1×e2で右手系を固定すると、この基底に対する符号付き二面角を定義できます。三原子が一直線、または結合長がゼロならこの基底は定義できません。

出典：Jumper et al. (2021)

残基の局所座標系を作る

Cαを原点、C方向を第1軸にします。N方向から第1軸成分を除いて第2軸を作り、外積で右手系の第3軸を作ります。

$$e_1 = \frac{C - C_\alpha}{\|C - C_\alpha\|}, \quad v = N - C_\alpha - [(N - C_\alpha) \cdot e_1]e_1$$

$$e_2 = v/\|v\|, \quad e_3 = e_1 \times e_2, \quad Q = [e_1\ e_2\ e_3]$$

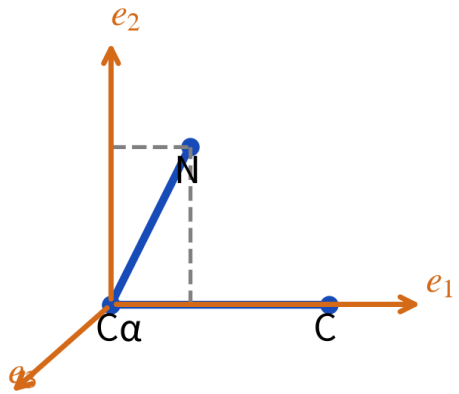
$$z_{ij} = Q_i^T(x_j - C_{\alpha,i})$$

$$Q_i^T Q_i = I, \quad \det Q_i = 1, \quad x_j = t_i + Q_i z_{ij}$$

$$\widetilde{Q}_i = RQ_i, \quad \widetilde{t}_i = Rt_i + t, \quad \widetilde{x}_j = Rx_j + t$$

$$\widetilde{Q}_i^T(\widetilde{x}_j - \widetilde{t}_i) = Q_i^T R^T R(x_j - t_i) = z_{ij}$$

Cαを原点にして直交する3軸を作る



全体の座標が回転しても、同じ残基の座標系で見た相対位置は変わりません。局所座標系を使う誤差は、骨格のどこから相手を見ているかを保持できます。

N、Cα、Cが一直線に近いと基底が不安定になります。入力の結合形状を先に検査し、欠損原子のある残基はマスクします。

出典：Jumper et al. (2021)

不変性と同変性を使い分ける

不変な表現は全体の回転・並進を無視します。比較用の距離やスカラーの性質予測に便利です。同変な出力は、入力を回すと同じように回ります。

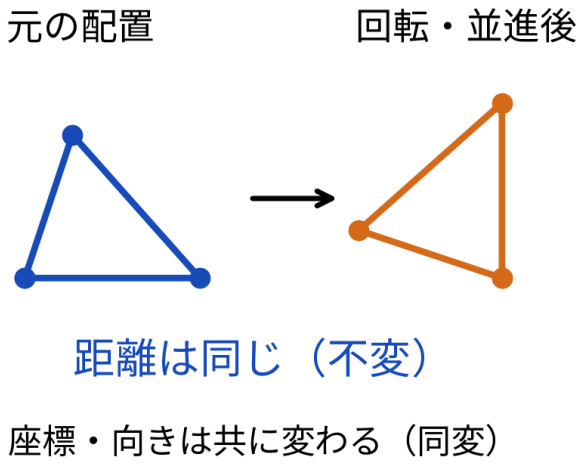
$$f(XR^T + \mathbf{1}t^T) = f(X) \quad \text{(invariant)}$$

$$g(XR^T + \mathbf{1}t^T) = g(X)R^T + \mathbf{1}t^T \quad \text{(coordinate equivariant)}$$

$$SO(3) = \{R : R^T R = I, \det R = 1\}, \quad SE(3) = SO(3) \ltimes \mathbb{R}^3$$

$$\|Rx_i + t - (Rx_j + t)\| = \|x_i - x_j\|$$

$$(Rx_i + t) - (Rx_j + t) = R(x_i - x_j)$$

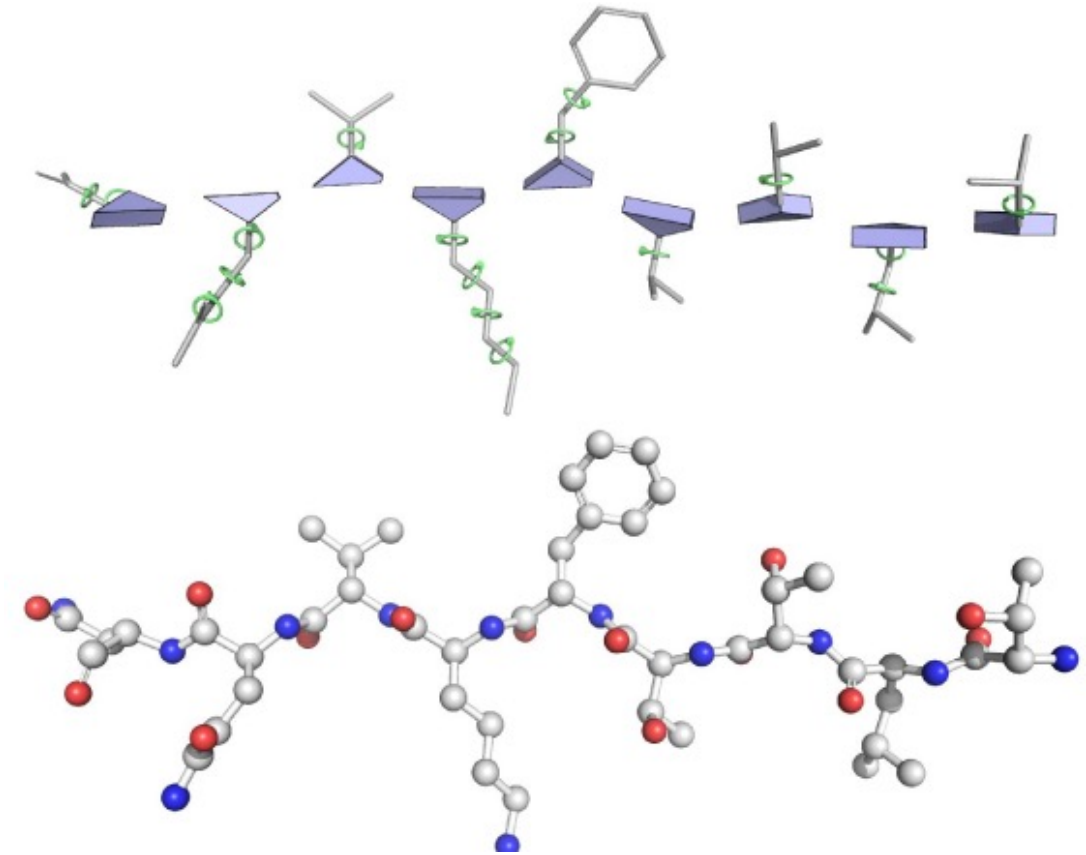


回転を無視することと、内部変形を無視することは違います。例えばループを骨格に対して回すと内部配置が変わるので、検出すべき変化です。

左右の鏡像まで同じとするO(3)不変量か、鏡映を含まない回転・並進を除くSO(3)/SE(3)かを明示します。タンパク質ではキラリティを区別する必要があります。

出典：Jumper et al. (2021) / Sverrisson et al. (2021)

Structure Module：残基ガスで主鎖を表す



残基ガス。上：残基ごとの剛体（三角形）、下：原子の構造（Jumper ら, Nature 596:583 (2021) Fig. 3e を切り出し、CC BY 4.0）

局所フレーム

$$T_i = (R_i, \mathbf{t}_i), \qquad T_i \circ \mathbf{x} = R_i\,\mathbf{x} + \mathbf{t}_i$$

各残基の N–Cα–C を 1 つの剛体（三角形）とみなし、回転 R_i と並進 $\mathbf{t}_i$ で置く。

特徴

初めは全残基を原点に置く（ブラックホール初期化）。残基間の結合を厳密な拘束としては課さず、学習の損失で結合の整合性を促す。二面角で表すときのような、鎖に沿った誤差の積み重ねがない。

Invariant Point Attention（IPA）

IPA の重み

$$a_{ij}^{h} = \mathrm{softmax}_j\left(w_L \left(\frac{\mathbf{q}_i^h \cdot \mathbf{k}_j^h}{\sqrt{c}} + b_{ij}^h - \frac{\gamma^h w_C}{2} \sum_p \left\| T_i \circ \mathbf{q}_i^{hp} - T_j \circ \mathbf{k}_j^{hp} \right\|^2 \right) \right)$$

前半：シングル表現とペア表現からの重み。後半：各残基から作った 3 次元の点 $\mathbf{q}_i^{hp}, \mathbf{k}_j^{hp}$（$p = 1, \cdots, 4$）を局所フレームで動かし、その距離で重みを下げる。h：ヘッド、w_L, w_C：スケールの係数、γ^h：学習で決まる。

補足：全体を回転・並進 $T_g = (R_g, \mathbf{t}_g)$ しても重みが変わらない理由

$$\left\| T_g \circ \mathbf{u} - T_g \circ \mathbf{w} \right\| = \left\| R_g \left(\mathbf{u} - \mathbf{w} \right) \right\| = \left\| \mathbf{u} - \mathbf{w} \right\|$$

並進は差で消え、回転は長さを変えない。だから「向きや位置を変えても同じ構造」をデータから学ぶ必要がない。

距離の項：局所フレームから置いた点が遠いほど注意のスコアを下げ、三次元配置を更新へ反映する。

FAPEは局所座標系で位置誤差を測る

残基iの座標系で原子jを表し、予測構造と参照構造で比較します。分子全体を同じように回しても値は変わりません。

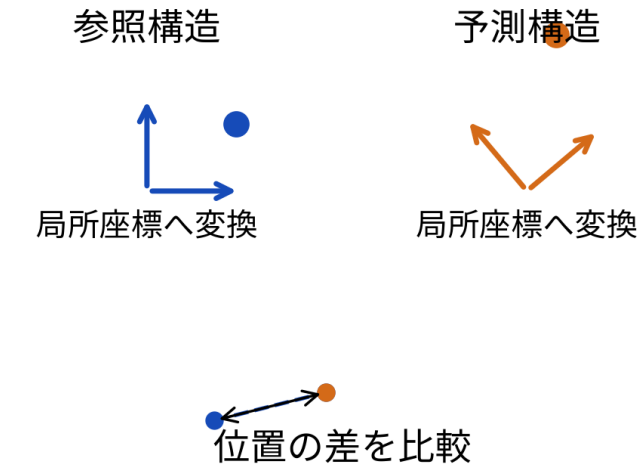
$$z_{ij} = Q_i^T(x_j - t_i), \quad \hat{z}_{ij} = \hat{Q}_i^T(\hat{x}_j - \hat{t}_i)$$

$$L_{\mathrm{FAPE}} = \frac{1}{|\mathcal{J}|} \sum_{(i,j)\in\mathcal{J}} \frac{\min(d_{\max}, \|\hat{z}_{ij} - z_{ij}\|)}{d_{\mathrm{scale}}}$$

$$T_i = (Q_i, t_i), \quad T_i^{-1}(x_j) = Q_i^T(x_j - t_i)$$

$$(GT_i)^{-1}(Gx_j) = T_i^{-1}(x_j), \quad G \in SE(3)$$

$$e_{ij} = \|T_i^{-1}(x_j) - \hat{T}_i^{-1}(\hat{x}_j)\|, \quad \rho(e) = \min(e, d_{\max})$$



フレームの向き自体も評価に入るため、Cαの位置だけの距離とは異なる情報を持ちます。遠い誤差の影響を制限するクランプが使われることがあります。

中央の式はFAPEの考え方を示す簡略形です。AlphaFoldの損失では適用するフレーム・原子・マスクなどの仕様も重要で、構造評価へ使う場合は定義を固定します。

出典：Jumper et al. (2021)

座標の生成、pLDDT、リサイクリング

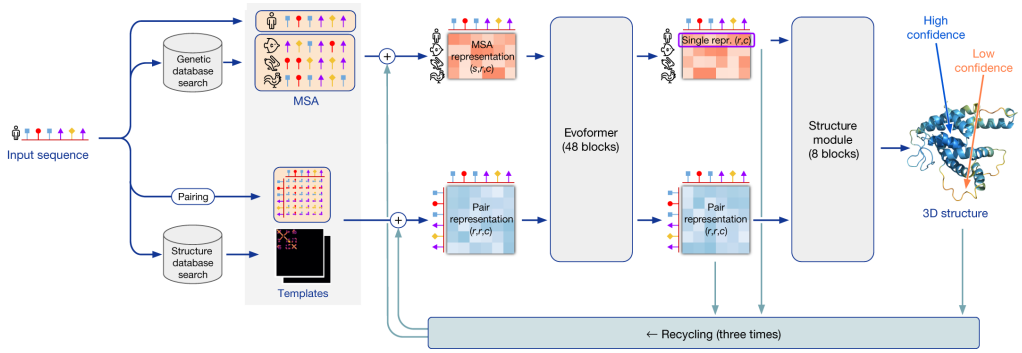
Structure Module の 1 ブロック

① IPA でシングル表現を更新する

② 局所フレーム $T_i = (R_i, \mathbf{t}_i)$ を更新する

③ 浅い ResNet で主鎖と側鎖の二面角を予測する

8 ブロック繰り返す（パラメータは共有）。最後に重原子の座標を計算する。



右端の構造の色が信頼度。下の矢印がリサイクリング（Jumper ら (2021) Fig. 1e を切り出し、CC BY 4.0）

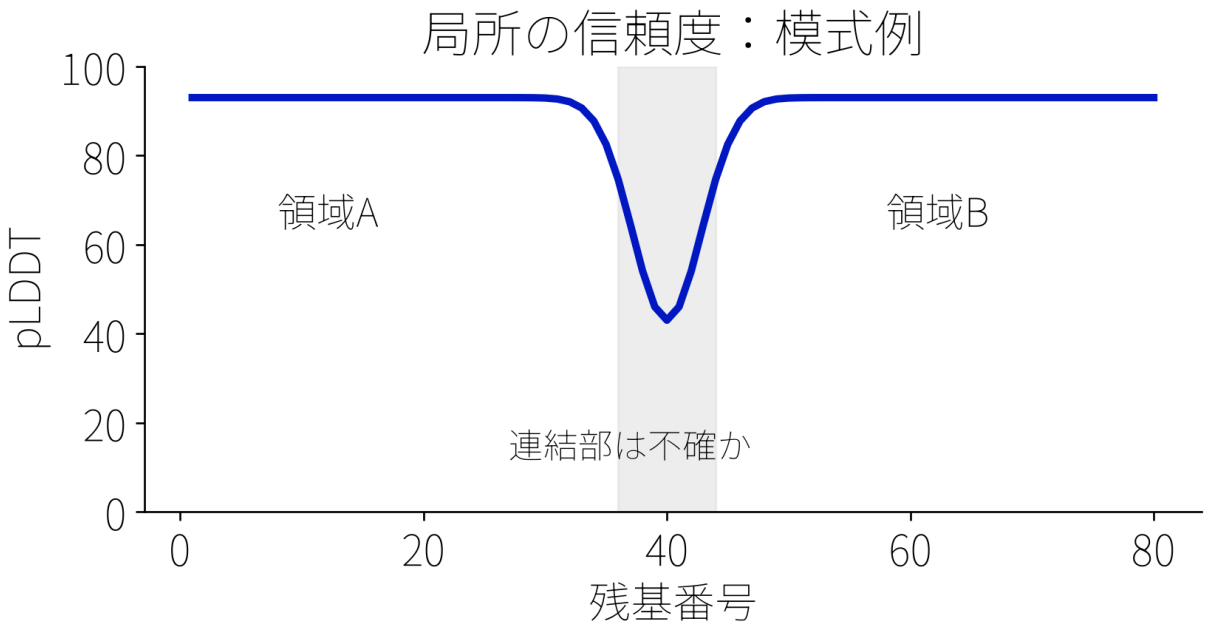
pLDDT：残基ごとの予測の信頼度

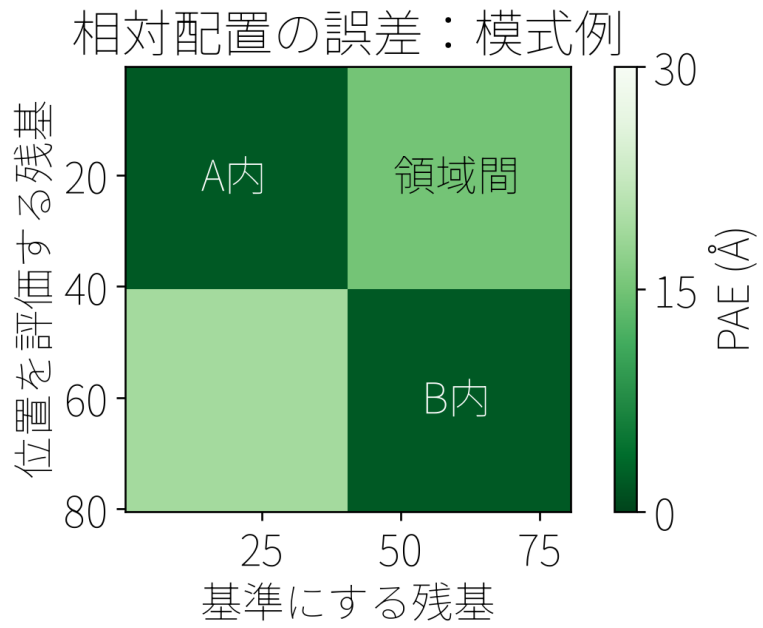
各残基の周辺構造が、どの程度正確かを予測した指標。

リサイクリング

予測した構造を Evoformer の入力に戻して、全体を再計算する（演習では初回の後に3回）。

pLDDTとPAEは、別の不確かさを表す





pLDDT：各残基の局所的な信頼度（0–100）。
高いほど信頼できると予測。
正解確率・結合の強さ・安定性ではない。

PAE：相対配置の予測誤差（Å）。
小さいほど信頼できると予測。
距離行列ではなく、一般に非対称。

Jumper et al. (2021), Supplementary Methods 1.9.6–1.9.7／模式図：本教材で作成

その後

AlphaFold 2 の限界

影響

予測構造のデータベース AlphaFold DB（DeepMind と EMBL-EBI）を無償で公開。ソースコードも Apache 2.0 ライセンスで公開され、世界中で使われ改良されている。

限界	内容
① MSA への依存	似た配列が少ないと精度が下がる。MSA を作る計算にも時間がかかる
② 原著の単量体モデル	複合体は別モデルのAlphaFold-MultimerやAF3で扱う
③ 1 つの静的な構造	構造変化や揺らぎなど、機能に欠かせない動きを捉えにくい。状態の存在確率や時間発展を直接は予測しない
④ その他	変異の影響の精密な予測、翻訳後修飾をもつタンパク質の扱い

その後

AlphaFold 2 のあとの発展

名前	何をしたか
AlphaFold-Multimer	タンパク質複合体の構造を高い精度で予測する
ColabFold	高速な配列検索（MMseqs2）とクラウド（Google Colaboratory）で、手軽に速く予測する
RoseTTAFold	配列・残基対・3次元構造を連携させる3トラックのモデル
ESMFold	タンパク質言語モデルを使い、MSA なしで 1 本の配列から予測する。速いが精度は MSA を使う方法に及ばないことも
MSA の間引き・クラスタリング	入力する MSA を変えて、複数の構造（構造の多様性）を出させる
AlphaFold 3	DNA・RNA・低分子・イオンとの複合体まで予測する。構造の生成に拡散モデルを使う

拡散モデル：ノイズから出発し、ノイズを少しずつ除去して、配列などの入力条件に合う構造を生成する。

まとめ

配列の情報から、表現・座標・信頼度へ

① 配列の情報を集める

配列とMSAから特徴を作る。MSAの保存・変異は、残基間の関係を推定する手掛かりになる。テンプレート構造も入力できる。

② 残基間の関係を更新する

EvoformerでMSA表現とペア表現を更新する。注意機構や三残基の更新で情報を交換する。ペア表現は距離そのものではない。

③ 三次元の座標を作る

Structure Moduleで残基の局所フレームと二面角を更新し、原子座標を作る。全体をリサイクリングで再計算する。折り畳みの時間経過を計算する操作ではない。

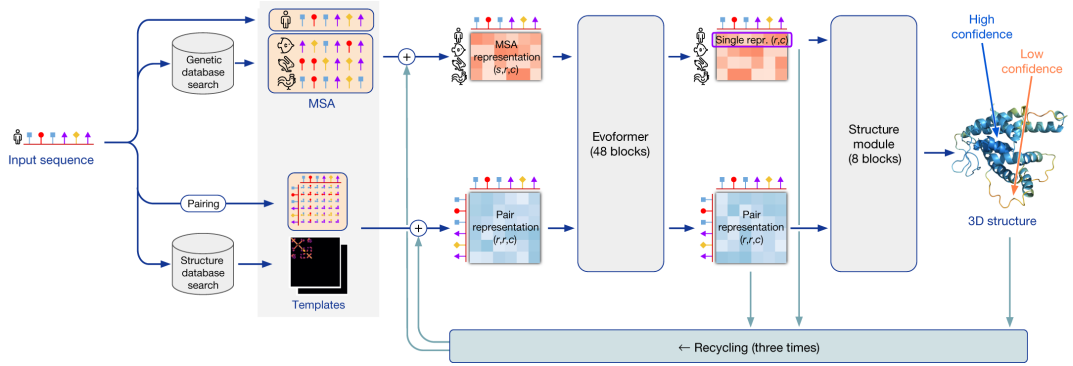
④ 予測の信頼度を読む

pLDDTは局所構造、PAEは相対配置の予測誤差を評価する。高い信頼度は、実際の構造・機能の証明ではない。演習では座標と信頼度を対応させて読む。

ユビキチンを配列から予測する

授業リポジトリ →「Colabで開く」

1. Googleアカウントでログイン
2. ランタイムのタイプ：T4 GPU
3. 「すべてのセルを実行」
4. 構造と信頼度の図を観察



入力：ユビキチン76残基。MSA検索あり・テンプレートなし・3回recycle・Amber緩和なし。

演習20分、採点・提出なし。初回準備と計算待ちは環境に依存する。
入力配列は公開MSA検索サーバーへ送られる。今回は公開配列だけを使う。

構造と信頼度を同じ残基番号で読む

立体構造

ドラッグして回転。color = rainbow で配列順、lDDT で信頼度。設定変更後は表示セルだけ再実行。

pLDDT と PAE

局所の信頼度と相対配置の予測誤差を区別。PAEの対角だけでなく、離れた領域間も読む。

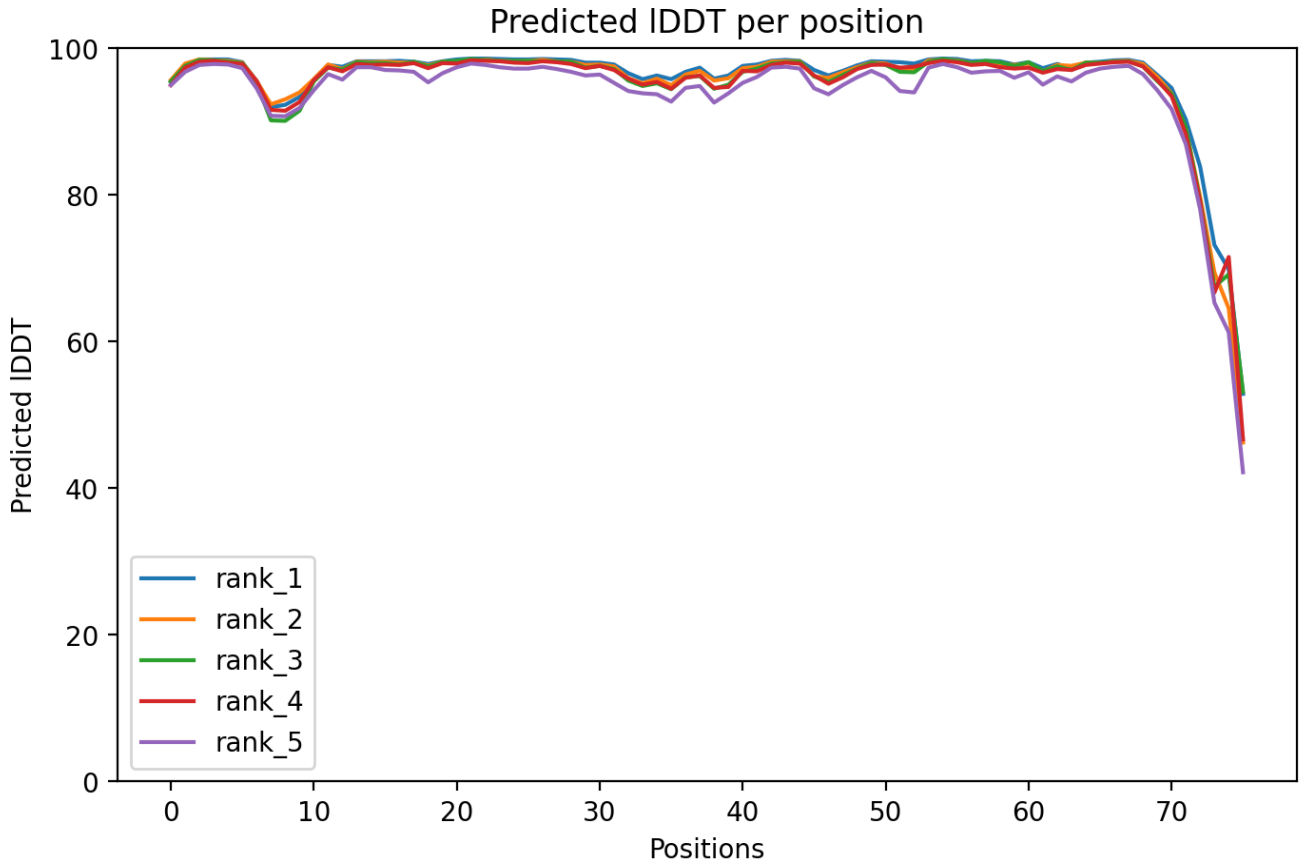
MSA と 5モデル

MSA coverage の偏りを確認。rank_num を変えて構造を比較し、信頼度による順位だと確認。

結果の保存

ZIPのPDB・MSA・scores JSON・logを保存。予測結果の解釈には入力条件も残す。

平均値だけでなく、末端の信頼度を見る



実行結果の読み方

5モデルとも、多くの残基で高い信頼度。

rank 1：平均95.9
最後の76番残基：52.9

平均が高くても、末端まで確かとは限らない。

2026-10-11実行：ユビキチン76残基、T4、5モデル、3 recycle。図のPositionsは0始まり（0が第1残基）。

従来法・Attention・設計の補足

従来法：用語、配列同一性、二次構造、断片、スレッディング、統計的ポテンシャル、物理計算、CASP。
Attention：Q・K・V、行列による計算、複数ヘッド。
設計：ColabDesignへの接続。

補足：距離行列から三次元座標を復元できる条件

$$J = I - \frac{1}{N}\mathbf{1}\mathbf{1}^T, \quad B = -\frac{1}{2}J(D \circ D)J = X_c X_c^T$$

$$D_{ij}^2 = B_{ii} + B_{jj} - 2B_{ij}, \quad B \succeq 0, \quad \operatorname{rank} B \leq 3$$

D：原子間距離、J：重心を引く操作、Xc：重心を原点にした座標。D∘Dは成分ごとの二乗。
Bが半正定値で階数3以下なら三次元へ埋め込める。座標は回転・並進・鏡映の違いを除いて定まる。

構造予測で使う言葉

用語	意味
ターゲット	構造を予測したいタンパク質
クエリ配列	ターゲットのアミノ酸配列
テンプレート	構造がわかっていて、ターゲットに配列が似たタンパク質
ホモロジーモデリング	テンプレートの構造をもとにターゲットの構造を組み立てる（相同性モデリング）
スレッディング	似た配列がないとき、配列を既知の折り畳みに当てはめ、最も合うものを選ぶ
分子シミュレーション	物理法則にしたがって一から折り畳ませる（今は小さなタンパク質だけ）

基本の考え方：2 つのタンパク質の配列が似ていれば、ふつうは構造も似ている。

配列同一性は信頼性を考える目安

成功に必要な 4 つのこと

(i) 関連するテンプレートを見つける

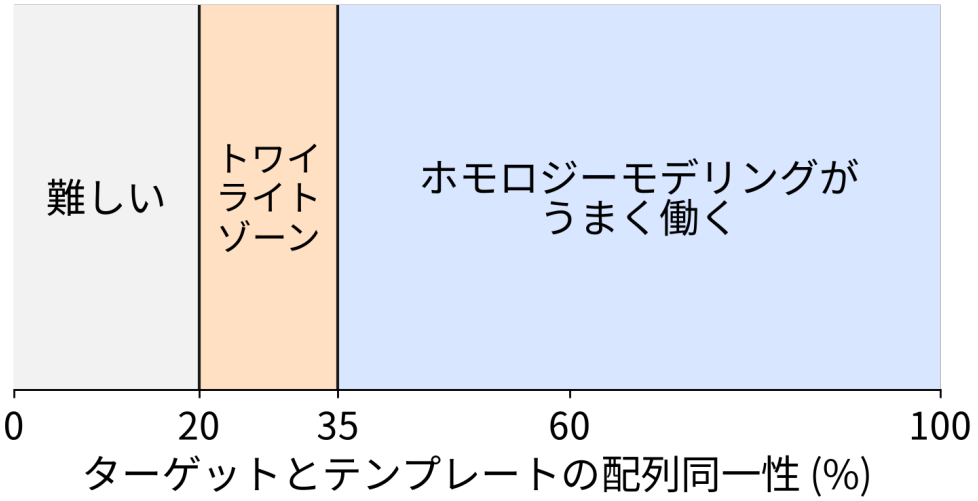
(ii) 良い配列アラインメントを得る

(iii) 天然に近い構造を見分けるスコア関数を用意する

(iv) 天然に近い構造に届くまで、十分に構造を探す

配列同一性とは

2 つの配列を並べたとき、同じアミノ酸が並ぶ位置の割合。



35% 以上：構造を推定しやすいことが多い

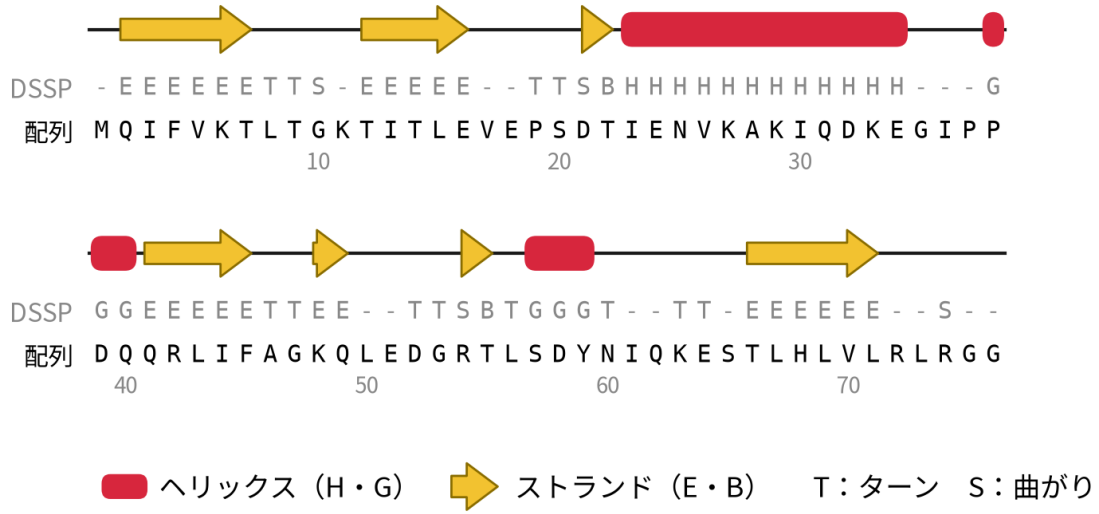
20〜35%：トワイライトゾーン。信頼性が下がる

配列長・整列の質にも依存し、絶対的な境界ではない。

二次構造を決める・予測する

構造がわかっているとき：DSSP

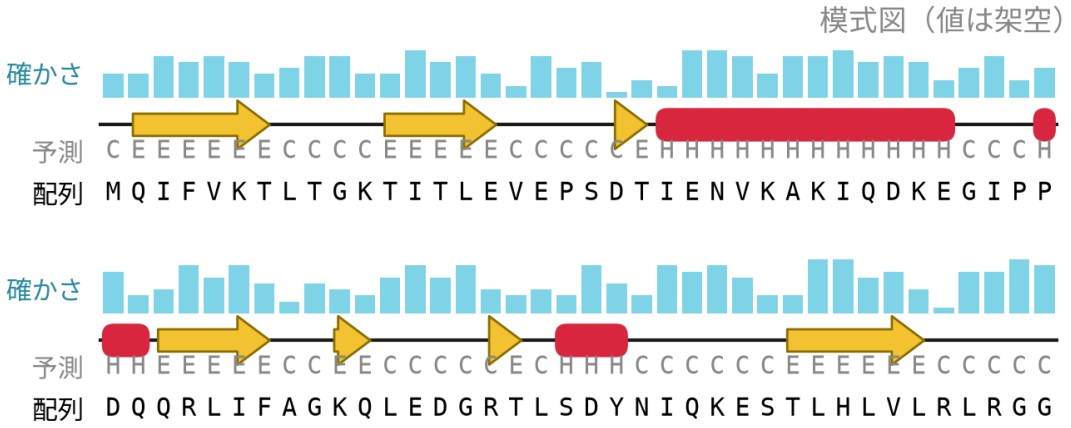
水素結合のパターンから二次構造を割り当てる。8 種類の文字列で表す（H：α ヘリックス、E：β ストランド、G：3_{10} ヘリックス、T：ターン など）。



DSSP の出力の例：ユビキチン（PDB 1UBQ）

構造がわからないとき：PSIPRED

配列から二次構造を予測するサーバー。ニューラルネットワークを使う。相同配列の情報も利用する。精度は予測するクラス数や評価データに依存する。



H：ヘリックス　E：ストランド　C：コイル。棒が高いほど確か

PSIPRED の出力の形（模式図、値は架空）

9 残基の断片で組み立てる

フラグメント組み立て法

① ターゲットを 9 残基ずつ、ずらしながら区切る

② 各断片で PDB を検索し、似た断片の主鎖の角度 (φ, ψ) を借りる

③ 断片をつなぎ替えながら構造を探し、スコアで評価する

背景

D. Baker らが開発し、予測プログラム Rosetta の中心になった。Baker は 2024 年のノーベル化学賞を AlphaFold の開発者と共に受賞。



9 残基ずつ区切り、PDB の似た断片の
主鎖の角度 (ϕ, ψ) を借りる

→ 断片をつないで、スコアで評価しながら構造を探す

模式図

スレッディング：既知の折り畳みに当てはめる

手順

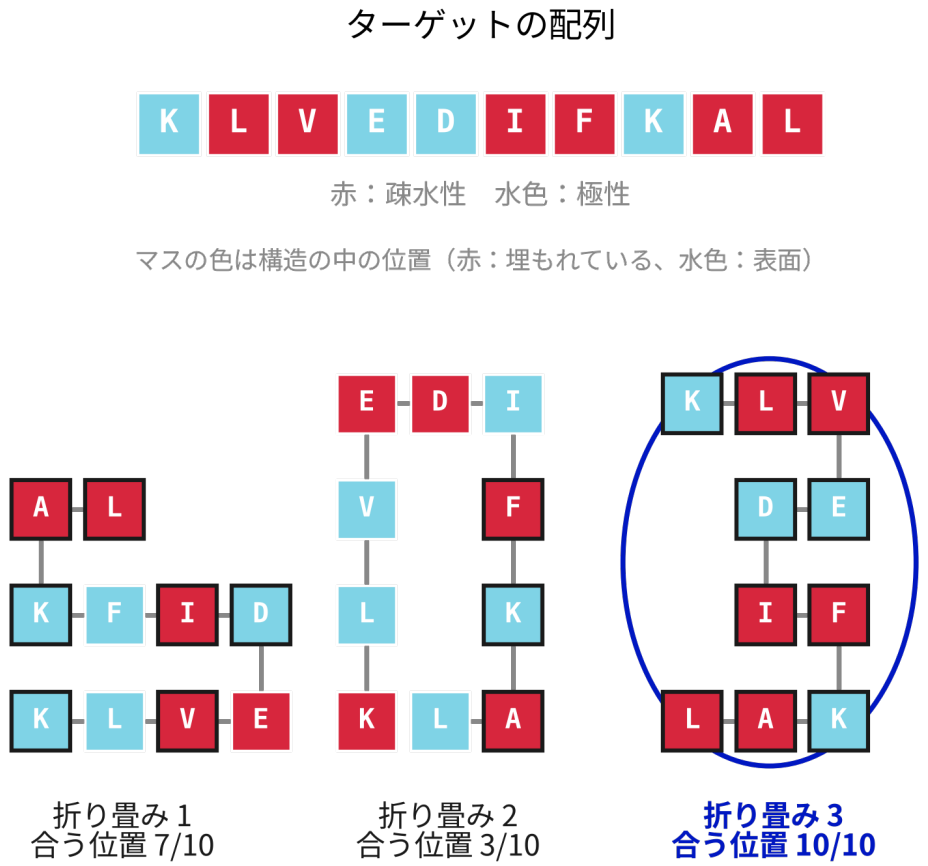
① ターゲットがとりそうな折り畳みを PDB から選ぶ（既知構造の集合）

② 配列を各構造に当てはめる（アミノ酸を置き換える）

③ 合い方をスコアで比べ、最も合う折り畳みを選ぶ

限界

候補の集合に適切な折り畳みがなければ選べない。挿入・欠失の扱いと、スコア関数の良し悪しにも左右される。



疎水性の残基が埋もれた位置に合う、折り畳み 3 が最適（模式図）

統計的ポテンシャル：頻度をエネルギーへ

PDB で数えた頻度から確率を作る

$$p_i = \frac{m_i}{M}, \qquad M = \sum_i m_i$$

m_i：二面角が i 番目のビンに入った数

確率をエネルギーに直す

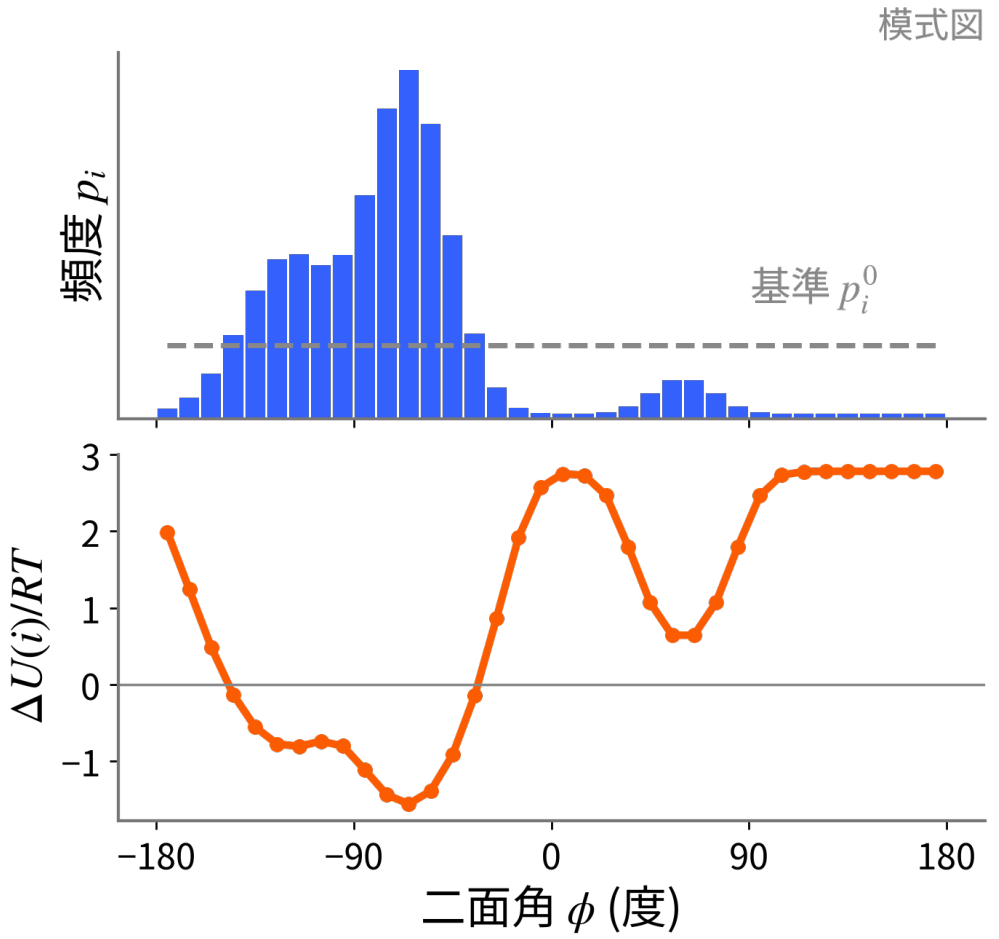
$$\frac{\Delta U(i)}{RT} = -\ln \frac{p_i}{p_i^0}$$

p_i^0：ランダムな分布（基準状態）の確率

補足：なぜ対数か（ボルツマン分布を逆に解く）

$$p_i \propto e^{-U_i/RT} \;\Rightarrow\; U_i = -RT \ln p_i + \text{const.}$$

基準状態との比をとると、定数が消える。



接触ポテンシャル：アミノ酸の対の好み

対の好みをエネルギーで表す

$$\Delta\Delta U = \Delta U_{AC} - \Delta U_{AB} = -RT \ln \frac{p(AC)}{p(AB)}$$

$$\Delta U_{ij} = U_{ij} - U_{ij}^{0} = -RT \ln \frac{p_{ij}}{p_{ij}^{0}}$$

20 × 20 の対称な表（210 種類の対）を、PDB の接触の数で埋める。側鎖の中心間が 6.8 Å 以下を接触とする。

対数をとると、エネルギーとして足し算できる（局所と非局所の寄与を同じ単位で合わせられる）。

統計的ポテンシャルは本当の自由エネルギーではない。RTはほかの項との釣り合いを調整するパラメータとして扱う。

接触ポテンシャル Uij（単位 RT）

	F	L	I	K	E
F	−7.26	−7.28	−6.84	−3.36	−3.56
L	−7.28	−7.37	−7.04	−3.37	−3.59
I	−6.84	−7.04	−6.54	−3.01	−3.27
K	−3.36	−3.37	−3.01	−0.12	−1.80
E	−3.56	−3.59	−3.27	−1.80	−0.91

F・L・I：疎水性（フェニルアラニン・ロイシン・イソロイシン）、K・E：電荷をもつ（リシン・グルタミン酸）

数値の出典：Protein Actions 日本語版、表11.A.1の一部。

物理シミュレーションで折り畳む

物理シミュレーションの良いところ

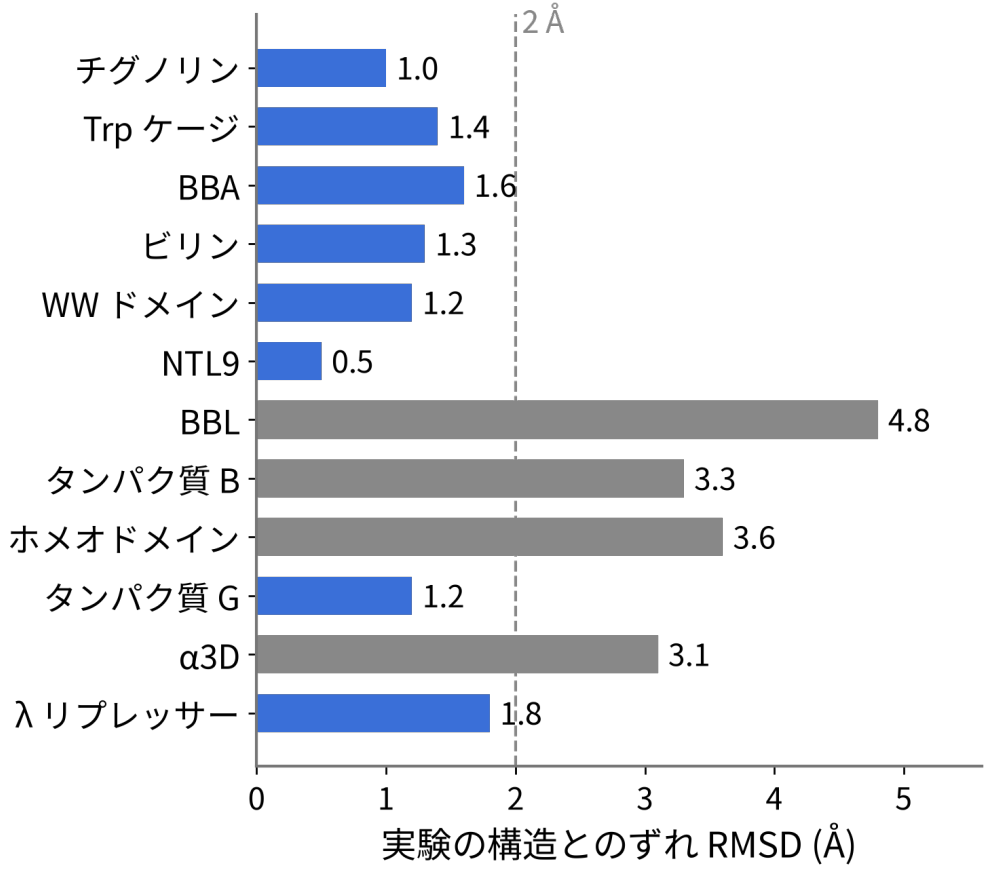
① 構造テンプレートを必要としない。ただし力場の精度に依存する。

② 配列アラインメントが要らない

③ 構造の動きや結合過程を計算し、十分に探索できれば自由エネルギーも評価できる。

現状

計算にとても時間がかかる。専用計算機 Anton による分子動力学（MD）シミュレーションで、小さなタンパク質を天然に近い形に折り畳ませることができた。



Anton で折り畳んだ構造と実験の構造のずれ（Lindorff-Larsen ら, Science 334:517 (2011) の値）

CASP：答えを伏せた予測コンテスト

CASP（Critical Assessment of Structure Prediction）

1994 年に J. Moult が始めた予測コンテスト。2 年ごとに開かれる。

① 構造が未公開のタンパク質の配列を出題する

② 参加者が構造を予測する

③ 実験の構造が公開されたあと、予測を評価する

従来法で予測しやすかった対象

小さく、水溶性で、単一ドメインで、良いテンプレートがあるタンパク質。AlphaFold以降は、良いテンプレートがない対象にも予測の適用範囲が広がった。

- 1994 CASP 開始
- 2011 直接結合分析（DCA）
- 2012 EVfold
- 2017 メタゲノム配列で予測
- 2018 AlphaFold 1（CASP13）
- 2020 AlphaFold 2（CASP14）
- 2021 論文・コード公開
- 2022 ColabFold
- 2024 AlphaFold 3・ノーベル化学賞

誤った接触は構造を壊す

共進化から構造を作る流れ

MSA → 共変異する対を見つける → 対に接触の束縛をかける → MD・モンテカルロ法・フラグメント組み立てで最適化

問題：偽陽性の対

本当は接触していないのに、接触すると判定した残基対。誤った拘束を加えると、構造をゆがめる原因になる。

配列の数と多様性が予測精度に影響する

Ovchinnikov ら（2017）：有効配列数 N_f が予測精度とよく相関する。

$$N_f = \frac{N_{80}}{\sqrt{L}}$$

N_{80}：配列同一性 80% 以上のものを 1 本とまとめて数えた配列の数、L：クエリ配列の長さ

結果

メタゲノム解析（環境中の微生物の DNA をまとめて読む）で配列を増やして N_f を上げ、構造が未知の 1297 ファミリーを高精度に予測した。

畳み込みニューラルネットワーク（CNN）

畳み込み層

$$(I * K)(i,j) = \sum_m \sum_n I(i+m,\ j+n)\, K(m,n)$$

フィルタ Kを入力 Iの上でずらしながら積和をとる。模様が似た場所で値が大きい。Kは学習で決まる。

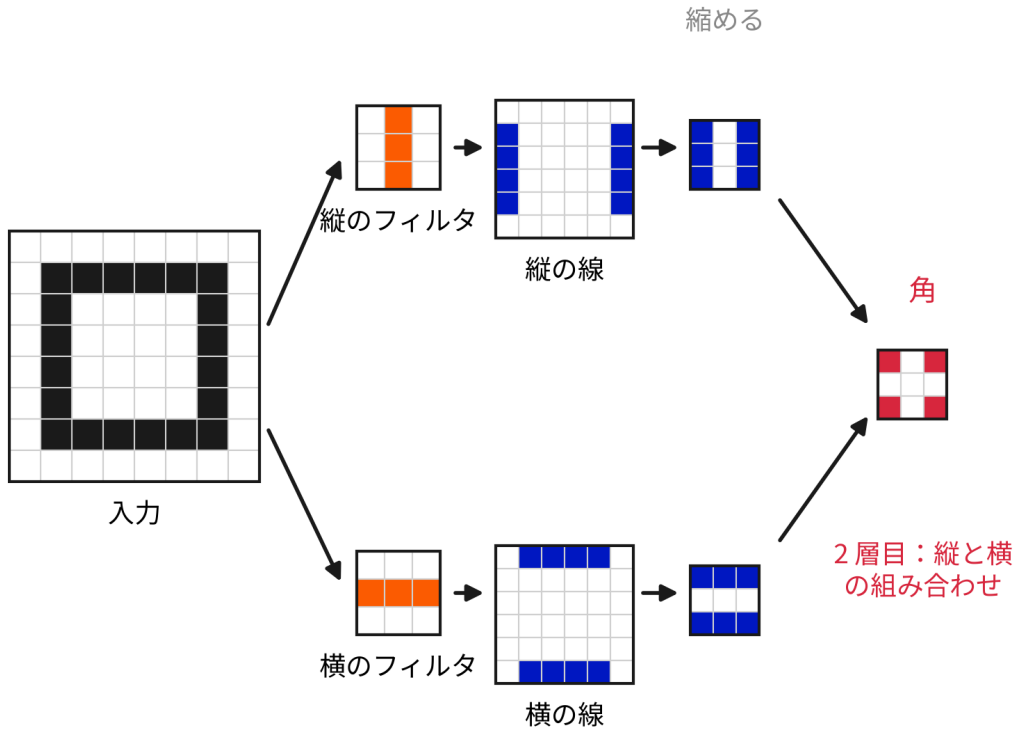
1 つのフィルタを使い回す（パラメータ共有）ので学習が効率的。模様がどこにあっても見つかる（並進同変性）。

プーリング層

小さな領域の最大値だけを残して縮める。位置の小さなずれに強くなる。

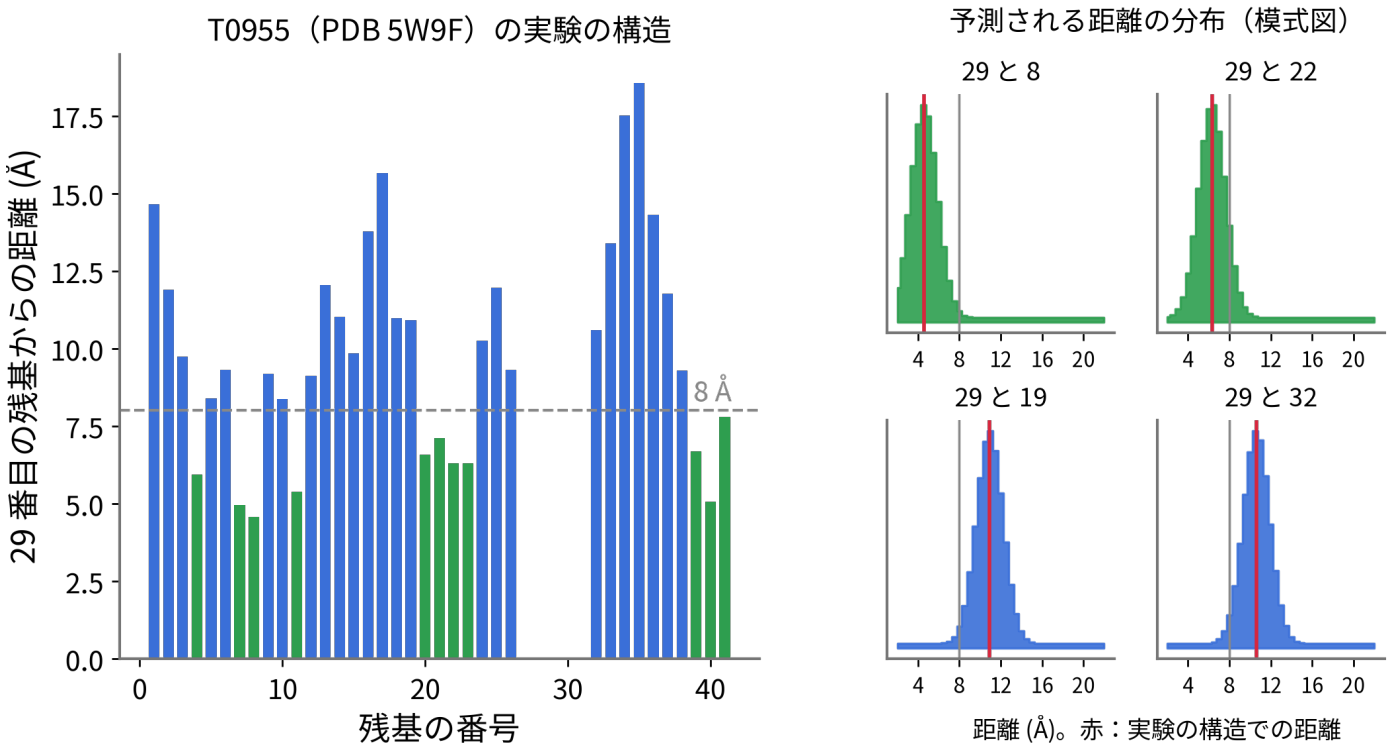
構造予測での使い方

MSA などの特徴量を 2 次元の「画像」にして入力し、接触マップを 2 次元で出力する。



1 層目で縦・横の線、2 層目でその組み合わせ（角）を捉える（模式図）

共進化は遠い距離の情報も含んでいた



T0955 の 29 番目の残基からの距離（左）と、予測される距離の分布の形（右、模式図）

図の見方

左：実験の構造での距離。緑：接している対（8 Å 以内）、青：接していない対

右：予測の形（模式図）。赤線：実験の構造での距離。灰色の縦線：8 Å

論文の結果

19・24・32・33・36 番は接していないのに、予測の山が正しい距離と一致した（Senior ら, Nature 577:706 (2020)）。

距離分布なら非接触の対も扱え、接触の二択より多くの情報を使える。ただし予測誤差は残る。

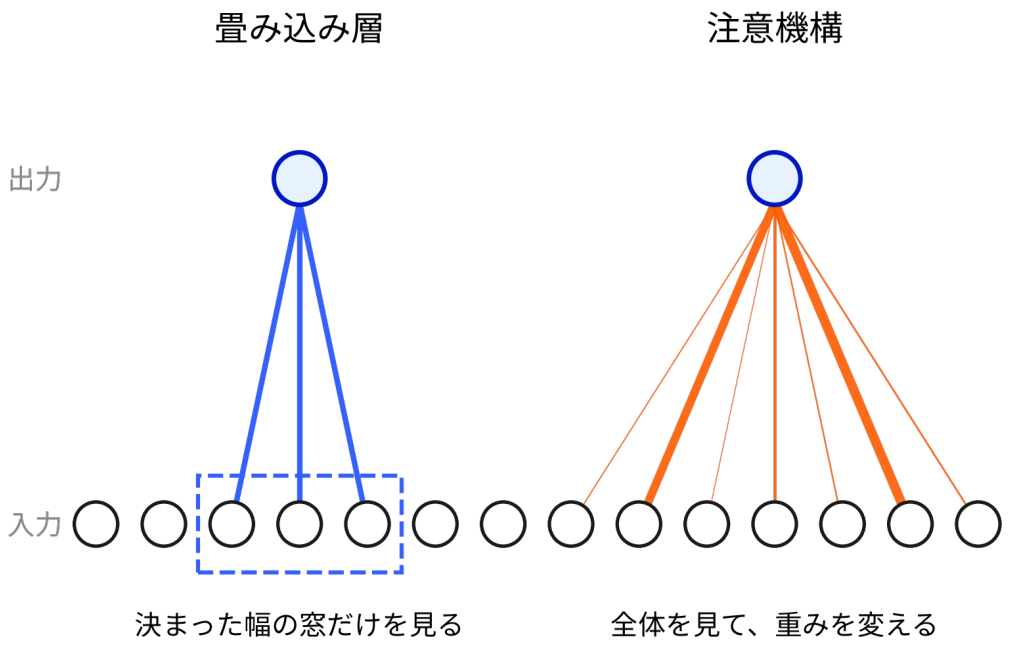
注意機構：クエリ・キー・バリュー

3 つのベクトルを作る

$$\mathbf{q}_i = \mathbf{x}_i W_Q, \quad \mathbf{k}_i = \mathbf{x}_i W_K, \quad \mathbf{v}_i = \mathbf{x}_i W_V$$

$\mathbf{x}_i$：i番目のトークン（横ベクトル）。W_Q, W_K, W_Vは学習で決まる行列。

	役割	計算で使うもの
クエリ	情報を集める位置の特徴	キーとの内積でスコアを作る
キー	参照される位置の特徴	各クエリと比較する
バリュー	集める情報の特徴	注意の重みを掛けて足し合わせる



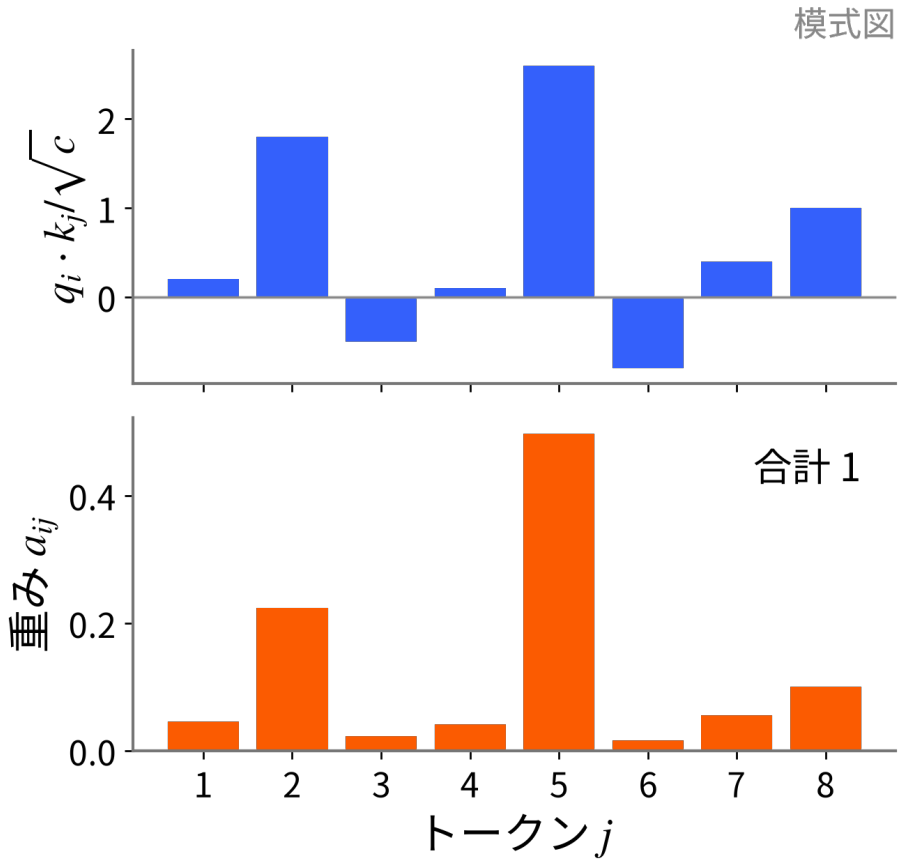
左：畳み込み層は局所を見る。右：注意機構は全体を見渡す（模式図）

注意機構の計算

③ 行列でまとめて書く

$$\mathrm{Attention}(Q,K,V)=\mathrm{softmax}\left(\frac{QK^T}{\sqrt{c}}\right)V$$

補足：$\sqrt{c}$で割るのは、次元 cが大きいと内積のばらつきが大きくなり、softmax が 1 つの要素に偏るのを防ぐため。



マルチヘッドと層の積み重ね

マルチヘッドアテンション

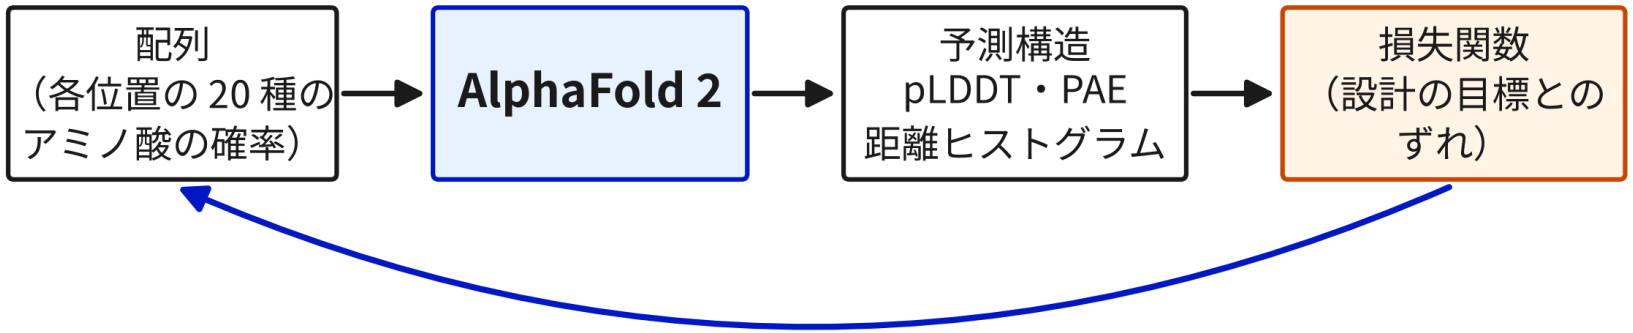
複数の注意機構（ヘッド）を並べて同時に計算する。ヘッドごとに異なる射影を使い、多様な関係を学べる。各ヘッドが特定の物理相互作用に対応するとは限らない。

層を重ねる

注意機構を含むブロックを何層も重ねて、複雑な依存関係を表す。計算は並列にしやすく、GPU で行う。

	CNN（畳み込み）	注意機構
入力	格子状のデータ（画像）	ベクトルの系列
見る範囲	決まった大きさの局所	系列の全体
遠い要素の関係	層を重ねて間接的に	1 つの層で直接
計算量	小さい	大きい（系列の長さの 2 乗）

ColabDesign は AlphaFold 2 をどう使うか



考え方（構造予測の逆）

配列を「各位置の 20 種のアミノ酸の確率」という連続な表で表し、AlphaFold 2 に入れる。損失の勾配を配列まで逆にたどり、配列を更新する。

使い方の例：骨格を固定した配列設計、目標なしで折り畳まる配列を作る（ハルシネーション）、標的に結合するタンパク質の設計

損失に使う出力

pLDDT：残基ごとの信頼度（高くしたい）

PAE（predicted aligned error）：残基 i の局所座標系を基準にした残基 j の位置の予測誤差（小さくしたい）

距離ヒストグラム：目標の構造との違い

第07回で配列設計として詳しく扱う