生命情報工学特論　第06回

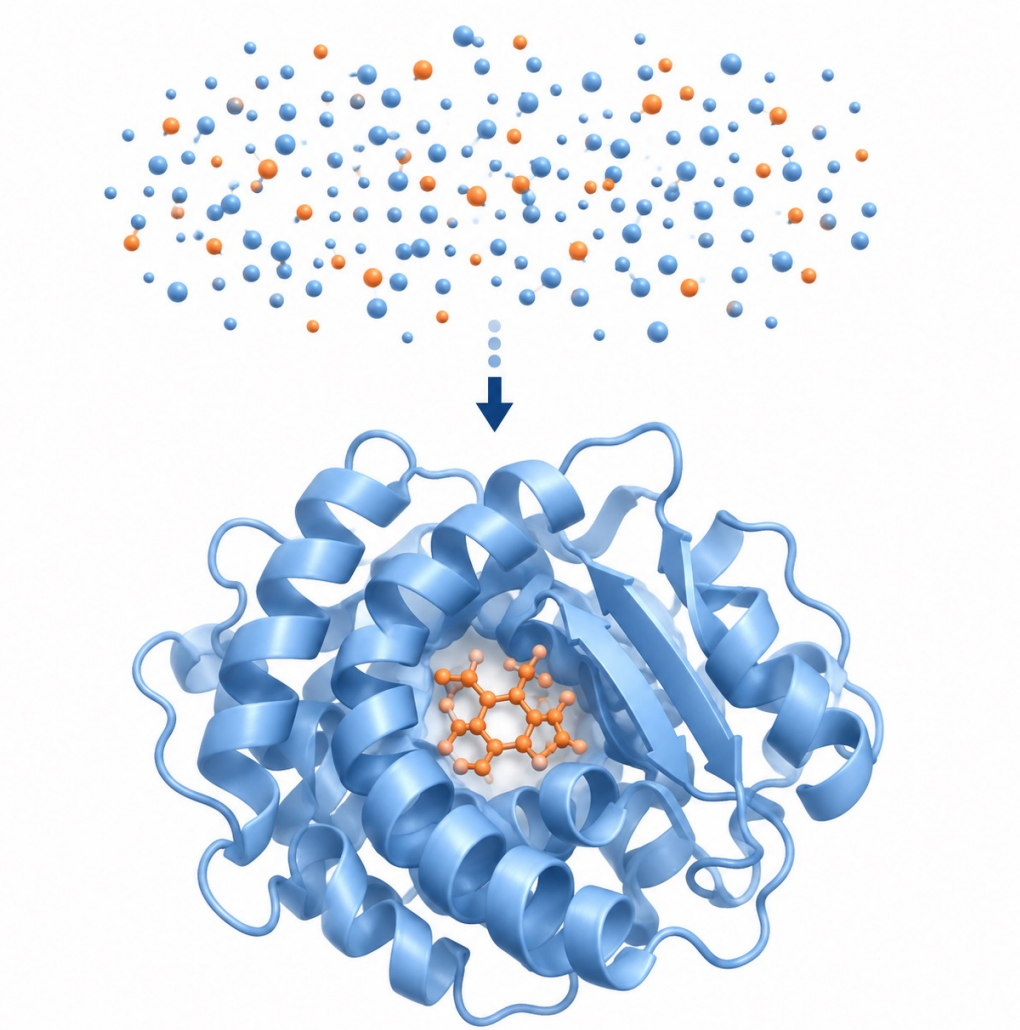
Boltz による
複合体構造予測

タンパク質と低分子の配置を予測する
拡散モデルの仕組み・Boltz演習

松永 康佑

埼玉大学 大学院理工学研究科
理化学研究所 計算科学研究センター ｜ 2026年11月2日

分子の情報を条件に、座標を生成



概念図：青はタンパク質、橙は低分子。実際の予測構造ではない。

今日の内容

分子を入力し、構造と信頼度を得る

入力：分子の条件

タンパク質A・固定MSA
SAH（C）・チロシン（E）

→

計算：座標の生成

初期ノイズ → 除去器
→ 小さいノイズへ更新

→

出力：複合体

CIF：原子の三次元座標
JSON・NPZ：信頼度

複合体：複数の分子が組み合わさった構造。
低分子：ここではタンパク質より小さい有機分子。結合位置と向きも予測対象になる。

モデルは既知の構造から学習済み。演習は推論だけを行う。
信頼度が高くても、結合の有無・結合の強さ・時間的な動きが実証されたわけではない。

学習するものと、繰り返す計算を分ける

AF2から複合体予測へ

原子・トークン・ペアの表現と、条件を作る共通部分。

ノイズを加え、元の座標を学ぶ

条件付き分布、二乗誤差、ノイズ除去器とスコア。

ノイズから構造を生成する

ノイズ量を下げる更新、数値積分、Boltzの座標ネットワーク。

信頼度とColab演習

構造の精度と予測された信頼度を分け、実際の出力を読む。

付録：詳しい数式の導出

DDPM、スコア恒等式、逆時間SDE、確率流ODE、EDMの尺度係数。

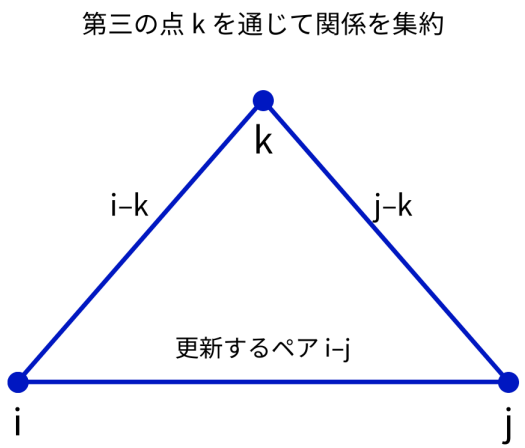
AlphaFold 2から引き継ぐもの

1 AlphaFold 2から引き継ぐもの

多重配列アラインメントは、進化の過程で残された配列の変化をまとめた情報です。

残基対の表現には、二つの残基の関係を数値として保持します。三角形を使う更新も引き継がれます。

リサイクリングは、得られた内部表現を次の推論へ戻して繰り返す処理です。



2 AlphaFold 3で座標生成が変わる

低分子や核酸を含む複合体では、タンパク質の残基だけでは表せない原子が多数あります。

AlphaFold 3は全原子座標の生成に拡散モデルを用います。ノイズの多い座標から徐々に構造を作ります。

Boltzを理解するには、この変化をAlphaFold 2との間に置くとつながりが見えます。

AF2：残基の骨格と局所構造 → AF3：多様な分子の全原子座標 → Boltz：公開実装で追う

Wohlwend et al., Boltz-1 (2024/2025), bioRxiv / Abramson et al., Nature 630, 493–500 (2024)

同じ分子を二つの細かさで見る

1 同じ分子を二つの細かさで見る

原子座標を求めるには、各原子の情報が必要です。一方、全原子どうしの注意計算は高価になります。

Boltzは原子単位の情報と、より粗いトークン単位の情報を使い分けます。

トークンとは、ネットワークが一単位として扱う要素です。

原子：元素・電荷・参照座標 → トークン：残基や原子 → トークン対：二者の関係

2 タンパク質と低分子で単位が違う

タンパク質は基本的に1残基を1トークン、DNA・RNAは1ヌクレオチドを1トークンとします。

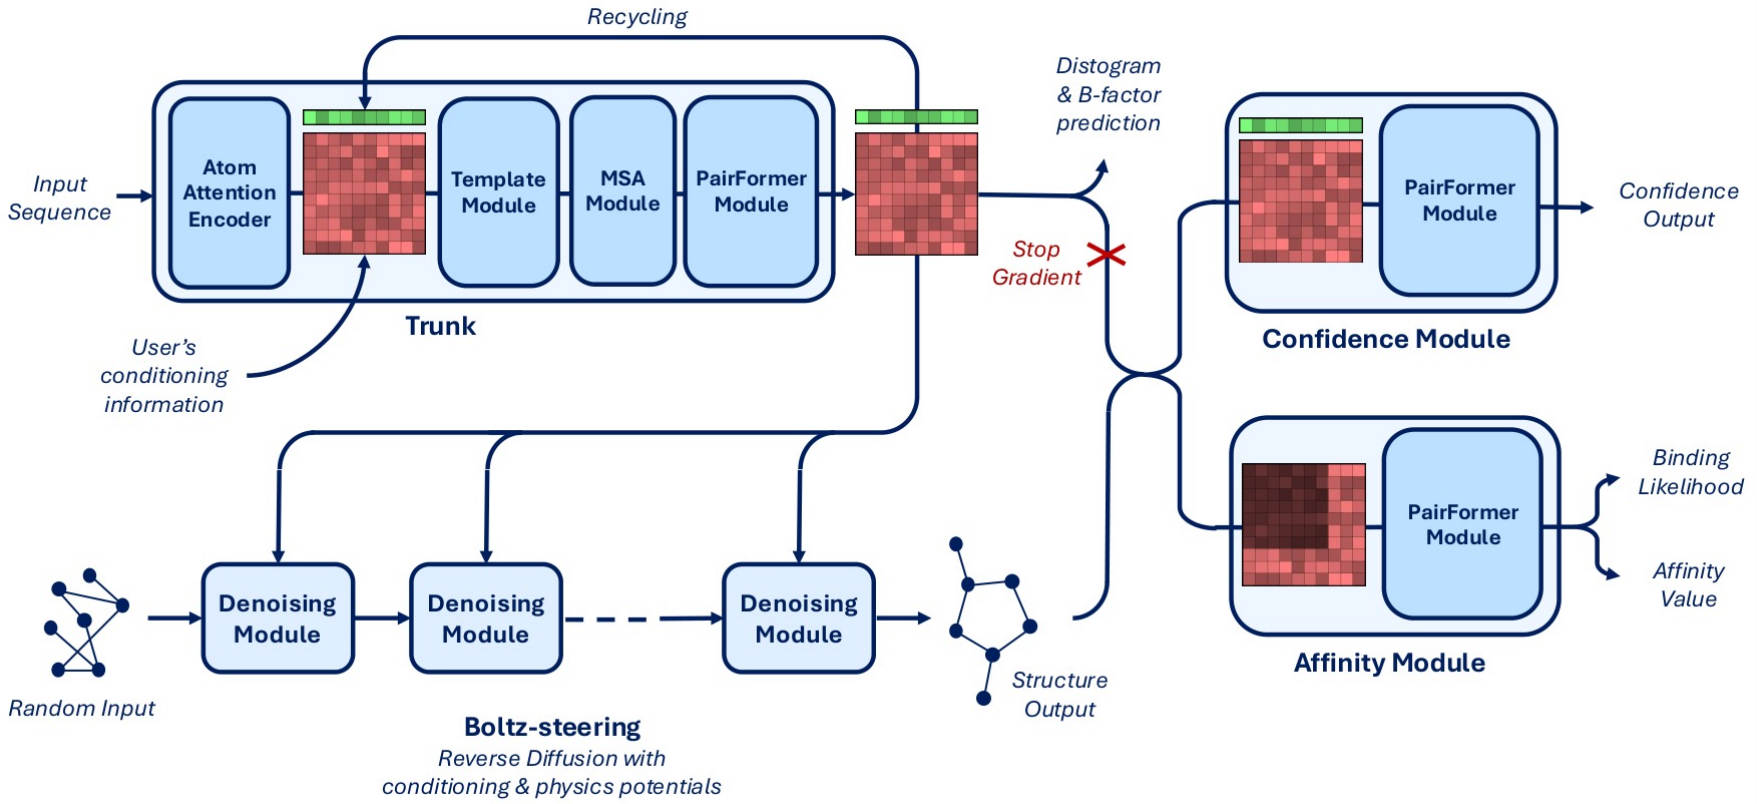
それ以外の分子は原子ごとのトークンで表します。

Boltz-2では非標準のアミノ酸やヌクレオチドも残基単位に保ちます。Boltz-1との相違点です。

タンパク質：残基ごと → DNA / RNA：ヌクレオチドごと → その他：原子ごと

Passaro et al., Boltz-2 (2025), bioRxiv

原著の図で四つの部品をつなぐ



共通部分（trunk）が分子の条件を作り、座標生成部が原子を配置する。
信頼度は別の出力。親和性の予測は今回の演習では行わない。

Passaro et al., Boltz-2 (2025), Fig. 2 · CC BY 4.0

Passaro et al., Boltz-2 (2025), bioRxiv

リサイクリングは拡散と別の反復

1 リサイクリングは拡散と別の反復

リサイクリングではtrunkの出力表現を正規化して戻し、分子間の関係を再推論します。

拡散の反復では、trunkの表現を条件にしながら原子座標を更新します。

前者の回数を増やすことと、後者の刻みを増やすことは計算経路も費用も違います。

recycling：表現を再推論 → diffusion steps：座標を生成 → diffusion samples：候補を増やす

2 高速化しても演算の意味を保つ

ペア配列が大きいため、三角演算の計算量とメモリ使用量が重要になります。

cuEquivarianceはBoltzの三角乗法更新と三角注意を高速に計算する経路を提供します。

同じ重みと入力で出力・勾配を比較してから、速さを測るのが実装編の課題です。

通常のPyTorch計算 → 同じ演算のGPUカーネル → 数値と勾配を照合 → 性能を測定

Boltz source 2.2.1・b1ebfc4・参照 2026-10-09 / Boltz prediction documentation・b1ebfc4 / NVIDIA cuEquivariance documentation・参照 2026-10-09

画家の下描きから、段階的な生成を考える

ラフ：位置と輪郭



中間：形と陰影



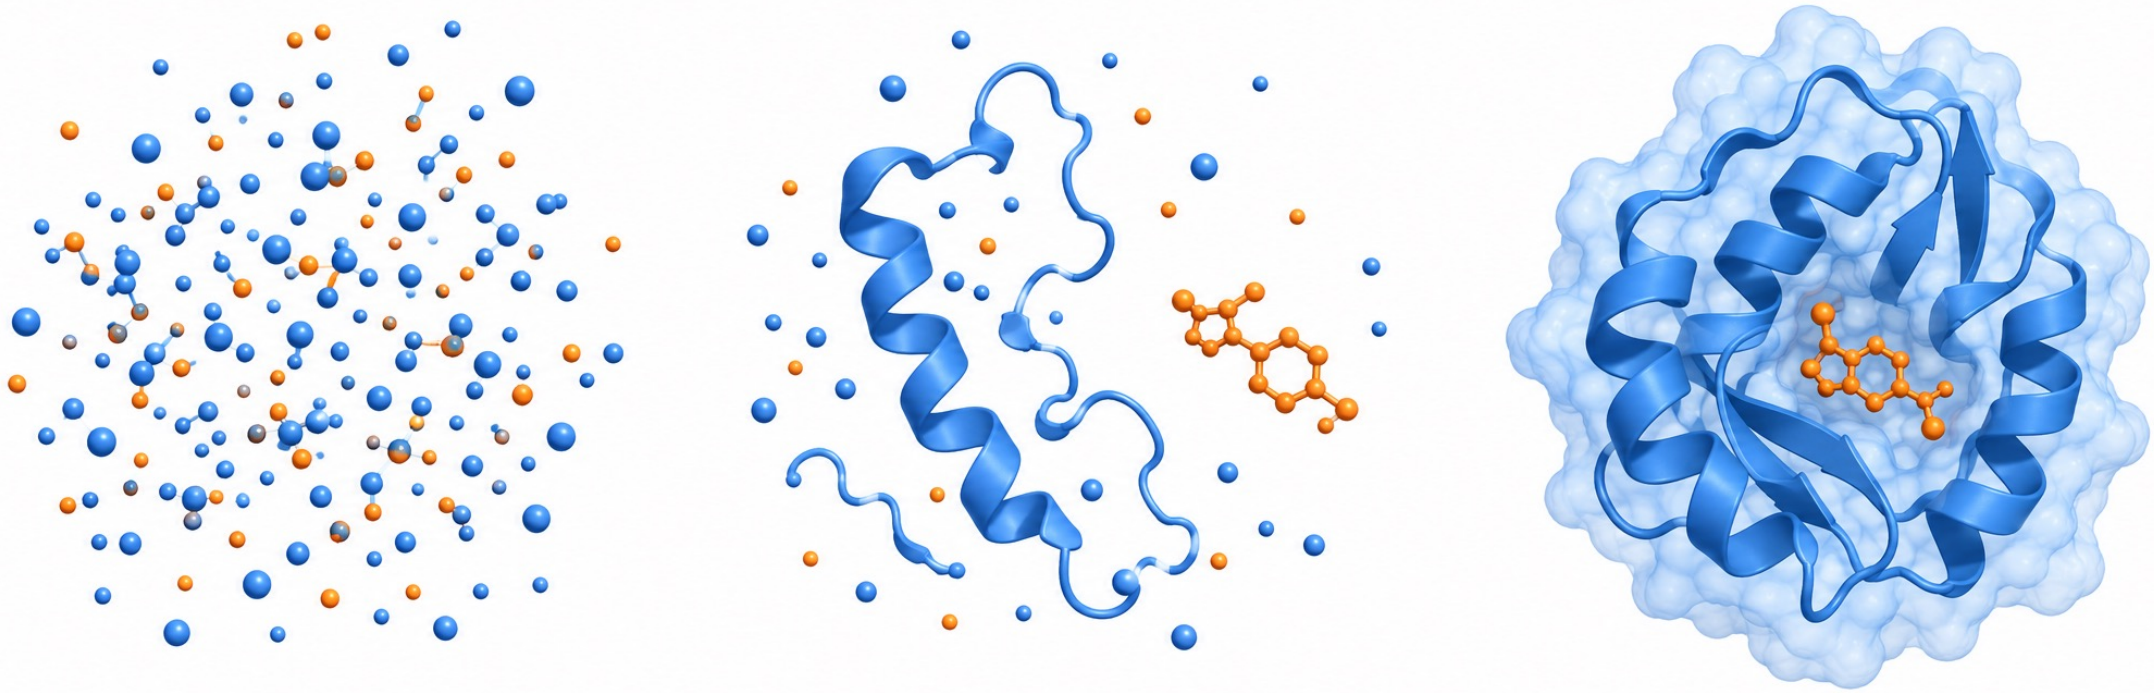
仕上げ：細部と質感



学習：既知構造にノイズを加えれば、「乱れた入力 → 元の座標」の練習材料を作れる。
生成：同じ除去器で座標を繰り返し更新する。初期ノイズを変えると別の候補も作れる。

図は例え：下描き ≠ 正規ノイズ。Boltzは原子座標を更新する。全体→細部という厳密な段階分けではない。

原子の位置を少しずつ決める

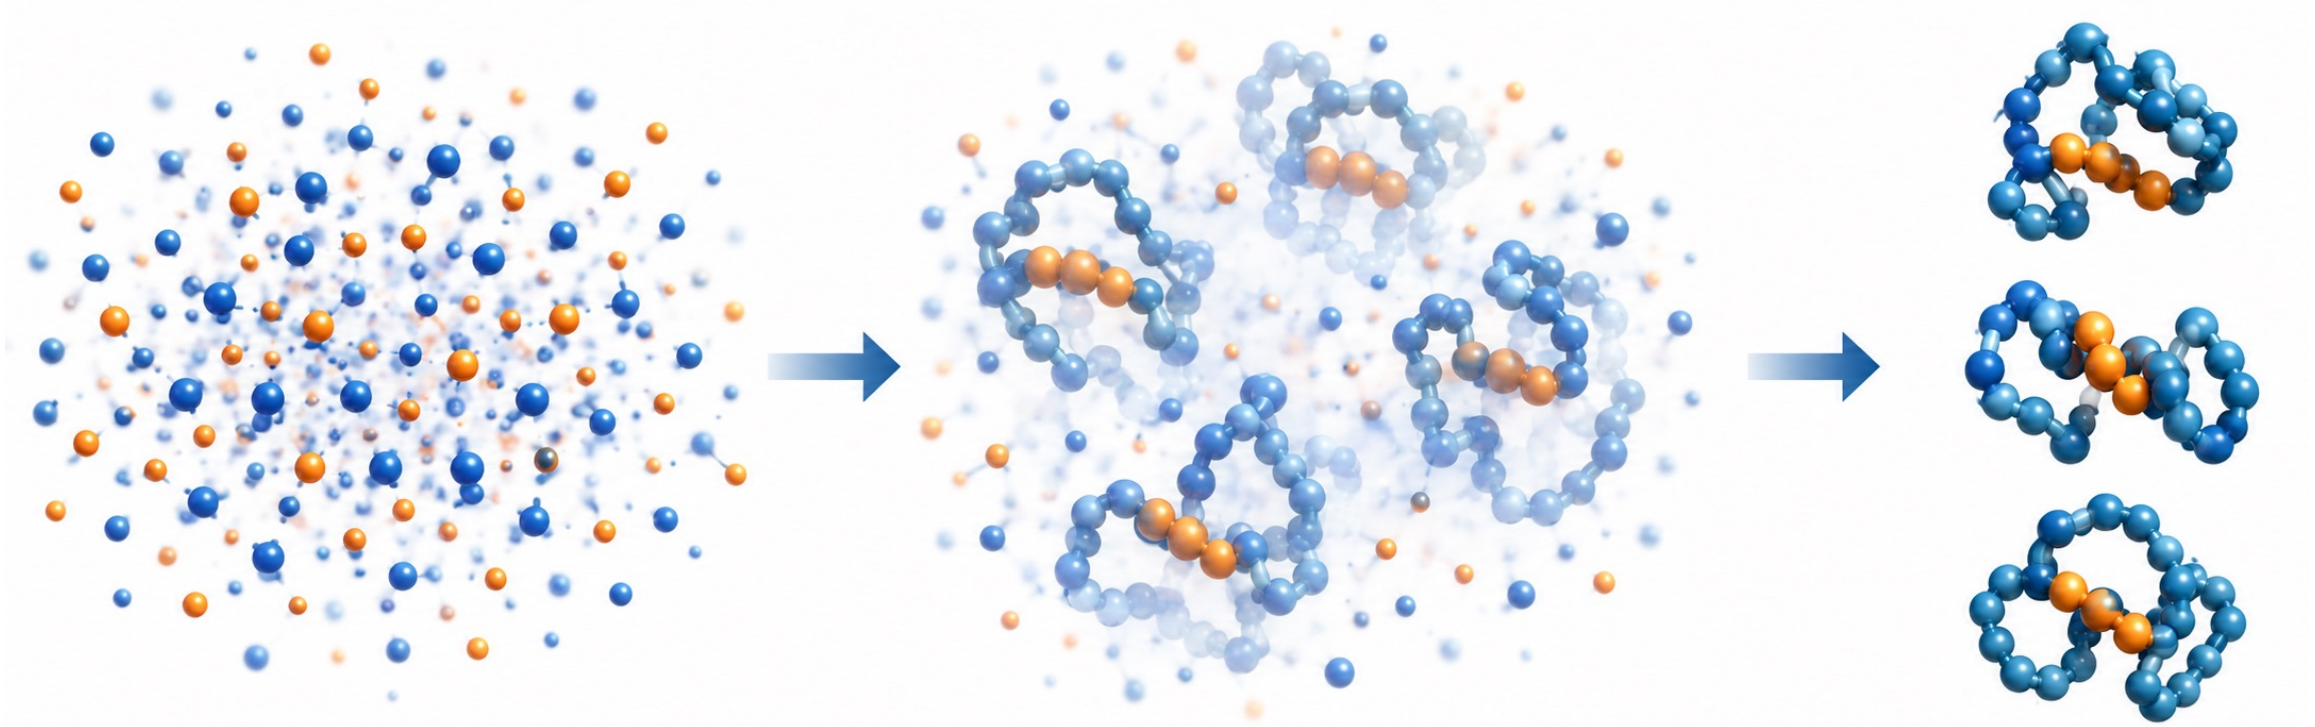


分子の情報を条件に、ノイズの多い原子座標を繰り返し更新する。
模式図：実際の原子・結合の推移や、分子動力学の時間発展を表す図ではない。

GPT Imageによる概念図。原子・結合の実計算やMDの時間発展ではない

本教材の導出・模型計算・演習

一つの平均では構造を表せない



二つの構造の平均が、実在する構造とは限らない。生成モデルは候補を分布として表す。
模式図：実在タンパク質や計算済みの平均座標ではない。Boltzの生成頻度は熱平衡の占有率を保証しない。

GPT Imageによる概念図。粒子数・結合・経路は実分子の計算結果を表さない。

Ho et al., Denoising Diffusion Probabilistic Models, NeurIPS (2020) / Karras et al., Elucidating the Design Space…, NeurIPS (2022)

条件付き分布は情報を固定する

1 条件付き分布は情報を固定する

配列や低分子の情報cを指定すると、知りたい分布はp(x｜c)です。

同じノイズ座標でも、条件が変わればもっともらしい構造は変わります。

以下の導出は記号を簡単にするため条件を省くことがあります。分子への応用では条件を戻します。

$$p(x \mid c) = \frac{p(x, c)}{p(c)}$$

$$p(x, c) = p(x \mid c)p(c)$$

式の縦棒の右側に置いた量を、いまは既知として読む習慣を付けてください。ノイズ量も予測器へ渡す重要な情報ですが、分子を指定する条件と同じ役割ではありません。後で式に現れたときにはそれぞれを分けて考えます。

2 ベイズ則で逆向きに考える

正しい構造x0からノイズ座標xtを作る確率は、こちらで定められます。

逆にxtからx0を推測するには、構造が元々どの程度現れるかという分布も必要です。

分母は、取り得るすべての元の構造について足し合わせた密度です。

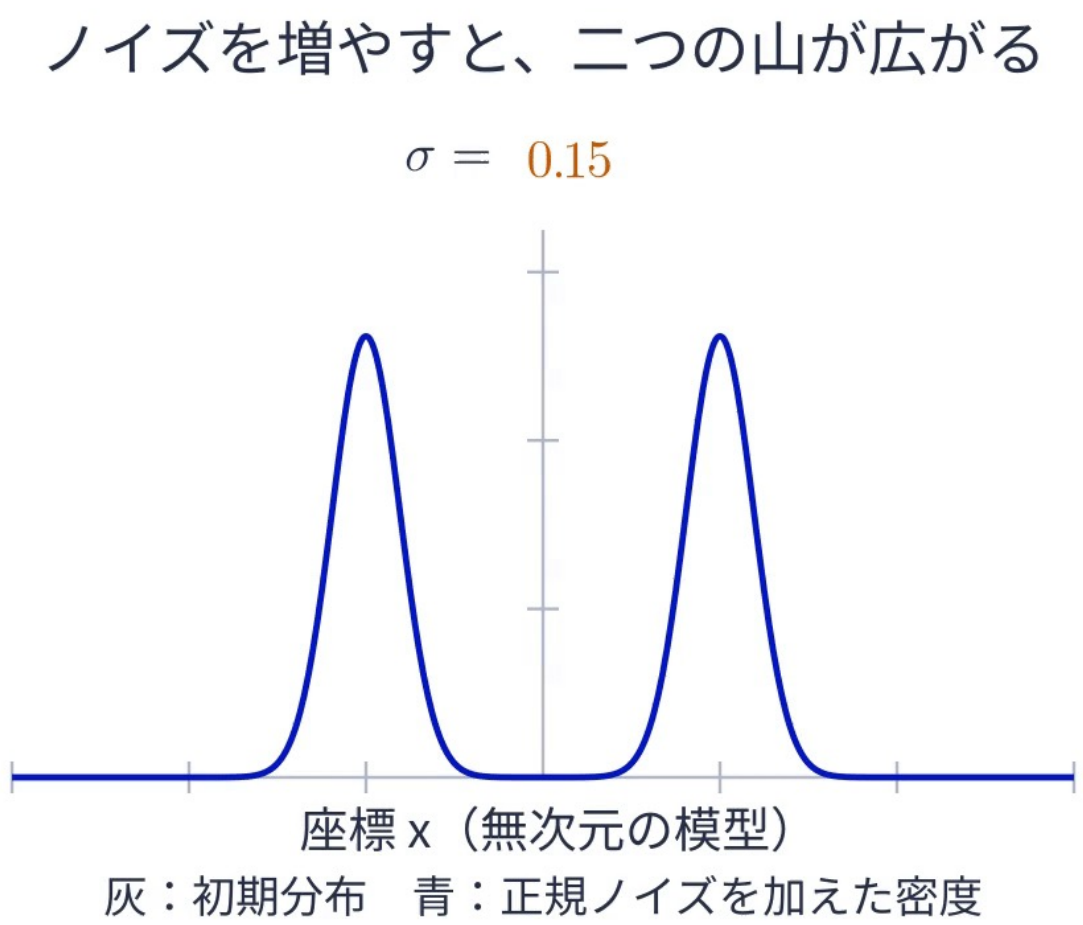
$$p(x_0 \mid x_t) = \frac{q(x_t \mid x_0)p_{\text{data}}(x_0)}{p_t(x_t)}$$

$$p_t(x_t) = \int q(x_t \mid x_0)p_{\text{data}}(x_0)\, dx_0$$

逆向きの推論が単に前向きの式を逆算するだけではない理由が、ここにあります。

Ho et al., Denoising Diffusion Probabilistic Models, NeurIPS (2020) / Passaro et al., Boltz-2 (2025), bioRxiv / Karras et al., Elucidating the Design Space···, NeurIPS (2022)

ノイズで分布の山をなだらかにする



Manim：正規混合分布にノイズを加える模型

ノイズで分布の山をなだらかにする

細かな構造を持つ分布でも、大きな正規ノイズを加えると山が広がります。

右の例では、離れた二つの山がノイズを増やすと一つの広い山に近づきます。

広い分布から始め、ノイズ量を下げながら元の分布へ戻すのが生成の考え方です。

動く青い曲線は、ノイズの標準偏差を増やしたときの確率密度です。

灰色の初期分布と比較すると、二つの山が広がる様子を追えます。

Ho et al., Denoising Diffusion Probabilistic Models, NeurIPS (2020) / Karras et al., Elucidating the Design Space…, NeurIPS (2022)

ノイズ座標とノイズ量から、元の座標を予測

教師：既知構造 y

分子の条件 c と組にする

→

ノイズ入力 x

標準正規乱数 ε を加える

→

除去器 Dθ

x・σ・c から y を予測

$$x = y + \sigma\epsilon, \quad \epsilon \sim \mathcal{N}(0, I)$$

$$\mathcal{L}(\theta) = \mathbb{E}_{y,\sigma,\epsilon}\left[\lambda(\sigma)\|D_\theta(x, \sigma, c) - y\|^2\right]$$

σ：ノイズの標準偏差。分子座標なら単位はÅ。λ：ノイズ量ごとの損失の重み。
単純な二乗誤差の最適解は条件付き平均。Boltzの損失には重ね合わせ・原子重み等も入る。

密度の対数を微分する

スコアとは、確率密度の対数を座標で微分した量です。密度が増える方向を局所的に示します。

密度の高さそのものではありません。山の頂点では勾配が0でも密度は高い場合があります。

正規分布のスコアは、平均へ戻る向きになります。

$$s(x) = \nabla_x \log p(x)$$

$$p = \mathcal{N}(\mu, \sigma^2 I) \quad \Rightarrow \quad s(x) = -\frac{x - \mu}{\sigma^2}$$

ここで微分しているのは密度ではなく、密度の対数です。対数を取ると積が和になるため、正規分布の微分などを扱いやすくなります。ある点での勾配は、その点の近くで対数密度が最も増える方向を示します。密度の絶対的な大きさと、その増え方は別の情報です。山の頂上では密度が高くても勾配はゼロになります。後でスコアを使って座標を更新するときには、この局所的な方向の情報を使います。分布全体の平均を直接指す矢印とは限りません。

Song et al., Score-Based Generative Modeling through SDEs, ICLR (2021) / Karras et al., Elucidating the Design Space···, NeurIPS (2022)

ノイズ除去から密度を知る

元データyに標準偏差σの正規ノイズを加えた座標がx。除去器Dは、xから推定するyの条件付き平均を学ぶ。

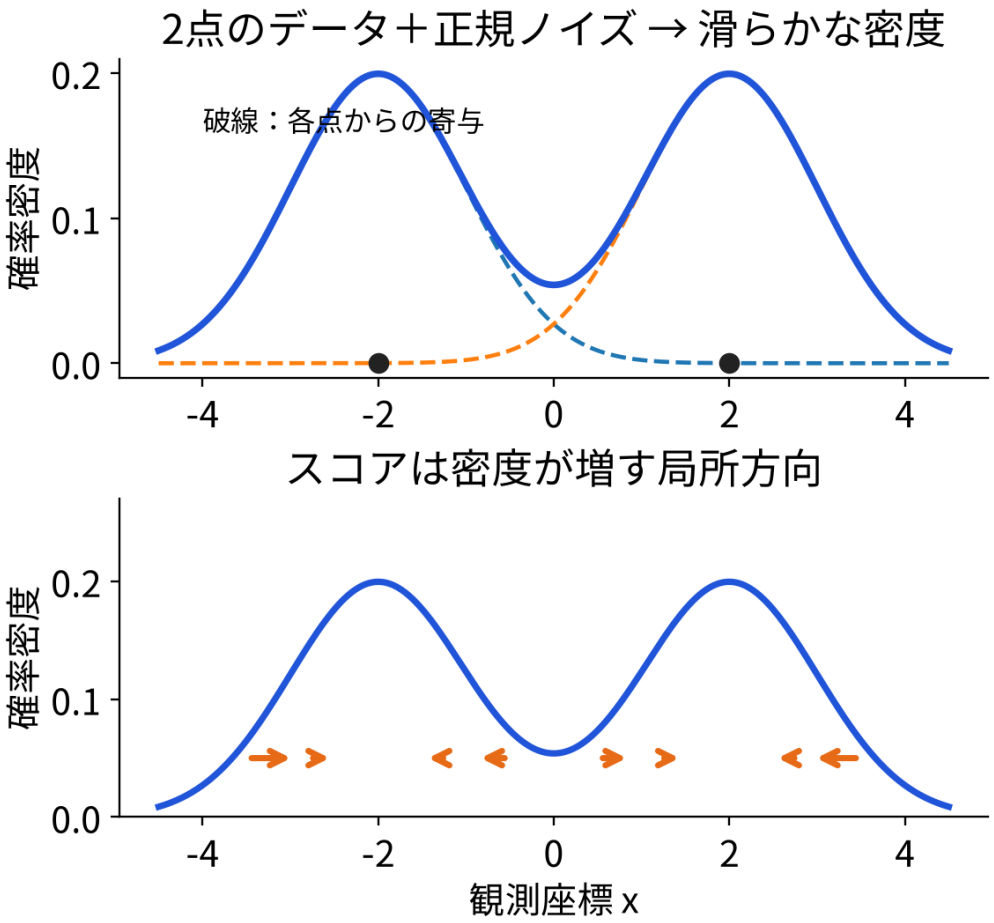
$$x = y + \sigma\epsilon, \quad \epsilon \sim \mathcal{N}(0, I)$$

$$D^*(x, \sigma) = \mathbb{E}[y \mid x]$$

$$p_\sigma(x) = \int p_{\text{data}}(y)\mathcal{N}(x; y, \sigma^2 I)\, dy$$

$$\nabla_x p_\sigma(x) = \int \frac{y - x}{\sigma^2} p_{\text{data}}(y)\mathcal{N}(x; y, \sigma^2 I)\, dy$$

元データが離散的でもσ>0なら密度は滑らかになる。微分と積分を交換できる条件の下で、正規分布の微分が$(y-x)/\sigma^2$を生む。密度で割ると、次頁のスコアとDの関係を得る。



模型：元データは−2と2の2点。橙の矢印は局所の密度増加方向。

Karras et al., Elucidating the Design Space…, NeurIPS (2022) / 本教材の導出・模型計算・演習

予測ノイズとの符号を確かめる

予測ノイズはx−Dの方向、スコアは逆のD−xの方向。σで割る回数と符号を区別する。

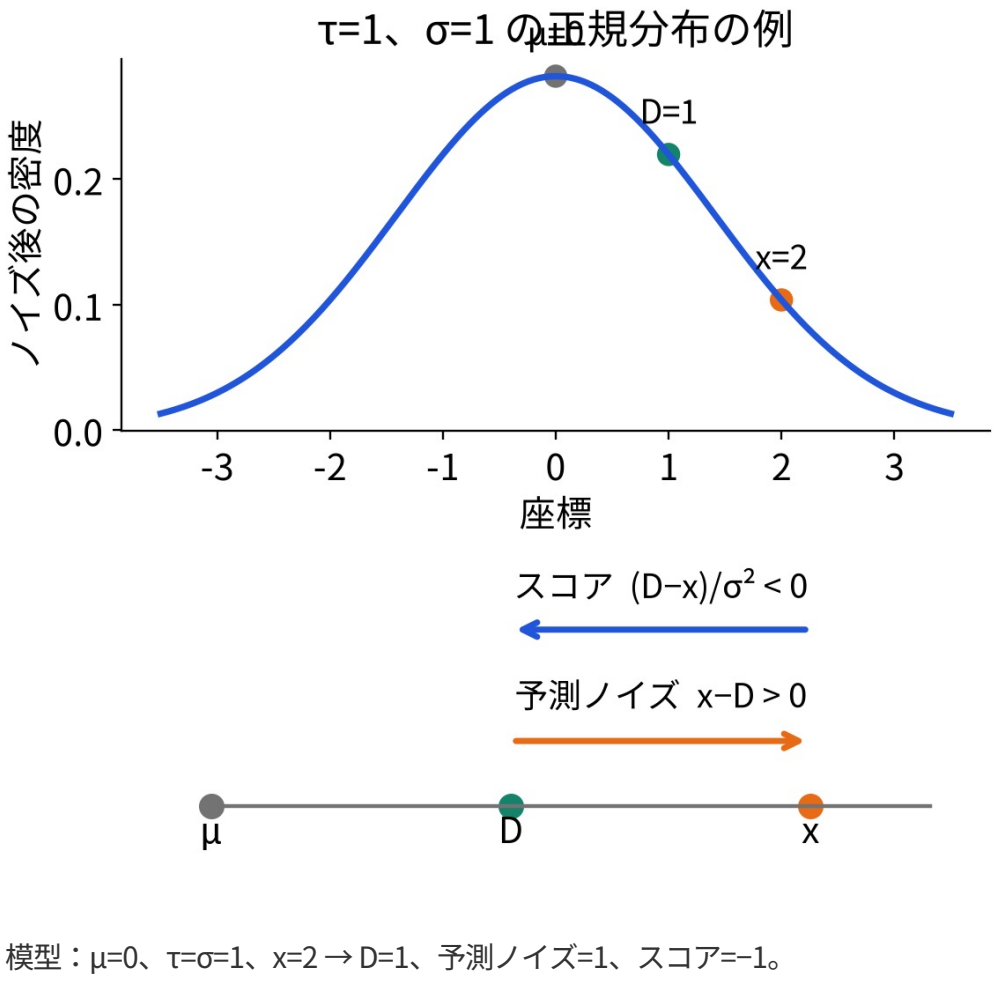
$$\hat{\epsilon} = \frac{x - D_\theta(x, \sigma)}{\sigma}$$

$$s_\theta = -\frac{\hat{\epsilon}}{\sigma}$$

$$s(x, \sigma) = -\frac{x - \mu}{\tau^2 + \sigma^2}$$

$$D(x, \sigma) = x + \sigma^2 s = \frac{\tau^2 x + \sigma^2 \mu}{\tau^2 + \sigma^2}$$

正規分布の例ではx>μならスコアは負。Dは観測xを平均μへ近づけ、σが大きいほどμの比重が増す。DDPMは信号も縮めるため、対応するノイズ尺度が異なる。



模型：μ=0、τ=σ=1、x=2 → D=1、予測ノイズ=1、スコア=−1。

Karras et al., Elucidating the Design Space…, NeurIPS (2022) / Ho et al., Denoising Diffusion Probabilistic Models, NeurIPS (2020) / 本教材の導出・模型計算・演習

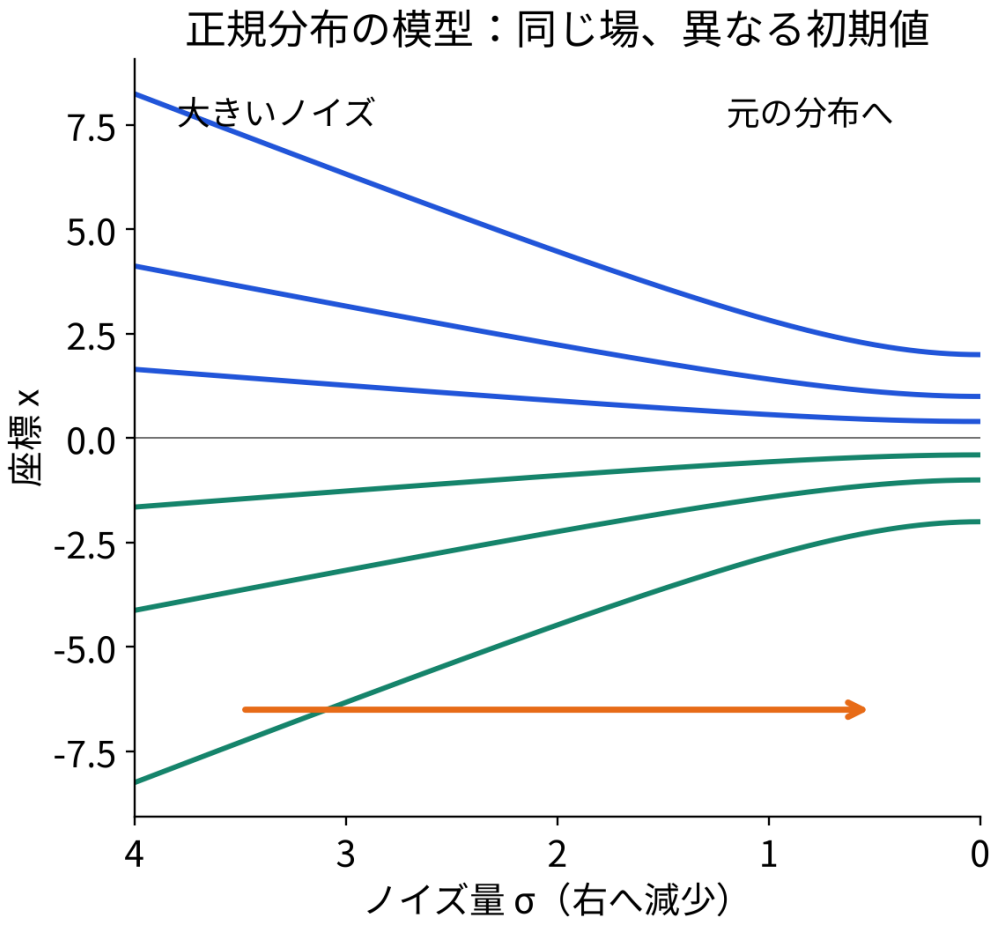
ノイズ量を下げながら、座標を更新する

除去器の予測からスコアを得て、ノイズ量σを大きい値から0へ下げる。原子座標全体を一つの長いベクトルと考える。

$$s(x,\sigma) = \nabla_x \log p_\sigma(x) \simeq \frac{D_\theta(x,\sigma,c) - x}{\sigma^2}$$

$$\frac{dx}{d\sigma} = -\sigma s(x,\sigma) \simeq \frac{x - D_\theta(x,\sigma,c)}{\sigma}$$

Δσ<0なので、更新はDへ近づく向きになる。異なる初期値は異なる生成経路を与える。式は正確なスコアと連続積分での関係。右は正規分布の解析例であり、すべての分布が原点へ縮むという意味ではない。



模型：元の分散は1。$x(\sigma)=z\sqrt{(1+\sigma^2)}$。有限刻み・予測器の誤差は別に残る。

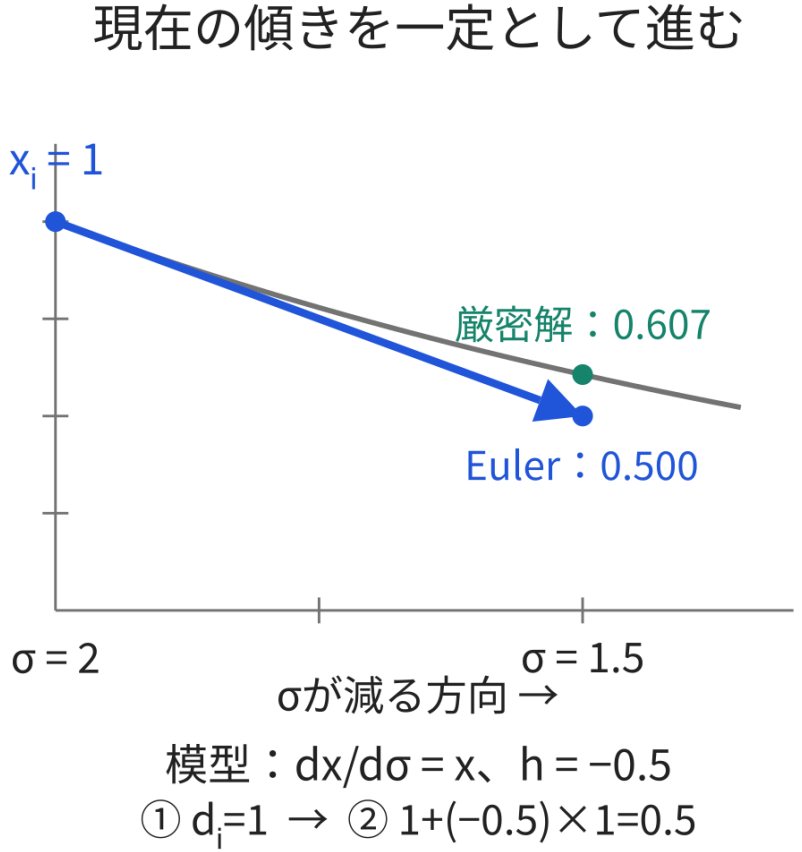
学習済みの予測器と積分法を分ける

Dは元座標を予測する学習済み関数。サンプラーはDを呼ぶノイズ量・回数と座標の更新法を決める。

$$d_i = \frac{x_i - D(x_i, \sigma_i)}{\sigma_i}$$

$$x_{i+1} = x_i + h_i d_i, \quad h_i = \sigma_{i+1} - \sigma_i$$

Euler法は現在の傾きを一段の間一定とみなす。同じDでも刻み方を変えられるが、品質と生成分布への影響は検証する。σ=0で傾きを再評価しない。刻みを細かくしても予測器の誤差は残る。



右は積分法を説明する模型。灰線は厳密解、青は現在の傾きだけで進む近似。

Karras et al., Elucidating the Design Space…, NeurIPS (2022)

Heun法は終点の傾きも見る

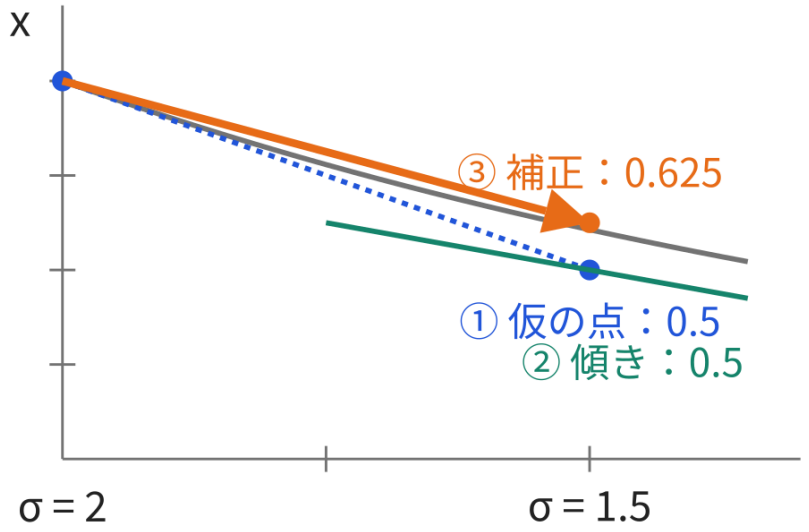
①Euler法で仮の終点を作る。②そこで傾きを再計算する。③始点と仮の終点の傾きを平均し、始点から更新し直す。

$$\tilde{x} = x_i + h_i d_i, \quad \tilde{d} = \frac{\tilde{x} - D(\tilde{x}, \sigma_{i+1})}{\sigma_{i+1}}$$

$$x_{i+1} = x_i + \frac{h_i}{2}(d_i + \tilde{d})$$

滑らかな問題では二次精度だが、通常Dの呼出しは一段に2回。仮の終点は確定した座標ではない。最後がσ=0なら別扱いが必要。Boltzの標準更新にこの2回目の予測があるわけではない。

仮の終点の傾きで補正する



平均の傾き：(1+0.5)/2 = 0.75

更新：1+(−0.5)×0.75 = 0.625

同じ模型の厳密解は約0.607

同じ模型でEulerは0.500、Heunは0.625、厳密解は約0.607。計算費用も比較する。

Karras et al., Elucidating the Design Space…, NeurIPS (2022)

小さいノイズ側へ刻みを集める

σのべき根を等間隔に置き、べき乗して元の尺度へ戻す。小さいノイズ側の刻みを細かくする。

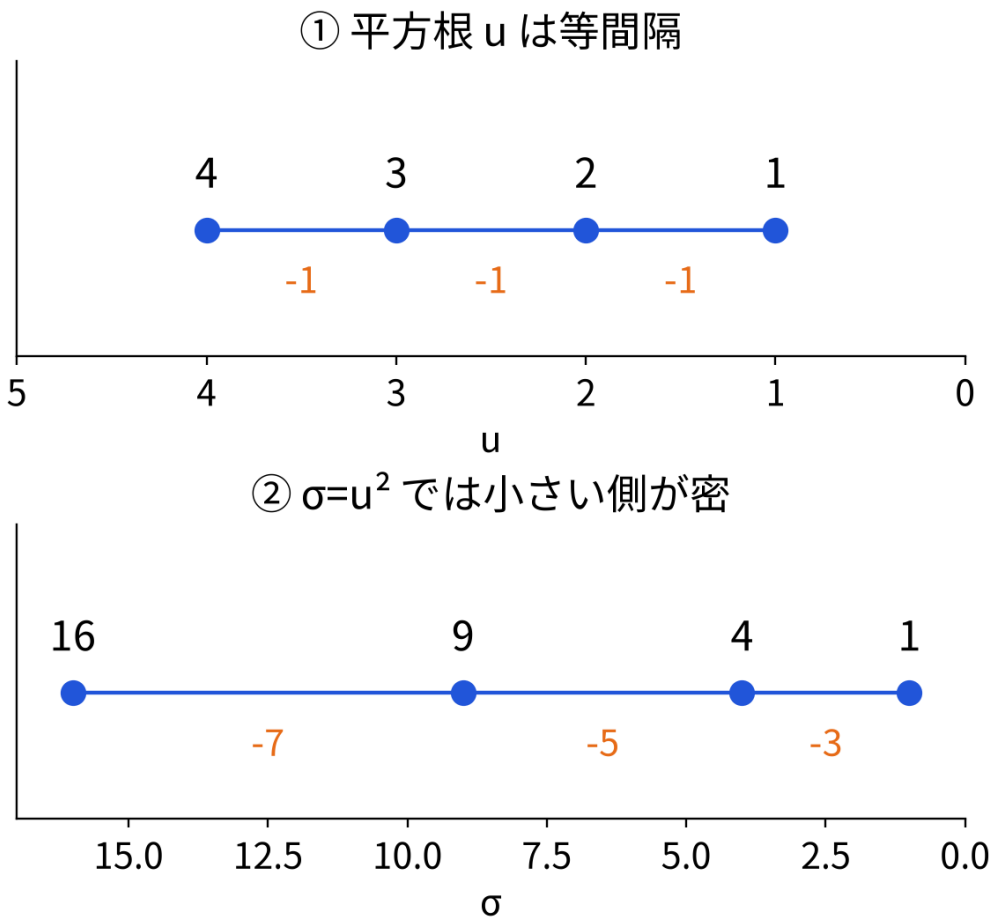
$$\sigma_i = \left(\sigma_{\max}^{1/\rho} + \frac{i}{N-1}(\sigma_{\min}^{1/\rho} - \sigma_{\max}^{1/\rho})\right)^{\rho}$$

$$u_i = 4 + \frac{i}{3}(1-4), \quad i = 0,1,2,3$$

$$\sigma_i = u_i^2 : \quad 16, 9, 4, 1$$

$$\Delta\sigma_i : \quad -7, -5, -3$$

模型ではσmax=16、σmin=1、ρ=2、N=4。uは4,3,2,1、σは16,9,4,1となる。EDMではρ=7の例があり、Boltzはさらにデータ尺度を掛ける。



図の横軸はどちらも線形。左から右へσが減り、差は−7、−5、−3。

ノイズを一時的に増やす更新

ノイズを追加する場合は、新旧の分散の差だけを足す。その後は増やしたσを除去器へ渡す。

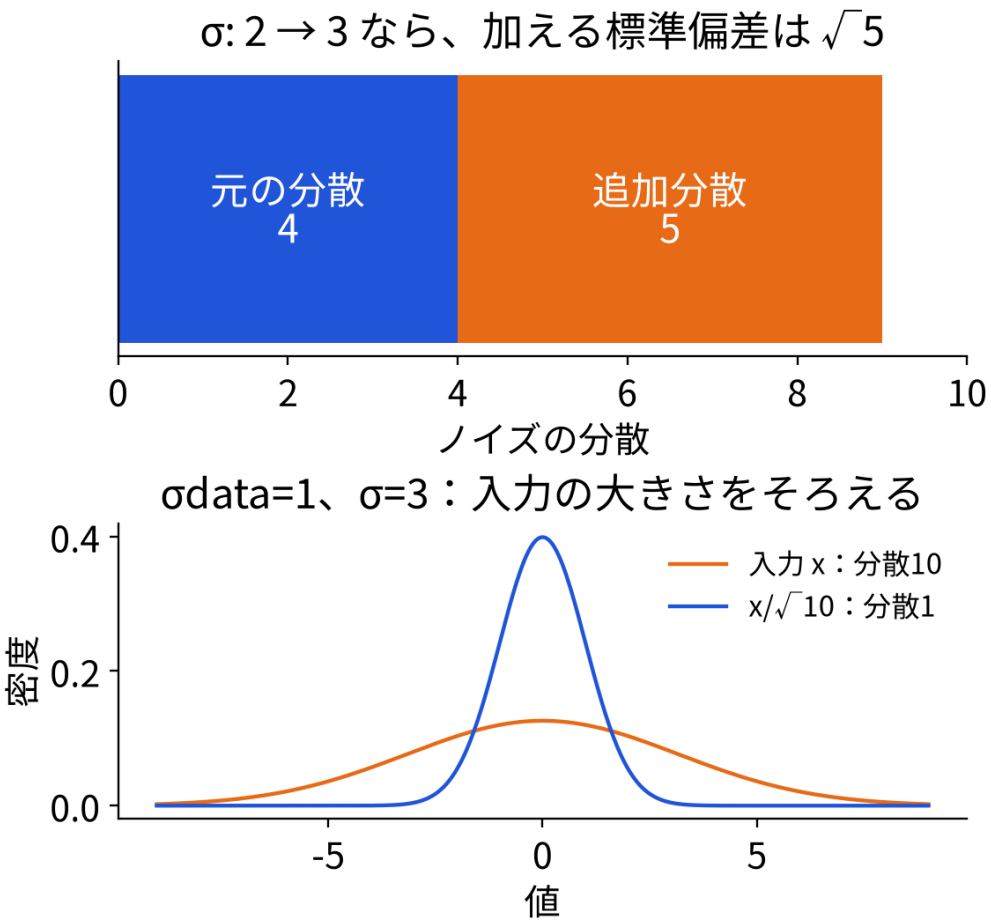
$$\hat{\sigma}_i = (1+\gamma_i)\sigma_i$$

$$\hat{x}_i = x_i + \sqrt{\hat{\sigma}_i^2 - \sigma_i^2}\,\epsilon_i$$

$$c_{\text{in}}(\sigma) = \frac{1}{\sqrt{\sigma^2 + \sigma_{\text{data}}^2}}$$

$$\text{Var}(c_{\text{in}} x) \simeq 1$$

入力xはデータと独立ノイズの和。分散σdata²+σ²で正規化し、ネットワークへ渡す尺度をそろえる。出力を元の座標単位へ戻す係数も必要。



上：既存分散4に追加分散5で計9。下：分散10の入力を√10で割って分散1へ。

Karras et al., Elucidating the Design Space…, NeurIPS (2022)

残差を単位分散へそろえる

入力を残す経路と、ネットワークFが補正する経路を足して、元座標の予測Dを作る。

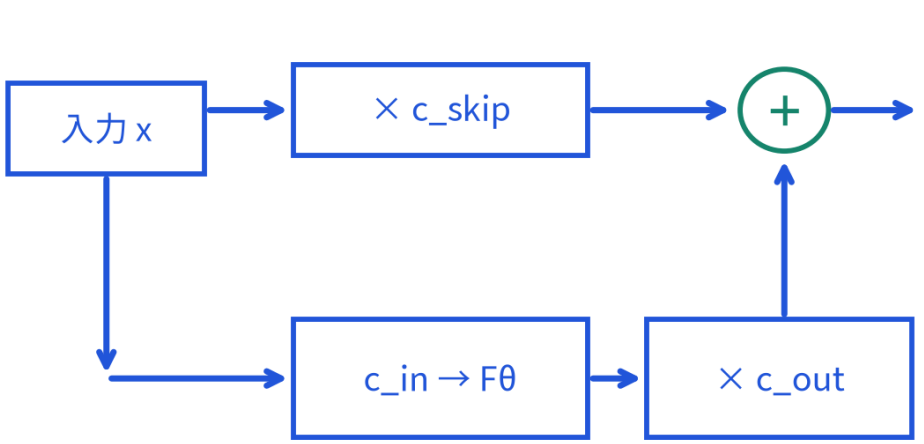
$$\mathrm{Var}(y - c_{\mathrm{skip}}x) = \frac{\sigma^2\sigma_{\mathrm{data}}^2}{\sigma^2 + \sigma_{\mathrm{data}}^2}$$

$$c_{\mathrm{out}} = \frac{\sigma\sigma_{\mathrm{data}}}{\sqrt{\sigma^2 + \sigma_{\mathrm{data}}^2}} \qquad F_{\mathrm{target}} = \frac{y - c_{\mathrm{skip}}x}{c_{\mathrm{out}}}$$

$$D_\theta(x,\sigma) = c_{\mathrm{skip}}x + c_{\mathrm{out}}F_\theta(c_{\mathrm{in}}x, c_{\mathrm{noise}})$$

$$c_{\mathrm{skip}} = \frac{\sigma_{\mathrm{data}}^2}{\sigma^2 + \sigma_{\mathrm{data}}^2}$$

Fの教師は残差をc_outで割った量。分散を約1にそろえ、出力時に座標の尺度へ戻す。低ノイズではc_skip→1となり入力を多く残す。Fの出力そのものはDではない。



教師の残差 (y − c_skip x) ÷ c_out
→ 分散が約1になる尺度で F を学ぶ

低ノイズ：c_skip → 1、入力を多く残す

右：青は入力を残す経路、下は学習する補正の経路。最後に両者を加える。

Karras et al., Elucidating the Design Space…, NeurIPS (2022) / 本教材の導出・模型計算・演習

出力尺度と損失の重み

c_outでFの教師の分散をそろえる。λ=1/c_out²を掛けると、F側の誤差の尺度をそろえられる。

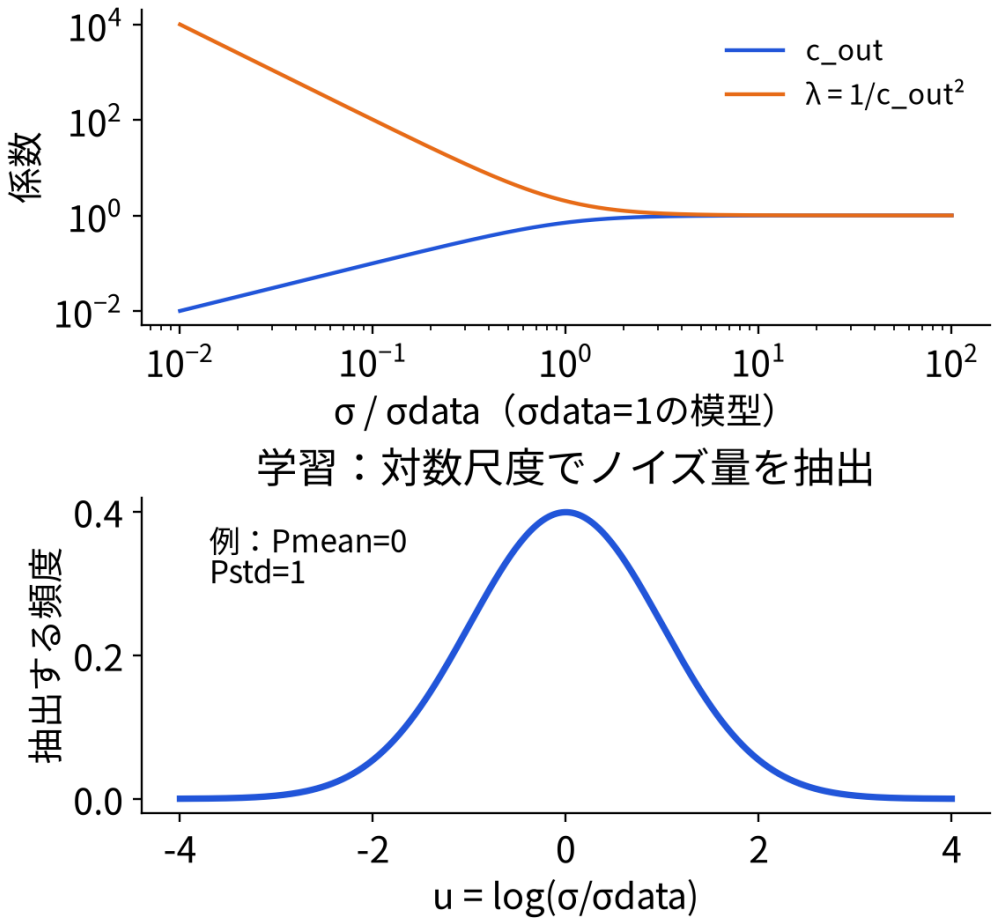
$$c_{\text{out}} = \frac{\sigma\sigma_{\text{data}}}{\sqrt{\sigma^2 + \sigma_{\text{data}}^2}}$$

$$\lambda(\sigma) = c_{\text{out}}^{-2} = \frac{\sigma^2 + \sigma_{\text{data}}^2}{(\sigma\sigma_{\text{data}})^2}$$

$$\log(\sigma/\sigma_{\text{data}}) \sim \mathcal{N}(P_{\text{mean}}, P_{\text{std}}^2)$$

$$c_{\text{noise}} = \frac{1}{4}\log(\sigma/\sigma_{\text{data}})$$

学習は対数ノイズ量を正規分布から抽出する。Boltzではσ/σdataの比を使う。学習時の抽出分布と、生成時の有限のノイズ列は別の設定。分子損失には原子重み・マスク・重ね合わせも加わる。

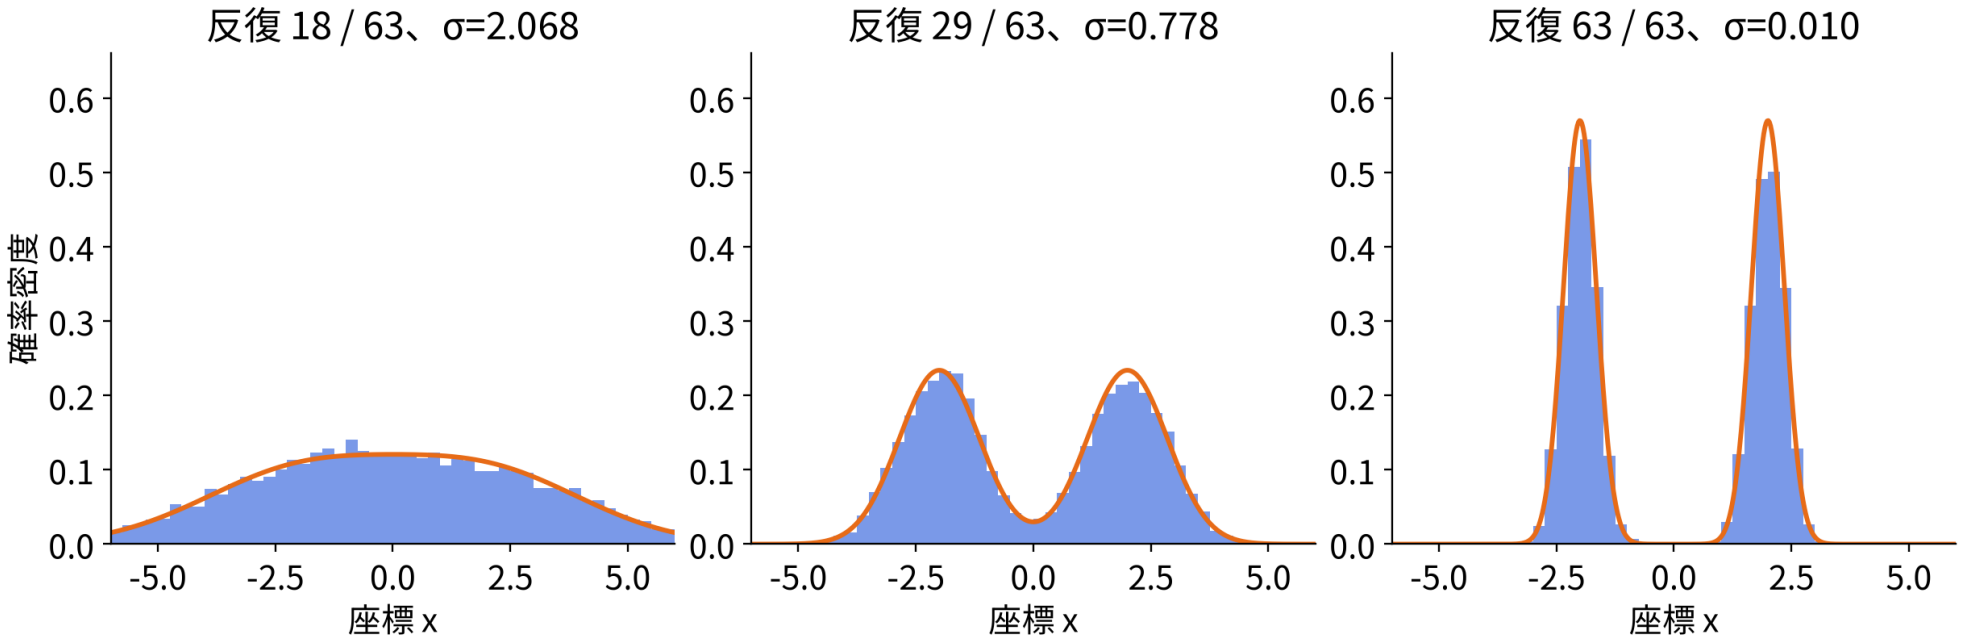


図はσdata=1の模型。下の分布は説明用の設定で、Boltzの既定値ではない。

Karras et al., Elucidating the Design Space…, NeurIPS (2022) / Boltz source 2.2.1・b1ebfc4・参照 2026-10-09

模型でノイズから分布を生成する

解析的なノイズ除去器とHeun法による63段の計算。12,000標本が、ノイズ量を下げるにつれて二つの山へ集まる。



青は標本のヒストグラム、橙は各σでの正確な密度。標本数が有限なため揺らぎがあり、曲線との差をすべて積分誤差と考えない。

保存済みの模型計算から3段階を抽出。Boltzの原子座標の予測結果ではない。

本教材の導出・模型計算・演習

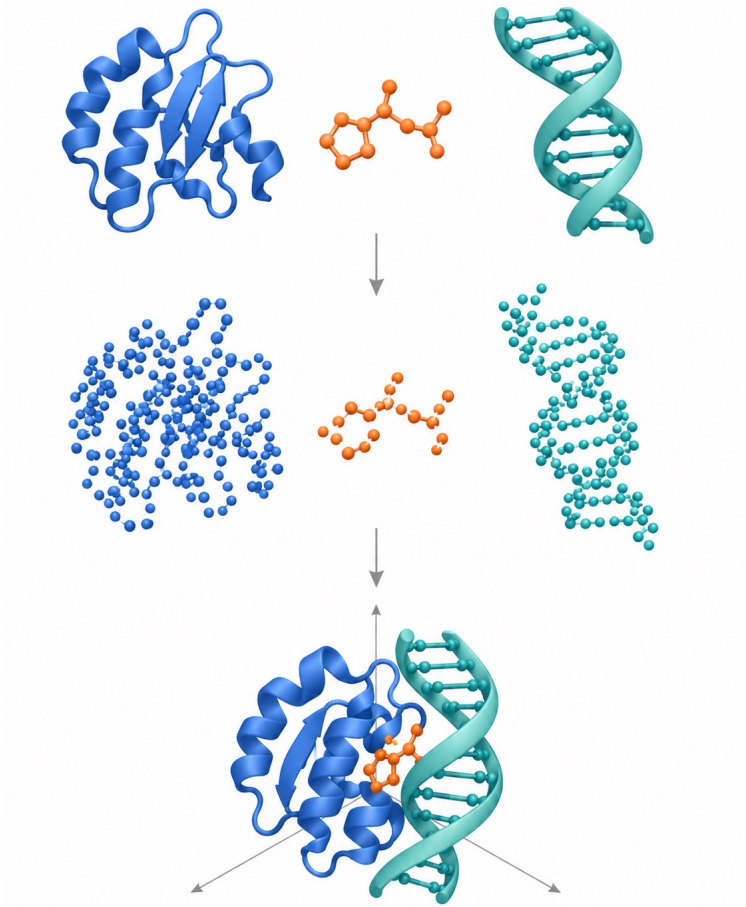
複合体全体の配置を、一緒に予測する

タンパク質・核酸・低分子を原子で表し、全分子を合わせたM×3個の座標を生成する。分子間の位置と向きも出力の一部になる。

$$X \in \mathbb{R}^{M\times 3}, \quad D_\theta(X, \sigma; c)$$

$$X_\sigma = X_0 + \sigma\epsilon$$

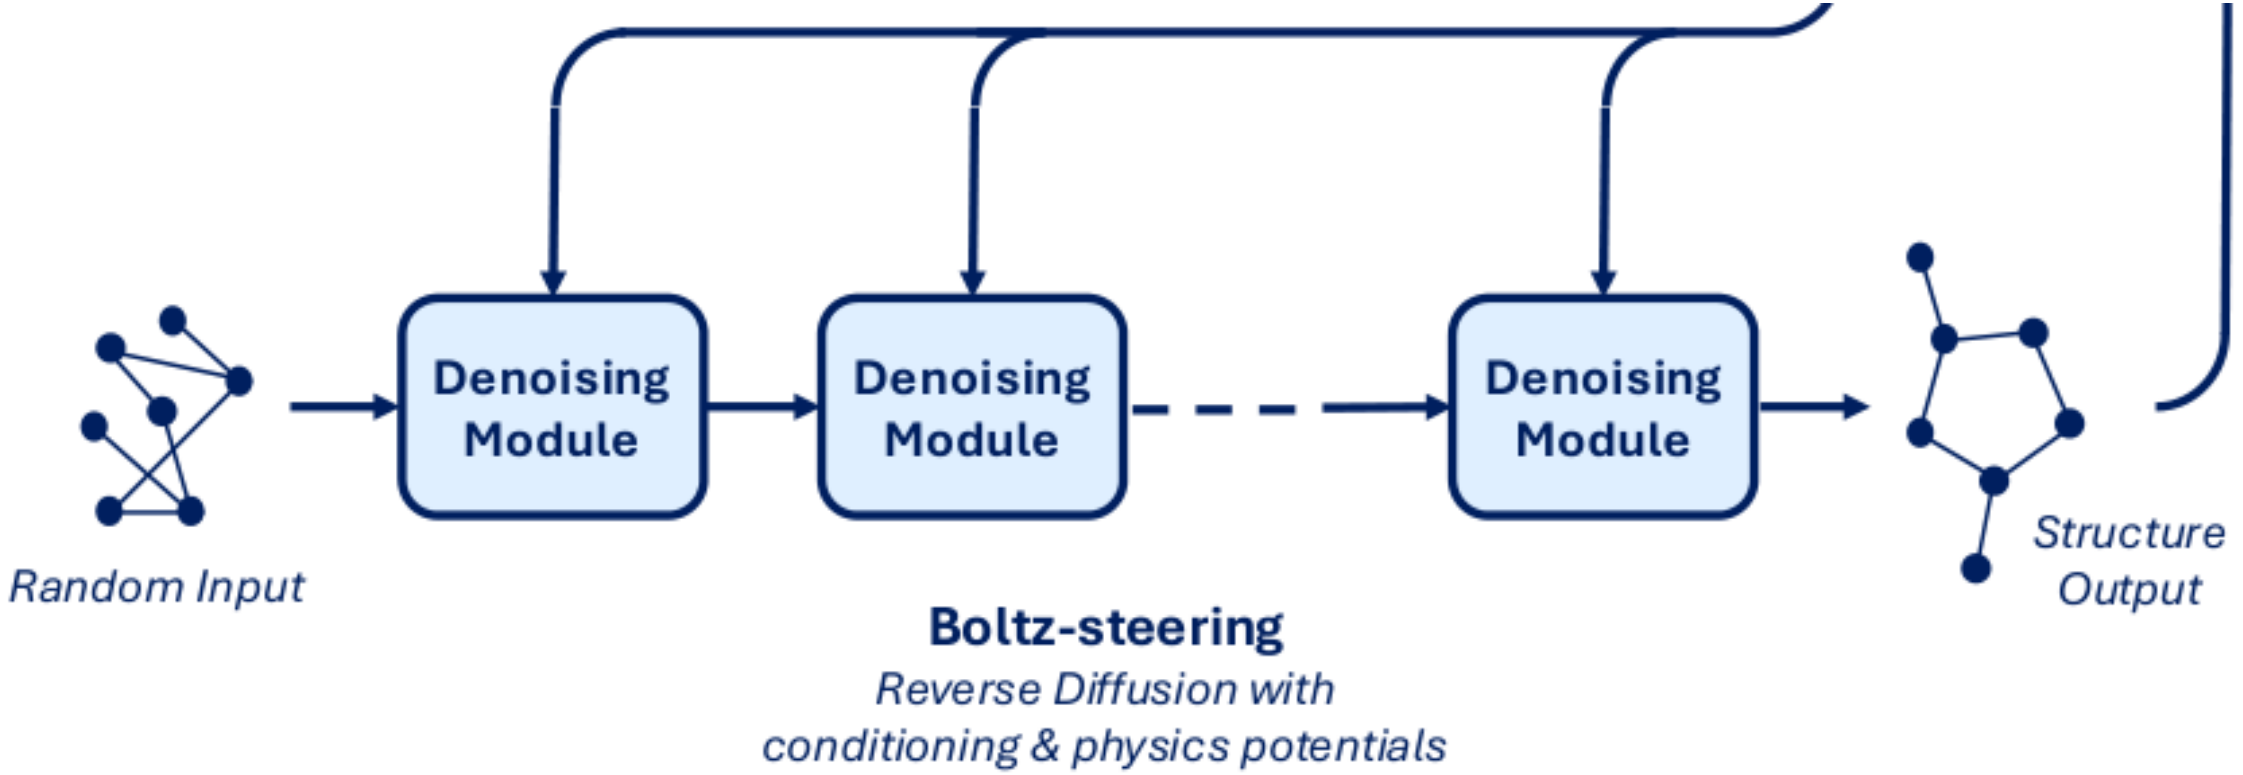
複合体予測を支えるのは、①多様な分子の共通表現、②分子をまたぐ情報交換、③既知の複合体を含む構造データからの学習。学習では複合体の座標にノイズを加え、条件cから元の配置を予測する。拡散は段階的に座標を生成する方法であり、結合位置の知識は学習済みネットワークにある。



模式図：多様な分子 → 全原子 → 共通の座標系の複合体。実測・予測構造ではない。

Passaro et al., Boltz-2 (2025), bioRxiv / Boltz source 2.2.1・b1ebfc4・参照 2026-10-09

原著の図で座標生成部を拡大する



上から来る線は共通の条件 c。各段で変わるのは座標 X とノイズ量 σ。
同じ重み θ の除去器を反復する。各段で別モデルを学習するわけではない。

Passaro et al., Boltz-2 (2025)・Fig. 2 座標生成部より。パネルを切り出し

Passaro et al., Boltz-2 (2025), bioRxiv

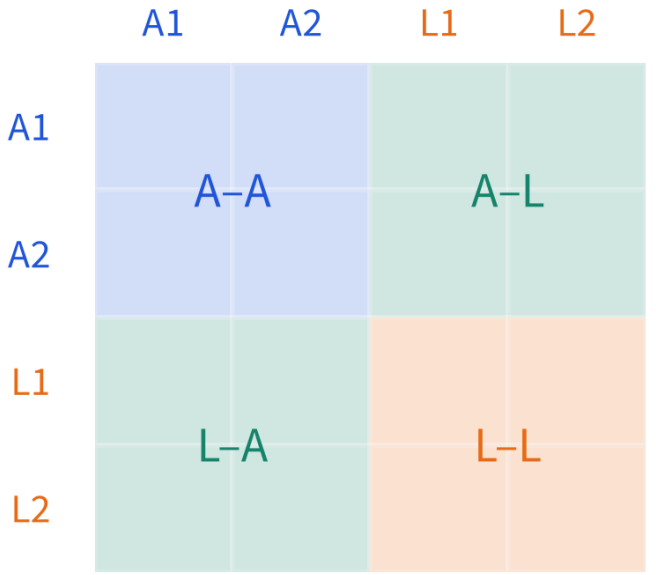
分子をまたぐペアから、相手の情報を受け取る

原子の特徴を所属トークンへ集める。タンパク質Aと低分子Lのトークンを一緒に扱い、分子をまたぐペアの表現も用いる。

図の緑の領域がA–LとL–Aの組。ペア表現は関係を表す特徴ベクトルで、距離や結合確率そのものではない。trunkで推論したこの情報が、座標生成のトークン間注意にも渡る。原子側は局所的に計算しても、トークン側では分子の境界を越えて情報を伝えられる。

原子の特徴をトークンへ集約

タンパク質 A ＋ 低分子 L



緑：分子をまたぐペア

全体の注意計算へ、相手との関係を渡す

A1,A2：タンパク質の残基。L1,L2：低分子の原子。色はペアの種類で、数値の大小ではない。

Wohlwend et al., Boltz-1 (2024/2025), bioRxiv / Boltz source 2.2.1・b1ebfc4・参照 2026-10-09

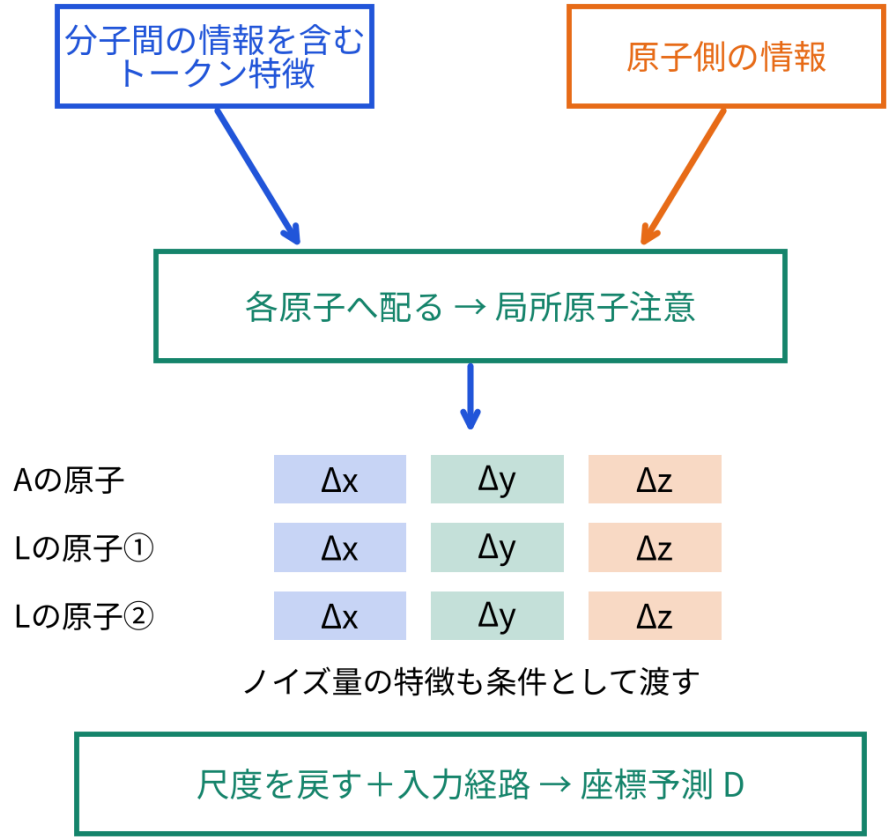
相手の情報を使って、全原子の座標を更新する

分子間の情報を含むトークン特徴を各原子へ戻し、原子側の情報と結合する。全分子の座標予測Dを同じ空間内で出す。

$$c_{\text{noise}} = \frac{1}{4}\log(\sigma/\sigma_{\text{data}})$$

$$\phi(t) = (\sin(\omega_k t), \cos(\omega_k t))_k$$

低分子の原子の更新も、タンパク質側の情報に依存できる。全原子をまとめた座標を繰り返し更新することで、分子内部の形と分子間の位置・向きを同時に予測する。σの特徴でノイズ量を知らせ、出力の尺度を戻して入力経路と合成する。構造を生成できても、実際の結合や結合の強さを証明したことにはならない。



AとLの各原子へ三成分の補正を出す。原子ごとに出力しても、各分子を独立に予測しているわけではない。

Boltz source 2.2.1・b1ebfc4・参照 2026-10-09 / Karras et al., Elucidating the Design Space…, NeurIPS (2022)

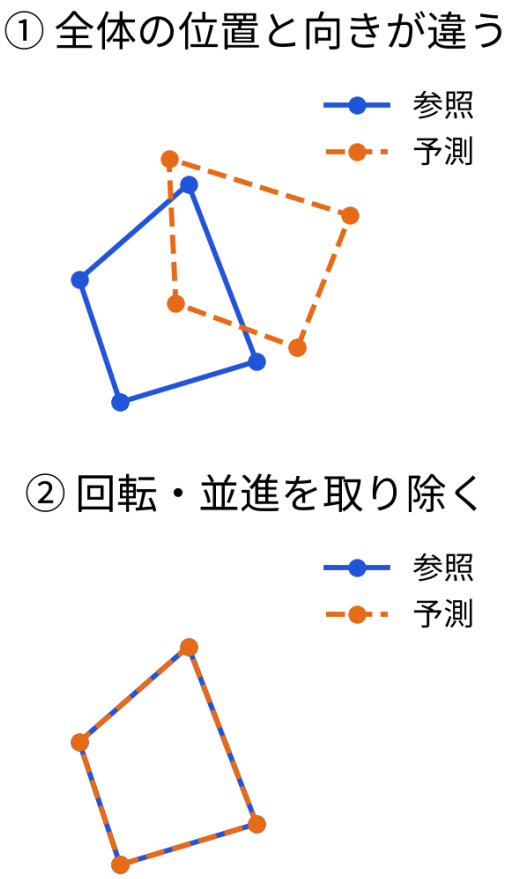
回転を変えて学習する

中心化・ランダムな回転と並進で、学習が一つの向きへ偏ることを防ぐ。データ拡張と厳密な回転同変性は異なる。

$$\min_{R,t} \sum_i w_i m_i \|\hat{x}_i - (Rx_i + t)\|^2$$

$$R^T R = I, \quad \det R = 1$$

損失では正解座標を予測へ剛体重ね合わせし、全体の位置と向きを除いて形の差を測る。Rは行列式が正の正規直交行列。鏡像へ反転して誤差を減らす操作は許さない。重みと欠損マスクは対応する原子にも影響する。



同じ4点の形を回転・並進した模型。下では完全に重なるが、形の違いがあれば残差が残る。

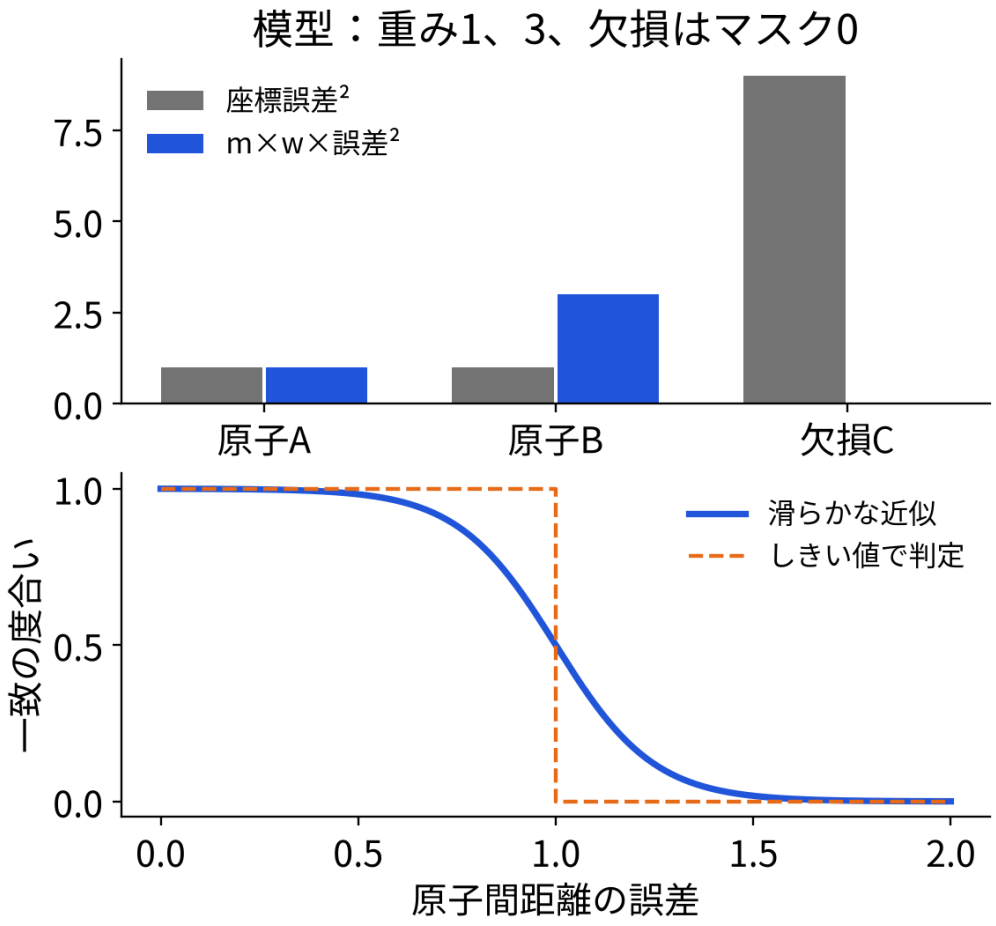
Boltz source 2.2.1・b1ebfc4・参照 2026-10-09 / Abramson et al., Nature 630, 493–500 (2024)

原子の種類とマスクで損失を重み付け

欠損座標はマスクm=0で除く。原子の種類に応じた重みwで、座標誤差の寄与を調整する。

$$L_{\text{coord}} = \mathbb{E}_{\sigma}\left[\lambda(\sigma)\frac{\sum_i m_i w_i \|\hat{x}_i - x_i^{\text{aligned}}\|^2}{3\sum_i m_i w_i + \varepsilon}\right]$$

有効重みの合計と3成分で平均し、ノイズ量の重みλを掛ける。局所距離の誤差には滑らかなlDDT型損失も使う。距離は回転・並進に依存しない一方、鏡像を区別できない。立体化学も別に確認する。



上の重み1,3,0と下の滑らかな曲線は説明用の模型で、Boltzの実装値そのものではない。

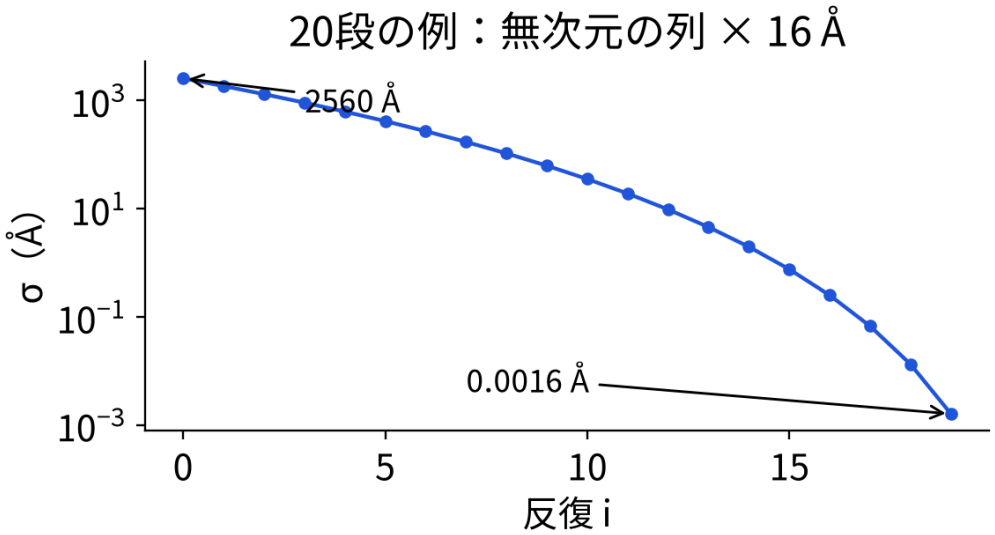
Boltz source 2.2.1・b1ebfc4・参照 2026-10-09 / Wohlwend et al., Boltz-1 (2024/2025), bioRxiv

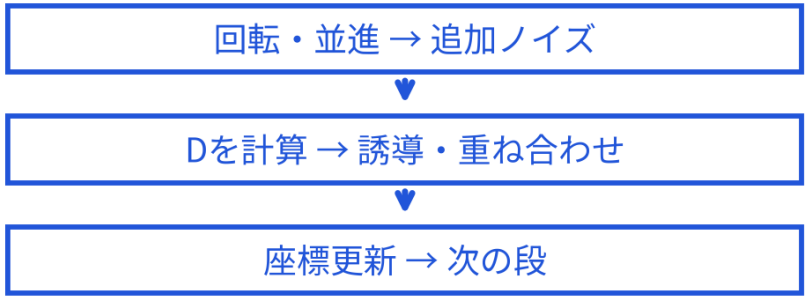
Boltzのノイズ列は尺度を掛ける

Boltz-2のCLI設定ではσdata=16。無次元のノイズ列に掛け、原子座標と同じÅの単位へ変換する。

$$\sigma_i^{\text{actual}} = \sigma_{\text{data}} \left[s_{\max}^{1/\rho} + \frac{i}{N-1}\left(s_{\min}^{1/\rho} - s_{\max}^{1/\rho}\right) \right]^{\rho}$$

引数160は2560 Å、0.0001は0.0016 Åとなり、末尾に0を追加する。クラス既定値とCLI設定を区別する。各段では回転・並進→追加ノイズ→D→有効なら誘導→重ね合わせ→更新の順を追う。





右上：ρ=7、20段の例。対数軸に0は描けないため、最後に追加する0は表示していない。

Boltz source 2.2.1・b1ebfc4・参照 2026-10-09

Boltzの更新はEuler型に尺度を加える

X̃は追加ノイズと必要な重ね合わせを経た座標。aはstep_scaleで、更新量の大きさを変える。

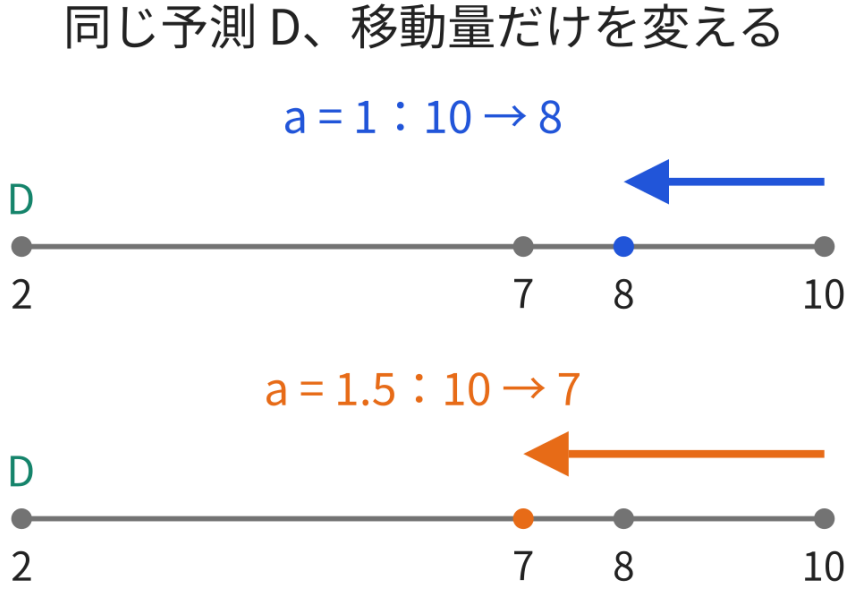
$$X_{i+1} = \tilde{X}_i + a(\sigma_{i+1} - \hat{\sigma}_i)\frac{\tilde{X}_i - D_\theta(\tilde{X}_i, \hat{\sigma}_i; c)}{\hat{\sigma}_i}$$

$$d = (10 - 2)/4 = 2$$

$$x_{\text{next}} = 10 + (3 - 4)\,2 = 8$$

$$a = 1.5 \quad \Rightarrow \quad x_{\text{next}} = 7$$

模型は現在値10、予測D=2、σ̂=4、次のσ=3。a=1なら8、a=1.5なら7へ進む。aを変えることと反復数を増やすことは同じではない。Boltz標準更新はHeunの2回目の予測を行わない。



傾き (10−2)/4 = 2

ノイズ量の差：3−4 = −1

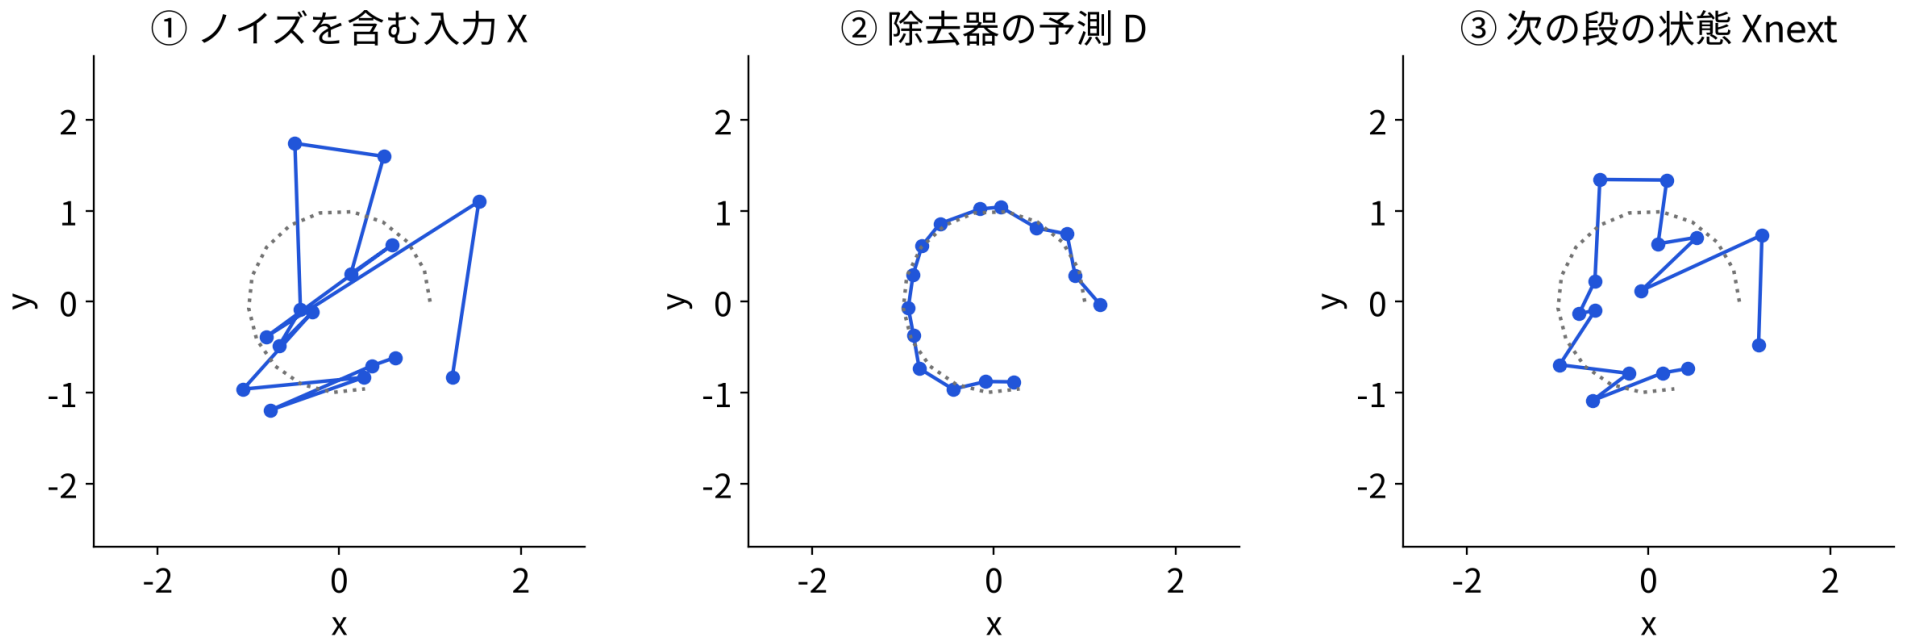
模型の一成分。回転・誘導は省略。

右：同じ出発点とDから、aだけを変えて比較。模型では誘導・重ね合わせを省いている。

Boltz source 2.2.1・b1ebfc4・参照 2026-10-09 / Karras et al., Elucidating the Design Space…, NeurIPS (2022) / 本教材の導出・模型計算・演習

途中座標を保存すると何が見えるか

同じ反復でも、①ノイズを含む入力、②除去器の予測、③次の段へ渡す状態は異なる。保存する量の名前を明確にする。



実計算は毎段回転も加わるため、共通基準へ重ね合わせて比較する。途中の大ノイズ状態は実在構造ではない。保存で乱数を余分に引いたり配列を書き換えたりしない。複数の生成構造の割合は平衡確率を保証せず、RMSF・接触・状態割合を別の参照データと比較する。

2次元の説明用座標。灰点線は基準形。Boltzの実際の途中出力や分子の運動ではない。

Boltz source 2.2.1・b1ebfc4・参照 2026-10-09 / 本教材の導出・模型計算・演習 / Passaro et al., Boltz-2 (2025), bioRxiv

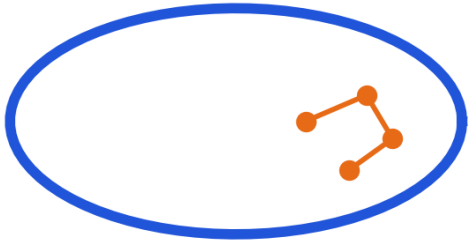
構造の評価は一つの数で済まない

全体の折り畳み、局所の原子配置、鎖間の向き、低分子の結合位置は異なる評価対象。どの原子・鎖を見るかを決める。

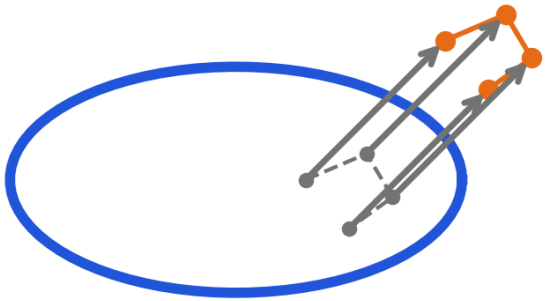
$$\mathrm{RMSD} = \sqrt{\frac{1}{N}\sum_i \|Rx_i + t - y_i\|^2}$$

RMSDは対応原子のずれの二乗平均の平方根。どの原子で重ね合わせたかで値が変わる。タンパク質を固定した低分子の評価では、その配置のずれが残る。対称原子の対応・欠損もそろえる。結合・衝突・立体化学も確認する。

参照：タンパク質と低分子



予測：タンパク質は一致、低分子はずれ



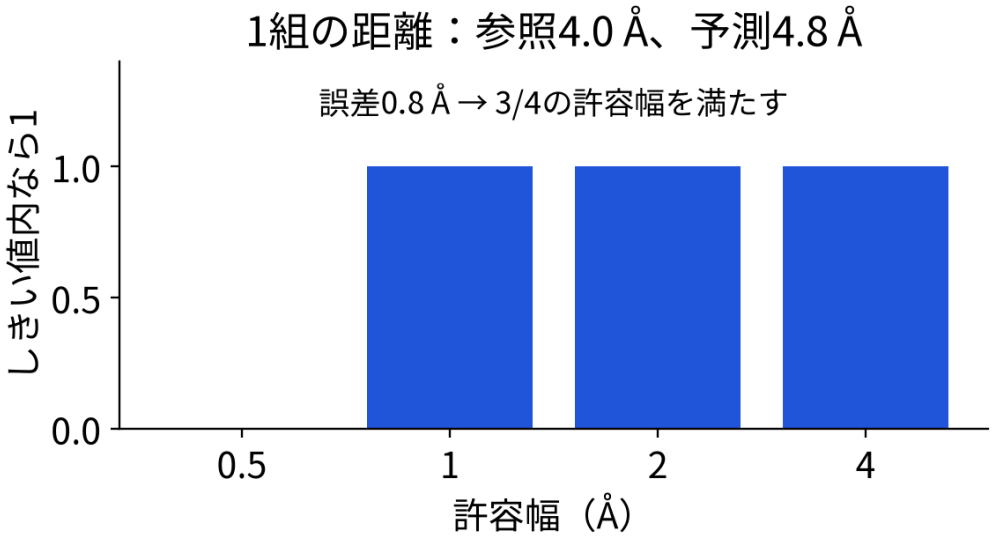
模型：青のタンパク質は一致。橙の低分子がずれ、灰の参照位置との差が残る。

Passaro et al., Boltz-2 (2025), bioRxiv / 本教材の導出・模型計算・演習

局所距離と界面の指標

lDDTは参照構造との局所距離が複数の許容幅に入るかを評価する。全体の剛体重ね合わせは不要。

右上は1組の距離だけの例。実際は評価対象の局所ペアに集計する。DockQは界面の複数指標を組み合わせ、鎖の対応も必要。一方、pLDDT・ipTMはモデルが予測した信頼度で、正解構造と比較して測った精度ではない。



参照構造と比較：lDDT・DockQ

測った精度と、予測された信頼度を分ける

正解なしでモデルが予測：pLDDT・ipTM

1組の距離差0.8 Åなら、許容幅0.5 Åは不合格、1・2・4 Åは合格となる。

lDDT: Mariani et al., Bioinformatics (2013), doi:10.1093/bioinformatics/btt473 / DockQ: Basu & Wallner, PLOS ONE (2016), doi:10.1371/journal.pone.0161879

局所構造と分子間の配置を分けて読む

pLDDT：局所構造

各トークンの局所的な信頼度。BoltzのJSON／NPZでは0–1、演習の図は100倍。

PAE：相対配置

一方を基準にした相対配置の予測誤差（Å）。小さいほど信頼できると予測する。

ipTM：分子間の配置

界面の相対配置についての予測信頼度（0–1）。鎖の組ごとの値も確認する。

出力を読む順序

タンパク質の形 → 低分子の位置 → 局所の信頼度 → 分子間の信頼度。

信頼度は実測の精度・結合の確率・結合親和性ではない。今回の演習では親和性を予測しない。

まとめ

条件とノイズ除去を組み合わせて、複合体を作る

条件を作る

配列・MSA・低分子
→ 単一表現とペア表現

→

座標を生成

学習済みDを反復評価
σを下げて原子を配置

→

出力を読む

複合体の原子座標
局所と界面の信頼度

学習：既知構造へノイズを加え、元の座標の予測誤差でネットワークを更新。
生成：重みを固定し、ノイズ量と座標を更新。候補数と反復数は別の設定。

座標の生成経路から、折り畳み時間や結合速度は読めない。
高い信頼度が得られても、結合の有無・親和性・生物学的機能は別に検証する。

授業のリンクから、Colabで複合体を予測する

1. 開く

授業リポジトリ
「Colabで開く」

→

2. 実行

T4 GPUを選択
すべてのセルを実行

→

3. 観察・保存

信頼度と3D構造
結果ZIPを保存

入力：タンパク質A、SAH（C）、チロシン（E）、固定MSA。
Boltz 2.2.1、1 recycle・20 diffusion steps・1候補・seed 42。
T4では専用カーネルを無効化し、PyTorchのGPU演算を使う。

演習20分、採点・提出なし。初回の取得と計算待ちは環境に依存する。
反復を減らした動作確認用条件。研究で精度を判断するための標準条件ではない。

鎖の色と、信頼度の指標を対応させる

構造を回転して見る

A：青いリボン、C（SAH）：橙、E（チロシン）：紫。低分子の位置と向きを確認。

信頼度の図と数値を見る

pLDDTの低い部分、PAE、ligand_ipTM、鎖の組ごとのipTMを対応させる。

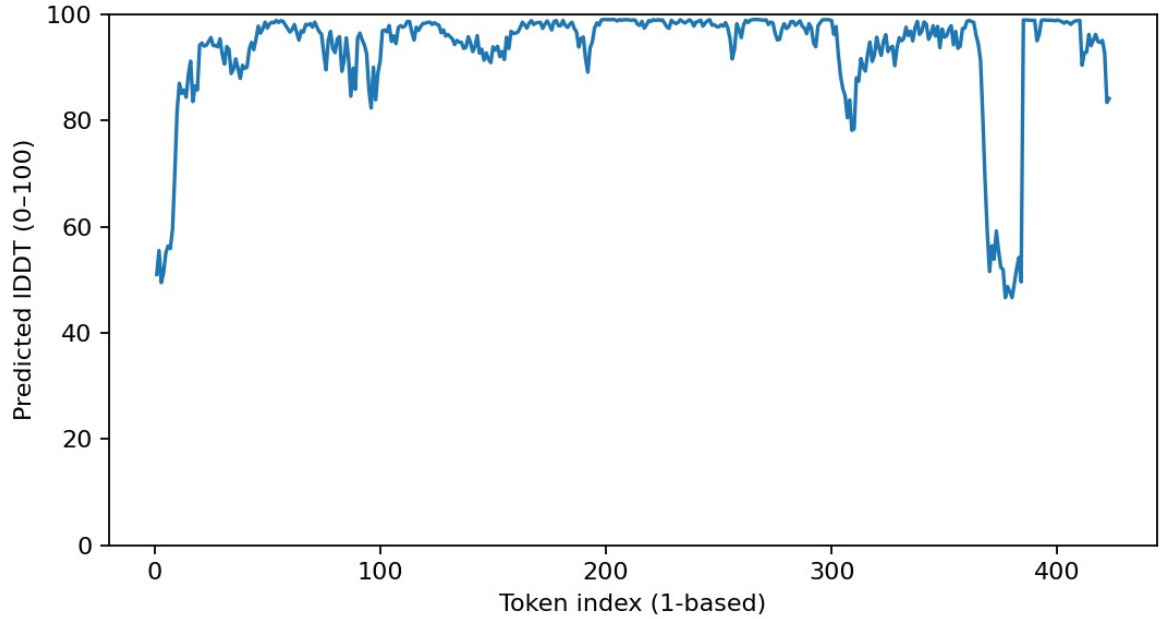
余裕があれば、一条件だけ変える

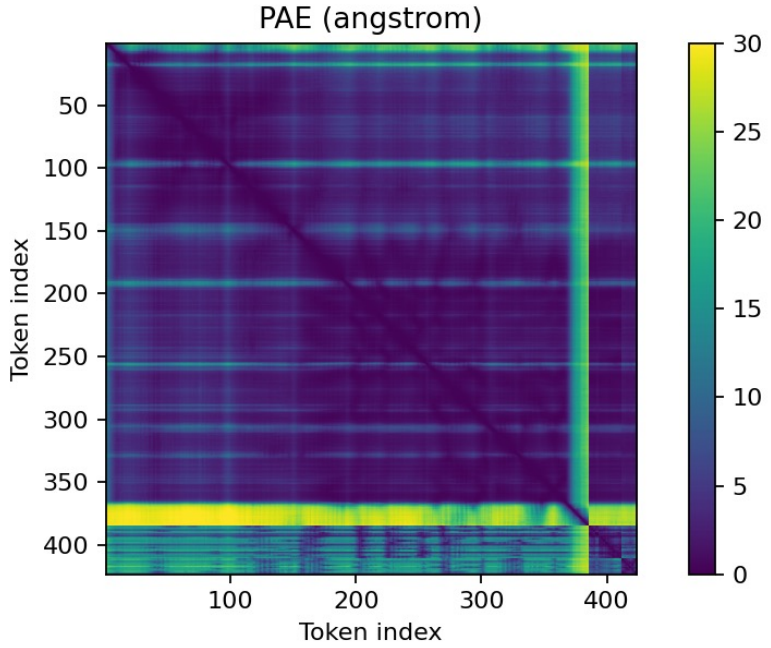
sampling_stepsを20から40へ。diffusion_samplesは候補数なので、同じ意味ではない。

結果ZIPを保存

入力・MSA・CIF・信頼度・実行条件・ログ・環境を残す。重みはZIPに含めない。

予測構造の信頼度を、場所ごとに確認する





実行例：平均pLDDT 0.930、ligand_ipTM 0.982（2026年10月11日、T4）。
タンパク質1鎖のため protein_ipTM = 0。これはタンパク質間の界面がない場合の値。

拡散モデルの導出を、途中式から確認する

A　確率と二乗誤差

確率密度・分散・条件付き平均。

B　DDPM

順過程の合成、事後分布、変分下限、ノイズ予測の損失。

C　スコアと逆時間の生成

スコア恒等式、Fokker–Planck方程式、逆SDE、確率流ODE。

D　EDMと数値計算

尺度係数の導出、Euler法とHeun法の誤差と計算量。

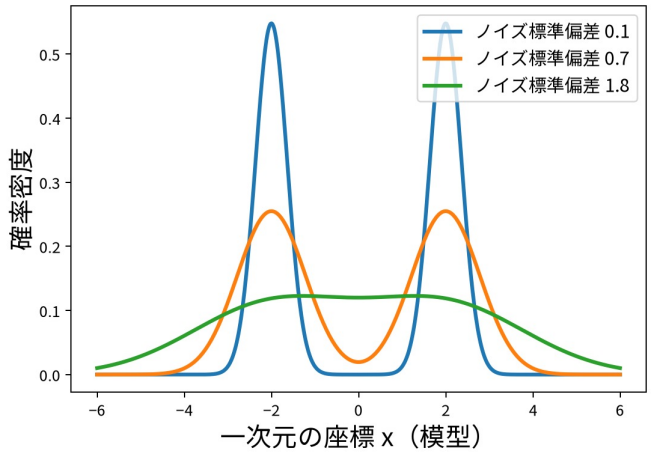
確率密度は面積で読む

1 確率密度は面積で読む

連続する座標xがちょうど一つの値を取る確率は0です。区間へ入る確率を、密度pの積分で表します。

密度そのものは1を超えても構いません。全領域の面積が1になることが条件です。

右の二つの山は、二通りの状態が現れやすい模型です。



2 正規分布でノイズを表す

正規分布は平均の周囲に広がる分布です。標準偏差σが大きいほど広がります。

標準正規分布からεを取り、σを掛けて平均μを足すと、望む分布を作れます。

多次元では各成分へ独立な標準正規ノイズを与える例から始めます。

$$p(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{(x-\mu)^2}{2\sigma^2}\right]$$

$$x = \mu + \sigma\epsilon, \quad \epsilon \sim \mathcal{N}(0,1)$$

三次元の原子座標では成分ごとの乱数を並べます。この独立な正規ノイズは生成計算の道具であり、分子に働く力そのものではありません。

本教材の導出・模型計算・演習 / Ho et al., Denoising Diffusion Probabilistic Models, NeurIPS (2020)

分散は尺度の二乗で変わる

1 分散は尺度の二乗で変わる

平均0の独立な確率変数ε1とε2を足すと、分散はそれぞれの分散の和です。

係数aを掛けると、分散はaの二乗倍になります。

この二つの性質により、何段階も加えた正規ノイズを一つにまとめられます。

$$\mathrm{Var}(a\epsilon_1 + b\epsilon_2) = a^2 + b^2$$

$$\mathbb{E}[\epsilon_1\epsilon_2] = 0$$

2 独立なノイズの分散が足せる理由

平均0の独立なノイズε1、ε2を考えます。

二乗を展開すると交差項が出ますが、独立性と平均0からその期待値は0です。

係数そのものではなく、係数の二乗が分散へ掛かります。

$$\mathbb{E}[(a\epsilon_1+b\epsilon_2)^2] = a^2\mathbb{E}[\epsilon_1^2]+2ab\mathbb{E}[\epsilon_1\epsilon_2]+b^2\mathbb{E}[\epsilon_2^2]$$

$$\mathbb{E}[\epsilon_1\epsilon_2] = 0, \quad \mathrm{Var}(a\epsilon_1+b\epsilon_2) = a^2+b^2$$

本教材の導出・模型計算・演習 / Ho et al., Denoising Diffusion Probabilistic Models, NeurIPS (2020)

二乗誤差は条件付き平均を学ぶ

1 二乗誤差は条件付き平均を学ぶ

ノイズ座標xが同じでも、元の構造yには複数の可能性があります。

二乗誤差の期待値を最小にする答えは、yの条件付き平均です。平均との差と予測のずれに分けると分かります。

一回のノイズ除去が、元の構造を一意に復元するとは限りません。

$$\mu(x) = \mathbb{E}[y \mid x]$$

$$\mathbb{E}[\|y - a\|^2 \mid x]$$

$$= \mathbb{E}[\|y-\mu(x)\|^2 \mid x] + \|a-\mu(x)\|^2$$

続く導出では、平均を選ぶと誤差が最小になる理由を式の展開で確かめます。

2 平均を選ぶと二乗誤差が最小になる

ノイズを含む入力xを固定し、元データyの推定値dを選びます。

条件付き平均mを加えて引き、二乗を展開します。

残る二項のうち、dで変わるのは平均からの距離だけです。

$$m = \mathbb{E}[y \mid x]$$

$$\mathbb{E}[\|y-d\|^2 \mid x] = \mathbb{E}[\|y-m\|^2 \mid x] + \|m-d\|^2$$

二乗すると交差項が出ますが、ワイから条件付き平均を引いた量の平均はゼロなので消えます。第一項は正解のばらつきで、ディーをどう選んでも変わりません。第二項は非負で、ディーをエムにするとゼロです。これが二乗誤差で学ぶ予測器が条件付き平均になる理由です。平均を一度返すことと、元の分布から標本を一つ作ることはまだ同じではありません。

段階ごとに少しずつノイズを加える

1 段階ごとに少しずつノイズを加える

DDPMは離散的な時刻tでノイズを加えるモデルです。元のデータをx0とします。

βtは一段で加えるノイズの分散で、0と1の間に取ります。元の信号は少し縮めます。

各段は直前だけに依存するマルコフ過程です。

$$q(x_t \mid x_{t-1}) = \mathcal{N}(\sqrt{1-\beta_t}x_{t-1}, \beta_t I)$$

$$x_t = \sqrt{\alpha_t}x_{t-1} + \sqrt{\beta_t}\epsilon_t, \quad \alpha_t = 1-\beta_t$$

2 二段分のノイズをまとめる

二段目の式へ一段目を代入すると、信号の係数は平方根の積になります。

二つのノイズは独立なので、分散は係数の二乗の和です。

その和が1−α1α2になることを、β=1−αを使って確かめます。

$$x_2 = \sqrt{\alpha_2\alpha_1}x_0 + \sqrt{\alpha_2\beta_1}\epsilon_1 + \sqrt{\beta_2}\epsilon_2$$

$$\alpha_2\beta_1 + \beta_2 = 1 - \alpha_1\alpha_2$$

Ho et al., Denoising Diffusion Probabilistic Models, NeurIPS (2020) / 本教材の導出・模型計算・演習

二段のノイズを数値で確かめる

例としてα1=α2=0.9、β1=β2=0.1とします。

信号の係数は0.9、ノイズ分散は0.19です。

標準偏差は√0.19です。0.19をそのままノイズへ掛けないようにします。

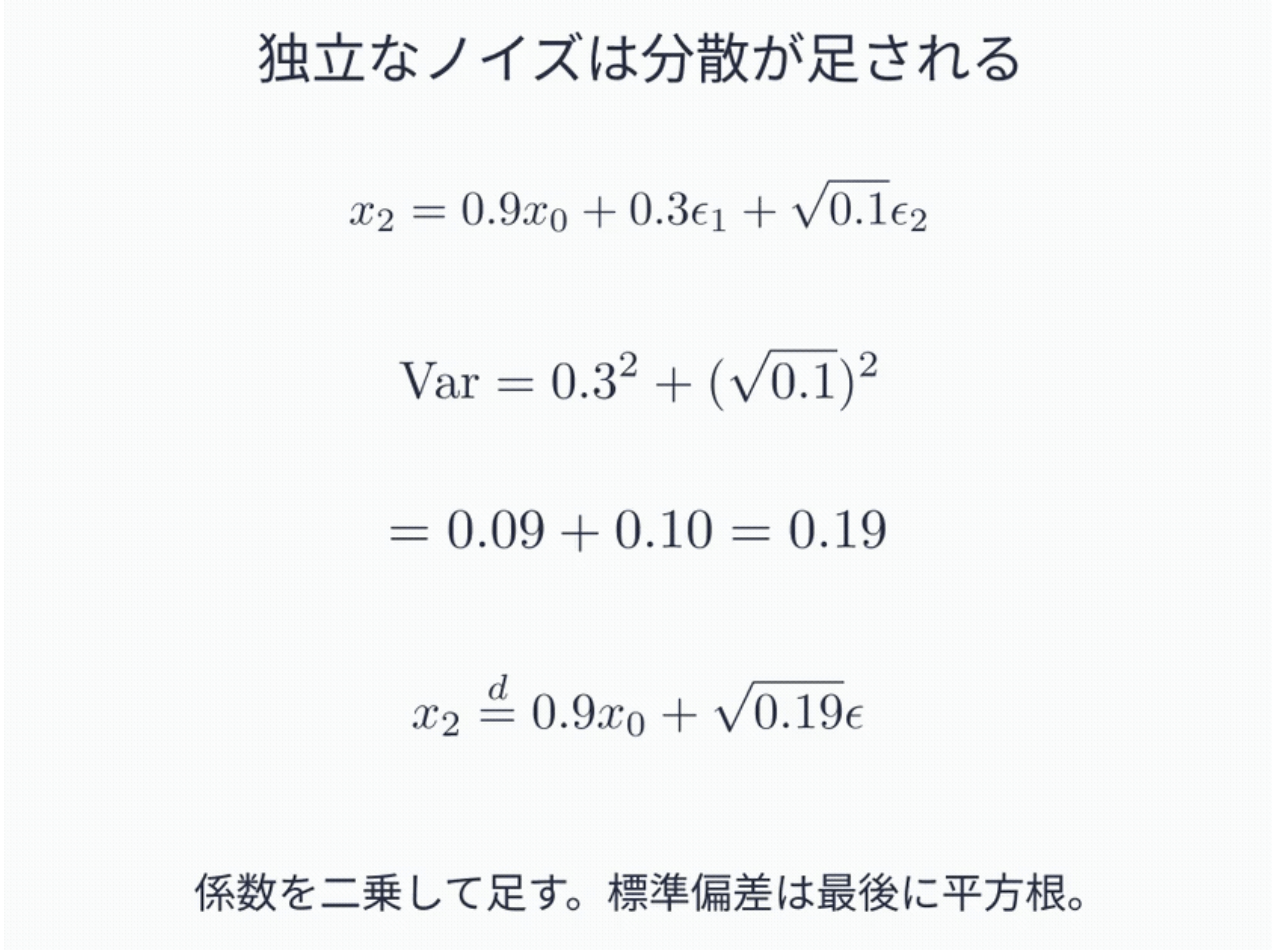
$$x_2 = 0.9x_0 + 0.3\epsilon_1 + \sqrt{0.1}\epsilon_2$$

$$0.3^2 + (\sqrt{0.1})^2 = 0.19$$

$$x_2 \overset{d}{=} 0.9x_0 + \sqrt{0.19}\epsilon$$

一段目の信号には平方根のゼロ点九を掛けます。二段目でも同じ係数を掛けるので、元データの係数はゼロ点九になります。一段目に加えたノイズも二段目で縮められ、その係数は平方根のゼロ点零九、つまりゼロ点三です。一方、二段目で新しく加えるノイズには平方根のゼロ点一が掛かります。独立な二つのノイズの分散を足すとゼロ点一九です。下の式の記号は、同じ乱数の値になるという意味ではなく、分布が同じという意味です。この違いを意識して、何段ものノイズを一つへ置き換える計算を読みましょう。

動きで確認：分散の合成



Manimによる説明用の数学模型

動きで確認：分散の合成

上から順に、二つのノイズの係数、分散、まとめた分布を追います。

独立性で交差項が消え、分散0.19のノイズへまとめられます。

ここでは先ほどの数式と同じ例を、順番が分かるように示しています。

表示が変わるたびに、どの量を固定し、何を更新したかを確認してください。

本教材の導出・模型計算・演習

任意の段階へ直接進める

1 任意の段階へ直接進める

αの累積積をᾱtと書きます。前の計算を繰り返すと、t段後の分布が分かります。

学習で時刻tのノイズ座標を作るために、1段目から順に計算する必要はありません。

元のデータと一つの正規ノイズだけで直接作れます。

$$\bar{\alpha}_t = \prod_{s=1}^{t} \alpha_s$$

$$q(x_t \mid x_0) = \mathcal{N}(\sqrt{\bar{\alpha}_t} x_0, (1 - \bar{\alpha}_t) I)$$

$$x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon$$

条件付き分布が一致するという主張です。

2 終点を単純な分布へ近づける

ᾱtが十分小さくなると、元の信号の係数は小さくなり、分散は1へ近づきます。

このため最後の分布を標準正規分布で近似し、生成の出発点にできます。

有限の段階では厳密に同一とは限りません。ノイズ列と終点の近似を区別します。

$$\bar{\alpha}_T \simeq 0 \quad \Rightarrow \quad x_T \simeq \epsilon, \quad \epsilon \sim \mathcal{N}(0, I)$$

元データに掛かる係数が十分小さくなると、最後の座標の大部分は正規ノイズで決まります。このため生成を単純な分布から始められます。ただし、有限の段数では元データの影響が厳密にゼロとは限りません。終点の近似をよくすることと、一段ごとの学習をよくすることは異なる課題です。学習目標の分解で終点の項が現れるのは、この一致も必要だからです。実装ではノイズの範囲と段数を一緒に確認します。

Ho et al., Denoising Diffusion Probabilistic Models, NeurIPS (2020)

逆向きの遷移を学習する

生成ではxTから始め、xtが与えられたときのxt−1の分布を学習します。

ネットワークが平均を予測し、必要に応じてノイズを加えて一段進めます。

真の逆向き分布は、元のデータ分布に依存します。小刻みな遷移を正規分布で近似します。

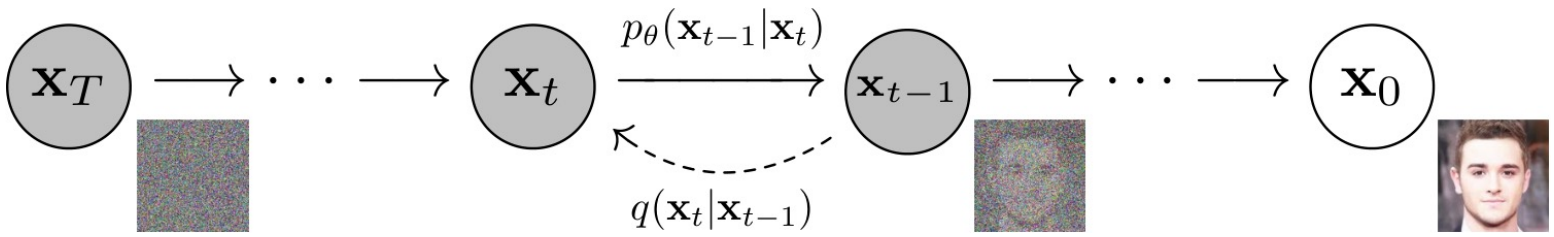
$$p_\theta(x_{0:T}) = p(x_T) \prod_{t=1}^{T} p_\theta(x_{t-1} \mid x_t)$$

$$p_\theta(x_{t-1} \mid x_t) = \mathcal{N}(\mu_\theta(x_t, t), \Sigma_\theta(x_t, t))$$

前向きの過程では、ノイズを加える規則を自分で決めました。逆向きでは、その観測を生んだ元のデータがどのように分布するかを知らなければなりません。ネットワークはこの逆向きの遷移を近似します。一つの段の平均と分散が分かれば、平均へ乱数を加えて次の座標を作れます。最後から順に繰り返すことで元データ側へ近づきます。真の逆遷移がどんな刻みでも正規分布になるという主張ではなく、小さな遷移を扱いやすい分布で近似する設計です。

Ho et al., Denoising Diffusion Probabilistic Models, NeurIPS (2020)

DDPM原著の図で二つの向きを読む



Ho et al., NeurIPS (2020)・Fig. 2より

DDPM原著の図で二つの向きを読む

qはデータからノイズへ進む、あらかじめ定めた過程です。pθは逆向きの遷移を学習します。

同じ変数の列でも、どちらを条件にして次を求めるかが違います。

原著の有向グラフを見て、二種類の矢印をたどります。

まず元のデータを固定した順方向では、ノイズを加える規則が既知なので、学習せずに途中の座標を作れます。

Ho et al., Denoising Diffusion Probabilistic Models, NeurIPS (2020)

学習時には正解x0が分かる

1 学習時には正解x0が分かる

生成時には未知のx0も、学習時にはデータとして既知です。

x0とxtを両方条件にしたxt−1の分布は、二つの正規分布の積から計算できます。

この計算可能な分布へ、モデルの逆遷移を近づけます。

$$q(x_{t-1} \mid x_t, x_0) \propto q(x_t \mid x_{t-1}) q(x_{t-1} \mid x_0)$$

2 平方完成のために変数を一つにする

zを一段前の座標と置き、zに依存する項だけを書きます。

一つ目は今の座標xtを説明する尤度、二つ目は元データx0からの分布です。

定数はzに依存しない項です。

$$z = x_{t-1}, \quad v = 1 - \bar{\alpha}_{t-1}$$

$$\log q(z \mid x_t, x_0) = -\frac{\|x_t - \sqrt{\alpha_t} z\|^2}{2\beta_t} - \frac{\|z - \sqrt{\bar{\alpha}_{t-1}} x_0\|^2}{2v} + \text{const.}$$

Ho et al., Denoising Diffusion Probabilistic Models, NeurIPS (2020) / 本教材の導出・模型計算・演習

二次係数と一次係数を集める

1 二次係数と一次係数を集める

二つの二乗を展開し、zの二次係数Aと一次係数bをまとめます。

zをAの逆数とbの積だけずらすと、一次項を消せます。

したがって事後分散はAの逆数、平均はb/Aです。

$$A = \frac{\alpha_t}{\beta_t} + \frac{1}{v}, \quad b = \frac{\sqrt{\alpha_t}}{\beta_t} x_t + \frac{\sqrt{\bar{\alpha}_{t-1}}}{v} x_0$$

$$-\frac{A}{2}\|z\|^2 + b^\top z = -\frac{A}{2}\|z - b/A\|^2 + \text{const.}$$

2 正規分布の積を平方完成する

xt−1に依存する二つの二乗項を展開し、二次と一次の係数を集めます。

精度は分散の逆数です。正規分布の積では精度が加算されます。

式の逆数が事後分散になります。tが2以上の段階で導出します。

$$\frac{1}{\tilde{\beta}_t} = \frac{\alpha_t}{\beta_t} + \frac{1}{1 - \bar{\alpha}_{t-1}}$$

$$\tilde{\beta}_t = \frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t} \beta_t$$

Ho et al., Denoising Diffusion Probabilistic Models, NeurIPS (2020) / 本教材の導出・模型計算・演習

事後分散の分母を整理する

1 事後分散の分母を整理する

Aの二つの項を通分します。

αtとβtの和が1、累積積がαt ᾱt−1であることを使います。

逆数を取ると、前ページの事後分散が得られます。

$$A = \frac{\alpha_t(1-\bar{\alpha}_{t-1}) + \beta_t}{\beta_t(1-\bar{\alpha}_{t-1})}$$

$$\alpha_t(1-\bar{\alpha}_{t-1}) + \beta_t = 1 - \bar{\alpha}_t$$

$$A^{-1} = \frac{\beta_t(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t}$$

式の分散が正になることも、各アルファがゼロと一の間にある条件から確認できます。

2 事後平均は二つの情報を混ぜる

平方完成で残った一次の係数へ事後分散を掛けると平均が得られます。

x0の情報とxtの情報を、ノイズの大きさに応じて混ぜています。

これは学習用に計算できる平均で、生成時にx0を参照できるという意味ではありません。

$$\tilde{\mu}_t = \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1-\bar{\alpha}_t} x_0 + \frac{\sqrt{\alpha_t}(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t} x_t$$

係数は前ページの一次項へ事後分散を掛けて得られます。式が長く見えても、新しい学習パラメータが増えたわけではありません。既知のノイズ列から決まる量です。後で元データをノイズの式へ置き換え、ネットワークが予測できる形に直します。

Ho et al., Denoising Diffusion Probabilistic Models, NeurIPS (2020) / 本教材の導出・模型計算・演習

尤度を直接計算するのは難しい

1 尤度を直接計算するのは難しい

観測したx0の確率は、途中のすべての座標を積分して求めます。高次元ではこの積分が難しくなります。

既知の順過程qで割って掛けると、qに関する期待値へ書き換えられます。

対数の凹性から、期待値を内側へ移した下限を得ます。

$$\log p_\theta(x_0) = \log \mathbb{E}_q\left[\frac{p_\theta(x_{0:T})}{q(x_{1:T}\mid x_0)}\right]$$

$$\log p_\theta(x_0) \geq \mathbb{E}_q\left[\log \frac{p_\theta(x_{0:T})}{q(x_{1:T}\mid x_0)}\right]$$

2 下限を段階ごとの誤差に分ける

下限の符号を反転して最小化する損失にします。終点の一致、中間の逆遷移、最後の復元に分けられます。

KLダイバージェンスは、二つの分布の違いを測る非負の量です。

中間段階では、計算できる事後分布とモデルの分布を近づけます。

$$L = L_T + \sum_{t=2}^{T} L_{t-1} + L_0$$

$$L_{t-1} = \mathbb{E}_q D_{\mathrm{KL}}\big(q(x_{t-1}\mid x_t, x_0)\,\|\,p_\theta(x_{t-1}\mid x_t)\big)$$

和の添字がどこからどこまでかも見てください。最後の復元は中間の正規事後と同じ扱いにできないため、別の項になっています。

Ho et al., Denoising Diffusion Probabilistic Models, NeurIPS (2020) / 本教材の導出・模型計算・演習

固定分散なら平均の二乗誤差になる

1 固定分散なら平均の二乗誤差になる

二つの正規分布の分散を固定して比較すると、重みに依存する部分は平均の差の二乗です。

モデルの平均を事後平均へ近づけることで、逆遷移のKLを小さくできます。

時刻ごとの係数は異なります。これを無視する簡略損失とは区別します。

$$L_{t-1} = \mathbb{E}_q\left[\frac{\|\tilde{\mu}_t - \mu_\theta(x_t, t)\|^2}{2\sigma_t^2}\right] + \text{const.}$$

2 元の座標の代わりにノイズを予測する

xtを作った式をx0について解けば、ノイズεが分かればx0も計算できます。

事後平均へ代入すると、平均の予測をノイズ予測で表せます。

εθは実際に加えたノイズを完全に知るのではなく、入力から推定します。

$$x_0 = \frac{x_t - \sqrt{1-\bar{\alpha}_t}\epsilon}{\sqrt{\bar{\alpha}_t}}$$

$$\mu_\theta = \frac{1}{\sqrt{\alpha_t}}\left(x_t - \frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}}\epsilon_\theta(x_t, t)\right)$$

Ho et al., Denoising Diffusion Probabilistic Models, NeurIPS (2020)

ノイズ予測の損失に付く係数

1 ノイズ予測の損失に付く係数

モデル平均と事後平均の差を、ノイズの予測誤差で書き直します。

同じxtの項は差を取ると消えます。

平均の二乗誤差へ代入すると、時刻に依存する係数が残ります。

$$\tilde{\mu}_t - \mu_\theta = \frac{\beta_t}{\sqrt{\alpha_t}\sqrt{1-\bar{\alpha}_t}}(\epsilon_\theta - \epsilon)$$

$$L_{t-1} = \mathbb{E}\left[\frac{\beta_t^2}{2\sigma_t^2\alpha_t(1-\bar{\alpha}_t)}\|\epsilon - \epsilon_\theta\|^2\right] + \text{const.}$$

2 簡略損失で何を学ぶのか

元のデータ、時刻、一つのノイズを取り、ノイズを予測する二乗誤差を計算します。

DDPMの簡略損失は、変分下限の時刻依存の重みをそのまま使わず、学習を重み付けし直します。

同じノイズ座標に複数の元データが対応するため、最適な予測は条件付き平均です。

$$x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1-\bar{\alpha}_t}\epsilon$$

$$L_{\text{simple}} = \mathbb{E}_{t,x_0,\epsilon}\|\epsilon - \epsilon_\theta(x_t, t)\|^2$$

Ho et al., Denoising Diffusion Probabilistic Models, NeurIPS (2020) / 本教材の導出・模型計算・演習

ノイズを当てるとスコアを学べる理由

補足導出：X=aY+bε、ε~N(0,I)、aとb>0は固定。ネットワークはXからεを二乗誤差で予測する。

$$\epsilon_*(x) = \arg\min_u E[\|\epsilon - u\|^2 \mid X = x] = E[\epsilon \mid x]$$

1 条件付き平均が二乗誤差の最適解。

$$\nabla_x \log q(x \mid y) = -\frac{x - ay}{b^2} = -\frac{\epsilon}{b}$$

2 条件付きの正規密度は既知なので微分できる。

$$\nabla_x \log p(x) = E[\nabla_x \log q(x \mid Y) \mid x]$$

3 積分の微分とベイズ則で、周辺のスコアへ移す。

$$s_*(x) = -\frac{\epsilon_*(x)}{b}, \quad b = \sqrt{1 - \bar{\alpha}_t}$$

4 DDPMでは信号の減衰aとノイズ尺度bを取り違えない。

その平均がスコアに必要な量なのです。

教師εは自分で発生させる乱数。未知のp(x)を評価せず、その対数勾配を学習できる。

Ho et al., Denoising Diffusion Probabilistic Models, NeurIPS (2020) / Song et al., Score-Based Generative Modeling through SDEs, ICLR (2021) / Vincent, Neural Computation 23, 1661–1674 (2011) / 本教材の導出・模型計算・演習

生成の一段を実行する

1 生成の一段を実行する

標準正規分布から初期座標を取り、時刻を大きい方から小さい方へ進めます。

各段階で予測したノイズから平均を計算し、選んだ分散に従うノイズを加えます。

最後の段階の分散や出力の扱いはモデルの定義に合わせます。

$$x_{t-1} = \mu_\theta(x_t, t) + \sigma_t z, \quad z \sim \mathcal{N}(0, I)$$

大きなノイズから始め、現在の座標と段階をネットワークへ渡し、予測ノイズを使って平均を計算します。その平均へ必要なランダム成分を足して一段前へ進みます。最後の段で同じようにノイズを加えるかは、定義した生成手順に従います。学習では任意の段を直接作れましたが、生成ではこの逆向きの更新を順にたどる必要があります。二つの計算手順を混同しないようにします。

2 画像の式を分子へ移すとき

画像の画素の代わりに、各原子の三次元座標を並べたベクトルを考えられます。

ただし分子には回転・並進、原子の対応、化学結合やキラリティーがあります。

BoltzはDDPMの式をそのまま使わず、連続的なノイズ量を用いた尺度調整と生成を採用します。

DDPM：離散段階を理解 → スコア：密度との関係 → EDM：尺度と数値計算 → Boltz：原子座標への設計

正規ノイズを使うという共通点だけで、画像用のモデルをそのまま分子へ移せるわけではありません。この節で学んだ確率と学習の考え方を、分子表現や座標の重ね合わせと組み合わせます。Boltzの説明では、その追加の設計を一つずつ確認します。

Ho et al., Denoising Diffusion Probabilistic Models, NeurIPS (2020) / Karras et al., Elucidating the Design Space…, NeurIPS (2022) / Passaro et al., Boltz-2 (2025), bioRxiv

学習時と生成時で、使える情報が違う

例：事後平均の式にx0が含まれるのに、生成時にはどう使えるのでしょうか。

説明：学習時にその平均や加えたノイズを教師とし、生成時にはネットワークの予測を使います。

次はノイズ除去器とスコアがどう結びつくかを導きます。

学習：x0と加えたノイズが既知 → 生成：ノイズ座標から推定 → 同じネットワークを全段で使用

学習用の事後平均の式には、元データの座標が現れました。生成の式には、その代わりに学習した予測が必要です。この違いを説明できるかが確認点です。学習時に使える正解を生成時にも読んでしまうコードでは、本当の予測になりません。次に学ぶスコアの関係も、理想的な教師の性質と、ネットワークが実際に近似する量を分けて読みます。

Ho et al., Denoising Diffusion Probabilistic Models, NeurIPS (2020)

積分の中の正規密度を微分する

加法ノイズx=y+σεで平滑化した密度を考えます。

正規密度の指数をxで微分すると、差y−xとσ²の逆数が出ます。

微分と積分を交換できる条件の下で、その結果を積分へ戻します。

$$p_\sigma(x) = \int p_0(y)\,\phi_\sigma(x-y)\,dy$$

$$\nabla_x \phi_\sigma(x-y) = \frac{y-x}{\sigma^2}\phi_\sigma(x-y)$$

$$\nabla_x p_\sigma(x) = \int \frac{y-x}{\sigma^2} p_0(y)\phi_\sigma(x-y)\,dy$$

まず、ワイは元のデータで、エックスはそこへノイズを加えた観測です。積分は、同じエックスを生じうるすべてのワイを足し合わせています。対応する行では正規分布の指数を微分しています。指数にはエックスからワイを引いた差の二乗があり、その微分で二が消え、マイナス符号をまとめるとワイからエックスになります。密度そのものを微分しているので、指数関数の部分も掛かったままです。これを一行目の積分へ代入したのが続く行です。次に密度で割ると、この積分が条件付き平均として読めるようになります。

Song et al., Score-Based Generative Modeling through SDEs, ICLR (2021) / Karras et al., Elucidating the Design Space…, NeurIPS (2022) / 本教材の導出・模型計算・演習

ベイズ則を使って条件付き平均にする

1 ベイズ則を使って条件付き平均にする

対数の微分は、密度の微分を密度で割ったものです。

積分中の密度の積をpσ(x)で割ると、元データyの事後分布になります。

その分布の平均が、最適なノイズ除去器Dです。

$$\frac{p_0(y)\phi_\sigma(x-y)}{p_\sigma(x)} = p(y \mid x)$$

$$\nabla_x \log p_\sigma(x) = \frac{1}{\sigma^2}\int (y-x)p(y \mid x)\,dy$$

$$s(x,\sigma) = \frac{D(x,\sigma)-x}{\sigma^2}$$

ここまでの等式は、理想的な条件付き平均についての関係です。学習したネットワークでは近似誤差も残ります。

2 条件付き平均がスコアになる

微分した密度を元の密度で割ると、積分の重みがベイズ則の条件付き分布になります。

その積分に現れるyの平均が、最適なノイズ除去器です。

近似ネットワークでは等号が近似になります。ノイズ量の二乗で割る点が重要です。

$$\nabla_x \log p_\sigma(x) = \frac{\mathbb{E}[y \mid x]-x}{\sigma^2}$$

$$s_\theta(x,\sigma) = \frac{D_\theta(x,\sigma)-x}{\sigma^2}$$

大きなノイズで平均の予測がぼやけることと、その予測を使って生成できることは両立します。どの更新式で利用するかが次の問題です。

Song et al., Score-Based Generative Modeling through SDEs, ICLR (2021) / Karras et al., Elucidating the Design Space…, NeurIPS (2022) / 本教材の導出・模型計算・演習

なぜランジュバン法で分布を保てるか

補足導出：目標密度πは正で滑らかとし、境界で確率が流出しない場合を考える。スコアs=∇logπは密度の対数の勾配。

$$dX = s(X)\,dt + \sqrt{2}\,dW_t$$

$$\partial_t p = -\nabla\cdot(sp) + \Delta p = -\nabla\cdot J$$

$$J = sp - \nabla p, \quad J\Big|_{p=\pi} = \pi\nabla\log\pi - \nabla\pi = 0$$

$$\pi \propto e^{-\beta U} \implies s = -\beta\nabla U = \beta F$$

1 ドリフトで密度の高い側へ動き、ノイズで広がる。

2 Fokker–Planck方程式で、標本の動きを密度の動きへ変える。

3 ∇logπ=(∇π)/πを代入すると、流入と流出が釣り合う。

4 定常であることと、短時間でその分布へ到達することは別。

例：π=N(0,1)なら s(x)=−x。揺らぎを除くと原点へ収束し、分散1の標本にはならない。

Song et al., Score-Based Generative Modeling through SDEs, ICLR (2021) / 本教材の導出・模型計算・演習

離散化すると定常分散もずれる

補足計算：π=N(0,1)、刻みη>0のEuler離散化。ξは各段で独立な標準正規乱数。

1 s(x)=−xを代入する。ノイズと現在値は独立。

$$X_{k+1} = (1-\eta)X_k + \sqrt{2\eta}\,\xi_k$$

2 両辺の分散を取り、交差項を独立性で消す。

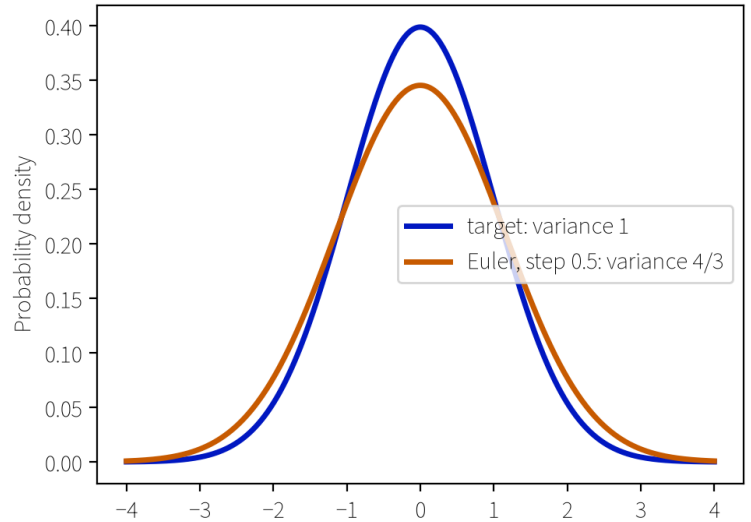
$$v_{k+1} = (1-\eta)^2 v_k + 2\eta$$

3 定常なら前後の分散が同じ。0<η<2で安定。

$$v_* = \frac{2\eta}{1-(1-\eta)^2} = \frac{1}{1-\eta/2}$$

4 標本数を増やしても、この離散化によるずれは消えない。

$$\eta = 0.1 : \ v_* \simeq 1.053, \quad \eta = 0.5 : \ v_* = 1.333$$



図では、目標の分布と有限の刻みの分布を同じ横軸へ重ねています。有限刻みの曲線が横へ広がるのは、分散が大きくなったためです。曲線の高さだけで誤差を判断せず、横方向の広がりも見ます。この例は解析解があるので、標本を作る実装の確認にも使えます。

区別：有限刻みの偏り、初期分布の影響、有限標本のばらつきは、それぞれ原因が違う。

連続時間の順過程を定義する

1 連続時間の順過程を定義する

時刻tを連続にし、決まった向きの変化fとランダムな変化を合わせます。

Wはウィーナー過程で、短い時間dtの増分の分散がdtになります。

ここではノイズの強さgは時刻だけに依存するとします。座標依存の場合は追加項が必要です。

$$dx = f(x,t)\,dt + g(t)\,dW_t$$
$$\Delta W \sim \mathcal{N}(0, \Delta t\, I)$$

ブラウン運動の増分の分散は時間幅に比例し、標準偏差は時間幅の平方根になります。したがって離散化すると、決定的な項とランダムな項で時間幅の掛かり方が違います。この節ではノイズ係数が位置に依存しない場合を扱い、より一般的な式と混ぜません。

2 密度が変わる式を見る

確率微分方程式に従う多数の標本を考えると、密度の時間変化はFokker–Planck方程式に従います。

第一項は流れによる密度の移動、第二項はノイズによる広がりです。

∇・は流れの発散、Δは各座標に関する二階微分の和です。

$$\partial_t p_t = -\nabla\cdot(f\,p_t) + \frac{g(t)^2}{2}\Delta p_t$$

一つの標本の動きと、多数の標本からなる密度の動きを区別します。発散の項はドリフトで密度が運ばれる効果、ラプラシアンの項はノイズで密度が広がる効果です。係数の二分の一は後の確率流にも残るので、ここで見ておきます。式を読みながら、ノイズだけのときに鋭い山がなだらかになる図を思い浮かべてください。

Song et al., Score-Based Generative Modeling through SDEs, ICLR (2021) / 本教材の導出・模型計算・演習

密度の式はTaylor展開から導ける

補足導出：滑らかな試験関数φと、位置に依存しないノイズ係数g(t)を用いる。境界項は0とする。

$$\Delta X = f\,h + g\sqrt{h}\,\xi, \quad E[\xi] = 0,\ E[\xi\xi^T] = I$$

1 平均変位はh、ランダム変位は√hの大きさ。

$$\frac{E[\Delta\varphi \mid X = x]}{h} \to f \cdot \nabla\varphi + \frac{g^2}{2}\Delta\varphi$$

2 二次のTaylor項も平均するとhの次数で残る。

$$\frac{d}{dt}\int \varphi p\,dx = \int \left(f \cdot \nabla\varphi + \frac{g^2}{2}\Delta\varphi\right) p\,dx$$

3 密度で平均する。φは時間に依存しない関数。

$$\int \varphi\,\partial_t p\,dx = \int \varphi \left[-\nabla\cdot(f\,p) + \frac{g^2}{2}\Delta p\right] dx$$

4 部分積分を1回・2回行い、微分をφからpへ移す。

任意のφについて成り立つので、$\partial_t p = -\nabla\cdot(fp) + (g^2/2)\Delta p$。1/2はTaylor展開の二次項から来る。

Song et al., Score-Based Generative Modeling through SDEs, ICLR (2021) / 本教材の導出・模型計算・演習

逆時間ではスコアが必要になる

1 逆時間ではスコアが必要になる

順過程が分布を広げる一方、逆向きには広がった分布から元の領域へ戻す必要があります。

逆時間のドリフトには、密度のスコアを使った補正が現れます。

式では時間をTから0へ積分し、dtは負です。ノイズ増分の分散には時間幅の絶対値を使います。

$$s_t(x) = \nabla_x \log p_t(x)$$
$$dx = [f(x,t) - g(t)^2 s_t(x)]\,dt + g(t)\,d\bar{W}_t$$
$$dt < 0$$

表示した式では時刻を減らす向きで積分しています。時間幅を正の数として書き直した式と比べるときには、時間の符号も同時に変えてください。符号だけを見て引力と斥力を判断すると誤りやすくなります。

2 符号を短い一段で確かめる

順過程のドリフトが0、戻る時間幅がh>0の場合を考えます。

dt=−hなので、逆時間の補正はプラスのスコア方向です。密度の高い領域へ向かいます。

ノイズを加える向きは決まっていません。分散はgの二乗とhの積です。

$$x_{t-h} \simeq x_t + h\,g(t)^2 s_\theta(x_t,t) + g(t)\sqrt{h}\,\xi$$

時間を戻す幅を正のエイチと定義したので、微小時間はマイナスエイチです。逆時間のドリフトにこれを掛けると、スコア方向への項はプラスになります。密度の高い方へ移動するという直感と照合できます。ランダム項の標準偏差はエイチの平方根に比例します。向きを決める項と、ばらつきを与える項を別々に確認してください。

逆向きの補正は確率の流れから読む

補足導出：逆向きの時計τ=T−tとqτ=pT−τを定義する。gは時刻のみに依存し、密度は正で滑らかとする。

$$J_t = f\,p_t - \frac{g^2}{2}\nabla p_t, \quad \partial_t p_t = -\nabla\cdot J_t$$

1 順過程の確率流。逆向きではこの流れが反転する。

$$\bar{J}_\tau = b q_\tau - \frac{g^2}{2}\nabla q_\tau = -J_{T-\tau}$$

2 同じ拡散係数を持つ逆過程のドリフトbを求める。

$$bq - \frac{g^2}{2}\nabla q = -fq + \frac{g^2}{2}\nabla q$$

3 広がる作用は逆過程にも残るため、ドリフトで補う。

$$b = -f + g^2\nabla \log q, \quad dY_\tau = b\,d\tau + g\,dW_\tau$$

4 qで割る。dτ>0の式なので、スコアの係数は正。

山を広げるノイズが残っている分も含めて、山へ戻す必要があると考えると、補正の役割が分かります。

これは逆過程の式の直観的導出。時間反転の成立には正則性条件が必要で、密度だけの一致では経路法則まで一意に決まらない。

Song et al., Score-Based Generative Modeling through SDEs, ICLR (2021) / Anderson, Stochastic Processes and their Applications 12, 313–326 (1982) / 本教材の導出・模型計算・演習

同じ密度を運ぶ常微分方程式

密度の二階微分は、密度とスコアの積の発散として書けます。

Fokker–Planck方程式を、速度場が密度を運ぶ連続の式へ書き換えます。

この速度場で標本を動かすと、理想的には同じ時刻の密度が得られます。

$$\Delta p = \nabla \cdot (p \nabla \log p)$$

$$\partial_t p = -\nabla \cdot \left[\left(f - \frac{g^2}{2} s \right) p \right]$$

$$\frac{dx}{dt} = f - \frac{g^2}{2} s$$

確率流の式は、密度の時間変化を決定的な速度場で表し直したものです。出発点を分布から引けば、各標本の動きが決定的でも集団として分布を作れます。逆確率過程のランダム項を消しただけでは密度の式が変わります。二階微分をスコアを含む発散へ書き直すことで、必要な速度が導かれます。続く途中式で係数の由来を確かめます。

密度の式を速度場として読み直す

1 密度の式を速度場として読み直す

この節ではノイズ係数gが時刻だけに依存すると仮定します。

密度の勾配をpとスコアの積へ置き換えます。

確率流の速度vを使うと、密度の保存を表す連続の式になります。

$$\partial_t p = -\nabla \cdot (f\,p) + \frac{1}{2} g^2 \Delta p$$

$$\Delta p = \nabla \cdot (p s)$$

$$\partial_t p = -\nabla \cdot (v p), \quad v = f - \frac{1}{2} g^2 s$$

スコアの前の二分の一は、密度の拡散項にもともとあった係数から来ています。ノイズだけを削除する操作で得た式ではないことが、この導出から分かります。

2 逆SDEと確率流ODEの違い

逆SDEは各段階でもランダムノイズを加えます。確率流ODEは初期値を決めれば決定的に進みます。

スコアが正確で適切に積分できれば、時刻ごとの分布は同じになります。

一つ一つの経路は同一ではありません。近似スコアと有限刻みでは結果も変わります。

逆SDE：補正係数 g^2 とノイズ → 確率流ODE：補正係数 $g^2/2$ → 同じ周辺分布・異なる経路

同じ時点の密度が一致することは、同じ初期点から同じ経路を通ることではありません。確率的な過程には途中にも乱数が入り、決定的な過程では初期値から経路が定まります。理想的なスコアと正確な積分という条件を離れると、有限の計算では出力分布にも差が出ます。実用上は計算量と結果を比較して手順を選びます。

Song et al., Score-Based Generative Modeling through SDEs, ICLR (2021) / 本教材の導出・模型計算・演習

確率流ODEの1/2を導く

補足導出：確率密度を速度vで運ぶ連続の式と、Fokker–Planck方程式を比べる。

1 順過程ではドリフトによる移流と、ノイズによる拡散が共存する。

$$\partial_t p = -\nabla \cdot (f\,p) + \frac{g^2}{2}\Delta p$$

2 密度が正の領域で、∇p=p∇logpを使う。

$$\Delta p = \nabla \cdot \nabla p = \nabla \cdot (p \nabla \log p)$$

3 共通の発散へまとめる。ここには新しいランダム項を加えない。

$$\partial_t p = -\nabla \cdot \left[\left(f - \frac{g^2}{2} s \right) p \right]$$

4 同じ時刻ごとの密度を運ぶ速度を読む。初期点の分布は必要。

$$\frac{dX}{dt} = f(X,t) - \frac{g(t)^2}{2} s_t(X)$$

密度を運ぶ速度へ書き換える

$$\partial_t p = -\nabla \cdot (fp) + \frac{g^2}{2}\Delta p$$

$$\nabla p = p\,\nabla \log p = p\,s$$

$$\partial_t p = -\nabla \cdot [(f - \frac{g^2}{2} s)p]$$

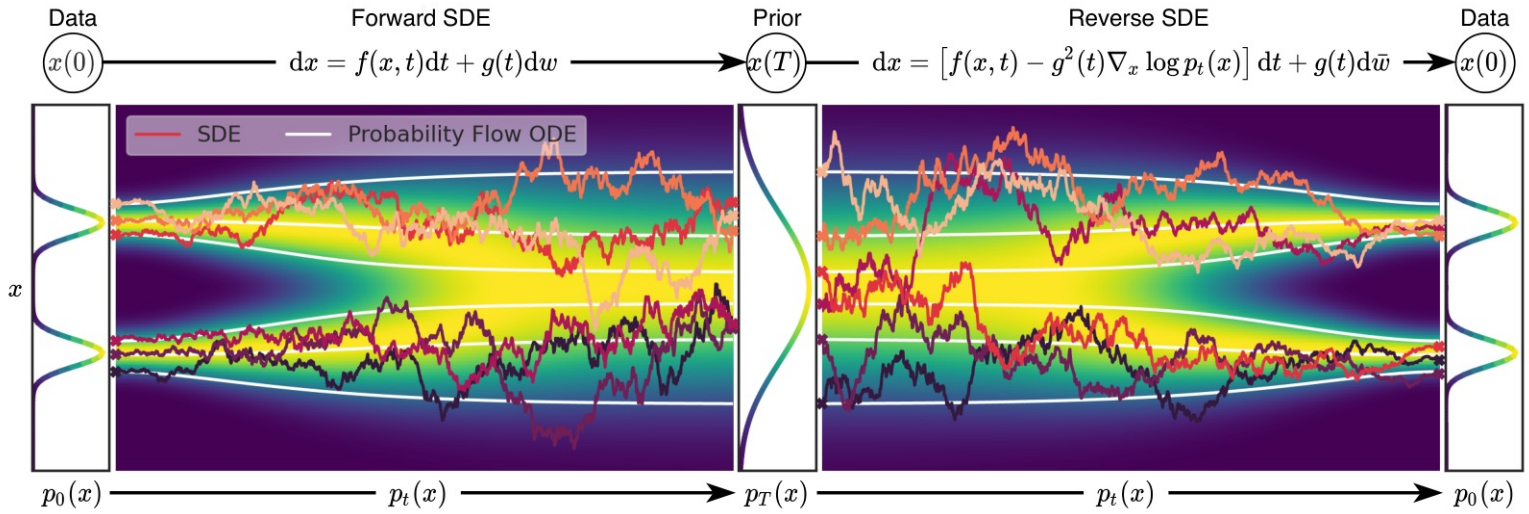
$$v = f - \frac{g^2}{2} s$$

補足導出：gは位置に依存しない

理想的なスコア・正しい初期分布・厳密な積分の下で密度が一致する。ODEとSDEの個々の軌道は一致しない。

Song et al., Score-Based Generative Modeling through SDEs, ICLR (2021) / 本教材の導出・模型計算・演習

原著の図で順過程と逆過程を読む



原著の図で順過程と逆過程を読む

左はデータをノイズへ広げる過程、右はノイズからデータへ戻る過程です。

背景色は密度、曲線は標本の経路です。同じ時刻の分布が同じでも、経路は異なります。

左右の外側には元のデータ分布、中央にはノイズの分布があります。

ギザギザの線は確率微分方程式による標本、滑らかな線は確率流の常微分方程式による標本です。

Song et al., ICLR (2021), Fig. 2・原著図の引用

Song et al., Score-Based Generative Modeling through SDEs, ICLR (2021)

加える分散をσで表す

1 加える分散をσで表す

信号を縮めず、元データへ分散σの二乗のノイズを足す場合を考えます。

順過程の分散増加率をgの二乗に対応させます。

これを確率流ODEへ代入し、時間の代わりにノイズ標準偏差σを変数にします。

$$g(t)^2 = \frac{d\sigma(t)^2}{dt} = 2\sigma\dot{\sigma}$$

$$\frac{dx}{d\sigma} = -\sigma s(x,\sigma) = \frac{x - D(x,\sigma)}{\sigma}$$

2 ノイズ量を下げて生成する

σを大きい値から小さい値へ進めるので、刻みΔσは負になります。

x−Dはノイズを含む座標からノイズ除去予測への差です。負の刻みを掛けるとDの方向へ進みます。

この式がEDMとBoltzの座標更新を読む基本になります。

$$x_{i+1} = x_i + (\sigma_{i+1} - \sigma_i)\frac{x_i - D_\theta(x_i,\sigma_i)}{\sigma_i}$$

Song et al., Score-Based Generative Modeling through SDEs, ICLR (2021) / Karras et al., Elucidating the Design Space…, NeurIPS (2022) / Boltz source 2.2.1・b1ebfc4・参照 2026-10-09

σで積分する式へ変数を変える

補足導出：加法ノイズX=Y+σε、順過程のドリフトf=0。σ(t)>0は微分可能で単調増加とする。

$$g(t)^2 = \frac{d\sigma^2}{dt} = 2\sigma\dot{\sigma}$$

$$\frac{dX}{dt} = -\sigma\dot{\sigma}\, s(X,\sigma)$$

$$s(X,\sigma) = \frac{D(X,\sigma) - X}{\sigma^2}$$

$$\frac{dX}{d\sigma} = \frac{dX/dt}{d\sigma/dt} = \frac{X - D(X,\sigma)}{\sigma}$$

1 独立なノイズの分散が増える速さをg^2とする。

2 確率流ODEへf=0とg^2を代入する。

3 加法ガウスノイズの条件付き平均とスコアの関係を使う。

4 連鎖律で時計をtからσへ変える。生成時はσを減らす。

傾きの符号だけを見て逆向きに動くと判断せず、刻み幅まで掛けた変位を確認しましょう。

単位：XとσがÅなら、dX/dσは無次元。負のΔσを掛けるので、更新はDへ近づく向きになる。

Karras et al., Elucidating the Design Space…, NeurIPS (2022) / Song et al., Score-Based Generative Modeling through SDEs, ICLR (2021) / 本教材の導出・模型計算・演習

EulerとHeunの誤差は何が違うか

補足計算：x′(σ)=d(x,σ)が滑らかとして一段を展開する。dの微分にはxを通じた変化も入る。

$$x(\sigma+h) = x+hd+\frac{h^2}{2}(\partial_\sigma d+J_d d)+O(h^3)$$

1 連鎖律で二階微分を計算。Jdはdのxに関するヤコビ行列。

$$\tilde{x} = x + hd, \quad \tilde{d} = d(\tilde{x}, \sigma + h)$$

2 Eulerの仮の終点で傾きを評価する。

$$\tilde{d} = d + h(\partial_\sigma d + J_d d) + O(h^2)$$

3 終点の傾きをTaylor展開する。

$$x_{\text{Heun}} = x+\frac{h}{2}(d+\tilde{d}) = x+hd+\frac{h^2}{2}(\partial_\sigma d+J_d d)+O(h^3)$$

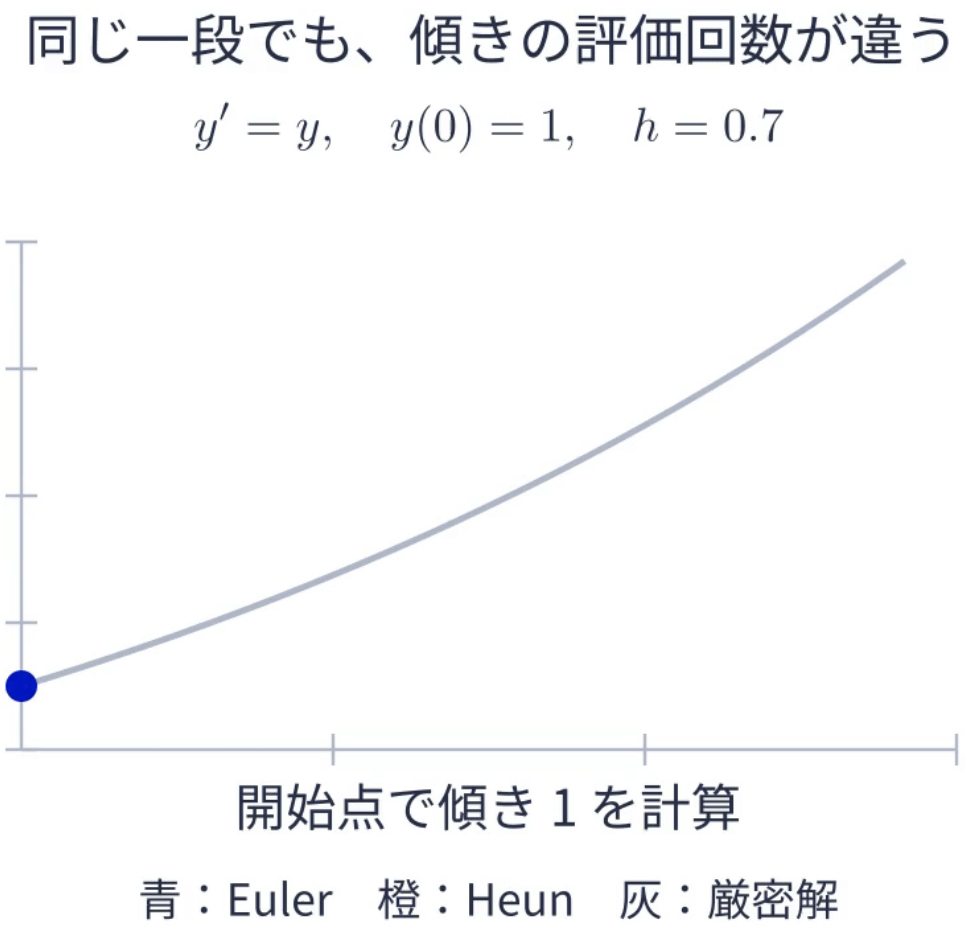
4 二つの傾きの平均で、二次まで正しい項が現れる。

大域誤差は一定の区間を最後まで進めた差で、段数が刻み幅の逆数程度になるため、一般に次数が一つ下がります。滑らかな例で刻みを半分にし、誤差が何分の一になるかを見れば、この違いを検査できます。

Eulerは局所$O(h^2)$・大域$O(h)$、Heunは局所$O(h^3)$・大域$O(h^2)$。同じ関数評価回数でも比較する。

Karras et al., Elucidating the Design Space…, NeurIPS (2022) / 本教材の導出・模型計算・演習

刻み数だけで計算費用を比べない



Manim：y′=y の数値積分の模型

刻み数だけで計算費用を比べない

一段に予測器を二回呼ぶ方法と、一回呼ぶ方法では、同じ段数でも費用が違います。

予測器の評価回数、全体時間、誤差を一緒に記録します。

高い次数の方法でも、ノイズやモデル誤差が大きければ常に有利とは限りません。

右は、導関数が自分自身に等しい、簡単な常微分方程式の例です。

オイラー法は出発点の傾きだけで進みます。

Karras et al., Elucidating the Design Space…, NeurIPS (2022)

残差の分散を最小にする係数

ノイズ座標x=y+σεから、元データyを予測します。

元データとノイズは独立、各成分の平均は0と仮定します。

y−cxの分散をcで微分し、0にするとc_skipが得られます。

$$\mathrm{Var}(y-cx) = (1-c)^2\sigma_{\mathrm{data}}^2 + c^2\sigma^2$$

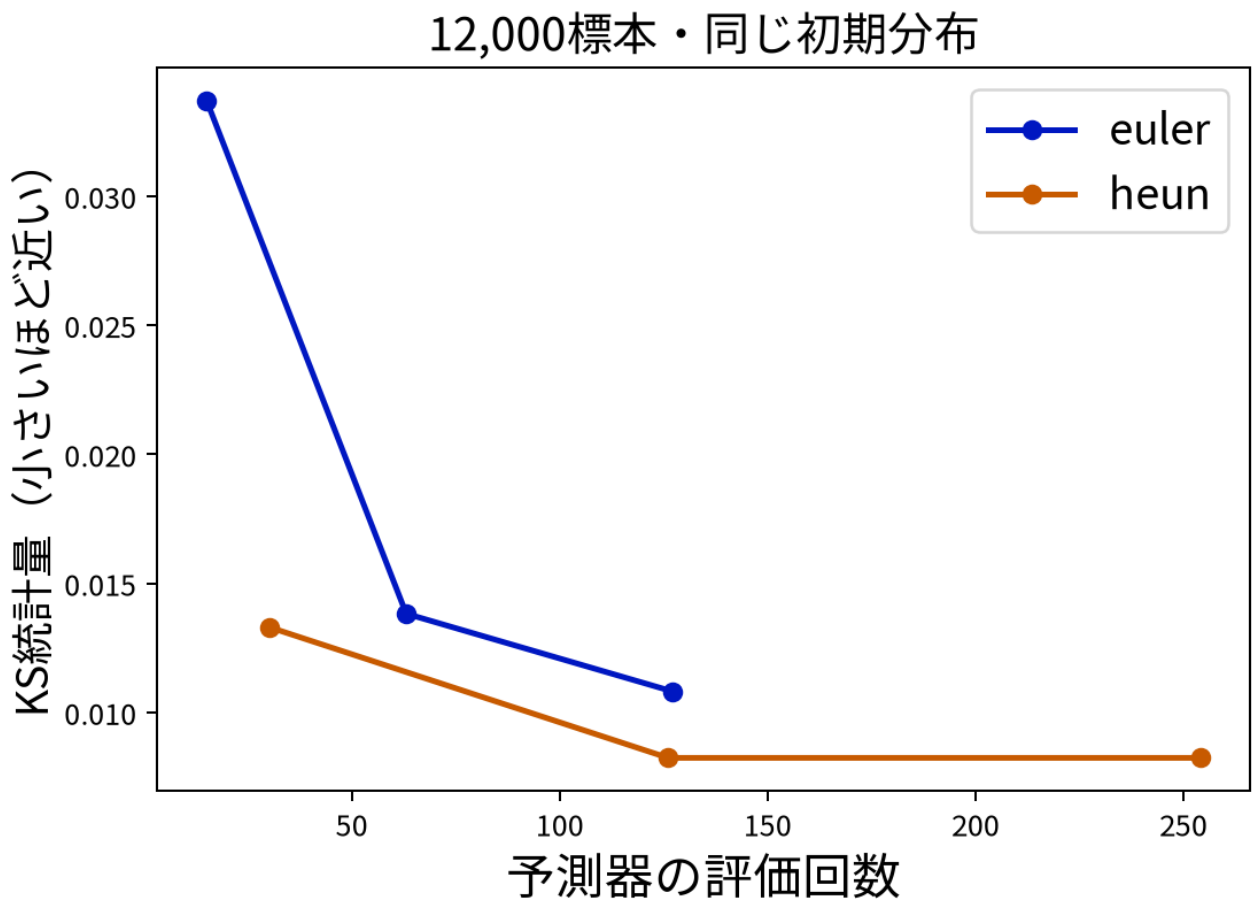
$$\frac{d}{dc}\mathrm{Var}(y-cx) = -2(1-c)\sigma_{\mathrm{data}}^2 + 2c\sigma^2$$

$$c = \frac{\sigma_{\mathrm{data}}^2}{\sigma_{\mathrm{data}}^2 + \sigma^2}$$

係数を暗記する代わりに、なぜこの形になるのかを追います。元データから入力のシー倍を引いた残差をネットワークに予測させたいとします。入力を元データとノイズの和へ戻すと、残差は元データの一引くシー倍と、ノイズのマイナスシー倍になります。独立なので分散は二つの二乗係数の和です。これをシーで微分した式が対応する行です。微分をゼロにして解くと続く行の係数になります。この操作は、すべてのデータ分布で条件付き平均を線形関数にするという主張ではありません。ネットワークへ渡す残差の代表的な尺度を整えるための設計です。

Karras et al., Elucidating the Design Space…, NeurIPS (2022) / 本教材の導出・模型計算・演習

模型の誤差を計算量と比較する



本教材の説明図

模型の誤差を計算量と比較する

同じ初期標本で生成し、最後の分布を理論的な累積分布と比較しました。

KS統計量は累積分布の最大の差で、小さいほど近い値です。横軸は予測器の呼出し回数です。

細かい刻みでも標本誤差が残ります。Boltzの実分子での精度を直接表す結果ではありません。

横軸は反復数ではなく、予測器の評価回数です。

縦軸の統計量は累積分布の差を見ており、平均だけが合っているかを検査するものではありません。

本教材の導出・模型計算・演習

出典と学び直す場所

Passaro et al., Boltz-2 (2025), bioRxiv

https://doi.org/10.1101/2025.06.14.659707

Wohlwend et al., Boltz-1 (2024/2025), bioRxiv

https://doi.org/10.1101/2024.11.19.624167

Abramson et al., Nature 630, 493–500 (2024)

https://doi.org/10.1038/s41586-024-07487-w

Boltz source 2.2.1・b1ebfc4・参照 2026-10-09

https://github.com/jwohlwend/boltz/blob/b1ebfc46ecf57f5414e0d1a6f9027bbb122c53bc/

出典と学び直す場所

授業用Notebook・入力・演習

https://github.com/matsunagalab/lecture_bioinfo

Boltz prediction documentation・b1ebfc4

https://github.com/jwohlwend/boltz/blob/b1ebfc46ecf57f5414e0d1a6f9027bbb122c53bc/docs/prediction.md

Ho et al., Denoising Diffusion Probabilistic Models, NeurIPS (2020)

https://arxiv.org/abs/2006.11239

Karras et al., Elucidating the Design Space…, NeurIPS (2022)

https://arxiv.org/abs/2206.00364

出典と学び直す場所

Song et al., Score-Based Generative Modeling through SDEs, ICLR (2021)

https://arxiv.org/abs/2011.13456

Vincent, Neural Computation 23, 1661–1674 (2011)

https://doi.org/10.1162/NECO_a_00142

Anderson, Stochastic Processes and their Applications 12, 313–326 (1982)

https://doi.org/10.1016/0304-4149(82)90051-5