生命情報工学特論　第06回

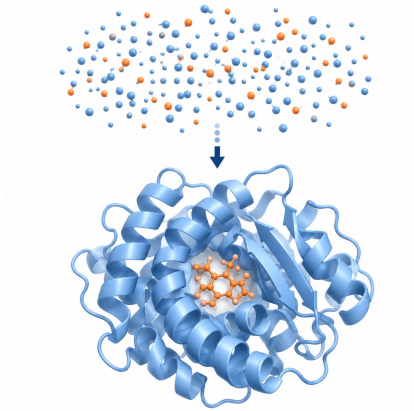
# Boltz による<br>複合体構造予測

タンパク質と低分子の配置を予測する<br>拡散モデルの仕組み・Boltz演習

**松永 康佑**

埼玉大学 大学院理工学研究科<br>理化学研究所 計算科学研究センター ｜ 2026年11月9日

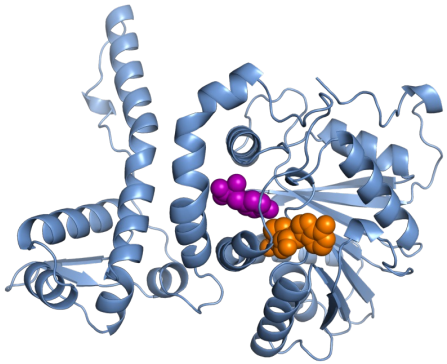
分子の情報を条件に、座標を生成



概念図：青はタンパク質、橙は低分子。実際の予測構造ではない。

この回の対象

## タンパク質と低分子の位置・向きを予測する



### 酵素 MfnG と二つの低分子

青：MfnG。チロシンにメチル基を付けるタンパク質。配列は384残基。

橙：SAH。メチル基を渡した後の補因子。

紫：チロシン。タンパク質中の残基ではなく、別分子として入力する基質。

### 入力から何を求めるか

配列・MSA・低分子の化学構造から、同じ座標系での原子配置と信頼度を求める。最後に実験構造7UX8と重ねて確かめる。

図：授業用Boltz-2の実予測。色は分子の種類。SAH自体をメチル基の供与体として入力しているわけではない。



この回の流れ

## 複合体の予測から、学習と座標更新の仕組みへ

| 説明する問い | たどる内容 |
|---|---|
| **なぜAF2の座標生成を変更するか** | 異なる分子を扱う全原子表現 |
| **どう分子どうしの配置を予測するか** | 分子間の情報 → 全原子の更新 |
| **どうノイズ除去を学習するか** | DDPMの発想 → デノイザー |
| **なぜスコアで構造を生成できるか** | 条件付き平均 → スコア → 座標更新 |
| **予測のどこまでを信じてよいか** | 信頼度 → 実験構造との比較 |

演習では学習済みのBoltzを使う。モデルの訓練と、訓練後の構造生成を区別して読む。



AF2 から複合体へ

## AF2 でも複数の構造は作れる。何を変えるのか

| 比べる点 | AlphaFold 2 | AlphaFold 3・Boltz |
|---|---|---|
| **対象** | タンパク質。Multimer ではタンパク質複合体も扱う | タンパク質・核酸・低分子などを一緒に扱う |
| **座標の表し方** | 残基のフームと二面角から原子を配置 | 全原子の直交座標を直接生成 |
| **複数の候補** | MSA の選び方や乱数などを変えて得られる | 学習した生成過程を、異なる乱数で実行する |
| **共通する注意** | 候補の出現頻度は、熱平衡の存在確率とは限らない | 拡散モデルでも、この保証は自動では得られない |

### 判断①：何を出力するか。分子の種類によらず、全原子の座標を扱う

AF2 の残基フームは、共通の主鎖を持つタンパク質に適している。低分子には同じ残基の型が使えない。全原子の座標なら、分子内部の形と分子間の位置・向きを共通の出力として表せる。

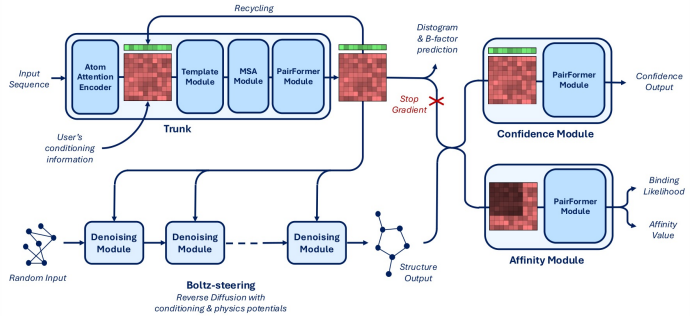
### 判断②：どう生成するか。拡散は、そのために選ばれた一つの方法

全原子を出力することから、拡散の採用が必然になるわけではない。次に「学習しやすい問題へどう分けるか」を考える。

del Alamo et al., eLife 11:e75751 (2022) / Abramson et al., Nature 630, 493–500 (2024)

複合体予測の全体像

## 分子間の情報を作り、全原子の座標を更新する




上段：配列・MSA・化学構造から条件を作る。下段：条件を参照して座標を繰り返し更新する。右：生成した構造の信頼度を予測する。親和性予測は今回の対象外。

Passaro et al., Boltz-2 (2025), Fig. 2. 原著の図を再利用。



分子の表し方

## タンパク質は残基、低分子は原子を単位にする

**タンパク質：1残基を1トークン**

残基1 | 残基2 | 残基3

トークンに所属する複数の原子へ
情報を渡し、各原子の座標を予測する。

**低分子：1原子を1トークン**

原子1 | 原子2 | 原子3

化学結合・元素・立体化学も入力。
分子名だけで原子配置を決めるわけではない。

トークンは、情報をまとめてやり取りする単位。出力する座標の単位は、どちらも原子である。低分子中のチロシンも、この演習では原子ごとに扱う。

| MfnG | SAH | チロシン |
|---|---|---|
| **384残基 → 384トークン** | 26原子 → 26トークン | 13原子 → 13トークン |

Boltz 2.2.1の授業入力：合計423トークン。水素原子は予測座標に含めない。



複合体を一緒に予測する仕組み

## 異なる分子のトークン間でも情報をやり取りする

| | MfnG タンパク質 | SAH 低分子 | チロシン 低分子 |
|---|---|---|---|
| MfnG タンパク質 | 同じ分子内 | 分子間の情報 | 分子間の情報 |
| SAH 低分子 | 分子間の情報 | 同じ分子内 | 分子間の情報 |
| チロシン 低分子 | 分子間の情報 | 分子間の情報 | 同じ分子内 |

行と列はトークンの所属分子。緑は分子をまたぐ組。

ペア表現は、トークン対の関係を表す学習済みの特徴ベクトル。

この情報を座標生成にも渡すので、低分子の配置がタンパク質の情報に依存する。

図はブロックの役割を示す模式図。色は距離やアテンションの重みの大小を表さない。

Wohlwend et al., Boltz-1 (2024/2025) / Boltz-2のtoken pair表現と座標生成。



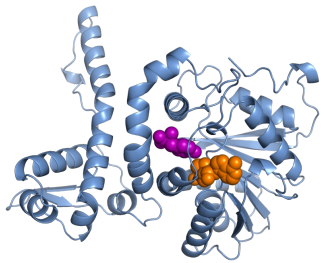
複合体を一緒に予測する仕組み

## 分子間の情報を使い、全原子を同じ空間へ配置する

**分子間の情報を含む トークンの特徴** → **各原子へ情報を渡す 現在の座標・ノイズ量も参照** → **全原子の座標を予測 タンパク質・SAH・Tyr**

分子内部の形と、分子どうしの位置・向きを同時に予測する。分子ごとに独立して生成し、最後に寄せ集める方法ではない。

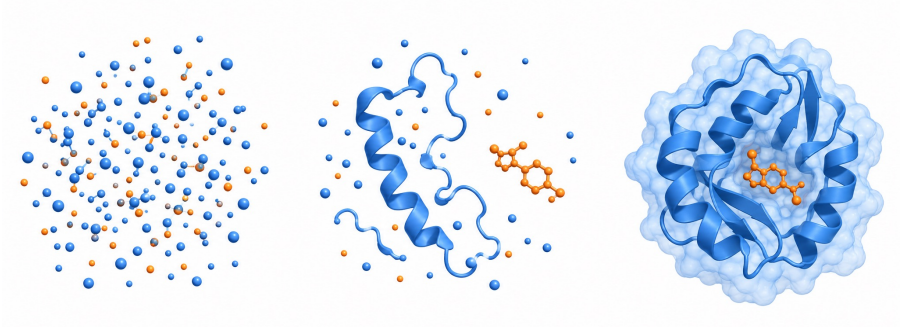
結合部位を知るための情報は、既知の複合体などから学習したネットワークにある。拡散の更新式だけに化学の知識が入っているわけではない。



Boltzの原子座標生成。ノイズ量の特徴変換・実装上の係数は付録に掲載。

ノイズ除去を学習する｜分子の場合

## 知りたいのは、条件を与えたときの構造の分布



知りたい分布は $p(X|c)$。$X$：全原子の座標、$c$：配列・MSA・低分子の情報。ノイズの多い座標を繰り返し更新して標本を作る。

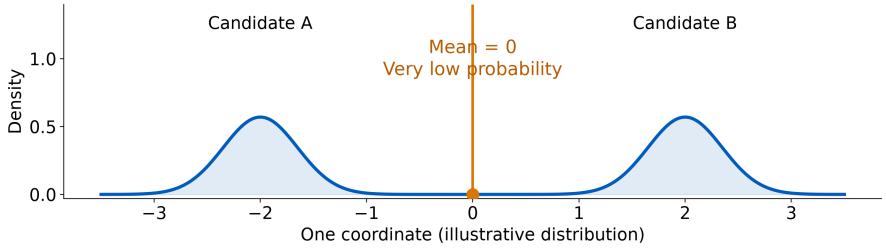
GPT Imageによる概念図。原子・結合の実計算やMDの時間発展ではない

本教材の導出・模型計算・演習



ノイズ除去を学習する｜生成の目標

## 候補を一つずつ作りたい。平均の座標では足りない




二乗誤差で一つの定数を予測すると平均0になるが、この分布では0の近くはほとんど現れない。

欲しいのは、山の周りにある候補を一つずつ作る方法。AF2 が平均座標を返すという意味ではない。

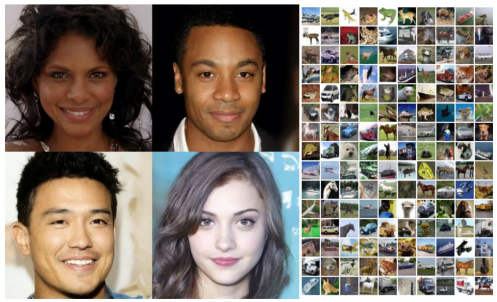
説明用の1次元模型。平均 ±2、標準偏差0.35の正規分布を等しい割合で混ぜた。

Ho et al., Denoising Diffusion Probabilistic Models, NeurIPS (2020) / Karras et al., Elucidating the Design Space···, NeurIPS (2022)



ノイズ除去を学習する｜拡散を選ぶ理由

## 直接生成する問題を、ノイズ除去の学習へ分ける



DDPM 原著の生成例。左：顔画像、右：CIFAR-10。特定の画像を復元する課題だけでなく、新しい画像の生成へ使える。

### 困ること：複雑な分布を直接作る

あり得る画像や原子配置は高次元の空間のごく一部にある。ランダムな値から、妥当な候補へ一度で移す規則は簡単には書けない。

### アイデア：壊す過程の逆を学ぶ

① 既知のデータへノイズを足し、入力と教師の組を作る。

② 少しだけ戻す問題を、いろいろなノイズ量で学習する。

③ 簡単な正規乱数から、その逆向きの更新を繰り返す。

複雑な生成を、同じネットワークによる局所的な予測の反復として学べる。これは拡散を選ぶ理由であり、ほかの生成法が不可能という意味ではない。

Ho, Jain & Abbeel, Denoising Diffusion Probabilistic Models (2020), Fig. 1–2・式(4)(11)(14)



ノイズ除去を学習する｜発想

## 画家の下描きから、段階的な生成を考える

### ラフ：位置と輪郭

### 中間：形と陰影

### 仕上げ：細部と質感



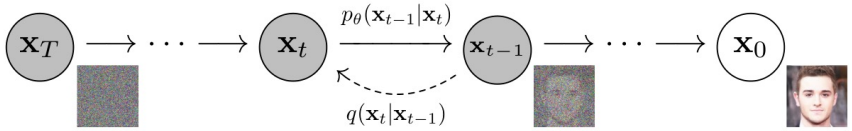
学習：既知構造にノイズを加えれば、「乱れた入力 → 元の座標」の練習材料を作れる。

生成：同じデノイザーで座標を繰り返し更新する。乱数を変えると別の候補も作れる。

図は例え：下描き ≠ 正規ノイズ。Boltzは原子座標を更新する。全体→細部という厳密な段階分けではない。

ノイズ除去を学習する｜DDPM 原著

# DDPM：壊す向きは決めて、戻す向きを学習する




原著の図は右がデータ、左がノイズ。下の矢印が順過程、上の矢印が学習する逆過程。

**順過程：少し縮めて、ノイズを足す**

$$x_t = \sqrt{1-\beta_t}\, x_{t-1} + \sqrt{\beta_t}\, \epsilon$$

各段のノイズは独立な標準正規乱数。小さいノイズを何段も加えると、元データの情報が薄れ、標準正規分布に近づく。ノイズ量は設計者が決める。

**逆過程：一段前の分布を予測する**

$$p_\theta(x_{t-1} \mid x_t) = \mathcal{N}(\mu_\theta(x_t, t), \Sigma_t)$$

壊すと情報が失われるので、逆は一意の逆算ではない。データから戻り先の平均を学び、設定した分散の乱数と組み合わせて一段戻る。これを繰り返す。

Ho, Jain & Abbeel, Denoising Diffusion Probabilistic Models (2020), Fig. 1–2・式(4)(11)(14)



ノイズ除去の学習｜DDPM

# 自分で加えたノイズを、予測の教師に使う

**既知のデータ**
**元の画像・構造**
→
**ノイズを加える**
**段階をランダムに選ぶ**
→
**ネットワーク**
**加えたノイズを予測**

$$x_t = \sqrt{\bar{\alpha}_t}\, x_0 + \sqrt{1-\bar{\alpha}_t}\, \epsilon$$

元データ $x_0$、残る信号の割合 $\bar{\alpha}_t$、標準正規ノイズ $\epsilon$。入力は $x_t$ と段階 t、正解は $\epsilon$。

$$L_{\text{simple}} = \mathbb{E}\left[\|\epsilon - \epsilon_\theta(x_t, t)\|^2\right]$$

学習時は正解のノイズが分かる。生成時は未知なので、学習済みネットワークの予測を使って一段ずつ戻す。逆過程の平均と損失の導出は付録に残す。

Ho, Jain & Abbeel, DDPM (2020), 式(4)(14)。単純化した損失は変分下限の重みを変更している。



DDPMからBoltzへ

# ノイズを当てることと、元の座標を当てること

**この後は、信号を縮めずにノイズを加える表記で考える**

$$x = y + \sigma\epsilon, \qquad D_\theta(x, \sigma, c) = x - \sigma\epsilon_\theta(x, \sigma, c)$$

| 記号 | 意味 |
|---|---|
| **y / x** | 元の座標 / ノイズを加えた現在の座標 |
| **σ / ε** | ノイズの標準偏差 / 標準正規乱数 |
| **c / Dθ** | 分子の情報 / 元の座標を予測するデノイザー |

予測したノイズを引けば、元座標の予測になる。DDPMの信号の縮小は尺度変換でそろえられる。ただし、Boltzの損失・ノイズ列・更新則はDDPM原著と同一ではない。

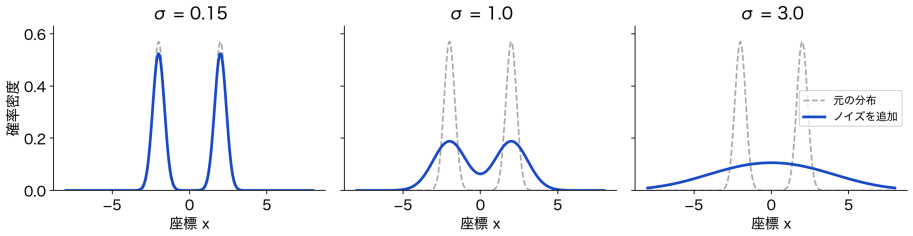
Ho et al. (2020) / Karras et al., EDM (2022)。尺度変換の式と逆過程の導出は付録。



ノイズ除去を学習する｜ノイズと分布

# ノイズで分布の山をなだらかにする

元の分布は、−2 と 2 を中心とする二つの正規分布の混合。独立な正規ノイズを加えると各山が広がる。灰の破線は元の分布、青線はノイズ追加後。同じ軸で $\sigma$ を変えて比較する。




学習ではノイズを加えた入力を作る。生成では大きなノイズから始め、$\sigma$ を下げて元の分布へ戻す。

Ho et al., Denoising Diffusion Probabilistic Models, NeurIPS (2020) / Karras et al., Elucidating the Design Space···, NeurIPS (2022)

ノイズ除去を学習する｜損失

# ノイズ座標とノイズ量から、元の座標を予測

**教師：既知構造 $y$**
分子の条件 $c$ と組にする

→

**ノイズ入力 $x$**
$\epsilon$ に $\sigma$ を掛けて足す

→

**デノイザー $D_\theta$**
$x$・$\sigma$・$c$ から $y$ を予測

$$x = y + \sigma\epsilon, \quad \epsilon \sim \mathcal{N}(0, I)$$

$$\mathcal{L}(\theta) = \mathbb{E}_{y,\sigma,\epsilon}\left[\lambda(\sigma)\|D_\theta(x,\sigma,c) - y\|^2\right]$$

**学習用の座標対を自分で作れる**

| | | | |
|---|---|---|---|
| 教師 y | 0.0 | 1.0 | 2.0 |
| ノイズ入力 x | 0.3 | 0.8 | 2.4 |

1成分ずつの説明例。実際は全原子の3成分を扱う。

$\sigma$：ノイズの標準偏差。分子座標なら単位は Å。$\lambda$：ノイズ量ごとの損失の重み。
単純な二乗誤差の最適解は条件付き平均。Boltz の損失には重ね合わせ・原子の重みも入る。



条件付き平均と生成

# 平均を一度返すことと、更新に使うことは違う

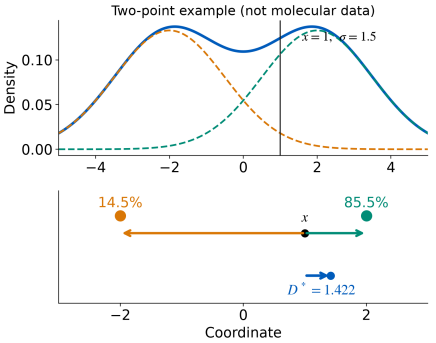
**全候補を一つの答えにする場合**

元データが −2 と +2 に半々なら、全体の平均は0。この値を最終候補として返すだけでは、二つの候補を生成できない。

**ノイズ座標を観測した場合**

x=1、σ=1.5なら、元が+2だった確率は85.5%。条件付き平均は1.422となり、現在の値から右へ修正する情報になる。

$$D^*(x,\sigma) = \mathbb{E}[y \mid x]$$




生成では、ノイズ量ごとにこの予測を更新則へ使う。条件付き平均そのものを最終候補として一度だけ出すのではない。

説明用の2点模型。事後確率はベイズ則で計算。実分子の座標ではない。



ノイズから座標を生成する｜なぜ対数の勾配なのか

# 戻る方向を平均すると、対数密度の勾配になる

元の密度を $p_0$、元の値を中心とする正規ノイズの密度を $q_\sigma$ とする。条件は固定し、1次元で書く。

$$p_\sigma(x) = \int p_0(y)\, q_\sigma(x \mid y)\, dy$$

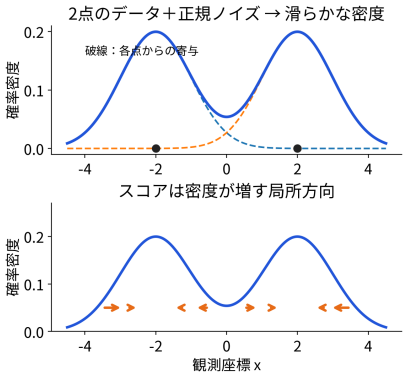
$$\partial_x q_\sigma(x \mid y) = q_\sigma(x \mid y)\frac{y - x}{\sigma^2}$$

$$\frac{\partial_x p_\sigma(x)}{p_\sigma(x)} = \int \underbrace{\frac{p_0(y) q_\sigma(x \mid y)}{p_\sigma(x)}}_{p(y|x)} \frac{y - x}{\sigma^2}\, dy$$

密度で割ると、候補の重みが「観測後の確率」になる。左辺は、微分の規則により対数密度の微分。

$$\partial_x \log p_\sigma(x) = \frac{D^*(x,\sigma) - x}{\sigma^2}$$

この量をスコアと呼ぶ。多次元では微分を勾配に替える。




模型：元データは −2 と 2 の2点。橙の矢印は局所の密度増加方向。



ノイズから座標を生成する｜スコアの意味

# スコアは、密度の相対的な変化を表す

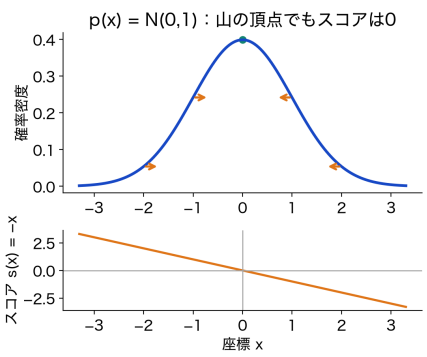
$$s(x) = \nabla_x \log p(x) = \frac{\nabla_x p(x)}{p(x)}$$

密度がどれだけ増えるかを、現在の密度に対する割合で測る。前の導出では、この割り算が候補の重みを事後確率に直していた。

$$p(x) = \tilde{p}(x)/Z \implies \nabla_x \log p = \nabla_x \log \tilde{p}$$

座標によらない正規化定数は消える。ただし、この便利さだけがスコアを使う根拠ではない。

右は標準正規分布。スコアは −x で、山の頂点では0。スコアの方向へ動かし続けるだけでは頂点へ集まり、分布からの生成にはならない。




Karras et al., Elucidating the Design Space of Diffusion-Based Generative Models (2022), 式(1)・付録B

ノイズから座標を生成する｜スコア

## 正規分布で、式の符号を確かめる

予測ノイズは $x-D$ の方向、スコアは逆の $D-x$ の方向。$\sigma$ で割る回数と符号を区別する。

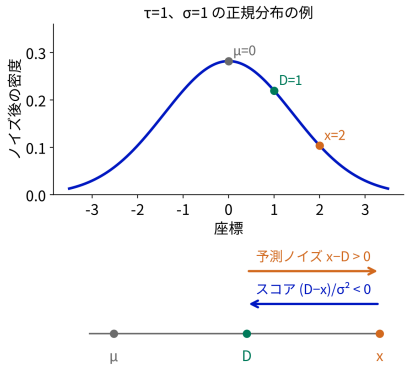
$$\hat{\epsilon} = \frac{x - D_\theta(x,\sigma)}{\sigma}$$

$$s_\theta = -\frac{\hat{\epsilon}}{\sigma}$$

$$s(x,\sigma) = -\frac{x-\mu}{\tau^2+\sigma^2}$$

$$D(x,\sigma) = x + \sigma^2 s = \frac{\tau^2 x + \sigma^2 \mu}{\tau^2+\sigma^2}$$

正規分布の例では $x>\mu$ ならスコアは負。$D$ は観測 $x$ を平均 $\mu$ へ近づけ、$\sigma$ が大きいほど $\mu$ の比重が増す。




模型：$\mu$=0、$\tau$=$\sigma$=1、$x$=2 のとき $D$=1、予測ノイズ 1、スコア −1。

Karras et al., Elucidating the Design Space···, NeurIPS (2022) / Ho et al., Denoising Diffusion Probabilistic Models, NeurIPS (2020) / 本教材の導出・模型計算・演習



スコアから座標更新へ

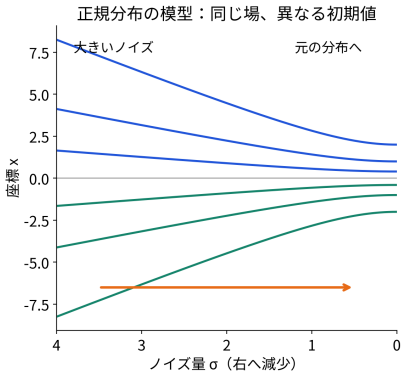
## 分布を戻すには、ノイズ量とともに更新を変える

同じ密度のスコアをたどり続けると、山の頂上に集まる。生成では、ノイズ量を下げながら、広がった分布全体を元へ戻したい。

$$\frac{dx}{d\sigma} = -\sigma s(x,\sigma) = \frac{x - D^*(x,\sigma)}{\sigma}$$

右は、異なる初期点から始めた座標の経路。生成は左から右へ進み、σは減る。初期値にばらつきがあるので、更新が決定的でも最終座標はばらつく。

係数 −σ は、ノイズで変わる密度と、座標の移動で変わる密度を一致させると得られる。途中式は付録。




Karras et al., EDM (2022)。理想的なスコア・連続積分での確率流ODE。有限の刻みと予測誤差は別に残る。



座標更新の具体例

## 現在の座標から、予測した座標の方向へ少し進む

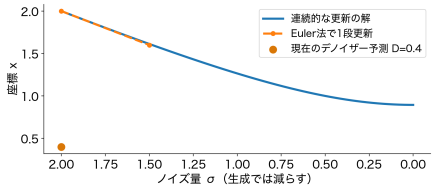
$$x_{i+1} = x_i + (\sigma_{i+1} - \sigma_i)\frac{x_i - D_i}{\sigma_i}$$

元の分布は平均0・分散1の正規分布。現在 x=2、σ=2 なら D=2/(1+2²)=0.4。

$$x_{\text{next}} = 2 + (1.5-2)\frac{2-0.4}{2} = 1.6$$

刻みは −0.5。傾き0.8に掛けると、変位は −0.4。予測値0.4へ一度で飛ばず、1.6へ進んで次の予測を行う。

図の厳密解は約1.612。刻みを小さくすると数値積分の誤差は小さくなる。

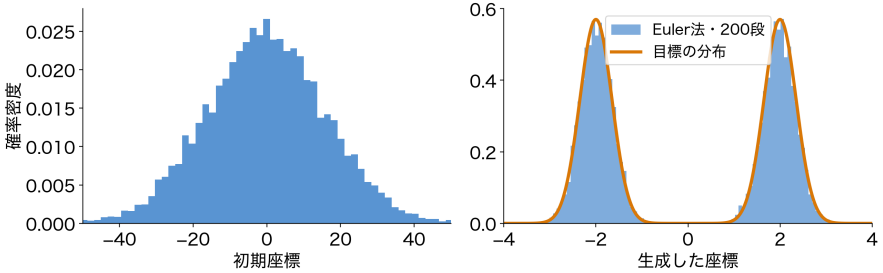



説明用の1次元正規分布。Boltz固有の追加ノイズ・更新幅の調整は付録。



反復による生成

## 同じデノイザーを繰り返し使い、二つの山を生成する




左：ばらついた初期座標。右：ノイズ量を下げて更新した結果。異なる初期値から、二つの山の周囲へ候補が分かれる。全候補を平均した0だけを返す計算とは異なる。

説明用の正規混合分布。12,000標本・Euler法200段・解析的デノイザー。Boltzでの精度を示す結果ではない。

分子どうしを一緒に配置する｜全分子の座標

# 複合体全体の配置を、一緒に予測する

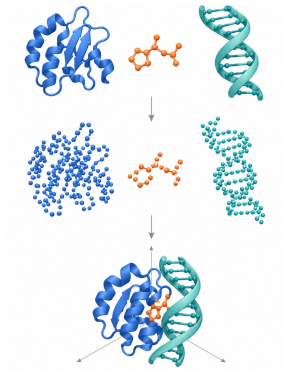
タンパク質・核酸・低分子を原子（水素を除く）で表し、全分子を合わせた $M\times 3$ 個の座標を生成する。分子どうしの位置と向きも出力の一部になる。

$$X \in \mathbb{R}^{M\times 3}, \quad D_\theta(X, \sigma; c)$$

$$X_\sigma = X_0 + \sigma\epsilon$$

複合体予測を支えるのは、①多様な分子の共通の表現、②分子をまたぐ情報交換、③既知の複合体を含む構造データからの学習。

学習では複合体の座標 $X_0$ にノイズを加え、条件 $c$ から元の配置を予測する。拡散は座標を生成する方法で、結合位置の知識は学習済みネットワークにある。



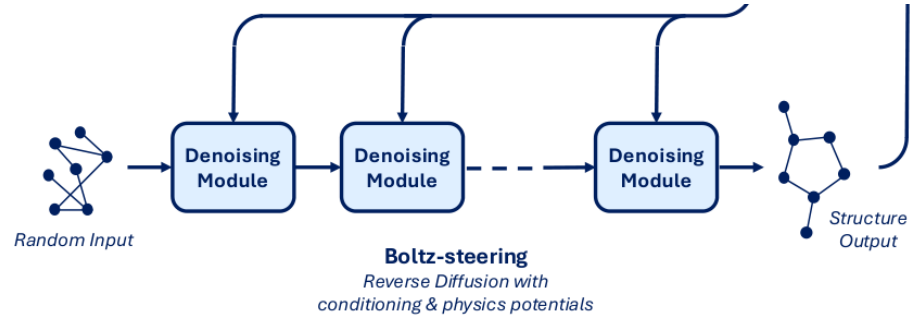
模式図：多様な分子 → 全原子 → 共通の座標系の複合体。実測・予測構造ではない。

Passaro et al., Boltz-2 (2025), bioRxiv / Boltz source 2.2.1 · b1ebfc4 · 参照 2026-10-09



分子どうしを一緒に配置する｜座標生成部

# 原著の図で、座標生成部を見る




上から来る線は共通部分からの条件 $c$。各段で変わるのは座標 $X$ とノイズ量 $\sigma$。

同じ重み $\theta$ のデノイザーを繰り返す。段ごとに別のモデルを学習するわけではない。

Passaro et al., Boltz-2 (2025) · Fig. 2 座標生成部より。パネルを切り出し

Passaro et al., Boltz-2 (2025), bioRxiv



分子どうしを一緒に配置する｜学習の工夫

# 向きを変えて学習し、重ね合わせて誤差を測る

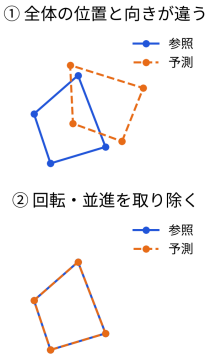
学習では座標を中心化し、ランダムに回転・並進する。向きへの偏りを防ぐデータ拡張である。

$$\min_{R,t} \sum_i w_i m_i \|\hat{x}_i - (Rx_i + t)\|^2$$

$$R^T R = I, \quad \det R = 1$$

損失では正解座標を予測へ剛体で重ね合わせ、全体の位置と向きを除いて形の差を測る。これが前回の FAPE に代わる。

$R$ は行列式が正の直交行列なので、鏡像へ反転して誤差を減らすことはできない。




同じ4点の形を回転・並進した模型。下では完全に重なるが、形の違いがあれば残差が残る。

Boltz source 2.2.1 · b1ebfc4 · 参照 2026-10-09 / Abramson et al., Nature 630, 493–500 (2024)



分子どうしを一緒に配置する｜三つの設定

# リサイクリング・段数・候補数は別の設定

### 反復は2種類ある

リサイクリング：共通部分の出力を入力へ戻し、分子の関係を計算し直す。

拡散の段数：共通部分の表現を条件に、原子座標を更新する回数。

候補数は反復ではなく、乱数（初期ノイズと途中のノイズ）を変えて作る構造の数。

**既定：リサイクリング3回・200段・1候補**

**演習：リサイクリング1回・20段・1候補**

### 三つの設定は、変える対象が違う

**recycling**

表現 → trunk → 表現 ↺

分子の関係を表す内部表現を再計算する。

**diffusion steps**

X(σ大) → X(σ中) → X(σ小)

1候補を生成する座標更新の段数。

**diffusion samples**

初期乱数① → 候補①　／　② → ②

乱数を変えて作る候補の数。

Boltz source 2.2.1 · b1ebfc4 · 参照 2026-10-09 / Boltz prediction documentation · b1ebfc4

予測を読む｜評価指標

# 構造の評価は一つの数で済まない

全体の折り畳み、局所の原子配置、鎖間の向き、低分子の結合位置は異なる評価対象。どの原子・鎖を見るかを決める。

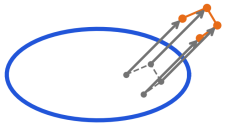
$$\mathrm{RMSD} = \sqrt{\frac{1}{N}\sum_i \|Rx_i + t - y_i\|^2}$$

RMSDは対応原子のずれの二乗平均の平方根。どの原子で重ね合わせたかで値が変わる。タンパク質を固定した低分子の評価では、その配置のずれが残る。対称原子の対応・欠損もそろえる。結合・衝突・立体化学も確認する。

参照：タンパク質と低分子



予測：タンパク質は一致、低分子はずれ



模型：青のタンパク質は一致。橙の低分子がずれ、灰の参照位置との差が残る。

Passaro et al., Boltz-2 (2025), bioRxiv / 本教材の導出・模型計算・演習

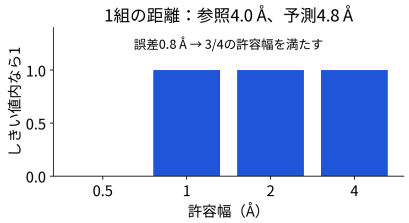


予測を読む｜評価指標

# 局所距離と界面の指標

lDDTは参照構造との局所距離が複数の許容幅に入るかを評価する。全体の剛体重ね合わせは不要。

右上は1組の距離だけの例。実際は評価対象の局所ペアに集計する。DockQは界面の複数指標を組み合わせ、鎖の対応も必要。一方、pLDDT・ipTMはモデルが予測した信頼度で、正解構造と比較して測った精度ではない。




参照構造と比較：lDDT・DockQ

測った精度と、予測された信頼度を分ける

正解なしでモデルが予測：pLDDT・ipTM

1組の距離差0.8 Åなら、許容幅0.5 Åは不合格、1・2・4 Åは合格となる。

lDDT: Mariani et al., Bioinformatics (2013), doi:10.1093/bioinformatics/btt473 / DockQ: Basu & Wallner, PLOS ONE (2016), doi:10.1371/journal.pone.0161879



予測の読み方

# 局所の形と、分子どうしの配置を分けて読む

### pLDDT：各部分の形への信頼度

タンパク質の各残基・低分子の各原子に付く。演習のグラフは0〜100。高いほど局所の配置が正しいとモデルが予測する。

### ipTM：分子間の配置への信頼度

0〜1の指標。分子の形が整っていても、相手に対する位置や向きが正しいとは限らないため、別に確認する。

### PAE：相対配置の予測誤差（Å）

行のトークンを基準に重ねたとき、列のトークンの位置にどれだけ誤差があると予測するか。小さいほど配置への信頼が高い。

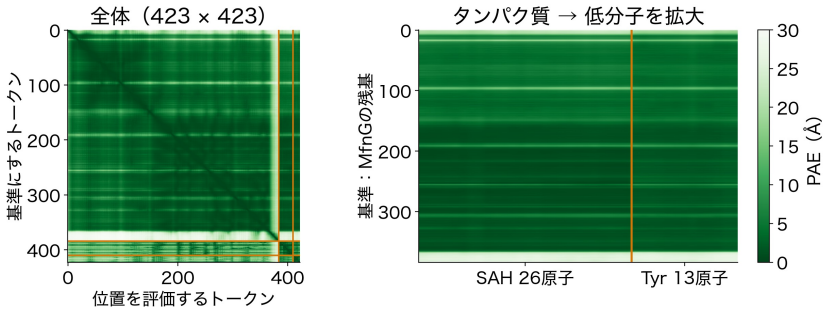
例えば「タンパク質を基準にした低分子の配置」を見たいなら、タンパク質の行と低分子の列の領域を見る。PAEは対称とは限らない。

これらはモデルが予測した信頼度。実験構造から測るRMSDやlDDT、結合の強さとは区別する。



信頼度を実データで読む

# 低分子の配置は、行列の分子間ブロックを見る




右は左の細い領域の拡大。タンパク質本体を基準にした低分子の位置と、C末端付近を基準にした位置では、予測誤差が異なる。

授業入力の実計算。20段・1候補。緑が濃いほどPAEが小さい。値は実測のずれではない。

まとめ

# 複合体予測の五つの問いへの答え

**なぜAF2の座標生成を変更するか**
多様な分子の全原子座標を共通に扱うため。AF2でも複数候補やタンパク質複合体は作れる。

**どう分子どうしの配置を予測するか**
分子間のペア表現を条件に、全原子を同じ座標系で更新する。

**どうノイズ除去を学習するか**
既知の構造へノイズを加え、元の座標を予測する課題を作る。

**なぜスコアで構造を生成できるか**
条件付き平均からスコアを得て、ノイズ量とともに分布を戻す更新に使う。

**予測のどこまでを信じてよいか**
局所と分子間の信頼度を分け、実験構造とのずれを確かめる。結合の強さや機能は別の検証が要る。



Boltz演習

# WebClass のリンクから、Colab で複合体を予測する

**1. 開く**
WebClass「06_演習」
のリンクから Colab へ

→

**2. 実行**
T4 GPU を選択
すべてのセルを実行

→

**3. 観察・保存**
信頼度・3D構造
実験構造との比較

入力：MfnG（鎖 A）、SAH（C）、チロシン（E）、配布した MSA。
Boltz 2.2.1、リサイクリング1回・20段・1候補・seed 42。

演習は20分を目安とし、採点・提出はない。初回の取得と計算待ちは環境による。
T4 が割り当てられない場合や間に合わない場合は、実行例のページの実行例を読む。
反復を減らした動作確認用の条件で、研究で精度を判断する標準条件ではない。



Boltz演習

# セルの順に、信頼度と構造を読む

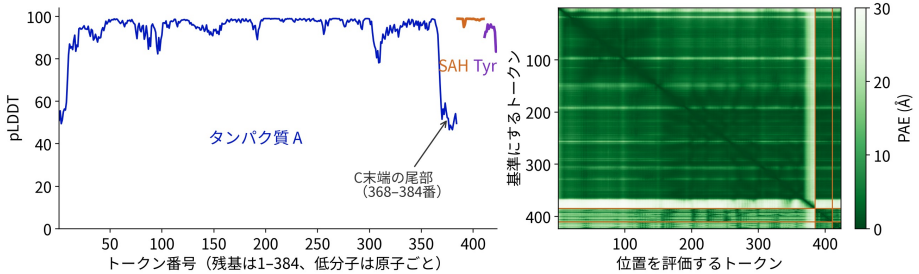
| 見るもの | 操作 | 対応する講義の内容 |
|---|---|---|
| **信頼度の数値** | セル5の ligand_iptm、鎖の組ごとの ipTM を読む | 分子間の信頼度 |
| **pLDDT と PAE** | グラフの縦線で鎖を区別する。低分子は原子ごとのトークン | 局所の信頼度と相対配置の誤差 |
| **立体構造** | セル6で回転・拡大し、低分子の位置を確認する | 同じ座標系への配置 |
| **実験構造** | セル7で 7UX8 と比べ、低分子のずれを読む | タンパク質で重ね合わせた RMSD |
| **条件を変える** | 余裕があれば sampling_steps を 40 へ変え、セル4〜7を再実行 | 段数と候補数の違い |

diffusion_samples は候補数で、sampling_steps とは意味が違う。
セル9の ZIP には入力・MSA・CIF・信頼度・実行条件・ログが入る。重みは含めない。



Boltz演習 | 実行例

# タンパク質の本体、尾部、低分子で信頼度が違う

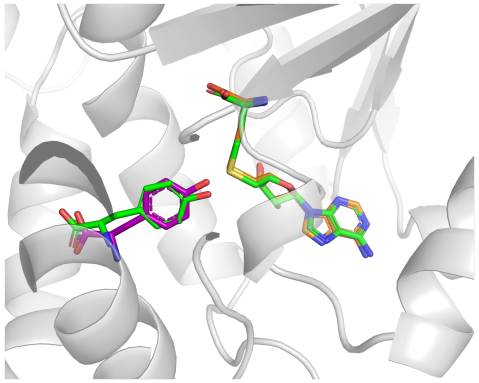



平均 pLDDT：本体（1–367番）94、C末端の尾部（368–384番）53、SAH 98、チロシン 92。ipTM 0.98。
タンパク質1鎖のため protein_ipTM = 0。これはタンパク質間の界面がないときの値で、低い信頼度という意味ではない。

2026-10-11 実行：T4、リサイクリング1回、20段、1候補。橙の線が鎖の境界。PAE の行が基準のトークン、列が位置を評価するトークン。

Boltz演習｜実行例

# 実験構造 7UX8 と比べて確かめる



緑：実験（7UX8 の鎖 B）、橙：SAH の予測、紫：チロシンの予測。タンパク質の Cα で重ね合わせた。

| 比べたもの | RMSD（Å） |
|---|---|
| **タンパク質の Cα（361残基）** | 0.68 |
| **SAH（26原子）** | 0.43 |
| **チロシン（13原子）** | 0.62 |

鎖 A と比べると SAH 0.58 Å、チロシン 1.02 Å。尾部（368番以降）は鎖 A でしか見えず、予測とはずれる。

**この一致から言えないこと**

7UX8 は2022年公開で、Boltz-2 の学習データの期限（2023年6月）より前の構造。未知の複合体に対する性能を示す結果ではない。

結晶は同じ鎖2本の組（二量体）だが、入力は1本の鎖である。



Boltz演習｜条件を変えて比較

# 20段と40段の結果を、同じ基準で比較する

| 変える条件 | そろえる条件 | 比較する出力 |
|---|---|---|
| **sampling_steps 20 → 40** | 入力・MSA・seed・候補数 | 計算時間・信頼度 |
| **1候補を作る更新回数** | タンパク質Cαで重ねる基準 | タンパク質・低分子のRMSD |

セル4の段数だけを変更し、セル4〜7を再実行する。最後の比較セルで保存済みの結果を並べ、低分子の位置と実験構造からのずれを見る。

段数を増やせば、この1例のRMSDが必ず下がるわけではない。信頼度と実際のずれを分けて比べる。GPUがない場合も、保存済みの20段の結果を回転して観察できる。



付録

# 拡散モデルの導出を、途中式から確認する


**A　確率と二乗誤差**
確率密度・分散・条件付き平均・ベイズ則

**B　DDPM**
順過程・逆過程・損失の導出・ノイズ予測と座標予測

**C　スコアと分布の生成**
スコア恒等式・逆時間の過程・確率流ODE

**D　Boltzの実装と数値計算**
尺度・重み・ノイズ列・追加ノイズ・積分法・参照文献




付録｜拡散モデルと学習

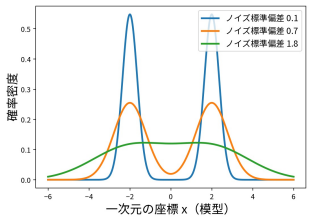
# 確率密度は面積で読む

## 1 確率密度は面積で読む

連続する座標xがちょうど一つの値を取る確率は0です。区間へ入る確率を、密度pの積分で表します。

密度そのものは1を超えても構いません。全領域の面積が1になることが条件です。

下図の二つの山は、二通りの状態が現れやすい模型。




## 2 正規分布でノイズを表す

正規分布は平均の周囲に広がる分布です。標準偏差σが大きいほど広がります。

標準正規分布からεを取り、σを掛けて平均μを足すと、望む分布を作れます。

多次元では各成分へ独立な標準正規ノイズを与える例から始めます。

$$p(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{(x-\mu)^2}{2\sigma^2}\right]$$

$$x = \mu + \sigma\epsilon, \quad \epsilon \sim \mathcal{N}(0,1)$$

三次元の原子座標では成分ごとの乱数を並べます。この独立な正規ノイズは生成計算の道具であり、分子に働く力そのものではありません。

本教材の導出・模型計算・演習 / Ho et al., Denoising Diffusion Probabilistic Models, NeurIPS (2020)

付録｜拡散モデルと学習

# 分散は尺度の二乗で変わる

## 1 分散は尺度の二乗で変わる

平均0・分散1の独立なε1、ε2を考える。和の分散は各項の分散の和になる。

係数aを掛けると、分散はaの二乗倍になります。

この二つの性質により、何段階も加えた正規ノイズを一つにまとめられます。

$$\mathrm{Var}(a\epsilon_1 + b\epsilon_2) = a^2 + b^2$$
$$\mathbb{E}[\epsilon_1\epsilon_2] = 0$$

## 2 独立なノイズの分散が足せる理由

平均0の独立なノイズε1、ε2を考えます。

二乗を展開すると交差項が出ますが、独立性と平均0からその期待値は0です。

係数そのものではなく、係数の二乗が分散へ掛かります。

$$\mathbb{E}[(a\epsilon_1+b\epsilon_2)^2] = a^2\mathbb{E}[\epsilon_1^2]+2ab\mathbb{E}[\epsilon_1\epsilon_2]+b^2\mathbb{E}[\epsilon_2^2]$$
$$\mathbb{E}[\epsilon_1\epsilon_2] = 0, \quad \mathrm{Var}(a\epsilon_1+b\epsilon_2) = a^2+b^2$$

本教材の導出・模型計算・演習 / Ho et al., Denoising Diffusion Probabilistic Models, NeurIPS (2020)



付録｜拡散モデルと学習

# 二乗誤差は条件付き平均を学ぶ

## 1 二乗誤差は条件付き平均を学ぶ

ノイズ座標xが同じでも、元の構造yには複数の可能性があります。

二乗誤差の期待値を最小にする答えは、yの条件付き平均です。平均との差と予測のずれに分けると分かります。

一回のノイズ除去が、元の構造を一意に復元するとは限りません。

$$\mu(x) = \mathbb{E}[y \mid x]$$
$$\mathbb{E}[\|y-a\|^2 \mid x]$$
$$= \mathbb{E}[\|y-\mu(x)\|^2 \mid x]+\|a-\mu(x)\|^2$$

続く導出では、平均を選ぶと誤差が最小になる理由を式の展開で確かめます。

## 2 平均を選ぶと二乗誤差が最小になる

ノイズを含む入力xを固定し、元データyの推定値dを選びます。

条件付き平均mを加えて引き、二乗を展開します。

残る二項のうち、dで変わるのは平均からの距離だけです。

$$m = \mathbb{E}[y \mid x]$$
$$\mathbb{E}[\|y-d\|^2 \mid x] = \mathbb{E}[\|y-m\|^2 \mid x]+\|m-d\|^2$$

E[y−m｜x]=0なので、二乗の展開に現れる交差項は消える。第1項はyの条件付き分散で、dに依存しない。第2項は||m−d||²≥0で、d=mのとき最小になる。平均を返すことと、分布から標本を生成することは別である。

Karras et al., Elucidating the Design Space···, NeurIPS (2022) / 本教材の導出・模型計算・演習



付録｜拡散モデルと学習

# 条件付き分布とベイズ則

## 条件付き分布は情報を固定する

配列や低分子の情報 $c$ を指定すると、知りたい分布は $p(x|c)$ である。

同じノイズ座標でも、条件が変わればもっともらしい構造は変わる。

導出では記号を簡単にするため条件を省くことがある。分子への応用では条件を戻す。

$$p(x \mid c) = \frac{p(x,c)}{p(c)}$$
$$p(x,c) = p(x \mid c)p(c)$$

ノイズ量も予測器へ渡す重要な情報だが、分子を指定する条件とは役割が違う。

## ベイズ則で逆向きに考える

正しい構造 $x_0$ からノイズ座標 $x_t$ を作る確率は、自分で決めた規則で書ける。

逆に $x_t$ から $x_0$ を推測するには、構造が元々どの程度現れるかという分布も必要である。

分母は、取り得るすべての元の構造について足し合わせた密度である。

$$p(x_0 \mid x_t) = \frac{q(x_t \mid x_0)p_{\mathrm{data}}(x_0)}{p_t(x_t)}$$
$$p_t(x_t) = \int q(x_t \mid x_0)p_{\mathrm{data}}(x_0)\,dx_0$$

逆向きの推論が、前向きの式を逆算するだけでは済まない理由がここにある。

Ho et al., Denoising Diffusion Probabilistic Models, NeurIPS (2020) / Passaro et al., Boltz-2 (2025), bioRxiv / Karras et al., Elucidating the Design Space···, NeurIPS (2022)



付録｜拡散モデルと学習

# 段階ごとに少しずつノイズを加える

## 1 段階ごとに少しずつノイズを加える

DDPMは離散的な時刻tでノイズを加えるモデルです。元のデータをx0とします。

βtは一段で加えるノイズの分散で、0と1の間に取ります。元の信号は少し縮めます。

各段は直前だけに依存するマルコフ過程です。

$$q(x_t \mid x_{t-1}) = \mathcal{N}(\sqrt{1-\beta_t}x_{t-1}, \beta_t I)$$
$$x_t = \sqrt{\alpha_t}x_{t-1}+\sqrt{\beta_t}\epsilon_t, \quad \alpha_t = 1-\beta_t$$

## 2 二段分のノイズをまとめる

二段目の式へ一段目を代入すると、信号の係数は平方根の積になります。

二つのノイズは独立なので、分散は係数の二乗の和です。

その和が1−α1α2になることを、β=1−αを使って確かめます。

$$x_2 = \sqrt{\alpha_2\alpha_1}x_0+\sqrt{\alpha_2\beta_1}\epsilon_1+\sqrt{\beta_2}\epsilon_2$$
$$\alpha_2\beta_1+\beta_2 = 1-\alpha_1\alpha_2$$

Ho et al., Denoising Diffusion Probabilistic Models, NeurIPS (2020) / 本教材の導出・模型計算・演習

# 二段のノイズを数値で確かめる

例としてα1=α2=0.9、β1=β2=0.1とします。

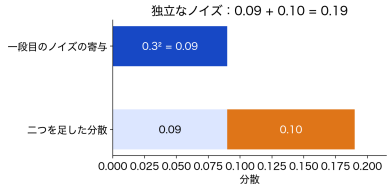
信号の係数は0.9、ノイズ分散は0.19です。

標準偏差は√0.19です。0.19をそのままノイズへ掛けないようにします。

$$x_2 = 0.9x_0 + 0.3\epsilon_1 + \sqrt{0.1}\epsilon_2$$

$$0.3^2 + (\sqrt{0.1})^2 = 0.19$$

$$x_2 \overset{d}{=} 0.9x_0 + \sqrt{0.19}\epsilon$$

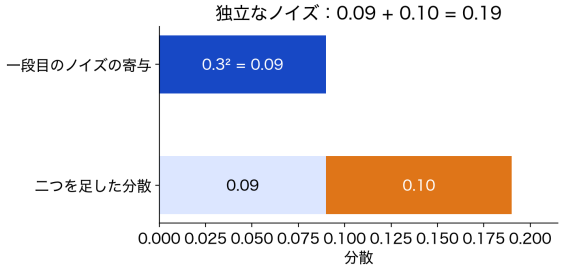



信号係数は√0.9×√0.9=0.9。第1段のノイズの係数は√(0.9×0.1)=0.3、第2段は√0.1となる。独立なノイズの分散を足すと0.09+0.10=0.19。式の等号は分布が一致することを表し、同じ乱数値になるという意味ではない。





# 分散の合成を、係数から順に追う




**係数 → 分散 → 標準偏差**

① 係数は0.3と√0.1。
② 二乗して0.09と0.10。
③ 独立なので足して0.19。
④ 平方根√0.19を標準正規乱数へ掛ける。

$$x_2 \overset{d}{=} 0.9x_0 + \sqrt{0.19}\epsilon$$

dを付けた等号は分布の一致。同じ乱数値という意味ではない。





# 任意の段階へ直接進める

## 1 任意の段階へ直接進める

αの累積積をᾱtと書きます。前の計算を繰り返すと、t段後の分布が分かります。

学習で時刻tのノイズ座標を作るために、1段目から順に計算する必要はありません。

元のデータと一つの正規ノイズだけで直接作れます。

$$\bar{\alpha}_t = \prod_{s=1}^{t} \alpha_s$$

$$q(x_t \mid x_0) = \mathcal{N}(\sqrt{\bar{\alpha}_t}x_0, (1-\bar{\alpha}_t)I)$$

$$x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1-\bar{\alpha}_t}\epsilon$$

条件付き分布が一致するという主張です。

## 2 終点を単純な分布へ近づける

ᾱtが十分小さくなると、元の信号の係数は小さくなり、分散は1へ近づきます。

このため最後の分布を標準正規分布で近似し、生成の出発点にできます。

有限の段階では厳密に同一とは限りません。ノイズ列と終点の近似を区別します。

$$\bar{\alpha}_T \simeq 0 \quad \Rightarrow \quad x_T \simeq \epsilon, \quad \epsilon \sim \mathcal{N}(0, I)$$

元データに掛かる係数が十分小さくなると、最後の座標の大部分は正規ノイズで決まります。このため生成を単純な分布から始められます。ただし、有限の段数では元データの影響が厳密にゼロとは限りません。終点の近似をよくすることと、一段ごとの学習をよくすることは異なる課題です。学習目標の分解で終点の項が現れるのは、この一致も必要だからです。実装ではノイズの範囲と段数を一緒に確認します。





# 逆向きの遷移を学習する

生成ではxTから始め、xtが与えられたときのxt−1の分布を学習します。

ネットワークが平均を予測し、必要に応じてノイズを加えて一段進めます。

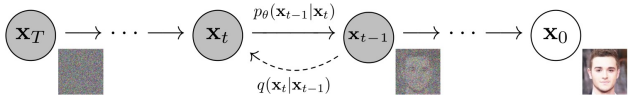
真の逆向き分布は、元のデータ分布に依存します。小刻みな遷移を正規分布で近似します。

$$p_\theta(x_{0:T}) = p(x_T)\prod_{t=1}^{T} p_\theta(x_{t-1} \mid x_t)$$

$$p_\theta(x_{t-1} \mid x_t) = \mathcal{N}(\mu_\theta(x_t, t), \Sigma_\theta(x_t, t))$$

前向きの過程では、ノイズを加える規則を自分で決めました。逆向きでは、その観測を生んだ元のデータがどのように分布するかを知らなければなりません。ネットワークはこの逆向きの遷移を近似します。一つの段の平均と分散が分かれば、平均へ乱数を加えて次の座標を作れます。最後から順に繰り返すことで元データ側へ近づきます。真の逆遷移がどんな刻みでも正規分布になるという主張ではなく、小さな遷移を扱いやすい分布で近似する設計です。

# DDPM原著の図で二つの向きを読む




## DDPM原著の図で二つの向きを読む

qはデータからノイズへ進む、あらかじめ定めた過程です。pθは逆向きの遷移を学習します。

同じ変数の列でも、どちらを条件にして次を求めるかが違います。

原著の有向グラフを見て、二種類の矢印をたどります。

まず元のデータを固定した順方向では、ノイズを加える規則が既知なので、学習せずに途中の座標を作れます。

Ho et al., NeurIPS (2020) · Fig. 2より





# 学習時には正解x0が分かる

## 1 学習時には正解x0が分かる

生成時には未知のx0も、学習時にはデータとして既知です。

x0とxtを両方条件にしたxt−1の分布は、二つの正規分布の積から計算できます。

この計算可能な分布へ、モデルの逆遷移を近づけます。

$$q(x_{t-1} \mid x_t, x_0) \propto q(x_t \mid x_{t-1}) q(x_{t-1} \mid x_0)$$

## 2 平方完成のために変数を一つにする

zを一段前の座標と置き、zに依存する項だけを書きます。

一つ目は今の座標xtを説明する尤度、二つ目は元データx0からの分布です。

定数はzに依存しない項です。

$$z = x_{t-1}, \quad v = 1 - \bar{\alpha}_{t-1}$$

$$\log q(z \mid x_t, x_0) = -\frac{\|x_t - \sqrt{\alpha_t} z\|^2}{2\beta_t} - \frac{\|z - \sqrt{\bar{\alpha}_{t-1}} x_0\|^2}{2v} + \text{const.}$$





# 二次係数と一次係数を集める

## 1 二次係数と一次係数を集める

二つの二乗を展開し、zの二次係数Aと一次係数bをまとめます。

zをAの逆数とbの積だけずらすと、一次項を消せます。

したがって事後分散はAの逆数、平均はb/Aです。

$$A = \frac{\alpha_t}{\beta_t} + \frac{1}{v}, \quad b = \frac{\sqrt{\alpha_t}}{\beta_t} x_t + \frac{\sqrt{\bar{\alpha}_{t-1}}}{v} x_0$$

$$-\frac{A}{2}\|z\|^2 + b^\top z = -\frac{A}{2}\|z - b/A\|^2 + \text{const.}$$

## 2 正規分布の積を平方完成する

xt−1に依存する二つの二乗項を展開し、二次と一次の係数を集めます。

精度は分散の逆数です。正規分布の積では精度が加算されます。

式の逆数が事後分散になります。tが2以上の段階で導出します。

$$\frac{1}{\tilde{\beta}_t} = \frac{\alpha_t}{\beta_t} + \frac{1}{1 - \bar{\alpha}_{t-1}}$$

$$\tilde{\beta}_t = \frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t} \beta_t$$





# 事後分散の分母を整理する

## 1 事後分散の分母を整理する

Aの二つの項を通分します。

αtとβtの和が1、累積積がαt ᾱt−1であることを使います。

逆数を取ると、前ページの事後分散が得られます。

$$A = \frac{\alpha_t(1 - \bar{\alpha}_{t-1}) + \beta_t}{\beta_t(1 - \bar{\alpha}_{t-1})}$$

$$\alpha_t(1 - \bar{\alpha}_{t-1}) + \beta_t = 1 - \bar{\alpha}_t$$

$$A^{-1} = \frac{\beta_t(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t}$$

0<αt<1の条件から、式の事後分散が正であることも確認できる。

## 2 事後平均は二つの情報を混ぜる

平方完成で残った一次の係数へ事後分散を掛けると平均が得られます。

x0の情報とxtの情報を、ノイズの大きさに応じて混ぜています。

これは学習用に計算できる平均で、生成時にx0を参照できるという意味ではありません。

$$\tilde{\mu}_t = \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1 - \bar{\alpha}_t} x_0 + \frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t} x_t$$

係数は前ページの一次項へ事後分散を掛けて得られます。式が長く見えても、新しい学習パラメータが増えたわけではありません。既知のノイズ列から決まる量です。後で元データをノイズの式へ置き換え、ネットワークが予測できる形に直します。

# 尤度を直接計算するのは難しい

## 1 尤度を直接計算するのは難しい

観測したx0の確率は、途中のすべての座標を積分して求めます。高次元ではこの積分が難しくなります。

既知の順過程qで割って掛けると、qに関する期待値へ書き換えられます。

対数の凹性から、期待値を内側へ移した下限を得ます。

$$\log p_\theta(x_0) = \log \mathbb{E}_q\left[\frac{p_\theta(x_{0:T})}{q(x_{1:T} \mid x_0)}\right]$$

$$\log p_\theta(x_0) \geq \mathbb{E}_q\left[\log \frac{p_\theta(x_{0:T})}{q(x_{1:T} \mid x_0)}\right]$$

## 2 下限を段階ごとの誤差に分ける

下限の符号を反転して最小化する損失にします。終点の一致、中間の逆遷移、最後の復元に分けられます。

KLダイバージェンスは、二つの分布の違いを測る非負の量です。

中間段階では、計算できる事後分布とモデルの分布を近づけます。

$$L = L_T + \sum_{t=2}^{T} L_{t-1} + L_0$$

$$L_{t-1} = \mathbb{E}_q D_{\mathrm{KL}}\big(q(x_{t-1} \mid x_t, x_0) \| p_\theta(x_{t-1} \mid x_t)\big)$$

和の添字がどこからどこまでかも見てください。最後の復元は中間の正規事後と同じ扱いにできないため、別の項になっています。





# 固定分散なら平均の二乗誤差になる

## 1 固定分散なら平均の二乗誤差になる

二つの正規分布の分散を固定して比較すると、重みに依存する部分は平均の差の二乗です。

モデルの平均を事後平均へ近づけることで、逆遷移のKLを小さくできます。

時刻ごとの係数は異なります。これを無視する簡略損失とは区別します。

$$L_{t-1} = \mathbb{E}_q\left[\frac{\|\tilde{\mu}_t - \mu_\theta(x_t, t)\|^2}{2\sigma_t^2}\right] + \text{const.}$$

## 2 元の座標の代わりにノイズを予測する

xtを作った式をx0について解けば、ノイズεが分かればx0も計算できます。

事後平均へ代入すると、平均の予測をノイズ予測で表せます。

εθは実際に加えたノイズを完全に知るのではなく、入力から推定します。

$$x_0 = \frac{x_t - \sqrt{1-\bar{\alpha}_t}\epsilon}{\sqrt{\bar{\alpha}_t}}$$

$$\mu_\theta = \frac{1}{\sqrt{\alpha_t}}\left(x_t - \frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}}\epsilon_\theta(x_t, t)\right)$$





# ノイズ予測の損失に付く係数

## 1 ノイズ予測の損失に付く係数

モデル平均と事後平均の差を、ノイズの予測誤差で書き直します。

同じxtの項は差を取ると消えます。

平均の二乗誤差へ代入すると、時刻に依存する係数が残ります。

$$\tilde{\mu}_t - \mu_\theta = \frac{\beta_t}{\sqrt{\alpha_t}\sqrt{1-\bar{\alpha}_t}}(\epsilon_\theta - \epsilon)$$

$$L_{t-1} = \mathbb{E}\left[\frac{\beta_t^2}{2\sigma_t^2 \alpha_t (1-\bar{\alpha}_t)}\|\epsilon - \epsilon_\theta\|^2\right] + \text{const.}$$

## 2 簡略損失で何を学ぶのか

元のデータ、時刻、一つのノイズを取り、ノイズを予測する二乗誤差を計算します。

DDPMの簡略損失は、変分下限の時刻依存の重みをそのまま使わず、学習を重み付けし直します。

同じノイズ座標に複数の元データが対応するため、最適な予測は条件付き平均です。

$$x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1-\bar{\alpha}_t}\epsilon$$

$$L_{\text{simple}} = \mathbb{E}_{t,x_0,\epsilon}\|\epsilon - \epsilon_\theta(x_t, t)\|^2$$





# ノイズを当てるとスコアを学べる理由

補足導出：X=aY+bε、ε~N(0,I)、aとb>0は固定。ネットワークはXからεを二乗誤差で予測する。

$$\epsilon_*(x) = \arg\min_u E[\|\epsilon - u\|^2 \mid X = x] = E[\epsilon \mid x]$$

1 条件付き平均が二乗誤差の最適解。

$$\nabla_x \log q(x \mid y) = -\frac{x - ay}{b^2} = -\frac{\epsilon}{b}$$

2 条件付きの正規密度は既知なので微分できる。

$$\nabla_x \log p(x) = E[\nabla_x \log q(x \mid Y) \mid x]$$

3 積分の微分とベイズ則で、周辺のスコアへ移す。

$$s_*(x) = -\frac{\epsilon_*(x)}{b}, \quad b = \sqrt{1-\bar{\alpha}_t}$$

4 DDPMでは信号の減衰aとノイズ尺度bを取り違えない。

条件付き平均E[ε｜X=x]を求めることで、周辺密度のスコアを推定できる。

教師εは自分で発生させる乱数。未知のp(x)を評価せず、その対数勾配を学習できる。

付録｜拡散モデルと学習

# 生成の一段を実行する

## 1 生成の一段を実行する

標準正規分布から初期座標を取り、時刻を大きい方から小さい方へ進めます。

各段階で予測したノイズから平均を計算し、選んだ分散に従うノイズを加えます。

最後の段階の分散や出力の扱いはモデルの定義に合わせます。

$$x_{t-1} = \mu_\theta(x_t, t) + \sigma_t z, \quad z \sim \mathcal{N}(0, I)$$

大きなノイズから始め、現在の座標と段階をネットワークへ渡し、予測ノイズを使って平均を計算します。その平均へ必要なランダム成分を足して一段前へ進みます。最後の段で同じようにノイズを加えるかは、定義した生成手順に従います。学習では任意の段を直接作れましたが、生成ではこの逆向きの更新を順にたどる必要があります。二つの計算手順を混同しないようにします。

## 2 画像の式を分子へ移すとき

画像の画素の代わりに、各原子の三次元座標を並べたベクトルを考えられます。

ただし分子には回転・並進、原子の対応、化学結合やキラリティーがあります。

BoltzはDDPMの式をそのまま使わず、連続的なノイズ量を用いた尺度調整と生成を採用します。

DDPM：離散段階を理解 → スコア：密度との関係 → EDM：尺度と数値計算 → Boltz：原子座標への設計

正規ノイズを使うという共通点だけで、画像用のモデルをそのまま分子へ移せるわけではありません。この節で学んだ確率と学習の考え方を、分子表現や座標の重ね合わせと組み合わせます。Boltzの説明では、その追加の設計を一つずつ確認します。

Ho et al., Denoising Diffusion Probabilistic Models, NeurIPS (2020) / Karras et al., Elucidating the Design Space···, NeurIPS (2022) / Passaro et al., Boltz-2 (2025), bioRxiv



付録｜拡散モデルと学習

# 学習時と生成時で、使える情報が違う

学習用の事後平均は正解x0を条件にする。生成時にはx0を使わず、学習済みネットワークの予測で置き換える。

学習では既知のノイズを教師にする。生成では観測したノイズ座標から、除去に必要な量を推定する。

次はデノイザーとスコアがどう結びつくかを導きます。

学習：x0と加えたノイズが既知 → 生成：ノイズ座標から推定 → 同じネットワークを全段で使用

学習用の事後平均の式には、元データの座標が現れました。生成の式には、その代わりに学習した予測が必要です。学習時と生成時で参照できる情報を分けます。学習時に使える正解を生成時にも読んでしまうコードでは、本当の予測になりません。次に学ぶスコアの関係も、理想的な教師の性質と、ネットワークが実際に近似する量を分けて読みます。

Ho et al., Denoising Diffusion Probabilistic Models, NeurIPS (2020)



付録｜本編の式と実装の補足

# 加えたノイズを当てると、戻す方向が分かる

**学習時は元データと加えたノイズを知っている。生成時はネットワークが予測する。**

$$x_t = \sqrt{\bar{\alpha}_t}\, x_0 + \sqrt{1-\bar{\alpha}_t}\, \epsilon, \qquad \bar{\alpha}_t = \prod_{s=1}^{t} (1-\beta_s)$$

$$L_{\text{simple}} = \mathbb{E}_{t, x_0, \epsilon}\left[\|\epsilon - \epsilon_\theta(x_t, t)\|^2\right]$$

原著の単純化した損失でノイズを予測し、生成時には次の平均へ戻す。

$$\mu_\theta(x_t, t) = \frac{1}{\sqrt{\alpha_t}}\left(x_t - \frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}}\epsilon_\theta(x_t, t)\right), \qquad \alpha_t = 1 - \beta_t$$

DDPM はこの平均と、設定した分散の乱数から一段前の値を作る。

**Boltz への接続：尺度を変え、ノイズ予測を元の座標の予測に書き換える**

$$x = x_t/\sqrt{\bar{\alpha}_t} = x_0 + \sigma\epsilon, \quad \sigma^2 = (1-\bar{\alpha}_t)/\bar{\alpha}_t, \quad D = x - \sigma\epsilon_\theta$$

座標の尺度を変えるとつながる。Boltz のスケジュール・損失・更新則は DDPM 原著と同一ではない。

Ho, Jain & Abbeel, Denoising Diffusion Probabilistic Models (2020), Fig. 1–2・式(4)(11)(14) / Karras et al. (2022)



付録｜拡散モデルと学習

# 積分の中の正規密度を微分する

加法ノイズx=y+σεで平滑化した密度を考えます。

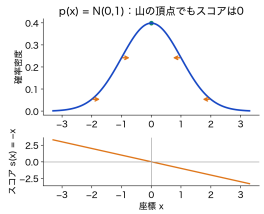
正規密度の指数をxで微分すると、差y−xとσ²の逆数が出ます。

微分と積分を交換できる条件の下で、その結果を積分へ戻します。

$$p_\sigma(x) = \int p_0(y)\, \phi_\sigma(x-y)\, dy$$

$$\nabla_x \phi_\sigma(x-y) = \frac{y-x}{\sigma^2}\phi_\sigma(x-y)$$

$$\nabla_x p_\sigma(x) = \int \frac{y-x}{\sigma^2} p_0(y) \phi_\sigma(x-y)\, dy$$




yは元データ、xはノイズを加えた観測。積分では、xを生じうるすべてのyの寄与を足す。正規密度の指数−||x−y||²/(2σ²)をxで微分すると(y−x)/σ²となり、密度そのものを掛ける。これを積分へ代入し、pσ(x)で割ると、次頁の条件付き平均が現れる。

Song et al., Score-Based Generative Modeling through SDEs, ICLR (2021) / Karras et al., Elucidating the Design Space···, NeurIPS (2022) / 本教材の導出・模型計算・演習

# ベイズ則を使って条件付き平均にする

## 1 ベイズ則を使って条件付き平均にする

対数の微分は、密度の微分を密度で割ったものです。

積分中の密度の積をpσ(x)で割ると、元データyの事後分布になります。

その分布の平均が、最適なデノイザーDです。

$$\frac{p_0(y)\phi_\sigma(x-y)}{p_\sigma(x)} = p(y \mid x)$$

$$\nabla_x \log p_\sigma(x) = \frac{1}{\sigma^2}\int (y-x)p(y \mid x)\,dy$$

$$s(x,\sigma) = \frac{D(x,\sigma)-x}{\sigma^2}$$

ここまでの等式は、理想的な条件付き平均についての関係です。学習したネットワークでは近似誤差も残ります。

## 2 条件付き平均がスコアになる

微分した密度を元の密度で割ると、積分の重みがベイズ則の条件付き分布になります。

その積分に現れるyの平均が、最適なデノイザーです。

近似ネットワークでは等号が近似になります。ノイズ量の二乗で割る点が重要です。

$$\nabla_x \log p_\sigma(x) = \frac{\mathbb{E}[y \mid x]-x}{\sigma^2}$$

$$s_\theta(x,\sigma) = \frac{D_\theta(x,\sigma)-x}{\sigma^2}$$

大きなノイズで平均の予測がぼやけることと、その予測を使って生成できることは両立します。どの更新式で利用するかが次の問題です。





# なぜランジュバン法で分布を保てるか

補足導出：目標密度πは正で滑らかとし、境界で確率が流出しない場合を考える。スコアs=∇logπは密度の対数の勾配。

$$dX = s(X)\,dt + \sqrt{2}\,dW_t$$

$$\partial_t p = -\nabla\cdot(sp) + \Delta p = -\nabla\cdot J$$

$$J = sp - \nabla p, \quad J\big|_{p=\pi} = \pi\nabla\log\pi - \nabla\pi = 0$$

$$\pi \propto e^{-\beta U} \implies s = -\beta\nabla U = \beta F$$

1 ドリフトで密度の高い側へ動き、ノイズで広がる。

2 Fokker–Planck方程式で、標本の動きを密度の動きへ変える。

3 ∇logπ=(∇π)/πを代入すると、流入と流出が釣り合う。

4 定常であることと、短時間でその分布へ到達することは別。

例：π=N(0,1)なら s(x)=−x。揺らぎを除くと原点へ収束し、分散1の標本にはならない。





# 離散化すると定常分散もずれる

補足計算：π=N(0,1)、刻みη>0のEuler離散化。ξは各段で独立な標準正規乱数。

1 s(x)=−xを代入する。ノイズと現在値は独立。

$$X_{k+1} = (1-\eta)X_k + \sqrt{2\eta}\,\xi_k$$

2 両辺の分散を取り、交差項を独立性で消す。

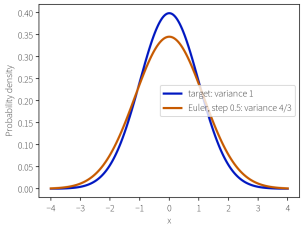
$$v_{k+1} = (1-\eta)^2 v_k + 2\eta$$

3 定常なら前後の分散が同じ。0<η<2で安定。

$$v_* = \frac{2\eta}{1-(1-\eta)^2} = \frac{1}{1-\eta/2}$$

4 標本数を増やしても、この離散化によるずれは消えない。

$$\eta = 0.1:\ v_* \simeq 1.053, \quad \eta = 0.5:\ v_* = 1.333$$




青は目標分布、橙は有限刻みでの定常分布。有限刻みでは分散が増え、曲線が横に広がる。
この解析例では、標本数を増やしても積分法の偏りは残る。

区別：有限刻みの偏り、初期分布の影響、有限標本のばらつきは、それぞれ原因が違う。





# 連続時間の順過程を定義する

## 1 連続時間の順過程を定義する

時刻tを連続にし、決まった向きの変化fとランダムな変化を合わせます。

Wはウィーナー過程で、短い時間dtの増分の分散がdtになります。

ここではノイズの強さgは時刻だけに依存するとします。座標依存の場合は追加項が必要です。

$$dx = f(x,t)\,dt + g(t)\,dW_t$$
$$\Delta W \sim \mathcal{N}(0, \Delta t\, I)$$

ブラウン運動の増分の分散は時間幅に比例し、標準偏差は時間幅の平方根になります。したがって離散化すると、決定的な項とランダムな項で時間幅の掛かり方が違います。この節ではノイズ係数が位置に依存しない場合を扱い、より一般的な式と混ぜません。

## 2 密度が変わる式を見る

確率微分方程式に従う多数の標本を考えると、密度の時間変化はFokker–Planck方程式に従います。

第一項は流れによる密度の移動、第二項はノイズによる広がりです。

∇・は流れの発散、Δは各座標に関する二階微分の和です。

$$\partial_t p_t = -\nabla\cdot(f\,p_t) + \frac{g(t)^2}{2}\Delta p_t$$

一つの標本の動きと、多数の標本からなる密度の動きを区別します。発散の項はドリフトで密度が運ばれる効果、ラプラシアンの項はノイズで密度が広がる効果です。係数の二分の一は後の確率流にも残るので、ここで見ておきます。式を読みながら、ノイズだけのときに鋭い山がなだらかになる図を思い浮かべてください。

付録｜拡散モデルと学習

## 密度の式はTaylor展開から導ける

補足導出：滑らかな試験関数φと、位置に依存しないノイズ係数g(t)を用いる。境界項は0とする。

$$\Delta X = f\,h + g\sqrt{h}\,\xi, \quad E[\xi]=0,\ E[\xi\xi^T]=I$$

1 平均変位はh、ランダム変位は√hの大きさ。

$$\frac{E[\Delta\varphi \mid X=x]}{h} \to f\cdot\nabla\varphi + \frac{g^2}{2}\Delta\varphi$$

2 二次のTaylor項も平均するとhの次数で残る。

$$\frac{d}{dt}\int \varphi p\,dx = \int \left(f\cdot\nabla\varphi + \frac{g^2}{2}\Delta\varphi\right) p\,dx$$

3 密度で平均する。φは時間に依存しない関数。

$$\int \varphi\,\partial_t p\,dx = \int \varphi\left[-\nabla\cdot(fp) + \frac{g^2}{2}\Delta p\right] dx$$

4 部分積分を1回・2回行い、微分をφからpへ移す。

任意のφについて成り立つので、$\partial_t p = -\nabla\cdot(fp) + (g^2/2)\Delta p$。1/2はTaylor展開の二次項から来る。



付録｜拡散モデルと学習

## 逆時間ではスコアが必要になる

### 1 逆時間ではスコアが必要になる

順過程が分布を広げる一方、逆向きには広がった分布から元の領域へ戻す必要があります。

逆時間のドリフトには、密度のスコアを使った補正が現れます。

式では時間をTから0へ積分し、dtは負です。ノイズ増分の分散には時間幅の絶対値を使います。

$$s_t(x) = \nabla_x \log p_t(x)$$
$$dx = [f(x,t) - g(t)^2 s_t(x)]\,dt + g(t)\,d\bar{W}_t$$
$$dt < 0$$

表示した式では時刻を減らす向きで積分しています。時間幅を正の数として書き直した式と比べるときには、時間の符号も同時に変えてください。符号だけを見て引力と斥力を判断すると誤りやすくなります。

### 2 符号を短い一段で確かめる

順過程のドリフトが0、戻る時間幅がh>0の場合を考えます。

dt=−hなので、逆時間の補正はプラスのスコア方向です。密度の高い領域へ向かいます。

ノイズを加える向きは決まっていません。分散はgの二乗とhの積です。

$$x_{t-h} \simeq x_t + h\,g(t)^2 s_\theta(x_t,t) + g(t)\sqrt{h}\,\xi$$

戻る幅h>0に対してdt=−h。$-g^2 s$に−hを掛けるため、平均変位は$+hg^2 s$となる。ノイズの分散は$g^2 h$、標準偏差は$g\sqrt{h}$。スコアによる平均変位と、ランダムな揺らぎを区別する。



付録｜拡散モデルと学習

## 逆向きの補正は確率の流れから読む

補足導出：逆向きの時計τ=T−tとqτ=pT−τを定義する。gは時刻のみに依存し、密度は正で滑らかとする。

$$J_t = f\,p_t - \frac{g^2}{2}\nabla p_t, \quad \partial_t p_t = -\nabla\cdot J_t$$

1 順過程の確率流。逆向きではこの流れが反転する。

$$\bar{J}_\tau = b q_\tau - \frac{g^2}{2}\nabla q_\tau = -J_{T-\tau}$$

2 同じ拡散係数を持つ逆過程のドリフトbを求める。

$$bq - \frac{g^2}{2}\nabla q = -fq + \frac{g^2}{2}\nabla q$$

3 広がる作用は逆過程にも残るため、ドリフトで補う。

$$b = -f + g^2\nabla\log q, \quad dY_\tau = b\,d\tau + g\,dW_\tau$$

4 qで割る。dτ>0の式なので、スコアの係数は正。

山を広げるノイズが残っている分も含めて、山へ戻す必要があると考えると、補正の役割が分かります。

これは逆過程の式の直観的導出。時間反転の成立には正則性条件が必要で、密度だけの一致では経路法則まで一意に決まらない。



付録｜拡散モデルと学習

## 同じ密度を運ぶ常微分方程式

密度の二階微分は、密度とスコアの積の発散として書けます。

Fokker–Planck方程式を、速度場が密度を運ぶ連続の式へ書き換えます。

この速度場で標本を動かすと、理想的には同じ時刻の密度が得られます。

$$\Delta p = \nabla\cdot(p\nabla\log p)$$
$$\partial_t p = -\nabla\cdot\left[\left(f - \frac{g^2}{2}s\right)p\right]$$
$$\frac{dx}{dt} = f - \frac{g^2}{2}s$$

確率流の式は、密度の時間変化を決定的な速度場で表し直したものです。出発点を分布から引けば、各標本の動きが決定的でも集団として分布を作れます。逆確率過程のランダム項を消しただけでは密度の式が変わります。二階微分をスコアを含む発散へ書き直すことで、必要な速度が導かれます。続く途中式で係数の由来を確かめます。

# 密度の式を速度場として読み直す

## 1 密度の式を速度場として読み直す

この節ではノイズ係数gが時刻だけに依存すると仮定します。

密度の勾配をpとスコアの積へ置き換えます。

確率流の速度vを使うと、密度の保存を表す連続の式になります。

$$\partial_t p = -\nabla \cdot (f p) + \frac{1}{2} g^2 \Delta p$$

$$\Delta p = \nabla \cdot (p s)$$

$$\partial_t p = -\nabla \cdot (v p), \quad v = f - \frac{1}{2} g^2 s$$

スコアの前の二分の一は、密度の拡散項にもともとあった係数から来ています。ノイズだけを削除する操作で得た式ではないことが、この導出から分かります。

## 2 逆SDEと確率流ODEの違い

逆SDEは各段階でもランダムノイズを加えます。確率流ODEは初期値を決めれば決定的に進みます。

スコアが正確で適切に積分できれば、時刻ごとの分布は同じになります。

一つ一つの経路は同一ではありません。近似スコアと有限刻みでは結果も変わります。

逆SDE：補正係数 $g^2$ とノイズ → 確率流ODE：補正係数 $g^2/2$ → 同じ周辺分布・異なる経路

同じ時点の密度が一致することは、同じ初期点から同じ経路を通ることではありません。確率的な過程には途中にも乱数が入り、決定的な過程では初期値から経路が定まります。理想的なスコアと正確な積分という条件を離れると、有限の計算では出力分布にも差が出ます。実用上は計算量と結果を比較して手順を選びます。





# 確率流ODEの1/2を導く

補足導出：確率密度を速度vで運ぶ連続の式と、Fokker–Planck方程式を比べる。

1 順過程ではドリフトによる移流と、ノイズによる拡散が共存する。

$$\partial_t p = -\nabla \cdot (f p) + \frac{g^2}{2} \Delta p$$

2 密度が正の領域で、∇p=p∇logpを使う。

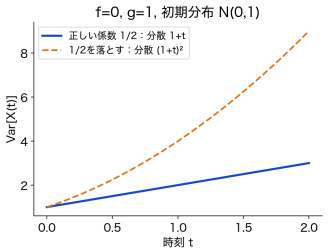
$$\Delta p = \nabla \cdot \nabla p = \nabla \cdot (p \nabla \log p)$$

3 共通の発散へまとめる。ここには新しいランダム項を加えない。

$$\partial_t p = -\nabla \cdot \left[ \left( f - \frac{g^2}{2} s \right) p \right]$$

4 同じ時刻ごとの密度を運ぶ速度を読む。初期点の分布は必要。

$$\frac{dX}{dt} = f(X,t) - \frac{g(t)^2}{2} s_t(X)$$



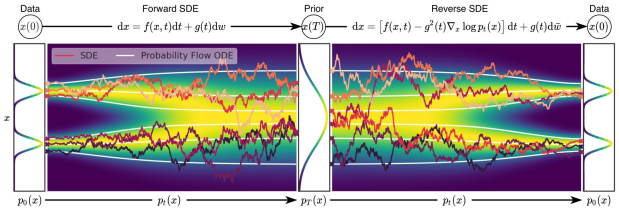

速度 x/[2(1+t)] が正しい分散増加を再現。

理想的なスコア・正しい初期分布・厳密な積分の下で密度が一致する。ODEとSDEの個々の軌道は一致しない。





# 原著の図で順過程と逆過程を読む




### 原著の図で順過程と逆過程を読む

左はデータをノイズへ広げる過程、右はノイズからデータへ戻る過程です。

背景色は密度、曲線は標本の経路です。同じ時刻の分布が同じでも、経路は異なります。

左右の外側には元のデータ分布、中央にはノイズの分布があります。

ギザギザの線は確率微分方程式による標本、滑らかな線は確率流の常微分方程式による標本です。

Song et al., ICLR (2021), Fig. 2 · 原著図の引用





# 加える分散をσで表す

## 1 加える分散をσで表す

信号を縮めず、元データへ分散σの二乗のノイズを足す場合を考えます。

順過程の分散増加率をgの二乗に対応させます。

これを確率流ODEへ代入し、時間の代わりにノイズ標準偏差σを変数にします。

$$g(t)^2 = \frac{d\sigma(t)^2}{dt} = 2\sigma\dot{\sigma}$$

$$\frac{dx}{d\sigma} = -\sigma s(x,\sigma) = \frac{x - D(x,\sigma)}{\sigma}$$

## 2 ノイズ量を下げて生成する

σを大きい値から小さい値へ進めるので、刻みΔσは負になります。

x−Dはノイズを含む座標からノイズ除去予測への差です。負の刻みを掛けるとDの方向へ進みます。

この式がEDMとBoltzの座標更新を読む基本になります。

$$x_{i+1} = x_i + (\sigma_{i+1} - \sigma_i) \frac{x_i - D_\theta(x_i, \sigma_i)}{\sigma_i}$$

付録｜拡散モデルと学習

# σで積分する式へ変数を変える

補足導出：加法ノイズX=Y+σε、順過程のドリフトf=0。σ(t)>0は微分可能で単調増加とする。

$$g(t)^2 = \frac{d\sigma^2}{dt} = 2\sigma\dot{\sigma}$$

1 独立なノイズの分散が増える速さを$g^2$とする。

$$\frac{dX}{dt} = -\sigma\dot{\sigma}\, s(X,\sigma)$$

2 確率流ODEへf=0と$g^2$を代入する。

$$s(X,\sigma) = \frac{D(X,\sigma) - X}{\sigma^2}$$

3 加法ガウスノイズの条件付き平均とスコアの関係を使う。

$$\frac{dX}{d\sigma} = \frac{dX/dt}{d\sigma/dt} = \frac{X - D(X,\sigma)}{\sigma}$$

4 連鎖律で時計をtからσへ変える。生成時はσを減らす。

傾きの符号だけを見て逆向きに動くと判断せず、刻み幅まで掛けた変位を確認しましょう。

単位：XとσがÅなら、dX/dσは無次元。負のΔσを掛けるので、更新はDへ近づく向きになる。

Karras et al., Elucidating the Design Space···, NeurIPS (2022) / Song et al., Score-Based Generative Modeling through SDEs, ICLR (2021) / 本教材の導出・模型計算・演習



付録｜本編の式と実装の補足

# 山の頂点へ集めず、分布全体を元へ戻す

目標は、ノイズで広がった分布を元の分布へ戻すこと。ノイズ量を変えたときの密度の変化と、座標を動かしたときの変化を一致させる。

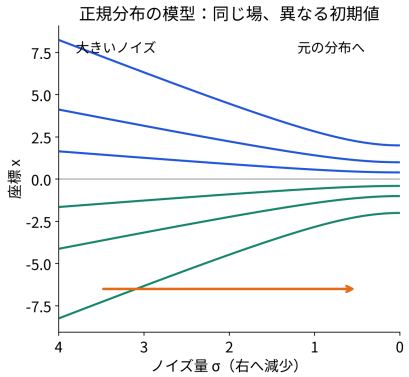
$$\partial_\sigma p_\sigma = \sigma\Delta p_\sigma, \qquad \partial_\sigma p_\sigma = -\nabla\cdot(p_\sigma v)$$

左：正規ノイズを足した密度の変化。右：速度で点を動かすときの確率の保存。両者を満たす選び方は、

$$v = -\sigma\frac{\nabla p_\sigma}{p_\sigma} = -\sigma s$$

$$\frac{dx}{d\sigma} = \frac{x - D^*(x,\sigma)}{\sigma}$$

生成ではノイズ量を下げるので、負の刻み幅を掛け、予測座標へ近づく。正確なスコアと連続積分では、各段で目標の分布を保つ。




模型：元の分散は 1。$x(\sigma)=\mathcal{N}(1+\sigma^2)$。有限の刻みと予測器の誤差は別に残る。



付録｜学習と数値計算の詳細

# 入力と出力の尺度をそろえる

入力を残す経路と、ネットワーク $F_\theta$ が補正する経路を足して、元座標の予測 $D_\theta$ を作る。

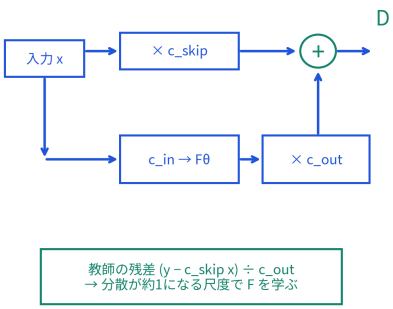
$$\mathrm{Var}(y - c_{\mathrm{skip}}x) = \frac{\sigma^2\sigma_{\mathrm{data}}^2}{\sigma^2 + \sigma_{\mathrm{data}}^2}$$

$$c_{\mathrm{out}} = \frac{\sigma\sigma_{\mathrm{data}}}{\sqrt{\sigma^2 + \sigma_{\mathrm{data}}^2}} \qquad F_{\mathrm{target}} = \frac{y - c_{\mathrm{skip}}x}{c_{\mathrm{out}}}$$

$$D_\theta(x,\sigma) = c_{\mathrm{skip}}x + c_{\mathrm{out}}F_\theta(c_{\mathrm{in}}x, c_{\mathrm{noise}})$$

$$c_{\mathrm{skip}} = \frac{\sigma_{\mathrm{data}}^2}{\sigma^2 + \sigma_{\mathrm{data}}^2} \qquad c_{\mathrm{in}}(\sigma) = \frac{1}{\sqrt{\sigma^2 + \sigma_{\mathrm{data}}^2}}$$

$c_{in}$ で入力の分散を約1にそろえる。$F$の教師は残差を $c_{\mathrm{out}}$ で割った量で、分散が約1になる。低ノイズでは $c_{\mathrm{skip}}\to 1$ となり入力を多く残す。




低ノイズ：c_skip → 1、入力を多く残す

青は入力を残す経路、下は学習する補正の経路。最後に両者を足す。

Karras et al., Elucidating the Design Space···, NeurIPS (2022) / 本教材の導出・模型計算・演習



付録｜学習と数値計算の詳細

# 損失の重みと、学習で使うノイズ量

$c_{\mathrm{out}}$ で $F$の教師の分散をそろえた。損失に $\lambda = 1/c_{\mathrm{out}}^2$ を掛けると、どのノイズ量でも誤差の尺度がそろう。

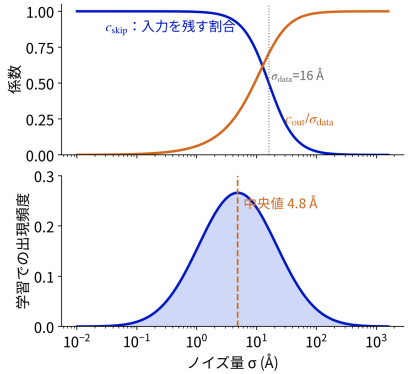
$$c_{\mathrm{out}} = \frac{\sigma\sigma_{\mathrm{data}}}{\sqrt{\sigma^2 + \sigma_{\mathrm{data}}^2}}$$

$$\lambda(\sigma) = c_{\mathrm{out}}^{-2} = \frac{\sigma^2 + \sigma_{\mathrm{data}}^2}{(\sigma\sigma_{\mathrm{data}})^2}$$

$$\log(\sigma/\sigma_{\mathrm{data}}) \sim \mathcal{N}(P_{\mathrm{mean}}, P_{\mathrm{std}}^2)$$

$$c_{\mathrm{noise}} = \frac{1}{4}\log(\sigma/\sigma_{\mathrm{data}})$$

学習ではノイズ量を対数正規分布から取る。Boltz-2 は $\sigma_{\mathrm{data}}$=16 Å、$P_{\mathrm{mean}}$=−1.2、$P_{\mathrm{std}}$=1.5 で、中央値は約 4.8 Å。$c_{\mathrm{noise}}$ はノイズ量をネットワークへ知らせる特徴。学習で取るノイズ量と、生成のノイズ列は別の設定である。




Boltz-2 の既定値で計算。小さいノイズでは局所の配置、大きいノイズでは全体の配置を学ぶ。

Karras et al., Elucidating the Design Space···, NeurIPS (2022) / Boltz source 2.2.1 · b1ebfc4 · 参照 2026-10-09

付録｜本編の式と実装の補足

## 相手の情報を使って、全原子の座標を更新する

分子間の情報を含むトークン特徴を各原子へ戻し、原子側の情報と結合する。全分子の座標予測 $D$ を同じ空間内で出す。

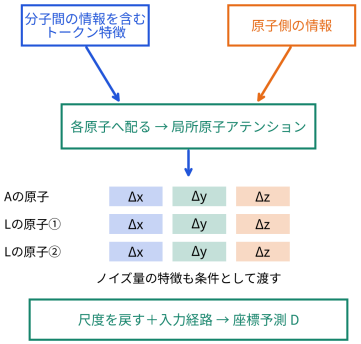
$$c_{\text{noise}} = \frac{1}{4}\log(\sigma/\sigma_{\text{data}})$$

$$\phi_k(t) = \cos(2\pi(\omega_k t + b_k))$$

低分子の原子の更新も、タンパク質側の情報に依存できる。全原子をまとめて更新するので、分子内部の形と分子どうしの位置・向きを同時に予測する。

ノイズ量は $c_{\text{noise}}$ を上の特徴へ変換し、トークン単位のアテンションへ知らせる（$\omega_k$、$b_k$ は固定の乱数）。

構造を生成できても、実際の結合や結合の強さを証明したことにはならない。




AとLの各原子へ三成分の補正を出す。原子ごとに出力しても、各分子を独立に予測しているわけではない。

Boltz source 2.2.1 · b1ebfc4 · 参照 2026-10-09 / Karras et al., Elucidating the Design Space···, NeurIPS (2022)



付録｜本編の式と実装の補足

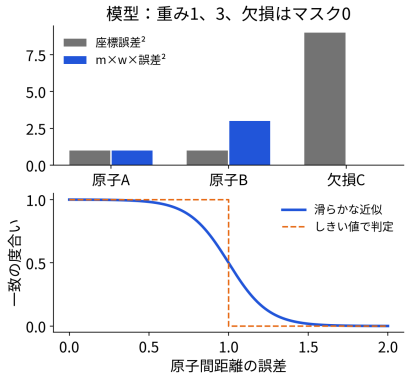
## 原子の種類とマスクで損失を重み付け

欠損座標はマスク $m$=0 で除く。原子の重み $w$ は、タンパク質 1、核酸 6、低分子 11 とする。

$$L_{\text{coord}} = \mathbb{E}_\sigma\left[\lambda(\sigma)\frac{\sum_i m_i w_i \|\hat{x}_i - x_i^{\text{aligned}}\|^2}{3\sum_i m_i w_i + \varepsilon}\right]$$

有効な重みの合計と3成分で割り、ノイズ量の重み $\lambda$ を掛ける。

局所の距離には滑らかな lDDT 型の損失も足す。距離は回転・並進に依存しないが、鏡像を区別できない。




上の重み 1、3 と下の滑らかな曲線は説明用の模型で、Boltz の実際の値ではない。

Boltz source 2.2.1 · b1ebfc4 · 参照 2026-10-09 / Wohlwend et al., Boltz-1 (2024/2025), bioRxiv



付録｜本編の式と実装の補足

## 小さいノイズ側へ刻みを集める

$\sigma$ のべき根を等間隔に置き、べき乗して元の尺度へ戻す。小さいノイズ側の刻みが細かくなる。

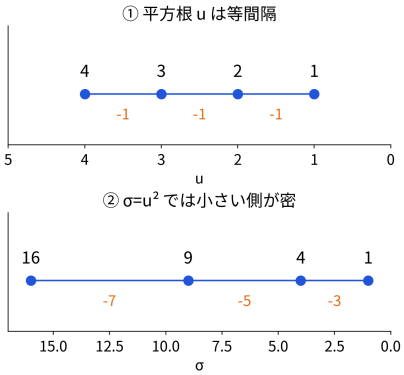
$$\sigma_i = \left(\sigma_{\max}^{1/\rho} + \frac{i}{N-1}(\sigma_{\min}^{1/\rho} - \sigma_{\max}^{1/\rho})\right)^\rho$$

$$u_i = 4 + \frac{i}{3}(1-4), \quad i = 0,1,2,3$$

$$\sigma_i = u_i^2 : \quad 16, 9, 4, 1$$

$$\Delta\sigma_i : \quad -7, -5, -3$$

模型では $\sigma_{\max}$=16、$\sigma_{min}$=1、$\rho$=2、$N$=4。$u$ は 4, 3, 2, 1、$\sigma$ は 16, 9, 4, 1 となる。Boltz-2 は $\rho$=7 を使い、さらにデータの尺度を掛ける。




図の横軸はどちらも線形。左から右へ $\sigma$ が減り、差は −7、−5、−3。

Karras et al., Elucidating the Design Space···, NeurIPS (2022) / Boltz source 2.2.1 · b1ebfc4 · 参照 2026-10-09 / 本教材の導出・模型計算・演習



付録｜本編の式と実装の補足

## ノイズを足してから下げる

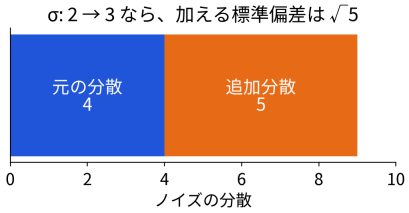
ノイズを追加する場合は、新旧の分散の差だけを足す。その後は、増やした $\hat{\sigma}$ をデノイザーへ渡す。

$$\hat{\sigma}_i = (1+\gamma_i)\sigma_i$$

$$\hat{x}_i = x_i + \sqrt{\hat{\sigma}_i^2 - \sigma_i^2}\,\epsilon_i$$

有限の刻みでは、前の段までの誤差が積み重なる。ノイズを足してから下げると、その誤差を直す効果がある。足しすぎると細部が失われる副作用もある。

Boltz-2 では、次の $\sigma$ が 1 Å より大きい段で $\gamma$=0.8 とする。EDM の上限 $\gamma \le \sqrt{2}-1$ より大きい値である。




$\sigma$ を 2 から 3 へ上げるなら、分散 4 に 5 を足して 9 にする。

Karras et al., Elucidating the Design Space···, NeurIPS (2022)

付録｜本編の式と実装の補足

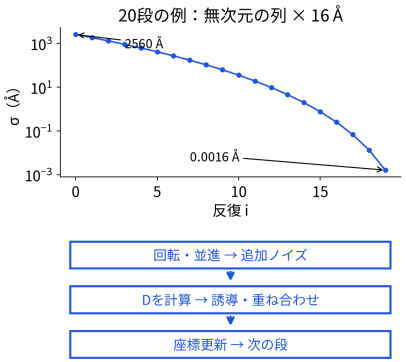
# Boltz-2 のノイズ列：2560 Å から 0 まで

Boltz-2 の既定は $\sigma_{\text{data}}$=16 Å、$s_{\max}$=160、$s_{min}$=0.0001、$\rho$=7。無次元の列に $\sigma_{\text{data}}$ を掛けて Å の単位へ変換する。

$$\sigma_i^{\text{actual}} = \sigma_{\text{data}} \left[ s_{\max}^{1/\rho} + \frac{i}{N-1}\left(s_{\min}^{1/\rho} - s_{\max}^{1/\rho}\right) \right]^{\rho}$$

初期座標は標準偏差 2560 Å の乱数。最小は 0.0016 Å で、最後に 0 を加える。

各段の順序：回転・並進 → 追加ノイズ（$\gamma$=0.8、尺度 1.003）→ $D$ → 有効なら誘導 → 重ね合わせ → 更新。




右上：$\rho$=7、20段の例。対数軸に 0 は描けないので、最後の 0 は表示していない。



付録｜本編の式と実装の補足

# Boltzの更新はEuler型に尺度を加える

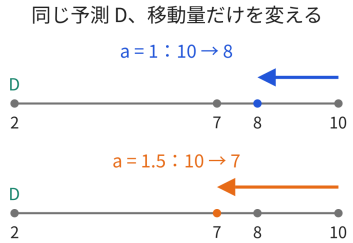
ハットの付いた $X$は追加ノイズを足した座標。波線の $X$は、それを予測 $D_i$へ重ねた座標。$a$は step_scale で、Boltz-2 の既定は $a$=1.5。

$$D_i = D_\theta(\hat{X}_i, \hat{\sigma}_i; c), \quad X_{i+1} = \bar{X}_i + a(\sigma_{i+1} - \hat{\sigma}_i)\frac{\bar{X}_i - D_i}{\hat{\sigma}_i}$$

$$d = (10-2)/4 = 2$$
$$x_{\text{next}} = 10 + (3-4)\,2 = 8$$
$$a = 1.5 \quad \Rightarrow \quad x_{\text{next}} = 7$$

模型：現在値 10、予測 $D$=2、$\hat{\sigma}$=4、次の $\sigma$=3。$a$=1 なら 8、$a$=1.5 なら 7 へ進む。

$a$を小さくすると候補の多様性が増える（公式の説明）。一段に $D$を呼ぶのは1回で、Heun 法の2回目はない。




傾き (10−2)/4 = 2

ノイズ量の差：3−4 = −1

模型の一成分。回転・誘導は省略。

右：同じ出発点と $D$から、$a$だけを変えて比較。模型では誘導・重ね合わせを省いた。



付録｜本編の式と実装の補足

# Euler 法：現在の傾きで一段進む

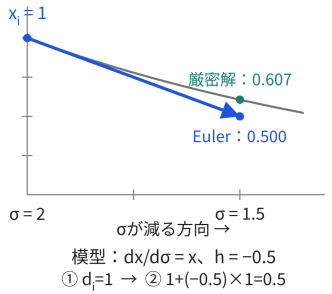
$D$は元座標を予測する学習済み関数。サンプラーは $D$を呼ぶノイズ量・回数と、座標の更新法を決める。

$$d_i = \frac{x_i - D(x_i, \sigma_i)}{\sigma_i}$$

$$x_{i+1} = x_i + h_i d_i, \quad h_i = \sigma_{i+1} - \sigma_i$$

Euler 法は現在の傾きを一段の間一定とみなす。

同じ $D$でも刻み方は変えられる。刻みを細かくしても予測器の誤差は残る。




右は積分法を説明する模型。灰線は厳密解、青は現在の傾きだけで進む近似。



付録｜学習と数値計算の詳細

# Heun法は終点の傾きも見る

①Euler法で仮の終点を作る。②そこで傾きを再計算する。③始点と仮の終点の傾きを平均し、始点から更新し直す。

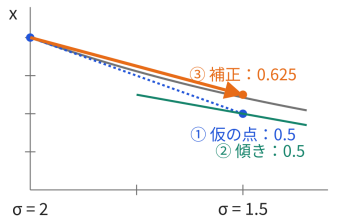
$$\tilde{x} = x_i + h_i d_i, \quad \tilde{d} = \frac{\tilde{x} - D(\tilde{x}, \sigma_{i+1})}{\sigma_{i+1}}$$

$$x_{i+1} = x_i + \frac{h_i}{2}(d_i + \tilde{d})$$

滑らかな問題では二次精度だが、$D$の呼び出しは一段に2回。

仮の終点は確定した座標ではない。最後が $\sigma$=0 の段は割り算ができないので Euler 法で進む。

Boltz の標準の更新に、この2回目の予測はない。




平均の傾き：(1+0.5)/2 = 0.75

更新：1+(−0.5)×0.75 = 0.625

同じ模型の厳密解は約0.607

同じ模型でEulerは0.500、Heunは0.625、厳密解は約0.607。計算費用も比較する。

# EulerとHeunの誤差は何が違うか

補足計算：x′(σ)=d(x,σ)が滑らかとして一段を展開する。dの微分にはxを通じた変化も入る。

$$x(\sigma+h) = x+hd+\frac{h^2}{2}(\partial_\sigma d+J_d d)+O(h^3)$$

1 連鎖律で二階微分を計算。Jdはdのxに関するヤコビ行列。

$$\tilde{x} = x + hd, \quad \tilde{d} = d(\tilde{x}, \sigma + h)$$

2 Eulerの仮の終点で傾きを評価する。

$$\tilde{d} = d + h(\partial_\sigma d + J_d d) + O(h^2)$$

3 終点の傾きをTaylor展開する。

$$x_{\text{Heun}} = x+\frac{h}{2}(d+\tilde{d}) = x+hd+\frac{h^2}{2}(\partial_\sigma d+J_d d)+O(h^3)$$

4 二つの傾きの平均で、二次まで正しい項が現れる。

大域誤差は一定の区間を最後まで進めた差で、段数が刻み幅の逆数程度になるため、一般に次数が一つ下がります。滑らかな例で刻みを半分にし、誤差が何分の一になるかを見れば、この違いを検査できます。

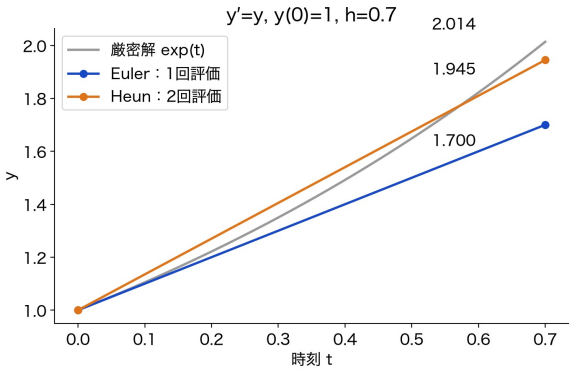
Eulerは局所O(h²)・大域O(h)、Heunは局所O(h³)・大域O(h²)。同じ関数評価回数でも比較する。

Karras et al., Elucidating the Design Space···, NeurIPS (2022) / 本教材の導出・模型計算・演習





# 刻み数だけで計算費用を比べない




説明用の数値計算：h=0.7。青＝Euler、橙＝Heun、灰＝厳密解。

Karras et al., Elucidating the Design Space···, NeurIPS (2022)

### 刻み数だけで計算費用を比べない

一段に予測器を二回呼ぶ方法と、一回呼ぶ方法では、同じ段数でも費用が違います。

予測器の評価回数、全体時間、誤差を一緒に記録します。

高い次数の方法でも、ノイズやモデル誤差が大きければ常に有利とは限りません。

左はy′=yを1段だけ進めた例。厳密解と二つの近似を同時に比較する。

Eulerは1回、Heunは2回の関数評価で1段進む。





# 残差の分散を最小にする係数

ノイズ座標x=y+σεから、元データyを予測します。

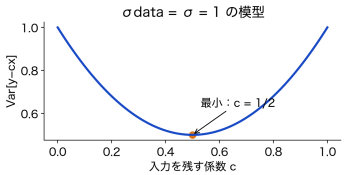
元データとノイズは独立、各成分の平均は0と仮定します。

y−cxの分散をcで微分し、0にするとc_skipが得られます。

$$\mathrm{Var}(y-cx) = (1-c)^2\sigma_{\text{data}}^2 + c^2\sigma^2$$

$$\frac{d}{dc}\mathrm{Var}(y-cx) = -2(1-c)\sigma_{\text{data}}^2 + 2c\sigma^2$$

$$c = \frac{\sigma_{\text{data}}^2}{\sigma_{\text{data}}^2 + \sigma^2}$$



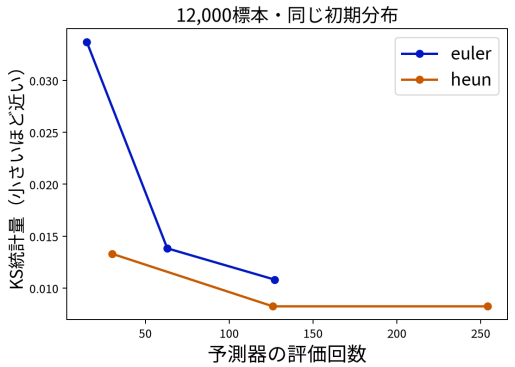

残差y−cx=(1−c)y−cσε。独立性から分散は(1−c)²σdata²+c²σ²となる。cで微分して0と置けばc_skipが得られる。これは残差の尺度を整えるための係数であり、一般の条件付き平均が線形関数になるという意味ではない。

Karras et al., Elucidating the Design Space···, NeurIPS (2022) / 本教材の導出・模型計算・演習





# 模型の誤差を計算量と比較する




本教材の説明図

本教材の導出・模型計算・演習

### 模型の誤差を計算量と比較する

同じ初期標本で生成し、最後の分布を理論的な累積分布と比較しました。

KS統計量は累積分布の最大の差で、小さいほど近い値です。横軸は予測器の呼出し回数です。

細かい刻みでも標本誤差が残ります。Boltzの実分子での精度を直接表す結果ではありません。

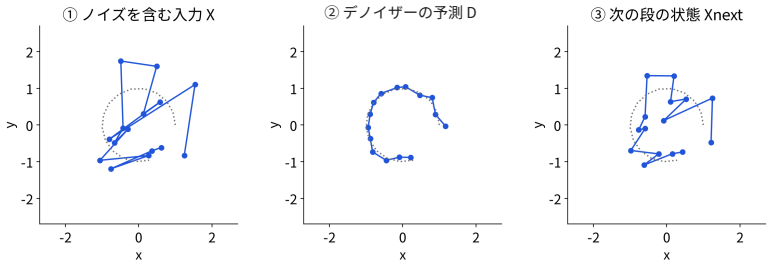
横軸は反復数ではなく、予測器の評価回数です。

縦軸の統計量は累積分布の差を見ており、平均だけが合っているかを検査するものではありません。

付録｜Boltz の実装

# 途中座標を保存すると何が見えるか

同じ反復でも、①ノイズを含む入力、②デノイザーの予測、③次の段へ渡す状態は異なる。保存する量の名前を明確にする。




実計算は毎段回転も加わるので、共通の基準へ重ね合わせて比較する。途中の大きなノイズの状態は実在の構造ではない。複数の生成構造の割合は平衡確率を保証しないので、RMSF・接触・状態の割合を別の参照データと比べる。

2次元の説明用座標。灰点線は基準形。Boltzの実際の途中出力や分子の運動ではない。



付録｜参考文献

# 出典と学び直す場所

**Passaro et al., Boltz-2 (2025), bioRxiv**

https://doi.org/10.1101/2025.06.14.659707

**Wohlwend et al., Boltz-1 (2024/2025), bioRxiv**

https://doi.org/10.1101/2024.11.19.624167

**Abramson et al., Nature 630, 493–500 (2024)**

https://doi.org/10.1038/s41586-024-07487-w

**Boltz source 2.2.1・b1ebfc4・参照 2026-10-09**

https://github.com/jwohlwend/boltz/blob/b1ebfc46ecf57f5414e0d1a6f9027bbb122c53bc/



付録｜参考文献

# 出典と学び直す場所

**授業用Notebook・入力・演習**

https://github.com/matsunagalab/lecture_bioinfo

**Boltz prediction documentation・b1ebfc4**

https://github.com/jwohlwend/boltz/blob/b1ebfc46ecf57f5414e0d1a6f9027bbb122c53bc/docs/prediction.md

**Ho et al., Denoising Diffusion Probabilistic Models, NeurIPS (2020)**

https://arxiv.org/abs/2006.11239

**Karras et al., Elucidating the Design Space…, NeurIPS (2022)**

https://arxiv.org/abs/2206.00364



付録｜参考文献

# 出典と学び直す場所

**Song et al., Score-Based Generative Modeling through SDEs, ICLR (2021)**

https://arxiv.org/abs/2011.13456

**Vincent, Neural Computation 23, 1661–1674 (2011)**

https://doi.org/10.1162/NECO_a_00142

**Anderson, Stochastic Processes and their Applications 12, 313–326 (1982)**

https://doi.org/10.1016/0304-4149(82)90051-5