生命情報工学特論　第06回

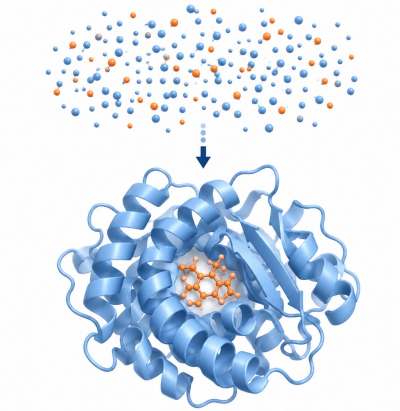
Boltz による
複合体構造予測

タンパク質と低分子の配置を予測する
拡散モデルの仕組み・Boltz演習

松永 康佑

埼玉大学 大学院理工学研究科
理化学研究所 計算科学研究センター ｜ 2026年11月2日

分子の情報を条件に、座標を生成



概念図：青はタンパク質、橙は低分子。実際の予測構造ではない。

この回の目標

酵素と低分子から、複合体の座標と信頼度を求める

入力：配列と低分子の情報
MfnG：チロシンにメチル基（$-CH_3$）を付ける酵素。384残基の配列と MSA。
SAH：メチル基を渡した後の補因子（酵素を助ける分子）。チロシン：反応する基質。

出力：水素を除く全原子の座標（CIF）と信頼度（pLDDT・PAE・ipTM）
低分子が酵素のどこに、どの向きで入るかを計算で求める。



演習で予測した複合体（橙：SAH、紫：チロシン）

入力から出力までの問い	説明する部分
① AlphaFold 2 の座標の作り方を、なぜ替えるのか	AF2 から Boltz への変更
② ノイズを除去するモデルを、どう学習するのか	デノイザーと損失
③ ノイズから、どう座標を生成するのか	スコアと数値積分
④ 分子どうしの配置を、どう予測するのか	Boltz の座標生成
⑤ 予測のどこまでを信じてよいか	評価指標と信頼度

デノイザー：ノイズを除去するモデル。既知の構造から学習済みで、演習は推論だけを行う。

講義の流れ

全体像を見てから、学習と生成の計算へ入る

① AF2 から複合体へ
AF2 から替えた部分、全体像、原子とトークン。

② ノイズ除去を学習する
平均では足りない理由、損失、入出力の尺度。

③ ノイズから座標を生成する
スコア、Euler 法と Heun 法、ノイズ列。

④ 分子どうしを一緒に配置する
分子をまたぐペア、全原子の更新、Boltz-2 の実際の値。

⑤ 予測を読む
精度の指標と、モデルが予測する信頼度。

演習
Boltz で予測し、実験構造と比べる。

到達目標

1. AF2 の座標の作り方を拡散モデルへ替えた理由を説明できる。
2. デノイザーの学習と、スコアを使う生成の関係を式で説明できる。
3. 分子間の情報が座標の更新へ届く経路を説明できる。
4. 精度の指標と、モデルが予測した信頼度を区別できる。

① AF2 から複合体へ

AlphaFold 2 から何を引き継ぎ、何を替えたか

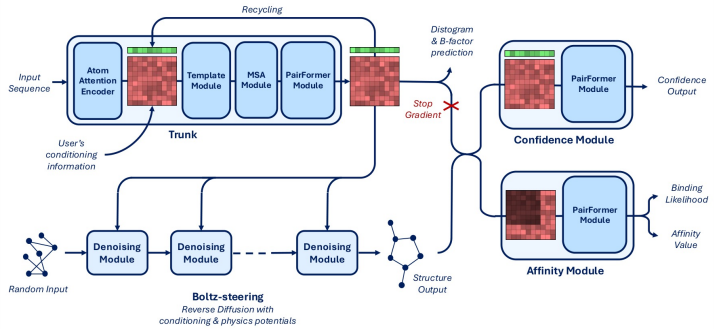
	AlphaFold 2	AlphaFold 3・Boltz
扱う分子	タンパク質	タンパク質・核酸・低分子・イオン
計算の単位	残基	トークン（残基、または原子）
表現の更新	Evoformer（MSA 表現とペア表現）	Pairformer（MSA の処理は小さい）
座標の作り方	残基のフレームと二面角を更新する	原子の座標を拡散モデルで直接生成する
予測の性質	1つの構造を出す	分布から候補を生成する
引き継ぐもの	MSA、ペア表現、三角形の更新、リサイクリング	pLDDT・PAE などの信頼度

なぜ座標の作り方を替えるのか
前回の Structure Module は、N–Cα–C のフレームとアミノ酸ごとの二面角で座標を作った。低分子には共通の骨格も決まった二面角もないので、そのままは当てはめにくい。原子の座標そのものを生成すれば、どの分子も同じ計算で扱える。小さいノイズの学習が局所の立体構造を担うので、AF2 の立体化学の損失も省ける。

Abramson et al., Nature 630, 493–500 (2024) / Wohlwend et al., Boltz-1 (2024/2025), bioRxiv

① AF2 から複合体へ｜全体像

全体像：共通部分が条件を作り、拡散で原子を置く



共通部分（trunk）がシングル表現とペア表現を作り、座標生成部が条件として受け取って原子を配置する。

信頼度は別の部品で計算する。親和性の予測は今回の演習では行わない。

Passaro et al., Boltz-2 (2025), Fig. 2 · CC BY 4.0

Passaro et al., Boltz-2 (2025), bioRxiv

① AF2 から複合体へ｜分子の表し方

同じ分子を二つの細かさで見る

原子とトークンを使い分ける

原子座標を求めるには各原子の情報が要る。一方、全原子どうしのアテンションは費用が大きい。

Boltz は原子単位の情報と、より粗いトークン単位の情報を使い分ける。

トークン：ネットワークが一単位として扱う要素。

原子：元素・電荷・参照座標（理想的な立体配置）→ トークン：残基や原子 → トークン対：二者の関係

タンパク質：複数の原子 → 1残基トークン

●●●	●●●	●●●
残基 1	残基 2	残基 3

分子の種類で単位が違う

タンパク質は1残基、DNA・RNA は1ヌクレオチドを1トークンとする。

それ以外の分子は原子ごとのトークンで表す。

Boltz-2 では非標準のアミノ酸やヌクレオチドも残基単位に保つ（Boltz-1 との違い）。

演習の入力：残基 384 ＋ SAH 26 原子 ＋ チロシン 13 原子（水素を除く）＝ 423 トークン

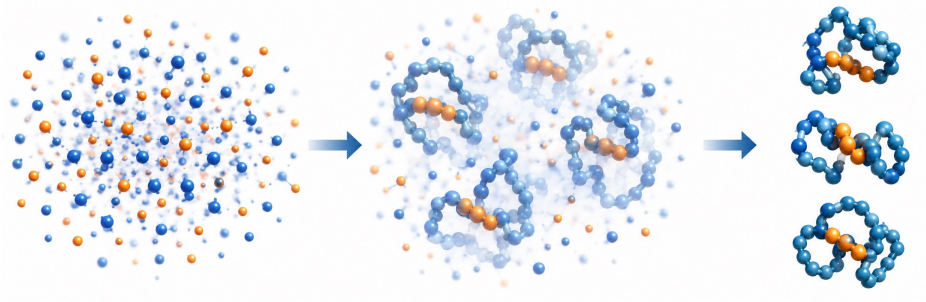
低分子：それぞれの原子が1トークン

C	C	N	O
原子1	原子2	原子3	原子4

Passaro et al., Boltz-2 (2025), bioRxiv

② ノイズ除去を学習する｜なぜ生成するのか

一つの平均では構造を表せない



二つの構造の平均が、実在する構造とは限らない。生成モデルは候補を分布として表す。

模式図：実在タンパク質や計算済みの平均座標ではない。Boltzの生成頻度は熱平衡の占有率を保証しない。

GPT Imageによる概念図。粒子数・結合・経路は実分子の計算結果を表さない。

Ho et al., Denoising Diffusion Probabilistic Models, NeurIPS (2020) / Karras et al., Elucidating the Design Space···, NeurIPS (2022)

② ノイズ除去を学習する｜発想

画家の下描きから、段階的な生成を考える

ラフ：位置と輪郭　**中間：形と陰影**　**仕上げ：細部と質感**



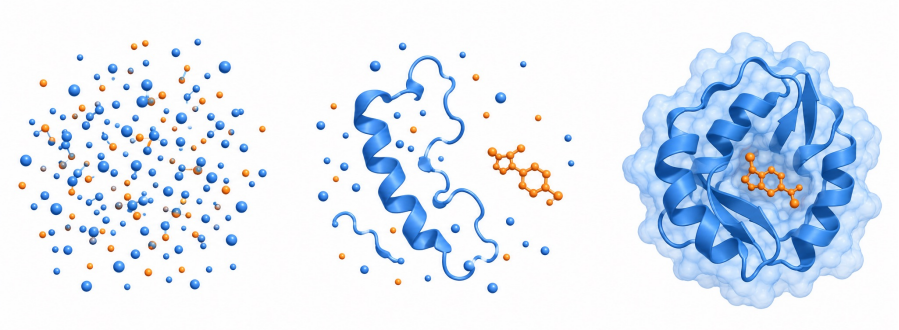
学習：既知構造にノイズを加えれば、「乱れた入力 → 元の座標」の練習材料を作れる。

生成：同じデノイザーで座標を繰り返し更新する。乱数を変えると別の候補も作れる。

図は例え：下描き ≠ 正規ノイズ。Boltzは原子座標を更新する。全体→細部という厳密な段階分けではない。

② ノイズ除去を学習する｜分子の場合

知りたいのは、条件を与えたときの構造の分布



知りたい分布は $p(X|c)$。X：全原子の座標、c：配列・MSA・低分子の情報。ノイズの多い座標を繰り返し更新して標本を作る。

GPT Imageによる概念図。原子・結合の実計算やMDの時間発展ではない

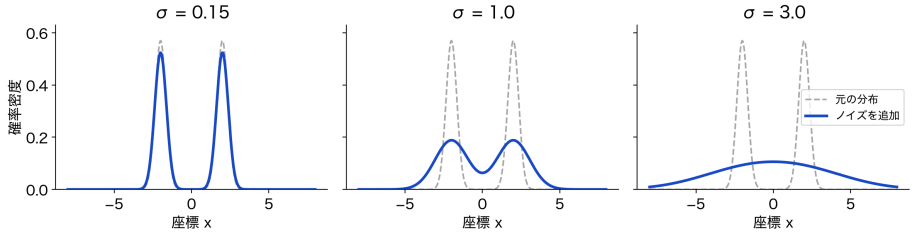
本教材の導出・模型計算・演習

② ノイズ除去を学習する｜ノイズと分布

ノイズで分布の山をなだらかにする

元の分布は、−2 と 2 を中心とする二つの正規分布の混合。独立な正規ノイズを加えると各山が広がる。

灰の破線は元の分布、青線はノイズ追加後。同じ軸で σ を変えて比較する。



学習ではノイズを加えた入力を作る。生成では大きなノイズから始め、σ を下げて元の分布へ戻す。

Ho et al., Denoising Diffusion Probabilistic Models, NeurIPS (2020) / Karras et al., Elucidating the Design Space···, NeurIPS (2022)

② ノイズ除去を学習する｜損失

ノイズ座標とノイズ量から、元の座標を予測

教師：既知構造 y
分子の条件 c と組にする

→

ノイズ入力 x
ε に σ を掛けて足す

→

デノイザー D_θ
x・σ・c から y を予測

$$x = y + \sigma\epsilon, \quad \epsilon \sim \mathcal{N}(0, I)$$

$$\mathcal{L}(\theta) = \mathbb{E}_{y,\sigma,\epsilon}\left[\lambda(\sigma)\|D_\theta(x,\sigma,c) - y\|^2\right]$$

学習用の座標対を自分で作れる

教師 y	0.0	1.0	2.0
ノイズ入力 x	0.3	0.8	2.4

1成分ずつの説明例。実際は全原子の3成分を扱う。

σ：ノイズの標準偏差。分子座標なら単位は Å。λ：ノイズ量ごとの損失の重み。

単純な二乗誤差の最適解は条件付き平均。Boltz の損失には重ね合わせ・原子の重みも入る。

② ノイズ除去を学習する｜尺度

入力と出力の尺度をそろえる

入力を残す経路と、ネットワーク F_θ が補正する経路を足して、元座標の予測 D_θ を作る。

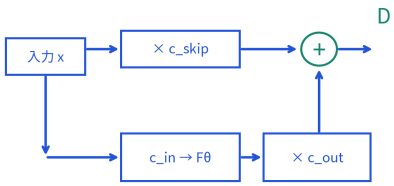
$$\mathrm{Var}(y - c_{\mathrm{skip}}x) = \frac{\sigma^2\sigma_{\mathrm{data}}^2}{\sigma^2 + \sigma_{\mathrm{data}}^2}$$

$$c_{\mathrm{out}} = \frac{\sigma\sigma_{\mathrm{data}}}{\sqrt{\sigma^2 + \sigma_{\mathrm{data}}^2}} \qquad F_{\mathrm{target}} = \frac{y - c_{\mathrm{skip}}x}{c_{\mathrm{out}}}$$

$$D_\theta(x,\sigma) = c_{\mathrm{skip}}x + c_{\mathrm{out}}F_\theta(c_{\mathrm{in}}x, c_{\mathrm{noise}})$$

$$c_{\mathrm{skip}} = \frac{\sigma_{\mathrm{data}}^2}{\sigma^2 + \sigma_{\mathrm{data}}^2} \qquad c_{\mathrm{in}}(\sigma) = \frac{1}{\sqrt{\sigma^2 + \sigma_{\mathrm{data}}^2}}$$

c_{in} で入力の分散を約1にそろえる。Fの教師は残差を c_{out} で割った量で、分散が約1になる。低ノイズでは $c_{\mathrm{skip}} \to 1$ となり入力を多く残す。



教師の残差 (y − c_skip x) ÷ c_out
→ 分散が約1になる尺度で F を学ぶ

低ノイズ：c_skip → 1、入力を多く残す

青は入力を残す経路、下は学習する補正の経路。最後に両者を足す。

Karras et al., Elucidating the Design Space···, NeurIPS (2022) / 本教材の導出・模型計算・演習

② ノイズ除去を学習する｜ノイズ量

損失の重みと、学習で使うノイズ量

c_{out} で F の教師の分散をそろえた。損失に $\lambda{=}1/c_{\text{out}}{}^2$ を掛けると、どのノイズ量でも誤差の尺度がそろう。

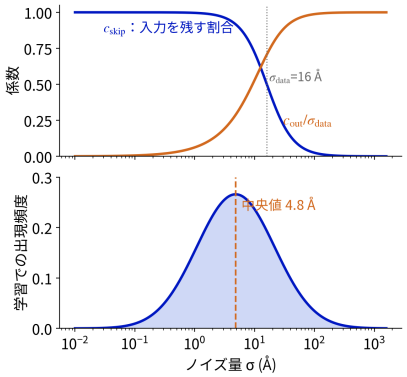
$$c_{\text{out}} = \frac{\sigma\sigma_{\text{data}}}{\sqrt{\sigma^2+\sigma_{\text{data}}^2}}$$

$$\lambda(\sigma) = c_{\text{out}}^{-2} = \frac{\sigma^2+\sigma_{\text{data}}^2}{(\sigma\sigma_{\text{data}})^2}$$

$$\log(\sigma/\sigma_{\text{data}}) \sim \mathcal{N}(P_{\text{mean}}, P_{\text{std}}^2)$$

$$c_{\text{noise}} = \frac{1}{4}\log(\sigma/\sigma_{\text{data}})$$

学習ではノイズ量を対数正規分布から取る。Boltz-2 は σ_{data}=16 Å、P_{mean}=−1.2、P_{std}=1.5 で、中央値は約 4.8 Å。c_{noise} はノイズ量をネットワークへ知らせる特徴。学習で取るノイズ量と、生成のノイズ列は別の設定である。



Boltz-2 の既定値で計算。小さいノイズでは局所の配置、大きいノイズでは全体の配置を学ぶ。

Karras et al., Elucidating the Design Space···, NeurIPS (2022) / Boltz source 2.2.1 · b1ebfc4 · 参照 2026-10-09

③ ノイズから座標を生成する｜スコア

スコア：密度が増える方向を示す

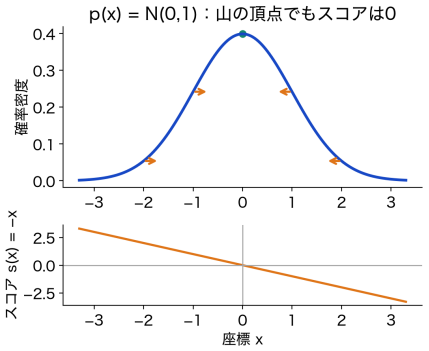
スコア $s(x)$ は確率密度の対数の勾配。密度が局所的に増える方向を示し、密度の高さとは異なる。

$$s(x) = \nabla_x \log p(x)$$

$$p = \mathcal{N}(\mu, \sigma^2 I) \quad \Rightarrow \quad s(x) = -\frac{x-\mu}{\sigma^2}$$

正規分布では平均へ向く。右の例は μ=0、σ=1 なので $s(x)$=−x。

山の頂点 x=0 では密度が最大でも $s(0)$=0。多峰分布では、スコアが分布全体の平均へ向くとは限らない。



Song et al., Score-Based Generative Modeling through SDEs, ICLR (2021) / Karras et al., Elucidating the Design Space···, NeurIPS (2022)

③ ノイズから座標を生成する｜スコア

デノイザーが分かれば、スコアが分かる

元データ y に標準偏差 σ の正規ノイズを加えた座標が x。最適なデノイザー D は、x から推定する y の条件付き平均である。

$$x = y + \sigma\epsilon, \quad \epsilon \sim \mathcal{N}(0, I)$$

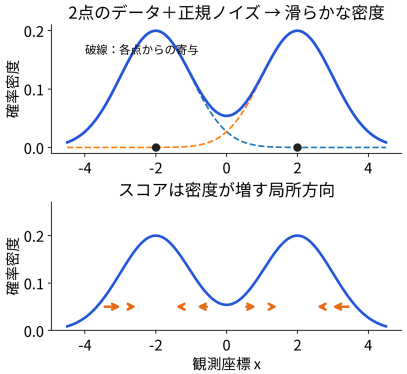
$$D^*(x,\sigma) = \mathbb{E}[y \mid x]$$

$$p_\sigma(x) = \int p_{\text{data}}(y)\mathcal{N}(x; y, \sigma^2 I)\, dy$$

$$\nabla_x p_\sigma(x) = \int \frac{y-x}{\sigma^2} p_{\text{data}}(y)\mathcal{N}(x; y, \sigma^2 I)\, dy$$

元データが離散的でも σ>0 なら密度は滑らか。微分と積分を交換し、$p_\sigma(x)$ で割ってベイズ則を使うと、次の関係を得る（導出は付録）。

$$s(x,\sigma) = \nabla_x \log p_\sigma(x) = \frac{D^*(x,\sigma)-x}{\sigma^2}$$



模型：元データは −2 と 2 の2点。橙の矢印は局所の密度増加方向。

Karras et al., Elucidating the Design Space···, NeurIPS (2022) / 本教材の導出・模型計算・演習

③ ノイズから座標を生成する｜スコア

正規分布で、式の符号を確かめる

予測ノイズは x−D の方向、スコアは逆の D−x の方向。σ で割る回数と符号を区別する。

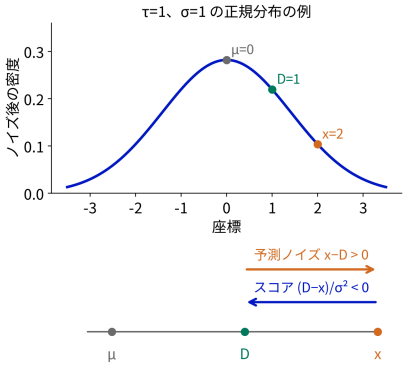
$$\hat{\epsilon} = \frac{x - D_\theta(x,\sigma)}{\sigma}$$

$$s_\theta = -\frac{\hat{\epsilon}}{\sigma}$$

$$s(x,\sigma) = -\frac{x-\mu}{\tau^2+\sigma^2}$$

$$D(x,\sigma) = x + \sigma^2 s = \frac{\tau^2 x + \sigma^2\mu}{\tau^2+\sigma^2}$$

正規分布の例では x>μ ならスコアは負。D は観測 x を平均 μ へ近づけ、σ が大きいほど μ の比重が増す。



模型：μ=0、τ=σ=1、x=2 のとき D=1、予測ノイズ 1、スコア −1。

Karras et al., Elucidating the Design Space···, NeurIPS (2022) / Ho et al., Denoising Diffusion Probabilistic Models, NeurIPS (2020) / 本教材の導出・模型計算・演習

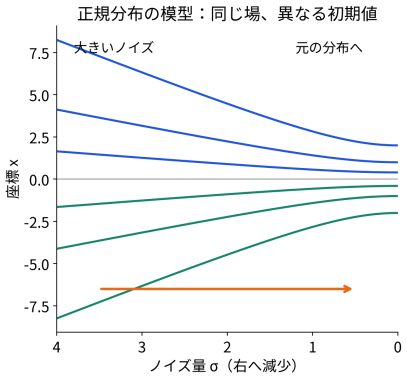
ノイズ量を下げながら、座標を更新する

デノイザーの予測からスコアを得て、ノイズ量 σ を大きい値から 0 へ下げる。原子座標全体を一つの長いベクトルと考える。

$$s(x,\sigma) = \nabla_x \log p_\sigma(x) \simeq \frac{D_\theta(x,\sigma,c) - x}{\sigma^2}$$

$$\frac{dx}{d\sigma} = -\sigma s(x,\sigma) \simeq \frac{x - D_\theta(x,\sigma,c)}{\sigma}$$

$\Delta\sigma<0$ なので、更新は D へ近づく向きになる。異なる初期値は異なる経路を与える。式は正確なスコアと連続の積分での関係。右は正規分布の解析例である。



模型：元の分散は 1。$x(\sigma)=z\sqrt{(1+\sigma^2)}$。有限の刻みと予測器の誤差は別に残る。

Euler 法：現在の傾きで一段進む

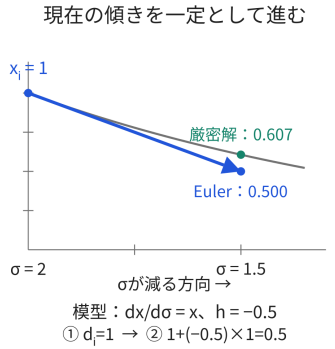
D は元座標を予測する学習済み関数。サンプラーは D を呼ぶノイズ量・回数と、座標の更新法を決める。

$$d_i = \frac{x_i - D(x_i,\sigma_i)}{\sigma_i}$$

$$x_{i+1} = x_i + h_i d_i, \quad h_i = \sigma_{i+1} - \sigma_i$$

Euler 法は現在の傾きを一段の間一定とみなす。

同じ D でも刻み方は変えられる。刻みを細かくしても予測器の誤差は残る。



右は積分法を説明する模型。灰線は厳密解、青は現在の傾きだけで進む近似。

Karras et al., Elucidating the Design Space···, NeurIPS (2022)

Heun法は終点の傾きも見る

①Euler法で仮の終点を作る。②そこで傾きを再計算する。③始点と仮の終点の傾きを平均し、始点から更新し直す。

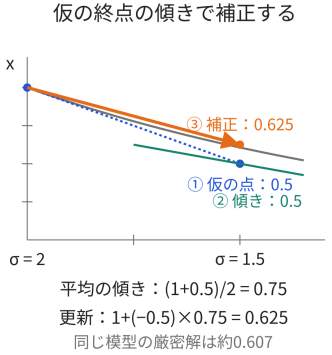
$$\tilde{x} = x_i + h_i d_i, \quad \tilde{d} = \frac{\tilde{x} - D(\tilde{x},\sigma_{i+1})}{\sigma_{i+1}}$$

$$x_{i+1} = x_i + \frac{h_i}{2}(d_i + \tilde{d})$$

滑らかな問題では二次精度だが、D の呼び出しは一段に2回。

仮の終点は確定した座標ではない。最後が σ=0 の段は割り算ができないので Euler 法で進む。

Boltz の標準の更新に、この2回目の予測はない。



同じ模型でEulerは0.500、Heunは0.625、厳密解は約0.607。計算費用も比較する。

Karras et al., Elucidating the Design Space···, NeurIPS (2022)

小さいノイズ側へ刻みを集める

σ のべき根を等間隔に置き、べき乗して元の尺度へ戻す。小さいノイズ側の刻みが細かくなる。

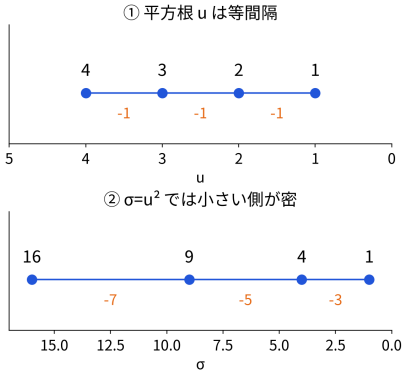
$$\sigma_i = \left(\sigma_{\max}^{1/\rho} + \frac{i}{N-1}(\sigma_{\min}^{1/\rho} - \sigma_{\max}^{1/\rho})\right)^\rho$$

$$u_i = 4 + \frac{i}{3}(1-4), \quad i = 0,1,2,3$$

$$\sigma_i = u_i^2 : \quad 16, 9, 4, 1$$

$$\Delta\sigma_i : \quad -7, -5, -3$$

模型では σ_{max}=16、σ_{min}=1、ρ=2、N=4。u は 4, 3, 2, 1、σ は 16, 9, 4, 1 となる。Boltz-2 は ρ=7 を使い、さらにデータの尺度を掛ける。



図の横軸はどちらも線形。左から右へ σ が減り、差は −7、−5、−3。

Karras et al., Elucidating the Design Space···, NeurIPS (2022) / Boltz source 2.2.1 · b1ebfc4 · 参照 2026-10-09 / 本教材の導出・模型計算・演習

③ ノイズから座標を生成する｜ノイズ列

ノイズを足してから下げる

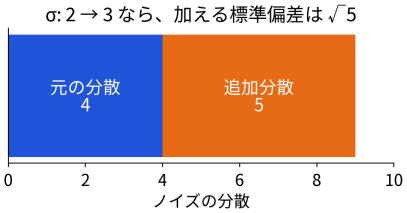
ノイズを追加する場合は、新旧の分散の差だけを足す。その後は、増やした $\hat{\sigma}$ をデノイザーへ渡す。

$$\hat{\sigma}_i = (1+\gamma_i)\sigma_i$$

$$\hat{x}_i = x_i + \sqrt{\hat{\sigma}_i^2 - \sigma_i^2}\,\epsilon_i$$

有限の刻みでは、前の段までの誤差が積み重なる。ノイズを足してから下げると、その誤差を直す効果がある。足しすぎると細部が失われる副作用もある。

Boltz-2 では、次の σ が 1 Å より大きい段で γ=0.8 とする。EDM の上限 $\gamma \le \sqrt{2}-1$ より大きい値である。



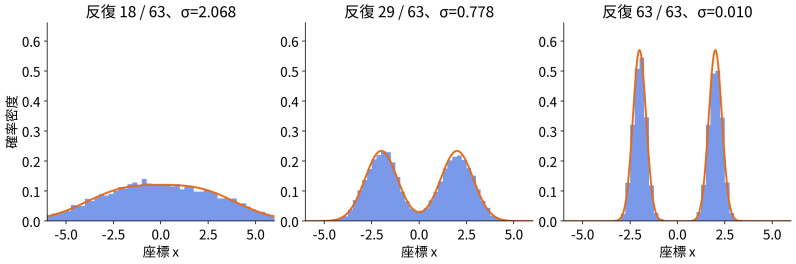
σを 2 から 3 へ上げるなら、分散 4 に 5 を足して 9 にする。

Karras et al., Elucidating the Design Space···, NeurIPS (2022)

③ ノイズから座標を生成する｜確かめ

模型でノイズから分布を生成する

解析的なデノイザーとHeun法による63段の計算。12,000標本が、ノイズ量を下げるにつれて二つの山へ集まる。



青は標本のヒストグラム、橙は各 σ での正確な密度。標本数が有限なので揺らぎがある。平均の1点ではなく、二つの山の両方に標本が集まる。

保存済みの模型計算から3段階を抽出。Boltzの原子座標の予測結果ではない。

本教材の導出・模型計算・演習

④ 分子どうしを一緒に配置する｜全分子の座標

複合体全体の配置を、一緒に予測する

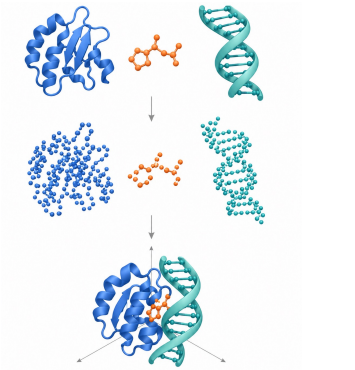
タンパク質・核酸・低分子を原子（水素を除く）で表し、全分子を合わせた $M\times 3$ 個の座標を生成する。分子どうしの位置と向きも出力の一部になる。

$$X \in \mathbb{R}^{M\times 3}, \quad D_\theta(X,\sigma;c)$$

$$X_\sigma = X_0 + \sigma\epsilon$$

複合体予測を支えるのは、①多様な分子の共通の表現、②分子をまたぐ情報交換、③既知の複合体を含む構造データからの学習。

学習では複合体の座標 X_0 にノイズを加え、条件 c から元の配置を予測する。拡散は座標を生成する方法で、結合位置の知識は学習済みネットワークにある。

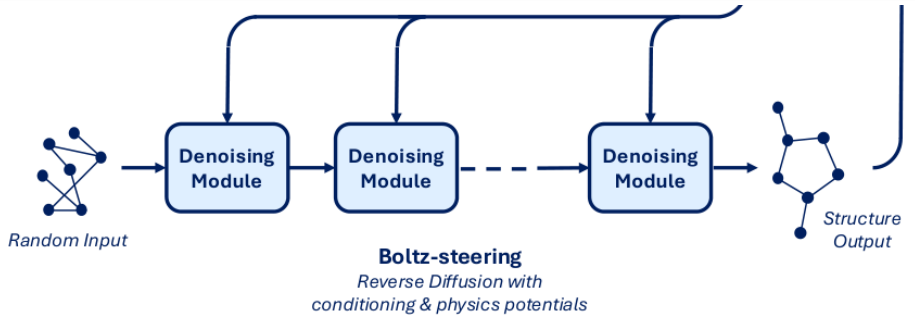


模式図：多様な分子 → 全原子 → 共通の座標系の複合体。実測・予測構造ではない。

Passaro et al., Boltz-2 (2025), bioRxiv / Boltz source 2.2.1 · b1ebfc4 · 参照 2026-10-09

④ 分子どうしを一緒に配置する｜座標生成部

原著の図で、座標生成部を見る



上から来る線は共通部分からの条件 c。各段で変わるのは座標 X とノイズ量 σ。

同じ重み θ のデノイザーを繰り返す。段ごとに別のモデルを学習するわけではない。

Passaro et al., Boltz-2 (2025) · Fig. 2 座標生成部より。パネルを切り出し

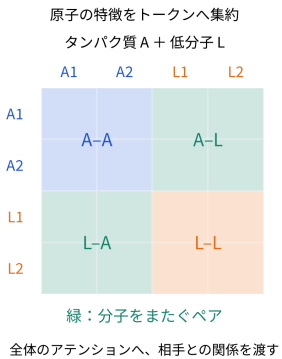
Passaro et al., Boltz-2 (2025), bioRxiv

④ 分子どうしを一緒に配置する｜分子をまたぐ情報

分子をまたぐペアから、相手の情報を受け取る

原子の特徴を所属トークンへ集める。タンパク質 A と低分子 L のトークンを一緒に扱い、分子をまたぐペアの表現も用いる。

図の緑の領域が A–L と L–A の組。ペア表現は関係を表す特徴ベクトルで、距離や結合確率そのものではない。共通部分で推論したこの情報が、座標生成のトークン間アテンションにも渡る。原子側は局所的に計算しても、トークン側では分子の境界を越えて情報を伝えられる。



A1,A2：タンパク質の残基。L1,L2：低分子の原子。色はペアの種類で、数値の大小ではない。

④ 分子どうしを一緒に配置する｜分子をまたぐ情報

相手の情報を使って、全原子の座標を更新する

分子間の情報を含むトークン特徴を各原子へ戻し、原子側の情報と結合する。全分子の座標予測 D を同じ空間内で出す。

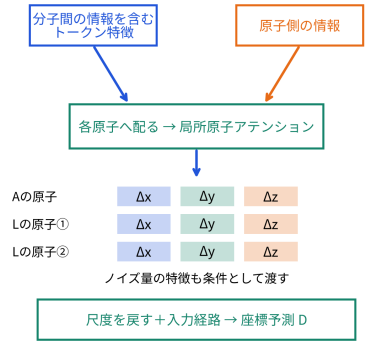
$$c_{\text{noise}} = \frac{1}{4}\log(\sigma/\sigma_{\text{data}})$$

$$\phi_k(t) = \cos\left(2\pi(\omega_k t + b_k)\right)$$

低分子の原子の更新も、タンパク質側の情報に依存できる。全原子をまとめて更新するので、分子内部の形と分子どうしの位置・向きを同時に予測する。

ノイズ量は c_{noise} を上の特徴へ変換し、トークン単位のアテンションへ知らせる（ω_k、b_k は固定の乱数）。

構造を生成できても、実際の結合や結合の強さを証明したことにはならない。



AとLの各原子へ三成分の補正を出す。原子ごとに出力しても、各分子を独立に予測しているわけではない。

④ 分子どうしを一緒に配置する｜学習の工夫

向きを変えて学習し、重ね合わせて誤差を測る

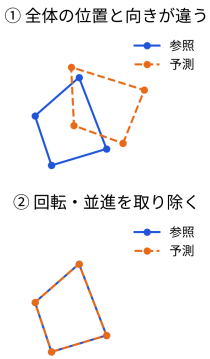
学習では座標を中心化し、ランダムに回転・並進する。向きへの偏りを防ぐデータ拡張である。

$$\min_{R,t} \sum_i w_i m_i \|\hat{x}_i - (Rx_i + t)\|^2$$

$$R^T R = I, \quad \det R = 1$$

損失では正解座標を予測へ剛体で重ね合わせ、全体の位置と向きを除いて形の差を測る。これが前回の FAPE に代わる。

R は行列式が正の直交行列なので、鏡像へ反転して誤差を減らすことはできない。



同じ4点の形を回転・並進した模型。下では完全に重なるが、形の違いがあれば残差が残る。

④ 分子どうしを一緒に配置する｜学習の工夫

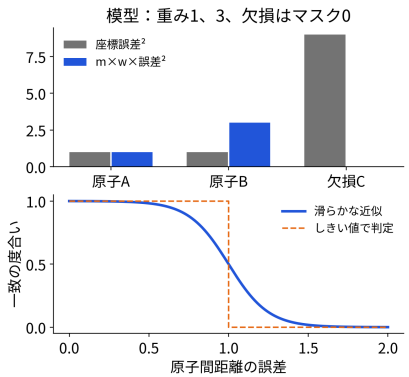
原子の種類とマスクで損失を重み付け

欠損座標はマスク $m=0$ で除く。原子の重み w は、タンパク質 1、核酸 6、低分子 11 とする。

$$L_{\text{coord}} = \mathbb{E}_\sigma\left[\lambda(\sigma)\frac{\sum_i m_i w_i \|\hat{x}_i - x_i^{\text{aligned}}\|^2}{3\sum_i m_i w_i + \varepsilon}\right]$$

有効な重みの合計と3成分で割り、ノイズ量の重み λ を掛ける。

局所の距離には滑らかな lDDT 型の損失も足す。距離は回転・並進に依存しないが、鏡像を区別できない。



上の重み 1、3 と下の滑らかな曲線は説明用の模型で、Boltz の実際の値ではない。

④ 分子どうしを一緒に配置する｜Boltz-2 の実際の値

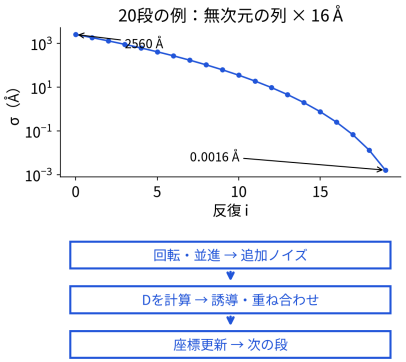
Boltz-2 のノイズ列：2560 Å から 0 まで

Boltz-2 の既定は σ_{data}=16 Å、$s_{\max}$=160、s_{min}=0.0001、ρ=7。無次元の列に σ_{data} を掛けて Å の単位へ変換する。

$$\sigma_i^{\text{actual}} = \sigma_{\text{data}} \left[s_{\max}^{1/\rho} + \frac{i}{N-1}\left(s_{\min}^{1/\rho} - s_{\max}^{1/\rho}\right) \right]^{\rho}$$

初期座標は標準偏差 2560 Å の乱数。最小は 0.0016 Å で、最後に 0 を加える。

各段の順序：回転・並進 → 追加ノイズ（γ=0.8、尺度 1.003）→ D → 有効なら誘導 → 重ね合わせ → 更新。



右上：ρ=7、20段の例。対数軸に 0 は描けないので、最後の 0 は表示していない。

④ 分子どうしを一緒に配置する｜Boltz-2 の実際の値

Boltzの更新はEuler型に尺度を加える

ハットの付いた Xは追加ノイズを足した座標。波線の Xは、それを予測 D_iへ重ねた座標。a は step_scale で、Boltz-2 の既定は a=1.5。

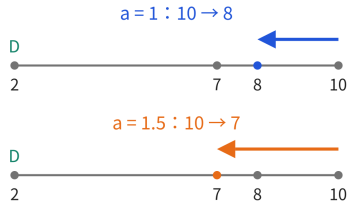
$$D_i = D_\theta(\hat{X}_i, \hat{\sigma}_i; c), \quad X_{i+1} = \bar{X}_i + a(\sigma_{i+1} - \hat{\sigma}_i)\frac{\bar{X}_i - D_i}{\hat{\sigma}_i}$$

$$d = (10-2)/4 = 2$$
$$x_{\text{next}} = 10 + (3-4)\,2 = 8$$
$$a = 1.5 \quad \Rightarrow \quad x_{\text{next}} = 7$$

模型：現在値 10、予測 D=2、$\hat{\sigma}$=4、次の σ=3。a=1 なら 8、a=1.5 なら 7 へ進む。

a を小さくすると候補の多様性が増える（公式の説明）。一段に D を呼ぶのは1回で、Heun 法の2回目はない。

同じ予測 D、移動量だけを変える



傾き (10−2)/4 = 2

ノイズ量の差：3−4 = −1

模型の一成分。回転・誘導は省略。

右：同じ出発点と Dから、aだけを変えて比較。模型では誘導・重ね合わせを省いた。

④ 分子どうしを一緒に配置する｜三つの設定

リサイクリング・段数・候補数は別の設定

反復は2種類ある

リサイクリング：共通部分の出力を入力へ戻し、分子の関係を計算し直す。

拡散の段数：共通部分の表現を条件に、原子座標を更新する回数。

候補数は反復ではなく、乱数（初期ノイズと途中のノイズ）を変えて作る構造の数。

既定：リサイクリング3回・200段・1候補

演習：リサイクリング1回・20段・1候補

三つの設定は、変える対象が違う

recycling

表現 → trunk → 表現 ↺

分子の関係を表す内部表現を再計算する。

diffusion steps

X(σ大) → X(σ中) → X(σ小)

1候補を生成する座標更新の段数。

diffusion samples

初期乱数① → 候補①　／　②→②

乱数を変えて作る候補の数。

⑤ 予測を読む｜評価指標

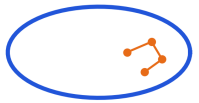
構造の評価は一つの数で済まない

全体の折り畳み、局所の原子配置、鎖間の向き、低分子の結合位置は異なる評価対象。どの原子・鎖を見るかを決める。

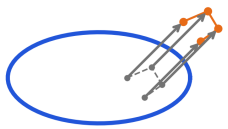
$$\text{RMSD} = \sqrt{\frac{1}{N}\sum_i \|Rx_i + t - y_i\|^2}$$

RMSDは対応原子のずれの二乗平均の平方根。どの原子で重ね合わせたかで値が変わる。タンパク質を固定した低分子の評価では、その配置のずれが残る。対称原子の対応・欠損もそろえる。結合・衝突・立体化学も確認する。

参照：タンパク質と低分子



予測：タンパク質は一致、低分子はずれ



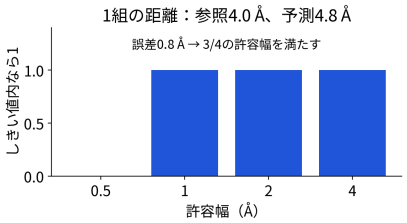
模型：青のタンパク質は一致。橙の低分子がずれ、灰の参照位置との差が残る。

⑤ 予測を読む｜評価指標

局所距離と界面の指標

lDDTは参照構造との局所距離が複数の許容幅に入るかを評価する。全体の剛体重ね合わせは不要。

右上は1組の距離だけの例。実際は評価対象の局所ペアに集計する。DockQは界面の複数指標を組み合わせ、鎖の対応も必要。一方、pLDDT・ipTMはモデルが予測した信頼度で、正解構造と比較して測った精度ではない。



参照構造と比較：lDDT・DockQ

測った精度と、予測された信頼度を分ける

正解なしでモデルが予測：pLDDT・ipTM

1組の距離差0.8 Åなら、許容幅0.5 Åは不合格、1・2・4 Åは合格となる。

lDDT: Mariani et al., Bioinformatics (2013), doi:10.1093/bioinformatics/btt473 / DockQ: Basu & Wallner, PLOS ONE (2016), doi:10.1371/journal.pone.0161879

⑤ 予測を読む｜信頼度

局所構造と分子間の配置を分けて読む

pLDDT：局所構造

各トークンの局所信頼度。JSON／NPZは0–1、演習の図は100倍。

PAE：相対配置

一方を基準にした配置の予測誤差（Å）。小さいほど高信頼と予測。

ipTM：分子間の配置

界面の相対配置の予測信頼度（0–1）。鎖の組ごとの値も確認する。

読む順序：タンパク質の形 → 低分子の位置 → 局所の信頼度 → 分子間の信頼度。

局所：トークンごとの値



配置：トークン対ごとの値

青：配置誤差が小さい／橙：大きい。
説明用の模式図で、実測値ではない。

信頼度は実測の精度・結合確率・結合親和性ではない。親和性の予測は今回の対象外。

まとめ

5つの問いへの答え

① なぜ座標の作り方を替えるのか

低分子には残基のフレームも共通の二面角もない。原子の座標を拡散モデルで直接生成する。

② どう学習するのか

既知の構造にノイズを加え、元の座標を予測するデノイザーを学習する。

③ どう座標を生成するのか

デノイザーからスコアを求め、ノイズ量を下げながら座標を積分する。

④ どう分子どうしを配置するのか

分子間の情報を含むペア表現を条件に、全原子の座標を一緒に更新する。結合位置の知識は、既知の複合体から学習したネットワークにある。

⑤ どこまで信じてよいか

信頼度はモデルの予測で、RMSD や lDDT の実測の精度とは別。局所と分子間を分けて読む。高い信頼度は結合の有無・親和性・機能の証明ではない。生成の経路は分子の運動ではなく、生成の割合は存在確率を保証しない。

Boltz演習

WebClass のリンクから、Colab で複合体を予測する

1. 開く
WebClass「06_演習」のリンクから Colab へ

→

2. 実行
T4 GPU を選択
すべてのセルを実行

→

3. 観察・保存
信頼度・3D構造
実験構造との比較

入力：MfnG（鎖 A）、SAH（C）、チロシン（E）、配布した MSA。
Boltz 2.2.1、リサイクリング1回・20段・1候補・seed 42。

演習は20分を目安とし、採点・提出はない。初回の取得と計算待ちは環境による。
T4 が割り当てられない場合や間に合わない場合は、本編の最後の2ページの実行例を読む。
反復を減らした動作確認用の条件で、研究で精度を判断する標準条件ではない。

Boltz演習

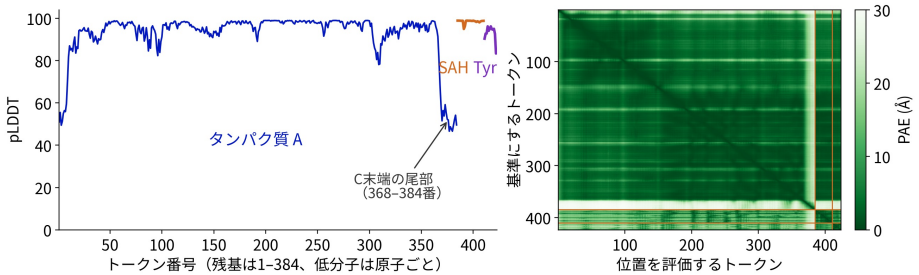
セルの順に、信頼度と構造を読む

見るもの	操作	対応する講義の内容
信頼度の数値	セル5の ligand_iptm、鎖の組ごとの ipTM を読む	⑤ 分子間の信頼度
pLDDT と PAE	グラフの縦線で鎖を区別する。低分子は原子ごとのトークン	⑤ 局所の信頼度と相対配置の誤差
立体構造	セル6で回転・拡大し、低分子の位置を確認する	④ 同じ座標系への配置
実験構造	セル7で 7UX8 と比べ、低分子のずれを読む	⑤ タンパク質で重ね合わせた RMSD
条件を変える	余裕があれば sampling_steps を 40 へ変え、セル4〜7を再実行	④ 段数と候補数の違い

diffusion_samples は候補数で、sampling_steps とは意味が違う。
セル8の ZIP には入力・MSA・CIF・信頼度・実行条件・ログが入る。重みは含めない。

Boltz演習｜実行例

タンパク質の本体、尾部、低分子で信頼度が違う

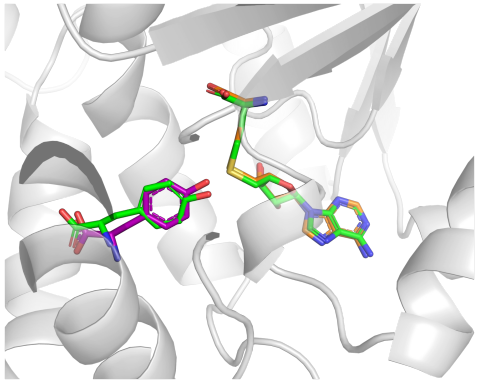


平均 pLDDT：本体（1–367番）94、C末端の尾部（368–384番）53、SAH 98、チロシン 92。ipTM 0.98。
タンパク質1鎖のため protein_ipTM = 0。これはタンパク質間の界面がないときの値で、低い信頼度という意味ではない。

2026-10-11 実行：T4、リサイクリング1回、20段、1候補。橙の線が鎖の境界。PAE の行が基準のトークン、列が位置を評価するトークン。

Boltz演習｜実行例

実験構造 7UX8 と比べて確かめる



緑：実験（7UX8 の鎖 B）、橙：SAH の予測、紫：チロシンの予測。タンパク質の Cα で重ね合わせた。

比べたもの	RMSD（Å）
タンパク質の Cα（361残基）	0.68
SAH（26原子）	0.43
チロシン（13原子）	0.62

鎖 A と比べると SAH 0.58 Å、チロシン 1.02 Å。尾部（368番以降）は鎖 A でしか見えず、予測とはずれる。

この一致から言えないこと

7UX8 は2022年公開で、Boltz-2 の学習データの期限（2023年6月）より前の構造。未知の複合体に対する性能を示す結果ではない。
結晶は同じ鎖2本の組（二量体）だが、入力は1本の鎖である。

付録

拡散モデルの導出を、途中式から確認する

A　確率と二乗誤差

確率密度・分散・条件付き平均。

B　DDPM

順過程の合成、事後分布、変分下限、ノイズ予測の損失。

C　スコアと逆時間の生成

スコア恒等式、Fokker–Planck方程式、逆SDE、確率流ODE。

D　EDMと数値計算

尺度係数の導出、Euler法とHeun法の誤差と計算量。

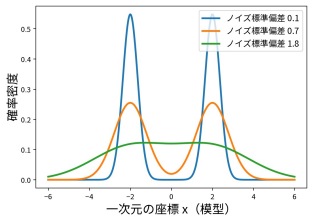
確率密度は面積で読む

1 確率密度は面積で読む

連続する座標xがちょうど一つの値を取る確率は0です。区間へ入る確率を、密度pの積分で表します。

密度そのものは1を超えても構いません。全領域の面積が1になることが条件です。

下図の二つの山は、二通りの状態が現れやすい模型。



2 正規分布でノイズを表す

正規分布は平均の周囲に広がる分布です。標準偏差σが大きいほど広がります。

標準正規分布からεを取り、σを掛けて平均μを足すと、望む分布を作れます。

多次元では各成分へ独立な標準正規ノイズを与える例から始めます。

$$p(x)=\frac{1}{\sqrt{2\pi\sigma^2}}\exp\left[-\frac{(x-\mu)^2}{2\sigma^2}\right]$$

$$x=\mu+\sigma\epsilon,\quad \epsilon\sim\mathcal{N}(0,1)$$

三次元の原子座標では成分ごとの乱数を並べます。この独立な正規ノイズは生成計算の道具であり、分子に働く力そのものではありません。

本教材の導出・模型計算・演習 / Ho et al., Denoising Diffusion Probabilistic Models, NeurIPS (2020)

分散は尺度の二乗で変わる

1 分散は尺度の二乗で変わる

平均0・分散1の独立なε1、ε2を考える。和の分散は各項の分散の和になる。

係数aを掛けると、分散はaの二乗倍になります。

この二つの性質により、何段階も加えた正規ノイズを一つにまとめられます。

$$\mathrm{Var}(a\epsilon_1+b\epsilon_2)=a^2+b^2$$

$$\mathbb{E}[\epsilon_1\epsilon_2]=0$$

2 独立なノイズの分散が足せる理由

平均0の独立なノイズε1、ε2を考えます。

二乗を展開すると交差項が出ますが、独立性と平均0からその期待値は0です。

係数そのものではなく、係数の二乗が分散へ掛かります。

$$\mathbb{E}[(a\epsilon_1+b\epsilon_2)^2]=a^2\mathbb{E}[\epsilon_1^2]+2ab\mathbb{E}[\epsilon_1\epsilon_2]+b^2\mathbb{E}[\epsilon_2^2]$$

$$\mathbb{E}[\epsilon_1\epsilon_2]=0,\quad \mathrm{Var}(a\epsilon_1+b\epsilon_2)=a^2+b^2$$

本教材の導出・模型計算・演習 / Ho et al., Denoising Diffusion Probabilistic Models, NeurIPS (2020)

二乗誤差は条件付き平均を学ぶ

1 二乗誤差は条件付き平均を学ぶ

ノイズ座標xが同じでも、元の構造yには複数の可能性があります。

二乗誤差の期待値を最小にする答えは、yの条件付き平均です。平均との差と予測のずれに分けると分かります。

一回のノイズ除去が、元の構造を一意に復元するとは限りません。

$$\mu(x)=\mathbb{E}[y\mid x]$$

$$\mathbb{E}[\|y-a\|^2\mid x]$$

$$=\mathbb{E}[\|y-\mu(x)\|^2\mid x]+\|a-\mu(x)\|^2$$

続く導出では、平均を選ぶと誤差が最小になる理由を式の展開で確かめます。

2 平均を選ぶと二乗誤差が最小になる

ノイズを含む入力xを固定し、元データyの推定値dを選びます。

条件付き平均mを加えて引き、二乗を展開します。

残る二項のうち、dで変わるのは平均からの距離だけです。

$$m=\mathbb{E}[y\mid x]$$

$$\mathbb{E}[\|y-d\|^2\mid x]=\mathbb{E}[\|y-m\|^2\mid x]+\|m-d\|^2$$

E[y−m｜x]=0なので、二乗の展開に現れる交差項は消える。第1項はyの条件付き分散で、dに依存しない。第2項は$\|m-d\|^2\geq 0$で、d=mのとき最小になる。平均を返すことと、分布から標本を生成することは別である。

Karras et al., Elucidating the Design Space···, NeurIPS (2022) / 本教材の導出・模型計算・演習

条件付き分布とベイズ則

条件付き分布は情報を固定する

配列や低分子の情報 c を指定すると、知りたい分布は $p(x|c)$ である。

同じノイズ座標でも、条件が変わればもっともらしい構造は変わる。

導出では記号を簡単にするため条件を省くことがある。分子への応用では条件を戻す。

$$p(x\mid c)=\frac{p(x,c)}{p(c)}$$

$$p(x,c)=p(x\mid c)p(c)$$

ノイズ量も予測器へ渡す重要な情報だが、分子を指定する条件とは役割が違う。

ベイズ則で逆向きに考える

正しい構造 x_0 からノイズ座標 x_t を作る確率は、自分で決めた規則で書ける。

逆に x_t から x_0 を推測するには、構造が元々どの程度現れるかという分布も必要である。

分母は、取り得るすべての元の構造について足し合わせた密度である。

$$p(x_0\mid x_t)=\frac{q(x_t\mid x_0)p_{\mathrm{data}}(x_0)}{p_t(x_t)}$$

$$p_t(x_t)=\int q(x_t\mid x_0)p_{\mathrm{data}}(x_0)\,dx_0$$

逆向きの推論が、前向きの式を逆算するだけでは済まない理由がここにある。

Ho et al., Denoising Diffusion Probabilistic Models, NeurIPS (2020) / Passaro et al., Boltz-2 (2025), bioRxiv / Karras et al., Elucidating the Design Space···, NeurIPS (2022)

段階ごとに少しずつノイズを加える

1 段階ごとに少しずつノイズを加える

DDPMは離散的な時刻tでノイズを加えるモデルです。元のデータをx0とします。

βtは一段で加えるノイズの分散で、0と1の間に取ります。元の信号は少し縮めます。

各段は直前だけに依存するマルコフ過程です。

$$q(x_t \mid x_{t-1}) = \mathcal{N}(\sqrt{1-\beta_t}x_{t-1}, \beta_t I)$$
$$x_t = \sqrt{\alpha_t}x_{t-1} + \sqrt{\beta_t}\epsilon_t, \quad \alpha_t = 1-\beta_t$$

2 二段分のノイズをまとめる

二段目の式へ一段目を代入すると、信号の係数は平方根の積になります。

二つのノイズは独立なので、分散は係数の二乗の和です。

その和が1−α1α2になることを、β=1−αを使って確かめます。

$$x_2 = \sqrt{\alpha_2\alpha_1}x_0 + \sqrt{\alpha_2\beta_1}\epsilon_1 + \sqrt{\beta_2}\epsilon_2$$
$$\alpha_2\beta_1 + \beta_2 = 1 - \alpha_1\alpha_2$$

Ho et al., Denoising Diffusion Probabilistic Models, NeurIPS (2020) / 本教材の導出・模型計算・演習

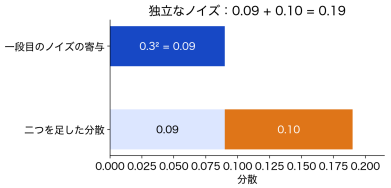
二段のノイズを数値で確かめる

例としてα1=α2=0.9、β1=β2=0.1とします。

信号の係数は0.9、ノイズ分散は0.19です。

標準偏差は√0.19です。0.19をそのままノイズへ掛けないようにします。

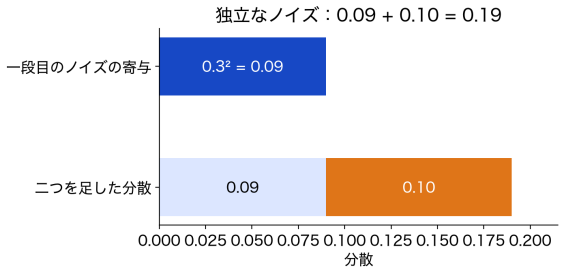
$$x_2 = 0.9x_0 + 0.3\epsilon_1 + \sqrt{0.1}\epsilon_2$$
$$0.3^2 + (\sqrt{0.1})^2 = 0.19$$
$$x_2 \overset{d}{=} 0.9x_0 + \sqrt{0.19}\epsilon$$



信号係数は√0.9×√0.9=0.9。第1段のノイズの係数は√(0.9×0.1)=0.3、第2段は√0.1となる。独立なノイズの分散を足すと0.09+0.10=0.19。式の等号は分布が一致することを表し、同じ乱数値になるという意味ではない。

Ho et al., Denoising Diffusion Probabilistic Models, NeurIPS (2020) / 本教材の導出・模型計算・演習

分散の合成を、係数から順に追う



$$x_2 \overset{d}{=} 0.9x_0 + \sqrt{0.19}\epsilon$$

係数 → 分散 → 標準偏差

① 係数は0.3と√0.1。
② 二乗して0.09と0.10。
③ 独立なので足して0.19。
④ 平方根√0.19を標準正規乱数へ掛ける。

dを付けた等号は分布の一致。同じ乱数値という意味ではない。

本教材の導出・模型計算・演習

任意の段階へ直接進める

1 任意の段階へ直接進める

αの累積積をᾱtと書きます。前の計算を繰り返すと、t段後の分布が分かります。

学習で時刻tのノイズ座標を作るために、1段目から順に計算する必要はありません。

元のデータと一つの正規ノイズだけで直接作れます。

$$\bar{\alpha}_t = \prod_{s=1}^{t} \alpha_s$$
$$q(x_t \mid x_0) = \mathcal{N}(\sqrt{\bar{\alpha}_t}x_0, (1-\bar{\alpha}_t)I)$$
$$x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1-\bar{\alpha}_t}\epsilon$$

条件付き分布が一致するという主張です。

2 終点を単純な分布へ近づける

ᾱtが十分小さくなると、元の信号の係数は小さくなり、分散は1へ近づきます。

このため最後の分布を標準正規分布で近似し、生成の出発点にできます。

有限の段階では厳密に同一とは限りません。ノイズ列と終点の近似を区別します。

$$\bar{\alpha}_T \simeq 0 \quad \Rightarrow \quad x_T \simeq \epsilon, \quad \epsilon \sim \mathcal{N}(0, I)$$

元データに掛かる係数が十分小さくなると、最後の座標の大部分は正規ノイズで決まります。このため生成を単純な分布から始められます。ただし、有限の段数では元データの影響が厳密にゼロとは限りません。終点の近似をよくすることと、一段ごとの学習をよくすることは異なる課題です。学習目標の分解で終点の項が現れるのは、この一致も必要だからです。実装ではノイズの範囲と段数を一緒に確認します。

Ho et al., Denoising Diffusion Probabilistic Models, NeurIPS (2020)

逆向きの遷移を学習する

生成ではxTから始め、xtが与えられたときのxt−1の分布を学習します。

ネットワークが平均を予測し、必要に応じてノイズを加えて一段進めます。

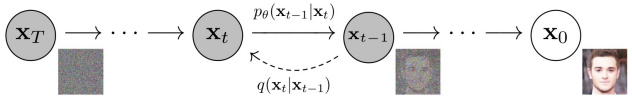
真の逆向き分布は、元のデータ分布に依存します。小刻みな遷移を正規分布で近似します。

$$p_\theta(x_{0:T}) = p(x_T)\prod_{t=1}^{T} p_\theta(x_{t-1}\mid x_t)$$

$$p_\theta(x_{t-1}\mid x_t) = \mathcal{N}(\mu_\theta(x_t,t),\Sigma_\theta(x_t,t))$$

前向きの過程では、ノイズを加える規則を自分で決めました。逆向きでは、その観測を生んだ元のデータがどのように分布するかを知らなければなりません。ネットワークはこの逆向きの遷移を近似します。一つの段の平均と分散が分かれば、平均へ乱数を加えて次の座標を作れます。最後から順に繰り返すことで元データ側へ近づきます。真の逆遷移がどんな刻みでも正規分布になるという主張ではなく、小さな遷移を扱いやすい分布で近似する設計です。

DDPM原著の図で二つの向きを読む



Ho et al., NeurIPS (2020) · Fig. 2より

DDPM原著の図で二つの向きを読む

qはデータからノイズへ進む、あらかじめ定めた過程です。pθは逆向きの遷移を学習します。

同じ変数の列でも、どちらを条件にして次を求めるかが違います。

原著の有向グラフを見て、二種類の矢印をたどります。

まず元のデータを固定した順方向では、ノイズを加える規則が既知なので、学習せずに途中の座標を作れます。

学習時には正解x0が分かる

1 学習時には正解x0が分かる

生成時には未知のx0も、学習時にはデータとして既知です。

x0とxtを両方条件にしたxt−1の分布は、二つの正規分布の積から計算できます。

この計算可能な分布へ、モデルの逆遷移を近づけます。

$$q(x_{t-1}\mid x_t,x_0)\propto q(x_t\mid x_{t-1})q(x_{t-1}\mid x_0)$$

2 平方完成のために変数を一つにする

zを一段前の座標と置き、zに依存する項だけを書きます。

一つ目は今の座標xtを説明する尤度、二つ目は元データx0からの分布です。

定数はzに依存しない項です。

$$z = x_{t-1},\quad v = 1-\bar\alpha_{t-1}$$

$$\log q(z\mid x_t,x_0) = -\frac{\|x_t-\sqrt{\alpha_t}z\|^2}{2\beta_t}-\frac{\|z-\sqrt{\bar\alpha_{t-1}}x_0\|^2}{2v}+\text{const.}$$

二次係数と一次係数を集める

1 二次係数と一次係数を集める

二つの二乗を展開し、zの二次係数Aと一次係数bをまとめます。

zをAの逆数とbの積だけずらすと、一次項を消せます。

したがって事後分散はAの逆数、平均はb/Aです。

$$A=\frac{\alpha_t}{\beta_t}+\frac{1}{v},\quad b=\frac{\sqrt{\alpha_t}}{\beta_t}x_t+\frac{\sqrt{\bar\alpha_{t-1}}}{v}x_0$$

$$-\frac{A}{2}\|z\|^2+b^{\mathsf T}z=-\frac{A}{2}\|z-b/A\|^2+\text{const.}$$

2 正規分布の積を平方完成する

xt−1に依存する二つの二乗項を展開し、二次と一次の係数を集めます。

精度は分散の逆数です。正規分布の積では精度が加算されます。

式の逆数が事後分散になります。tが2以上の段階で導出します。

$$\frac{1}{\tilde\beta_t}=\frac{\alpha_t}{\beta_t}+\frac{1}{1-\bar\alpha_{t-1}}$$

$$\tilde\beta_t=\frac{1-\bar\alpha_{t-1}}{1-\bar\alpha_t}\beta_t$$

事後分散の分母を整理する

1 事後分散の分母を整理する

Aの二つの項を通分します。

αtとβtの和が1、累積積がαt ᾱt−1であることを使います。

逆数を取ると、前ページの事後分散が得られます。

$$A = \frac{\alpha_t(1-\bar{\alpha}_{t-1}) + \beta_t}{\beta_t(1-\bar{\alpha}_{t-1})}$$

$$\alpha_t(1-\bar{\alpha}_{t-1}) + \beta_t = 1 - \bar{\alpha}_t$$

$$A^{-1} = \frac{\beta_t(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t}$$

0<αt<1の条件から、式の事後分散が正であることも確認できる。

2 事後平均は二つの情報を混ぜる

平方完成で残った一次の係数へ事後分散を掛けると平均が得られます。

x0の情報とxtの情報を、ノイズの大きさに応じて混ぜています。

これは学習用に計算できる平均で、生成時にx0を参照できるという意味ではありません。

$$\tilde{\mu}_t = \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1-\bar{\alpha}_t}x_0 + \frac{\sqrt{\alpha_t}(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t}x_t$$

係数は前ページの一次項へ事後分散を掛けて得られます。式が長く見えても、新しい学習パラメータが増えたわけではありません。既知のノイズ列から決まる量です。後で元データをノイズの式へ置き換え、ネットワークが予測できる形に直します。

尤度を直接計算するのは難しい

1 尤度を直接計算するのは難しい

観測したx0の確率は、途中のすべての座標を積分して求めます。高次元ではこの積分が難しくなります。

既知の順過程qで割って掛けると、qに関する期待値へ書き換えられます。

対数の凹性から、期待値を内側へ移した下限を得ます。

$$\log p_\theta(x_0) = \log \mathbb{E}_q\left[\frac{p_\theta(x_{0:T})}{q(x_{1:T}\mid x_0)}\right]$$

$$\log p_\theta(x_0) \geq \mathbb{E}_q\left[\log \frac{p_\theta(x_{0:T})}{q(x_{1:T}\mid x_0)}\right]$$

2 下限を段階ごとの誤差に分ける

下限の符号を反転して最小化する損失にします。終点の一致、中間の逆遷移、最後の復元に分けられます。

KLダイバージェンスは、二つの分布の違いを測る非負の量です。

中間段階では、計算できる事後分布とモデルの分布を近づけます。

$$L = L_T + \sum_{t=2}^{T} L_{t-1} + L_0$$

$$L_{t-1} = \mathbb{E}_q D_{\mathrm{KL}}\big(q(x_{t-1}\mid x_t, x_0)\,\|\,p_\theta(x_{t-1}\mid x_t)\big)$$

和の添字がどこからどこまでかも見てください。最後の復元は中間の正規事後と同じ扱いにできないため、別の項になっています。

固定分散なら平均の二乗誤差になる

1 固定分散なら平均の二乗誤差になる

二つの正規分布の分散を固定して比較すると、重みに依存する部分は平均の差の二乗です。

モデルの平均を事後平均へ近づけることで、逆遷移のKLを小さくできます。

時刻ごとの係数は異なります。これを無視する簡略損失とは区別します。

$$L_{t-1} = \mathbb{E}_q\left[\frac{\|\tilde{\mu}_t - \mu_\theta(x_t,t)\|^2}{2\sigma_t^2}\right] + \text{const.}$$

2 元の座標の代わりにノイズを予測する

xtを作った式をx0について解けば、ノイズεが分かればx0も計算できます。

事後平均へ代入すると、平均の予測をノイズ予測で表せます。

εθは実際に加えたノイズを完全に知るのではなく、入力から推定します。

$$x_0 = \frac{x_t - \sqrt{1-\bar{\alpha}_t}\,\epsilon}{\sqrt{\bar{\alpha}_t}}$$

$$\mu_\theta = \frac{1}{\sqrt{\alpha_t}}\left(x_t - \frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}}\epsilon_\theta(x_t,t)\right)$$

ノイズ予測の損失に付く係数

1 ノイズ予測の損失に付く係数

モデル平均と事後平均の差を、ノイズの予測誤差で書き直します。

同じxtの項は差を取ると消えます。

平均の二乗誤差へ代入すると、時刻に依存する係数が残ります。

$$\tilde{\mu}_t - \mu_\theta = \frac{\beta_t}{\sqrt{\alpha_t}\sqrt{1-\bar{\alpha}_t}}(\epsilon_\theta - \epsilon)$$

$$L_{t-1} = \mathbb{E}\left[\frac{\beta_t^2}{2\sigma_t^2\alpha_t(1-\bar{\alpha}_t)}\|\epsilon - \epsilon_\theta\|^2\right] + \text{const.}$$

2 簡略損失で何を学ぶのか

元のデータ、時刻、一つのノイズを取り、ノイズを予測する二乗誤差を計算します。

DDPMの簡略損失は、変分下限の時刻依存の重みをそのまま使わず、学習を重み付けし直します。

同じノイズ座標に複数の元データが対応するため、最適な予測は条件付き平均です。

$$x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1-\bar{\alpha}_t}\epsilon$$

$$L_{\text{simple}} = \mathbb{E}_{t,x_0,\epsilon}\|\epsilon - \epsilon_\theta(x_t,t)\|^2$$

ノイズを当てるとスコアを学べる理由

補足導出：X=aY+bε、ε~N(0,I)、aとb>0は固定。ネットワークはXからεを二乗誤差で予測する。

$$\epsilon_*(x) = \arg\min_u E[\|\epsilon - u\|^2 \mid X = x] = E[\epsilon \mid x]$$

1 条件付き平均が二乗誤差の最適解。

$$\nabla_x \log q(x \mid y) = -\frac{x - ay}{b^2} = -\frac{\epsilon}{b}$$

2 条件付きの正規密度は既知なので微分できる。

$$\nabla_x \log p(x) = E[\nabla_x \log q(x \mid Y) \mid x]$$

3 積分の微分とベイズ則で、周辺のスコアへ移す。

$$s_*(x) = -\frac{\epsilon_*(x)}{b}, \quad b = \sqrt{1 - \bar{\alpha}_t}$$

4 DDPMでは信号の減衰aとノイズ尺度bを取り違えない。

条件付き平均E[ε｜X=x]を求めることで、周辺密度のスコアを推定できる。

教師εは自分で発生させる乱数。未知のp(x)を評価せず、その対数勾配を学習できる。

生成の一段を実行する

1 生成の一段を実行する

標準正規分布から初期座標を取り、時刻を大きい方から小さい方へ進めます。

各段階で予測したノイズから平均を計算し、選んだ分散に従うノイズを加えます。

最後の段階の分散や出力の扱いはモデルの定義に合わせます。

$$x_{t-1} = \mu_\theta(x_t, t) + \sigma_t z, \quad z \sim \mathcal{N}(0, I)$$

大きなノイズから始め、現在の座標と段階をネットワークへ渡し、予測ノイズを使って平均を計算します。その平均へ必要なランダム成分を足して一段前へ進みます。最後の段で同じようにノイズを加えるかは、定義した生成手順に従います。学習では任意の段を直接作れましたが、生成ではこの逆向きの更新を順にたどる必要があります。二つの計算手順を混同しないようにします。

2 画像の式を分子へ移すとき

画像の画素の代わりに、各原子の三次元座標を並べたベクトルを考えられます。

ただし分子には回転・並進、原子の対応、化学結合やキラリティーがあります。

BoltzはDDPMの式をそのまま使わず、連続的なノイズ量を用いた尺度調整と生成を採用します。

DDPM：離散段階を理解 → スコア：密度との関係 → EDM：尺度と数値計算 → Boltz：原子座標への設計

正規ノイズを使うという共通点だけで、画像用のモデルをそのまま分子へ移せるわけではありません。この節で学んだ確率と学習の考え方を、分子表現や座標の重ね合わせと組み合わせます。Boltzの説明では、その追加の設計を一つずつ確認します。

学習時と生成時で、使える情報が違う

学習用の事後平均は正解x0を条件にする。生成時にはx0を使わず、学習済みネットワークの予測で置き換える。

学習では既知のノイズを教師にする。生成では観測したノイズ座標から、除去に必要な量を推定する。

次はデノイザーとスコアがどう結びつくかを導きます。

学習：x0と加えたノイズが既知 → 生成：ノイズ座標から推定 → 同じネットワークを全段で使用

学習用の事後平均の式には、元データの座標が現れました。生成の式には、その代わりに学習した予測が必要です。学習時と生成時で参照できる情報を分けます。学習時に使える正解を生成時にも読んでしまうコードでは、本当の予測になりません。次に学ぶスコアの関係も、理想的な教師の性質と、ネットワークが実際に近似する量を分けて読みます。

積分の中の正規密度を微分する

加法ノイズx=y+σεで平滑化した密度を考えます。

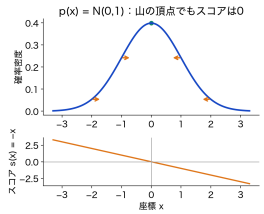
正規密度の指数をxで微分すると、差y−xとσ²の逆数が出ます。

微分と積分を交換できる条件の下で、その結果を積分へ戻します。

$$p_\sigma(x) = \int p_0(y)\, \phi_\sigma(x - y)\, dy$$

$$\nabla_x \phi_\sigma(x - y) = \frac{y - x}{\sigma^2} \phi_\sigma(x - y)$$

$$\nabla_x p_\sigma(x) = \int \frac{y - x}{\sigma^2} p_0(y) \phi_\sigma(x - y)\, dy$$



yは元データ、xはノイズを加えた観測。積分では、xを生じうるすべてのyの寄与を足す。正規密度の指数−||x−y||²/(2σ²)をxで微分すると(y−x)/σ²となり、密度そのものを掛ける。これを積分へ代入し、pσ(x)で割ると、次頁の条件付き平均が現れる。

ベイズ則を使って条件付き平均にする

1 ベイズ則を使って条件付き平均にする

対数の微分は、密度の微分を密度で割ったものです。

積分中の密度の積をpσ(x)で割ると、元データyの事後分布になります。

その分布の平均が、最適なデノイザーDです。

$$\frac{p_0(y)\phi_\sigma(x-y)}{p_\sigma(x)} = p(y \mid x)$$

$$\nabla_x \log p_\sigma(x) = \frac{1}{\sigma^2}\int (y-x)p(y \mid x)\,dy$$

$$s(x,\sigma) = \frac{D(x,\sigma)-x}{\sigma^2}$$

ここまでの等式は、理想的な条件付き平均についての関係です。学習したネットワークでは近似誤差も残ります。

2 条件付き平均がスコアになる

微分した密度を元の密度で割ると、積分の重みがベイズ則の条件付き分布になります。

その積分に現れるyの平均が、最適なデノイザーです。

近似ネットワークでは等号が近似になります。ノイズ量の二乗で割る点が重要です。

$$\nabla_x \log p_\sigma(x) = \frac{\mathbb{E}[y \mid x]-x}{\sigma^2}$$

$$s_\theta(x,\sigma) = \frac{D_\theta(x,\sigma)-x}{\sigma^2}$$

大きなノイズで平均の予測がぼやけることと、その予測を使って生成できることは両立します。どの更新式で利用するかが次の問題です。

なぜランジュバン法で分布を保てるか

補足導出：目標密度πは正で滑らかとし、境界で確率が流出しない場合を考える。スコアs=∇logπは密度の対数の勾配。

$$dX = s(X)\,dt + \sqrt{2}\,dW_t$$

$$\partial_t p = -\nabla\cdot(sp) + \Delta p = -\nabla\cdot J$$

$$J = sp - \nabla p, \quad J\big|_{p=\pi} = \pi\nabla\log\pi - \nabla\pi = 0$$

$$\pi \propto e^{-\beta U} \implies s = -\beta\nabla U = \beta F$$

1 ドリフトで密度の高い側へ動き、ノイズで広がる。

2 Fokker–Planck方程式で、標本の動きを密度の動きへ変える。

3 ∇logπ=(∇π)/πを代入すると、流入と流出が釣り合う。

4 定常であることと、短時間でその分布へ到達することは別。

例：π=N(0,1)なら s(x)=−x。揺らぎを除くと原点へ収束し、分散1の標本にはならない。

離散化すると定常分散もずれる

補足計算：π=N(0,1)、刻みη>0のEuler離散化。ξは各段で独立な標準正規乱数。

1 s(x)=−xを代入する。ノイズと現在値は独立。

$$X_{k+1} = (1-\eta)X_k + \sqrt{2\eta}\,\xi_k$$

2 両辺の分散を取り、交差項を独立性で消す。

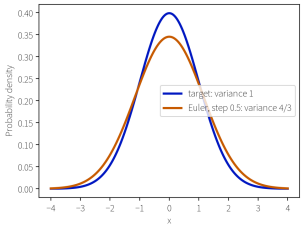
$$v_{k+1} = (1-\eta)^2 v_k + 2\eta$$

3 定常なら前後の分散が同じ。0<η<2で安定。

$$v_* = \frac{2\eta}{1-(1-\eta)^2} = \frac{1}{1-\eta/2}$$

4 標本数を増やしても、この離散化によるずれは消えない。

$$\eta = 0.1 : \ v_* \simeq 1.053, \quad \eta = 0.5 : \ v_* = 1.333$$



青は目標分布、橙は有限刻みでの定常分布。有限刻みでは分散が増え、曲線が横に広がる。
この解析例では、標本数を増やしても積分法の偏りは残る。

区別：有限刻みの偏り、初期分布の影響、有限標本のばらつきは、それぞれ原因が違う。

連続時間の順過程を定義する

1 連続時間の順過程を定義する

時刻tを連続にし、決まった向きの変化fとランダムな変化を合わせます。

Wはウィーナー過程で、短い時間dtの増分の分散がdtになります。

ここではノイズの強さgは時刻だけに依存するとします。座標依存の場合は追加項が必要です。

$$dx = f(x,t)\,dt + g(t)\,dW_t$$
$$\Delta W \sim \mathcal{N}(0, \Delta t\, I)$$

ブラウン運動の増分の分散は時間幅に比例し、標準偏差は時間幅の平方根になります。したがって離散化すると、決定的な項とランダムな項で時間幅の掛かり方が違います。この節ではノイズ係数が位置に依存しない場合を扱い、より一般的な式と混ぜません。

2 密度が変わる式を見る

確率微分方程式に従う多数の標本を考えると、密度の時間変化はFokker–Planck方程式に従います。

第一項は流れによる密度の移動、第二項はノイズによる広がりです。

∇・は流れの発散、Δは各座標に関する二階微分の和です。

$$\partial_t p_t = -\nabla\cdot(f\,p_t) + \frac{g(t)^2}{2}\Delta p_t$$

一つの標本の動きと、多数の標本からなる密度の動きを区別します。発散の項はドリフトで密度が運ばれる効果、ラプラシアンの項はノイズで密度が広がる効果です。係数の二分の一は後の確率流にも残るので、ここで見ておきます。式を読みながら、ノイズだけのときに鋭い山がなだらかになる図を思い浮かべてください。

密度の式はTaylor展開から導ける

補足導出：滑らかな試験関数φと、位置に依存しないノイズ係数g(t)を用いる。境界項は0とする。

$$\Delta X = f\,h + g\sqrt{h}\,\xi, \quad E[\xi]=0,\ E[\xi\xi^T]=I$$

1 平均変位はh、ランダム変位は√hの大きさ。

$$\frac{E[\Delta\varphi \mid X=x]}{h} \to f\cdot\nabla\varphi + \frac{g^2}{2}\Delta\varphi$$

2 二次のTaylor項も平均するとhの次数で残る。

$$\frac{d}{dt}\int \varphi p\,dx = \int \left(f\cdot\nabla\varphi + \frac{g^2}{2}\Delta\varphi\right) p\,dx$$

3 密度で平均する。φは時間に依存しない関数。

$$\int \varphi\,\partial_t p\,dx = \int \varphi\left[-\nabla\cdot(fp) + \frac{g^2}{2}\Delta p\right] dx$$

4 部分積分を1回・2回行い、微分をφからpへ移す。

任意のφについて成り立つので、∂t p=−∇·(fp)+(g²/2)Δp。1/2はTaylor展開の二次項から来る。

逆時間ではスコアが必要になる

1 逆時間ではスコアが必要になる

順過程が分布を広げる一方、逆向きには広がった分布から元の領域へ戻す必要があります。

逆時間のドリフトには、密度のスコアを使った補正が現れます。

式では時間をTから0へ積分し、dtは負です。ノイズ増分の分散には時間幅の絶対値を使います。

$$s_t(x) = \nabla_x \log p_t(x)$$
$$dx = [f(x,t) - g(t)^2 s_t(x)]\,dt + g(t)\,d\bar{W}_t$$
$$dt < 0$$

表示した式では時刻を減らす向きで積分しています。時間幅を正の数として書き直した式と比べるときには、時間の符号も同時に変えてください。符号だけを見て引力と斥力を判断すると誤りやすくなります。

2 符号を短い一段で確かめる

順過程のドリフトが0、戻る時間幅がh>0の場合を考えます。

dt=−hなので、逆時間の補正はプラスのスコア方向です。密度の高い領域へ向かいます。

ノイズを加える向きは決まっていません。分散はgの二乗とhの積です。

$$x_{t-h} \simeq x_t + h\,g(t)^2 s_\theta(x_t,t) + g(t)\sqrt{h}\,\xi$$

戻る幅h>0に対してdt=−h。−g²sに−hを掛けるため、平均変位は+hg²sとなる。ノイズの分散はg²h、標準偏差はg√h。スコアによる平均変位と、ランダムな揺らぎを区別する。

逆向きの補正は確率の流れから読む

補足導出：逆向きの時計τ=T−tとqτ=pT−τを定義する。gは時刻のみに依存し、密度は正で滑らかとする。

$$J_t = f\,p_t - \frac{g^2}{2}\nabla p_t, \quad \partial_t p_t = -\nabla\cdot J_t$$

1 順過程の確率流。逆向きではこの流れが反転する。

$$\bar{J}_\tau = b q_\tau - \frac{g^2}{2}\nabla q_\tau = -J_{T-\tau}$$

2 同じ拡散係数を持つ逆過程のドリフトbを求める。

$$bq - \frac{g^2}{2}\nabla q = -fq + \frac{g^2}{2}\nabla q$$

3 広がる作用は逆過程にも残るため、ドリフトで補う。

$$b = -f + g^2\nabla\log q, \quad dY_\tau = b\,d\tau + g\,dW_\tau$$

4 qで割る。dτ>0の式なので、スコアの係数は正。

山を広げるノイズが残っている分も含めて、山へ戻す必要があると考えると、補正の役割が分かります。

これは逆過程の式の直観的導出。時間反転の成立には正則性条件が必要で、密度だけの一致では経路法則まで一意に決まらない。

同じ密度を運ぶ常微分方程式

密度の二階微分は、密度とスコアの積の発散として書けます。

Fokker–Planck方程式を、速度場が密度を運ぶ連続の式へ書き換えます。

この速度場で標本を動かすと、理想的には同じ時刻の密度が得られます。

$$\Delta p = \nabla\cdot(p\nabla\log p)$$
$$\partial_t p = -\nabla\cdot\left[\left(f - \frac{g^2}{2}s\right)p\right]$$
$$\frac{dx}{dt} = f - \frac{g^2}{2}s$$

確率流の式は、密度の時間変化を決定的な速度場で表し直したものです。出発点を分布から引けば、各標本の動きが決定的でも集団として分布を作れます。逆確率過程のランダム項を消しただけでは密度の式が変わります。二階微分をスコアを含む発散へ書き直すことで、必要な速度が導かれます。続く途中式で係数の由来を確かめます。

密度の式を速度場として読み直す

1 密度の式を速度場として読み直す

この節ではノイズ係数gが時刻だけに依存すると仮定します。

密度の勾配をpとスコアの積へ置き換えます。

確率流の速度vを使うと、密度の保存を表す連続の式になります。

$$\partial_t p = -\nabla \cdot (fp) + \frac{1}{2} g^2 \Delta p$$

$$\Delta p = \nabla \cdot (ps)$$

$$\partial_t p = -\nabla \cdot (vp), \quad v = f - \frac{1}{2} g^2 s$$

スコアの前の二分の一は、密度の拡散項にもともとあった係数から来ています。ノイズだけを削除する操作で得た式ではないことが、この導出から分かります。

2 逆SDEと確率流ODEの違い

逆SDEは各段階でもランダムノイズを加えます。確率流ODEは初期値を決めれば決定的に進みます。

スコアが正確で適切に積分できれば、時刻ごとの分布は同じになります。

一つ一つの経路は同一ではありません。近似スコアと有限刻みでは結果も変わります。

逆SDE：補正係数 g^2 とノイズ → 確率流ODE：補正係数 $g^2/2$ → 同じ周辺分布・異なる経路

同じ時点の密度が一致することは、同じ初期点から同じ経路を通ることではありません。確率的な過程には途中にも乱数が入り、決定的な過程では初期値から経路が定まります。理想的なスコアと正確な積分という条件を離れると、有限の計算では出力分布にも差が出ます。実用上は計算量と結果を比較して手順を選びます。

確率流ODEの1/2を導く

補足導出：確率密度を速度vで運ぶ連続の式と、Fokker–Planck方程式を比べる。

1 順過程ではドリフトによる移流と、ノイズによる拡散が共存する。

$$\partial_t p = -\nabla \cdot (fp) + \frac{g^2}{2} \Delta p$$

2 密度が正の領域で、∇p=p∇logpを使う。

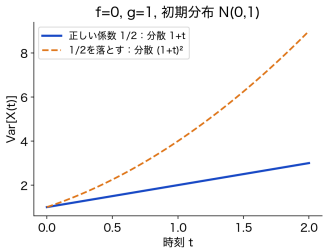
$$\Delta p = \nabla \cdot \nabla p = \nabla \cdot (p \nabla \log p)$$

3 共通の発散へまとめる。ここには新しいランダム項を加えない。

$$\partial_t p = -\nabla \cdot \left[\left(f - \frac{g^2}{2} s \right) p \right]$$

4 同じ時刻ごとの密度を運ぶ速度を読む。初期点の分布は必要。

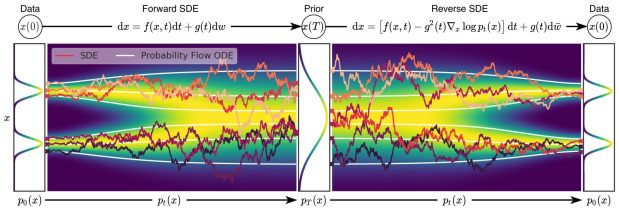
$$\frac{dX}{dt} = f(X,t) - \frac{g(t)^2}{2} s_t(X)$$



速度 x/[2(1+t)] が正しい分散増加を再現。

理想的なスコア・正しい初期分布・厳密な積分の下で密度が一致する。ODEとSDEの個々の軌道は一致しない。

原著の図で順過程と逆過程を読む



原著の図で順過程と逆過程を読む

左はデータをノイズへ広げる過程、右はノイズからデータへ戻る過程です。

背景色は密度、曲線は標本の経路です。同じ時刻の分布が同じでも、経路は異なります。

左右の外側には元のデータ分布、中央にはノイズの分布があります。

ギザギザの線は確率微分方程式による標本、滑らかな線は確率流の常微分方程式による標本です。

Song et al., ICLR (2021), Fig. 2 · 原著図の引用

加える分散をσで表す

1 加える分散をσで表す

信号を縮めず、元データへ分散σの二乗のノイズを足す場合を考えます。

順過程の分散増加率をgの二乗に対応させます。

これを確率流ODEへ代入し、時間の代わりにノイズ標準偏差σを変数にします。

$$g(t)^2 = \frac{d\sigma(t)^2}{dt} = 2\sigma\dot{\sigma}$$

$$\frac{dx}{d\sigma} = -\sigma s(x,\sigma) = \frac{x - D(x,\sigma)}{\sigma}$$

2 ノイズ量を下げて生成する

σを大きい値から小さい値へ進めるので、刻みΔσは負になります。

x−Dはノイズを含む座標からノイズ除去予測への差です。負の刻みを掛けるとDの方向へ進みます。

この式がEDMとBoltzの座標更新を読む基本になります。

$$x_{i+1} = x_i + (\sigma_{i+1} - \sigma_i) \frac{x_i - D_\theta(x_i, \sigma_i)}{\sigma_i}$$

σで積分する式へ変数を変える

補足導出：加法ノイズX=Y+σε、順過程のドリフトf=0。σ(t)>0は微分可能で単調増加とする。

$$g(t)^2 = \frac{d\sigma^2}{dt} = 2\sigma\dot{\sigma}$$

1 独立なノイズの分散が増える速さをg^2とする。

$$\frac{dX}{dt} = -\sigma\dot{\sigma}\, s(X,\sigma)$$

2 確率流ODEへf=0とg^2を代入する。

$$s(X,\sigma) = \frac{D(X,\sigma) - X}{\sigma^2}$$

3 加法ガウスノイズの条件付き平均とスコアの関係を使う。

$$\frac{dX}{d\sigma} = \frac{dX/dt}{d\sigma/dt} = \frac{X - D(X,\sigma)}{\sigma}$$

4 連鎖律で時計をtからσへ変える。生成時はσを減らす。

傾きの符号だけを見て逆向きに動くと判断せず、刻み幅まで掛けた変位を確認しましょう。

単位：XとσがÅなら、dX/dσは無次元。負のΔσを掛けるので、更新はDへ近づく向きになる。

EulerとHeunの誤差は何が違うか

補足計算：x′(σ)=d(x,σ)が滑らかとして一段を展開する。dの微分にはxを通じた変化も入る。

$$x(\sigma+h) = x + hd + \frac{h^2}{2}(\partial_\sigma d + J_d d) + O(h^3)$$

1 連鎖律で二階微分を計算。Jdはdのxに関するヤコビ行列。

$$\tilde{x} = x + hd, \quad \tilde{d} = d(\tilde{x}, \sigma + h)$$

2 Eulerの仮の終点で傾きを評価する。

$$\tilde{d} = d + h(\partial_\sigma d + J_d d) + O(h^2)$$

3 終点の傾きをTaylor展開する。

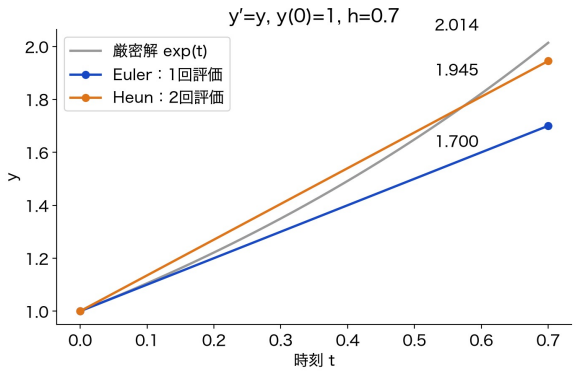
$$x_{\text{Heun}} = x + \frac{h}{2}(d + \tilde{d}) = x + hd + \frac{h^2}{2}(\partial_\sigma d + J_d d) + O(h^3)$$

4 二つの傾きの平均で、二次まで正しい項が現れる。

大域誤差は一定の区間を最後まで進めた差で、段数が刻み幅の逆数程度になるため、一般に次数が一つ下がります。滑らかな例で刻みを半分にし、誤差が何分の一になるかを見れば、この違いを検査できます。

Eulerは局所$O(h^2)$・大域$O(h)$、Heunは局所$O(h^3)$・大域$O(h^2)$。同じ関数評価回数でも比較する。

刻み数だけで計算費用を比べない



説明用の数値計算：h=0.7。青＝Euler、橙＝Heun、灰＝厳密解。

刻み数だけで計算費用を比べない

一段に予測器を二回呼ぶ方法と、一回呼ぶ方法では、同じ段数でも費用が違います。

予測器の評価回数、全体時間、誤差を一緒に記録します。

高い次数の方法でも、ノイズやモデル誤差が大きければ常に有利とは限りません。

左はy′=yを1段だけ進めた例。厳密解と二つの近似を同時に比較する。

Eulerは1回、Heunは2回の関数評価で1段進む。

残差の分散を最小にする係数

ノイズ座標x=y+σεから、元データyを予測します。

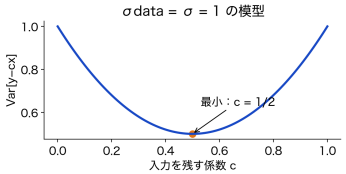
元データとノイズは独立、各成分の平均は0と仮定します。

y−cxの分散をcで微分し、0にするとc_skipが得られます。

$$\mathrm{Var}(y - cx) = (1-c)^2\sigma_{\text{data}}^2 + c^2\sigma^2$$

$$\frac{d}{dc}\mathrm{Var}(y - cx) = -2(1-c)\sigma_{\text{data}}^2 + 2c\sigma^2$$

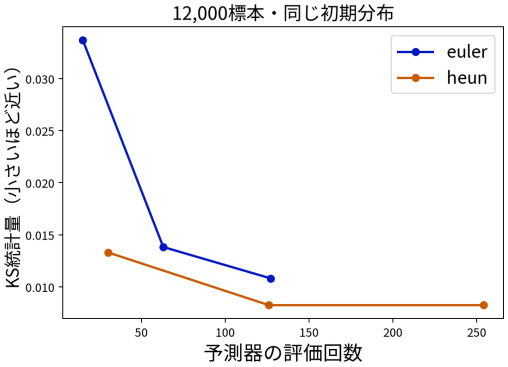
$$c = \frac{\sigma_{\text{data}}^2}{\sigma_{\text{data}}^2 + \sigma^2}$$



残差y−cx=(1−c)y−cσε。独立性から分散は$(1-c)^2\sigma\text{data}^2+c^2\sigma^2$となる。cで微分して0と置けばc_skipが得られる。これは残差の尺度を整えるための係数であり、一般の条件付き平均が線形関数になるという意味ではない。

付録｜拡散モデルと学習

模型の誤差を計算量と比較する



本教材の説明図

本教材の導出・模型計算・演習

模型の誤差を計算量と比較する

同じ初期標本で生成し、最後の分布を理論的な累積分布と比較しました。

KS統計量は累積分布の最大の差で、小さいほど近い値です。横軸は予測器の呼出し回数です。

細かい刻みでも標本誤差が残ります。Boltzの実分子での精度を直接表す結果ではありません。

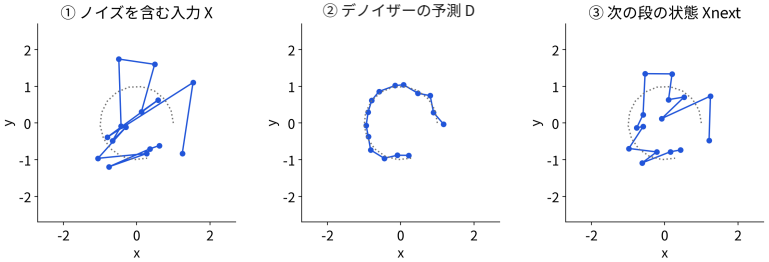
横軸は反復数ではなく、予測器の評価回数です。

縦軸の統計量は累積分布の差を見ており、平均だけが合っているかを検査するものではありません。

付録｜Boltz の実装

途中座標を保存すると何が見えるか

同じ反復でも、①ノイズを含む入力、②デノイザーの予測、③次の段へ渡す状態は異なる。保存する量の名前を明確にする。



実計算は毎段回転も加わるので、共通の基準へ重ね合わせて比較する。途中の大きなノイズの状態は実在の構造ではない。複数の生成構造の割合は平衡確率を保証しないので、RMSF・接触・状態の割合を別の参照データと比べる。

2次元の説明用座標。灰点線は基準形。Boltzの実際の途中出力や分子の運動ではない。

Boltz source 2.2.1・b1ebfc4・参照 2026-10-09 / 本教材の導出・模型計算・演習 / Passaro et al., Boltz-2 (2025), bioRxiv

付録｜参考文献

出典と学び直す場所

Passaro et al., Boltz-2 (2025), bioRxiv

https://doi.org/10.1101/2025.06.14.659707

Wohlwend et al., Boltz-1 (2024/2025), bioRxiv

https://doi.org/10.1101/2024.11.19.624167

Abramson et al., Nature 630, 493–500 (2024)

https://doi.org/10.1038/s41586-024-07487-w

Boltz source 2.2.1・b1ebfc4・参照 2026-10-09

https://github.com/jwohlwend/boltz/blob/b1ebfc46ecf57f5414e0d1a6f9027bbb122c53bc/

付録｜参考文献

出典と学び直す場所

授業用Notebook・入力・演習

https://github.com/matsunagalab/lecture_bioinfo

Boltz prediction documentation・b1ebfc4

https://github.com/jwohlwend/boltz/blob/b1ebfc46ecf57f5414e0d1a6f9027bbb122c53bc/docs/prediction.md

Ho et al., Denoising Diffusion Probabilistic Models, NeurIPS (2020)

https://arxiv.org/abs/2006.11239

Karras et al., Elucidating the Design Space…, NeurIPS (2022)

https://arxiv.org/abs/2206.00364

出典と学び直す場所

Song et al., Score-Based Generative Modeling through SDEs, ICLR (2021)

https://arxiv.org/abs/2011.13456

Vincent, Neural Computation 23, 1661–1674 (2011)

https://doi.org/10.1162/NECO_a_00142

Anderson, Stochastic Processes and their Applications 12, 313–326 (1982)

https://doi.org/10.1016/0304-4149(82)90051-5