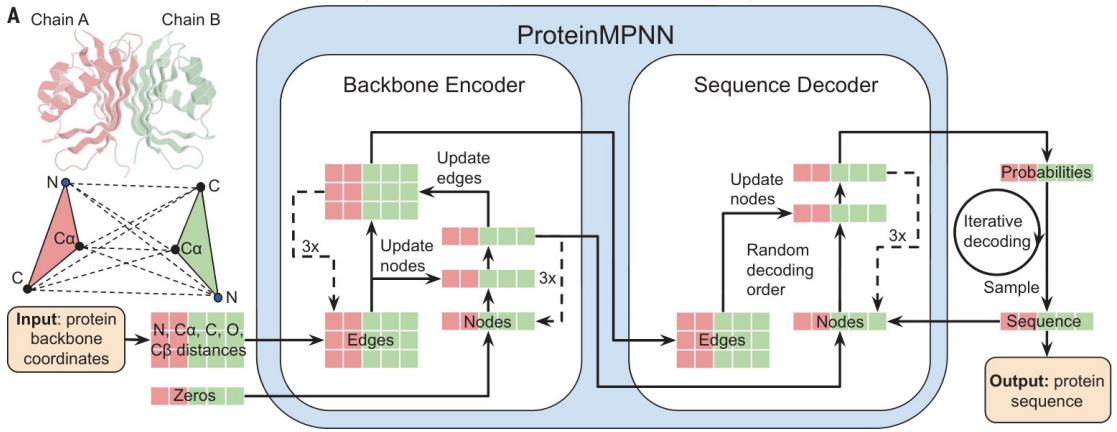
生命情報工学特論　第07回

タンパク質設計



骨格を作り、配列を選び、
予測構造と比べる

骨格 → 配列 → 予測構造
構造を条件に、配列を選ぶ。
元の骨格と再予測した形を比べる。

松永 康佑

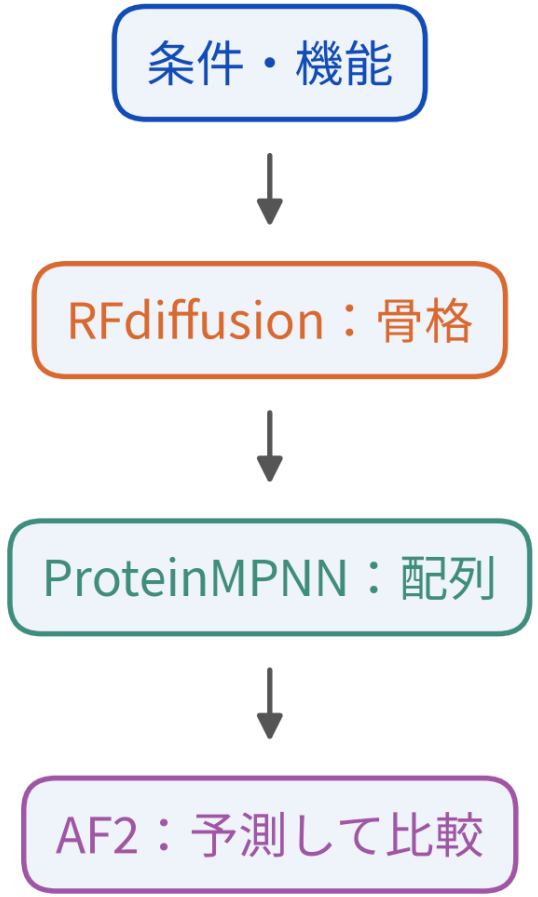
埼玉大学 大学院理工学研究科
理化学研究所 計算科学研究センター

2026年11月9日

講義

目標の構造から配列を作り、予測構造と比べる

入力：目標となる骨格構造や、残したい機能部位。
出力：候補のアミノ酸配列と、その予測構造。
同じ骨格に合う配列は一つとは限らない。
構造の一致と、発現・安定性・機能を分けて評価する。

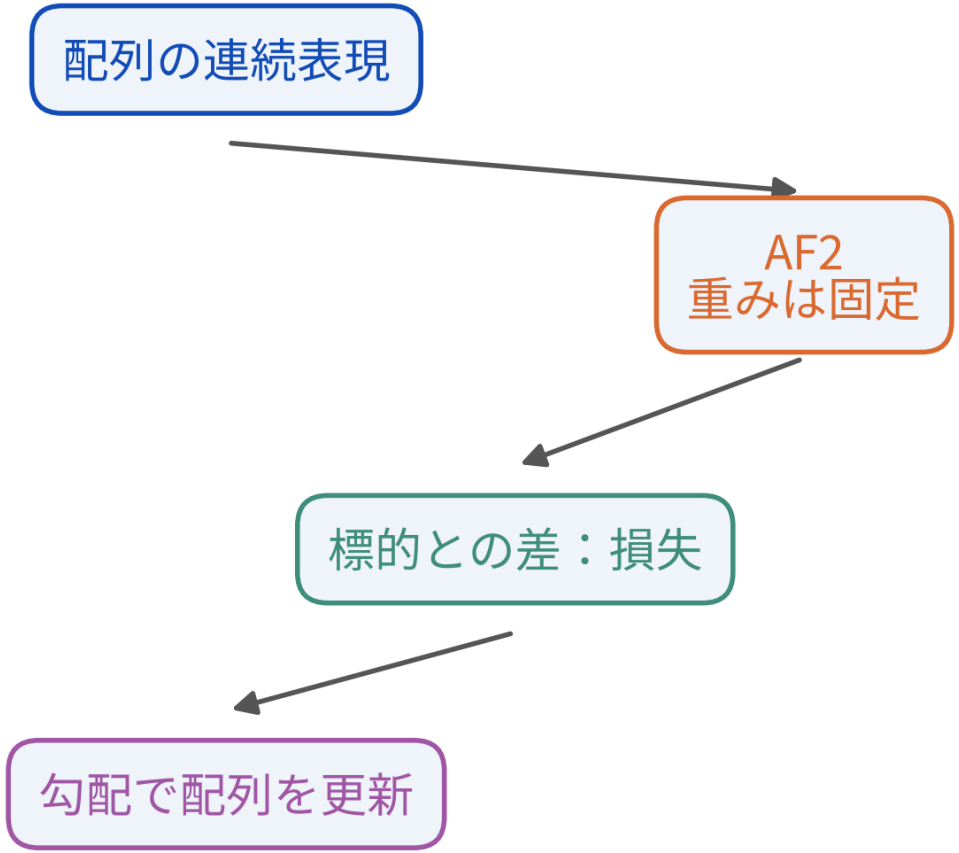


講義

骨格・配列・評価の役割を分けて学ぶ

1　予測と設計：入力と出力の違い
2　RFdiffusion：条件付きの骨格生成
3　ProteinMPNN：構造から配列の分布へ
4　AF2：設計配列を予測して比較
5　AfDesign：予測器を使う配列最適化

最後に固定骨格設計をColabで体験する。



背景

配列設計は構造が決まっている配列を探す逆折り畳み

順方向: 構造予測

配列 s から構造 X を予測する（AlphaFoldなどが扱う）

逆方向: 配列設計（逆折り畳み）

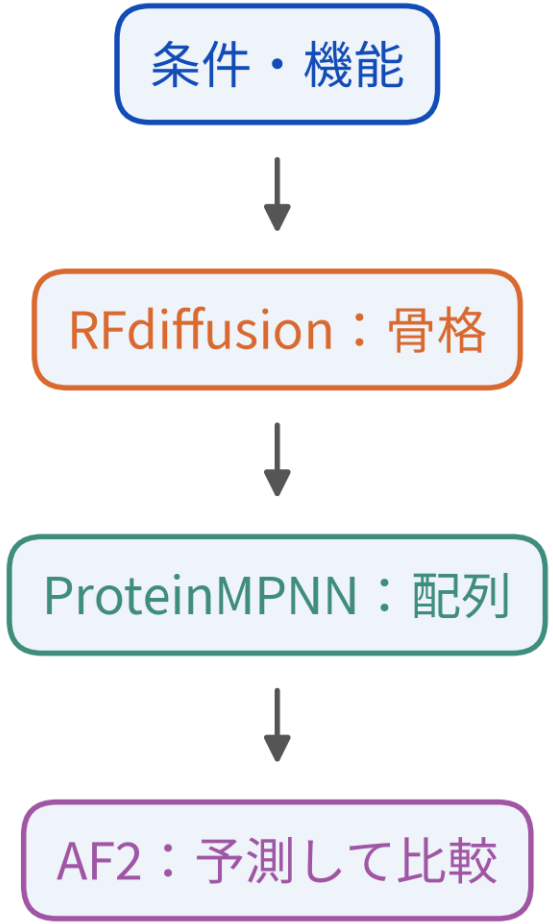
構造 X が先に決まっている。折りたたまれる配列は大勢ある

→ 条件付き確率 $P(s \mid X)$ を出す問題として解く

この論文が解くこと

主鎖構造 X が与えられたときの配列の条件付き確率を、PDBの天然構造から学ぶ

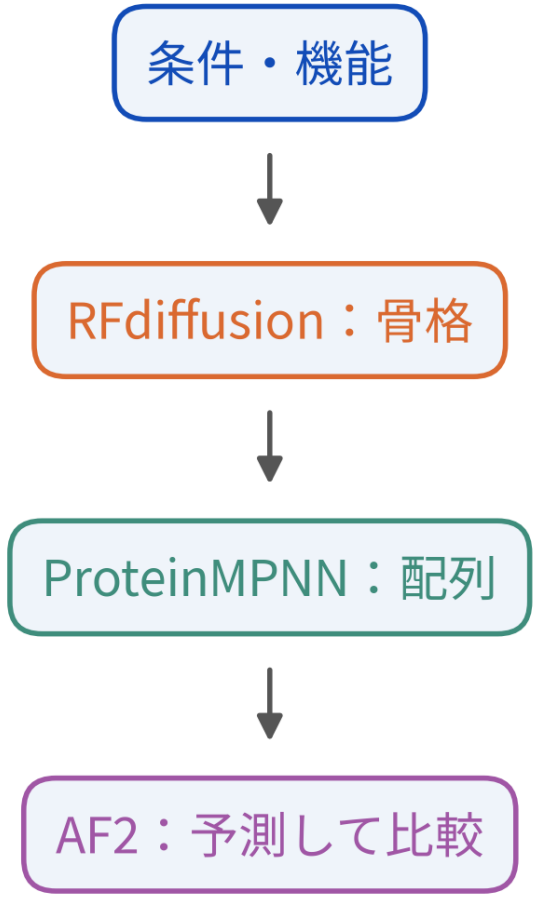
単量体・環状オリゴマー・ナノ粒子・結合界面の設計に同じモデルで対応する



講義

三つのモデルは、異なる条件付き問題を解く

RFdiffusion：長さ・モチーフ・対称性などの条件から、主鎖の形を作る。
ProteinMPNN：与えられた主鎖に合う配列をサンプルする。
AF2：候補配列から構造を予測して、最初の骨格との差を測る。
候補は各段階で複数残し、実験へ進めるものを絞る。



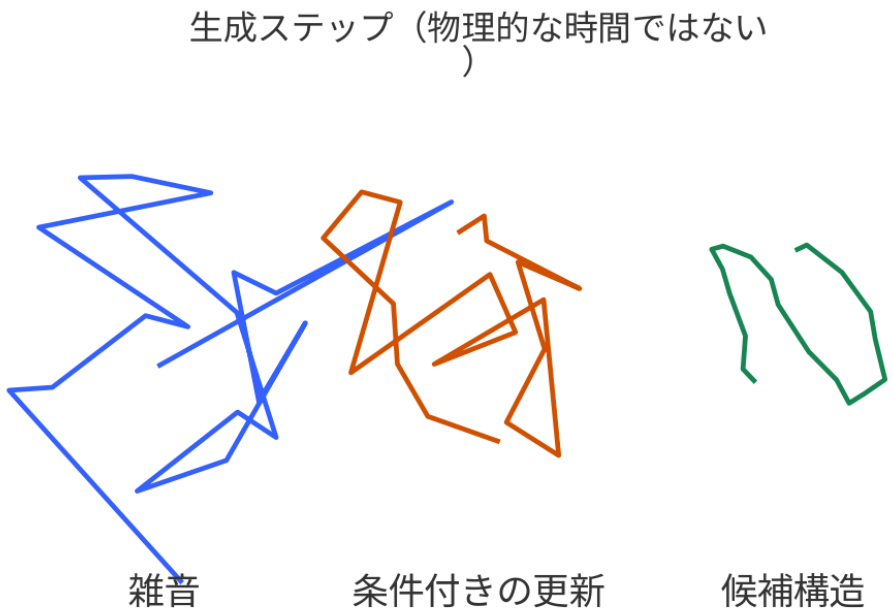
$$X \sim p_\theta(X \mid c), \quad s \sim p_\phi(s \mid X), \quad \hat{X} = f_{\mathrm{AF2}}(s)$$

AIで認識を予測し設計する

拡散モデルは雑音を段階的に減らす

学習では構造などへ雑音を加え、元へ近づける操作を覚えます。生成時は雑音のある状態から、条件に合う候補へ進めます。

この段階は実時間の分子運動とは異なります。生成ステップの動画を、その分子が溶液中で動く経路と解釈しません。



自作模式図（寸法・時間は実物と異なる）

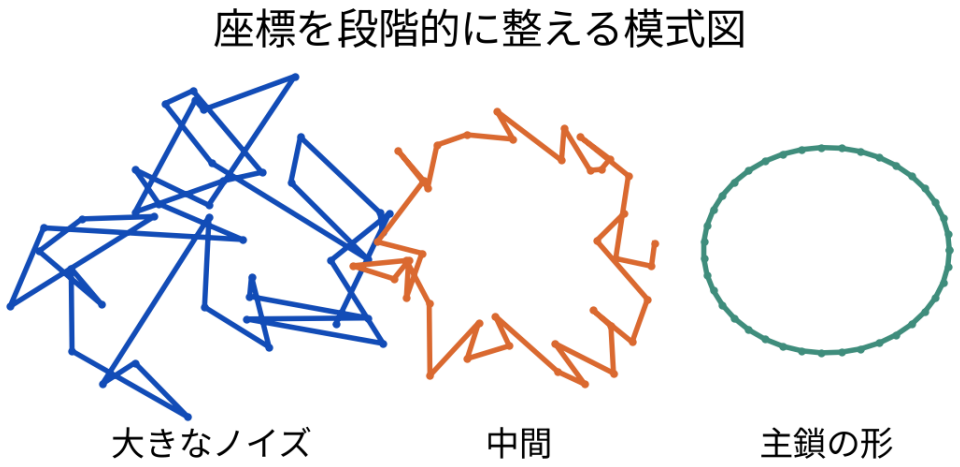
生成過程の時間と、物理的な時間を分ける。

[26] AlphaFold 3　[37] DiffAb

講義

RFdiffusionは主鎖の位置と向きを更新する

残基を、Cαの位置と局所座標系の向きで表す。
学習では既知の主鎖を段階的に乱し、元の配置を推定する。
生成では大きく乱れた配置から始め、同じ学習済みモデルで形を整える。
右は位置だけの模式図。実際には回転のノイズも扱う。折り畳みの物理時間ではない。

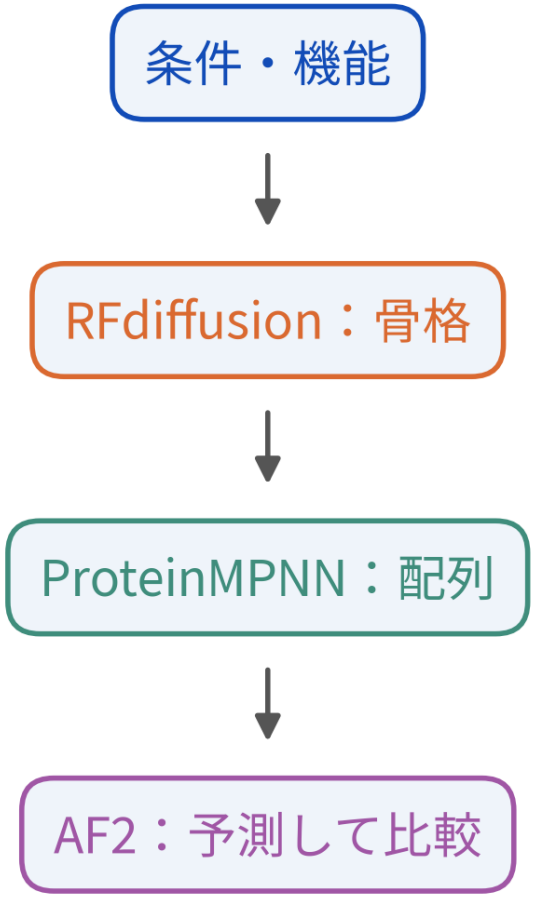


$$\text{residue } i:\ (\mathbf{t}_i, R_i), \quad \mathbf{t}_i \in \mathbb{R}^3,\ R_i \in SO(3)$$

講義

機能部位を残し、その周囲の骨格を生成する

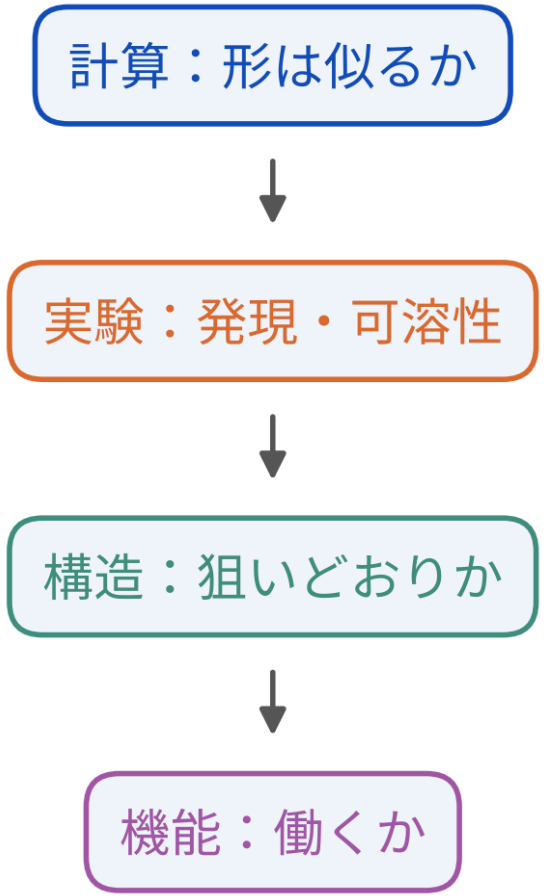
モチーフ：残したい局所構造。例えば触媒残基の配置や結合部位。
固定する部分と、生成する部分を入力で区別する。
結合相手を条件として、接触する新しい骨格を作ることもできる。
条件を満たす座標が出ても、配列が折り畳まれ、機能するとは限らない。



講義

生成した骨格を、配列と実験へつなぐ

RFdiffusionの出力だけでは、発現するタンパク質は決まらない。
一つの骨格につき複数の配列を設計し、再予測して形の再現性を見る。
実験では発現・可溶性、構造、結合や触媒機能を調べる。
計算での絞り込みと実験の成功率を区別する。



方法

ProteinMPNN の全体像

入力は主鎖の座標のみ。encoder（3 層・隠れ次元 128）で節点と枝の特徴を作り、decoder（3 層）がランダムなデコード順で配列を 1 残基ずつ出力する

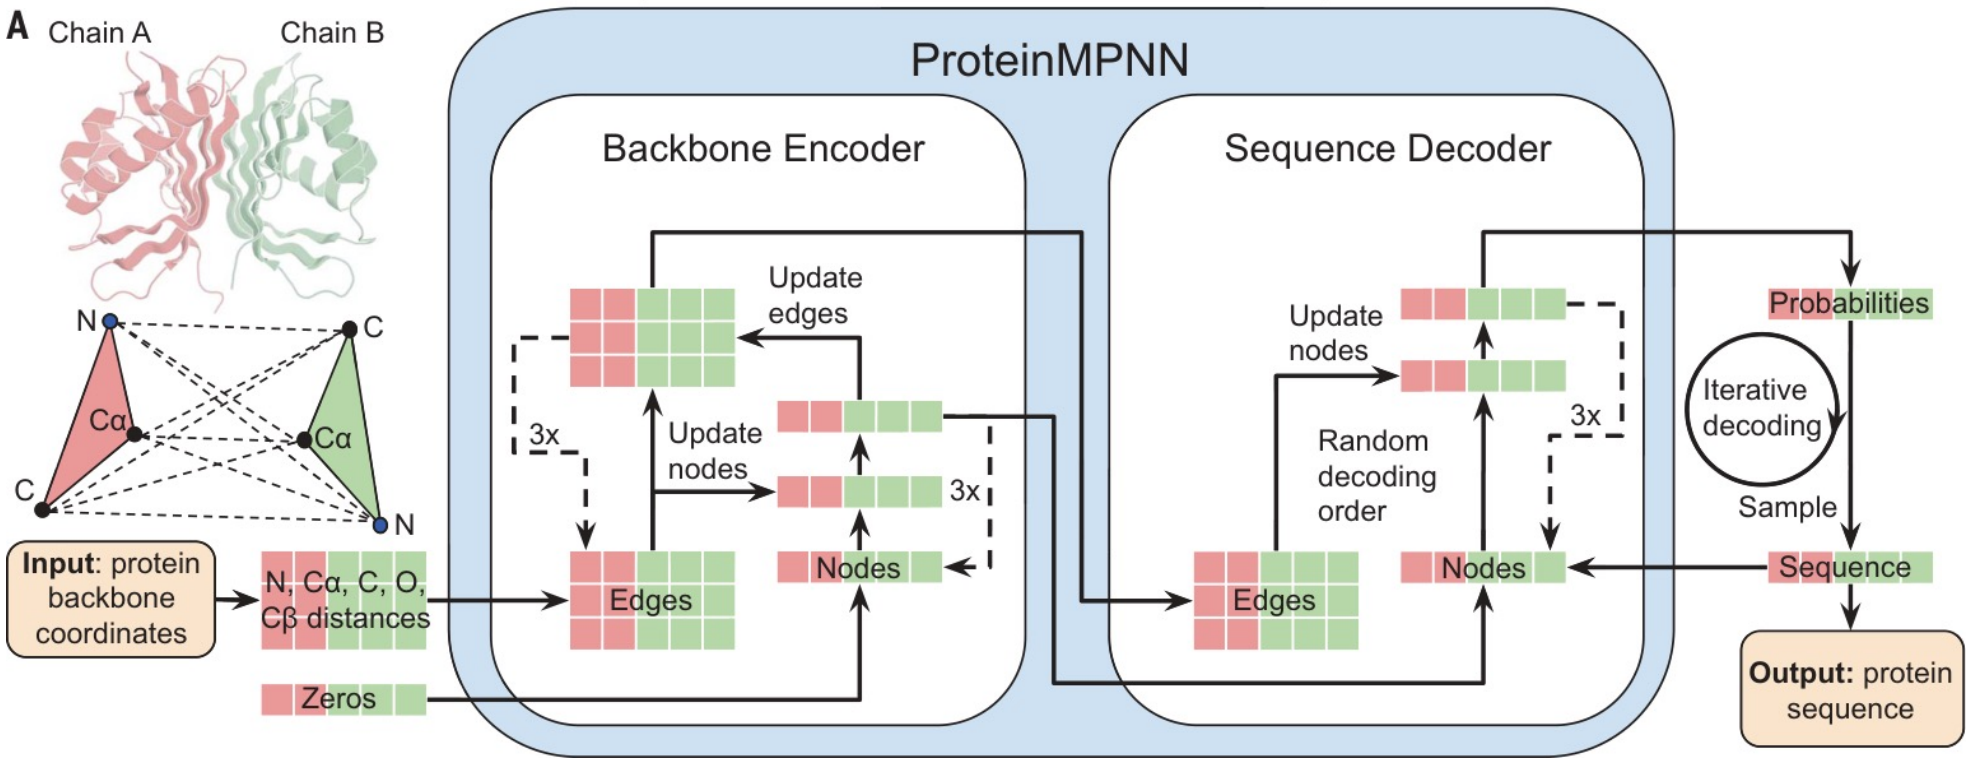


Fig. 1A より

補足

残基のグラフをメッセージパッシングで読む

メッセージパッシングの 1 層（Methods より整理）

$$M_{ij} = \mathrm{MLP}\left[V_i, V_j, E_{ij}\right]$$

$$\mathrm{d}V_i = \sum_{j \in N(i)} M_{ij}$$

$$V_i \leftarrow \mathrm{LayerNorm}\left[V_i + \mathrm{Dropout}(\mathrm{d}V_i)\right]$$

$$E_{ij} \leftarrow \mathrm{LayerNorm}\left[E_{ij} + \mathrm{MLP}\left[V_i, V_j, E_{ij}\right]\right]$$

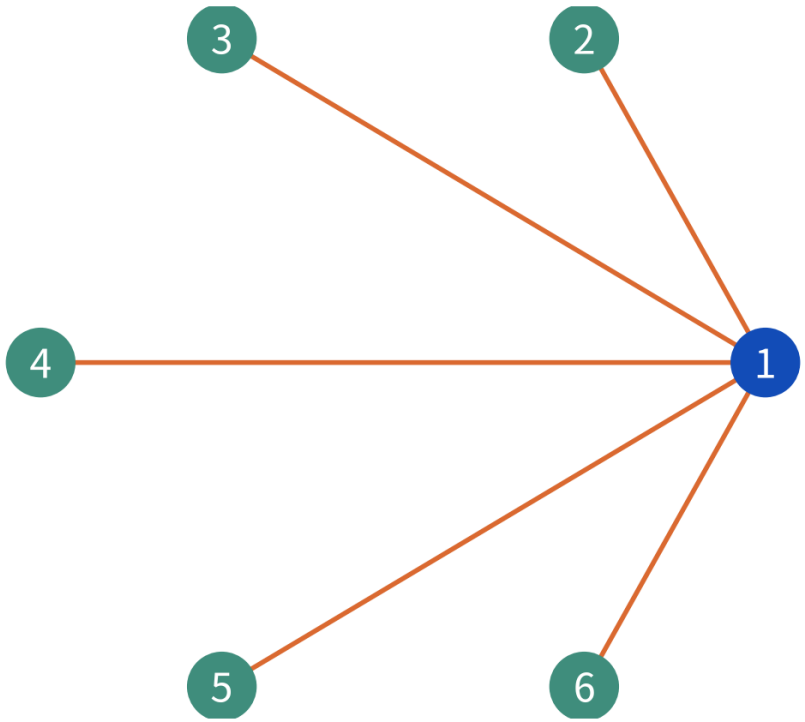
読み方

V_i: 残基 i の節点の状態、E_{ij}: 残基対の枝の状態

メッセージ M_{ij} を隣の残基 j の範囲で足して更新する

encoder は構造を特徴へ、decoder は配列を決め打ちながら出力する

層の直前の値 V_i を残して足す（residual 接続）



距離で近い残基から
メッセージを集める

方法

入力は主鎖5原子の距離、Cβは仮想で作る

仮想 Cβ の作り方（Methods より）

$$\mathbf{b} = \mathbf{C}_\alpha - \mathbf{N},\ \mathbf{c} = \mathbf{C} - \mathbf{C}_\alpha,\ \mathbf{a} = \mathbf{b} \times \mathbf{c}$$

$$\mathbf{C}_\beta = -0.5827\,\mathbf{a} + 0.5680\,\mathbf{b} - 0.5407\,\mathbf{c} + \mathbf{C}_\alpha$$

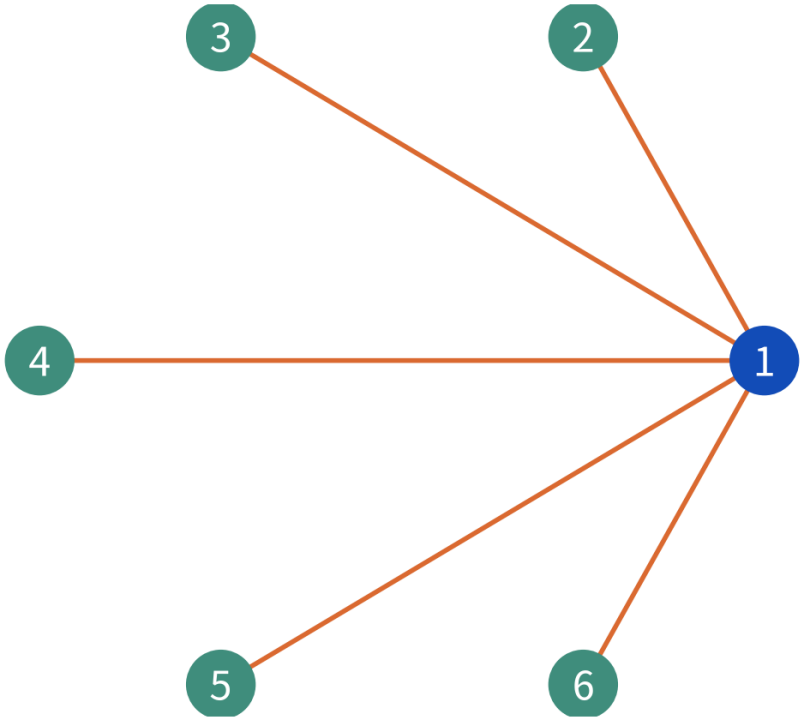
入力特徴

N, Cα, C, O, 仮想 Cβ の残基間距離。16 個のガウス基底関数でエンコード（Table 1 の実験 1）

二面角や座標系の向きより、距離のほうが残基間相互作用をよく表した

Table 1: 回収率 41.2 → 49.0%。パープレキシティ 6.51 → 5.03

ノイズあり学習では 40.1 → 46.1% と、利得は減る（後述）



距離で近い残基から
メッセージを集める

補足

配列は1か所ずつ順に決める自己回帰モデル

確率と学習の式

$$p(a_i \mid X) = \frac{\exp z_i(a)}{\sum_b \exp z_i(b)}$$

$$\mathcal{L} = -\frac{1}{T}\sum_{t=1}^{T} \log P\left(s_{o_t} \mid s_{o_1}, \ldots, s_{o_{t-1}}, X\right)$$

$$\mathrm{PPL} = \exp \mathcal{L}$$

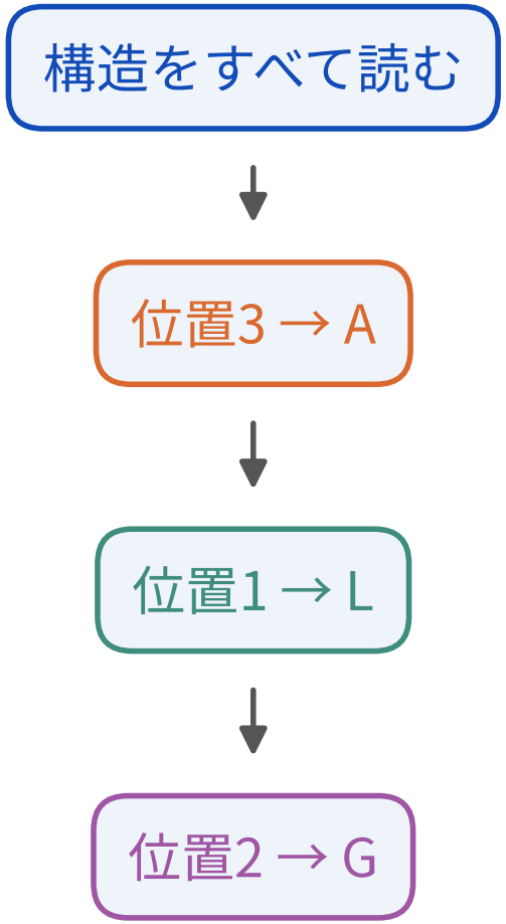
読み方

$z_i(a)$: 残基 i のアミノ酸 a のロジット（正規化前の得点）

正しい天然配列の対数確率を最大にする学習。負の平均が交差エントロピー ¥mathcal{L}

パープレキシティ: 絞り込みの実効的な候補数。1 に近いほど強い予測

Table 1 の「perplexity」はこの値（テスト集合での値）



方法

デコード順をランダムにすると固定領域を扱える

自己回帰の分解（デコード順 o はランダム）

$$P(s_{o_1}, \ldots, s_{o_T} \mid X) = \prod_{t=1}^{T} P\left(s_{o_t} \mid s_{o_1}, \ldots, s_{o_{t-1}}, X\right)$$

学習のたびに o を全順列からサンプル（Table 1 の実験 4）

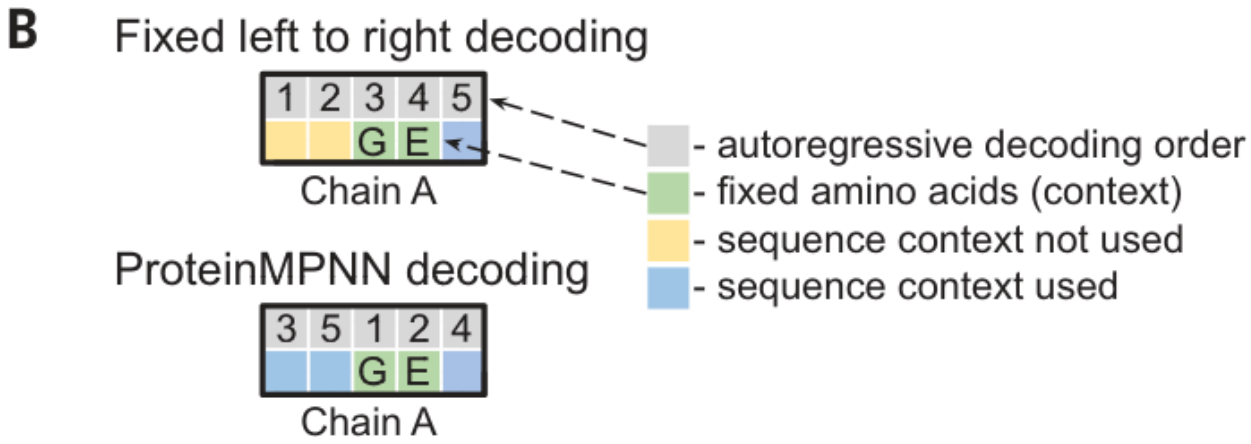


Fig. 1B より

左から右の固定順では、決め打ちの残基（緑）を文脈に使えない

ランダム順なら、結合相手の配列を先にデコードしておき、文脈として使える（結合設計に必須）

方法

位置の結合で対称性と多状態の設計ができる

結合した位置のグループ G ごとに平均

$$\bar{z}(a) = \frac{1}{n}\sum_{i \in G} z_i(a)$$

$$p(a) = \frac{\exp \bar{z}(a)}{\sum_b \exp \bar{z}(b)}$$

多状態設計: ¥bar{z} = ¥sum_k w_k z^(k)（w_k は正負あり）

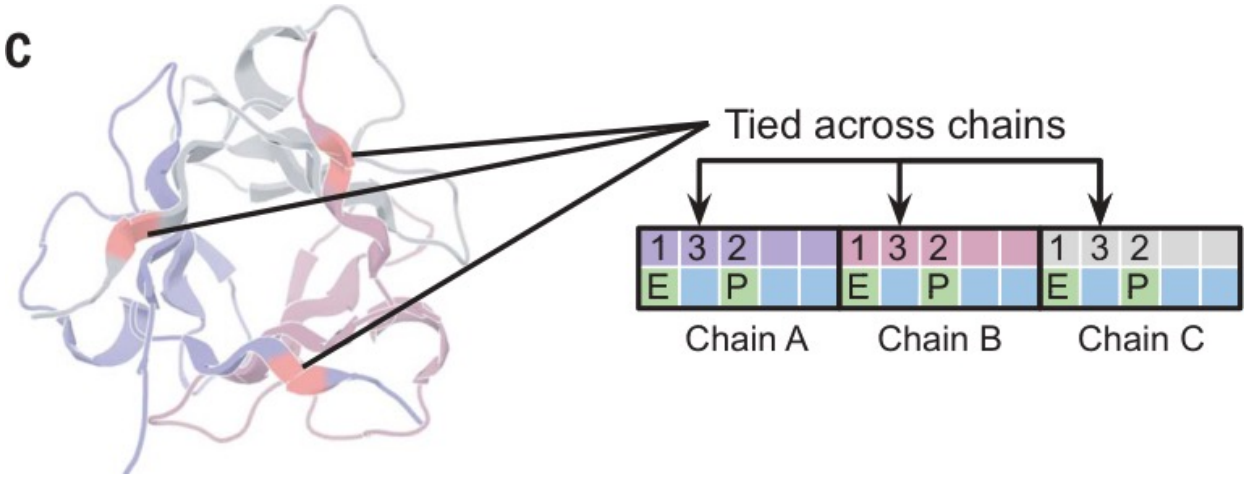


Fig. 1C より

ホモ三量体では 3 本の鎖の対応位置を結合。予測確率の平均から 1 残基をサンプル

リピートはユニット内の対応位置、対称体は鎖間の対応位置を結ぶ（Fig. 3 の実験で使う）

方法

学習データは PDB の25,361クラスタ

損失（Methods より）

$$\mathcal{L} = \frac{1}{2000} \sum_{t} \ell_t \, m_t$$

¥ell_t: 残基ごとの交差エントロピー、m_t: マスク

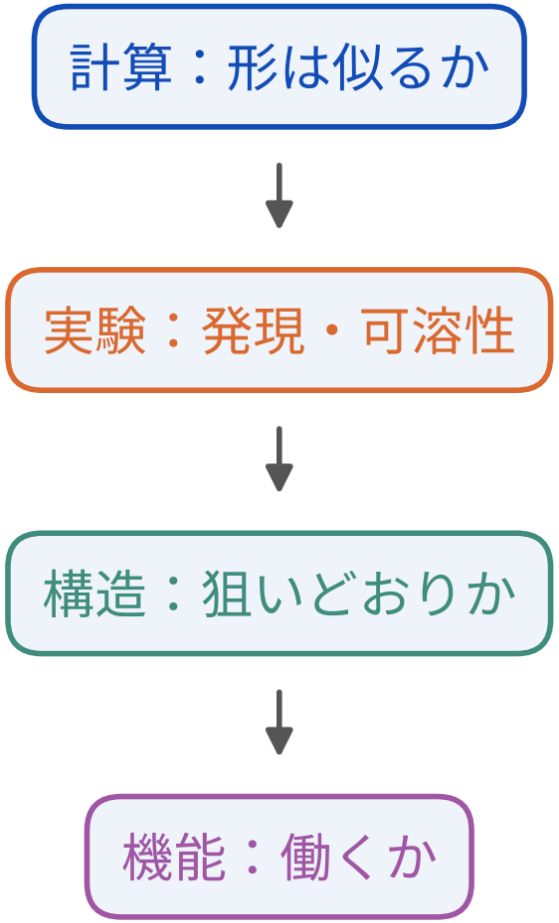
データと最適化

多量体: PDB 会合体（分解能 3.5 Å 以上、10,000 残基未満）。mmseqs2 で 30% 一致のクラスタ分割

訓練 23,358 / 検証 1,464 / テスト 1,539 クラスタ。同一配列は片方の集合にしか入らない

ラベルスムージング 10%、Adam（$\beta_2 = 0.98$）。A100 1 枚で混合精度

検証パープレキシティは約 15 万ステップ（約 100 エポック）で収束（Fig. S3D）



方法

主鎖に小さなノイズを加えて学習すると強くなる

学習時のノイズ

$$\widetilde{X} = X + \varepsilon,\ \varepsilon \sim \mathcal{N}(0, \sigma^2 I)$$

$$\sigma = 0.02\ \text{¥AA}$$

なぜ効くか

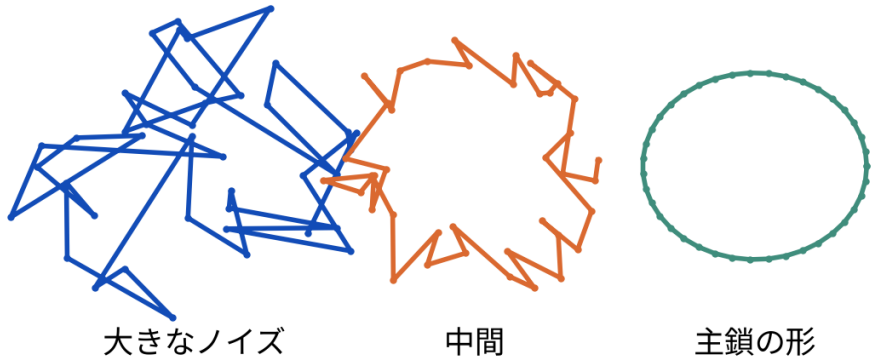
結晶構造は精製によって配列の記憶を座標にわずかに残す。ノイズがそれを消す

きれいな PDB 主鎖では回収率が下がる（41.2→40.1 など）が、現実の主鎖では上がる

ノイズの大きさごとの 16 種モデルが公開されている。入力主鎖の質に合わせて選ぶ

ノイズを大きくすると AlphaFold での折りたたみ成功率が上がる（Fig. 2C で後述）

座標を段階的に整える模式図



結果

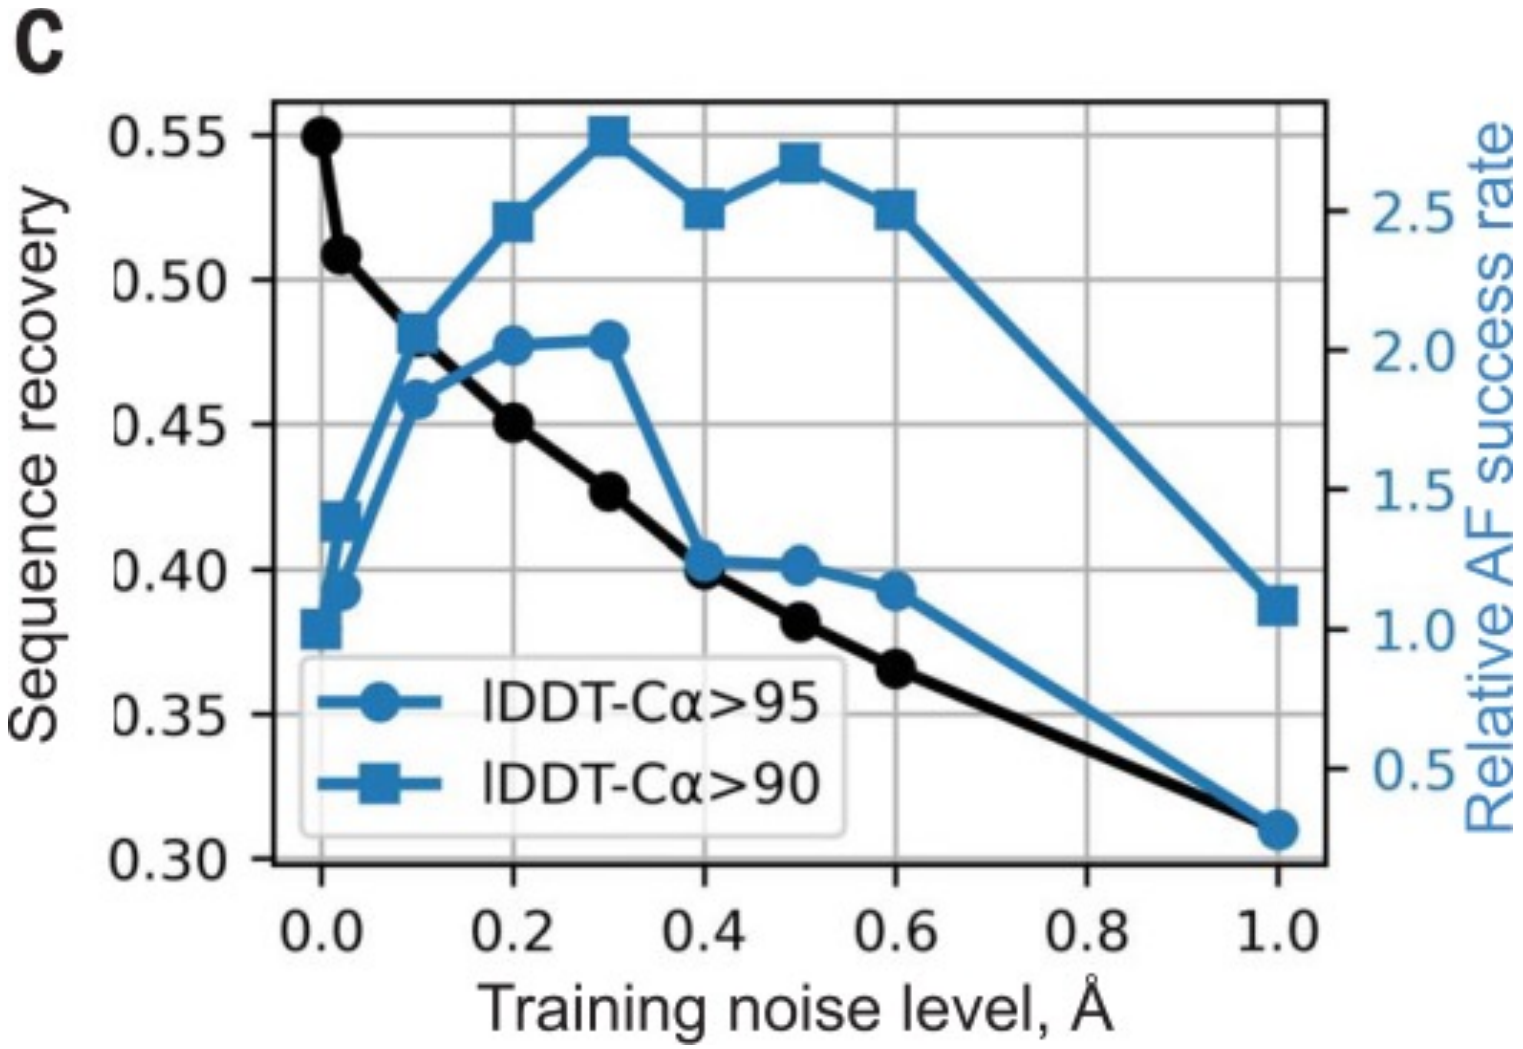
ノイズ付き学習はAlphaFoldの成功率を上げる

黒: 回収率（ノイズで下がる）

青: AF 成功率（ノイズで上がる）

0.3 Å ノイズで 2–3 倍の配列が高精度予測に

出典: Fig. 2C



結果

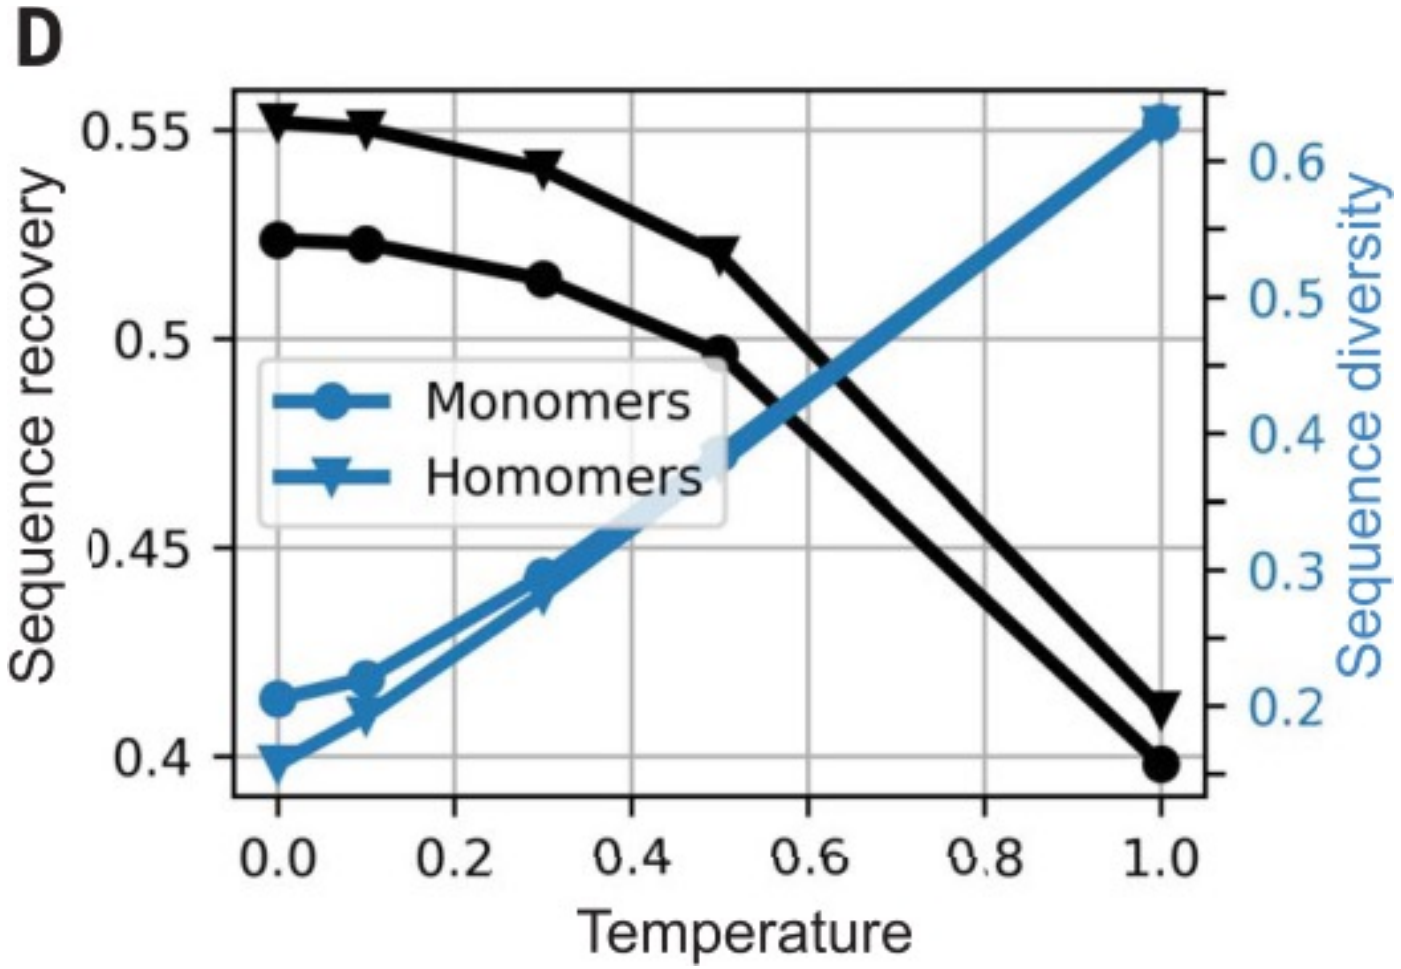
温度を上げると多様性が増え回収率は下がる

温度つきソフトマックス（補足より）

$$p(a \mid X) = \frac{\exp(z(a)/T)}{\sum_b \exp(z_b/T)}$$

学習時は $T=1$。推論時に動かす

出典: Fig. 2D



結果

回収率はconfidenceと構造の質で決まる

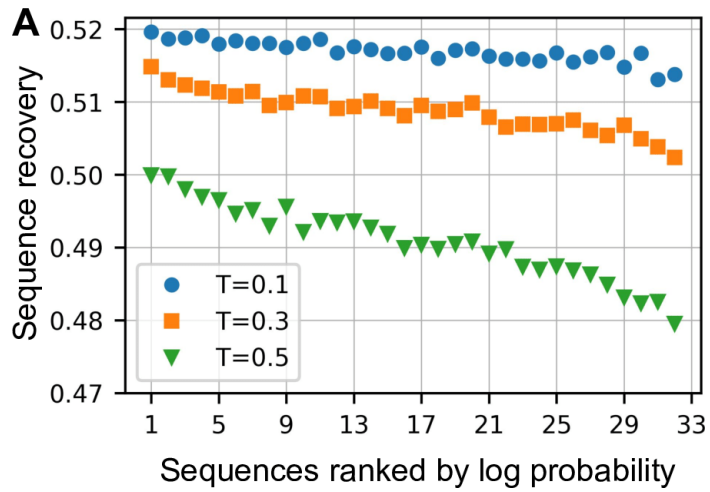
A: 対数確率でランキングできる

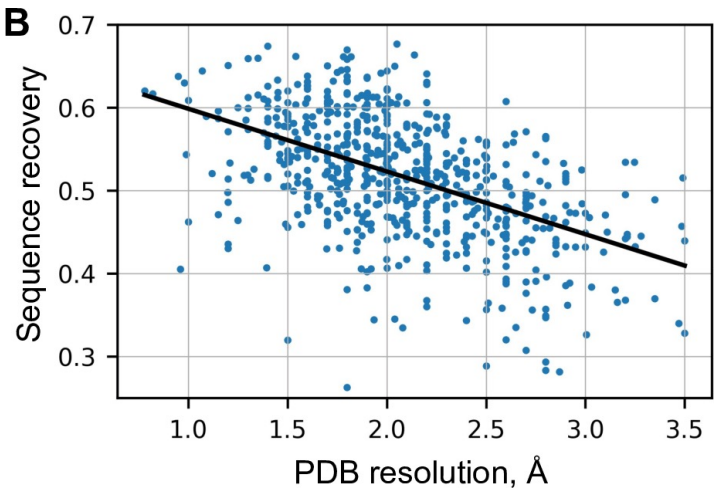
B: 分解能が荒いと回収率が下がる

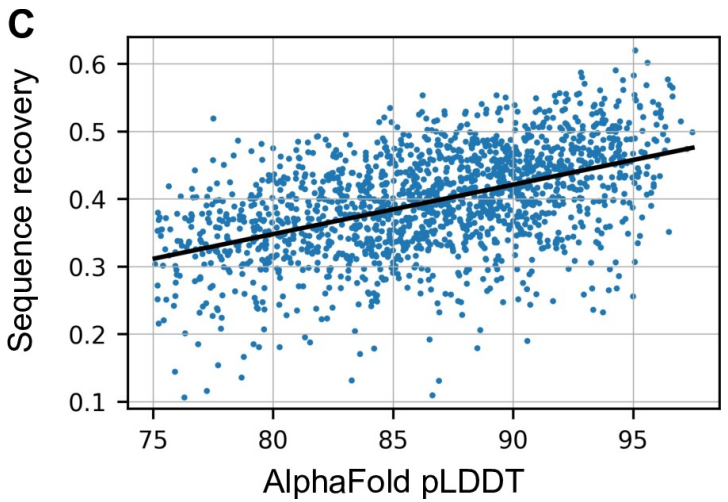
C: pLDDT とも相関

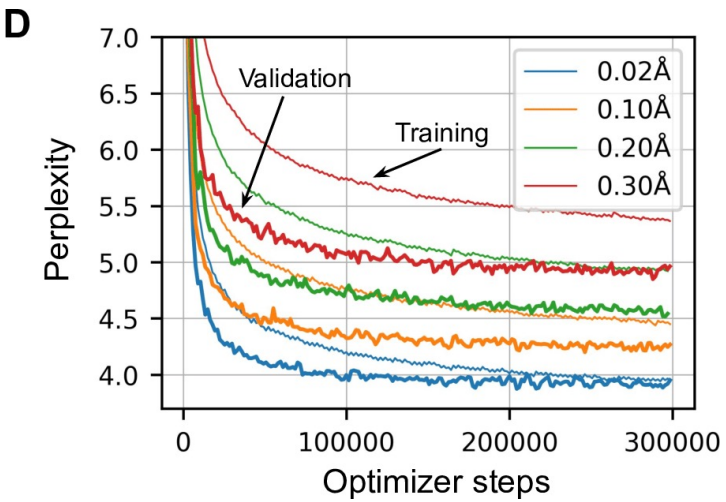
D: ノイズ大は検証 PPL を上げる

出典: Fig. S3 A–D









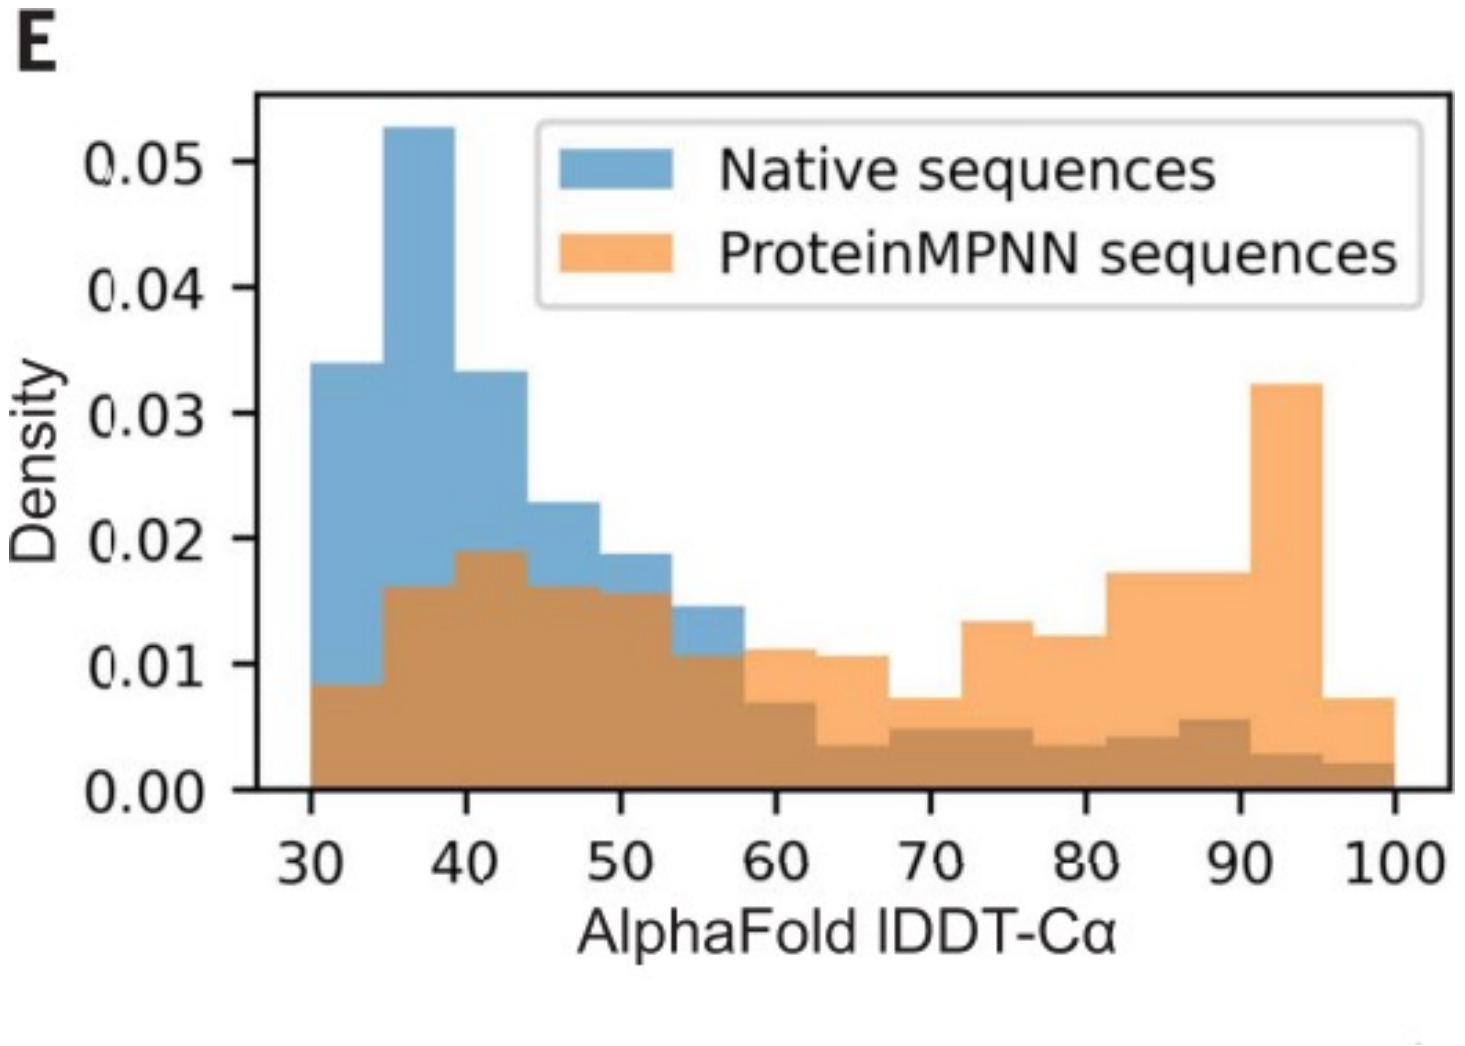
結果

設計配列は天然配列よりAlphaFoldで折れる

天然骨格の再設計配列のほうが AF
の単一配列予測が当たる
進化は安定性を最適化しないため

組換え発現・安定化への応用を示唆

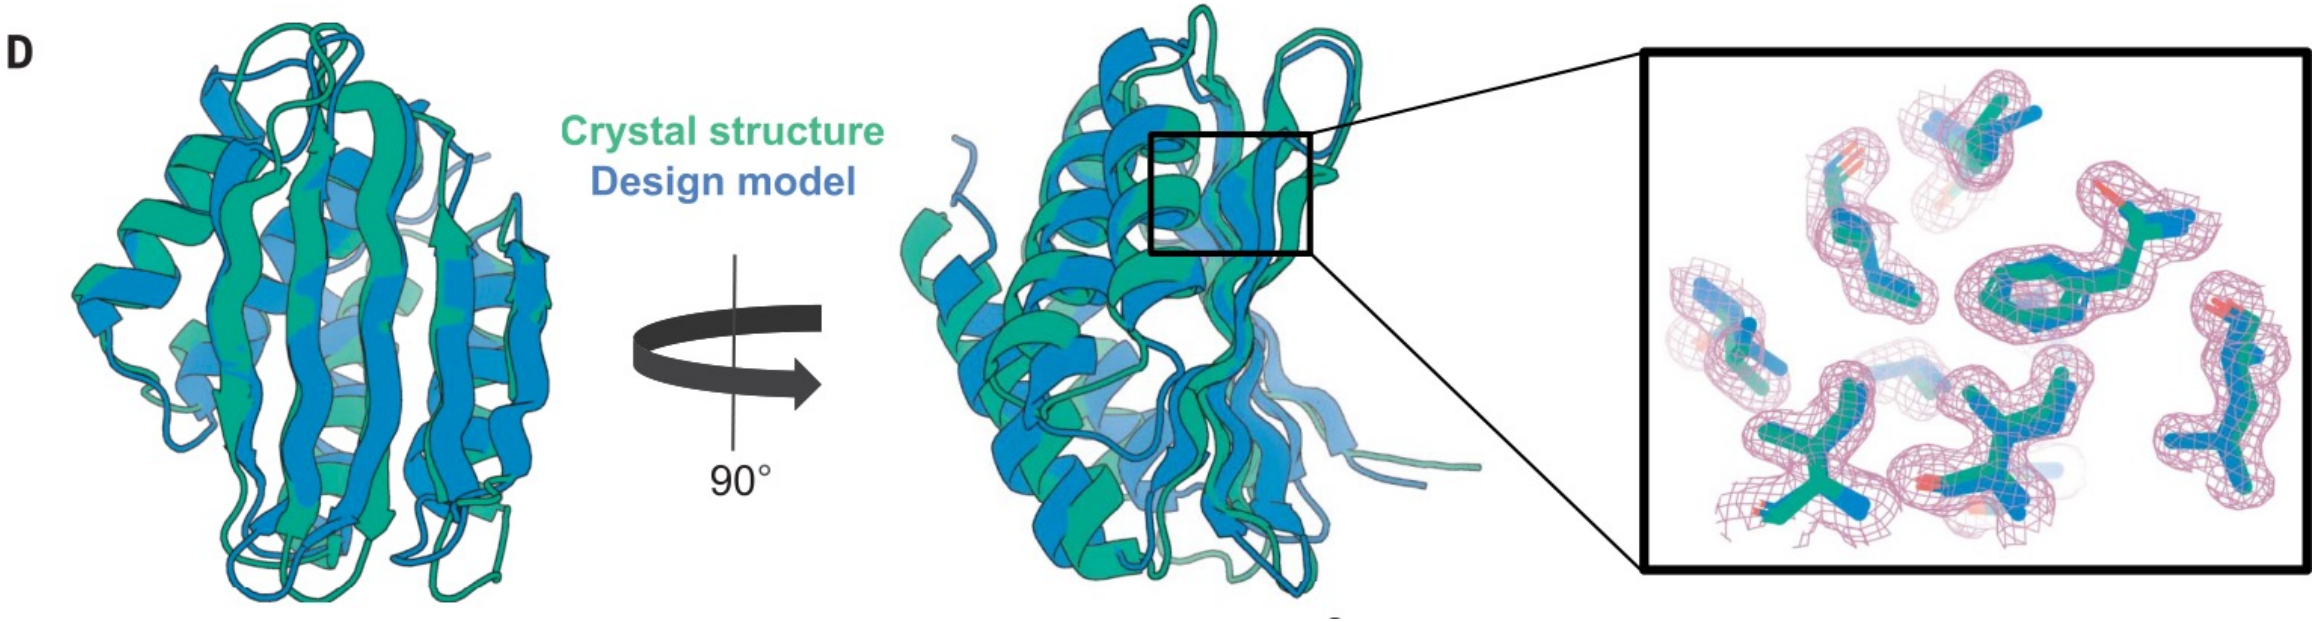
出典: Fig. 2E



実験

結晶構造は設計モデルと2.35Å一致

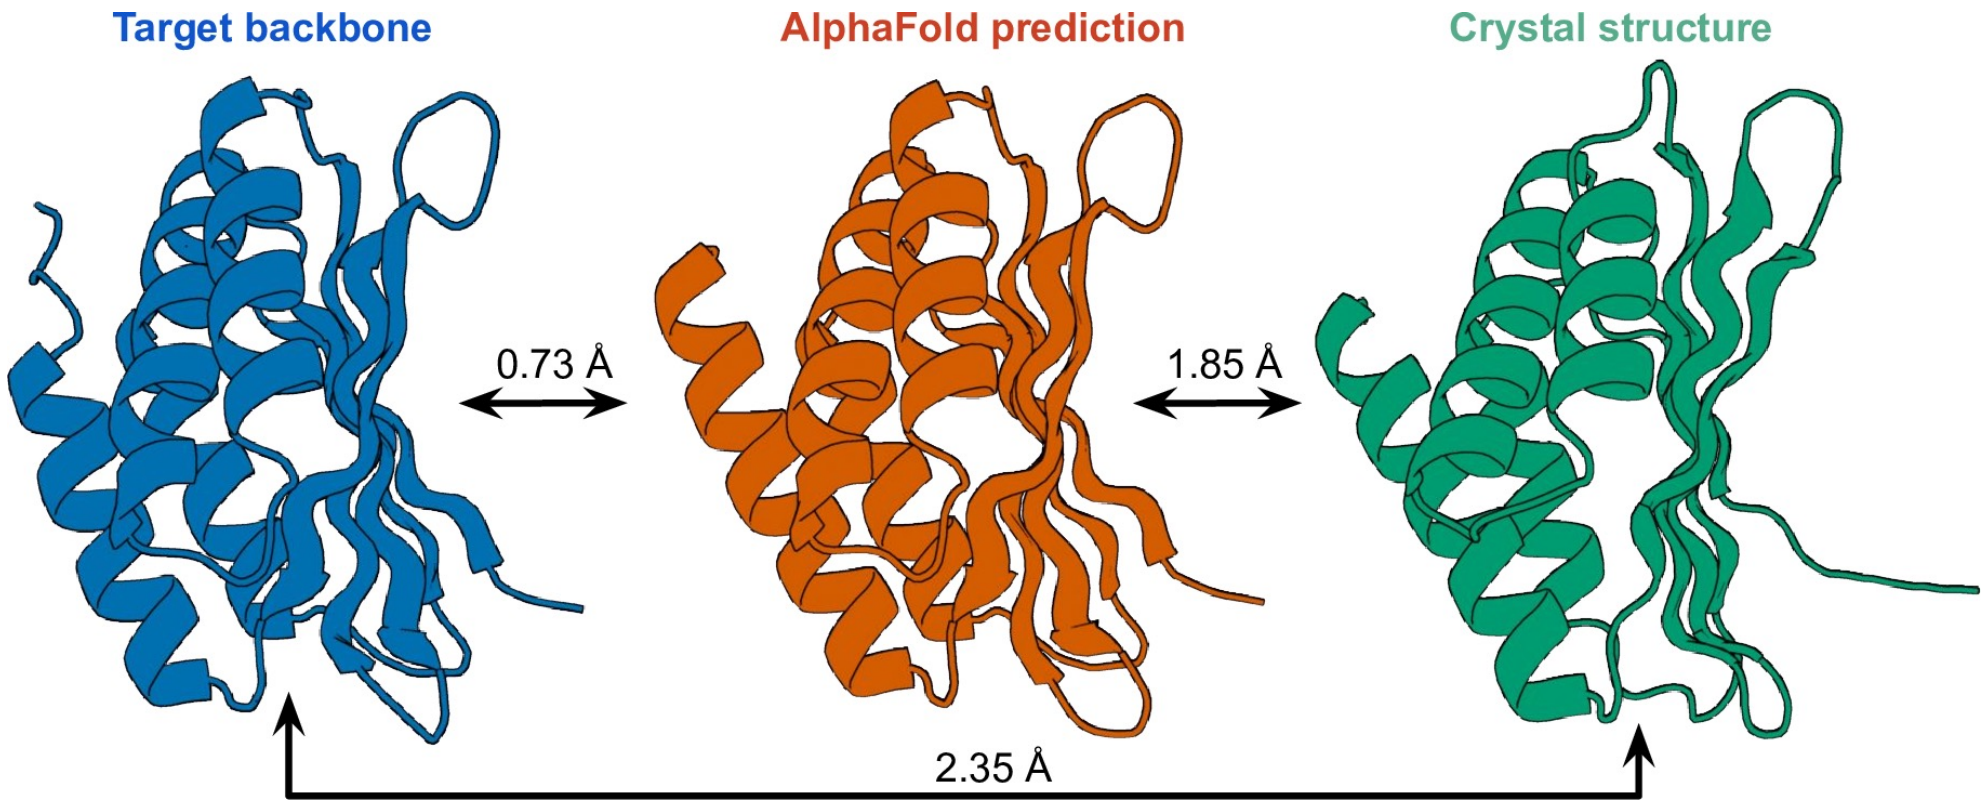
幻覚法設計 HALC1_878（PDB ID: 8CYK）。Cα 2.35 Å RMSD（130 残基）。TM スコア 0.56。コア側鎖は電子密度に一致（Fig. 3D、fig. S5）



実験

設計・予測・結晶の3者はほぼ同じ形

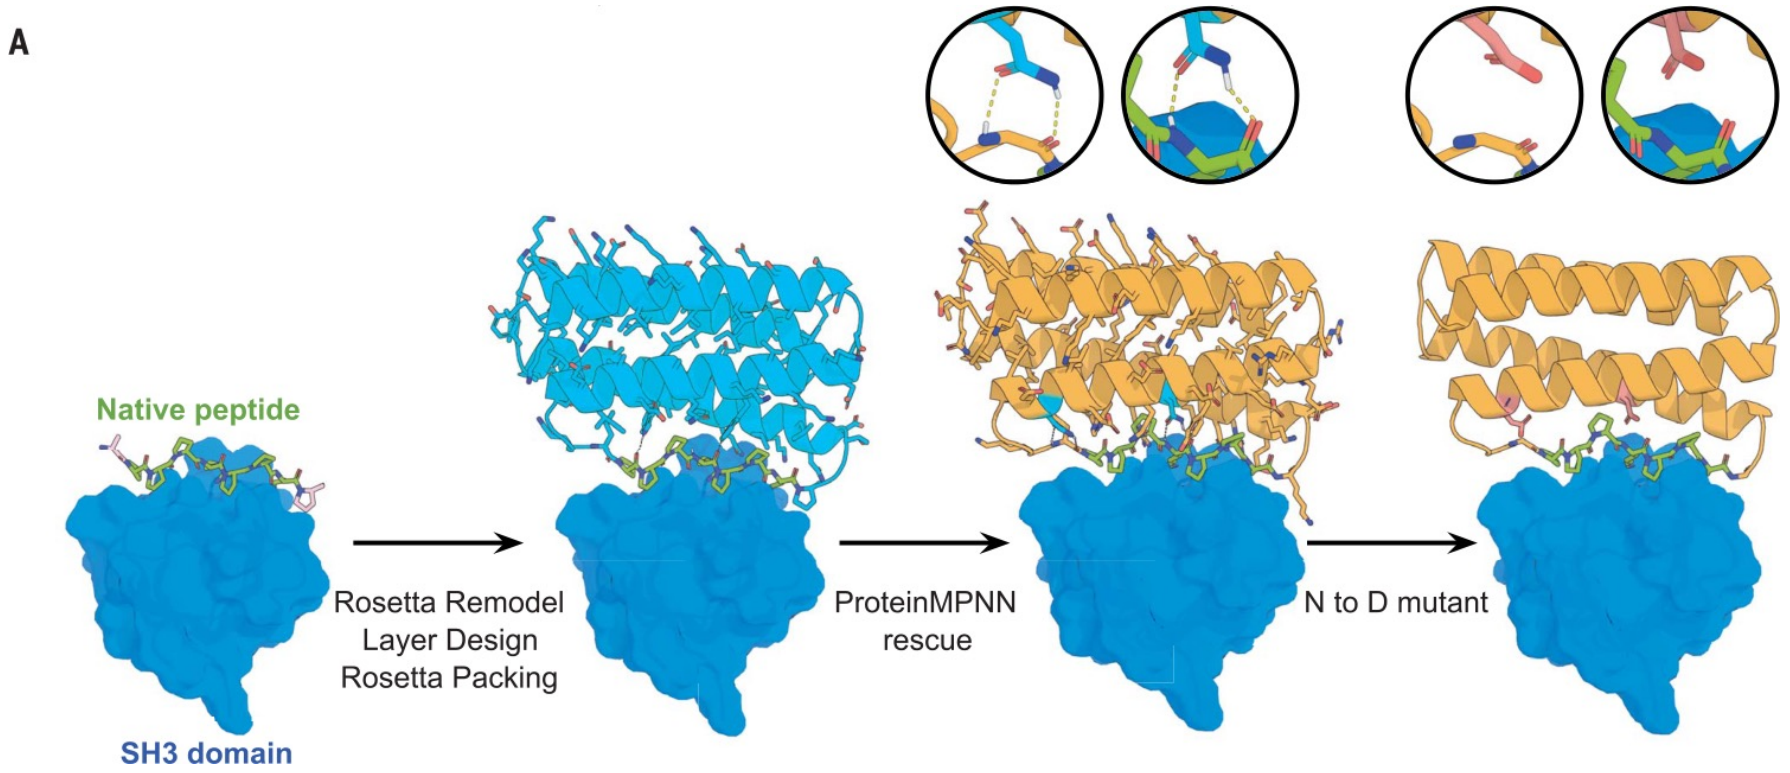
RMSD: 設計モデル対 AF 予測 0.73 Å、設計対結晶 1.35 Å、予測対結晶 1.65 Å（Fig. S5）



実験

SH3結合タンパクはmotif固定で設計

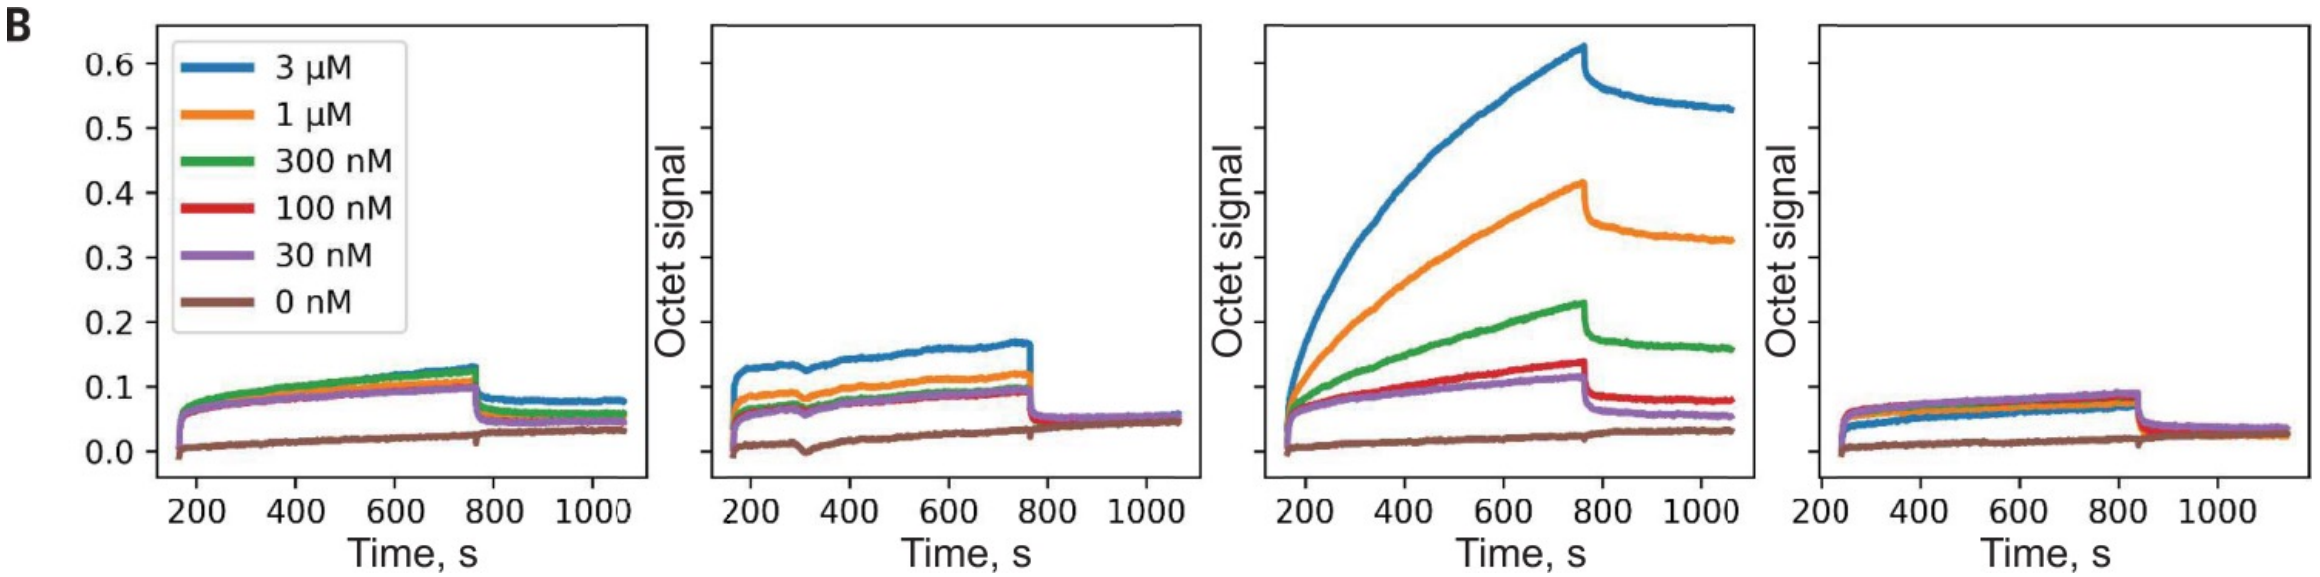
Gab2 ペプチド（モチーフ PPPRPPK は緑）を RIFDOCK＋Rosetta remodel で足場に載せ、MPNN で足場側のみ再設計。N は足場の水素結合を担い、N→D 変異で破綻するよう設計（Fig. 4A）



実験

結合は実測され、変異で消える

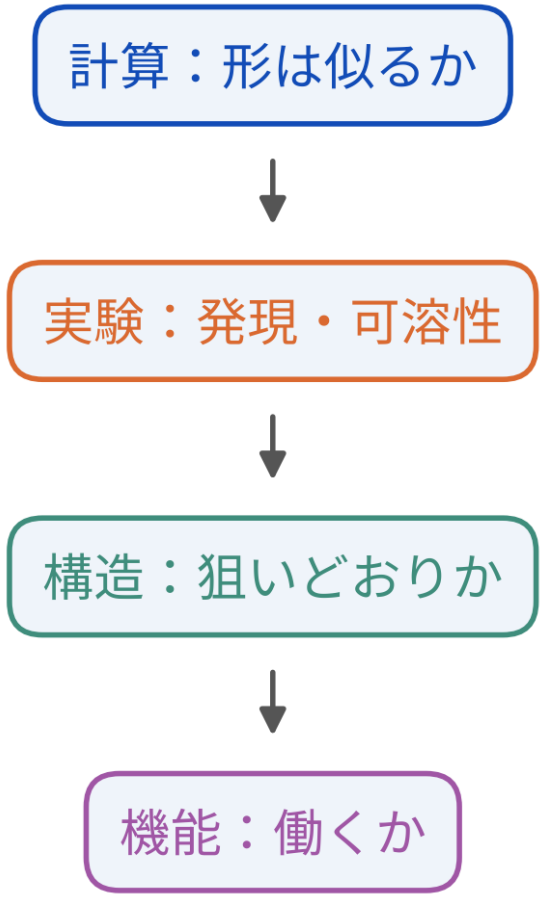
生物層干渉法（BLI）。ペプチド / 元の Rosetta 設計 / MPNN 設計 / N→D 変異体の順。MPNN 設計が最も強く結合し、変異でシグナル消失（Fig. 4B）



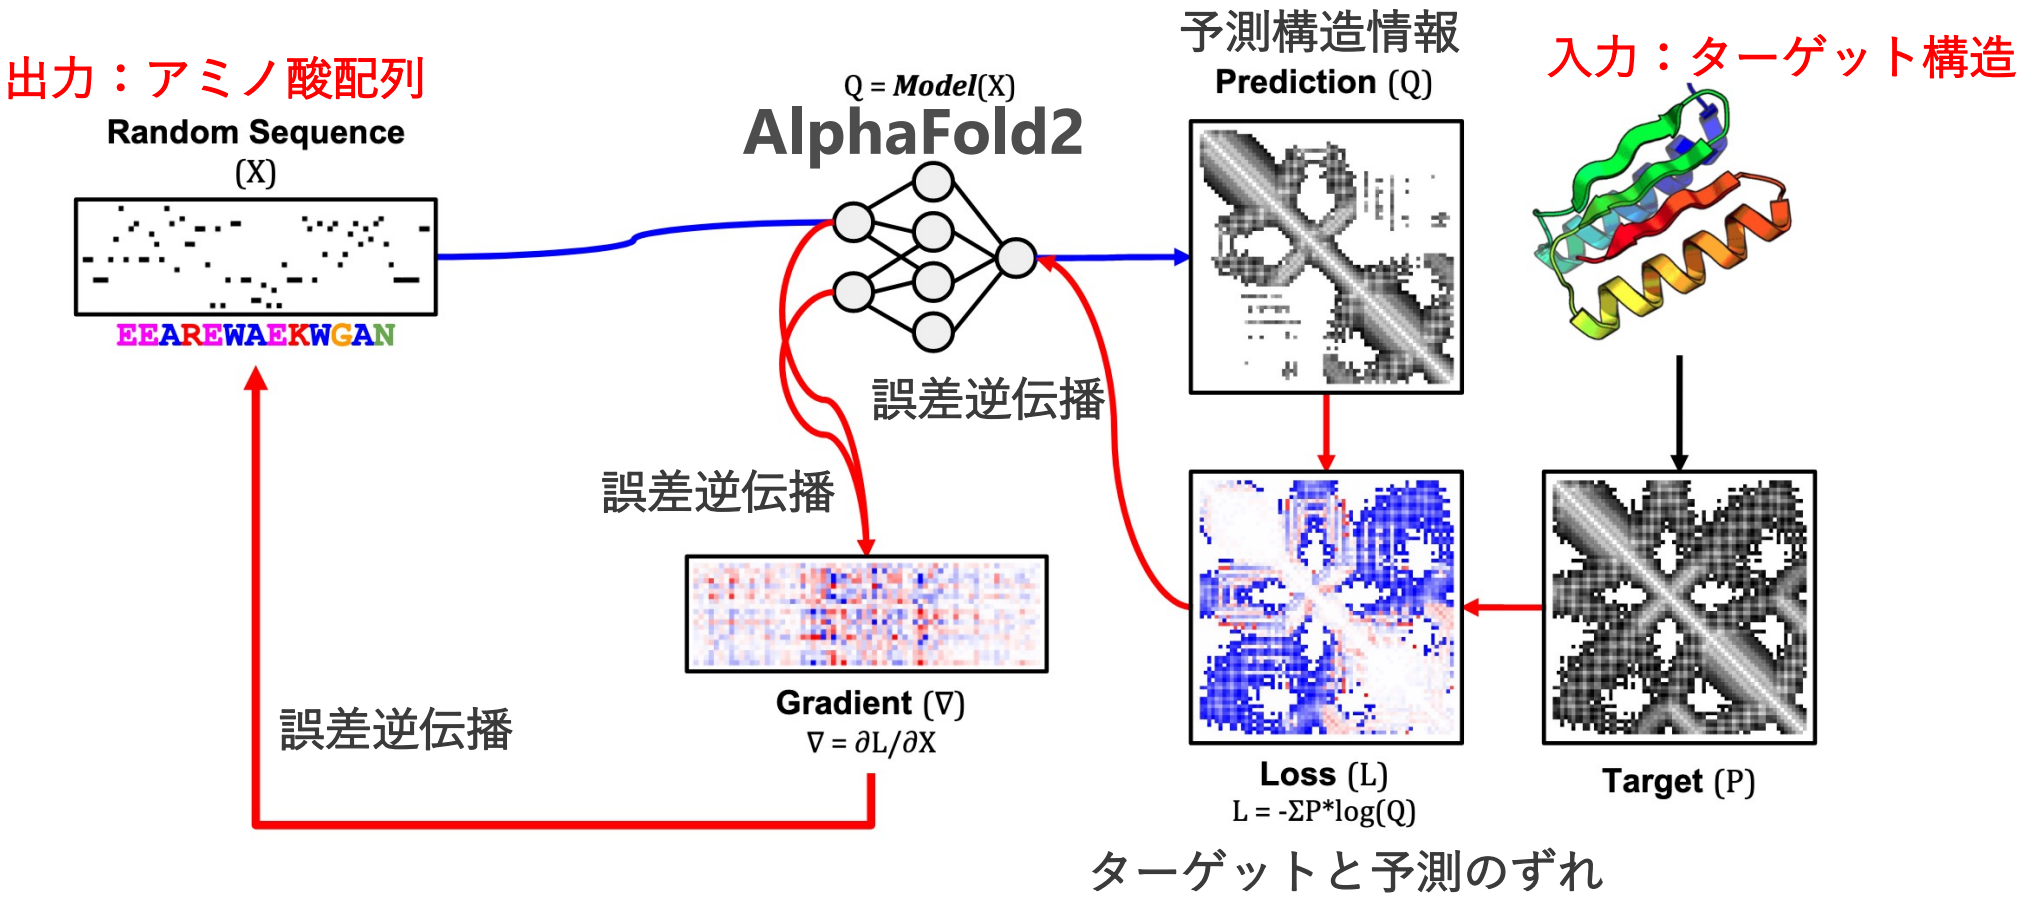
講義

天然配列の回収率と、設計成功は違う

回収率は、既知構造から天然と同じ残基を何割選べたか。
配列の条件付き確率が高いことは、熱力学的な安定性そのものではない。
別の配列でも同じ構造へ折り畳まれるなら、設計として成功しうる。
構造の一致、発現、機能という別の観測を組み合わせる。



ColabDesign　AlphaFold 2による予測構造のずれを逆伝播させて配列を探索



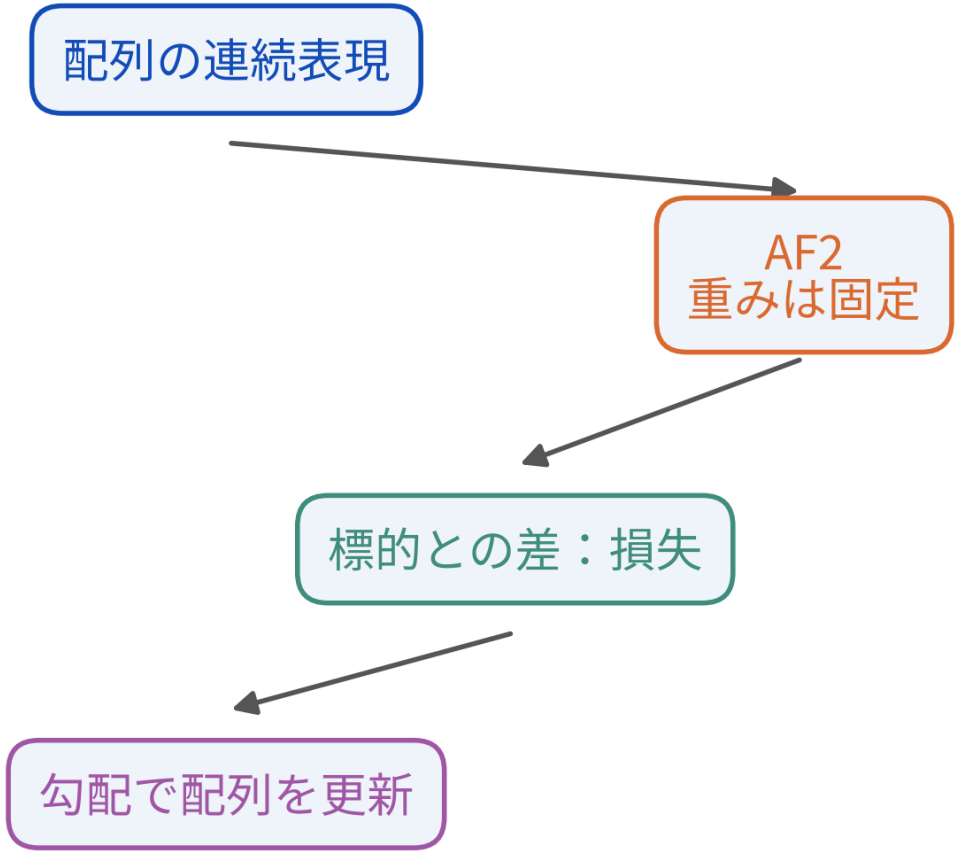
C. Frank et al., Scalable protein design using optimization in a relaxed sequence space, Science **386**, 439 (2024).

S. Ovchinnikov, https://github.com/sokrypton/ColabDesign

講義

AfDesignは、AF2を微分して配列へ戻る

AF2の重みを固定し、入力する配列側を変える。
目標の構造と予測との差を損失にし、配列の連続表現に対する勾配を計算する。
ProteinMPNNのように配列の条件付き分布を学習し直す手順ではない。
固定骨格設計では、目標骨格を損失の参照に使う。

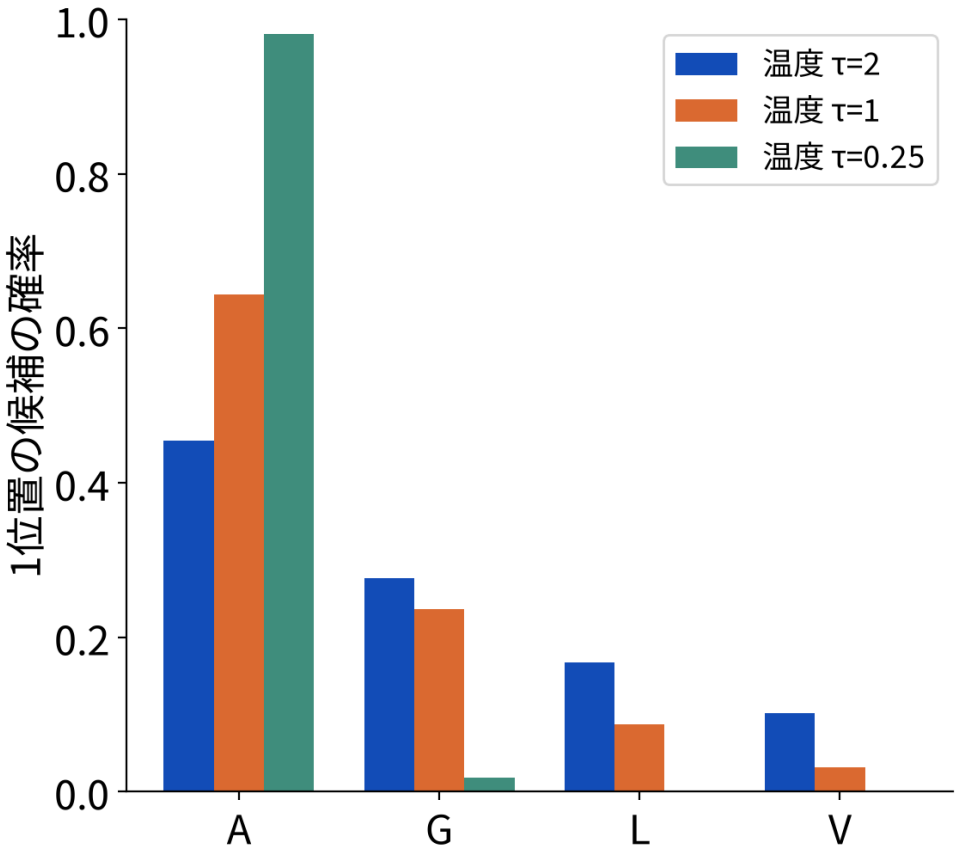


$$z \leftarrow z - \eta \nabla_z \mathcal{L}(f_{\mathrm{AF2}}(p(z)), X^*)$$

講義

離散的なアミノ酸を、連続表現から選ぶ

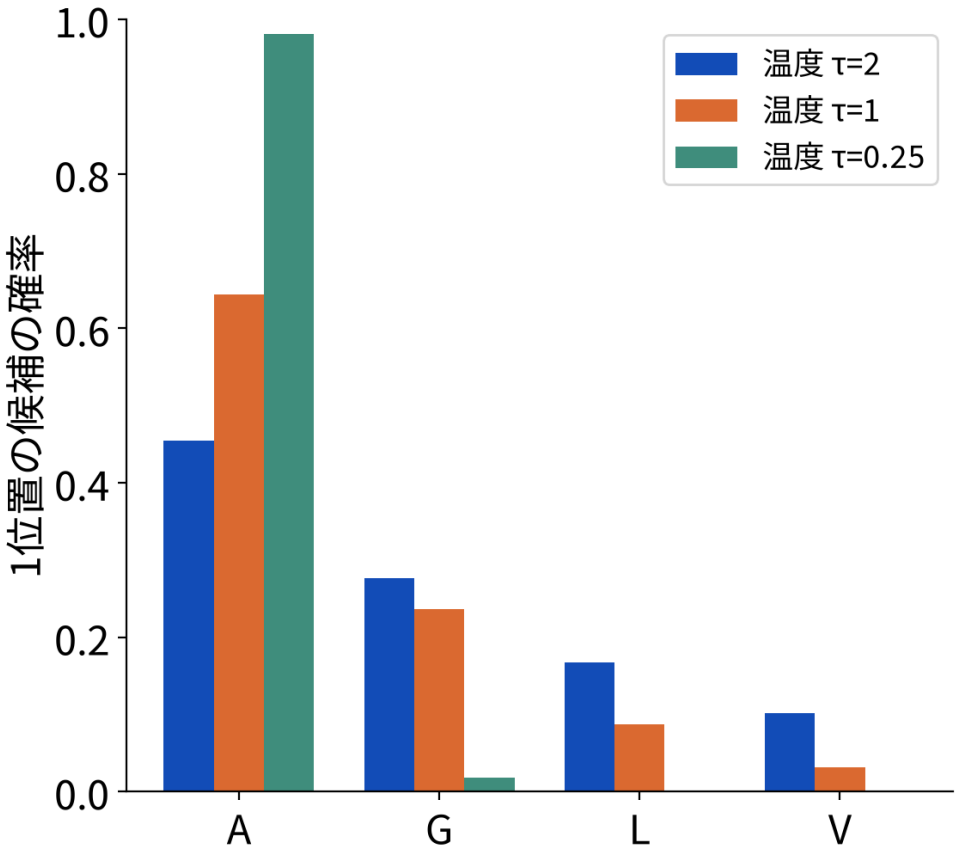
各位置に20種類の得点（ロジット）を置く。
softmaxで重みへ変換すれば、配列入力を連続的に変えられる。
温度を下げると一つの候補へ集中し、最後に離散的な配列へ移す。
右は4種類に減らした説明用の計算。実際は20種類。



$$p_i(a) = \frac{\exp(z_i(a)/\tau)}{\sum_b \exp(z_i(b)/\tau)}$$

三段階で、配列を離散的な候補へ近づける

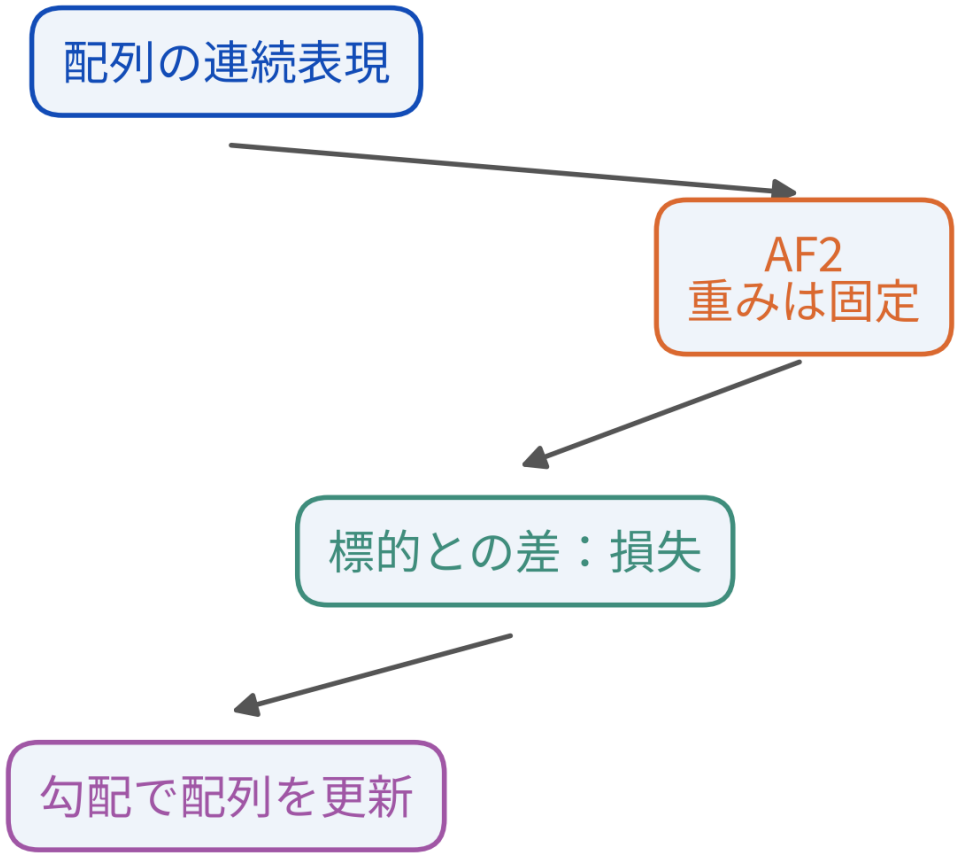
soft：連続的な入力を動かして形を探す。
temp：softmaxの温度を下げ、候補を絞る。
hard：離散的な配列を使う段階へ進む。
短い演習設定は動作を見るためのもの。十分な最適化や実験成功を保証しない。



講義

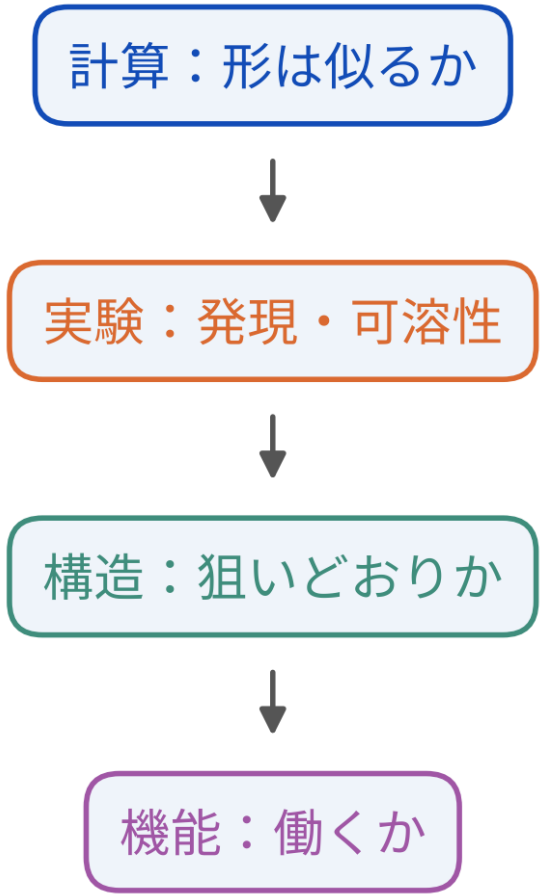
構造への適合と、予測の信頼度を分ける

固定骨格設計では、目標構造との距離分布の差などを減らす。
pLDDTなどの信頼度を損失へ加える場合もある。
RMSDは目標との座標の差、pLDDTは予測器自身の信頼度。値の意味も単位も違う。
重みや反復数は記録し、条件の違う実行を混ぜて比較しない。



設計に使った予測器だけでは独立な検証にならない

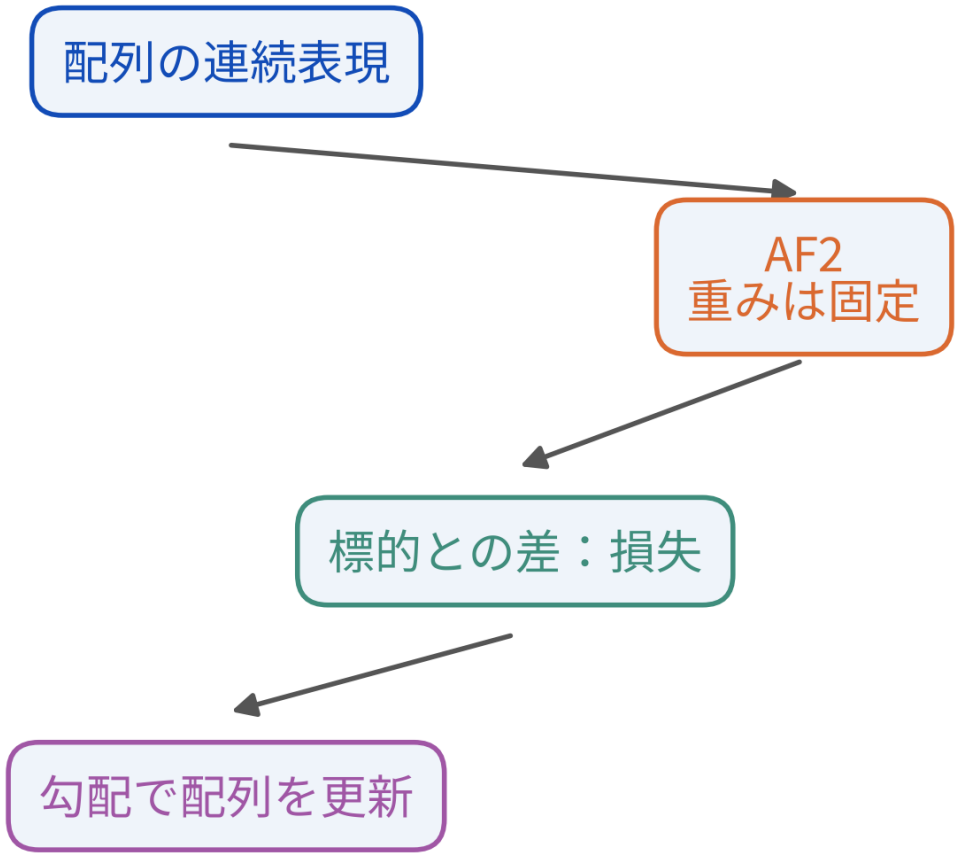
AfDesignでAF2へ適合させた配列を、同じAF2で評価すると循環する。
高い信頼度でも、予測器の弱点を利用した配列が残る場合がある。
別のモデル・異なる条件での再予測は補助になるが、実験とは異なる。
発現・構造・機能を測る検証へつなげる。



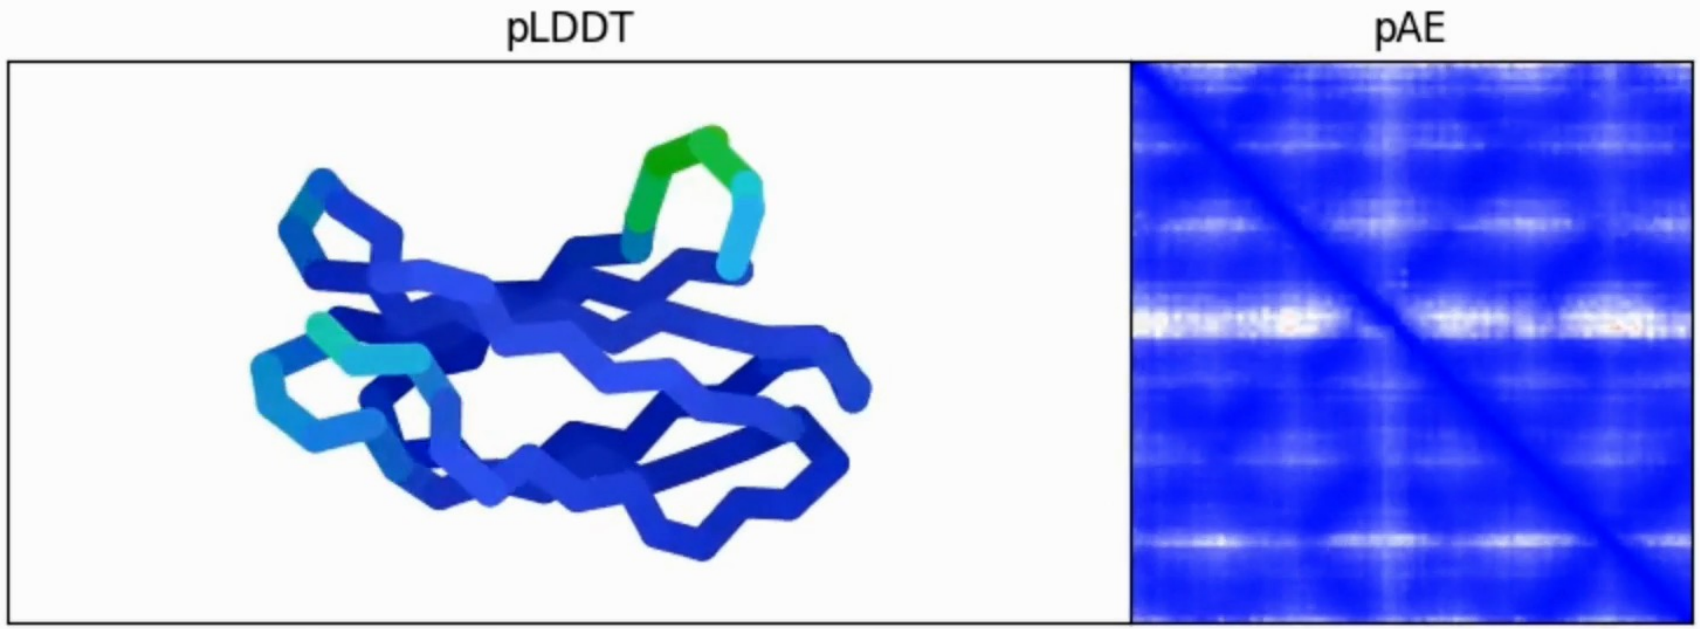
講義

固定骨格設計の対象：1TENの鎖A

1TENはテネイシンのフィブロネクチンIII型ドメイン。
公式AfDesignの固定骨格設計例を再利用する。
入力：PDB 1TENの鎖A。
出力：設計配列、予測PDB、損失の推移。
標的の原子が登録されている残基を対象とし、番号と長さを確認する。

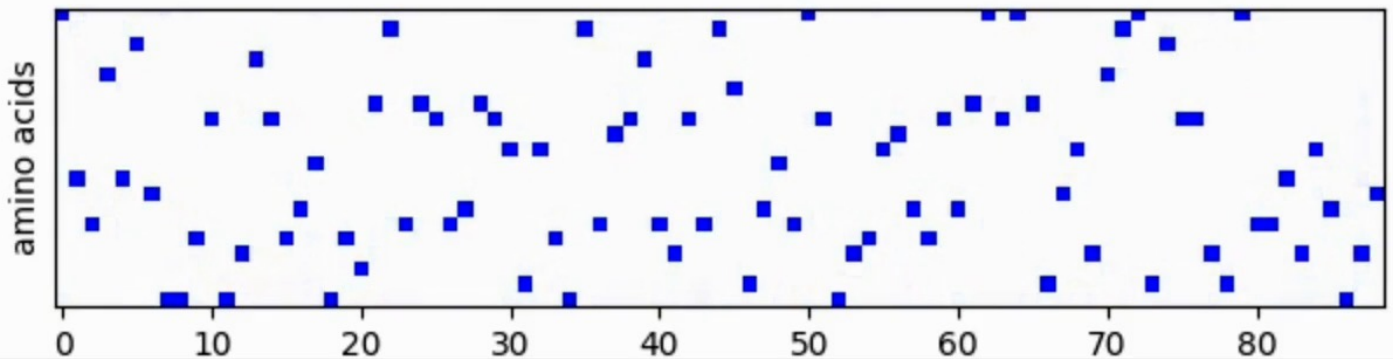


ColabDesignの動作例



各ステップの予測構造

残基ごとの
相対的な配置精度

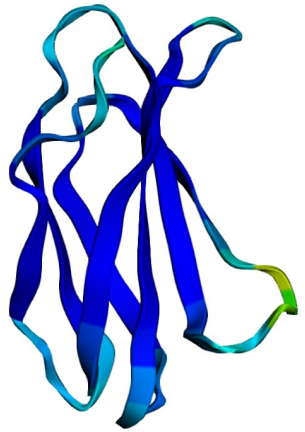


アミノ酸配列の予測の推移

ターゲット構造 (PDB ID: 1TEN)



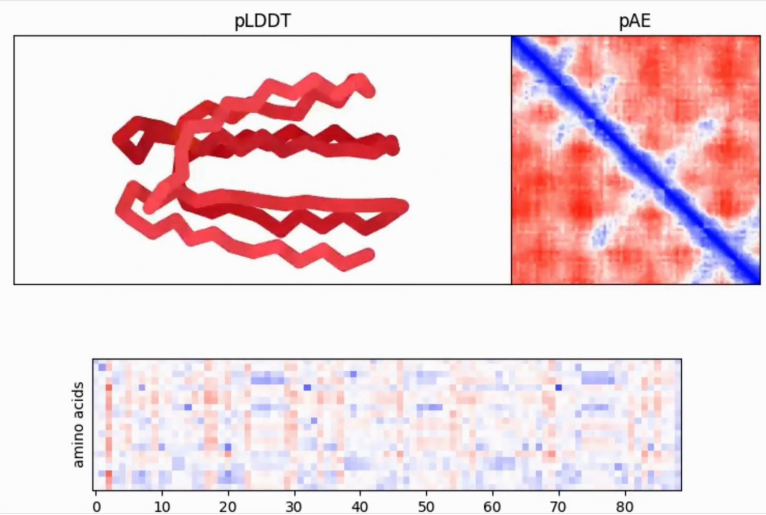
リデザイン構造



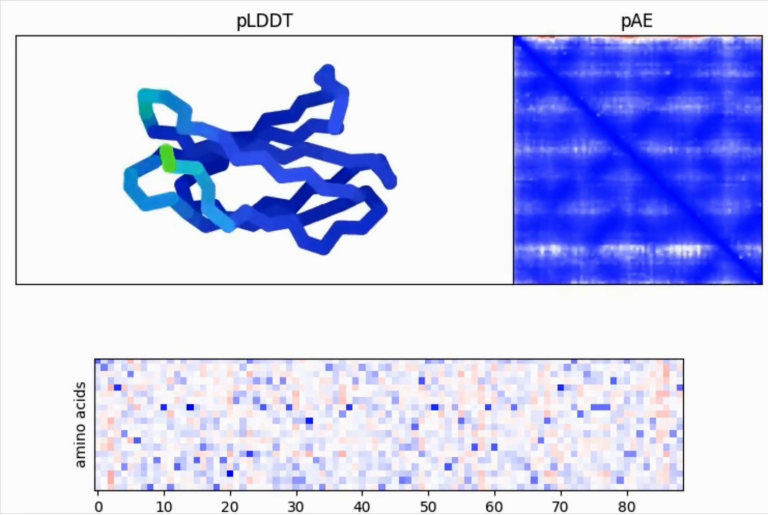
配列設計の推移

予測構造を繰り返し比べて、配列を更新する

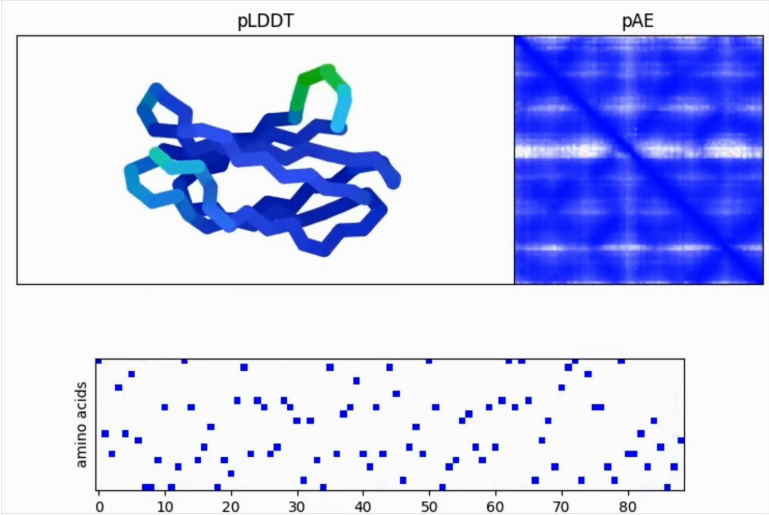
初期



中間



終盤



原資料の最適化動画から3時点を抜粋。物理時間に沿った折り畳みの動画ではない。

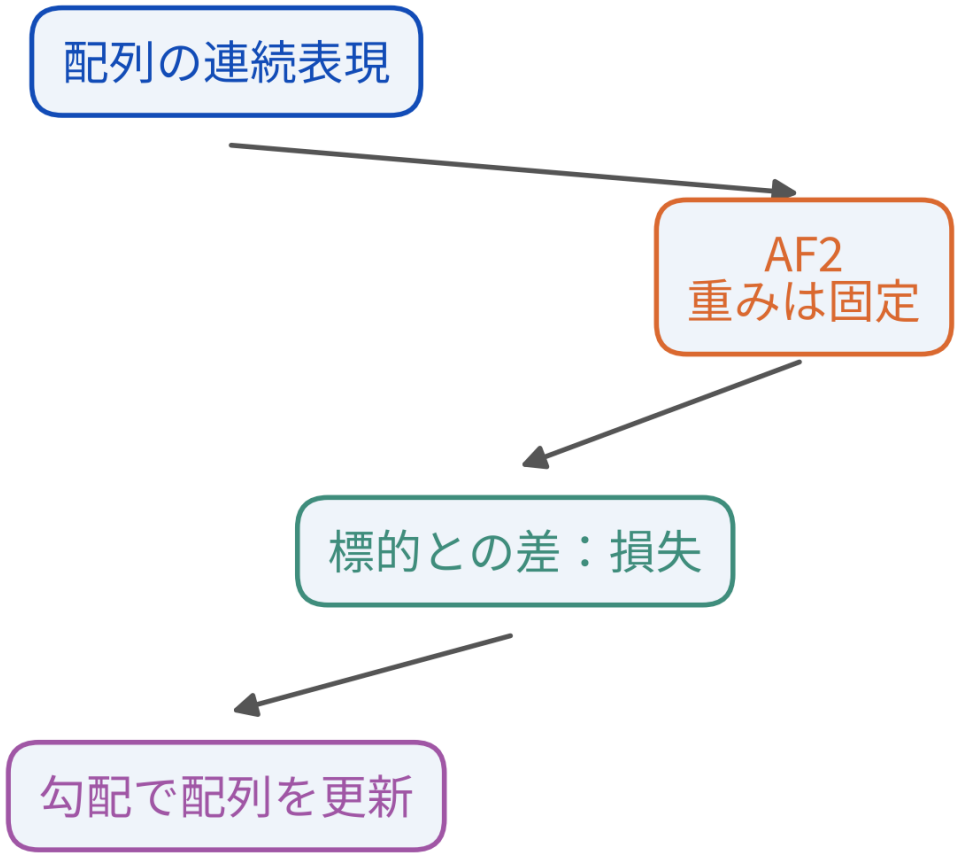
ColabDesignの動作例

> 天然配列 (PDB ID: 1TEN)
RLDAPSQIEVKDVTDTTALITWFKPLAEIDGIELTYGIKDVPGDRTTIDLTEDENQ
YSIGNLKPDTEYEVSLISRRGDMSSNPAKETFTT

> リデザイン配列
AKPCKNMVVSGVTDGSFLVSWERPEGPFEGIYISVRPHGDPTGPRQYFLPAGVTSI
HFSGFEAGAEYMITCRAYNGGTYAPPKTIFVTM

演習：固定骨格設計をColabで動かす

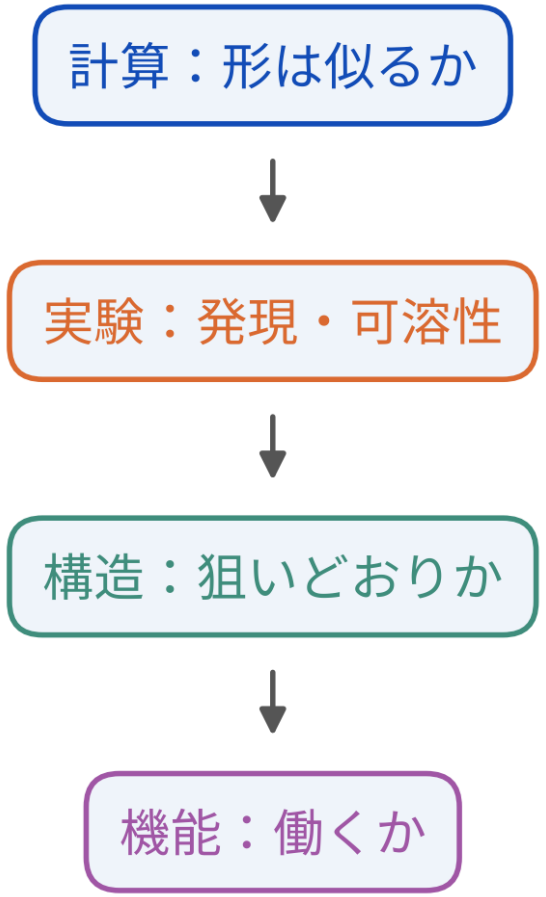
T4 GPUを選び、準備 → 入力確認 → 設計 → 観察の順に実行する。
演習20分を目安。初回の重み取得とGPU待ち時間は別に変動する。
損失の変化、得られた配列、標的と予測構造の重ね合わせを確認する。
採点・提出なし。長い実行は途中経過を保存する。



演習

結果は、配列・構造・条件を一緒に残す

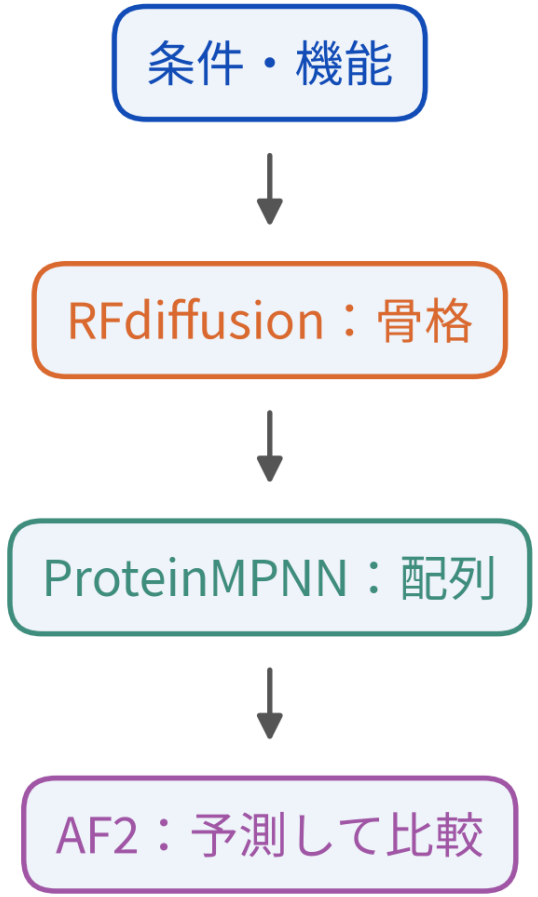
設計配列だけでなく、標的のPDBと鎖、乱数seed、反復数、損失の重みを残す。
RMSDは同じ残基・同じ原子の対応で、重ね合わせ後に計算する。
pLDDTが高いのに形が異なる場合もあるため、立体表示を併用する。
この演習の結果を、実験で機能を確認した設計とは扱わない。



まとめ

骨格を作る・配列を選ぶ・確かめる

RFdiffusionは条件から骨格候補を作る。
ProteinMPNNは骨格を条件に配列を選ぶ。
AF2で再予測し、骨格との一致と信頼度を見る。
AfDesignは予測器を通して配列を最適化する別の方法。
冒頭の目標は「候補を作って比較する」こと。実際の構造と機能は実験で確かめる。



付録：配列設計の式と実験評価

ここからは独習用の補足です。
本編で使った式の導出や、手法の条件を確認します。
必要な項目から参照してください。

背景

Rosetta との違い: 最適化から学習へ

Rosetta: エネルギー最適化

側鎖回転体の詰め込みでエネルギー最小の配列を探す

低エネルギー状態が目的構造になる保証は直接は最適化できない

表面の疎水制限など人手の調整が必要で、設計が失敗することもあった

深層学習: PDB の例から条件付き確率を学ぶ

「主鎖の局所的な形」から「どの残基が自然か」を学習する

100 残基で Rosetta の約 200 分の 1 の時間（1.2 秒対 258.8 秒）

透明性は Rosetta に劣るが、調整が不要で頑健。本論文は実験まで検証した

補足

主な記号の一覧

記号	意味
X	主鎖構造（N, Cα, C, O の座標。仮想 Cβ を含む）
s_i	残基 i のアミノ酸の種類
o	デコード順（残基の並べ方の順列）
$z_i(a)$	残基 i のアミノ酸 a のロジット
T	サンプリング温度（学習時は 1）
σ	主鎖座標に加えるガウスノイズの標準偏差
PPL	パープレキシティ（交差エントロピーの指数）
lDDT-Cα / pLDDT	構造予測の正しさの指標 / その AlphaFold による予測値

方法

近傍数・埋まり・平均方法の検証

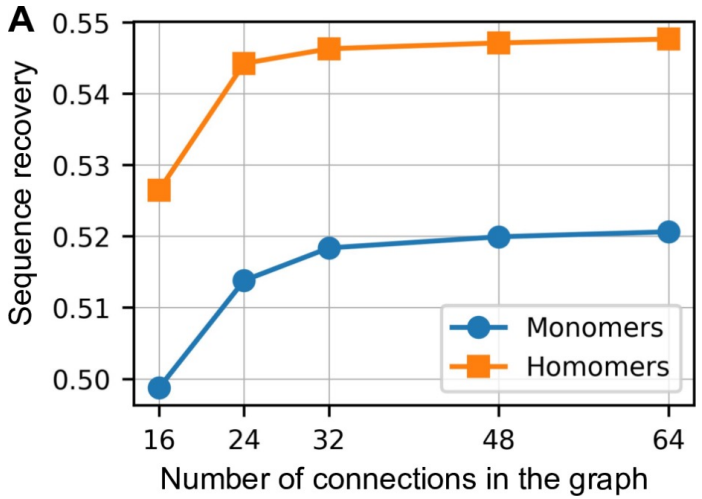
A: 近傍数は 32–48 で飽和

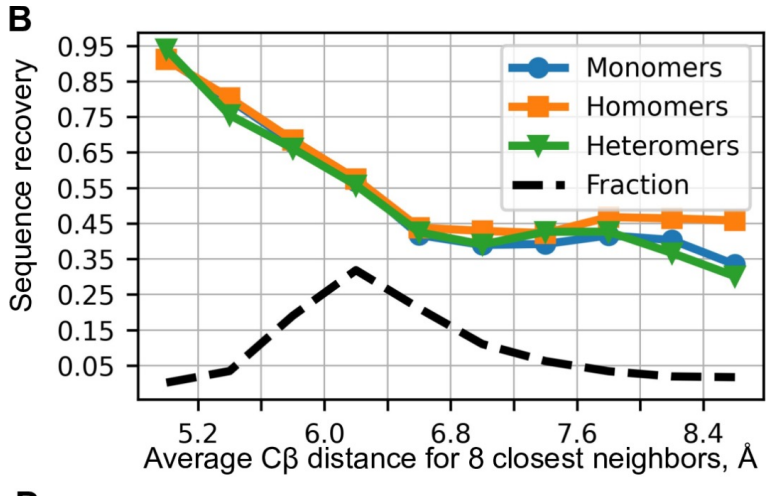
B: コアほど回収率が高い

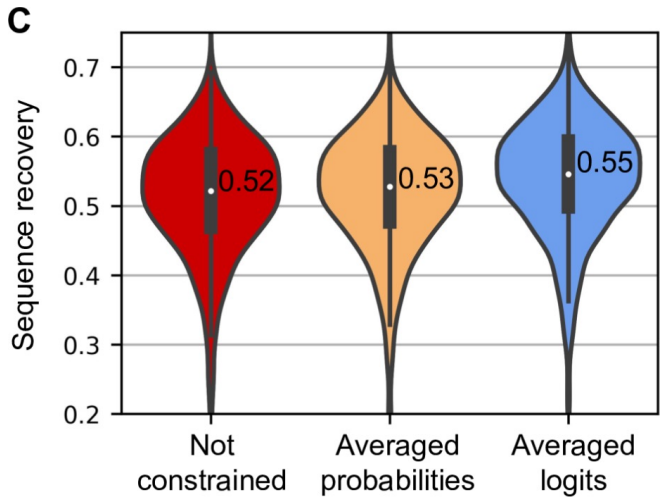
C: 対応位置は確率の平均が最良

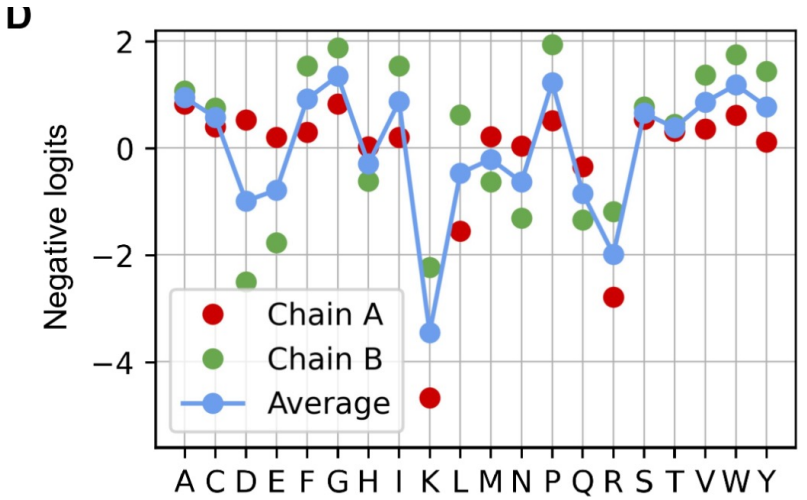
D: 鎖 A と B のロジットとその平均

出典: Fig. S1 A–D









方法

改良の積み重ねで回収率41.2→50.8%

モデル	改良	パラメータ (M)	PDB 回収率 (%)	PDB PPL	AF 回収率 (%)
Baseline	なし	1.381	41.2 / 40.1	6.51 / 6.77	41.4 / 41.4
Exp 1	N, Cα, C, Cβ, O 距離	1.430	49.0 / 46.1	5.03 / 5.54	45.7 / 47.4
Exp 2	encoder の枝を更新	1.629	43.1 / 42.0	6.12 / 6.37	43.3 / 43.0
Exp 3	1 と 2 を結合	1.678	50.5 / 47.3	4.82 / 5.36	46.3 / 47.9
Exp 4	3 ＋ ランダムデコード	1.678	50.8 / 47.9	4.74 / 5.25	46.9 / 48.5

値は「ノイズなし学習 / ノイズ 0.02 Å 学習」。テスト集合の値。Table 1 より

結果

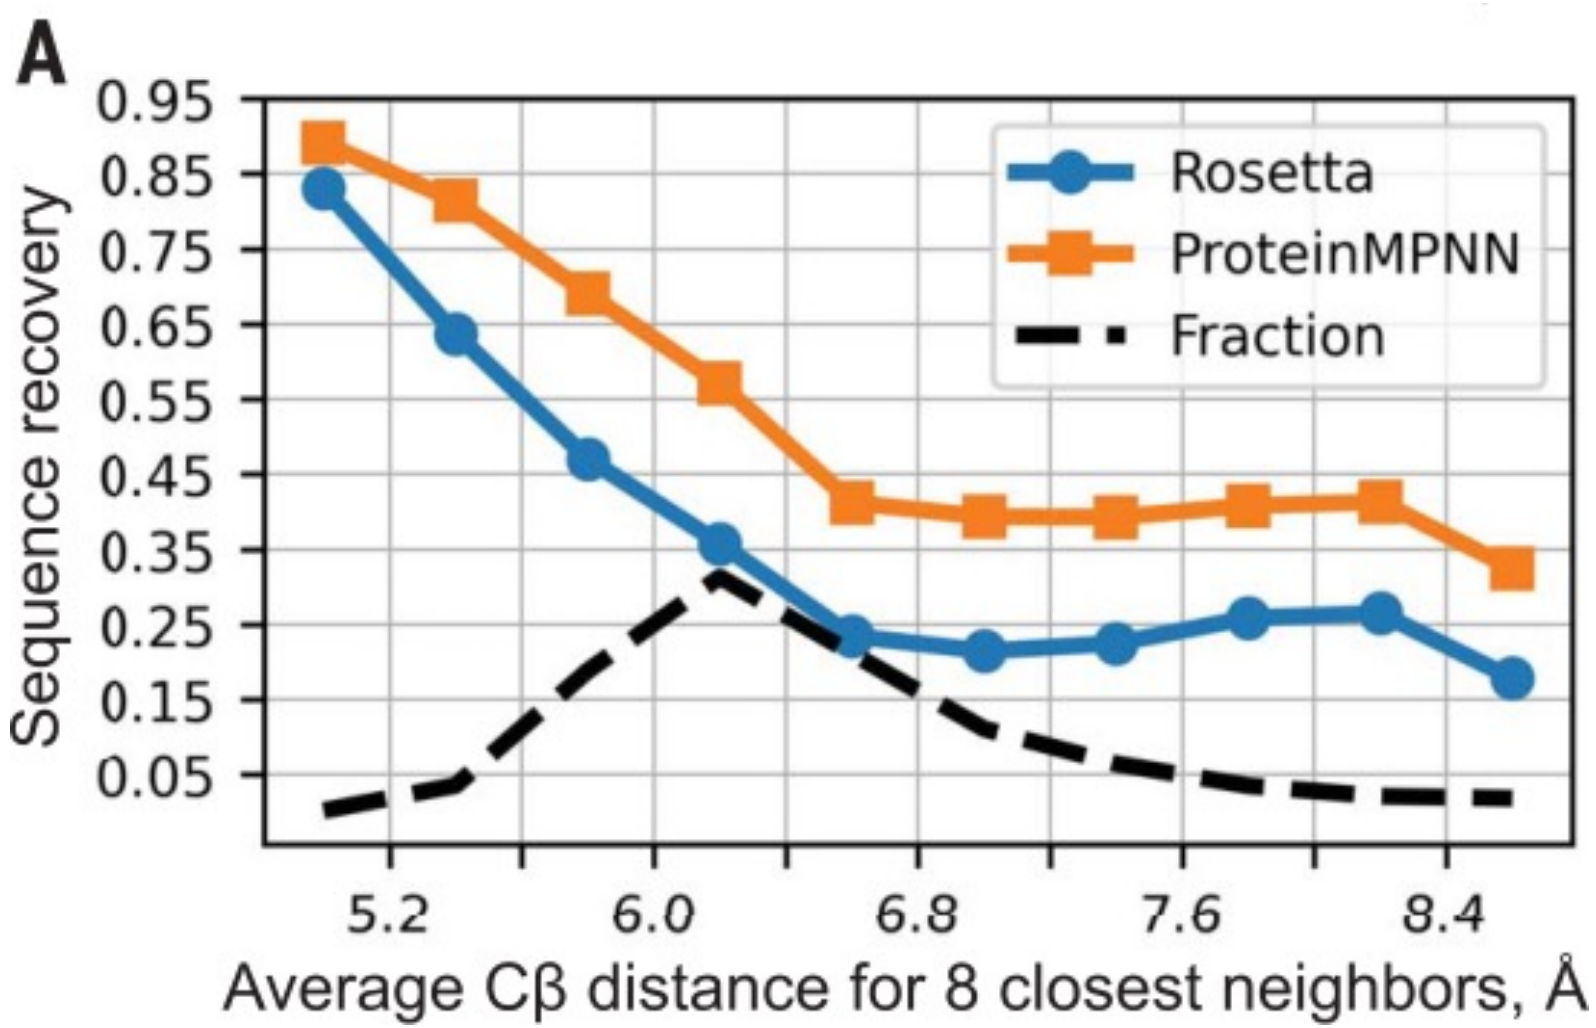
Rosetta より回収率が19.5ポイント高い

平均回収率 52.4% 対 32.9%

計算時間 1.2 秒対 258.8 秒（100 残基）

埋まりの全範囲で ProteinMPNN が上回る

出典: Fig. 2A



結果

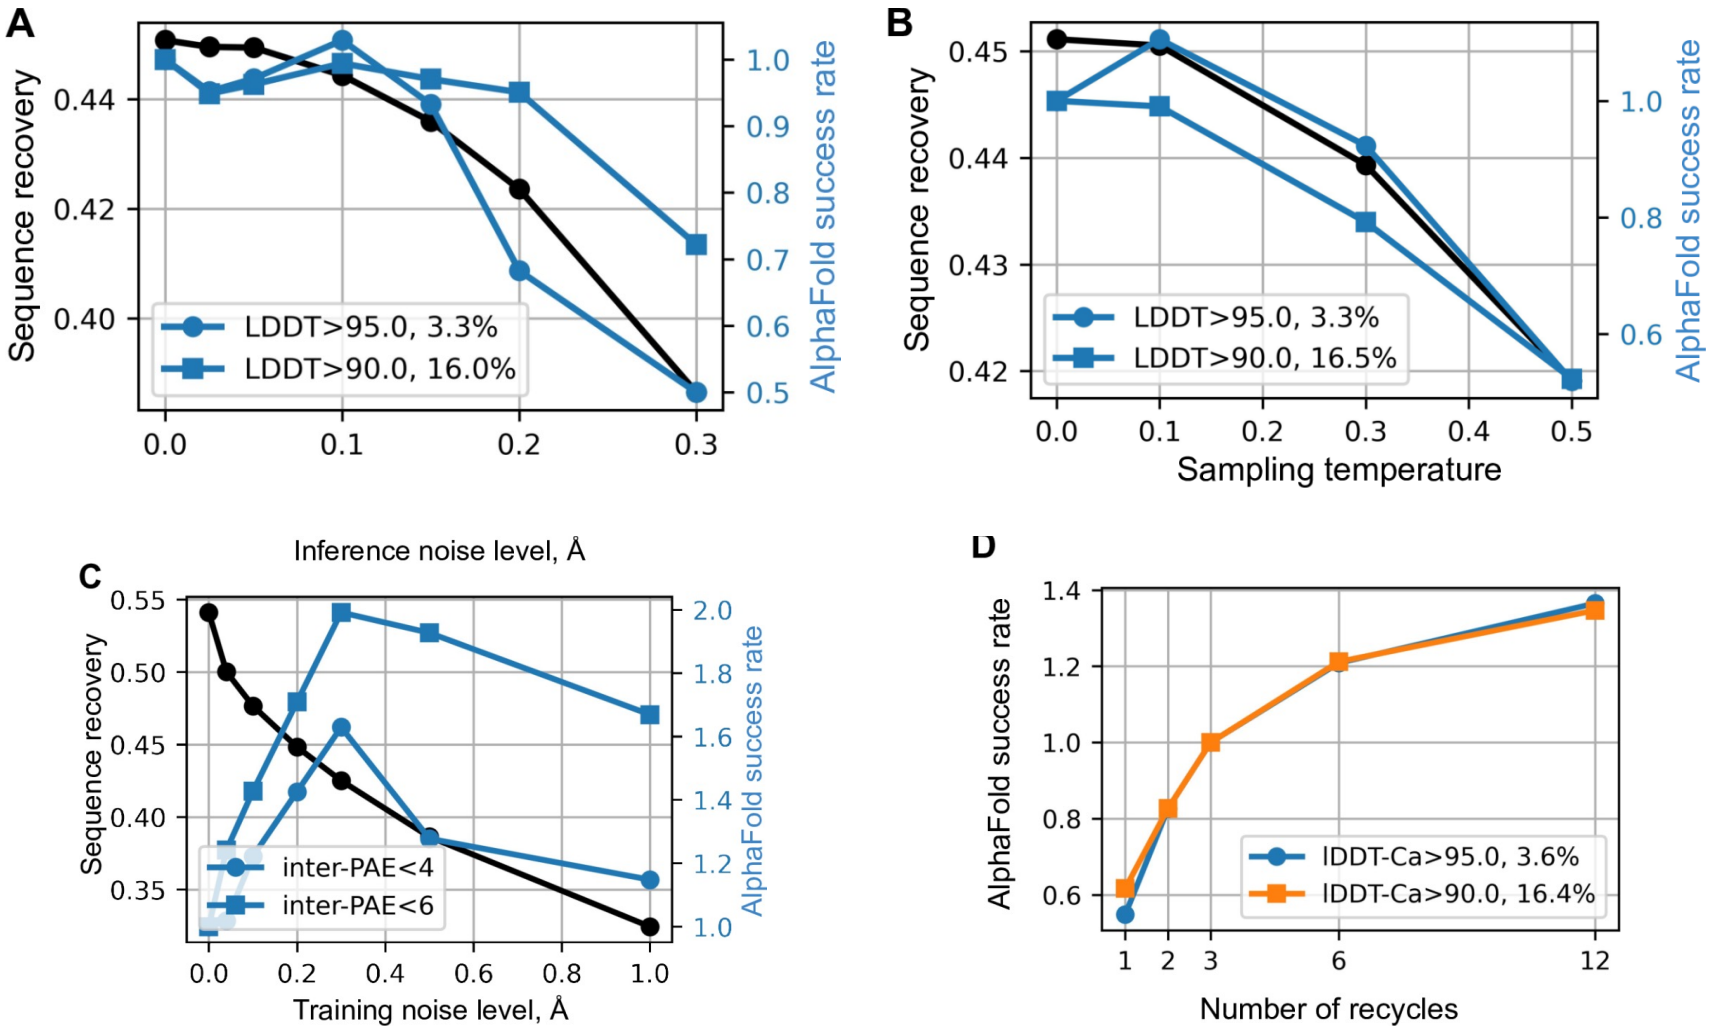
0.2Åモデルの条件別のベンチマーク

A 推論時ノイズ / B 温度 / C ホモの PAE / D recycles

0.2 Å 学習モデル。どの条件も増やすと成功率は下がる

recycles 増で成功率は単調に上がる → 配列は構造を正しく符号化

出典: Fig. S7 A–D



結果

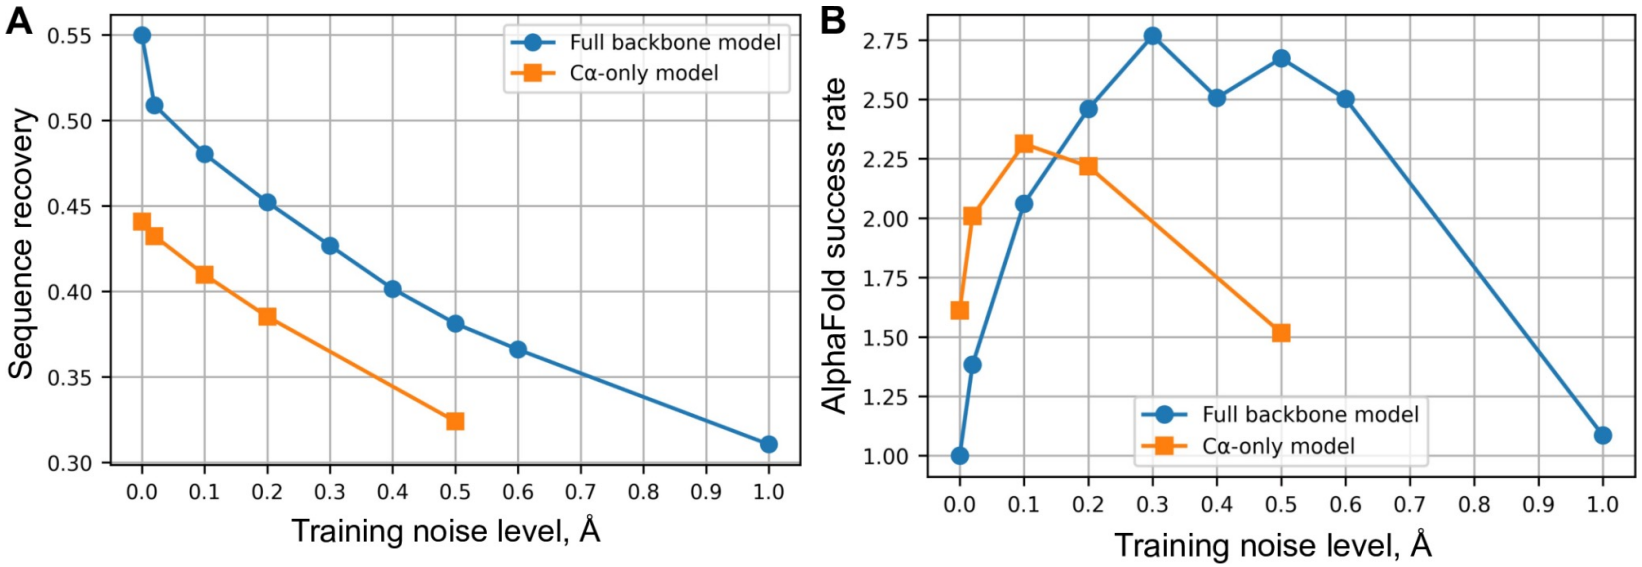
粗い主鎖向けにCαだけのモデルもある

Cα 3 点の距離を入力にした版

回収率はフル原子版より 2–3 ポイント低い

AF 成功率はノイズで上がる（フル原子と同じ傾向）

出典: Fig. S9 A, B



粗いモデルやモデル予測の主鎖に配列を載せるときに使う。公開コードに同梱

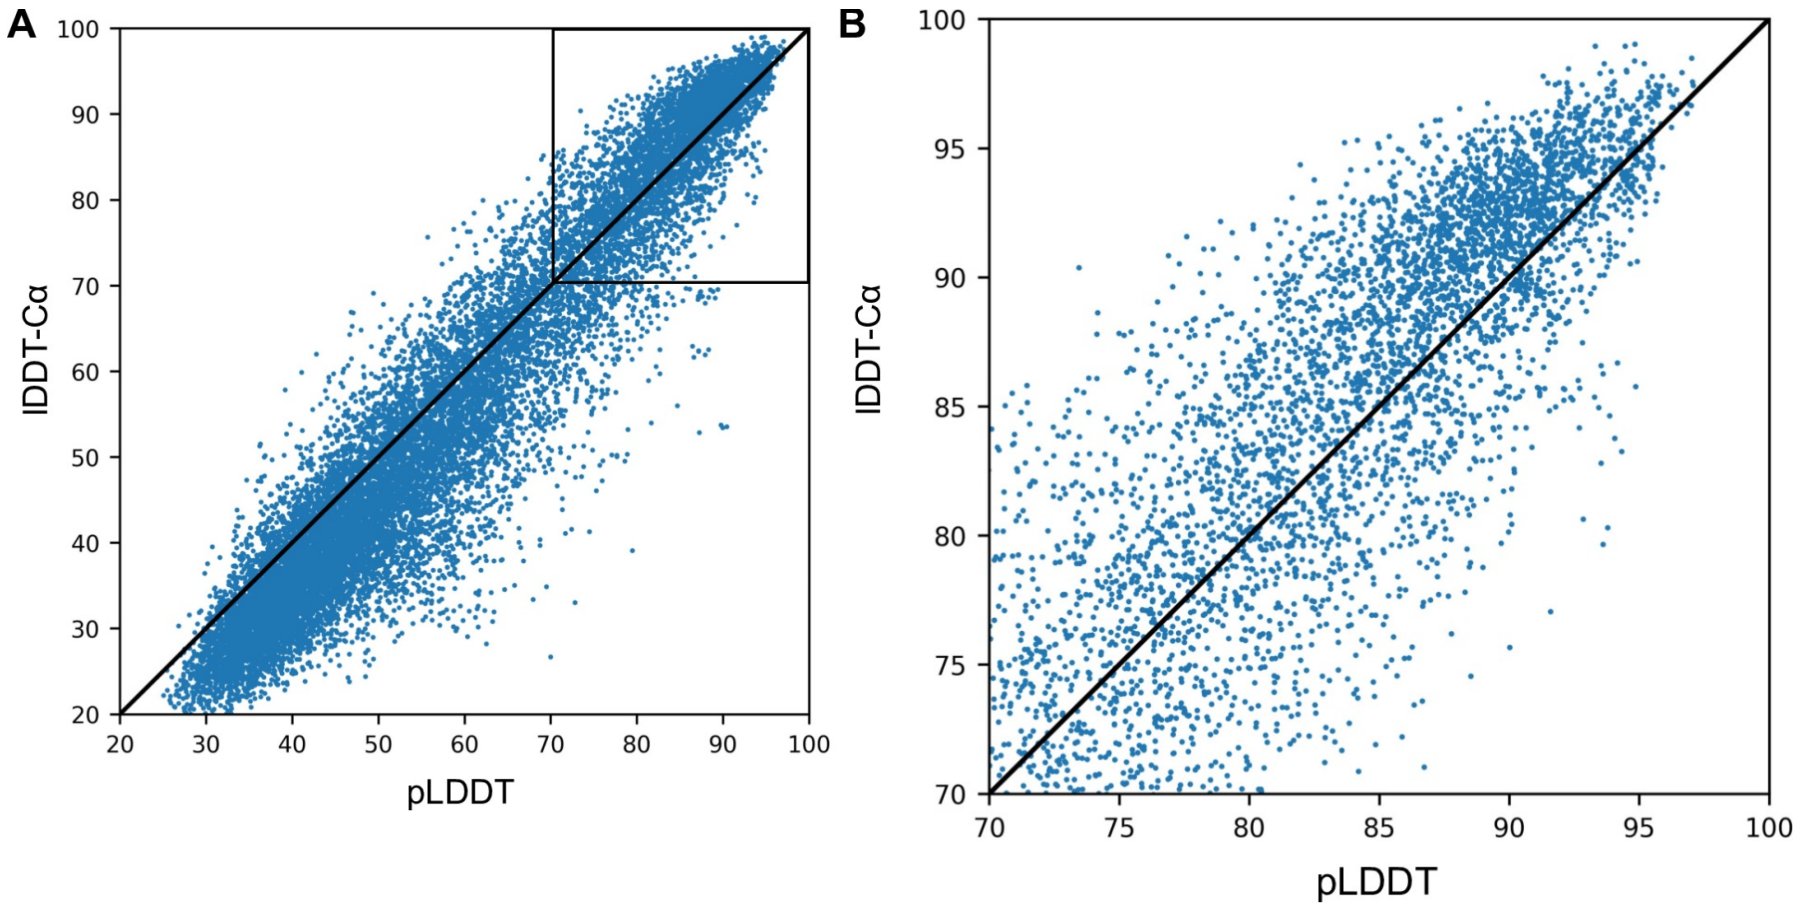
結果

pLDDTは真のlDDTをわずかに過小評価

単一配列でも pLDDT と真の lDDT は強く相関

pLDDT はわずかに過小評価（B）

出典: Fig. S8 A, B

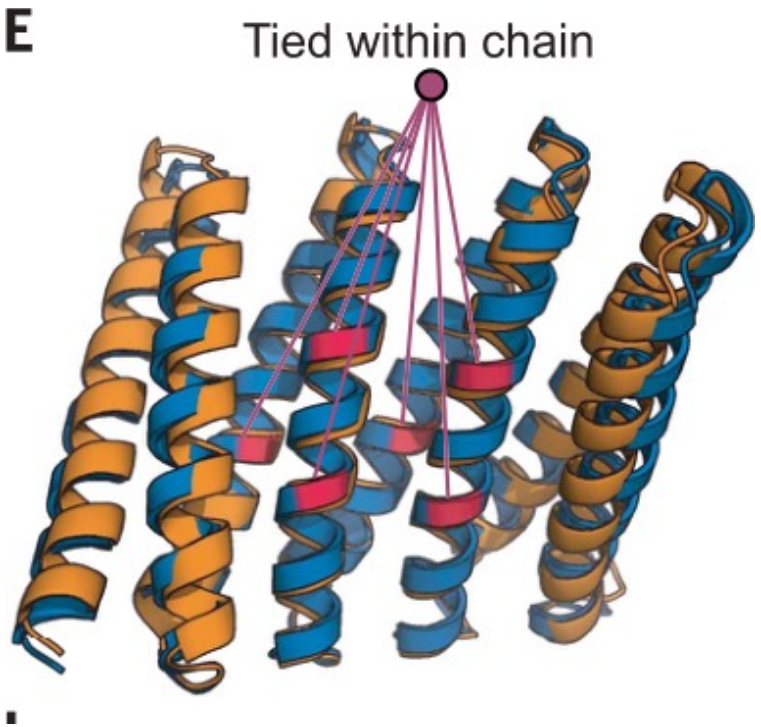


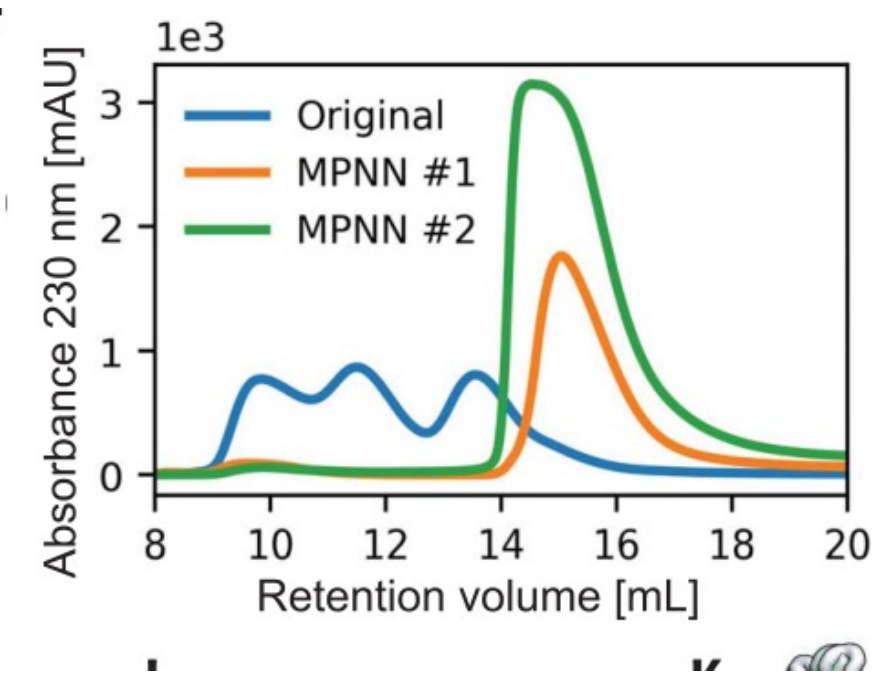
実験

リピートは対応位置を結ぶと救える

E: 設計モデル（橙）と rescue の AF 予測（青）。対応位置は線で結ぶ
232 残基で約 1.2 Å

出典: Fig. 3E, F





考察

最適化ではなく条件付き確率として解く

枠組みの違い

Rosetta: 「他の構造に低くならない」を直接は最適化できない → 人手の調整

ProteinMPNN: PDB 全例から主鎖→配列の確率を直接学習 → 調整が不要

物理的な透明性は Rosetta に劣る

限界と注意

天然回収率は分解能に敏感で、折りたたみの成功を保証しない

翻訳の正確さが最終的に人に評価されるのと同じく、設計は実験で検証する

1 残基の置換でも折りたたみを止めることはある

参考文献と再利用元

ProteinMPNN：Dauparas et al., Science (2022).
https://doi.org/10.1126/science.add2187
RFdiffusion：Watson et al., Nature (2023).
https://doi.org/10.1038/s41586-023-06415-8
AfDesign：Frank et al., Science (2024).
https://doi.org/10.1126/science.adq1741