生命情報工学特論　第07回

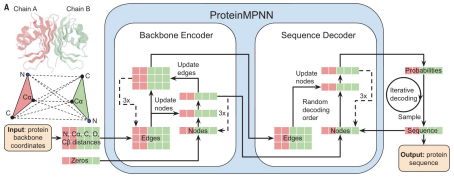
タンパク質設計

骨格を作り、配列を選び、
予測構造と比べる

松永 康佑

埼玉大学 大学院理工学研究科
理化学研究所 計算科学研究センター

2026年11月9日



骨格 → 配列 → 予測構造
構造を条件に、配列を選ぶ。
元の骨格と再予測した形を比べる。

講義

目標の構造から配列を作り、予測構造と比べる

入力：目標となる骨格構造や、残したい機能部位。
出力：候補のアミノ酸配列と、その予測構造。
同じ骨格に合う配列は一つとは限らない。
構造の一致と、発現・安定性・機能を分けて評価する。

条件・機能
↓
RFdiffusion：骨格
↓
ProteinMPNN：配列
↓
AF2：予測して比較

講義

骨格・配列・評価の役割を分けて学ぶ

1　予測と設計：入力と出力の違い
2　RFdiffusion：条件付きの骨格生成
3　ProteinMPNN：構造から配列の分布へ
4　AF2：設計配列を予測して比較
5　AfDesign：予測器を使う配列最適化
最後に固定骨格設計をColabで体験する。

配列の連続表現
→
AF2
重みは固定
→
標的との差：損失
→
勾配で配列を更新

背景

配列設計は、目標の構造に合う配列を探す

順方向: 構造予測
配列 s から構造 X を予測する（AlphaFoldなどが扱う）

逆方向: 配列設計（逆折り畳み）
構造 X が先に決まっている。同じ形へ折りたたまれる配列は複数ありうる

→ 条件付き確率 P(s | X) を出す問題として解く

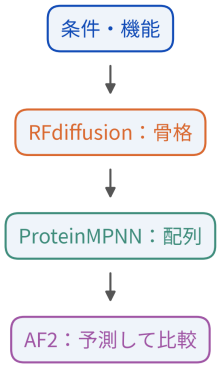
この論文が解くこと
主鎖構造 X が与えられたときの配列の条件付き確率を、PDB の天然構造から学ぶ
単量体・環状オリゴマー・ナノ粒子・結合界面の設計に同じモデルで対応する

目標の構造 X → **配列候補 s** → **構造を再予測** → **標的と比較**

講義

三つのモデルは、異なる条件付き問題を解く

RFdiffusion：長さ・モチーフ・対称性などの条件から、主鎖の形を作る。
ProteinMPNN：与えられた主鎖に合う配列をサンプルする。
AF2：候補配列から構造を予測して、最初の骨格との差を測る。
候補は各段階で複数残し、実験へ進めるものを絞る。



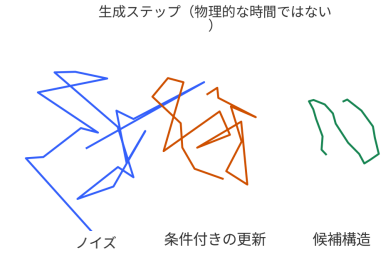
$$X \sim p_\theta(X \mid c), \quad s \sim p_\phi(s \mid X), \quad \hat{X} = f_{\mathrm{AF2}}(s)$$

AIで認識を予測し設計する

拡散モデルはノイズを段階的に減らす

学習では構造などへノイズを加え、元へ近づける操作を覚えます。生成時はノイズのある状態から、条件に合う候補へ進めます。

この段階は実時間の分子運動とは異なります。生成ステップの動画を、その分子が溶液中で動く経路と解釈しません。



自作模式図（寸法・時間は実物と異なる）

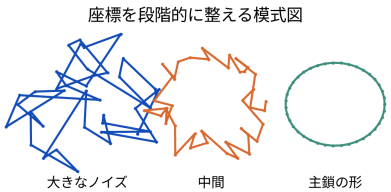
生成過程の時間と、物理的な時間を分ける。

[26] AlphaFold 3　[37] DiffAb

講義

RFdiffusionは主鎖の位置と向きを更新する

残基を、Cαの位置と局所座標系の向きで表す。
学習では既知の主鎖を段階的に乱し、元の配置を推定する。
生成では大きく乱れた配置から始め、同じ学習済みモデルで形を整える。
右は位置だけの模式図。実際には回転のノイズも扱う。折り畳みの物理時間ではない。



$$\text{residue } i: \ (\mathbf{t}_i, R_i), \quad \mathbf{t}_i \in \mathbb{R}^3, \ R_i \in SO(3)$$

講義

機能部位を残し、その周囲の骨格を生成する

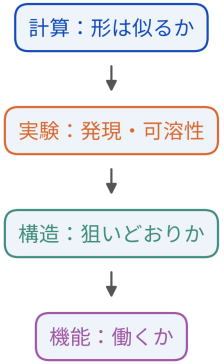
モチーフ：残したい局所構造。例えば触媒残基の配置や結合部位。
固定する部分と、生成する部分を入力で区別する。
結合相手を条件として、接触する新しい骨格を作ることもできる。
条件を満たす座標が出ても、配列が折り畳まれ、機能するとは限らない。

残す局所構造を指定 → **周囲の骨格を生成** → **配列を設計** → **機能を検証**

講義

生成した骨格を、配列と実験へつなぐ

RFdiffusionの出力だけでは、発現するタンパク質は決まらない。
一つの骨格につき複数の配列を設計し、再予測して形の再現性を見る。
実験では発現・可溶性、構造、結合や触媒機能を調べる。
計算での絞り込みと実験の成功率を区別する。



方法

ProteinMPNN の全体像

入力は主鎖の座標のみ。encoder（3 層・隠れ次元 128）で節点と枝の特徴を作り、decoder（3 層）がランダムなデコード順で配列を 1 残基ずつ出力する

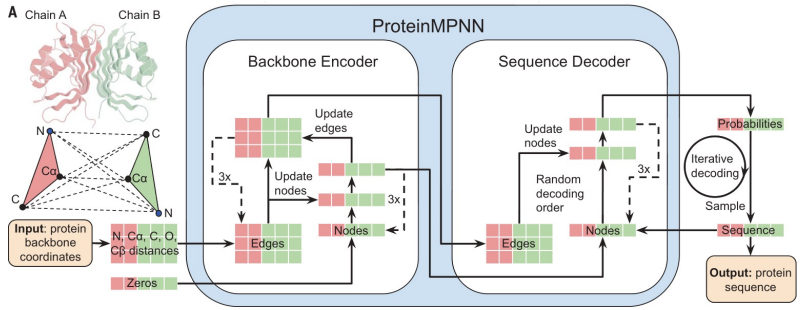


Fig. 1A より

補足

残基のグラフをメッセージパッシングで読む

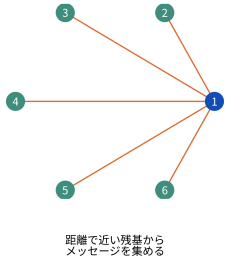
近傍から集めた特徴で、節点と枝を更新

$$M_{ij} = \mathrm{MLP}[V_i, V_j, E_{ij}]$$

$$dV_i = \mathrm{MLP}\left[\sum_{j \in N(i)} M_{ij}\right]$$

$$V_i^{new} = \mathrm{LayerNorm}[V_i + \mathrm{Dropout}(dV_i)]$$

$$E_{ij}^{new} = \mathrm{LayerNorm}[E_{ij} + \mathrm{Dropout}(\mathrm{MLP}[V_i^{new}, V_j^{new}, E_{ij}])]$$



距離で近い残基からメッセージを集める

V：残基の特徴、E：残基対の特徴。MLPは小さな全結合ニューラルネットワーク。
encoderは構造を特徴へ変換し、decoderは確定済みの配列も参照して次の残基を選ぶ。
前の特徴を足す残差接続と、LayerNorm（特徴の規格化）を各層に用いる。

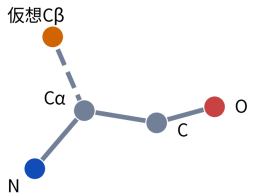
方法

主鎖4原子と仮想Cβの距離を入力する

仮想 Cβ の作り方（Methods より）

$\mathbf{b} = \mathbf{C}_\alpha - \mathbf{N}$, $\mathbf{c} = \mathbf{C} - \mathbf{C}_\alpha$, $\mathbf{a} = \mathbf{b} \times \mathbf{c}$

$$\mathbf{C}_\beta = -0.5827\,\mathbf{a} + 0.5680\,\mathbf{b} - 0.5407\,\mathbf{c} + \mathbf{C}_\alpha$$



1UBQの主鎖を使い、Methodsの式で仮想Cβを算出。

入力特徴

主鎖のN・Cα・C・Oと仮想Cβの残基間距離を、16個のガウス基底関数で表す。
距離特徴の追加で、天然配列の回収率は41.2 → 49.0%、パープレキシティは6.51 → 5.03に改善した（Table 1）。
ノイズあり学習では回収率40.1 → 46.1%。

補足

配列は1か所ずつ順に決める自己回帰モデル

確率と学習の式

$$p(a_i \mid X) = \frac{\exp z_i(a)}{\sum_b \exp z_i(b)}$$

$$\mathcal{L} = -\frac{1}{T}\sum_{t=1}^{T} \log P\left(s_{o_t} \mid s_{o_1}, \ldots, s_{o_{t-1}}, X\right)$$

$$\mathrm{PPL} = \exp \mathcal{L}$$

読み方

$z_i(a)$：残基iにおけるアミノ酸aのロジット（正規化前の得点）。
天然配列の対数確率を最大にする。負の平均が交差エントロピーL。
パープレキシティPPLは、正解残基に対する予測の不確かさを表す。1に近いほど正解に高い確率を与える。Table 1の値はテスト集合で評価したもの。

位置の順序を選ぶ → 既知の残基を参照 → 次の残基の確率 → 1残基を選ぶ

方法

デコード順をランダムにすると固定領域を扱える

自己回帰の分解（デコード順 o はランダム）

$$P(s_{o_1}, \ldots, s_{o_T} \mid X) = \prod_{t=1}^{T} P\left(s_{o_t} \mid s_{o_1}, \ldots, s_{o_{t-1}}, X\right)$$

学習のたびに o を全順列からサンプル（Table 1 の実験 4）

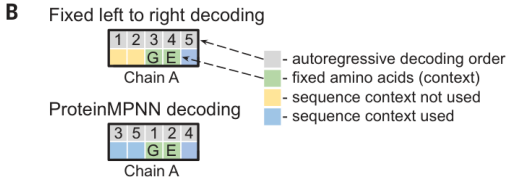


Fig. 1B より

左から右の固定順では、決め打ちの残基（緑）を文脈に使えない

ランダム順なら、結合相手の配列を先にデコードしておき、文脈として使える（結合設計に必須）

方法

対応位置を同じ残基にして対称性を保つ

対応位置のグループ G でロジットを平均

$$\bar{z}(a) = \frac{1}{n}\sum_{i \in G} z_i(a)$$

$$p(a) = \frac{\exp \bar{z}(a)}{\sum_b \exp \bar{z}(b)}$$

多状態設計では各状態のロジットを重み付きで足す。

$$\bar{z}(a) = \sum_k w_k z^{(k)}(a)$$

重みを正・負にして、望む状態と避けたい状態を指定する。

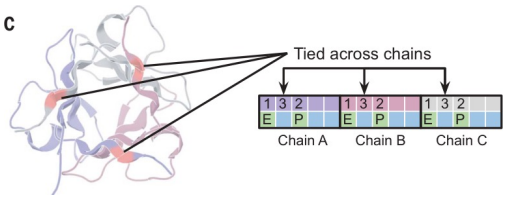


Fig. 1C より

ホモ三量体では 3 本の鎖の対応位置を結合。ロジットを平均して確率へ変換し、そこから 1 残基をサンプル

リピートはユニット内の対応位置、対称体は鎖間の対応位置を同じ残基にする（Fig. 3 の実験で使う）

方法

類似配列をまとめてからデータを分割する

損失（Methods より）

$$\mathcal{L} = \frac{1}{2000}\sum_t \ell_t \, m_t$$

ℓt: 残基ごとの交差エントロピー、mt: マスク

データと最適化

多量体: PDB 会合体（分解能 3.5 Å より良好、10,000 残基未満）。mmseqs2 で 30% 一致のクラスタ分割

訓練 23,358 / 検証 1,464 / テスト 1,539 クラスタ。同じクラスタの鎖が複数の集合に入らないようにする

ラベルスムージング 10%、Adam（$\beta_2 = 0.98$）。A100 1 枚で混合精度

検証パープレキシティは約 15 万ステップ（約 100 エポック）で収束（Fig. S3D）

訓練 23,358	検証 1,464	テスト 1,539

配列クラスタを単位として分割し、似た配列が学習側と評価側に混在するのを防ぐ。

方法

主鎖へのノイズで、座標の違いに対応しやすくする

学習時のノイズ

$\tilde{X} = X + \varepsilon,\ \varepsilon \sim \mathcal{N}(0, \sigma^2 I)$

$\sigma = 0.02\ \text{Å}$

同じ構造の座標を少しずらして学習



変位を25倍に拡大して表示（実際の σ = 0.02 Å）

なぜ効くか

結晶構造の精密化では、配列に依存する微細な座標の特徴が残りうる。ノイズはその細部への依存を弱める

PDBの座標では回収率が下がる例がある（41.2→40.1%）。一方、AF予測構造での回収率は改善した

ノイズの大きさごとの 16 種モデルが公開されている。入力主鎖の質に合わせて選ぶ

評価したノイズ範囲では、設計配列のAF構造予測成功率が上がる（Fig. 2C で後述）

結果

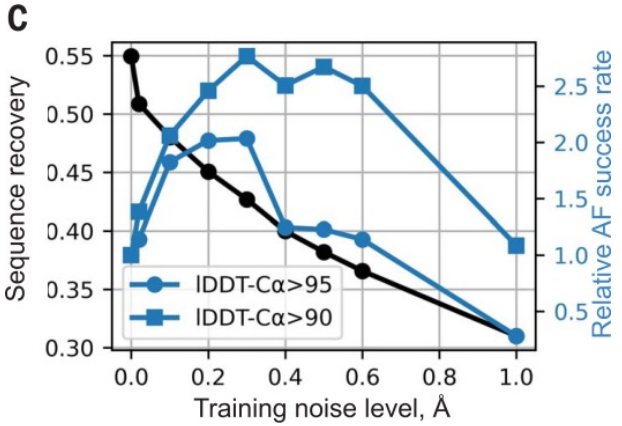
ノイズ付き学習はAlphaFoldの成功率を上げる

黒: 回収率（ノイズで下がる）

青: AF 成功率（ノイズで上がる）

0.3 Å ノイズで 2–3 倍の配列が高精度予測に

出典: Fig. 2C



結果

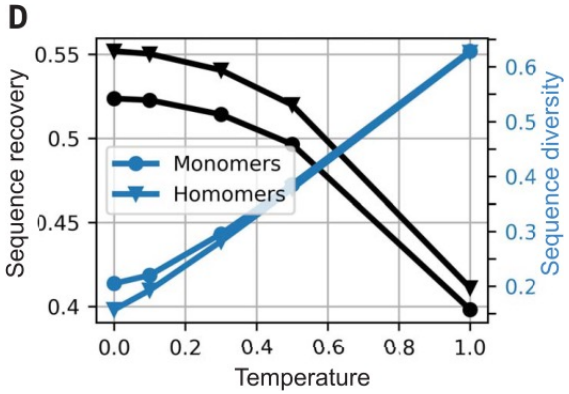
温度を上げると多様性が増え回収率は下がる

温度つきソフトマックス（補足より）

$$p(a \mid X) = \frac{\exp[z(a)/T]}{\sum_b \exp[z(b)/T]}$$

学習時は T=1。推論時に動かす

出典: Fig. 2D



結果

回収率は配列の対数確率や構造の質と相関する

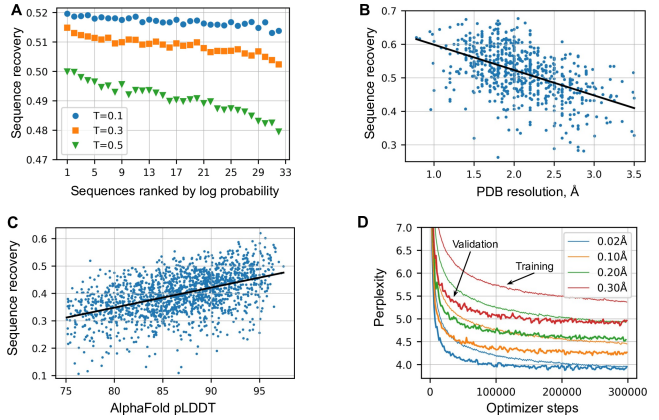
A: 対数確率でランキングできる

B: 分解能が低いと回収率が下がる

C: pLDDT とも相関

D: ノイズ大は検証 PPL を上げる

出典: Fig. S3 A–D



結果

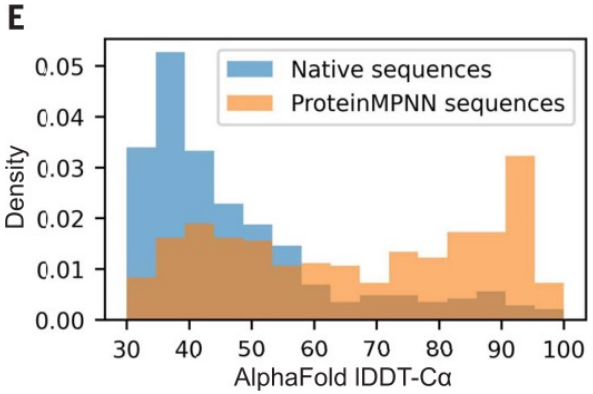
設計配列は、単一配列のAF予測で構造を再現しやすい

この評価では、再設計配列のほうが天然配列よりAFの単一配列予測で標的構造を再現した

著者らは、天然配列が安定性だけで選ばれていないことを一つの背景として挙げている

組換え発現・安定化への応用を示唆

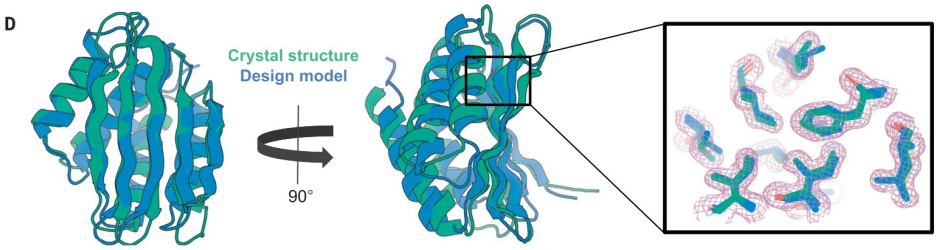
出典: Fig. 2E



実験

結晶構造と設計モデルのRMSDは2.35 Å

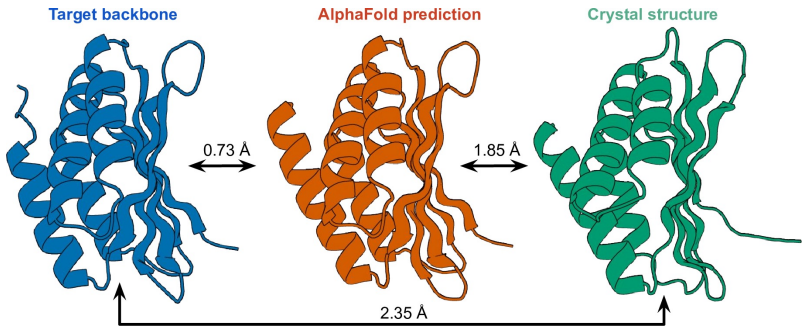
幻覚法設計 HALC1_878（PDB ID: 8CYK）。Cα 2.35 Å RMSD（130 残基）。TM スコア 0.56。コア側鎖は電子密度に一致（Fig. 3D、fig. S5）



実験

設計・AF予測・結晶構造をRMSDで比べる

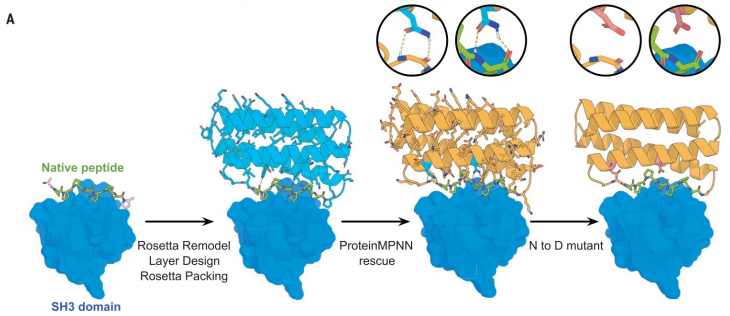
RMSD: 設計モデル対 AF 予測 0.73 Å、設計対結晶 2.35 Å、予測対結晶 1.85 Å（Fig. S5）



実験

モチーフを固定してSH3結合タンパク質を設計する

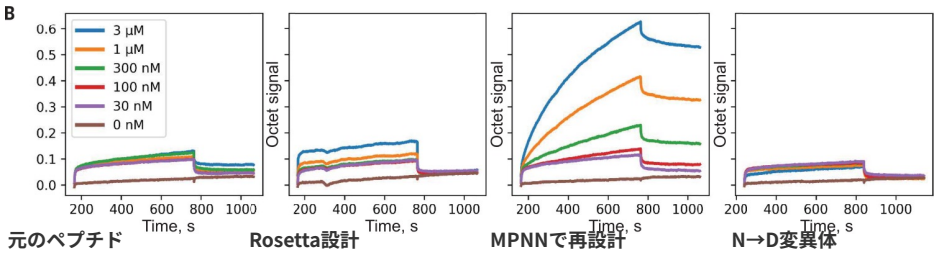
Gab2 ペプチド（モチーフ PPPRPPK は緑）を RIFDOCK＋Rosetta remodel で足場に載せ、MPNN で足場側のみ再設計。N は足場の水素結合を担い、N→D 変異で破綻するよう設計（Fig. 4A）



実験

結合は実測され、変異で消える

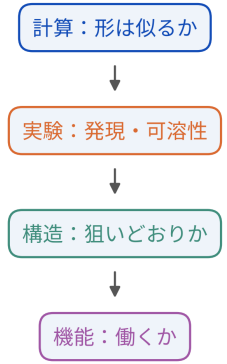
生物層干渉法（BLI）。ペプチド / 元の Rosetta 設計 / MPNN 設計 / N→D 変異体の順。MPNN 設計が最も強く結合し、変異でシグナル消失（Fig. 4B）



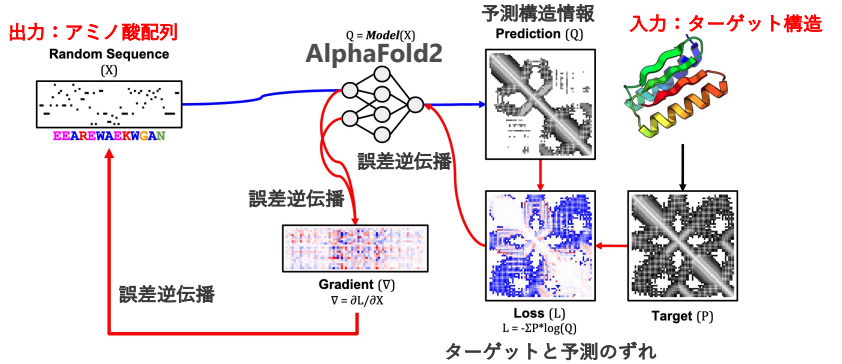
講義

天然配列の回収率と、設計成功は違う

回収率は、既知構造から天然と同じ残基を何割選べたか。
配列の条件付き確率が高いことは、熱力学的な安定性そのものではない。
別の配列でも同じ構造へ折り畳まれるなら、設計として成功しうる。
構造の一致、発現、機能という別の観測を組み合わせる。



ColabDesign　AlphaFold 2による予測構造のずれを逆伝播させて配列を探索

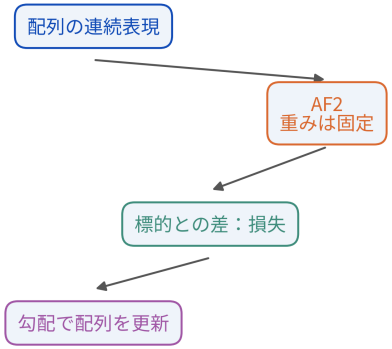


C. Frank et al., Scalable protein design using optimization in a relaxed sequence space, Science **386**, 439 (2024).
S. Ovchinnikov, https://github.com/sokrypton/ColabDesign

講義

AfDesignは、AF2を微分して配列へ戻る

AF2の重みを固定し、入力する配列側を変える。
目標の構造と予測との差を損失にし、配列の連続表現に対する勾配を計算する。
ProteinMPNNのように配列の条件付き分布を学習し直す手順ではない。
固定骨格設計では、目標骨格を損失の参照に使う。

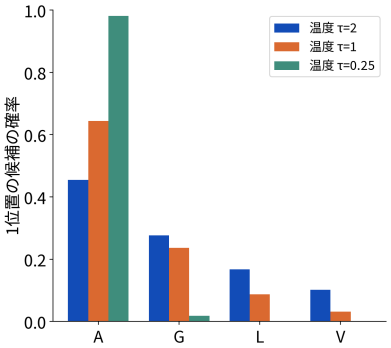


$$z \leftarrow z - \eta \nabla_z \mathcal{L}(f_{\mathrm{AF2}}(p(z)), X^*)$$

講義

離散的なアミノ酸を、連続表現から選ぶ

各位置に20種類の得点（ロジット）を置く。
softmaxで重みへ変換すれば、配列入力を連続的に変えられる。
温度を下げると一つの候補へ集中し、最後に離散的な配列へ移す。
右は4種類に減らした説明用の計算。実際は20種類。

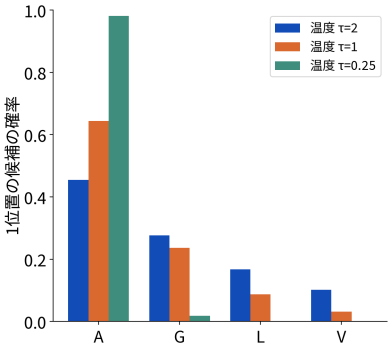


$$p_i(a) = \frac{\exp(z_i(a)/\tau)}{\sum_b \exp(z_i(b)/\tau)}$$

講義

三段階で、配列を離散的な候補へ近づける

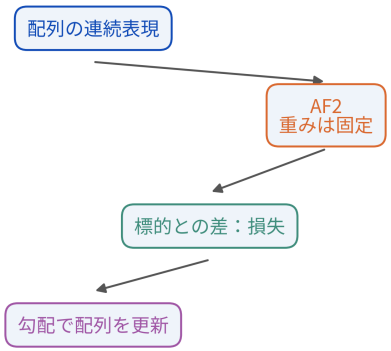
soft：連続的な入力を動かして形を探す。
temp：softmaxの温度を下げ、候補を絞る。
hard：離散的な配列を使う段階へ進む。
短い演習設定は動作を見るためのもの。十分な最適化や実験成功を保証しない。



講義

構造への適合と、予測の信頼度を分ける

固定骨格設計では、目標構造との距離分布の差などを減らす。
pLDDTなどの信頼度を損失へ加える場合もある。
RMSDは目標との座標の差、pLDDTは予測器自身の信頼度。値の意味も単位も違う。
重みや反復数は記録し、条件の違う実行を混ぜて比較しない。



講義

設計に使った予測器だけでは独立な検証にならない

AfDesignでAF2へ適合させた配列を、同じAF2で評価すると循環する。
高い信頼度でも、予測器の弱点を利用した配列が残る場合がある。
別のモデル・異なる条件での再予測は補助になるが、実験とは異なる。
発現・構造・機能を測る検証へつなげる。

同じAF2で再評価
設計に使った評価器。適合の確認にはなる。

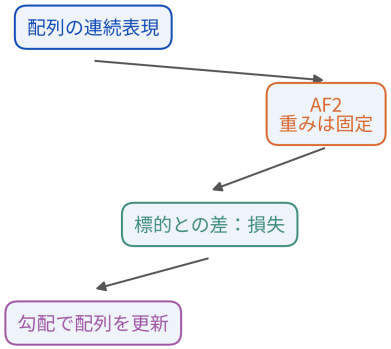
別モデル・条件で再予測
モデルや設定への依存を調べる。

発現・構造・機能を測定
計算と独立な観測で確かめる。

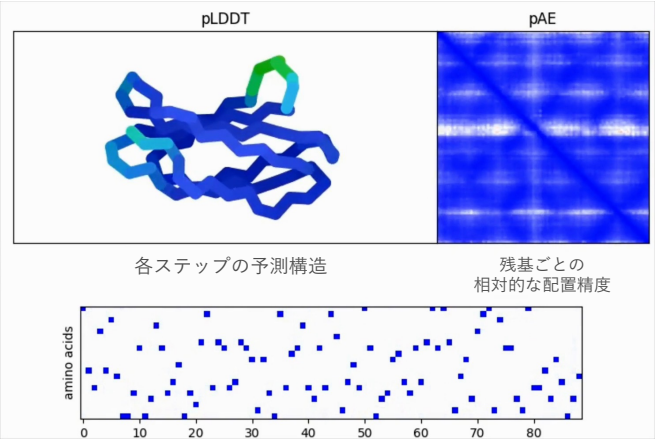
講義

固定骨格設計の対象：1TENの鎖A

1TENはテネイシンのフィブロネクチンIII型ドメイン。
公式AfDesignの固定骨格設計例を再利用する。
入力：PDB 1TENの鎖A。
出力：設計配列、予測PDB、損失の推移。
標的の原子が登録されている残基を対象とし、番号と長さを確認する。



ColabDesignの動作例



アミノ酸配列の候補が絞られる様子

ターゲット構造 (PDB ID: 1TEN)



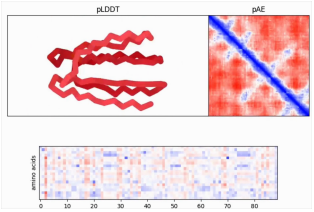
リデザイン構造



配列設計の推移

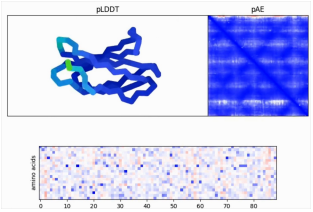
予測構造を繰り返し比べて、配列を更新する

初期



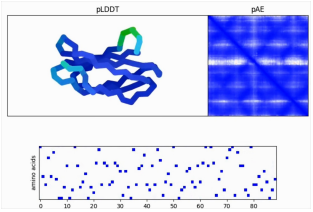
初期：多くの残基候補に重みが分散。
構造の予測信頼度もまだ低い。

中間



中間：目標とのずれを減らし、配列候補を更新している。

終盤



終盤：一つの残基へ重みが集中。
離散配列として再評価する。

原資料の最適化動画から3時点を抜粋。物理時間に沿った折り畳みの動画ではない。

同じ位置をそろえて、天然配列と設計配列を比べる

配列中の位置 1–45

天然 RLDAPSQIEVKDVTDTTALITWFKPLAEIDGIELTYGIKDVPGDR

設計 –AKPCKNMVVSGVTDGSFLVSWERPEGPFEGIYISVRPHGDPTGP

配列中の位置 46–90

天然 TTIDLTEDENQYSIGNLKPDTEYEVSLISRRGDMSSNPAKETFTT

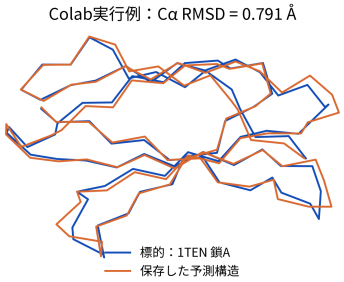
設計 RQYFLPAGVTSIHFSGFEAGAEYMITCRAYNGGTYAPPKTIFVTM

研究発表時の設計例。天然配列の先頭Rは座標未登録で設計対象外（–）。今回の演習結果とは別。

演習

演習：固定骨格設計をColabで動かす

T4 GPUを選び、準備 → 入力確認 → 設計 → 観察の順に実行する。
演習20分を目安。初回の重み取得とGPU待ち時間は別に変動する。
損失の変化、得られた配列、標的と予測構造の重ね合わせを確認する。
採点・提出なし。長い実行は途中経過を保存する。



動作確認例：T4、seed 42、soft 100 / temp 30 / hard 10。保存した89残基のCαを重ね合わせた。

演習

結果は、配列・構造・条件を一緒に残す

設計配列だけでなく、標的のPDBと鎖、乱数seed、反復数、損失の重みを残す。
RMSDは同じ残基・同じ原子の対応で、重ね合わせ後に計算する。
pLDDTが高いのに形が異なる場合もあるため、立体表示を併用する。
この演習の結果を、実験で機能を確認した設計とは扱わない。

design.fasta
候補のアミノ酸配列

design.pdb
保存した予測座標

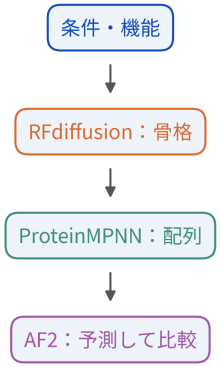
result.json
条件・損失・信頼度

trajectory.png
最適化の推移

まとめ

骨格を作る・配列を選ぶ・確かめる

RFdiffusionは条件から骨格候補を作る。
ProteinMPNNは骨格を条件に配列を選ぶ。
AF2で再予測し、骨格との一致と信頼度を見る。
AfDesignは予測器を通して配列を最適化する別の方法。
冒頭の目標は「候補を作って比較する」こと。実際の構造と機能は実験で確かめる。



付録

付録：配列設計の式と実験評価

ここからは独習用の補足です。
本編で使った式の導出や、手法の条件を確認します。
必要な項目から参照してください。

背景

Rosetta との違い: 最適化から学習へ

Rosetta: エネルギー最適化

側鎖回転体の詰め込みでエネルギー最小の配列を探す

低エネルギー状態が目的構造になる保証は直接は最適化できない

表面の疎水制限など人手の調整が必要で、設計が失敗することもあった

深層学習: PDB の例から条件付き確率を学ぶ

「主鎖の局所的な形」から「どの残基が自然か」を学習する

100 残基で Rosetta の約 200 分の 1 の時間（1.2 秒対 258.8 秒）

物理的な解釈は難しいが、側鎖の組合せを明示的に探索せず配列を作れる。本論文は実験でも評価した

補足

主な記号の一覧

記号	意味
X	主鎖構造（N, Cα, C, O の座標。仮想 Cβ を含む）
s_i	残基 i のアミノ酸の種類
o	デコード順（残基の並べ方の順列）
$z_i(a)$	残基 i のアミノ酸 a のロジット
T	サンプリング温度（学習時は 1）
σ	主鎖座標に加えるガウスノイズの標準偏差
PPL	パープレキシティ（交差エントロピーの指数）
lDDT-Cα / pLDDT	構造予測の正しさの指標 / その AlphaFold による予測値

方法

近傍数・埋まり・平均方法の検証

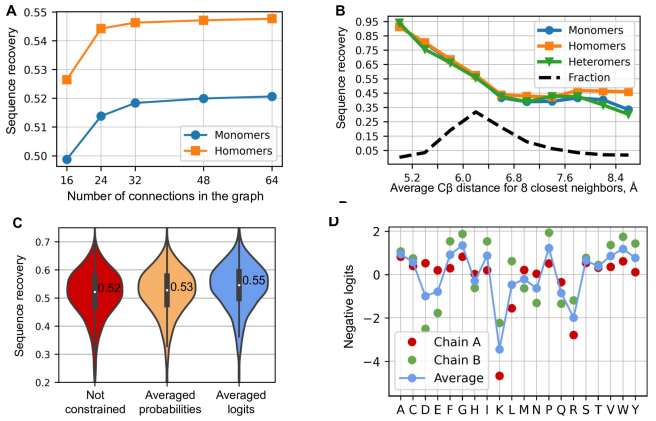
A: 近傍数は 32–48 で飽和

B: コアほど回収率が高い

C: ロジット平均が最良（0.55）。確率平均は0.53

D: 鎖 A と B のロジットとその平均

出典: Fig. S1 A–D



方法

改良の積み重ねで回収率41.2→50.8%

モデル	改良	パラメータ (M)	PDB 回収率 (%)	PDB PPL	AF 回収率 (%)
Baseline	なし	1.381	41.2 / 40.1	6.51 / 6.77	41.4 / 41.4
Exp 1	N, Cα, C, Cβ, O 距離	1.430	49.0 / 46.1	5.03 / 5.54	45.7 / 47.4
Exp 2	encoder の枝を更新	1.629	43.1 / 42.0	6.12 / 6.37	43.3 / 43.0
Exp 3	1 と 2 を結合	1.678	50.5 / 47.3	4.82 / 5.36	46.3 / 47.9
Exp 4	3 ＋ ランダムデコード	1.678	50.8 / 47.9	4.74 / 5.25	46.9 / 48.5

値は「ノイズなし学習 / ノイズ 0.02 Å 学習」。テスト集合の値。Table 1 より

結果

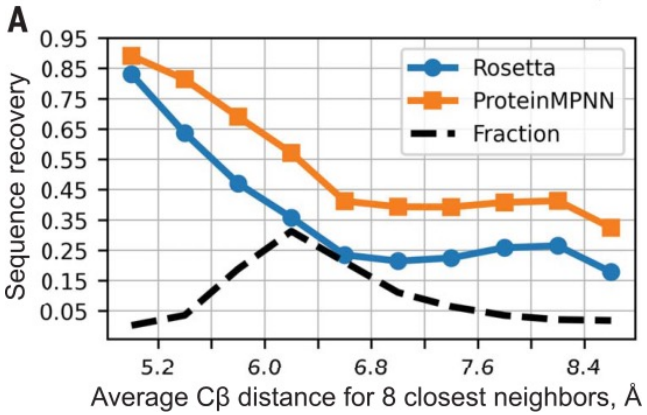
Rosetta より回収率が19.5ポイント高い

平均回収率 52.4% 対 32.9%

計算時間 1.2 秒対 258.8 秒（100 残基）

埋まりの全範囲で ProteinMPNN が上回る

出典: Fig. 2A



結果

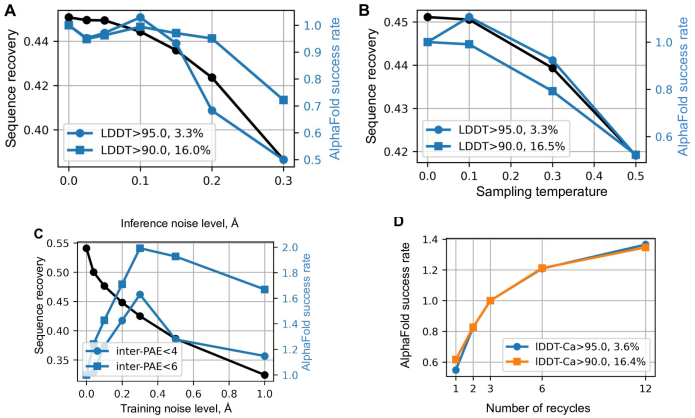
予測成功率への影響は、変える条件で異なる

A：推論時ノイズ
B：配列を選ぶ温度
C：学習時ノイズと鎖間PAE
D：AFの再計算回数

A・Bでは、推論時ノイズや温度を大きくすると成功率が下がる傾向。

Dでは、AFの再計算回数を増やすと成功率が上がる。

出典: Fig. S7 A–D



結果

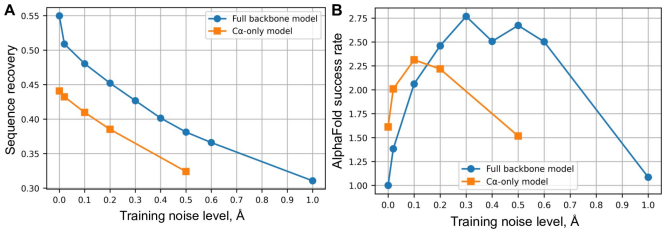
粗い主鎖向けにCαだけのモデルもある

Cα 3 点の距離を入力にした版

回収率はフル原子版より 2–3 ポイント低い

AF 成功率はノイズで上がる（フル原子と同じ傾向）

出典: Fig. S9 A, B



粗いモデルやモデル予測の主鎖に配列を載せるときに使う。公開コードに同梱

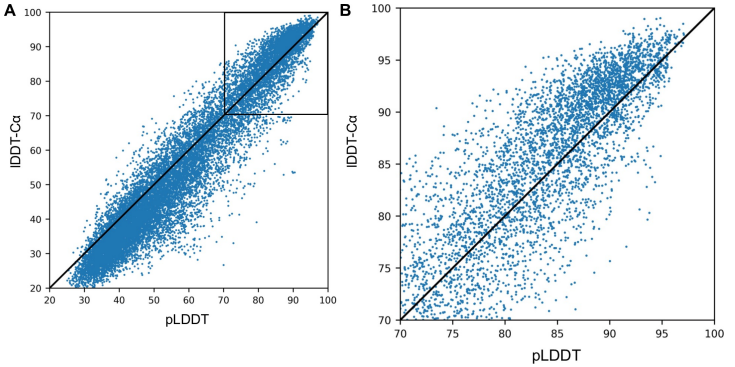
結果

pLDDTは真のlDDTをわずかに過小評価

単一配列でも pLDDT と真の lDDT は強く相関

pLDDT はわずかに過小評価（B）

出典: Fig. S8 A, B



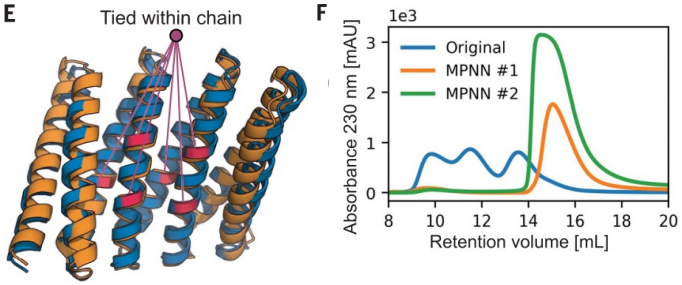
実験

リピートの対応位置をそろえて配列を再設計する

E：元の設計骨格（橙）と、再設計配列のAF予測（青）。同じ残基にする位置を線で示す。

E：232残基の構造比較でRMSD約1.2 Å。F：再設計後は、サイズ排除クロマトグラフィーのピークが鋭くなった。

出典: Fig. 3E, F



考察

学習した配列分布から候補を作り、実験で確かめる

枠組みの違い

Rosetta：指定した骨格上でエネルギーを評価する。他の構造との競合まで完全に排除できるわけではない。

ProteinMPNN：PDBの構造と配列から条件付き分布を学ぶ。温度、固定位置、評価条件などは選ぶ必要がある。

物理的な透明性は Rosetta に劣る

限界と注意

天然回収率は分解能に敏感で、折りたたみの成功を保証しない

設計配列が発現し、狙った構造と機能を示すかを実験で検証する。

1残基の置換でも、構造の安定性や機能が変わる場合がある。

配列候補を作る → 発現・精製を確かめる → 構造を測る → 機能を調べる

参考

参考文献と再利用元

ProteinMPNN：Dauparas et al., Science (2022). https://doi.org/10.1126/science.add2187
RFdiffusion：Watson et al., Nature (2023). https://doi.org/10.1038/s41586-023-06415-8
AfDesign：Frank et al., Science (2024). https://doi.org/10.1126/science.adq1741