生命情報工学特論　第07回

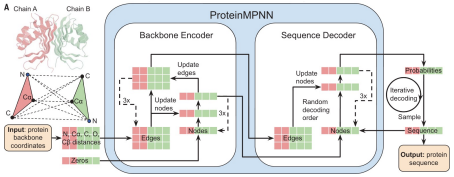
タンパク質設計

骨格を作り、配列を選び、
予測構造と比べる

松永 康佑

埼玉大学 大学院理工学研究科
理化学研究所 計算科学研究センター

2026年11月9日

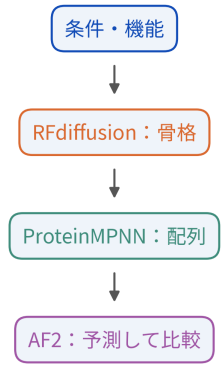


骨格 → 配列 → 予測構造
構造を条件に、配列を選ぶ。
元の骨格と再予測した形を比べる。

講義

目標の構造から配列を作り、予測構造と比べる

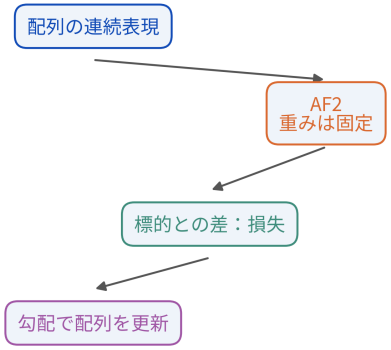
入力：目標となる骨格構造や、残したい機能部位。
出力：候補のアミノ酸配列と、その予測構造。
同じ骨格に合う配列は一つとは限らない。
構造の一致と、発現・安定性・機能を分けて評価する。



講義

骨格・配列・評価の役割を分けて学ぶ

1　予測と設計：入力と出力の違い
2　RFdiffusion：条件付きの骨格生成
3　ProteinMPNN：構造から配列の分布へ
4　AF2：設計配列を予測して比較
5　AfDesign：予測器を使う配列最適化
最後に固定骨格設計をColabで体験する。



背景

配列設計は構造が決まっている配列を探す逆折り畳み

順方向: 構造予測

配列 s から構造 x を予測する（AlphaFoldなどが扱う）

逆方向: 配列設計（逆折り畳み）

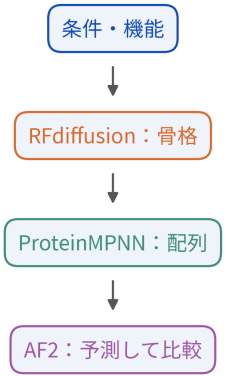
構造 x が先に決まっている。折りたたまれる配列は大勢ある

→ 条件付き確率 $P(s \mid x)$ を出す問題として解く

この論文が解くこと

主鎖構造 x が与えられたときの配列の条件付き確率を、PDBの天然構造から学ぶ

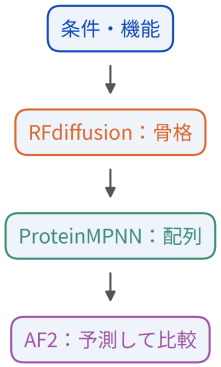
単量体・環状オリゴマー・ナノ粒子・結合界面の設計に同じモデルで対応する



講義

三つのモデルは、異なる条件付き問題を解く

RFdiffusion：長さ・モチーフ・対称性などの条件から、主鎖の形を作る。
ProteinMPNN：与えられた主鎖に合う配列をサンプルする。
AF2：候補配列から構造を予測して、最初の骨格との差を測る。
候補は各段階で複数残し、実験へ進めるものを絞る。



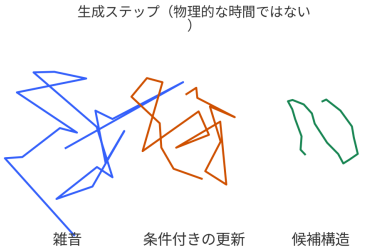
$$X \sim p_\theta(X \mid c), \quad s \sim p_\phi(s \mid X), \quad \hat{X} = f_{\mathrm{AF2}}(s)$$

AIで認識を予測し設計する

拡散モデルは雑音を段階的に減らす

学習では構造などへ雑音を加え、元へ近づける操作を覚えます。生成時は雑音のある状態から、条件に合う候補へ進めます。

この段階は実時間の分子運動とは異なります。生成ステップの動画を、その分子が溶液中で動く経路と解釈しません。



自作模式図（寸法・時間は実物と異なる）

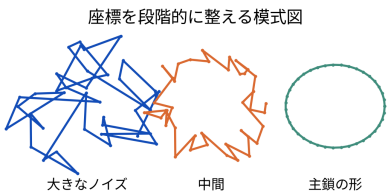
生成過程の時間と、物理的な時間を分ける。

[26] AlphaFold 3　[37] DiffAb

講義

RFdiffusionは主鎖の位置と向きを更新する

残基を、Cαの位置と局所座標系の向きで表す。
学習では既知の主鎖を段階的に乱し、元の配置を推定する。
生成では大きく乱れた配置から始め、同じ学習済みモデルで形を整える。
右は位置だけの模式図。実際には回転のノイズも扱う。折り畳みの物理時間ではない。

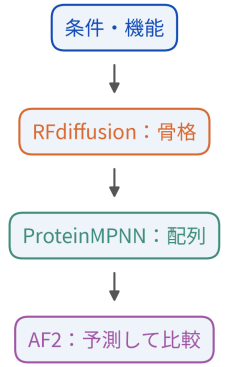


$$\text{residue } i: \ (\mathbf{t}_i, R_i), \quad \mathbf{t}_i \in \mathbb{R}^3, \ R_i \in SO(3)$$

講義

機能部位を残し、その周囲の骨格を生成する

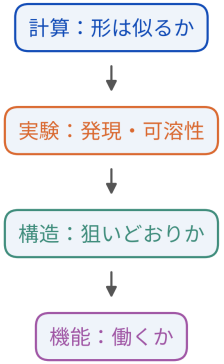
モチーフ：残したい局所構造。例えば触媒残基の配置や結合部位。
固定する部分と、生成する部分を入力で区別する。
結合相手を条件として、接触する新しい骨格を作ることもできる。
条件を満たす座標が出ても、配列が折り畳まれ、機能するとは限らない。



講義

生成した骨格を、配列と実験へつなぐ

RFdiffusionの出力だけでは、発現するタンパク質は決まらない。
一つの骨格につき複数の配列を設計し、再予測して形の再現性を見る。
実験では発現・可溶性、構造、結合や触媒機能を調べる。
計算での絞り込みと実験の成功率を区別する。



方法

ProteinMPNN の全体像

入力は主鎖の座標のみ。encoder（3 層・隠れ次元 128）で節点と枝の特徴を作り、decoder（3 層）がランダムなデコード順で配列を 1 残基ずつ出力する

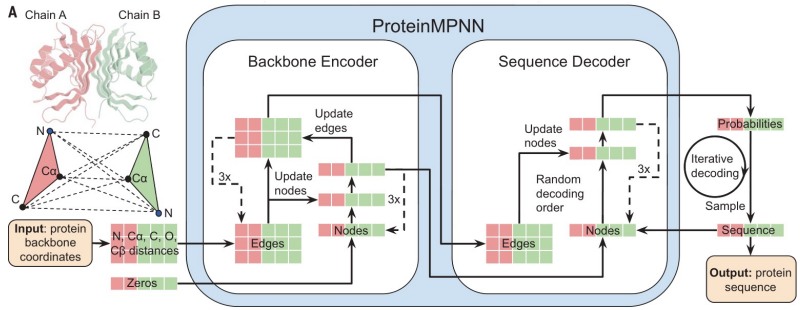


Fig. 1A より

補足

残基のグラフをメッセージパッシングで読む

メッセージパッシングの 1 層（Methods より整理）

$$M_{ij} = \mathrm{MLP}\left[V_i, V_j, E_{ij}\right]$$

$$\mathrm{d}V_i = \sum_{j \in N(i)} M_{ij}$$

$$V_i \leftarrow \mathrm{LayerNorm}\left[V_i + \mathrm{Dropout}(\mathrm{d}V_i)\right]$$

$$E_{ij} \leftarrow \mathrm{LayerNorm}\left[E_{ij} + \mathrm{MLP}[V_i, V_j, E_{ij}]\right]$$

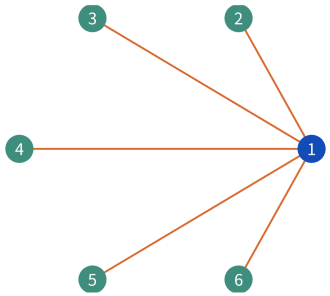
読み方

V_i: 残基 i の節点の状態、E_{ij}: 残基対の枝の状態

メッセージ M_{ij} を隣の残基 j の範囲で足して更新する

encoder は構造を特徴へ、decoder は配列を決め打ちながら出力する

層の直前の値 V_i を残して足す（residual 接続）



距離で近い残基から
メッセージを集める

方法

入力は主鎖5原子の距離、Cβは仮想で作る

仮想 Cβ の作り方（Methods より）

$$\mathbf{b} = \mathbf{C}_\alpha - \mathbf{N},\ \mathbf{c} = \mathbf{C} - \mathbf{C}_\alpha,\ \mathbf{a} = \mathbf{b} \times \mathbf{c}$$

$$\mathbf{C}_\beta = -0.5827\,\mathbf{a} + 0.5680\,\mathbf{b} - 0.5407\,\mathbf{c} + \mathbf{C}_\alpha$$

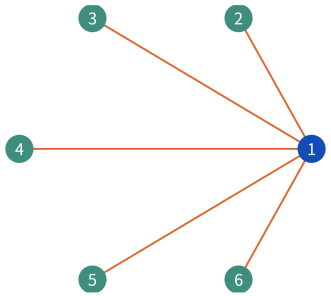
入力特徴

N, Cα, C, O, 仮想 Cβ の残基間距離。16 個のガウス基底関数でエンコード（Table 1 の実験 1）

二面角や座標系の向きより、距離のほうが残基間相互作用をよく表した

Table 1: 回収率 41.2 → 49.0%。パープレキシティ 6.51 → 5.03

ノイズあり学習では 40.1 → 46.1% と、利得は減る（後述）



距離で近い残基から
メッセージを集める

補足

配列は1か所ずつ順に決める自己回帰モデル

確率と学習の式

$$p(a_i \mid X) = \frac{\exp z_i(a)}{\sum_b \exp z_i(b)}$$

$$\mathcal{L} = -\frac{1}{T}\sum_{t=1}^{T} \log P\left(s_{o_t} \mid s_{o_1}, \ldots, s_{o_{t-1}}, X\right)$$

$$\mathrm{PPL} = \exp \mathcal{L}$$

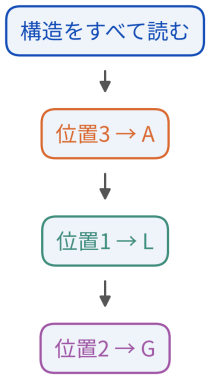
読み方

$z_i(a)$: 残基 i のアミノ酸 a のロジット（正規化前の得点）

正しい天然配列の対数確率を最大にする学習。負の平均が交差エントロピー ¥mathcal{L}

パープレキシティ: 絞り込みの実効的な候補数。1 に近いほど強い予測

Table 1 の「perplexity」はこの値（テスト集合での値）



方法

デコード順をランダムにすると固定領域を扱える

自己回帰の分解（デコード順 o はランダム）

$$P\left(s_{o_1}, \ldots, s_{o_T} \mid X\right) = \prod_{t=1}^{T} P\left(s_{o_t} \mid s_{o_1}, \ldots, s_{o_{t-1}}, X\right)$$

学習のたびに o を全順列からサンプル（Table 1 の実験 4）

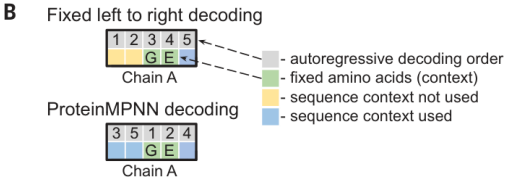


Fig. 1B より

左から右の固定順では、決め打ちの残基（緑）を文脈に使えない

ランダム順なら、結合相手の配列を先にデコードしておき、文脈として使える（結合設計に必須）

方法

位置の結合で対称性と多状態の設計ができる

結合した位置のグループ G ごとに平均

$$\bar{z}(a) = \frac{1}{n}\sum_{i \in G} z_i(a)$$

$$p(a) = \frac{\exp \bar{z}(a)}{\sum_b \exp \bar{z}(b)}$$

多状態設計: ¥bar{z} = ¥sum_k w_k z^(k)（w_k は正負あり）

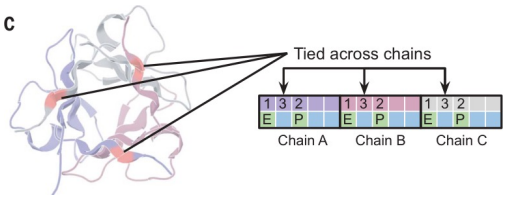


Fig. 1C より

ホモ三量体では 3 本の鎖の対応位置を結合。予測確率の平均から 1 残基をサンプル

リピートはユニット内の対応位置、対称体は鎖間の対応位置を結ぶ（Fig. 3 の実験で使う）

方法

学習データは PDB の25,361クラスタ

損失（Methods より）

$$\mathcal{L} = \frac{1}{2000}\sum_t \ell_t m_t$$

¥ell_t: 残基ごとの交差エントロピー、m_t: マスク

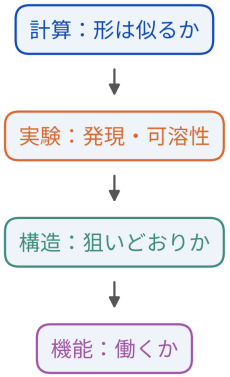
データと最適化

多量体: PDB 会合体（分解能 3.5 Å 以上、10,000 残基未満）。mmseqs2 で 30% 一致のクラスタ分割

訓練 23,358 / 検証 1,464 / テスト 1,539 クラスタ。同一配列は片方の集合にしか入らない

ラベルスムージング 10%、Adam（$\beta_2 = 0.98$）。A100 1 枚で混合精度

検証パープレキシティは約 15 万ステップ（約 100 エポック）で収束（Fig. S3D）



方法

主鎖に小さなノイズを加えて学習すると強くなる

学習時のノイズ

$\tilde{X} = X + \varepsilon,\ \varepsilon \sim \mathcal{N}(0, \sigma^2 I)$

$\sigma = 0.02$ ¥AA

なぜ効くか

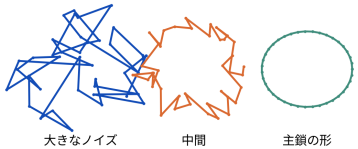
結晶構造は精製によって配列の記憶を座標にわずかに残す。ノイズがそれを消す

きれいな PDB 主鎖では回収率が下がる（41.2→40.1 など）が、現実の主鎖では上がる

ノイズの大きさごとの 16 種モデルが公開されている。入力主鎖の質に合わせて選ぶ

ノイズを大きくすると AlphaFold での折りたたみ成功率が上がる（Fig. 2C で後述）

座標を段階的に整える模式図



結果

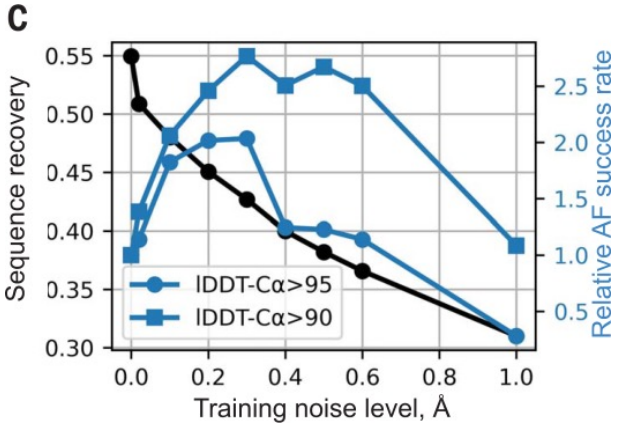
ノイズ付き学習はAlphaFoldの成功率を上げる

黒: 回収率（ノイズで下がる）

青: AF 成功率（ノイズで上がる）

0.3 Å ノイズで 2–3 倍の配列が高精度予測に

出典: Fig. 2C



結果

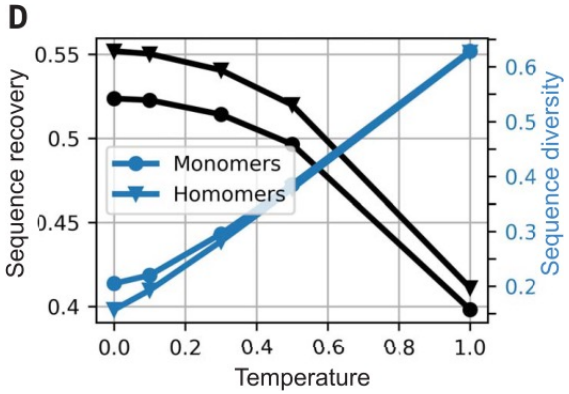
温度を上げると多様性が増え回収率は下がる

温度つきソフトマックス（補足より）

$$p(a \mid X) = \frac{\exp(z(a)/T)}{\sum_b \exp(z_b/T)}$$

学習時は T=1。推論時に動かす

出典: Fig. 2D



結果

回収率はconfidenceと構造の質で決まる

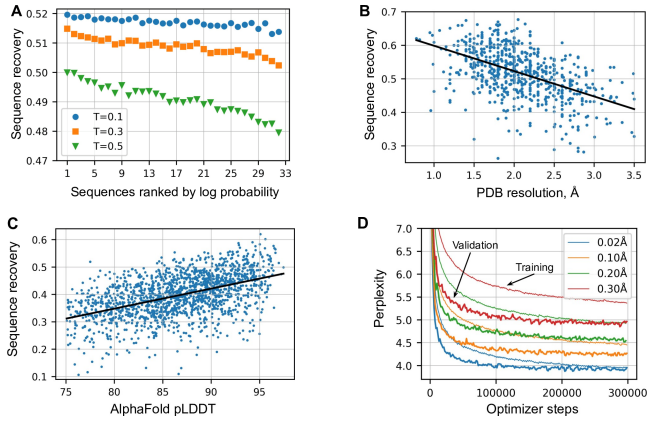
A: 対数確率でランキングできる

B: 分解能が荒いと回収率が下がる

C: pLDDT とも相関

D: ノイズ大は検証 PPL を上げる

出典: Fig. S3 A–D



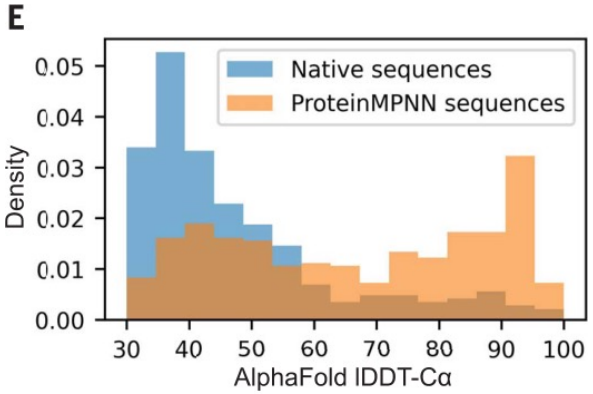
結果

設計配列は天然配列よりAlphaFoldで折れる

天然骨格の再設計配列のほうが AF の単一配列予測が当たる
進化は安定性を最適化しないため

組換え発現・安定化への応用を示唆

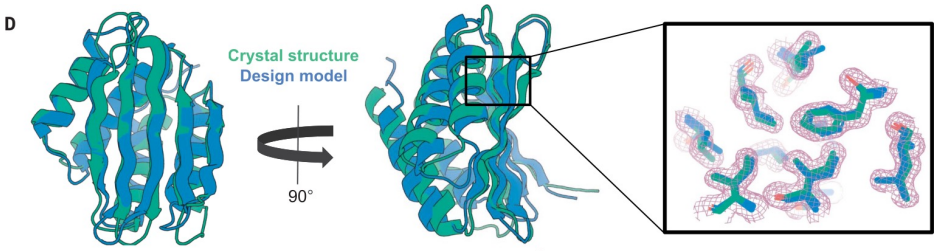
出典: Fig. 2E



実験

結晶構造は設計モデルと2.35Å一致

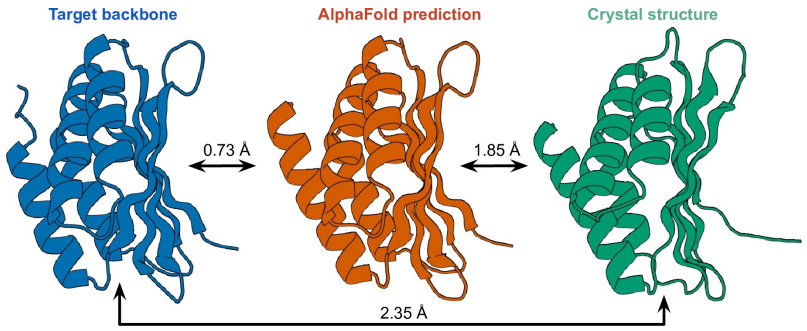
幻覚法設計 HALC1_878（PDB ID: 8CYK）。Cα 2.35 Å RMSD（130 残基）。TM スコア 0.56。コア側鎖は電子密度に一致（Fig. 3D、fig. S5）



実験

設計・予測・結晶の3者はほぼ同じ形

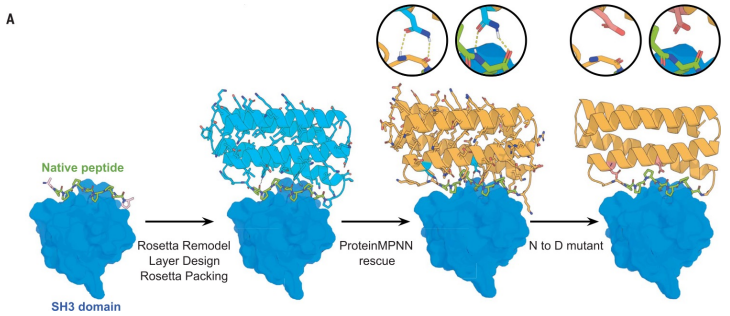
RMSD: 設計モデル対 AF 予測 0.73 Å、設計対結晶 1.35 Å、予測対結晶 1.65 Å（Fig. S5）



実験

SH3結合タンパクはmotif固定で設計

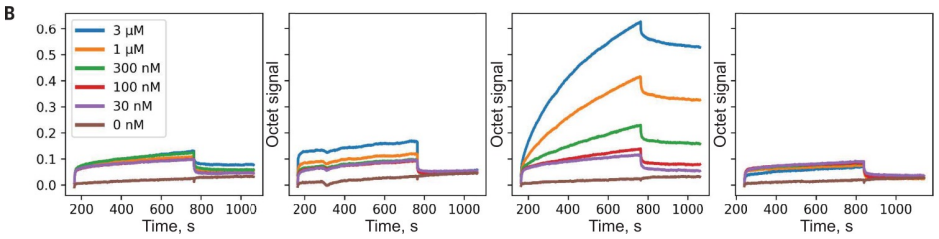
Gab2 ペプチド（モチーフ PPPRPPK は緑）を RIFDOCK＋Rosetta remodel で足場に載せ、MPNN で足場側のみ再設計。N は足場の水素結合を担い、N→D 変異で破綻するよう設計（Fig. 4A）



実験

結合は実測され、変異で消える

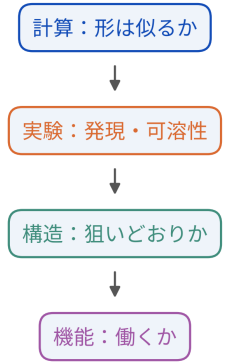
生物層干渉法（BLI）。ペプチド / 元の Rosetta 設計 / MPNN 設計 / N→D 変異体の順。MPNN 設計が最も強く結合し、変異でシグナル消失（Fig. 4B）



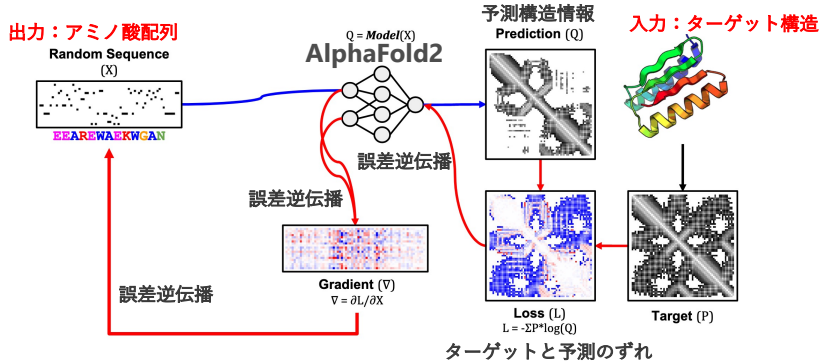
講義

天然配列の回収率と、設計成功は違う

回収率は、既知構造から天然と同じ残基を何割選べたか。
配列の条件付き確率が高いことは、熱力学的な安定性そのものではない。
別の配列でも同じ構造へ折り畳まれるなら、設計として成功しうる。
構造の一致、発現、機能という別の観測を組み合わせる。



ColabDesign　AlphaFold 2による予測構造のずれを逆伝播させて配列を探索

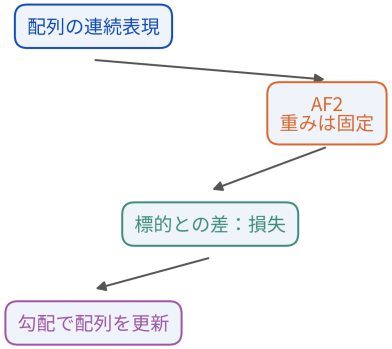


C. Frank et al., Scalable protein design using optimization in a relaxed sequence space, Science **386**, 439 (2024).
S. Ovchinnikov, https://github.com/sokrypton/ColabDesign

講義

AfDesignは、AF2を微分して配列へ戻る

AF2の重みを固定し、入力する配列側を変える。
目標の構造と予測との差を損失にし、配列の連続表現に対する勾配を計算する。
ProteinMPNNのように配列の条件付き分布を学習し直す手順ではない。
固定骨格設計では、目標骨格を損失の参照に使う。

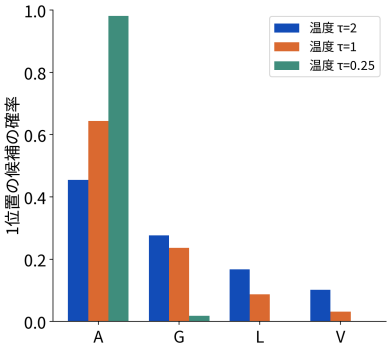


$$z \leftarrow z - \eta \nabla_z \mathcal{L}(f_{\mathrm{AF2}}(p(z)), X^*)$$

講義

離散的なアミノ酸を、連続表現から選ぶ

各位置に20種類の得点（ロジット）を置く。
softmaxで重みへ変換すれば、配列入力を連続的に変えられる。
温度を下げると一つの候補へ集中し、最後に離散的な配列へ移す。
右は4種類に減らした説明用の計算。実際は20種類。

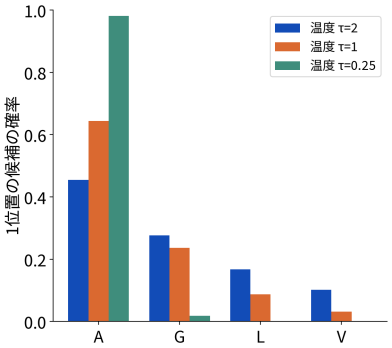


$$p_i(a) = \frac{\exp(z_i(a)/\tau)}{\sum_b \exp(z_i(b)/\tau)}$$

講義

三段階で、配列を離散的な候補へ近づける

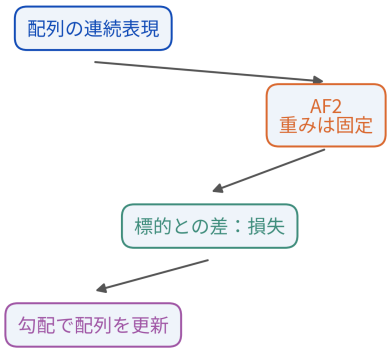
soft：連続的な入力を動かして形を探す。
temp：softmaxの温度を下げ、候補を絞る。
hard：離散的な配列を使う段階へ進む。
短い演習設定は動作を見るためのもの。十分な最適化や実験成功を保証しない。



講義

構造への適合と、予測の信頼度を分ける

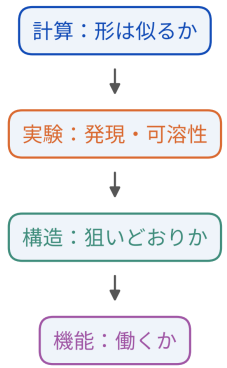
固定骨格設計では、目標構造との距離分布の差などを減らす。
pLDDTなどの信頼度を損失へ加える場合もある。
RMSDは目標との座標の差、pLDDTは予測器自身の信頼度。値の意味も単位も違う。
重みや反復数は記録し、条件の違う実行を混ぜて比較しない。



講義

設計に使った予測器だけでは独立な検証にならない

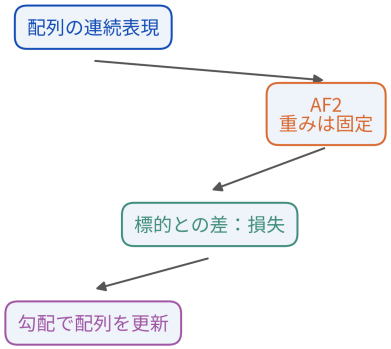
AfDesignでAF2へ適合させた配列を、同じAF2で評価すると循環する。
高い信頼度でも、予測器の弱点を利用した配列が残る場合がある。
別のモデル・異なる条件での再予測は補助になるが、実験とは異なる。
発現・構造・機能を測る検証へつなげる。



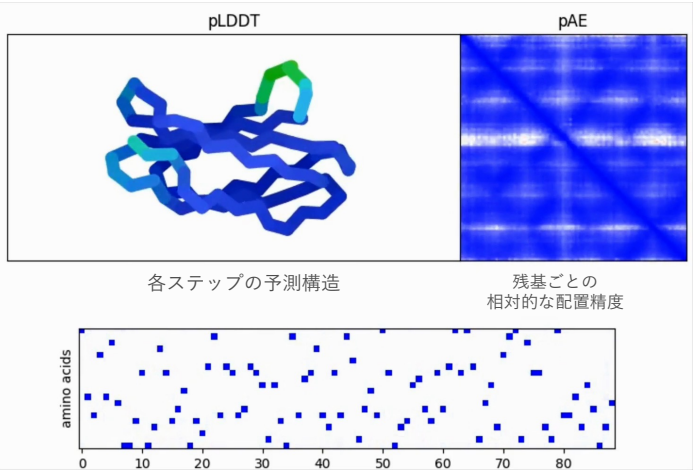
講義

固定骨格設計の対象：1TENの鎖A

1TENはテネイシンのフィブロネクチンIII型ドメイン。
公式AfDesignの固定骨格設計例を再利用する。
入力：PDB 1TENの鎖A。
出力：設計配列、予測PDB、損失の推移。
標的の原子が登録されている残基を対象とし、番号と長さを確認する。



ColabDesignの動作例

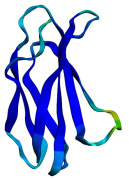


アミノ酸配列の予測の推移

ターゲット構造 (PDB ID: 1TEN)



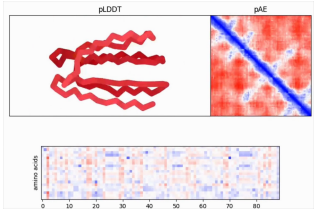
リデザイン構造



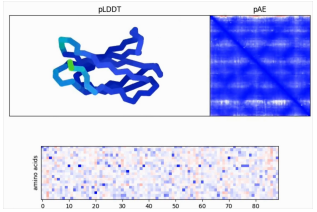
配列設計の推移

予測構造を繰り返し比べて、配列を更新する

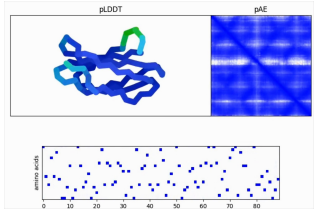
初期



中間



終盤



原資料の最適化動画から3時点を抜粋。物理時間に沿った折り畳みの動画ではない。

ColabDesignの動作例

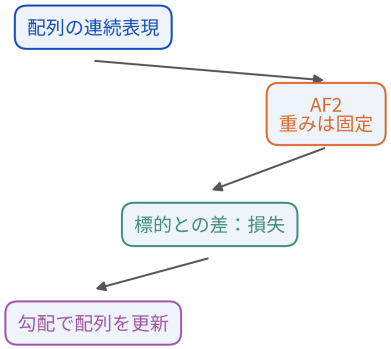
> 天然配列 (PDB ID: 1TEN)
RLDAPSQIEVKDVTDTTALITWFKPLAEIDGIELTYGIKDVPGDRTTIDLTEDENQ
YSIGNLKPDTEYEVSLISRRGDMSSNPAKETFTT

> リデザイン配列
AKPCKNMVVSGVTDGSFLVSWERPEGPFEGIYISVRPHGDPTGPRQYFLPAGVTSI
HFSGFEAGAEYMITCRAYNGGTYAPPKTIFVTM

演習

演習：固定骨格設計をColabで動かす

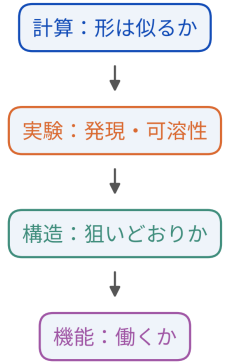
T4 GPUを選び、準備 → 入力確認 → 設計 → 観察の順に実行する。
演習20分を目安。初回の重み取得とGPU待ち時間は別に変動する。
損失の変化、得られた配列、標的と予測構造の重ね合わせを確認する。
採点・提出なし。長い実行は途中経過を保存する。



演習

結果は、配列・構造・条件を一緒に残す

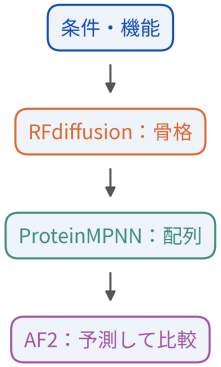
設計配列だけでなく、標的のPDBと鎖、乱数seed、反復数、損失の重みを残す。
RMSDは同じ残基・同じ原子の対応で、重ね合わせ後に計算する。
pLDDTが高いのに形が異なる場合もあるため、立体表示を併用する。
この演習の結果を、実験で機能を確認した設計とは扱わない。



まとめ

骨格を作る・配列を選ぶ・確かめる

RFdiffusionは条件から骨格候補を作る。
ProteinMPNNは骨格を条件に配列を選ぶ。
AF2で再予測し、骨格との一致と信頼度を見る。
AfDesignは予測器を通して配列を最適化する別の方法。
冒頭の目標は「候補を作って比較する」こと。実際の構造と機能は実験で確かめる。



付録

付録：配列設計の式と実験評価

ここからは独習用の補足です。
本編で使った式の導出や、手法の条件を確認します。
必要な項目から参照してください。

背景

Rosetta との違い: 最適化から学習へ

Rosetta: エネルギー最適化

側鎖回転体の詰め込みでエネルギー最小の配列を探す

低エネルギー状態が目的構造になる保証は直接は最適化できない

表面の疎水制限など人手の調整が必要で、設計が失敗することもあった

深層学習: PDB の例から条件付き確率を学ぶ

「主鎖の局所的な形」から「どの残基が自然か」を学習する

100 残基で Rosetta の約 200 分の 1 の時間（1.2 秒対 258.8 秒）

透明性は Rosetta に劣るが、調整が不要で頑健。本論文は実験まで検証した

補足

主な記号の一覧

記号	意味
X	主鎖構造（N, Cα, C, O の座標。仮想 Cβ を含む）
s_i	残基 i のアミノ酸の種類
o	デコード順（残基の並べ方の順列）
$z_i(a)$	残基 i のアミノ酸 a のロジット
T	サンプリング温度（学習時は 1）
σ	主鎖座標に加えるガウスノイズの標準偏差
PPL	パープレキシティ（交差エントロピーの指数）
lDDT-Cα / pLDDT	構造予測の正しさの指標 / その AlphaFold による予測値

方法

近傍数・埋まり・平均方法の検証

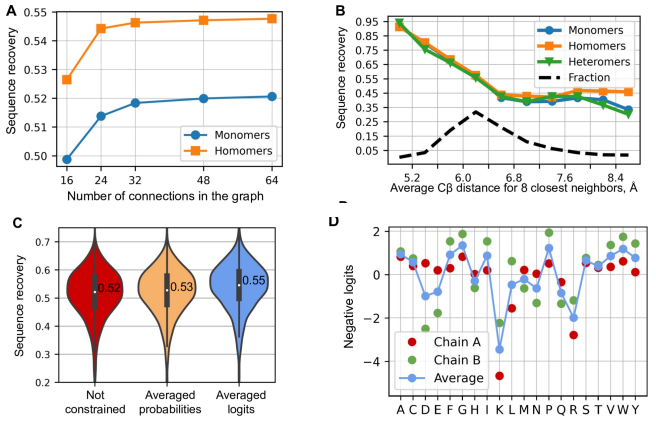
A: 近傍数は 32–48 で飽和

B: コアほど回収率が高い

C: 対応位置は確率の平均が最良

D: 鎖 A と B のロジットとその平均

出典: Fig. S1 A–D



方法

改良の積み重ねで回収率41.2→50.8%

モデル	改良	パラメータ (M)	PDB 回収率 (%)	PDB PPL	AF 回収率 (%)
Baseline	なし	1.381	41.2 / 40.1	6.51 / 6.77	41.4 / 41.4
Exp 1	N, Cα, C, Cβ, O 距離	1.430	49.0 / 46.1	5.03 / 5.54	45.7 / 47.4
Exp 2	encoder の枝を更新	1.629	43.1 / 42.0	6.12 / 6.37	43.3 / 43.0
Exp 3	1 と 2 を結合	1.678	50.5 / 47.3	4.82 / 5.36	46.3 / 47.9
Exp 4	3 ＋ ランダムデコード	1.678	50.8 / 47.9	4.74 / 5.25	46.9 / 48.5

値は「ノイズなし学習 / ノイズ 0.02 Å 学習」。テスト集合の値。Table 1 より

結果

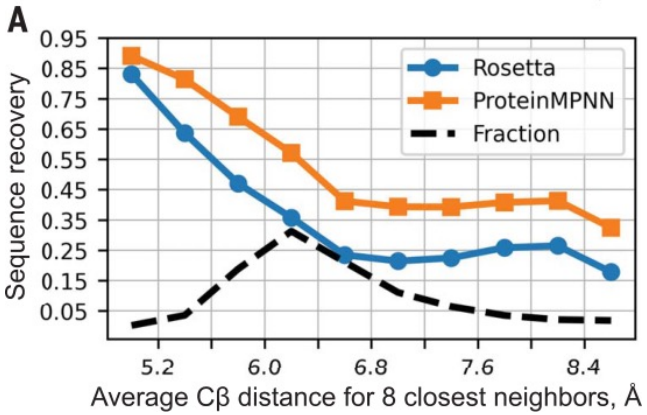
Rosetta より回収率が19.5ポイント高い

平均回収率 52.4% 対 32.9%

計算時間 1.2 秒対 258.8 秒（100 残基）

埋まりの全範囲で ProteinMPNN が上回る

出典: Fig. 2A



結果

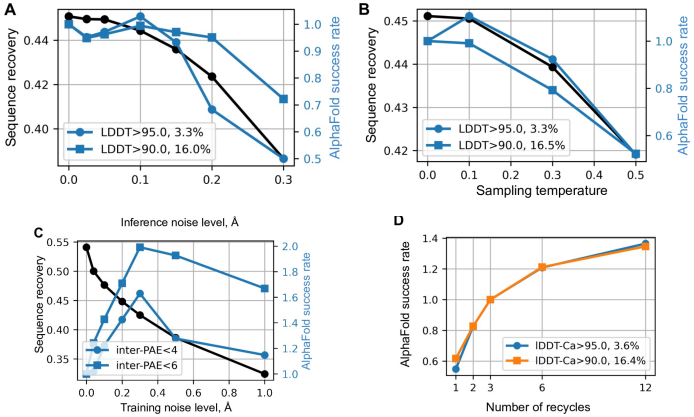
0.2Åモデルの条件別のベンチマーク

A 推論時ノイズ / B 温度 / C ホモの PAE / D recycles

0.2 Å 学習モデル。どの条件も増やすと成功率は下がる

recycles 増で成功率は単調に上がる → 配列は構造を正しく符号化

出典: Fig. S7 A–D



結果

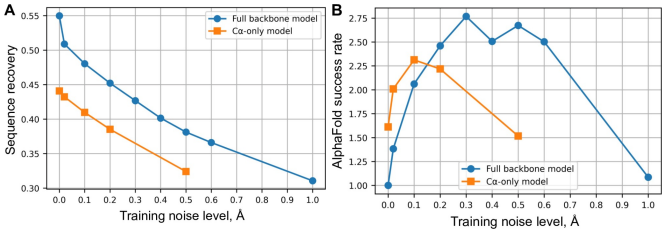
粗い主鎖向けにCαだけのモデルもある

Cα 3 点の距離を入力にした版

回収率はフル原子版より 2–3 ポイント低い

AF 成功率はノイズで上がる（フル原子と同じ傾向）

出典: Fig. S9 A, B



粗いモデルやモデル予測の主鎖に配列を載せるときに使う。公開コードに同梱

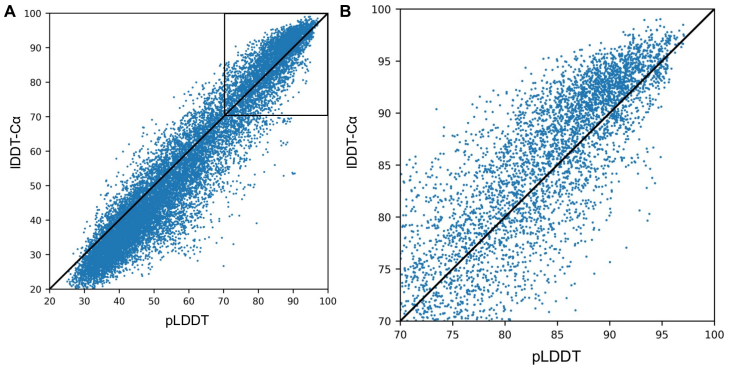
結果

pLDDTは真のlDDTをわずかに過小評価

単一配列でも pLDDT と真の lDDT は強く相関

pLDDT はわずかに過小評価（B）

出典: Fig. S8 A, B

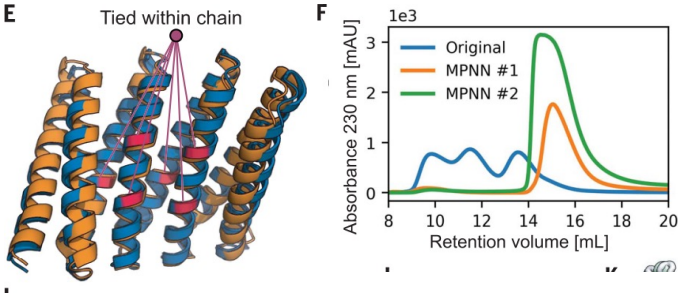


実験

リピートは対応位置を結ぶと救える

E: 設計モデル（橙）と rescue の AF 予測（青）。対応位置は線で結ぶ
232 残基で約 1.2 Å

出典: Fig. 3E, F



考察

最適化ではなく条件付き確率として解く

枠組みの違い

Rosetta:「他の構造に低くならない」を直接は最適化できない → 人手の調整

ProteinMPNN: PDB 全例から主鎖→配列の確率を直接学習 → 調整が不要

物理的な透明性は Rosetta に劣る

限界と注意

天然回収率は分解能に敏感で、折りたたみの成功を保証しない

翻訳の正確さが最終的に人に評価されるのと同じく、設計は実験で検証する

1 残基の置換でも折りたたみを止めることはある

参考

参考文献と再利用元

ProteinMPNN：Dauparas et al., Science (2022). https://doi.org/10.1126/science.add2187
RFdiffusion：Watson et al., Nature (2023). https://doi.org/10.1038/s41586-023-06415-8
AfDesign：Frank et al., Science (2024). https://doi.org/10.1126/science.adq1741