生命情報工学特論　第10回

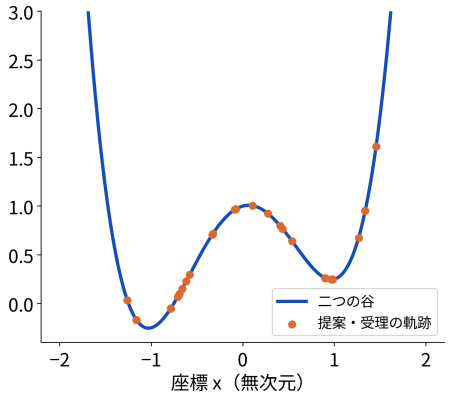
構造の分布を計算する

Metropolis法で
ボルツマン分布をサンプリングする

松永 康佑

埼玉大学 大学院理工学研究科
理化学研究所 計算科学研究センター

2026年12月5日（オンデマンド）



講義

提案と受理を繰り返し、構造の現れやすさを調べる

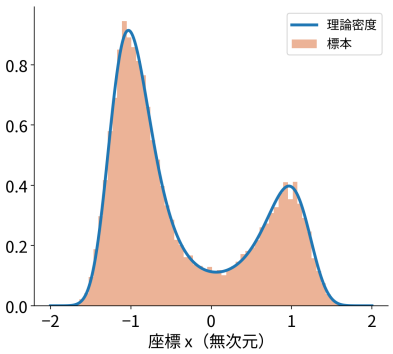
入力：エネルギー関数と温度。
目標：サンプリングで構造を集め、その温度での平均や構造群の確率を推定する。
エネルギーの最小値だけを探す計算ではない。
提案と受理で目標分布を保つ更新則を作り、有限の計算で十分に標本を集められたかを確かめる。

現在 x から候補 y
↓
エネルギー差を計算
↓
乱数と受理確率を比較
↓
受理：y／棄却：x を記録

講義

更新則から分布と誤差までをつなぐ

1　期待値とサンプリング
2　Metropolis法の提案・受理・棄却
3　詳細釣り合いと定常分布
4　移動幅、相関、有限標本の誤差
最後に二つの谷の模型をColabで動かす。



温度一定の平衡状態では、構造はボルツマン分布に従う

ボルツマン分布 (Boltzmann Distribution)

$$p(\boldsymbol{x}) = \frac{e^{-\frac{U(\boldsymbol{x})}{k_B T}}}{\int e^{-\frac{U(\boldsymbol{x})}{k_B T}} d\boldsymbol{x}} = \frac{e^{-\beta U(\boldsymbol{x})}}{Z}$$

- $\boldsymbol{x}$ は全ての原子の構造を表すベクトル
  $\boldsymbol{x} = (x_1, y_1, z_1, \ldots, x_n, y_n, z_n)$
- $U(\boldsymbol{x})$はポテンシャルエネルギー
- Tは温度
- k_Bはボルツマン定数
- $\beta = (k_B T)^{-1}$は逆温度
- Zは分配関数

連続な座標xでは、p(x)は確率密度を表す。
同じ微小体積で比べると、Uが高い配置ほど現れにくい。
温度が上がると、高いUの配置との相対的な確率密度の差が小さくなる。

シミュレーションから、観測量の期待値を求める

システムのポテンシャルエネルギーを $U(x)$ とする。
ここで x は全原子のデカルト座標。

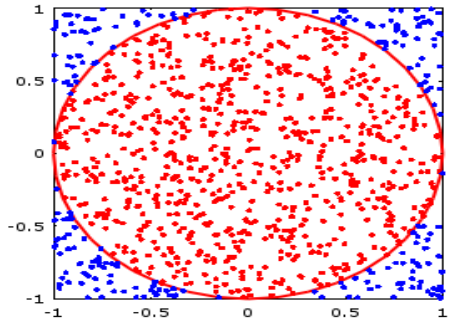
$A(x)$を 座標 x に依存する物理量とすると、シミュレーションでは$A(x)$の期待値を求めたいことが多い。

$$\langle A(\boldsymbol{x})\rangle = \int A(\boldsymbol{x})P(\boldsymbol{x})d\boldsymbol{x} = \frac{\int A(\boldsymbol{x})e^{-\beta U(\boldsymbol{x})}\,d\boldsymbol{x}}{Z}$$

例えば、対応するタンパク質原子を重ね合わせて並進・回転を除き、
座標を平均すれば平均構造を得る。複数の大きく異なる構造を
平均した座標が、実在する構造を表すとは限らない。

モンテカルロ法

乱数を用いて、統計量を計算する手法の総称



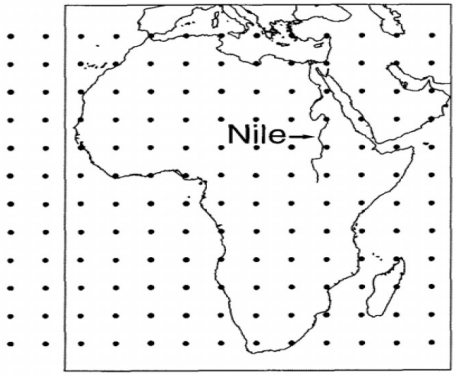
円周率の計算 (求積法)の例

- 正方形の面積 4 と単位円の面積 $V=\pi$ の比は $V/4=\pi/4$
- 一様乱数が単位円の中をヒットする比率がそれと同じとして、円周率πを計算
  π/4= ヒットした点(赤点)/全ての点

http://labs.timedia.co.jp/2016/09/octave.html

広い領域から一様に点を選ぶと、狭い川を捉えにくい

ナイル川の平均水深を求める例。アフリカ大陸全体から点を一様に選ぶと、
川に入る点が少ない。対象の領域を重点的に調べる必要がある。



Frenkel & Schmit, "Understanding Molecular Simulation"

高次元の構造空間を、
二次元の領域にたとえる



図 16　変な形

伊庭幸人, 種村正美 他, 計算統計 2 マルコフ連鎖モンテカルロ法とその周辺 (統計科学のフロンティア 12) 岩波書店 (2005)

サンプリング

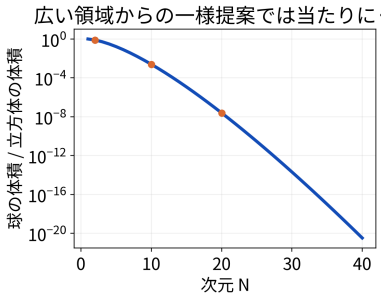
次元が高いほど、球に入る一様乱数の割合は小さい

半径1のN次元球を、一辺2の立方体で囲む。
立方体から一様に点を選ぶと、球に入る確率は体積比になる。

$$V_{\text{cube}} = 2^N, \qquad V_{\text{ball}} = \frac{\pi^{N/2}}{\Gamma(N/2+1)}$$

$$\frac{V_{\text{ball}}}{V_{\text{cube}}} = \frac{\pi^{N/2}}{2^N \Gamma(N/2+1)}$$

Γはガンマ関数。偶数NではΓ(N/2+1)=(N/2)!。
N=10で約0.00249、N=20で約2.46×10⁻⁸。

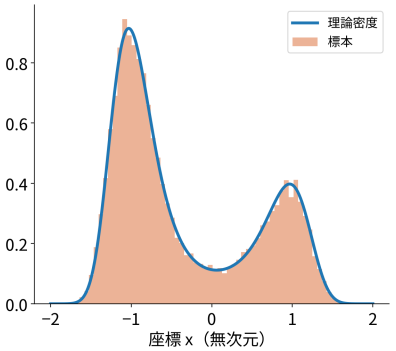


高次元では、重要な領域をほとんど訪れない一様サンプリングになりうる。
ボルツマン密度 π(x) ∝ exp[−βU(x)] に沿って構造を訪れる規則を考える。

講義

標本平均で、分布に対する積分を近似する

すべての座標の組を細かい格子で足し合わせる代わりに、目標分布から標本を取る。
よく現れる構造が多く含まれるため、観測量の平均を標本の平均で近似できる。
どの分布から標本を取ったかが重要。構造をランダムに並べるだけではよくない。



$$\langle A \rangle = \int A(x)\pi(x)\,dx \simeq \frac{1}{N}\sum_{t=1}^{N} A(x_t)$$

サンプリングとマルコフ連鎖

乱数から連鎖へ：次の状態の作り方

Monte Carloは、乱数を使って計算する方法の総称

一様乱数から直接作れる分布もあるが、生体分子のBoltzmann分布から独立な構造を直接引くのは難しい。

そこで今の状態から次の状態を作る規則を設計し、連鎖をたどって必要な標本を得る。

マルコフ連鎖Monte Carlo、略してMCMCは、このように分布を保つ連鎖を用いる汎用的な方法。物理以外の確率モデルにも使える。

$$x_0 \longrightarrow x_1 \longrightarrow \cdots \longrightarrow x_M$$

連鎖の隣接標本は一般に相関する。標本数Mと、独立な情報の個数は同じではない。

条件付き確率は、今の状態を知ったうえでの次の確率

$$P(X_{n+1} = j \mid X_n = i) = T_{ij}$$

縦線の右側は条件。T_{ij}は、今iにいるとき次にjへ移る確率。各iについて行の合計は1になる。

$$\sum_j T_{ij} = 1$$

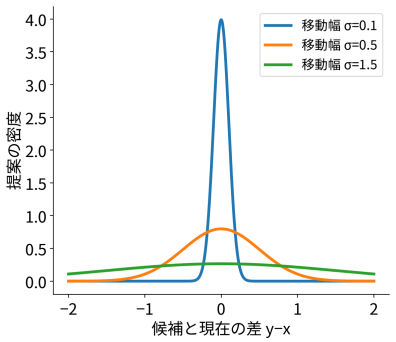
次の分布が、過去の履歴全体ではなく今の状態だけで決まる規則をマルコフ性と呼ぶ。状態の定義に必要な変数を含めることが前提。

原著：Metropolis et al. (1953), Hastings (1970)（付録末に書誌・リンク）

講義

現在の状態から、次の候補を作る

マルコフ連鎖では、次の状態の分布を現在の状態から決める。
例：現在値に平均0の正規乱数を加えて候補yを作る。
右は変位y−xの分布で、中心は0。幅が大きいほど遠い候補を出しやすい。
対称な提案ではq(y|x)=q(x|y)。これは後の式の簡約に使う。

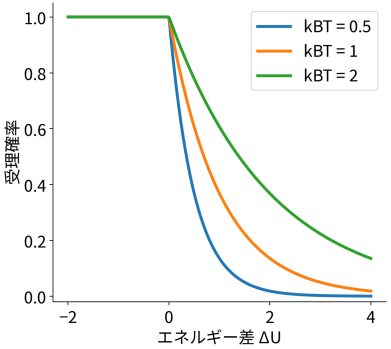


$$y = x + \sigma\xi, \quad \xi \sim \mathcal{N}(0,1)$$

講義

低エネルギーへの移動は、必ず受理する

対称な提案のMetropolis法では、ΔU≤0なら受理確率1。
高エネルギー側への移動も、指数関数で決まる確率で受理する。
高い位置を一切認めないと、エネルギー最小化になり、有限温度の分布を作れない。
右では同じエネルギー差に対する温度の効果を比較する。

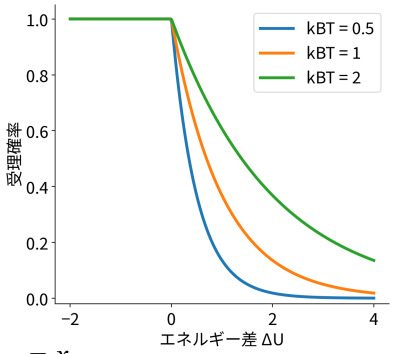


$$\alpha(x, y) = \min\{1, \exp[-(U(y) - U(x))/(k_B T)]\}$$

講義

乱数を使って、一回の受理判定を行う

例：ΔU=2、kBT=1なら受理確率は$e^{-2} \approx 0.135$。
一様乱数u=0.08なら受理し、u=0.40なら棄却する。
0.135の重みで中間へ動かすのではなく、候補へ移るか、その場に残るかを決める。
同じ差でも乱数が違えば結果は変わる。

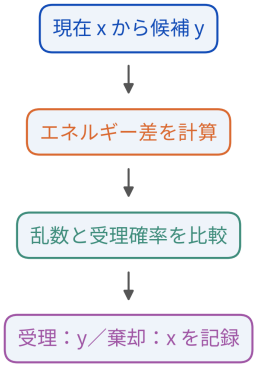


$$u \sim U(0,1), \quad u < \alpha \Rightarrow x_{t+1} = y; \quad \text{otherwise } x_{t+1} = x_t$$

講義

棄却したときも、現在の状態を記録する

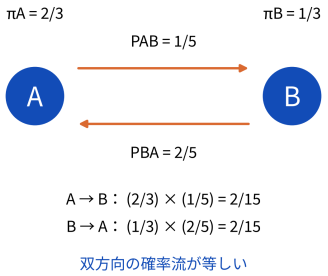
棄却は計算の失敗ではなく、遷移規則の一部。
その場にとどまった回数が、状態の確率へ反映される。
受理した候補だけを保存すると、動きやすい状態を過大に数えることがある。
右の流れを毎ステップ実行し、必ず一つの状態を追加する。



講義

二状態の流れが釣り合えば、確率は変わらない

Aの確率2/3、Bの確率1/3を考える。
A→Bを1/5、B→Aを2/5にすると、双方向の流れはどちらも2/15。
Aに残る確率は4/5、Bに残る確率は3/5。
一方向の移動確率が等しい必要はない。状態の確率を掛けた流れを比べる。



$$\pi_A P_{AB} = \pi_B P_{BA}$$

遷移行列から定常分布を求める

二状態の遷移を、数の表で読む

$$T = \begin{pmatrix} 0.8 & 0.2 \\ 0.4 & 0.6 \end{pmatrix}$$

行は現在A・B、列は次のA・B。Aからは0.2でBへ進み、0.8でAに残る。Bからは0.4でAへ進む。

今の確率をp=(1,0)とすれば、次は(0.8,0.2)。さらに次はAが0.8×0.8+0.2×0.4=0.72になる。

$$p_j^{\text{new}} = \sum_i p_i T_{ij}$$

定常分布は、更新しても変わらない分布

$$\pi_j = \sum_i \pi_i T_{ij}$$

二状態では$\pi_A \times 0.2 = \pi_B \times 0.4$と$\pi_A + \pi_B = 1$を解く。

$$\pi_A = 2/3, \qquad \pi_B = 1/3$$

一つの連鎖の状態はAとBを動く。それでも、十分多数の連鎖を集めた分布は変わらない、という意味。

いつもA↔Bを交互に移るだけの連鎖などでは、初期分布からの収束を別に検討する必要がある。

原著：Metropolis et al. (1953), Hastings (1970)（付録末に書誌・リンク）

詳細釣り合いから定常性が従う理由

詳細釣り合いは、各対の流れを等しくする条件

$$\pi_i T_{ij} = \pi_j T_{ji}$$

iからjへの確率流と、jからiへの確率流を等しくする。両辺をiについて足すと、

$$\sum_i \pi_i T_{ij} = \pi_j \sum_i T_{ji} = \pi_j$$

右の和はjからどこかへ移る確率の合計なので1。したがって詳細釣り合いは定常性の十分条件。

定常性に必須の条件ではない。循環する確率流を持ちながら分布を保つ方法もある。

$$\sum_x \pi(x) T(x,y) = \sum_x \pi(y) T(y,x) = \pi(y)$$

最後の等号では、状態yからの遷移確率の総和が1であることを使う。

目標分布へ収束するには、行き来できることも必要

ある領域へ絶対に移れない提案では、その領域の確率を正しく推定できない。状態空間がつながることが必要。

毎回A→B→Aと決まっている場合、分布が周期的に動く。自己遷移を許すことは、周期性を避ける一つの方法。

有限状態では、既約性（全状態へ到達できる）と非周期性の条件下で、一意な定常分布へ近づく。連続空間でも対応する到達・再帰条件が必要。

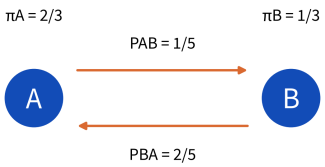
数学的に到達可能でも、その時間が極端に長ければ有限計算では役に立たない。

原著：Metropolis et al. (1953), Hastings (1970)（付録末に書誌・リンク）

講義

詳細釣り合いは、定常性を作る十分条件

すべての状態対で双方向の確率流が等しければ、各状態へ流入する総量と流出する総量が等しい。
したがって目標分布から一度更新しても、分布は変わらない。
ただし、任意の初期値から到達できることや、実用時間で混ざることは別に確かめる。



A → B： (2/3) × (1/5) = 2/15
B → A： (1/3) × (2/5) = 2/15

双方向の確率流が等しい

$$\sum_x \pi(x) P(x,y) = \sum_x \pi(y) P(y,x) = \pi(y)$$

Metropolis–Hastingsの受理式を導く

提案する規則と、受理する規則を分ける

$$T(x \to y) = q(y \mid x)\, a(x \to y) \qquad (y \neq x)$$

qは候補yを提案する確率密度、aは受理する確率。受理しなかった確率は、今の状態xへ残る部分に入る。

候補を作る方法に自由を持たせ、後から受理率を調整して目標分布を保つ。

提案の左右対称性は必ずしも成立しない。端で切った提案や、状態に依存する候補数には注意する。

Metropolis–Hastingsの受理率を導く

$$\pi(x) q(y \mid x) a(x \to y) = \pi(y) q(x \mid y) a(y \to x)$$

$$R = \frac{\pi(y) q(x \mid y)}{\pi(x) q(y \mid x)}, \qquad a(x \to y) = \min(1, R)$$

R<1なら前向きをR、逆向きを1とすることで流れが等しくなる。R>1なら逆の関係になる。

どちら向きにも提案できる範囲で使う。逆向きの提案が不可能なら、その一方向の移動をこの規則では受理できない。

$$\frac{a(x,y)}{a(y,x)} = R$$

R≤1ではa(x,y)=R、a(y,x)=1。R≥1では逆。両場合とも詳細釣り合いを満たす。

原著：Metropolis et al. (1953), Hastings (1970)（付録末に書誌・リンク）

サンプリングとマルコフ連鎖

Boltzmann分布へ代入すると何が消えるか

未知の正規化定数が、確率比で消える

$$\pi(x) = \tilde{\pi}(x)/Z \quad \Rightarrow \quad \frac{\pi(y)}{\pi(x)} = \frac{\tilde{\pi}(y)}{\tilde{\pi}(x)}$$

全状態を積分したZを知らなくても、二つの状態の重みだけ評価できれば受理できる。これが高次元の問題で役立つ。

分子なら重みはexp(−βU)。統計モデルなら、データへの適合と事前の知識を掛けた重みでもよい。

MCMCは特定の分子の運動方程式に限られない。何の分布を作るかを先に定義する道具。

対称な提案では、エネルギー差だけで受理できる

$$q(y \mid x) = q(x \mid y), \qquad \pi(x) \propto e^{-\beta U(x)}$$

$$a = \min[1, e^{-\beta(U(y)-U(x))}]$$

エネルギーが下がる候補は採り、上がる候補も必要な確率で採る。すべて下りだけにすると最小化に近く、熱平衡の分布にならない。

例：βΔU=1なら受理率exp(−1)≈0.368。一様乱数0.2なら採り、0.7なら棄却する。

原著：Metropolis et al. (1953), Hastings (1970)（付録末に書誌・リンク）

サンプリングとマルコフ連鎖

提案の偏りと、棄却の滞在時間を数える

非対称提案では、提案の偏りを補正する

二状態の目標確率π_A=π_B=1/2とする。A→Bの候補を0.8、B→Aの候補を0.2で提案する。

$$R_{A\to B} = 0.2/0.8 = 1/4$$

A→Bの受理率は1/4、逆向きは1。実際の遷移確率は両方向とも0.2になる。

重みが同じだから両方必ず採る、ではAとBの滞在割合が偏る。提案確率の比を受理率に含めて補正する。

棄却した状態も、必ず標本として数える

AからBを毎回候補にし、A→Bの受理率1/3、B→Aの受理率1とする。目標はA:B=3:1。

受理だけを保存するとA,B,A,Bと交互になり、誤って1:1に見える。棄却したA,A,…の滞在も必要。

$$\overline{A} = \frac{1}{M}\sum_{n=1}^{M} A(x_n)$$

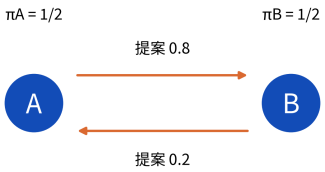
nは成功した移動の番号ではなく、提案を一回試みた番号。繰り返された状態も同じ重みで入れる。

原著：Metropolis et al. (1953), Hastings (1970)（付録末に書誌・リンク）

講義

対称でない提案では、提案確率の比も必要

近い点と遠い点を違う規則で選ぶと、逆向きの提案確率が等しくない場合がある。
Metropolis–Hastings法は逆向きと順向きの提案の比を受理率へ含める。
非対称な提案でこの補正を省くと、一般には目標分布を保てなくなる。
今回の演習の正規提案は対称なので、その比は1。



受理率 A→B：1/4、B→A：1
遷移確率は両方向とも 0.2

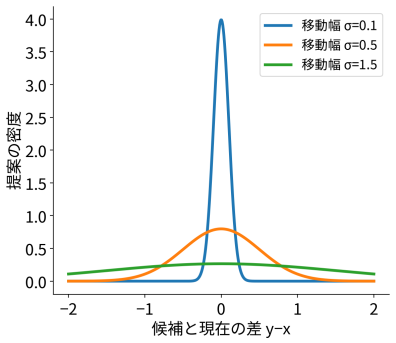
偏った提案を、受理判定で補正

$$\alpha(x,y) = \min\left\{1, \frac{\pi(y)q(x \mid y)}{\pi(x)q(y \mid x)}\right\}$$

講義

小さい移動幅と、大きい移動幅には別の難しさがある

小さすぎる：受理されやすいが、近くの位置ばかりで相関が強い。
大きすぎる：高エネルギーの候補が増え、棄却が多くなる。
受理率だけを最大化しても、効率的なサンプリングにはならない。
谷を行き来し、観測量の平均を精度よく求められるかを見る。



サンプリングとマルコフ連鎖

高い障壁では、独立な情報が増えにくい

高温は障壁を越えやすくするが、分布も変える

$$\pi_T(x) \propto e^{-U(x)/(k_{\mathrm{B}}T)}$$

エネルギーの高い領域の相対的な重みが増え、障壁を越える機会が増える場合がある。

しかし低温で知りたい構造の割合と、高温の割合は異なる。高温の標本をそのまま低温の平均へ混ぜられない。

通り道が非常に狭いなど、状態の数の問題が律速する場合には、高温だけで十分速くならないこともある。

一般化アンサンブルは、探索しやすい分布を設計する

物理的な目標分布をそのまま動かす以外に、重みを変えた分布や、温度などの変数も含む広い状態空間を作る。

最後に欲しい量を得るには、条件ごとに標本を選ぶか、変えた重みを補正する。

分布を平らにした座標以外の遅い変化が残る場合がある。何を平らにし、何を交換するかを明示する。

$$T = \begin{pmatrix} 1-a & a \\ b & 1-b \end{pmatrix}, \quad \pi_A = \frac{b}{a+b}$$

$$\lambda_2 = 1-a-b, \quad \tau = -1/\ln|\lambda_2|$$

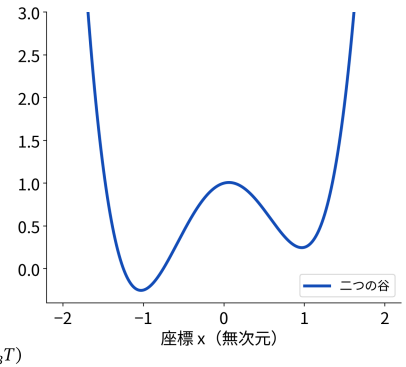
同じa:bでもa+bを小さくすると緩和が遅い。τは更新回数を単位とする緩和時間。

原著：Sugita & Okamoto (1999), Sugita, Kitao & Okamoto (2000)（付録末に書誌・リンク）

講義

二つの谷を、既知の密度と比べる

授業の模型は一次元で、数値積分から基準の密度を計算できる。
右の谷はエネルギーが少し高く、同じ温度でも現れる割合は等しくない。
この小さな模型で、提案・受理・相関を具体的に確かめる。
数値は無次元で、タンパク質の実際の自由エネルギーを表すものではない。

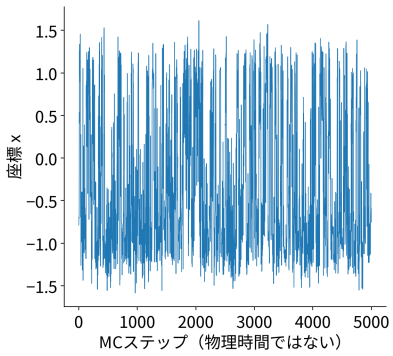


$$U(x) = (x^2-1)^2 + 0.25x, \qquad \pi(x) \propto e^{-U(x)/(k_BT)}$$

講義

軌跡では、谷の往復と長い滞在を見る

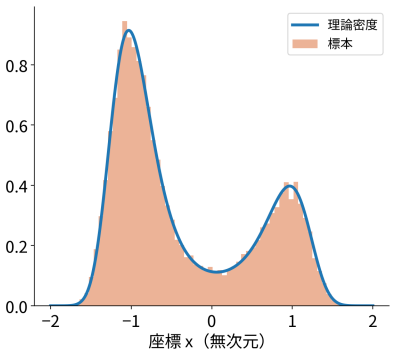
一つの谷に長くとどまると、標本数が多くても反対側の割合が分からない。
計算の初期値を変えた実行も比べる。
平衡化前の部分を除いても、その後に十分な往復があるかを確認する。
横軸はMCのステップ。分子の物理時間ではない。



講義

ヒストグラムは、理論密度と面積で比べる

密度表示なら、棒の高さの総和ではなく、棒の面積の総和が1。
標本が増えると理論密度へ近づくことが期待されるが、相関や探索不足で誤差が残る。
棒の形だけでなく、左右の谷の確率や平均値も比較する。
右はkBT=0.6、移動幅0.7の計算例。



標本の解析

標本のばらつきと、平均の誤差を導く

ばらつきの大きさと、平均の不確かさを分ける

説明用の4標本が1,2,3,4なら、標本平均は2.5。各標本が平均からどれくらい散らばるかを分散で測る。

$$s^2 = \frac{1}{M-1}\sum_n (A_n - \overline{A})^2 = 5/3$$

sは標本の標準偏差。母分散の不偏推定では、同じデータから平均を推定した自由度を一つ引いてM−1で割る。

$$\mathrm{SE}(\overline{A}) \simeq s/\sqrt{M}$$

最後の標準誤差SEは、独立同分布の標本という条件が必要。MDの連続フレームではそのまま使えない。

$$\mathbb{E}\left[\sum_n (A_n - \overline{A})^2\right] = (M-1)\sigma^2$$

独立標本では、母平均からの二乗和の期待値Mσ²から、M Var(平均)=σ²を引くためM−1。

標本平均の分散を、二つの時刻の和へ展開する

$$\overline{A} - \mu = \frac{1}{M}\sum_{n=1}^{M}(A_n - \mu)$$

$$\mathrm{Var}(\overline{A}) = \frac{1}{M^2}\sum_{n,m}\langle (A_n-\mu)(A_m-\mu)\rangle$$

μは母平均。同じ時刻の項だけでなく、別の時刻の積も残る。独立なら別時刻の共分散は0。

似た値が続くと別時刻の項が正に寄与し、独立標本と仮定した見積もりより平均の誤差が大きくなる。

統計の参考：Grossfield et al., LiveCoMS 1, 5067 (2019)（付録末に書誌・リンク）

標本の解析

相関した標本の誤差と、有効標本数

定常な時系列では、時間差ごとにまとめられる

$$C(k) = \langle (A_n-\mu)(A_{n+k}-\mu)\rangle, \qquad \rho(k) = C(k)/C(0)$$

$$\mathrm{Var}(\overline{A}) = \frac{\sigma^2}{M}\left[1 + 2\sum_{k=1}^{M-1}\left(1-\frac{k}{M}\right)\rho(k)\right]$$

同じ差kを持つ時刻対がM−k組、正負の差で二組あるので係数2が出る。対角項はMσ²。

定常性は平均や相関が開始時刻に依存しない条件。初期緩和が混じる場合、この式の前提から点検する。

積分相関時間と有効標本数を定義する

$$g = 1 + 2\sum_{k=1}^{\infty}\rho(k), \qquad N_{\mathrm{eff}} = M/g$$

$$\tau_{\mathrm{int}} = \Delta t\left[\frac{1}{2} + \sum_{k=1}^{\infty}\rho(k)\right], \qquad g = 2\tau_{\mathrm{int}}/\Delta t$$

軌跡が相関時間より十分長い近似で、平均の分散はσ²/N_{eff}になる。Δtは保存間隔。

この教材のτ_{int}は半時刻分を含む規約。他の文献では定義の係数が違う場合がある。量Aごとに相関時間も違う。

統計の参考：Grossfield et al., LiveCoMS 1, 5067 (2019)（付録末に書誌・リンク）

標本の解析

相関の数値例と、ブロック平均の誤差

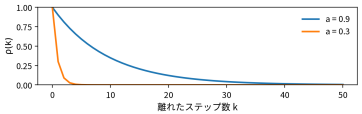
指数的に似た値が続く例を計算する

$$\rho(k) = a^k, \quad 0 < a < 1, \qquad \sum_{k=1}^{\infty} a^k = \frac{a}{1-a}$$

$$g = \frac{1+a}{1-a}$$

a=0.9ならg=19。1900フレームでも、独立標本約100個分の平均精度になる。

相関の長い尾は有限データでノイズに埋もれる。見た目の滑らかさだけで打切りを決めず、ブロック法や独立計算でも確認する。



ρ(k)=aᵏの説明用の相関関数。

ブロック平均は、近い時刻をまとめてから比べる

長さLの連続区間ごとに平均B_bを作り、ブロック数をKとする。Lが相関時間より十分長ければ、ブロック間の依存が小さくなる。

$$\widehat{\mathrm{Var}}(\overline{A}) \simeq \frac{1}{K(K-1)}\sum_{b=1}^{K}(B_b - \overline{B})^2$$

ブロック長を増やして推定が安定する範囲を見る。ただし長くしすぎるとブロック数が少なく、推定自体が不安定になる。

軌跡全体が一つの谷にいる場合、どんな分割でも未訪問の谷の誤差は分からない。

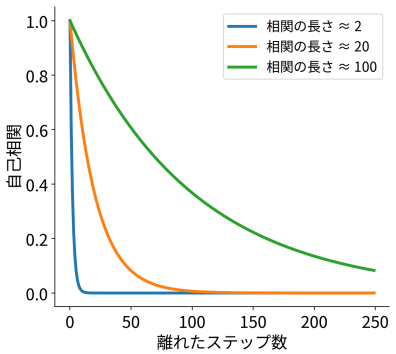
区間 1 → B1	区間 2 → B2	区間 3 → B3	区間 4 → B4

統計の参考：Grossfield et al., LiveCoMS 1, 5067 (2019)（付録末に書誌・リンク）

講義

相関が強いと、見かけの標本数ほど情報は増えない

隣り合う標本がよく似ると、独立な情報の数は小さくなる。
相関時間は観測量によって変わる。座標だけでなく、谷の所属も見る。
有効標本数は誤差の見積もりであり、未訪問の谷を見つける保証ではない。
右は相関の減衰の模式図で、実際の測定結果とは区別する。



$$N_{\mathrm{eff}} \simeq \frac{N}{1 + 2\sum_{k\geq 1}\rho(k)}$$

標本の解析

ブートストラップと、収束の確かめ方

ブートストラップは、独立な単位を引き直す

データの単位を復元抽出し、解析全体を繰り返して推定値の分布を見る。独立フレームならフレームを、相関があれば連続ブロックを単位にする。

独立な繰り返し計算が複数あるなら、その単位も利用できる。軌跡ごとの長さや依存を明示する。

標本が含まない状態は、再抽出しても現れない。信頼区間は使用したデータと統計的な前提の範囲で読む。

収束は、観測量ごとに複数の証拠で判断する

累積平均、前半と後半、ブロック長、初期構造の違う計算を比較する。平均値だけでなく分布や状態間遷移を見る。

同じ谷から始めた計算同士が一致しても、別の谷が存在しない証明にはならない。

結果には、推定値、単位、計算本数、各時間、除外区間、不確かさの計算法を添える。誤差が小さく見える桁を過剰に並べない。

統計の参考：Grossfield et al., LiveCoMS 1, 5067 (2019)（付録末に書誌・リンク）

サンプリングとマルコフ連鎖

MCMCの用途と、物理時間の区別

MCMCは、未知のパラメータを推定する問題にも使える

例：コインの表確率θを知りたい。10回中7回表というデータの起こりやすさは$\theta^7(1-\theta)^3$に比例する。

$$\pi(\theta \mid \text{data}) \propto \theta^7(1-\theta)^3\,\pi_0(\theta)$$

π_0は観測前に置く分布。0<θ<1で一様なら、上の重みの比でθの候補を受理できる。

このようなベイズ推定でもZを知らずに分布を調べられる。MDとの違いは、状態が原子座標でなく未知パラメータであること。

MCのステップ数は、そのまま物理時間ではない

候補を大きく跳ばしたり、分子を回転したりする規則を自由に設計できる。同じ目標分布を作っても、一回の移動に実時間の意味は一般にない。

構造の割合や平衡平均と、速度定数・拡散などの動態を区別する。

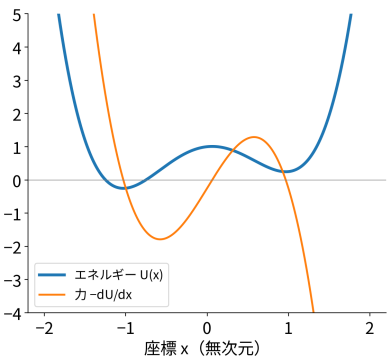
MDの区間を含む方法でも、交換や人工的なバイアスを含む全履歴を、通常MDの連続した時間軌跡と無条件に同一視しない。

原著：Metropolis et al. (1953), Hastings (1970)（付録末に書誌・リンク）

講義

MDとの共通点と違いを押さえる

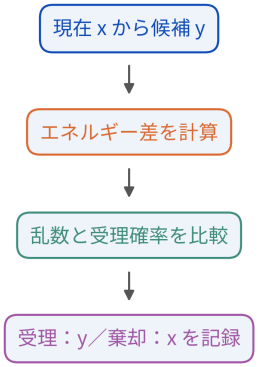
MCもMDも、条件が適切なら同じ平衡分布を対象にできる。
Metropolis法の移動は人工的な提案で、経路は通常、実時間の運動を表さない。
MDは力と運動方程式で位置を更新する。時間刻みや温度制御を検討する。
次回はこのMDの更新計算を扱う。



演習

演習：温度と移動幅を一つずつ変える

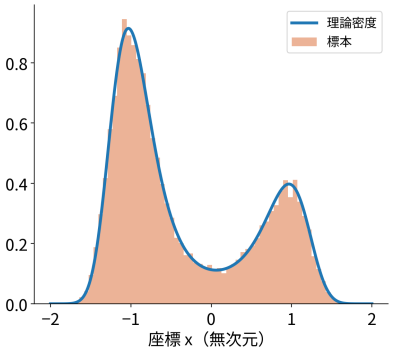
Colabで授業用ノートブックを開き、全セルを実行する。GPUは不要。
エネルギー、提案、受理判定、棄却時の記録をコードで読む。
温度と移動幅を変え、軌跡・密度・受理率・谷の確率を比べる。
演習20分を目安。採点・提出なし。



演習

結果を読む順序を決める

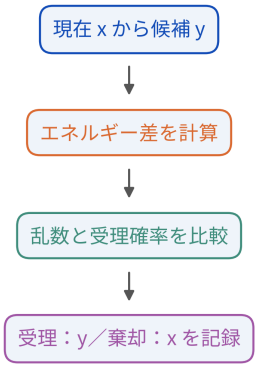
軌跡：左右の谷を往復したか。
分布：理論密度と同じ座標・規格化で比べたか。
数値：受理率だけでなく平均と谷の確率も見たか。
再実行：seedや初期値を変えても大きな食い違いがないか。
一度うまく見えたことだけで収束を断定しない。



まとめ

更新則を設計し、有限の標本を点検する

提案と受理を組み合わせ、目標分布を定常分布にする。
詳細釣り合いはそのための十分条件。
棄却も記録し、移動幅・障壁・相関を確認する。
冒頭の目標だった「構造の現れやすさ」は、軌跡から確率として推定する。
分布が正しい条件と、有限時間で精度よく計算できる条件を分ける。



付録

付録：サンプリングと推定の補足

ここからは独習用の補足です。
本編で使った式の導出や、手法の条件を確認します。
必要な項目から参照してください。

サンプリングとマルコフ連鎖

拡張サンプリングで求めたい量

困っていること

計算が安定していても、一つの構造の周辺だけを動き続ける場合がある。状態の割合を知るには、必要な構造群を行き来する必要がある。

高温にする、力場を変える、特定の座標へ力を加える、経路を探す、といった方法がある。ただし、変えた分布を目的の分布と混同しない。

本回ではMCMCとMDを組み合わせる条件まで扱う。レプリカ交換やアンブレラ法は第12回で学ぶ。

$$\pi_0(x) = Z_0^{-1} e^{-\beta U(x)}, \quad \beta = (k_{\mathrm{B}}T)^{-1}$$

Uは系全体のポテンシャルエネルギー、Tは絶対温度。モル単位のUを使う式ではk_Bを気体定数Rへ置き換える。

原著：Metropolis et al. (1953), Hastings (1970)（付録末に書誌・リンク）

確率分布を標本平均へつなぐ

$$\langle A \rangle = \int A(x)\pi(x)\,\mathrm{d}x \simeq \frac{1}{M}\sum_{n=1}^{M} A(x_n)$$

xは全座標などをまとめた状態。πは目標確率密度。x_nがその分布を十分に訪れる標本なら、平均を推定できる。

高次元では、すべての座標の組を格子で並べると点の数が爆発する。よく現れる状態を重点的にサンプリングしたい。

最小値を一つ探す問題と、分布全体を数える問題は違う。高いエネルギーの状態も、必要な重みで訪れる。

サンプリングとマルコフ連鎖

MDとMCを交互に使える条件

同じ分布を保つ更新は、組み合わせても分布を保つ

K_1とK_2を、いずれもπを保つ遷移規則とする。連続状態なら和を積分へ置き換える。

$$\sum_x \pi(x)K_1(x,y) = \pi(y)$$

$$\sum_{x,y} \pi(x)K_1(x,y)K_2(y,z) = \sum_y \pi(y)K_2(y,z) = \pi(z)$$

この式が、平衡を保つMDとMCを交互に実行する根拠。各更新が詳細釣り合いを満たしても、順序を固定した合成が詳細釣り合いまで満たすとは限らない。

MDを提案に使う：Hamiltonian Monte Carlo

運動量をGaussian分布から作り、Hamiltonの運動を数値積分して離れた候補を作る。これをHMCと呼ぶ。

① pを再生成。② 可逆で体積を保つVerlet型の積分を一定回数行う。③ 最後に運動量を反転した候補を作る。

$$a = \min[1, e^{-\beta(H_{\mathrm{new}} - H_{\mathrm{old}})}]$$

④ 受理なら候補へ、棄却なら元の状態へ戻す。運動量を毎回完全に再生成する基本形では、次回の運動量は新しく引く。

原著：Metropolis et al. (1953), Hastings (1970) ／ 原著：Duane et al., Phys. Lett. B 195, 216 (1987)（付録末に書誌・リンク）

サンプリングとマルコフ連鎖

HMCの受理式を支える可逆性と体積保存

可逆性と体積保存が、HMCの受理式を支える

運動量反転をR、可逆積分をΦとすると、RΦR=Φ^{-1}。したがって候補写像RΦを二回作用させると元に戻る。

$$(R\Phi)^2 = I, \qquad |\det D\Phi| = 1$$

逆候補が対応し、微小体積の倍率も1なので、目標密度の比だけが残る。有限刻みのエネルギー差をMCで補正する。

摩擦を加えた任意のMDを同じ式へ代入してもよいわけではない。写像の可逆性・測度・乱数の扱いを確認する。

なぜ全エネルギーの差になるか

$$\rho(x,p) = Z^{-1}e^{-\beta H(x,p)}, \quad H = U + K$$

$$R = \frac{\rho(x^*,p^*)}{\rho(x,p)}\,|\det D\Phi| = e^{-\beta\Delta H}$$

可逆性は逆の候補との対応、体積保存はJacobianが1という条件。両方を用いてこの簡単な形になる。

積分誤差がゼロならΔH=0で必ず受理。刻みを大きくして移動距離を伸ばしても、棄却が増える場合がある。

原著：Duane et al. (1987)（付録末に書誌・リンク）

標本の解析

確率・密度・自由エネルギーと座標の変換

頻度を、確率と密度へ順番に変える

$$\hat{p}_j = h_j/M, \qquad \hat{\rho}_j = \frac{h_j}{M\Delta\xi_j}$$

h_jはビンjのカウント。p_jはその区間へ入る確率、ρ_jは単位幅あたりの密度。幅が違うビンでは高さをそのまま比較しない。

$$F(\xi_j) = -k_{\mathrm{B}}T\ln\hat{\rho}_j + C$$

Cは自由に選べる基準。h_j=0は、その領域の確率が本当に0である証拠ではなく、有限標本で観測していないという意味。

座標を変えると、自由エネルギー曲線も変わる

$$\rho_y(y)\,\mathrm{d}y = \rho_x(x)\,\mathrm{d}x$$

$$F_y(y) = F_x(x) - k_{\mathrm{B}}T\ln\left|\frac{\mathrm{d}x}{\mathrm{d}y}\right| + C$$

同じ物理状態でも横軸の数え方で密度は変わる。自由エネルギーの谷の見た目は、座標の選択と切り離せない。

距離rのヒストグラムには球殻の$4\pi r^2$が含まれる。一様な空間を基準にしたPMFは$-k_{\mathrm{B}}T\ln g(r)$で、$-k_{\mathrm{B}}T\ln p(r)$とは異なる。

$$y = x^2\ (x>0), \quad \rho_y(y) = \frac{\rho_x(\sqrt{y})}{2\sqrt{y}}$$

座標変換の例：一様なxでもyの密度は一様でない。ヤコビアンを落とすと分布を誤解する。

統計の参考：Grossfield et al., LiveCoMS 1, 5067 (2019)／説明の参考：GROMACS 2026.0, Analysis（付録末に書誌・リンク）

タンパク質構造のMCMC

- 構造の候補は、角度や二面角などの内部座標を動かして作れる。
- 逆向きの提案確率を確認し、非対称ならMetropolis–Hastingsの比で補正する。

- 水を陽に含める場合は、周囲の水との衝突にも注意する。
- タンパク質を動かすと水分子と衝突するかもしれない
- 局所的な構造変更でも周囲の水と衝突し、受理率が低くなる場合がある。暗黙溶媒や粗視化モデルではこの負担を減らせる。明示的な水を含む系でも、HMCなどの工夫でMCを使うことはできる。

タンパク質構造の提案分布の作り方

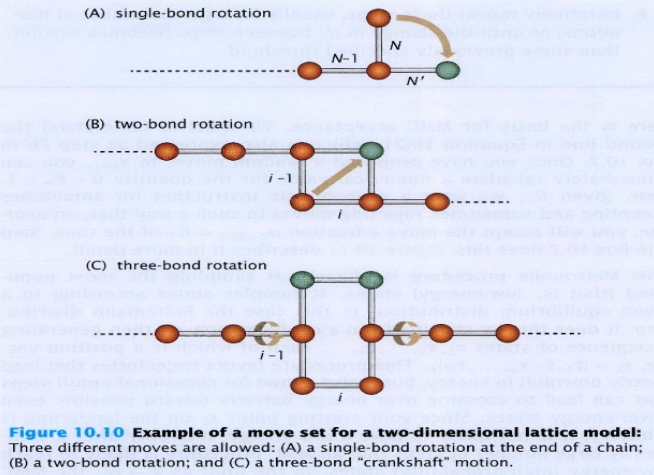


Figure 10.10 **Example of a move set for a two-dimensional lattice model:** Three different moves are allowed: (A) a single-bond rotation at the end of a chain; (B) a two-bond rotation; and (C) a three-bond "crankshaft" motion.

K. Dill, R. L. Jernigan, and I. Bahar, *Protein Actions* (Garland Science, 2017)

サンプリングとマルコフ連鎖

参考文献・説明の出典 1

MCMC原著：Metropolis N et al. Equation of State Calculations by Fast Computing Machines. J. Chem. Phys. 21, 1087–1092 (1953). DOI: 10.1063/1.1699114.

原著：Hastings WK. Monte Carlo sampling methods using Markov chains and their applications. Biometrika 57, 97–109 (1970). DOI: 10.1093/biomet/57.1.97.

HMC原著：Duane S, Kennedy AD, Pendleton BJ, Roweth D. Hybrid Monte Carlo. Phys. Lett. B 195, 216–222 (1987). DOI: 10.1016/0370-2693(87)91197-X.

原著：Berg BA, Neuhaus T. Multicanonical algorithms for first order phase transitions. Phys. Lett. B 267, 249–253 (1991). DOI: 10.1016/0370-2693(91)91256-U.

原著：Marinari E, Parisi G. Simulated Tempering: A New Monte Carlo Scheme. Europhys. Lett. 19, 451–458 (1992). DOI: 10.1209/0295-5075/19/6/002.

REMD原著：Sugita Y, Okamoto Y. Replica-exchange molecular dynamics method for protein folding. Chem. Phys. Lett. 314, 141–151 (1999). DOI: 10.1016/S0009-2614(99)01123-9.

REUS原著：Sugita Y, Kitao A, Okamoto Y. Multidimensional replica-exchange method for free-energy calculations. J. Chem. Phys. 113, 6042–6051 (2000). DOI: 10.1063/1.1308516.

REST原著：Liu P et al. Replica exchange with solute tempering: A method for sampling biological systems in explicit water. PNAS 102, 13749–13754 (2005). DOI: 10.1073/pnas.0506346102.

出典確認：2026-10-09〜10。項目をクリックすると原文を開く。

標本の解析

参考文献・説明の出典 2

説明の参考：GROMACS 2026.0 Reference Manual, Analysis. 前処理、構造量、相関、PCAなど。

統計の参考：Grossfield A et al. Best Practices for Quantification of Uncertainty and Sampling Quality in Molecular Simulations. LiveCoMS 1, 5067 (2019). DOI: 10.33011/livecoms.1.1.5067.

原著：Zhang Y, Skolnick J. Scoring function for automated assessment of protein structure template quality. Proteins 57, 702–710 (2004). DOI: 10.1002/prot.20264.

実装の参考：Zhang group, TM-score program instructions. 正規化の長さ、d_0、構造対応の指定。

原著：Kabsch W, Sander C. Dictionary of protein secondary structure: Pattern recognition of hydrogen-bonded and geometrical features. Biopolymers 22, 2577–2637 (1983). DOI: 10.1002/bip.360221211.

原著：Shrake A, Rupley JA. Environment and exposure to solvent of protein atoms. Lysozyme and insulin. J. Mol. Biol. 79, 351–371 (1973). DOI: 10.1016/0022-2836(73)90011-9.

WHAM原著：Kumar S et al. The weighted histogram analysis method for free-energy calculations on biomolecules. I. The method. J. Comput. Chem. 13, 1011–1021 (1992). DOI: 10.1002/jcc.540130812.

出典確認：2026-10-09〜10。項目をクリックすると原文を開く。