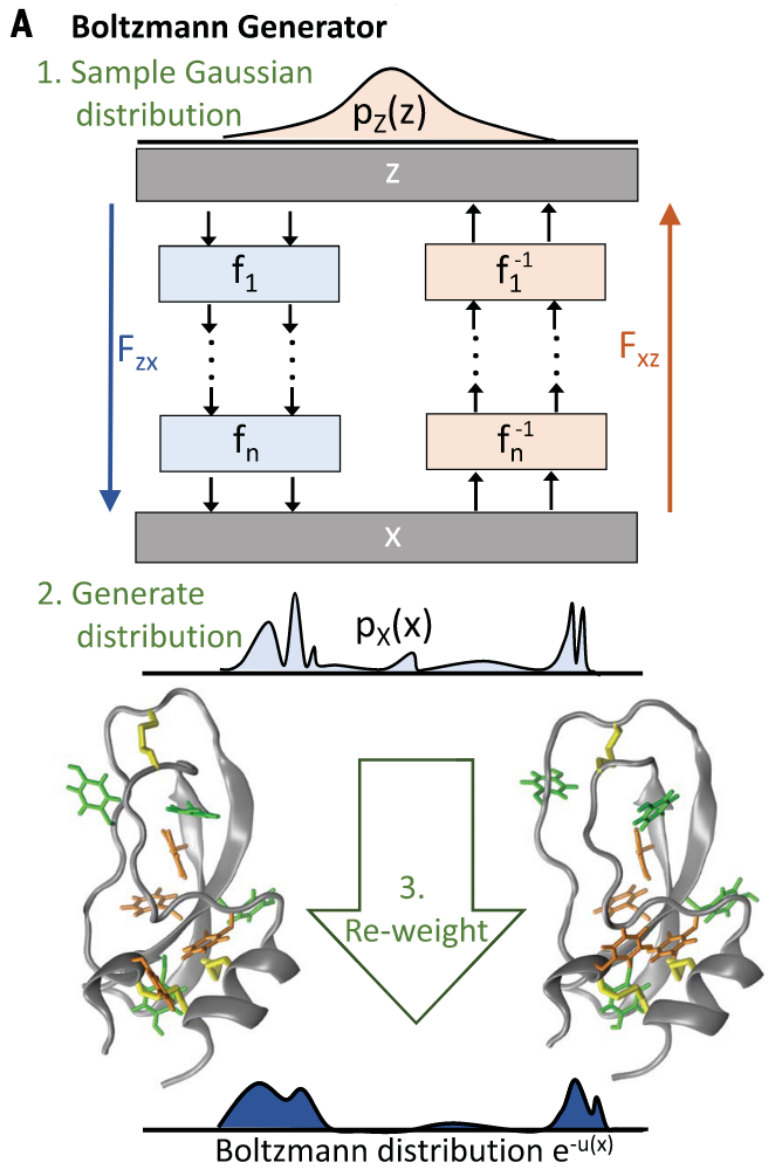
生命情報工学特論　第13回

構造アンサンブルを生成するAI



乱数から構造アンサンブルを生成し、
目標分布とのずれを評価する

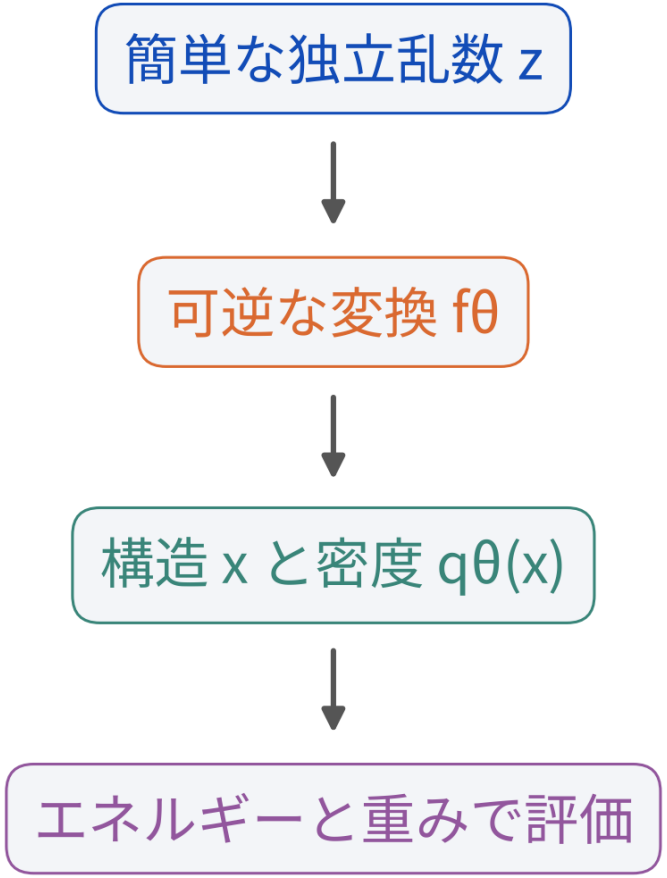
松永 康佑

埼玉大学 大学院理工学研究科
理化学研究所 計算科学研究センター

2026年12月21日

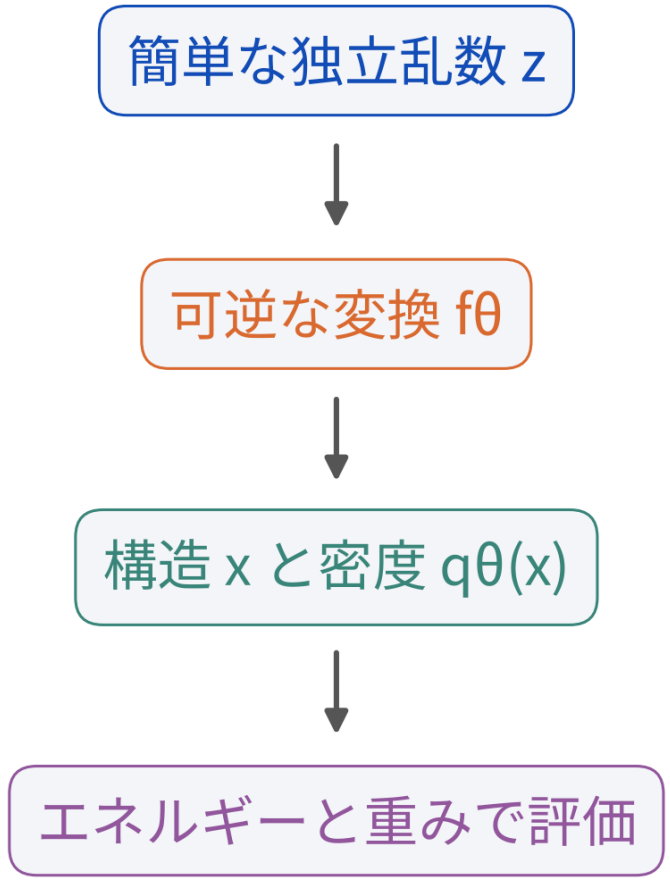
乱数から構造アンサンブルを生成し、分布のずれを評価する

構造アンサンブルは、複数の構造とその割合。乱数から生成し、目標の平衡分布へ近づける。
中心となるBoltzmann generatorでは、可逆変換によって生成密度を計算する。
学習だけで分布の一致は保証されない。リウェイティング（重みの補正）の条件と、生成できていない状態の有無を調べる。
生成の順番から反応速度は求まらない。



分布の変換・学習・評価をつなぐ

1　座標の変換と確率密度
2　可逆なニューラルネットと体積変化
3　データ・エネルギーからの学習
4　リウェイティングとBioEmuの構造アンサンブル
5　二つの谷を生成する小さな模型



構造アンサンブルを得るための計算を速くできるか

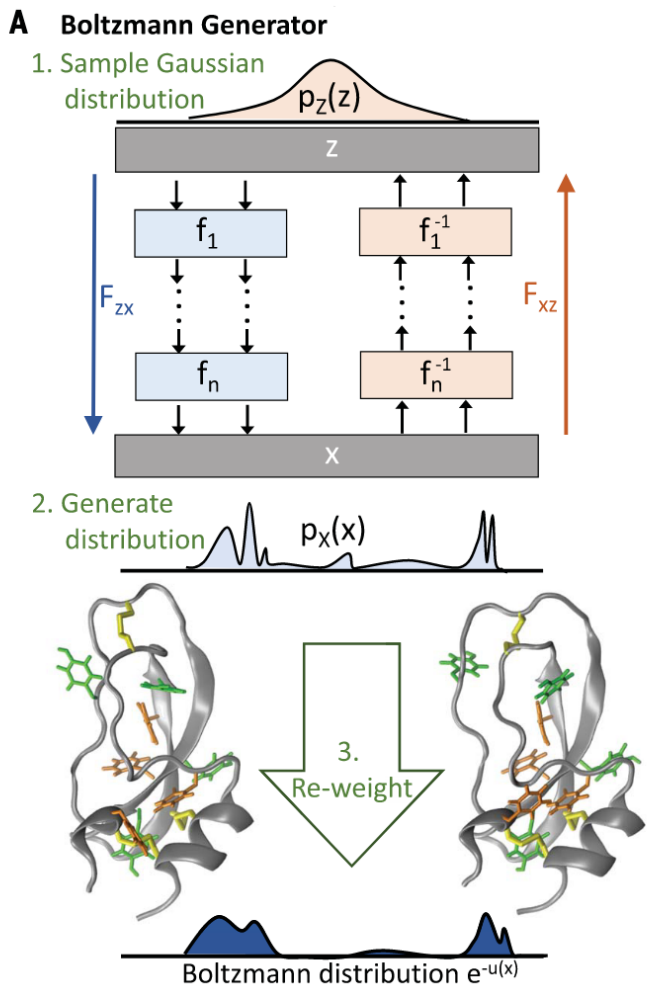
分子動力学（MD）は原子の運動から構造の時間変化を計算する。多くの状態を訪れるまで、長い計算が必要になる場合がある。
生成モデルは構造を直接作る。速さの比較には、学習・補正・検証の費用も含める。分布の精度を保って効率化できるかが、この回で考える問題。

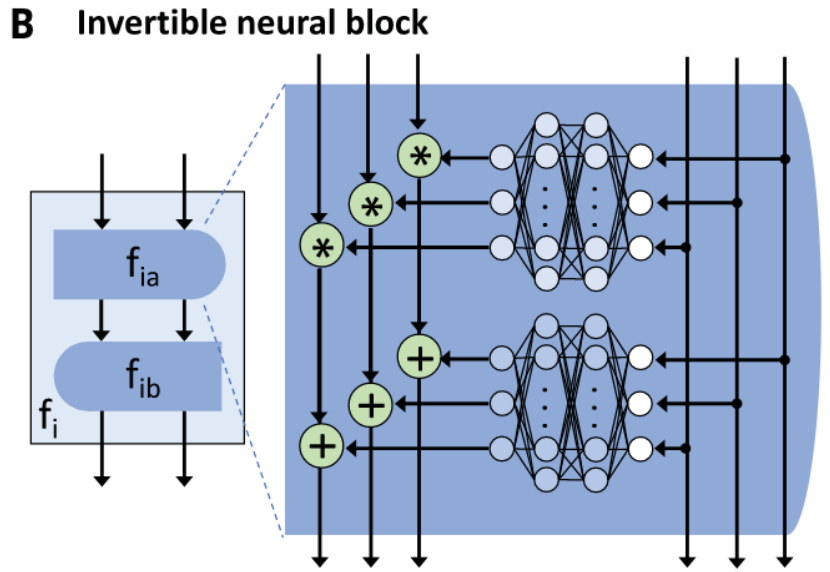




存在割合を学ぶ。生成した順番は、物理的な時間ではない。

Boltzmann generator：可逆変換で平衡構造を生成する



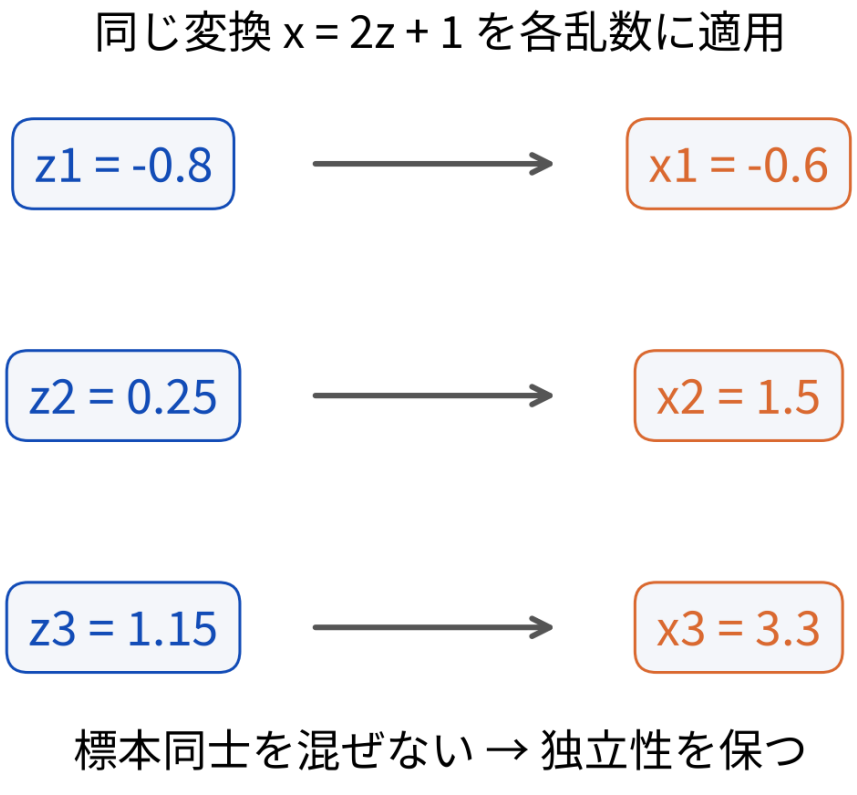


A：構造 x と、単純な潜在変数 z を双方向に変換する。生成した標本は必要に応じて重みで補正する。
B：可逆な層を重ね、逆変換と確率密度を計算する。これを normalizing flow（正規化フロー）と呼ぶ。

BG：Boltzmann generator。Noé et al., Science (2019), Fig. 1A–B.

独立な乱数を変換すれば、独立な標本を得られる

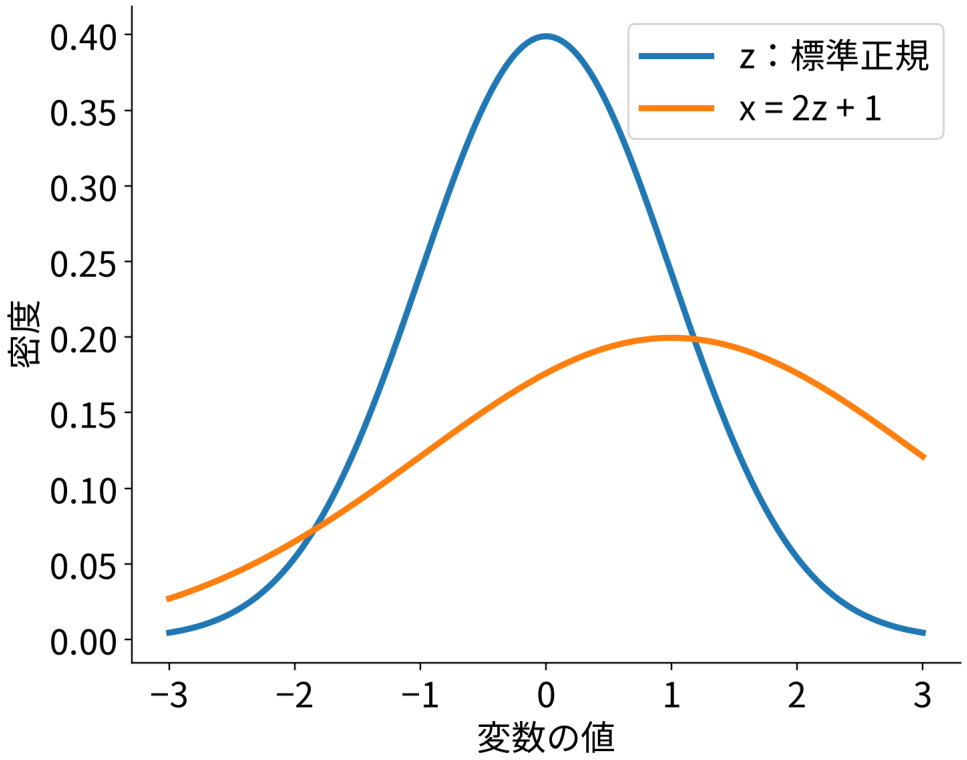
基底分布：標準正規分布や一様分布など、容易に乱数を引ける分布。
fθ：パラメータθを学習する座標変換。入力と出力は同じ次元とする。
学習済みの同じ変換を独立な乱数へ適用すると、出力も独立になる。ただし目標分布に一致するかは別の問題。



$$z \sim p_Z(z), \qquad x = f_\theta(z), \qquad x \sim q_\theta(x)$$

変数を2倍に伸ばすと、密度は半分になる

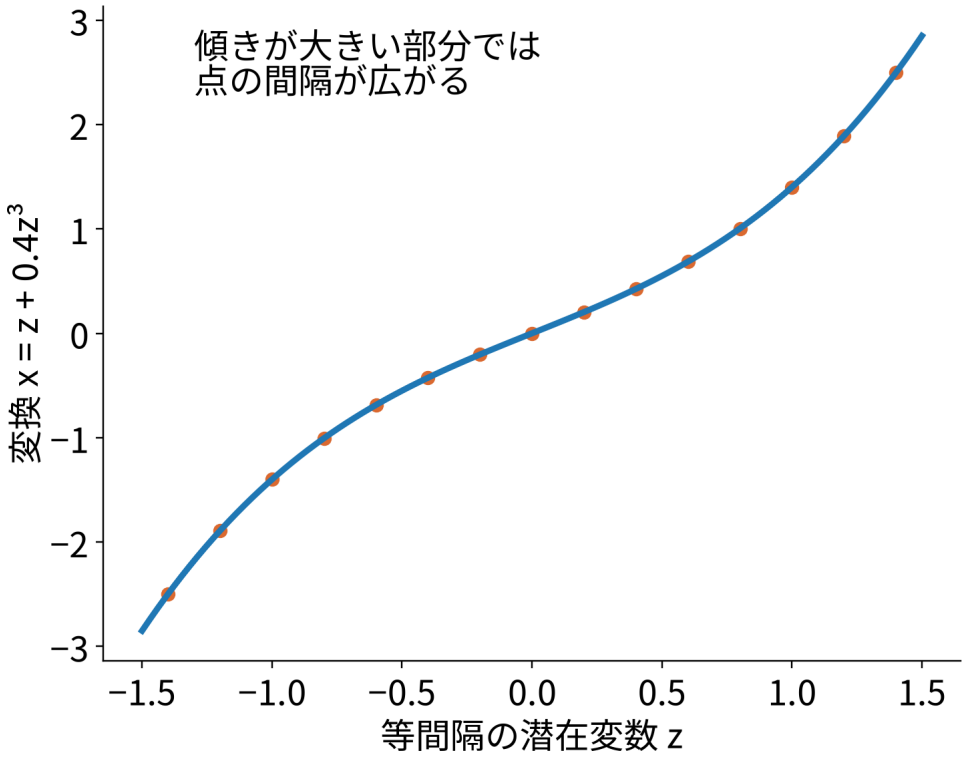
zの幅1の区間が、x=2z+1では幅2へ広がる。
区間に入る確率は変わらないため、単位長さあたりの密度は半分になる。
標準正規分布は、平均1・標準偏差2の正規分布へ変わる。
この「確率を保つ」条件を一般化する。



$$q_X(x) = \frac{1}{2} p_Z\left(\frac{x-1}{2}\right)$$

一般の1次元変換では、局所の傾きで割る

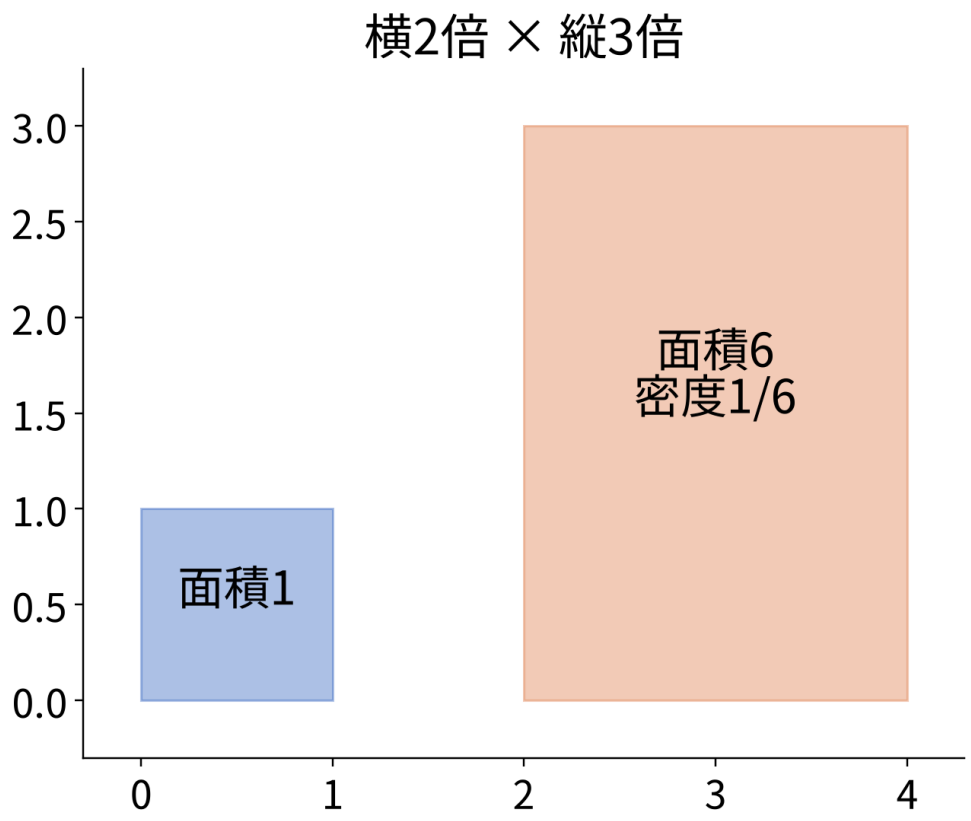
微小区間では、曲線を傾きf′の直線で近似できる。
dx=|f′(z)|dzだから、同じ確率が入る区間の長さが変わる。
図では外側ほど点の間隔が広がり、密度は低くなる。
絶対値は向きが反転する変換にも対応するため。



$$q_X(x)\,dx = p_Z(z)\,dz, \quad q_X(f(z)) = \frac{p_Z(z)}{|f'(z)|}$$

多次元では、長さの伸びを体積の伸びへ置き換える

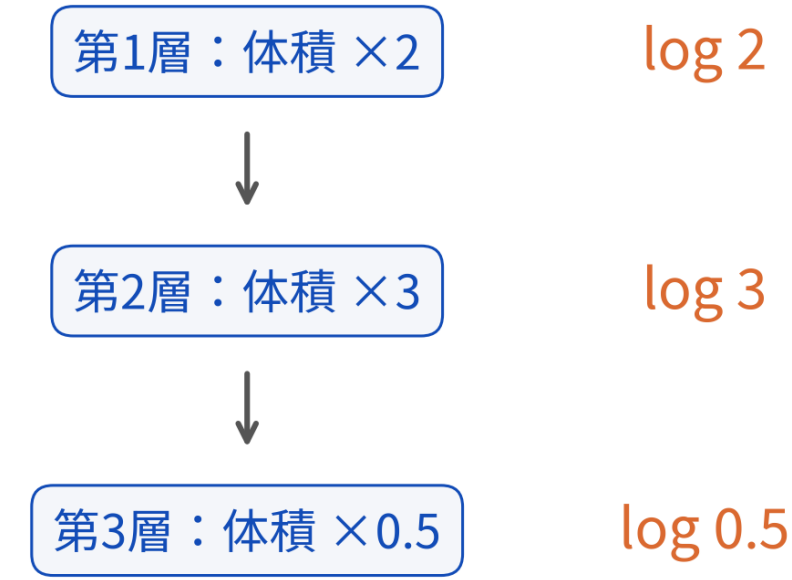
ヤコビ行列Jのij成分は、入力zのj成分を変えたときの出力xのi成分の変化。
微小な箱が平行多面体へ変わり、その体積比が|det J|になる。
例：二方向に2倍と3倍へ伸ばせば、面積は6倍、密度は1/6になる。



$$J_{ij} = \frac{\partial f_i}{\partial z_j}, \quad q_X(f(z)) = p_Z(z)|\det J|^{-1}$$

対数密度を使うと、層ごとの変化を足せる

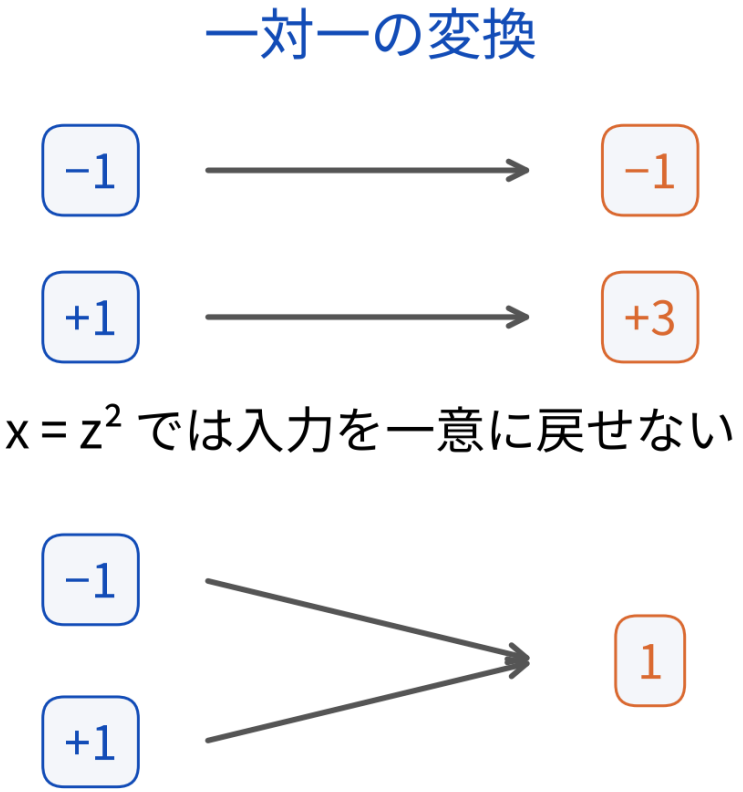
複数の可逆な層を順に適用する。
合成変換のヤコビ行列は行列積になり、行列式も積になる。
対数を取ると、各層の対数体積変化の和になる。
密度を計算しやすい層を重ねることが正規化フロー（normalizing flow）の設計の要点。



$$\log q_X(x) = \log p_Z(z) - \sum_{\ell} \log \left| \det J_\ell \right|$$

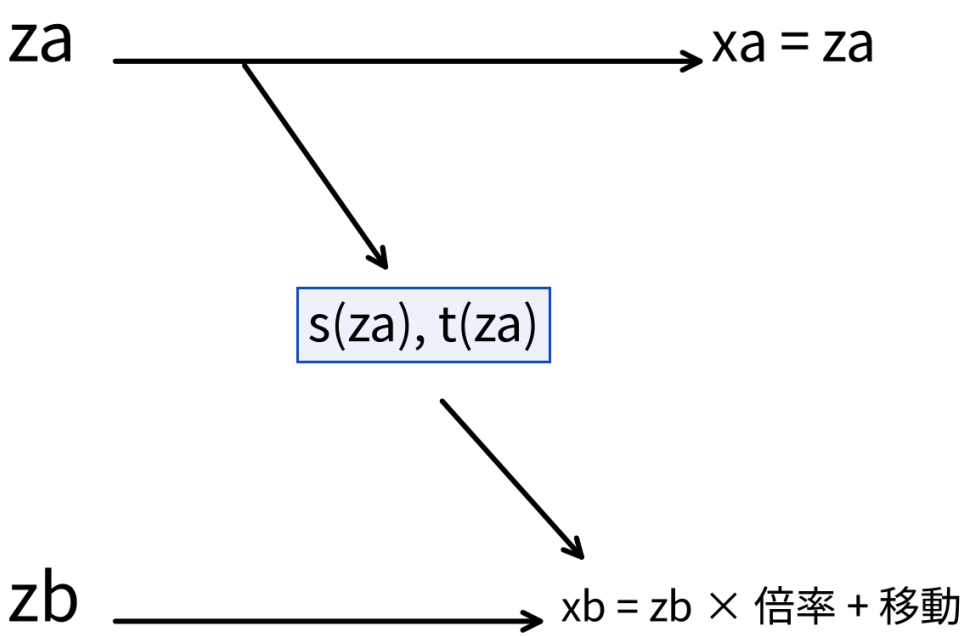
可逆であることと、逆変換が計算しやすいこと

任意のニューラルネットは、異なる入力を同じ出力へ潰すことがある。
その場合、元の入力や密度を一意に求められない。
正規化フローでは逆変換と体積変化を計算できる構造を選ぶ。
これによって生成だけでなく、既存構造がどれほど生成されやすいかも評価できる。



affine couplingは、一方を固定して他方を動かす

変数をaとbの二群に分ける。aはそのまま、bをaに依存した拡大と平行移動で変える。
exp(s)は正なので、b側の変換を必ず戻せる。
sとtは通常のニューラルネットでよい。交互に担当する変数を替え、全体を変換する。



$$x_a = z_a, \quad x_b = z_b \odot e^{s(z_a)} + t(z_a)$$

三角行列の形を使い、行列式を簡単に計算する

a側は変えないので、aをbで微分した成分は0。
b側の対角成分はexp(s)。三角行列の行列式は対角成分の積だから、対数はsの和になる。
複雑なsやtの微分を、密度評価のために行列式へ展開する必要がない。

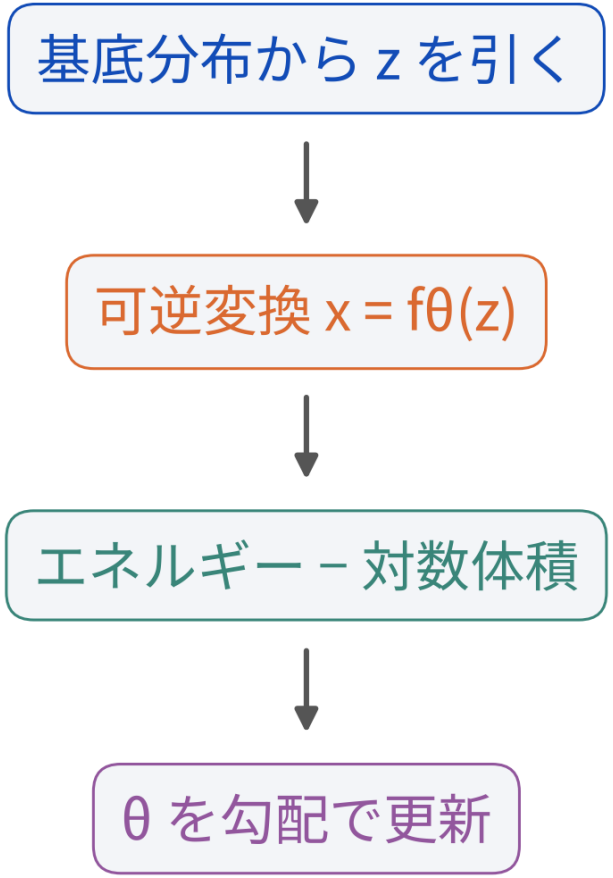
$$J = \begin{pmatrix} I & 0 \\ * & \mathrm{diag}(e^{s(z_a)}) \end{pmatrix}$$

右上のブロックは 0。
左下の * は複雑でもよい。
行列式は対角成分だけから求まる。

$$\log|\det J| = \sum_i s_i(z_a), \quad z_b = (x_b - t(x_a)) \odot e^{-s(x_a)}$$

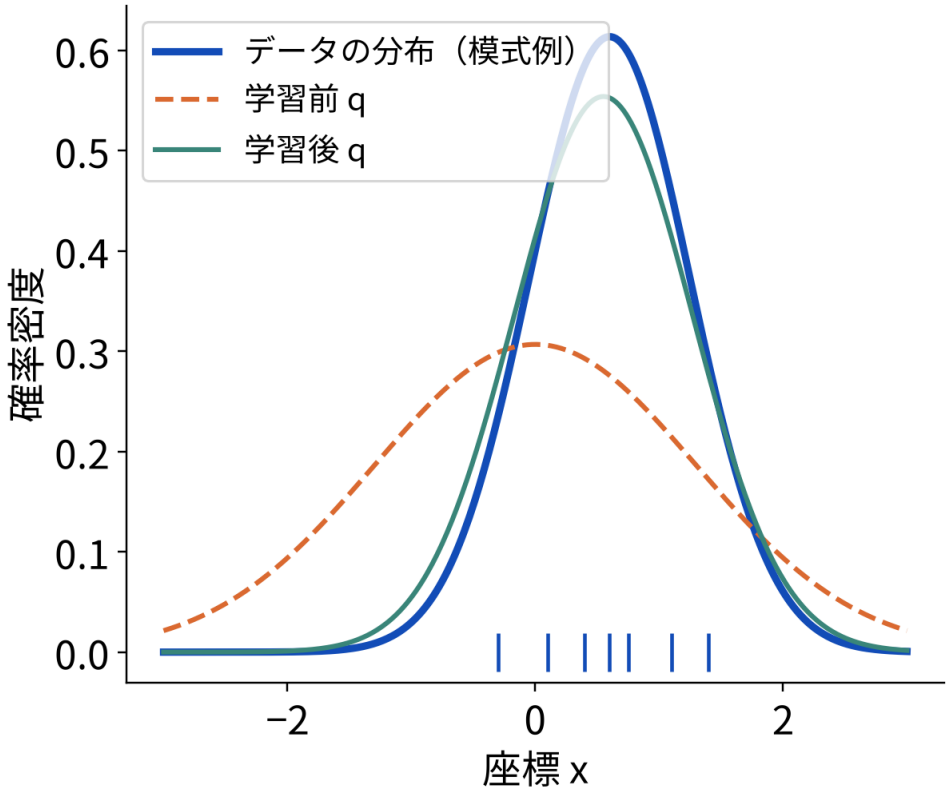
学習の情報は、標本とエネルギーの二通り

標本がある：観測された構造に高い密度を与える。
エネルギーが計算できる：生成した構造のエネルギーと、分布の広がりを評価する。
二つを組み合わせると、既知の谷へ学習を導きつつ、その周囲を物理モデルで評価できる。
目標は一点の最低エネルギー構造ではなく、分布。



データ学習は、標本の負の対数密度を下げる

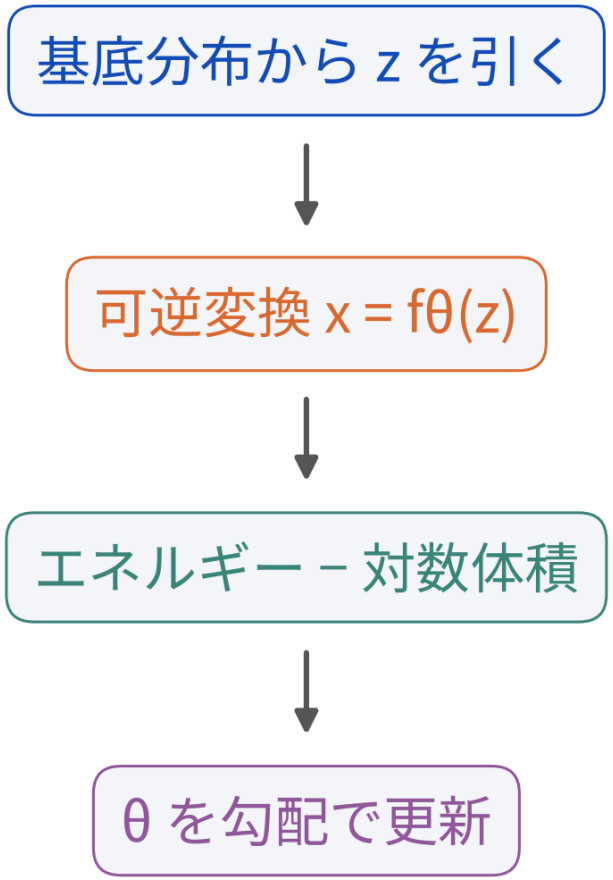
学習標本xが多い場所でqθ(x)を大きくする。
目標分布pから標本が得られていれば、これはKL(p ‖ qθ)のθ依存部分に一致する。
学習データが偏っていれば、その偏りも学ぶ。希少な状態がデータに存在するかを確認する。



$$L_{\mathrm{ML}} = -\mathbb{E}_{x\sim p_{\mathrm{data}}}[\log q_\theta(x)]$$

エネルギー学習は、KL(qθ ‖ p)を下げる

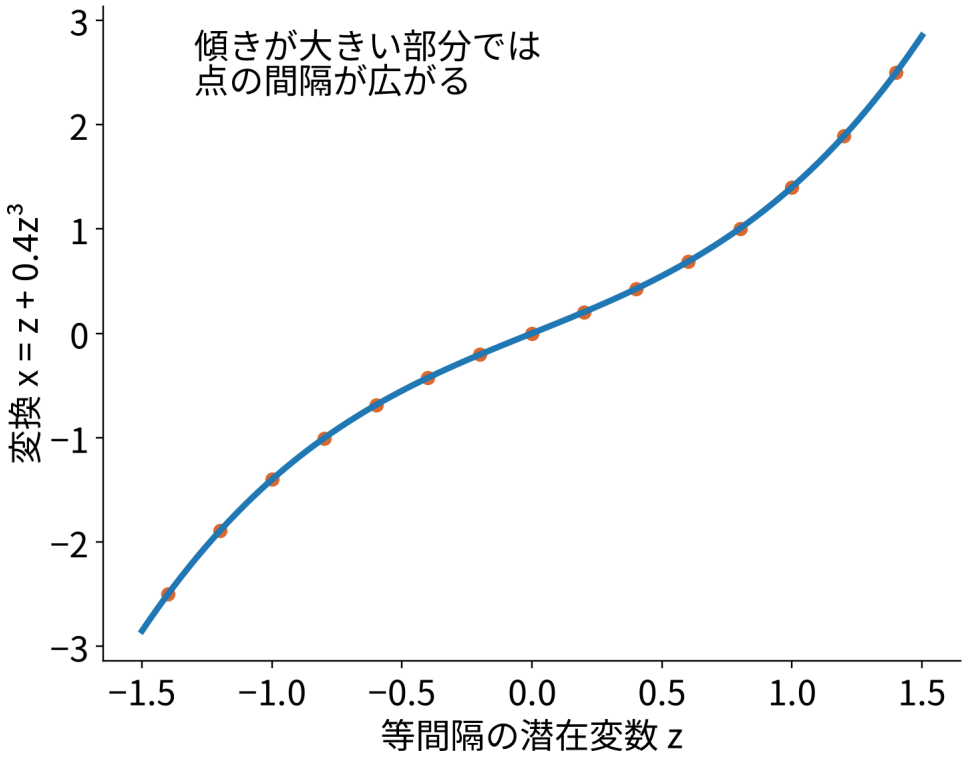
目標はp(x)=exp(−βU(x))/Z。生成分布qθから平均を取る。
log p=−βU−log Zを代入すると、エネルギーとlog qの平均になる。
未知のlog Zはθに依存しないので、学習時の勾配から消える。



$$D_{\mathrm{KL}}(q_\theta \| p) = \mathbb{E}_q[\log q_\theta + \beta U] + \log Z$$

変数変換を代入すると、潜在空間で学習できる

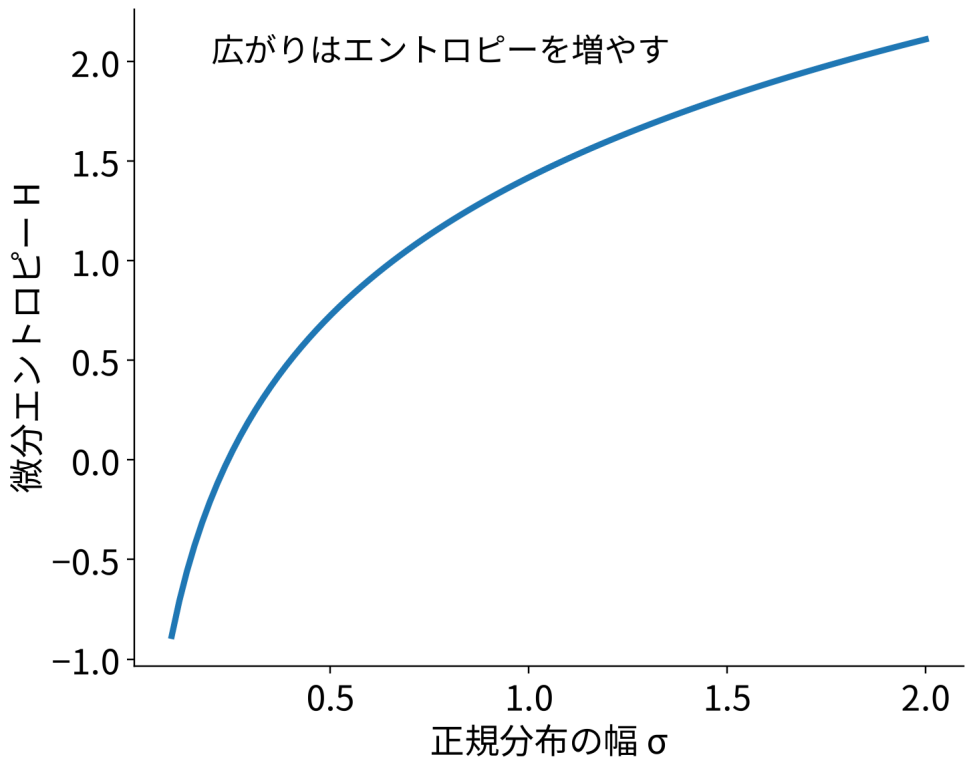
生成x=fθ(z)におけるlog qは、基底密度のlog pZから対数体積変化を引いた値。
基底分布は固定されているため、その平均もθに依存しない。
実際の損失にはエネルギーと、変換による体積変化が残る。



$$L_E = \mathbb{E}_{z\sim p_Z}[\beta U(f_\theta(z)) - \log|\det J_{f_\theta}(z)|]$$

エネルギーだけを下げると、分布が一点へ縮む

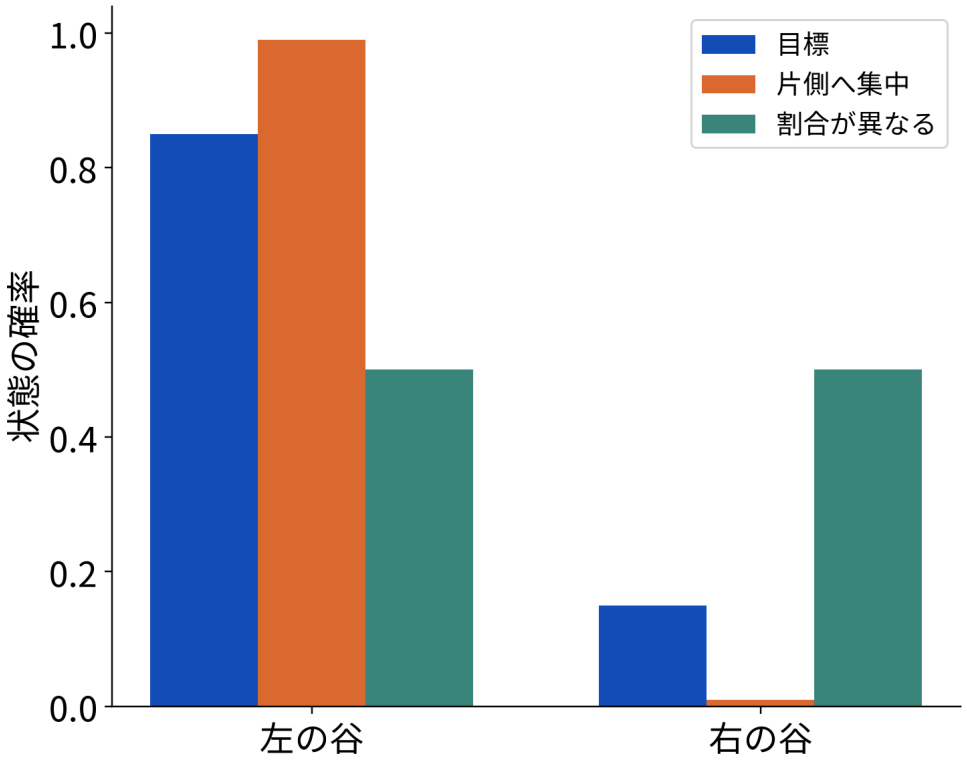
低いエネルギーだけを目指すと、最小値の近くへ全標本を集めたくなる。
負の対数体積項は、過度の圧縮を抑える。
これは平均エネルギーとエントロピーの競合であり、第09回の自由エネルギーにつながる。
右の図は正規分布の幅と微分エントロピーの例。



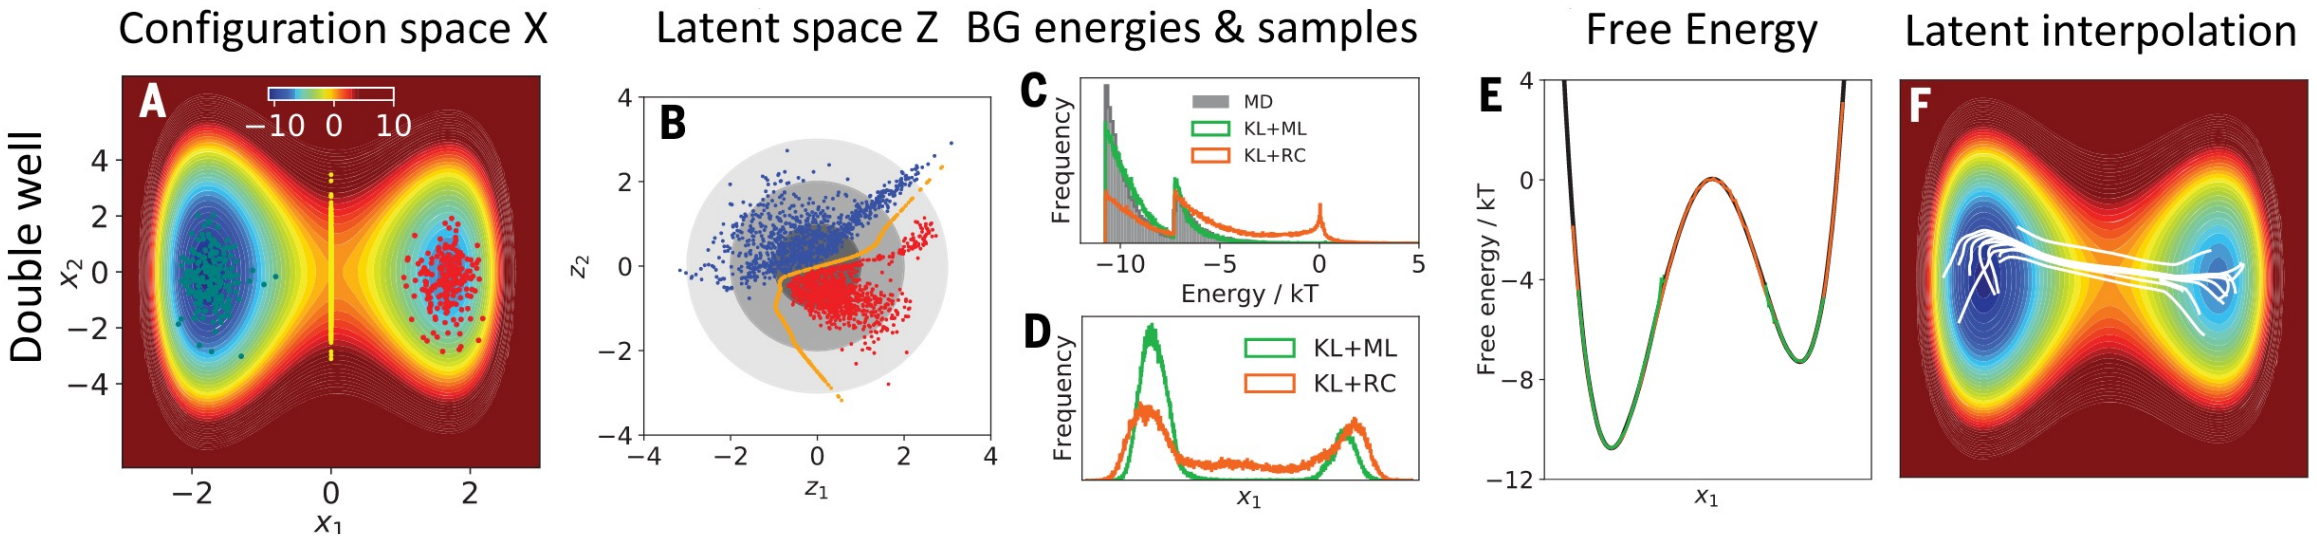
$$L_E = \beta\langle U\rangle_q - H(q) + \text{const.}, \quad H(q) = -\mathbb{E}_q \log q$$

損失が下がっても、すべての谷を見たとは限らない

逆向きKLは、現在ほとんど生成しない領域の寄与を評価しにくい。
二つの谷の片方へ偏った初期化では、もう片方を見逃す可能性がある。
データ学習・複数初期値・独立な基準計算を組み合わせる。
図は確率の偏りを示す説明用の二状態模型。



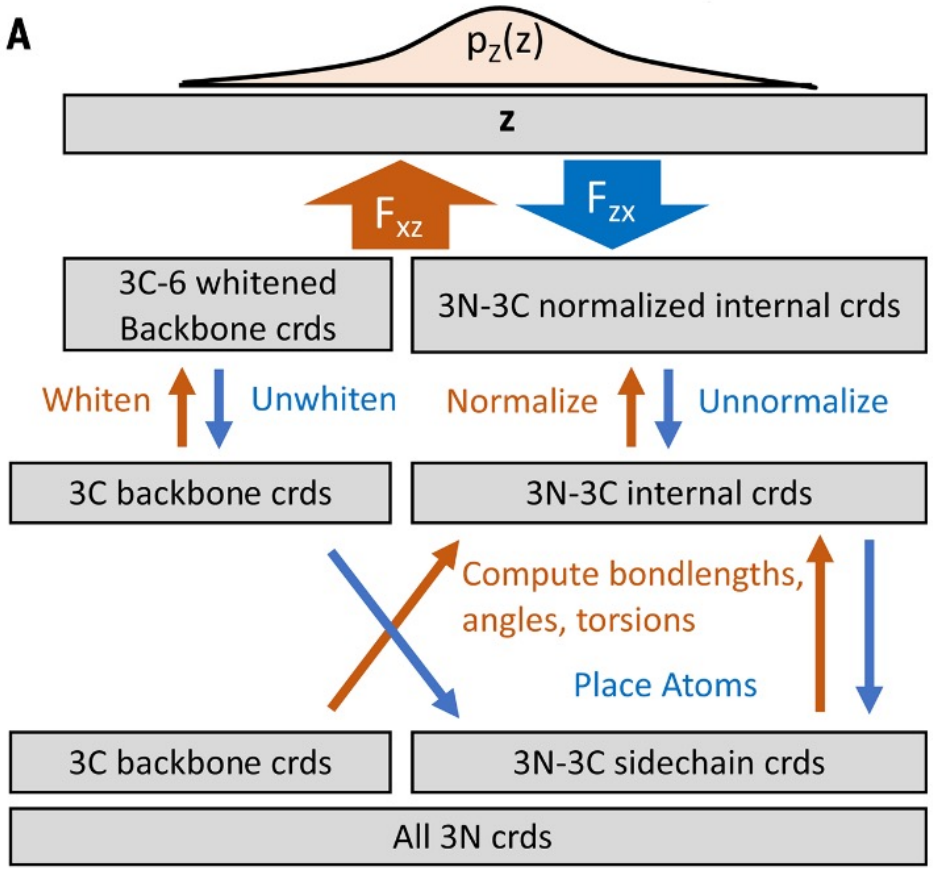
二つの谷を持つ分布を、学習とリウェイティングで再現する

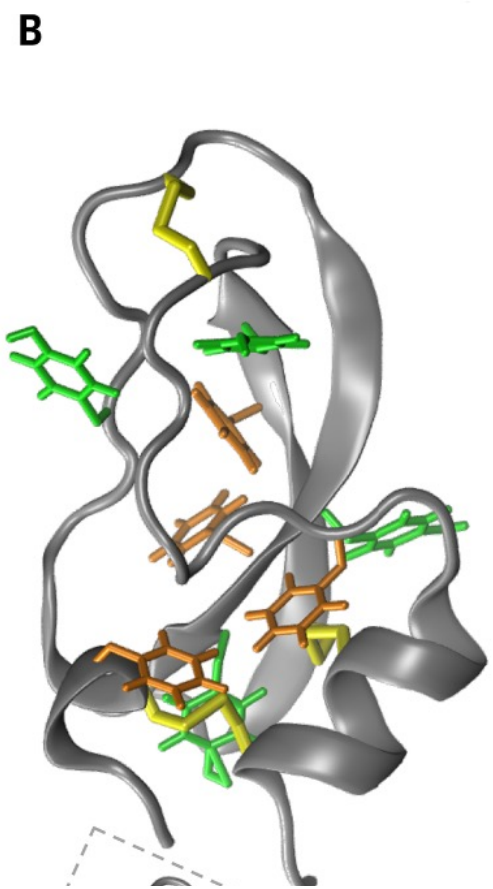


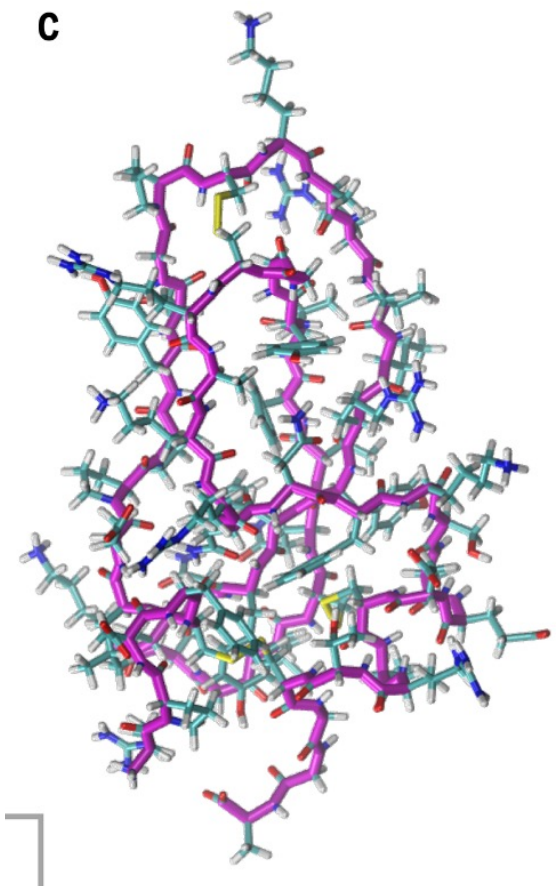
A–B：二重井戸ポテンシャルと、単純な潜在変数からの変換。
C–D：生成したエネルギーと座標の分布。E：リウェイティング後の自由エネルギー。F：潜在空間の補間から得た候補経路。
潜在空間での補間が作る候補経路は、物理的な遷移経路や時間を保証しない。

Noé et al., Science (2019), Fig. 2A–F。Muellerポテンシャルの例は付録42頁。

BPTIの原子座標を、可逆な変換で生成する





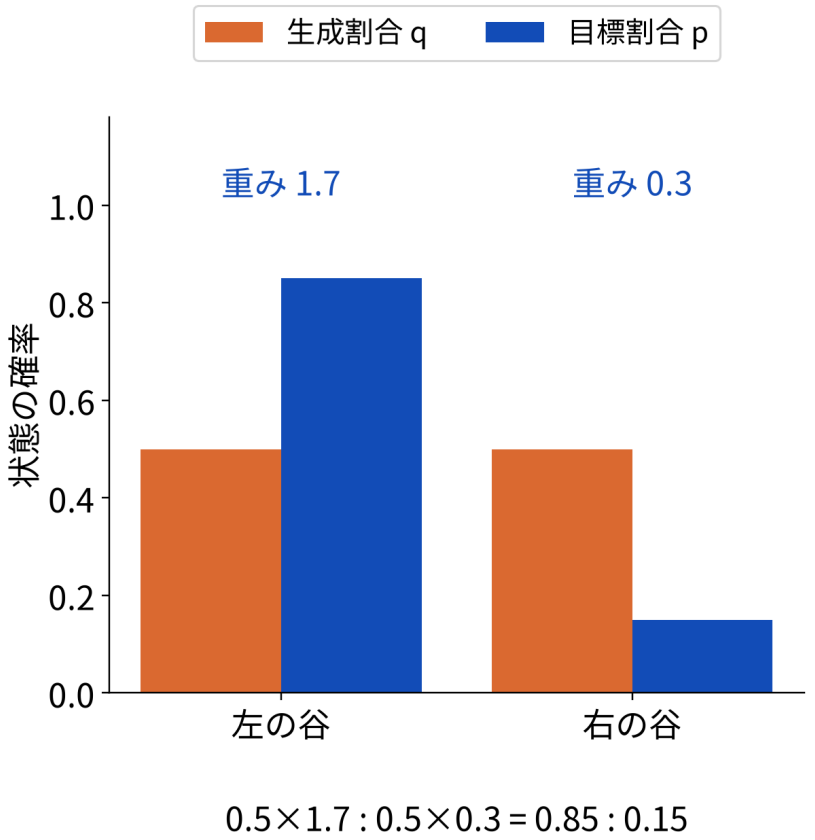


A：直交座標と内部座標を組み合わせる。B–C：主鎖・側鎖を含む構造を生成する。分布の検証は付録43頁。

Noé et al., Science (2019), Fig. 5A–C。原著のBPTI・暗黙溶媒での結果。

生成密度が分かれば、重要度で補正できる

qθから得た標本へ、目標の非正規化密度をqθで割った重みを与える。
Zは分子・分母の比で消える。
目標の重要な領域でqθが十分正であることが必要。生成していない谷は補正だけでは回復できない。

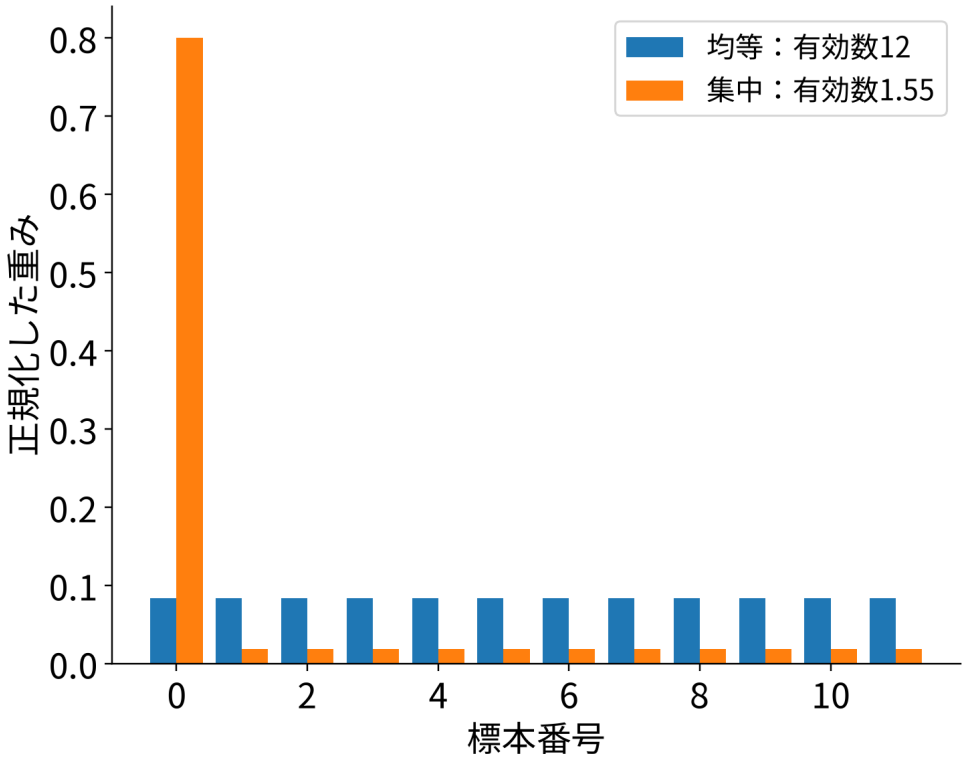


0.5×1.7 : 0.5×0.3 = 0.85 : 0.15

$$\langle A \rangle_p \approx \frac{\sum_n w_n A(x_n)}{\sum_n w_n}, \qquad w_n = \frac{e^{-\beta U(x_n)}}{q_\theta(x_n)}$$

重みが偏ると、有効標本数が減る

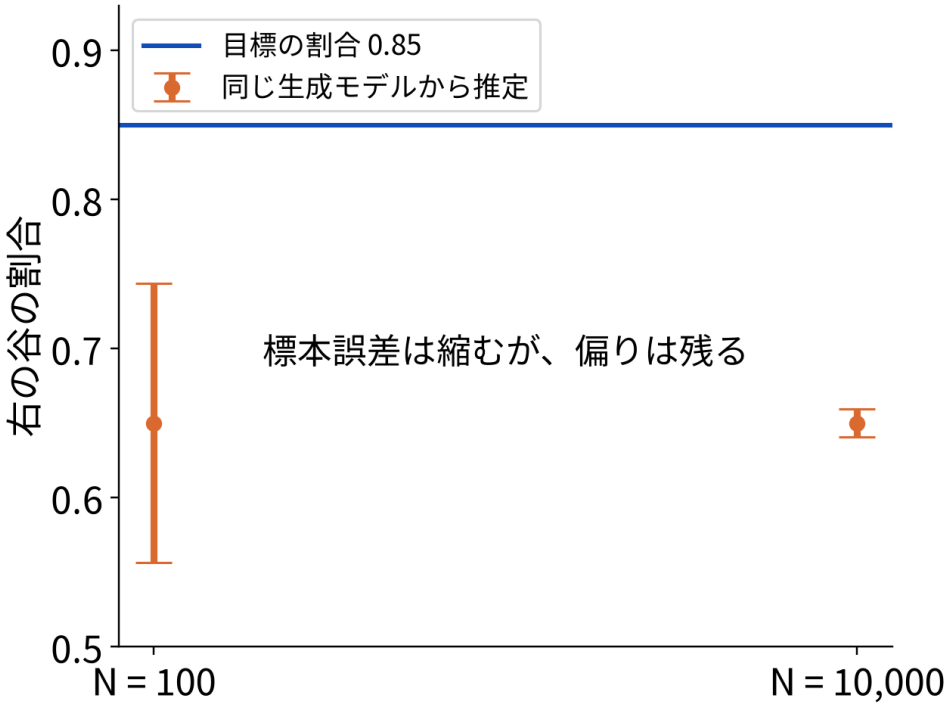
同じ数を生成しても、少数だけが大きな重みを持つと推定は不安定になる。
正規化重みを使い、有効標本数を診断する。
この指標は重みのばらつきを見るもので、未知の谷の見逃しを検出する万能な指標ではない。



$$N_{\mathrm{eff}} = \frac{(\sum_n w_n)^2}{\sum_n w_n^2} = \frac{1}{\sum_n \bar{w}_n^2}$$

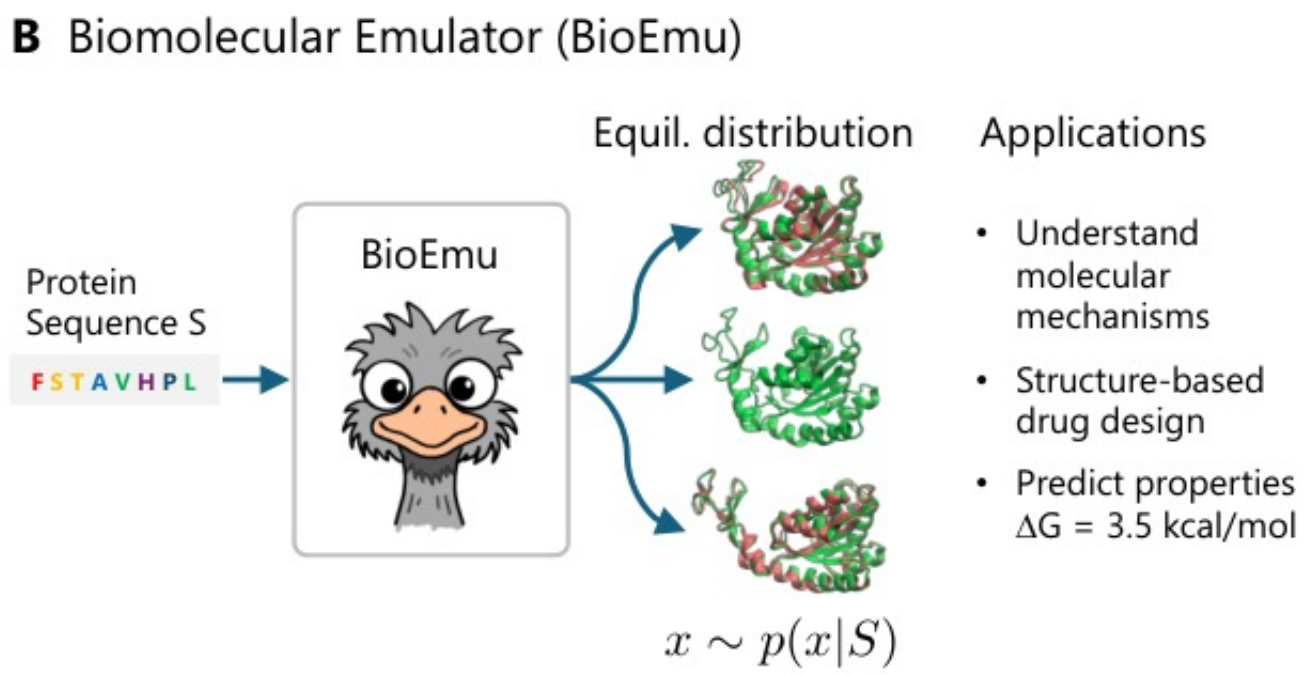
独立標本でも、学習誤差と有限標本誤差は残る

同じ学習済みモデルからの生成同士が独立であることと、モデルが正しいことは別。
比較は、分布・状態の割合・エネルギー・独立な実験量で行う。
標本数を増やせば有限標本誤差は減るが、学習モデルの偏りは自動では消えない。



誤差棒：二項分布の正規近似による約95%幅

BioEmuは構造の集まりを生成する



入力は配列で、出力は複数の立体構造です。図の右側のように、構造分布から状態の集団や自由エネルギー差を考えます。

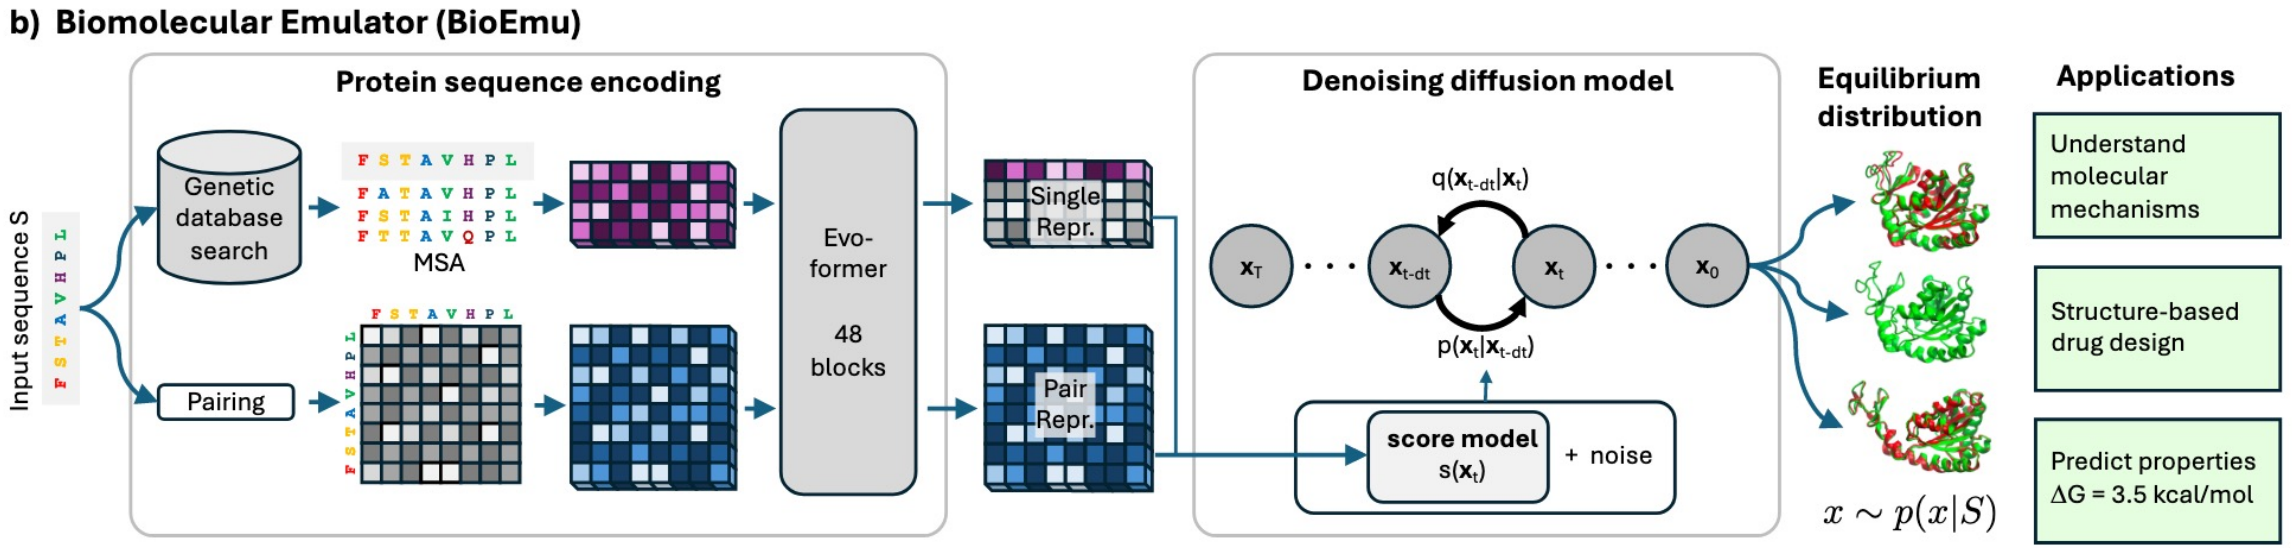
近似した平衡分布を生成するモデルです。新しい配列や条件へ適用する際は、実験や物理計算で分布の妥当性を確かめます。

多様な構造が出ることと、割合が正しいことを分ける。

Lewis et al., Science (2025), Fig. 1B（著者公開稿）

原著図／公式公開図／著者公開稿：再利用ライセンス明記なし／パネルを抜粋。色・データ改変なし。

BioEmu：配列を条件に、拡散モデルで構造アンサンブルを作る



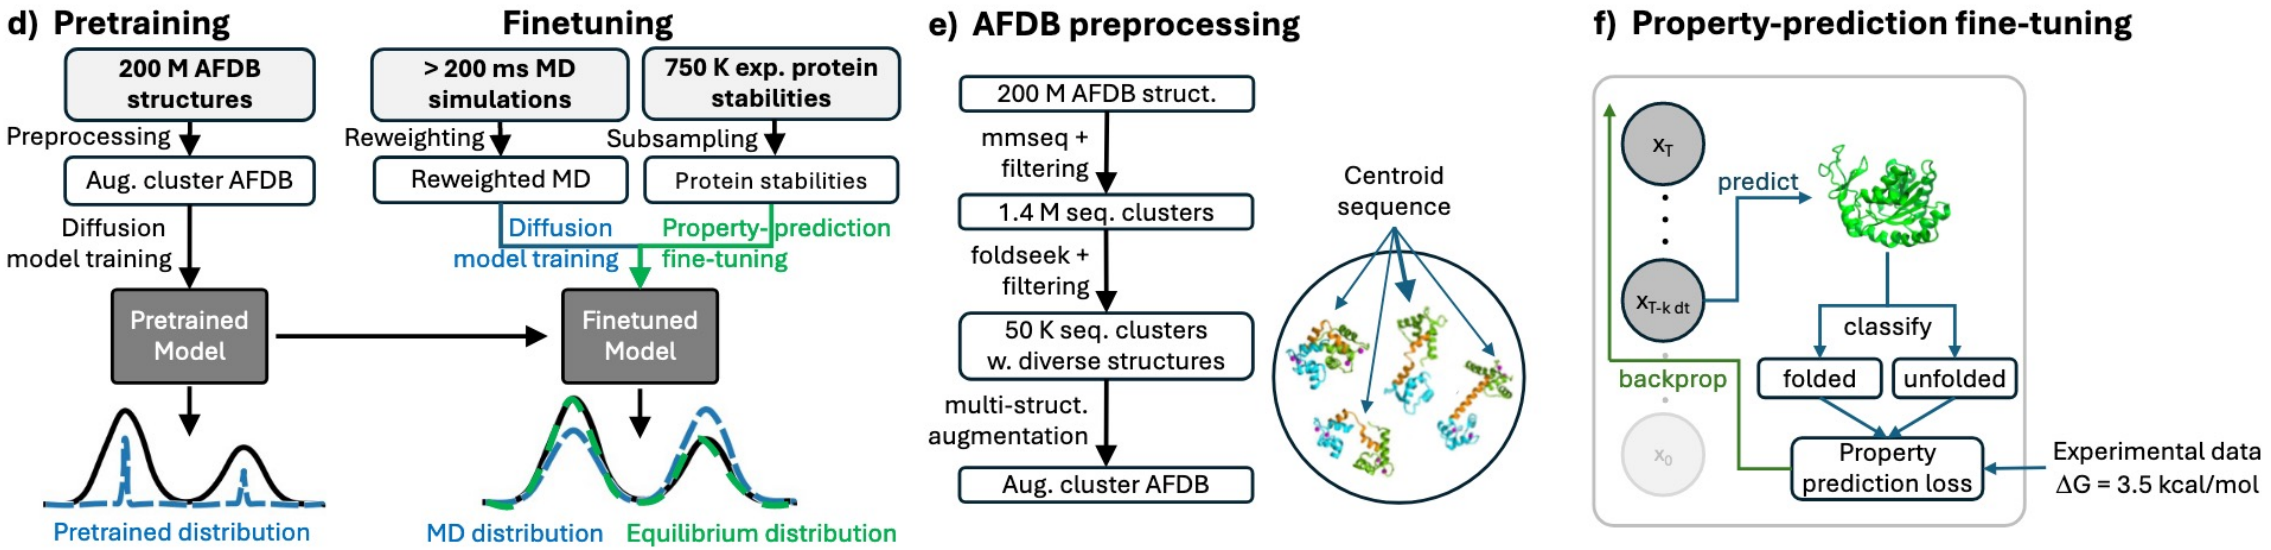
配列から特徴を作る
AlphaFold2由来の表現から、残基ごと・残基対ごとの特徴を得る。

座標の分布を学ぶ
特徴を条件に、ノイズを除く過程を使って複数の構造を生成する。

構造アンサンブルを評価する
状態の存在割合や性質を比べる。
生成順は実時間順ではない。

Lewis et al., Science (2025), Fig. 1A–C。

構造・MD・実験の情報を、段階ごとに学習へ使う



d：学習の段階
構造の生成を事前学習し、MDの構造アンサンブルや安定性の情報で調整する。

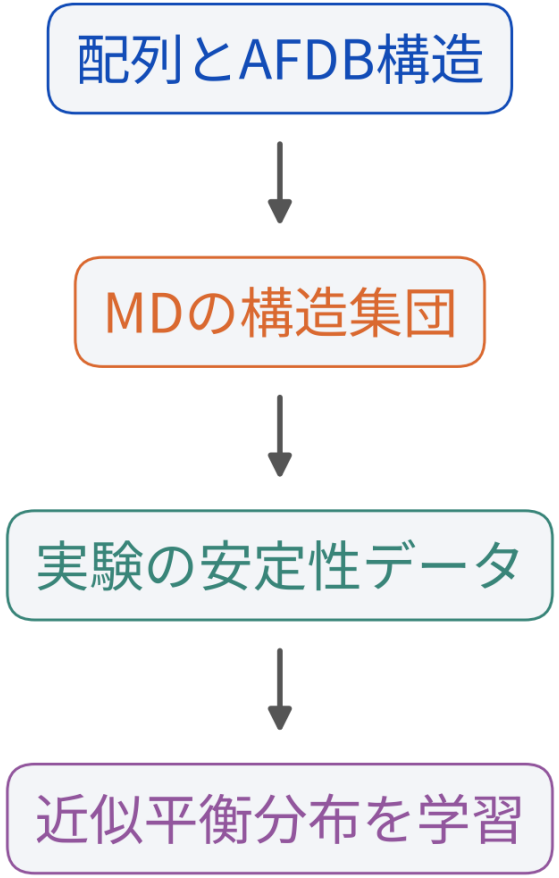
e：構造データ
AlphaFoldデータベース（AFDB）から、多様な配列と構造の対応を学ぶ。

f：性質による調整
実験の安定性情報を取り入れ、計算データだけでは決まらない部分を補う。

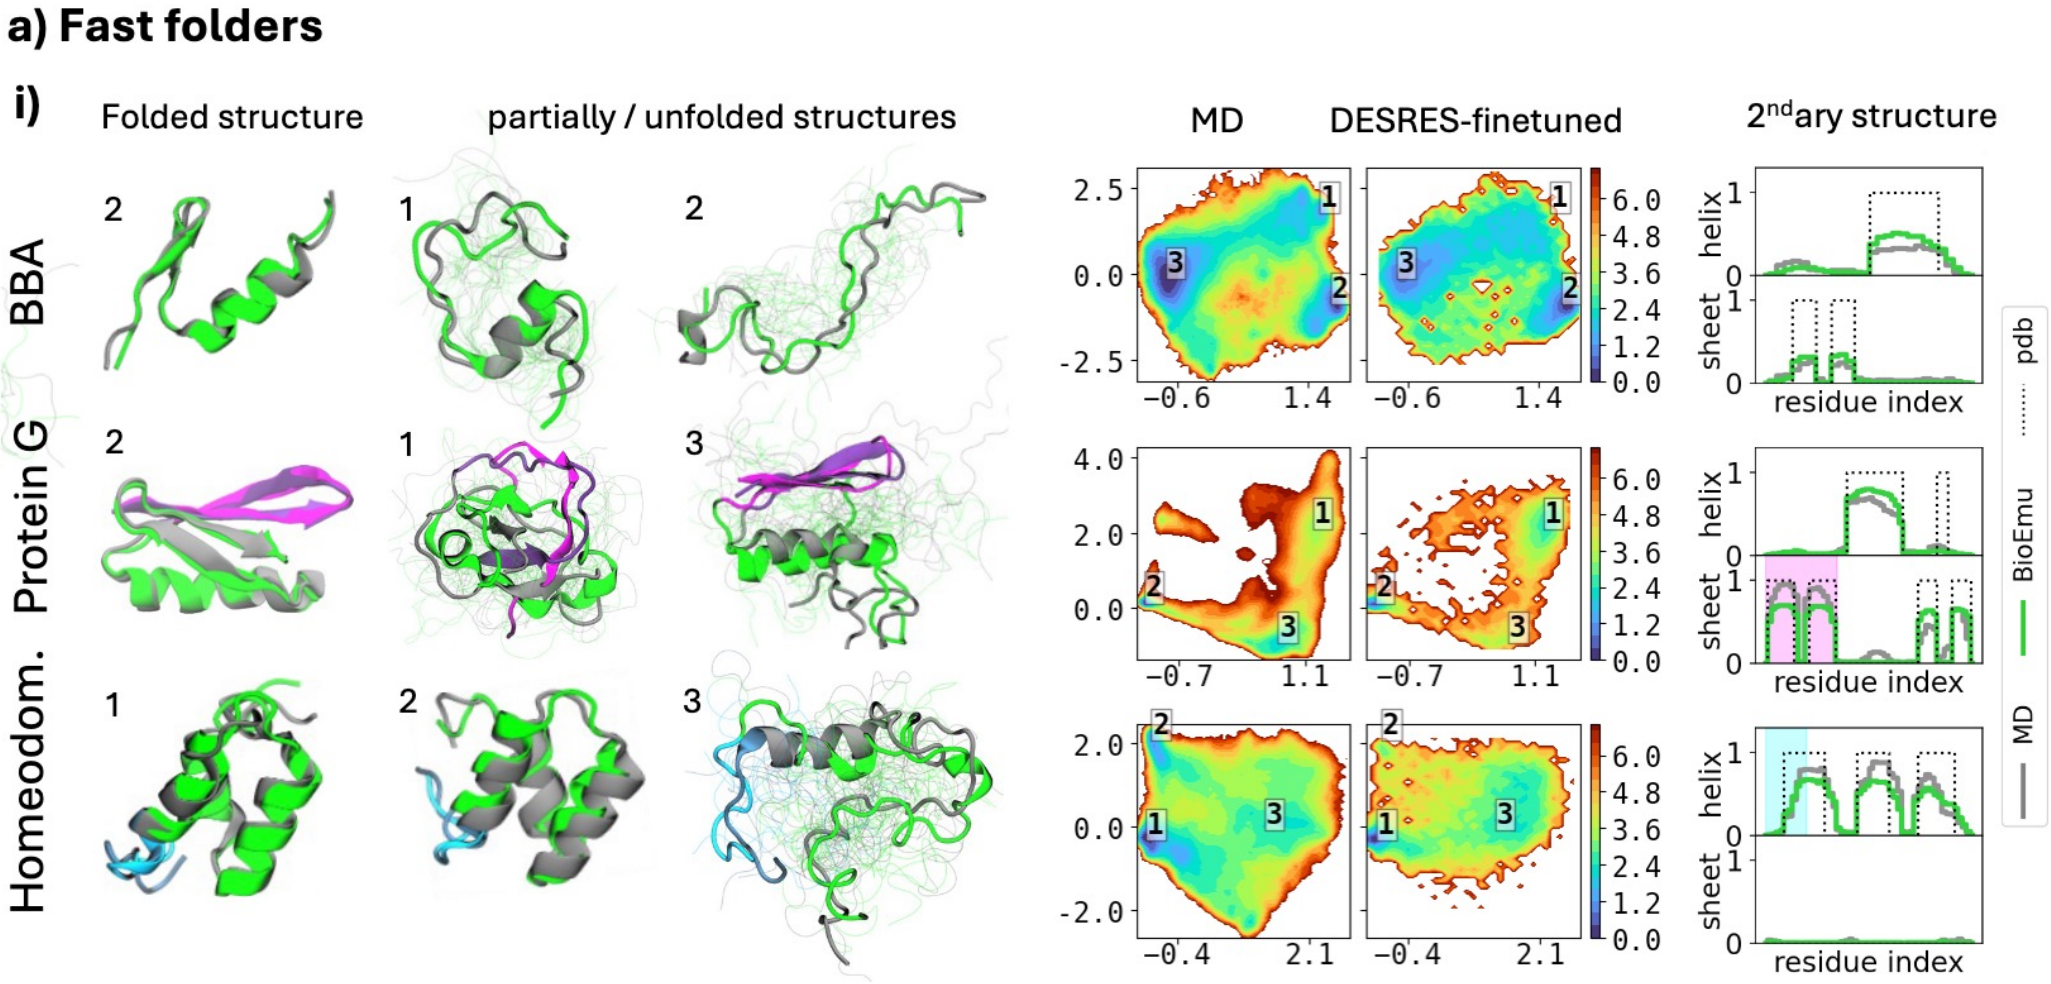
Lewis et al., Science (2025), Fig. 1D–F。各段階のデータの役割を区別する。

BioEmuは学習データの役割を分けて使う

AFDBの構造は配列と構造の対応を、MDは一つの配列が取り得る集団を与える。
実験の安定性情報も学習に使い、計算だけの偏りを補う。
同じ「生成」でも、正規化flowと拡散モデルでは密度評価の仕組みが異なる。BGの重み式を、そのままBioEmuへ適用できるとは限らない。



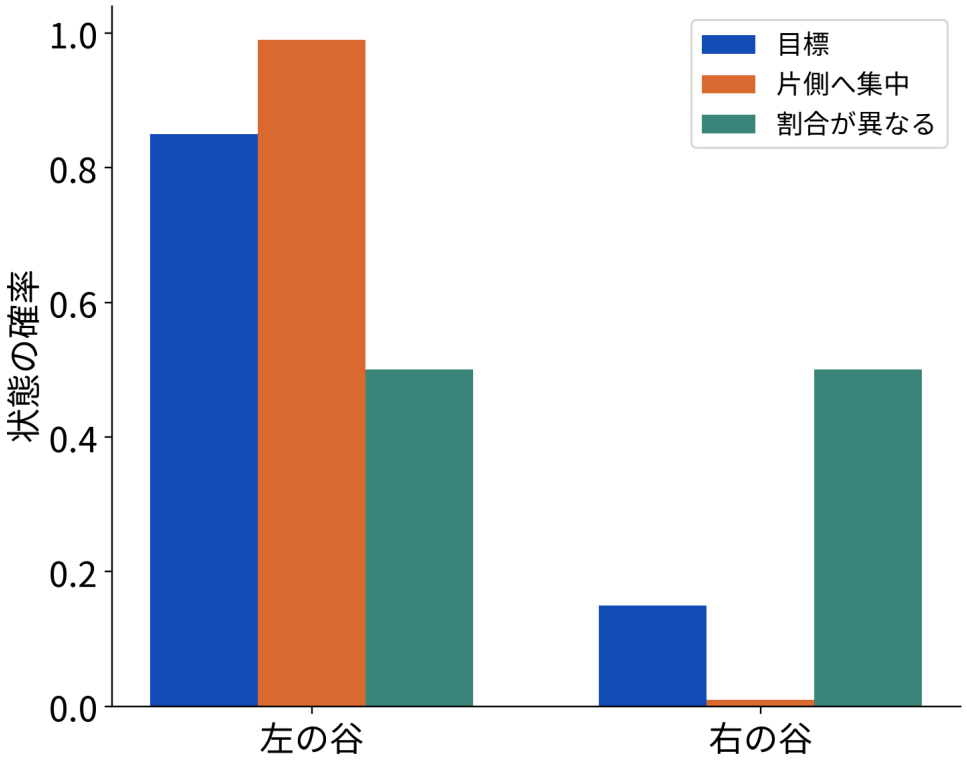
参照MDと比べ、構造の分布と存在割合を確かめる



Lewis et al., Science (2025)。左：構造、中央：MDと生成分布、右：二次構造。分布の比較であり、遷移速度の検証ではない。

多様性と、正しい存在割合を分けて評価する

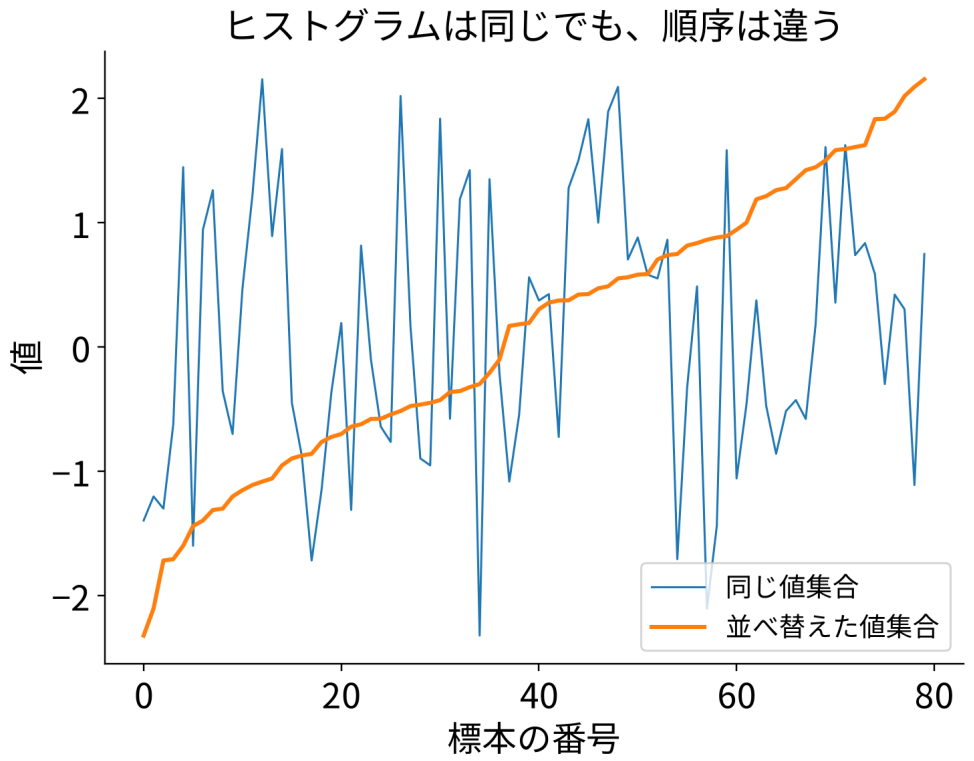
異なる形が出たことだけでは、自由エネルギー差は分からない。
二つの状態A・Bの確率がpA・pBなら、その比から自由エネルギー差を求める。
構造生成モデルの割合を用いるには、目的の条件で分布の妥当性を検証する必要がある。



$$F_B - F_A = -k_B T \log(p_B / p_A)$$

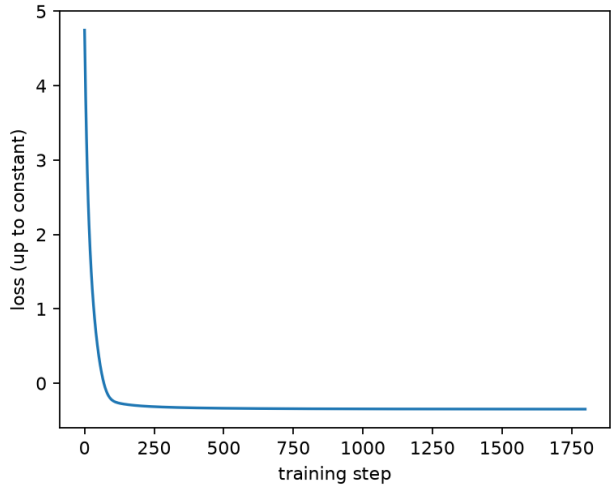
構造アンサンブルから、時間の順序は復元できない

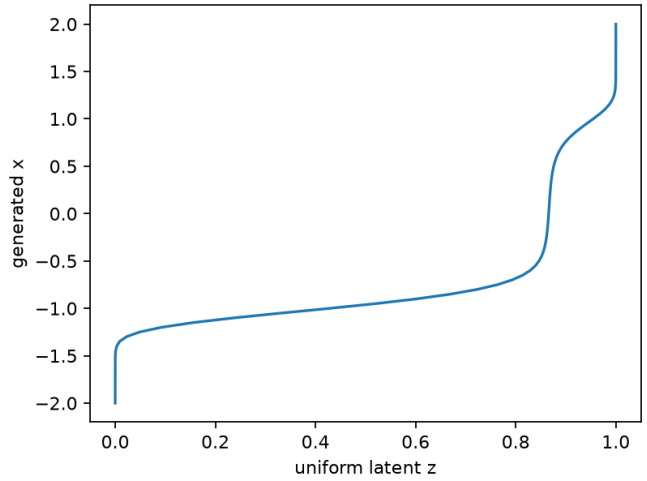
右の二つの系列は同じ値の集合で、ヒストグラムも同じ。
しかし隣り合う値の関係は異なる。
平衡分布は存在割合を与えるが、遷移速度・経路・時間相関には動力学の情報が必要。
拡散モデルの生成ステップも、物理時間ではない。

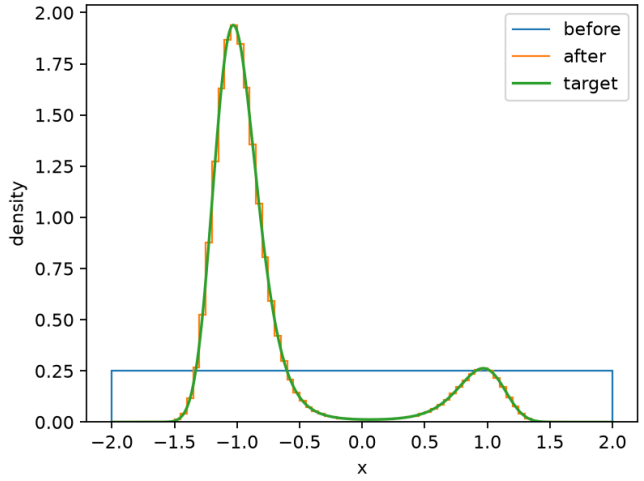


演習の模型は、一様乱数を単調な折れ線で変換する

xの区間[−2,2]を80個に分ける。各区間の確率piをsoftmaxで正に保つ。
潜在区間の長さpiを、座標区間の幅Δxへ写す。傾きはΔx/pi、密度はpi/Δx。
目標分布も同じ有限区間で正規化する。タンパク質モデルの再現ではなく、原理の実装例。



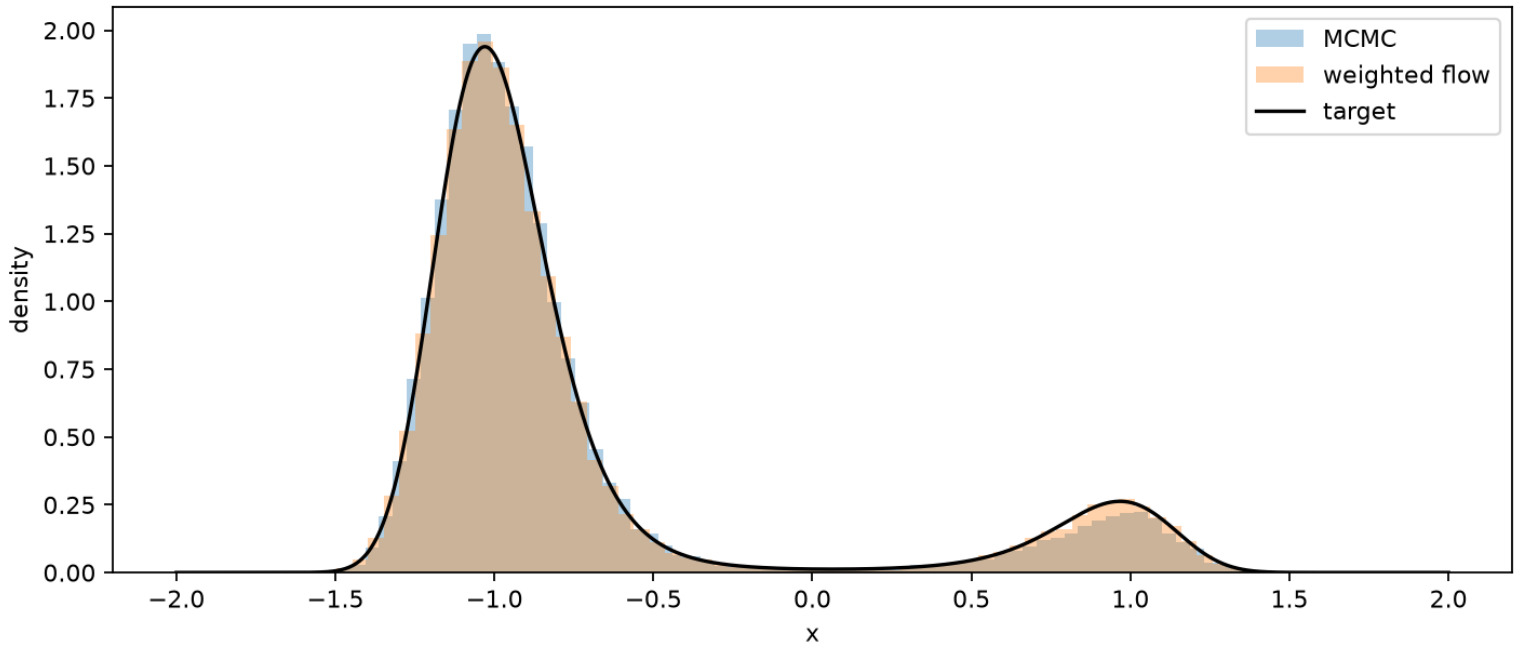




$$x = x_i + (z - c_i)\frac{\Delta x}{p_i}, \quad q(x) = \frac{p_i}{\Delta x}$$

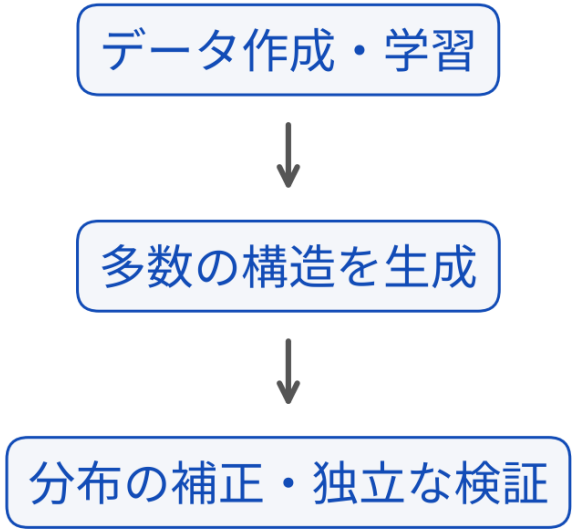
学習前後の密度と、補正後の割合を比較する

学習前は座標区間で一様。学習後は二つの谷へ確率が集まる。
有限個の区間を使うため、密度は階段状になる。
生成密度とエネルギーから重みを計算し、右の谷の割合を理論積分と比べる。
下図は今回のNotebookの実行結果。



学習・補正・検証も含めて計算量を比べる

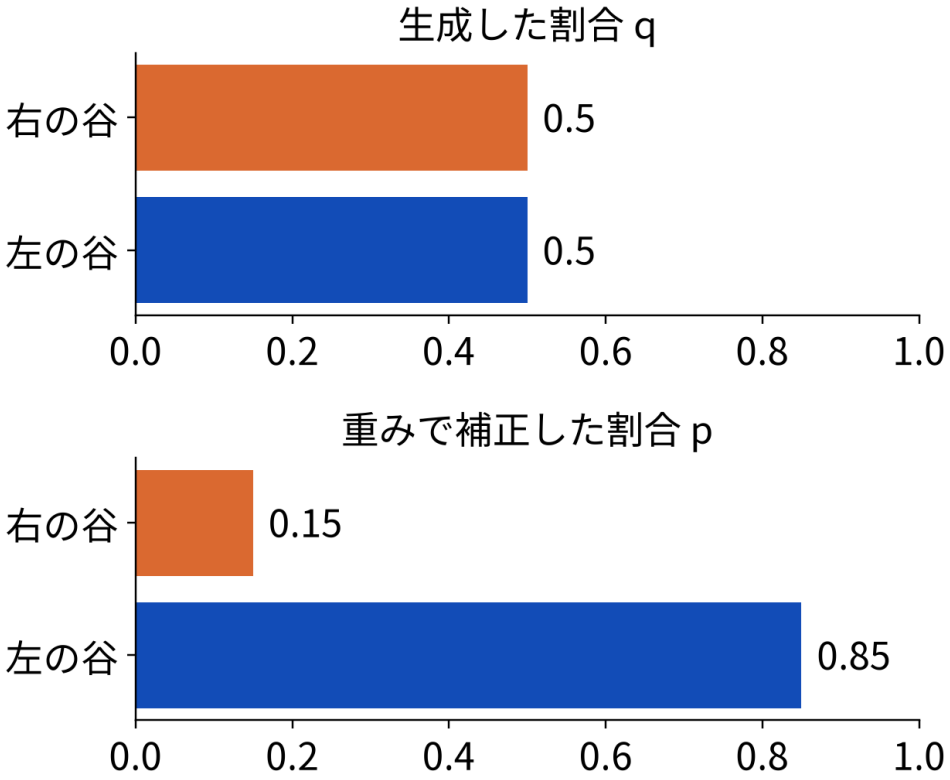
MDは運動方程式をその都度解く。生成モデルは事前の学習を経て標本を作る。
生成一回の速さだけでなく、学習データの作成・学習・補正・適用範囲の検証を含めて考える。
新しい配列や条件へ使うときは、分布の誤差を再確認する。



一回の生成時間だけでなく、全体の計算量を比べる

まとめ：変換・密度・学習・補正をつなぐ

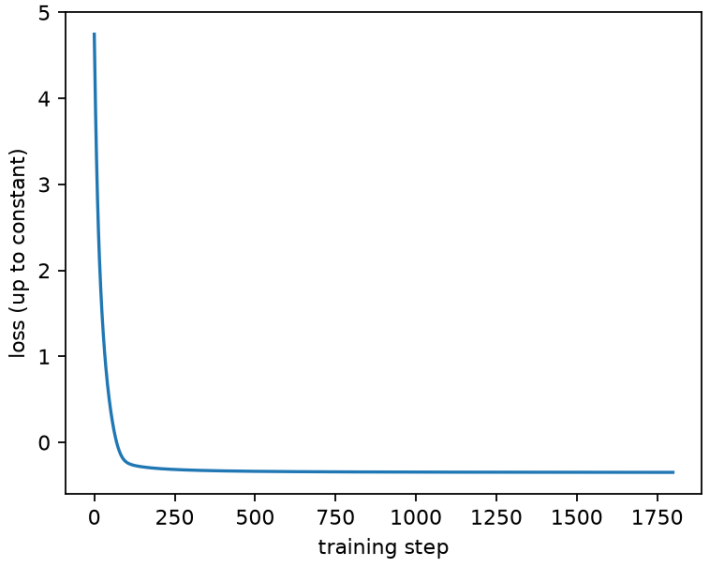
BGでは可逆変換を学習し、生成密度を使って目標分布とのずれを補正する。重要な領域を十分に生成できることが条件となる。
冒頭の問いへの答え：標本生成を速める可能性はあるが、学習・補正・検証を含む計算量と精度で判断する。
BioEmuも構造アンサンブルを生成する。多様性と存在割合を別に検証し、生成順を物理時間と解釈しない。

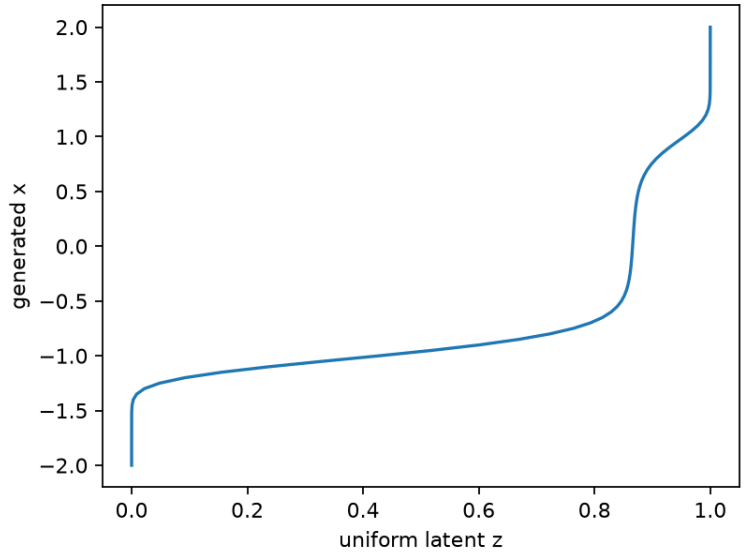


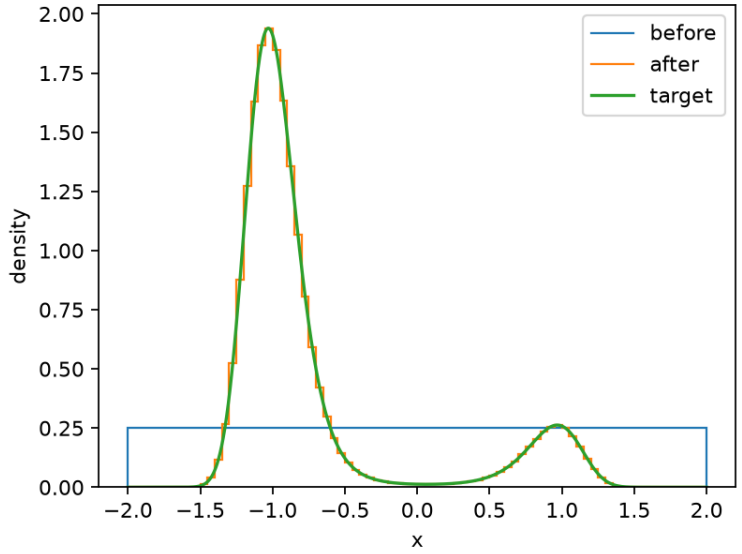
演習：小さな生成モデルを学習する

20分・採点なし。13_演習.ipynbを使う。

1　正の区間確率と、可逆な折れ線の関係を見る。
2　エネルギーと密度の損失を学習し、前後の分布を比較。
3　リウェイティング後の右の谷の割合を、理論・MCMCと比べる。
4　区間数を変え、近似の細かさを観察して結果を保存する。





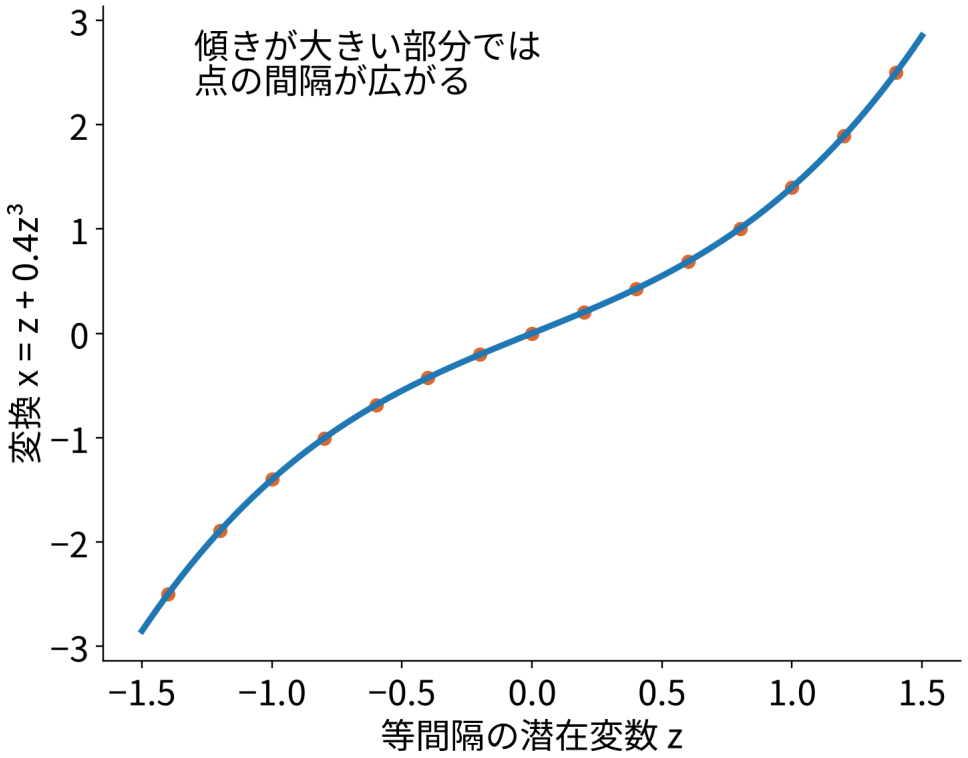


付録：導出と補足資料

ここからは本編の補足です。
導出の途中式、計算条件、研究例の詳細を示します。
本編の各手法の前提と対応させて読んでください。

変数変換の式を、微小領域の確率から導く

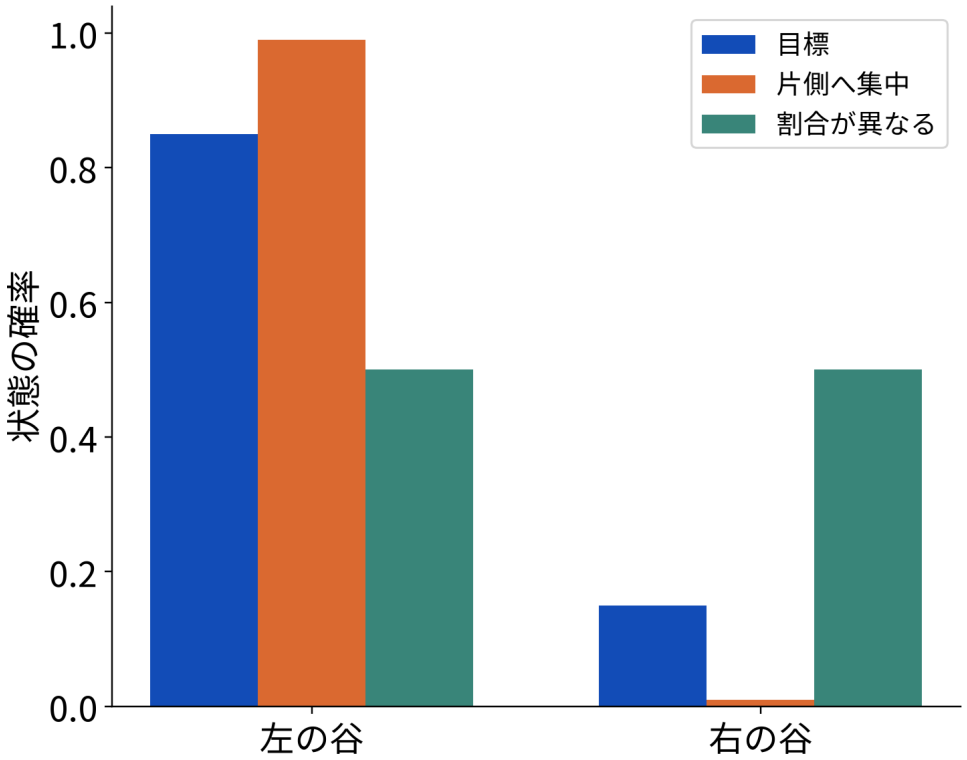
微小領域dzを変換すると、体積は|det J|dzになる。
その領域の確率が保存されることから、密度変換の式が得られる。
可逆性があればxからzを一意に戻せる。
向きに依存しない体積を扱うため絶対値を用いる。



$$p_Z(z)dz = q_X(f(z))|\det J|dz$$

KLの二つの向きを、平均する分布から区別する

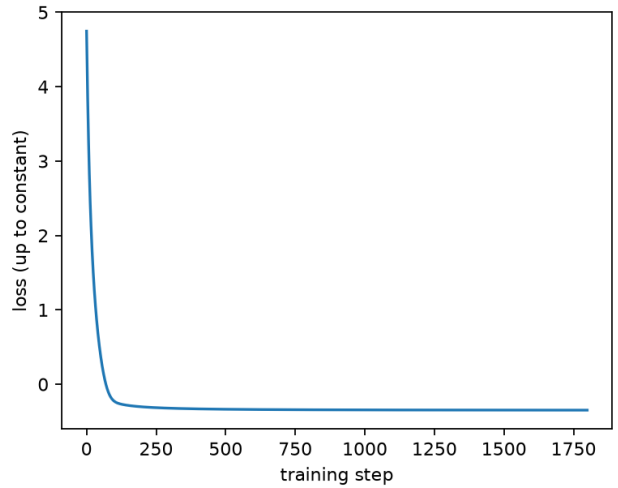
データからの学習はp側から標本を取る。
エネルギー学習は生成q側から標本を取る。
いずれもp=qで最小だが、有限なモデルや標本では学習中の挙動が違う。
KLは距離のように使うが、対称ではない。

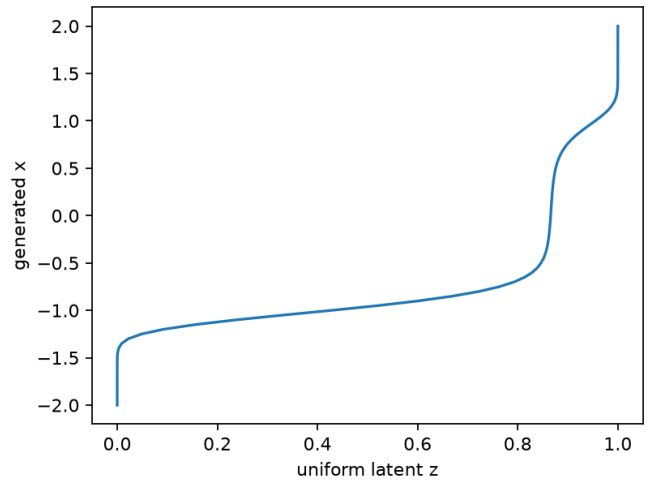


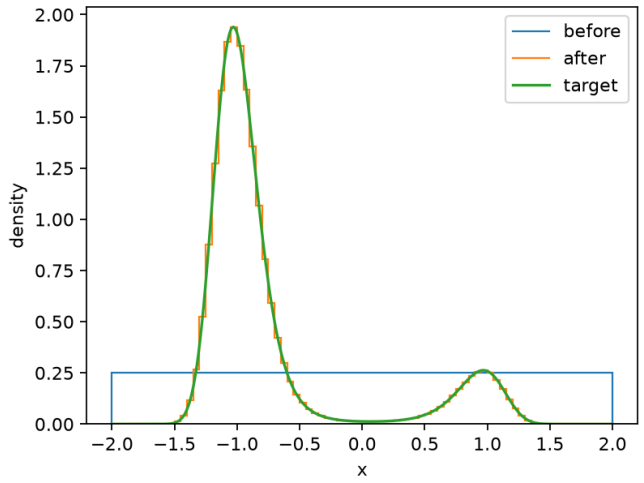
$$D_{\mathrm{KL}}(p\|q) = \mathbb{E}_p \log(p/q), \quad D_{\mathrm{KL}}(q\|p) = \mathbb{E}_q \log(q/p)$$

演習の区間損失は、区間内の積分で計算する

区間iではq=pi/Δxが一定。したがってlog qも一定。
平均エネルギーŪiは区間内のUの積分を幅で割る。
この模型では多項式を厳密に積分でき、学習中の標本誤差を避けられる。
有限区間・区分一定密度による近似は残る。







$$L = \sum_i p_i \left[\beta \bar{U}_i + \log \frac{p_i}{\Delta x} \right], \quad \bar{U}_i = \frac{1}{\Delta x} \int_{x_i}^{x_{i+1}} U(x) dx$$

リウェイティングは、確率密度の比から導ける

観測量の積分へ1を掛ける

$$\langle A\rangle_0 = \int A(x)\pi_0(x)\,dx$$

$$= \int A(x)\frac{\pi_0(x)}{\pi_B(x)}\pi_B(x)\,dx$$

$$\frac{\pi_0(x)}{\pi_B(x)} = \frac{Z_B}{Z_0}e^{\beta B(x)}$$

$$\langle A\rangle_0 = \frac{\langle Ae^{\beta B}\rangle_B}{\langle e^{\beta B}\rangle_B}$$

分母はA=1の同じ式を用いて未知のZB/Z0を除いたもの。

なぜ正の指数で補正するか

バイアスでエネルギーを上げた配置は、標本中では少なくなる。補正はその配置の重みを増やすので、指数は+βBとなる。

$$w_n = e^{\beta B(x_n)},\quad \widehat{A} = \frac{\sum_n w_n A(x_n)}{\sum_n w_n}$$

数値例：訪れた回数と、元の割合は違う

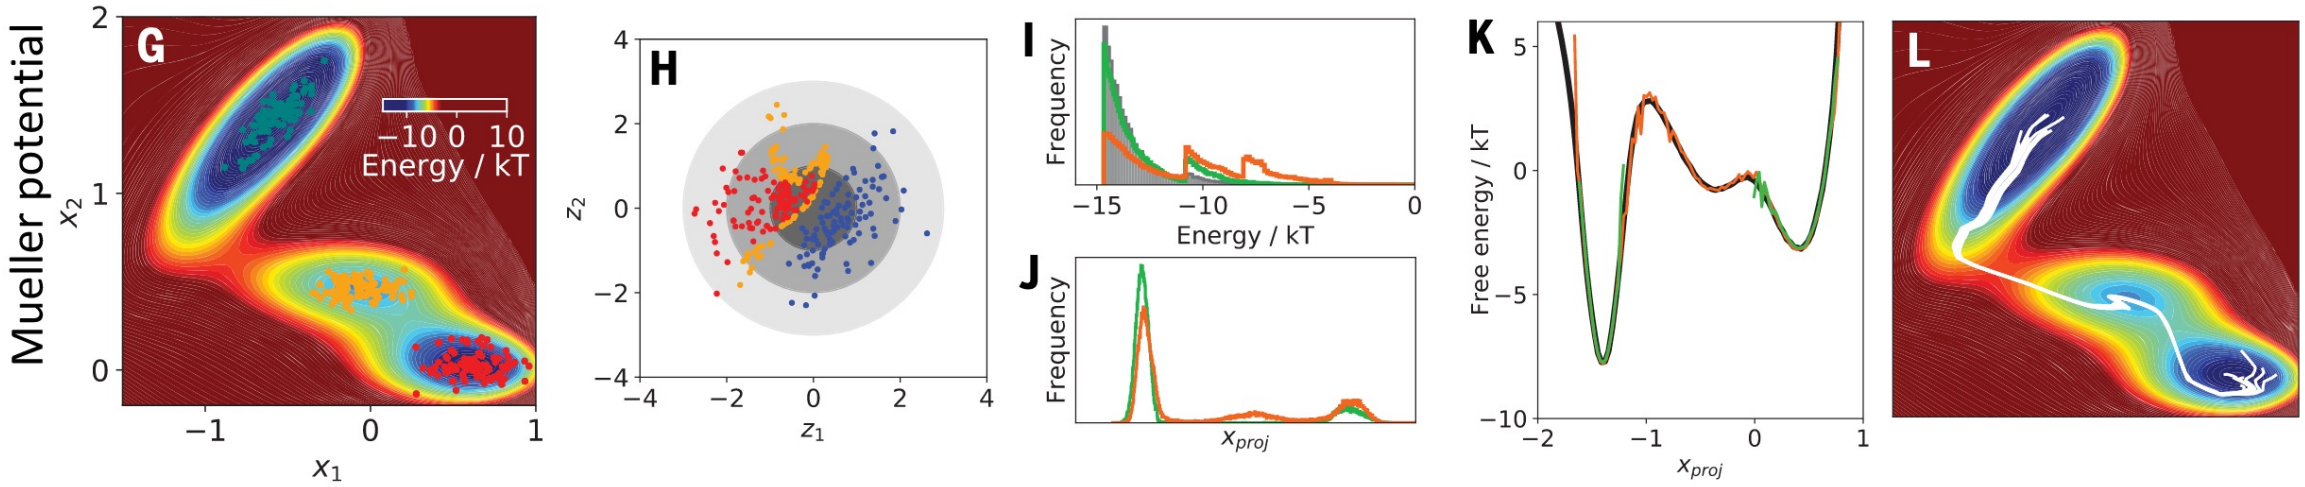
AとBを同数観測し、加えたバイアスがそれぞれ0とkBT ln 3なら、補正重みは1と3。元の割合は1:3となる。

$$N_{\mathrm{eff}}^{(w)} = \frac{(\sum_n w_n)^2}{\sum_n w_n^2}$$

一つの重みが支配すると有効な情報が減る。この式は重みの偏りの指標であり、時間相関は別に扱う。

バイアス付き分布 πB ∝ exp[−β(U+B)] の例。Torrie & Valleau (1977); Shirts & Chodera (2008)。

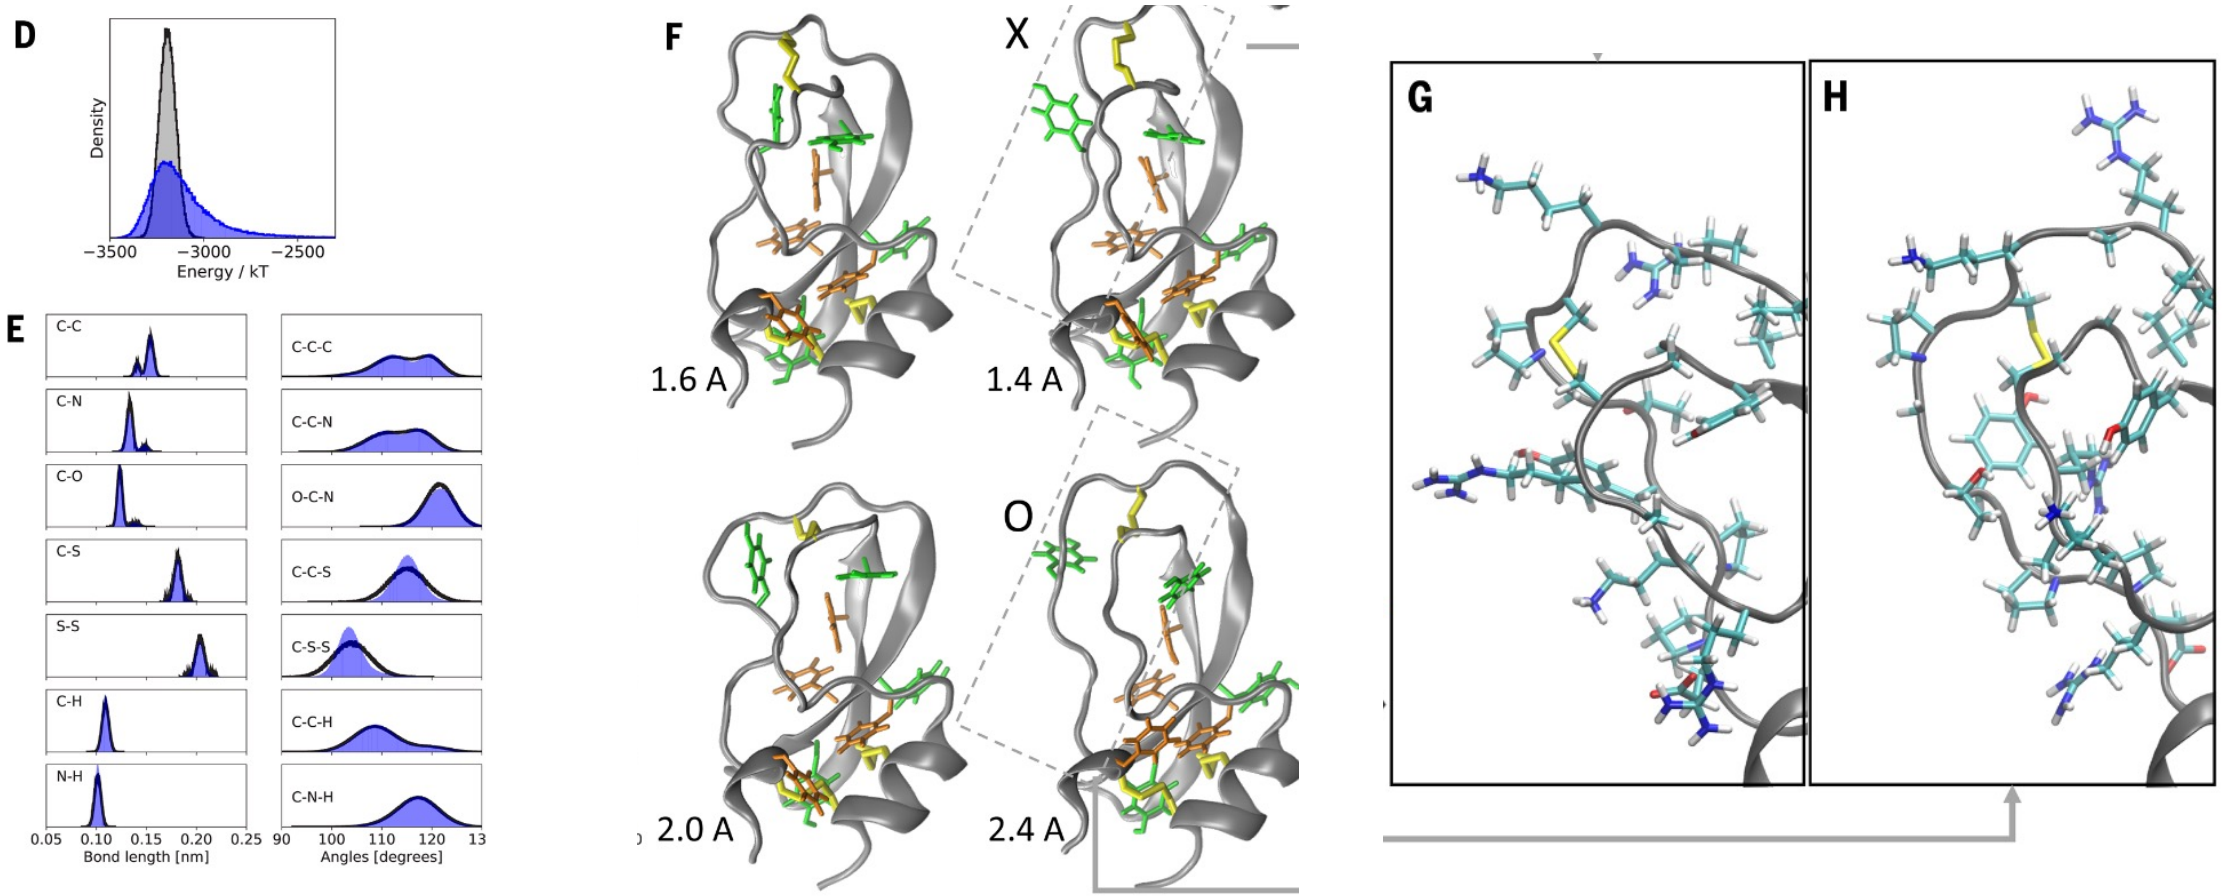
付録：Muellerポテンシャルでも分布と経路を比べる



G–H：複数の谷を持つ2次元のエネルギー面と、潜在空間での表現。I–J：生成したエネルギーと、投影座標の分布。
K：リウェイティング後の自由エネルギー。L：潜在空間の補間から得た候補経路。
滑らかな補間は候補構造の列を作る操作であり、物理的な時間発展を与えるものではない。

Noé et al., Science (2019), Fig. 2G–L。原著パネルを拡大。

付録：BPTIのエネルギー・局所構造・構造アンサンブルを評価する



D–E：エネルギーと結合幾何。F：閉じた構造X・開いた構造O。G–H：局所配置を比較し、ずれを調べる。

Noé et al., Science (2019), Fig. 5D–H。BPTI・暗黙溶媒での評価。

原著・実装と、授業の模型

Boltzmann generators：Noé, Olsson, Köhler & Wu, Science 365, eaaw1147 (2019)。DOI:10.1126/science.aaw1147
BioEmu：Lewis et al., Science (2025)。DOI:10.1126/science.adv9817
公式実装：github.com/microsoft/bioemu
授業の1次元折れ線モデルは、原著の考え方を単純化した実装。原著モデルの性能評価とは区別する。