生命情報工学特論　第13回

構造集団を生成するAI

簡単な乱数から、目標の分布に
従う構造を作る

松永 康佑

埼玉大学 大学院理工学研究科
理化学研究所 計算科学研究センター

2026年12月21日

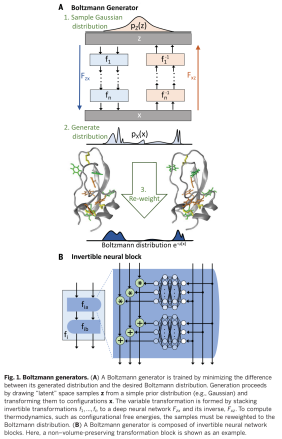


Fig. 1. Boltzmann generators. (**A**) A Boltzmann generator is trained by minimizing the difference between its generated distribution and the desired Boltzmann distribution. Generation proceeds by drawing "latent" space samples **z** from a simple prior distribution (e.g., Gaussian) and transforming them to configurations **x**. The variable transformation is formed by stacking invertible transformations $f_1, \ldots, f_6$ to a deep neural network F_{θ}, and its inverse, F_{θ}^{-1}. To compute thermodynamics, such as configurational free energies, the samples must be reweighted to the Boltzmann distribution. (**B**) A Boltzmann generator is composed of invertible neural network blocks. Here, a non–volume-preserving transformation block is shown as an example.

生命情報工学特論

簡単な乱数から、目標の分布に従う構造を作る

簡単な乱数から、目標の分布に
従う構造を作る。
サンプルしやすい基底分布を、可逆な変換で複雑な分布へ写す。
密度を計算できれば、エネルギーによる学習や重み補正につなげられる。
生成の順番から反応速度は求まらない。

簡単な独立乱数 z
↓
可逆な変換 fθ
↓
構造 x と密度 qθ(x)
↓
エネルギーと重みで評価

生命情報工学特論

分布の変換・学習・評価をつなぐ

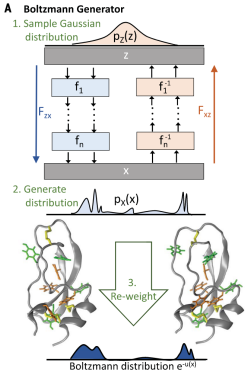
1　座標の変換と確率密度
2　可逆なニューラルネットと体積変化
3　データ・エネルギーからの学習
4　重み補正とBioEmuの構造集団
5　二つの谷を生成する小さな模型

簡単な独立乱数 z
↓
可逆な変換 fθ
↓
構造 x と密度 qθ(x)
↓
エネルギーと重みで評価

既存の計算手法における課題

- 分子動力学シミュレーションは時空間解像度に優れた情報を与えてくれるが計算に時間がかかる
- AIモデルを使って分子動力学シミュレーションを模倣することで、代理計算を高速に実行できないか？

Boltzmann generator (Normalizing flow based)



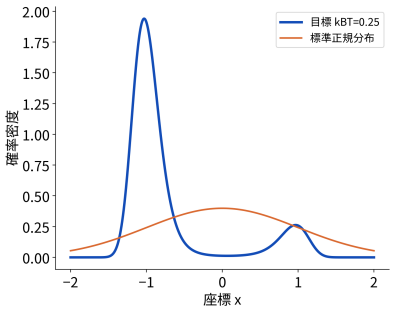
F. Noé, S. Olsson, J. Köhler, and H. Wu, Boltzmann generators: Sampling equilibrium states of many-body systems with deep learning, Science **365**, eaaw1147 (2019).

潜在変数の簡単な分布を、可逆変換で構造分布へ写す。Noé et al., Science 365, eaaw1147 (2019)。

生命情報工学特論

独立な乱数を変換すれば、独立な標本を得られる

基底分布：標準正規分布や一様分布など、容易に乱数を引ける分布。
fθ：パラメータθを学習する座標変換。入力と出力は同じ次元とする。
学習済みの同じ変換を独立な乱数へ適用すると、出力も独立になる。ただし目標分布に一致するかは別の問題。

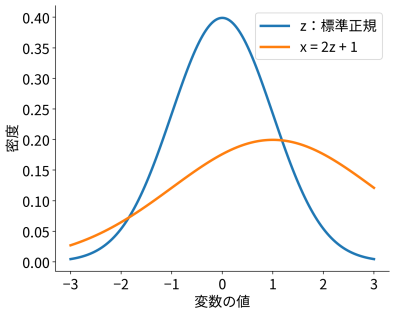


$$z \sim p_Z(z), \qquad x = f_\theta(z), \qquad x \sim q_\theta(x)$$

生命情報工学特論

変数を2倍に伸ばすと、密度は半分になる

zの幅1の区間が、x=2z+1では幅2へ広がる。
区間に入る確率は変わらないため、単位長さあたりの密度は半分になる。
標準正規分布は、平均1・標準偏差2の正規分布へ変わる。
この「確率を保つ」条件を一般化する。

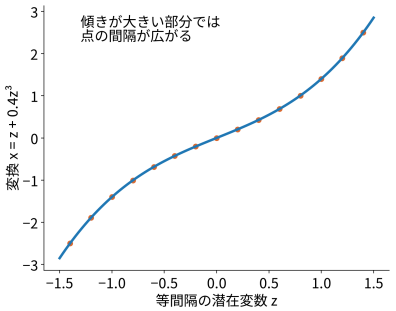


$$q_X(x) = \frac{1}{2} p_Z\left(\frac{x-1}{2}\right)$$

生命情報工学特論

一般の1次元変換では、局所の傾きで割る

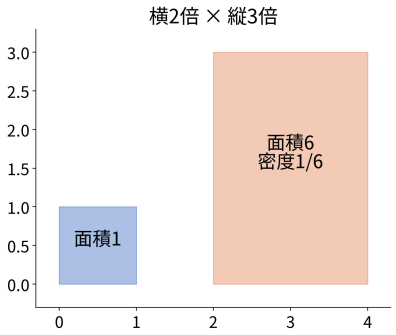
微小区間では、曲線を傾きf'の直線で近似できる。
dx=|f'(z)|dzだから、同じ確率が入る区間の長さが変わる。
図では外側ほど点の間隔が広がり、密度は低くなる。
絶対値は向きが反転する変換にも対応するため。



$$q_X(x)\,dx = p_Z(z)\,dz, \quad q_X(f(z)) = \frac{p_Z(z)}{|f'(z)|}$$

多次元では、長さの伸びを体積の伸びへ置き換える

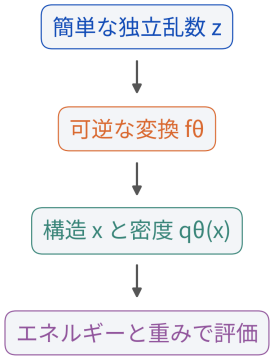
ヤコビ行列Jのij成分は、入力zのj成分を変えたときの出力xのi成分の変化。
微小な箱が平行多面体へ変わり、その体積比が|det J|になる。
例：二方向に2倍と3倍へ伸ばせば、面積は6倍、密度は1/6になる。



$$J_{ij} = \frac{\partial f_i}{\partial z_j}, \quad q_X(f(z)) = p_Z(z)|\det J|^{-1}$$

対数密度を使うと、層ごとの変化を足せる

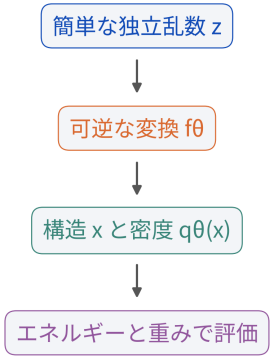
複数の可逆な層を順に適用する。
合成変換のヤコビ行列は行列積になり、行列式も積になる。
対数を取ると、各層の対数体積変化の和になる。
密度を計算しやすい層を重ねることがnormalizing flowの設計の要点。



$$\log q_X(x) = \log p_Z(z) - \sum_\ell \log|\det J_\ell|$$

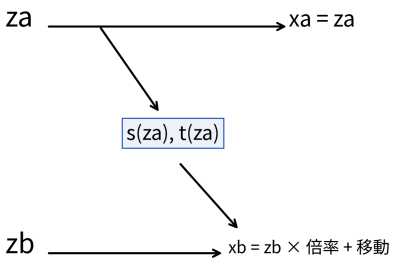
可逆であることと、逆変換が計算しやすいこと

任意のニューラルネットは、異なる入力を同じ出力へ潰すことがある。
その場合、元の入力や密度を一意に求められない。
flowでは逆変換と体積変化を計算できる構造を選ぶ。
これによって生成だけでなく、既存構造がどれほど生成されやすいかも評価できる。



affine couplingは、一方を固定して他方を動かす

変数をaとbの二群に分ける。aはそのまま、bをaに依存した拡大と平行移動で変える。
exp(s)は正なので、b側の変換を必ず戻せる。
sとtは通常のニューラルネットでよい。交互に担当する変数を替え、全体を変換する。

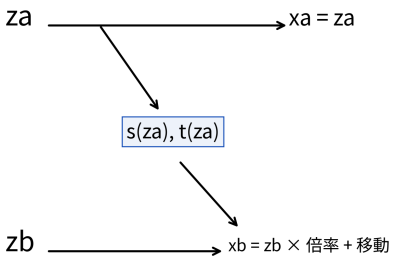


$$x_a = z_a, \quad x_b = z_b \odot e^{s(z_a)} + t(z_a)$$

生命情報工学特論

三角形のヤコビ行列なら、行列式が簡単になる

a側は変えないので、aをbで微分した成分は0。
b側の対角成分はexp(s)。三角行列の行列式は対角成分の積だから、対数はsの和になる。
複雑なsやtの微分を、密度評価のために行列式へ展開する必要がない。

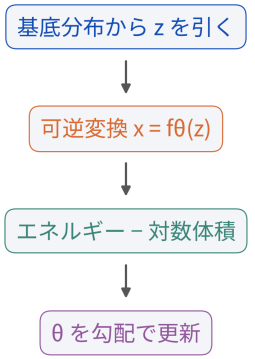


$$\log|\det J| = \sum_i s_i(z_a), \quad z_b = (x_b - t(x_a)) \odot e^{-s(x_a)}$$

生命情報工学特論

学習の情報は、標本とエネルギーの二通り

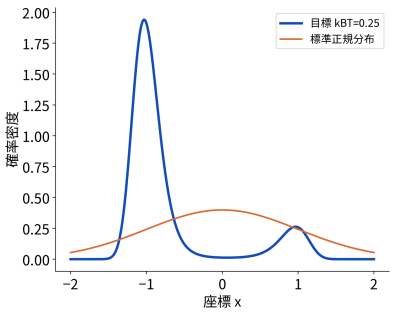
標本がある：観測された構造に高い密度を与える。
エネルギーが計算できる：生成した構造のエネルギーと、分布の広がりを評価する。
二つを組み合わせると、既知の谷へ学習を導きつつ、その周囲を物理モデルで評価できる。
目標は一点の最低エネルギー構造ではなく、分布。



生命情報工学特論

データ学習は、標本の負の対数密度を下げる

学習標本xが多い場所でqθ(x)を大きくする。
目標分布pから標本が得られていれば、これはKL(p ‖ qθ)のθ依存部分に一致する。
学習データが偏っていれば、その偏りも学ぶ。希少な状態がデータに存在するかを確認する。

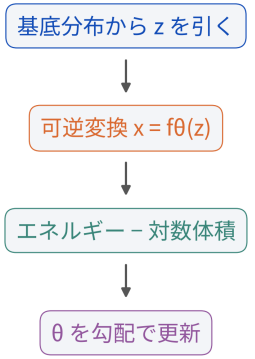


$$L_{\mathrm{ML}} = -\mathbb{E}_{x\sim p_{\mathrm{data}}}[\log q_\theta(x)]$$

生命情報工学特論

エネルギー学習は、KL(qθ ‖ p)を下げる

目標はp(x)=exp(−βU(x))/Z。生成分布qθから平均を取る。
log p=−βU−log Zを代入すると、エネルギーとlog qの平均になる。
未知のlog Zはθに依存しないので、学習時の勾配から消える。

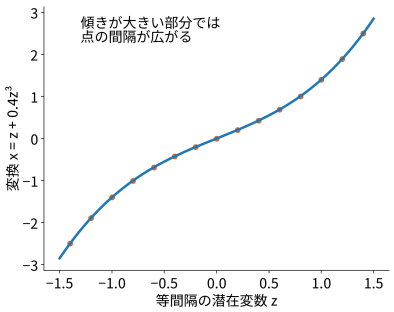


$$D_{\mathrm{KL}}(q_\theta\|p) = \mathbb{E}_q[\log q_\theta + \beta U] + \log Z$$

生命情報工学特論

変数変換を代入すると、潜在空間で学習できる

生成x=fθ(z)におけるlog qは、基底密度のlog pZから対数体積変化を引いた値。
基底分布は固定されているため、その平均もθに依存しない。
実際の損失にはエネルギーと、変換による体積変化が残る。

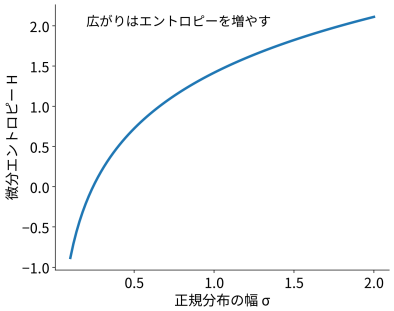


$$L_E = \mathbb{E}_{z\sim p_Z}[\beta U(f_\theta(z)) - \log|\det J_{f_\theta}(z)|]$$

生命情報工学特論

エネルギーだけを下げると、分布が一点へ縮む

低いエネルギーだけを目指すと、最小値の近くへ全標本を集めたくなる。
負の対数体積項は、過度の圧縮を抑える。
これは平均エネルギーとエントロピーの競合であり、第09回の自由エネルギーにつながる。
右の図は正規分布の幅と微分エントロピーの例。

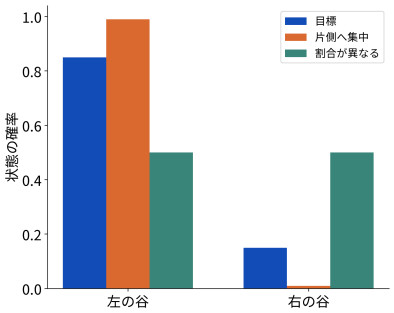


$$L_E = \beta\langle U\rangle_q - H(q) + \text{const.}, \quad H(q) = -\mathbb{E}_q \log q$$

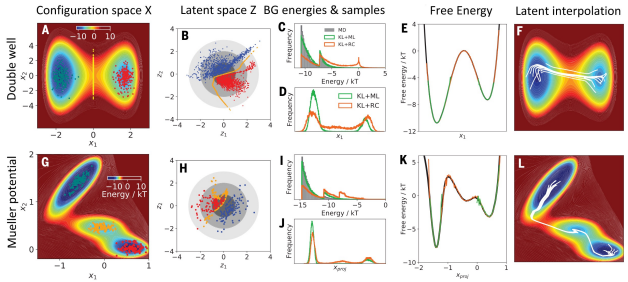
生命情報工学特論

損失が下がっても、すべての谷を見たとは限らない

逆向きKLは、現在ほとんど生成しない領域の寄与を評価しにくい。
二つの谷の片方へ偏った初期化では、もう片方を見逃す可能性がある。
データ学習・複数初期値・独立な基準計算を組み合わせる。
図は確率の偏りを示す説明用の二状態模型。



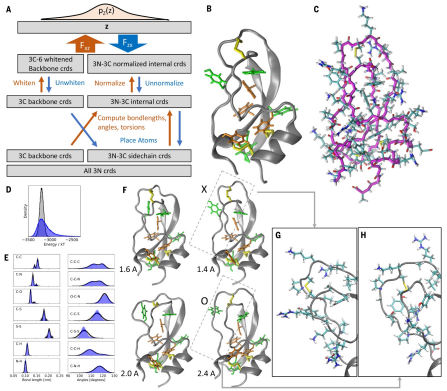
Boltzmann generatorの適用例



F. Noé, S. Olsson, J. Köhler, and H. Wu, Boltzmann generators: Sampling equilibrium states of many-body systems with deep learning, Science **365**, eaaw1147 (2019).

潜在空間での補間は構造候補の経路を作れる。ただし物理的な遷移経路や時間を保証しない。Noé et al. (2019)。

Boltzmann generatorの適用例

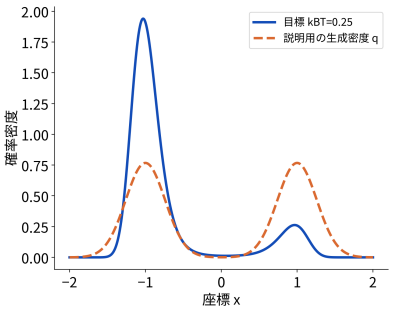


F. Noé, S. Olsson, J. Köhler, and H. Wu, Boltzmann generators: Sampling equilibrium states of many-body systems with deep learning, Science **365**, eaaw1147 (2019).

BPTIの構造集団の例。生成分布と参照分布の差を調べ、必要なら重みを補正する。Noé et al. (2019)。

生成密度が分かれば、重要度で補正できる

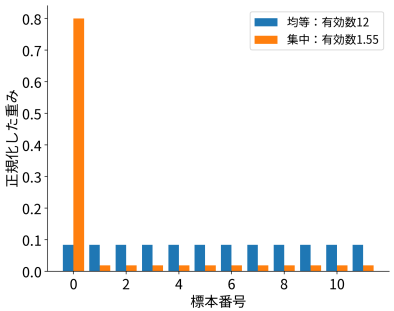
qθから得た標本へ、目標の非正規化密度をqθで割った重みを与える。
Zは分子・分母の比で消える。
目標の重要な領域でqθが十分正であることが必要。生成していない谷は補正だけでは回復できない。



$$\langle A \rangle_p \approx \frac{\sum_n w_n A(x_n)}{\sum_n w_n}, \quad w_n = \frac{e^{-\beta U(x_n)}}{q_\theta(x_n)}$$

重みの集中は、使える標本の減少として現れる

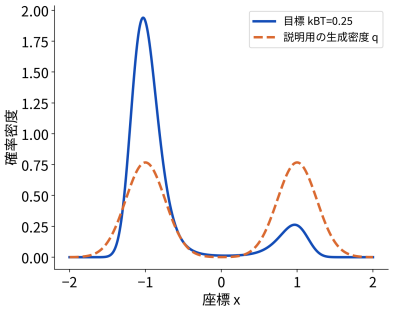
同じ数を生成しても、少数だけが大きな重みを持つと推定は不安定になる。
正規化重みを使い、有効標本数を診断する。
この指標は重みのばらつきを見るもので、未知の谷の見逃しを検出する万能な指標ではない。



$$N_{\mathrm{eff}} = \frac{(\sum_n w_n)^2}{\sum_n w_n^2} = \frac{1}{\sum_n \bar{w}_n^2}$$

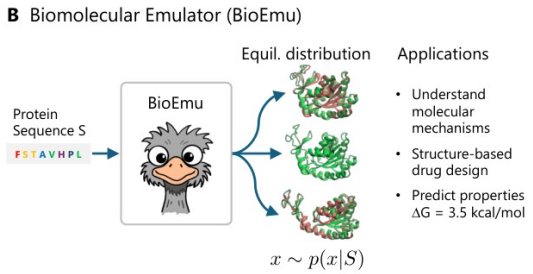
独立標本でも、学習誤差と有限標本誤差は残る

同じ学習済みモデルからの生成同士が独立であることと、モデルが正しいことは別。
比較は、分布・状態の割合・エネルギー・独立な実験量で行う。
標本数を増やせば有限標本誤差は減るが、学習モデルの偏りは自動では消えない。



AIで認識を予測し設計する

BioEmuは構造の集まりを生成する



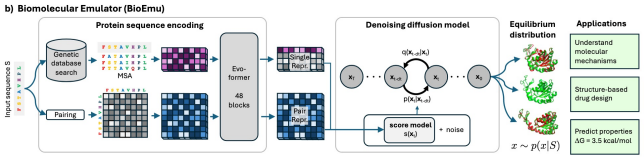
入力は配列で、出力は複数の立体構造です。図の右側のように、構造分布から状態の集団や自由エネルギー差を考えます。

近似した平衡分布を生成するモデルです。特定のVHHや複合体に使う際は、実験や物理計算で分布の妥当性を確かめます。

多様な構造が出ることと、割合が正しいことを分ける。

Lewis et al., Science (2025), Fig. 1B（著者公開版）
原著図／公式公開図／著者公開版：再利用ライセンス明記なし／パネルを抜粋。色・データ改変なし。

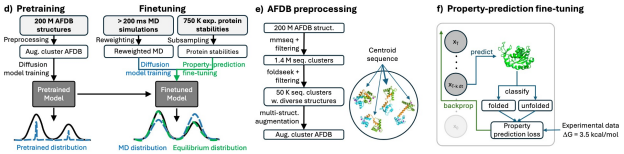
BioEmu (AlphaFold2 + diffusion model)



S. Lewis et al., *Scalable Emulation of Protein Equilibrium Ensembles with Generative Deep Learning*. Science (2025)

BioEmuは配列を条件とする近似平衡分布の生成モデル。生成順は実時間順ではない。Lewis et al., Science (2025)。

BioEmuの学習



S. Lewis et al., *Scalable Emulation of Protein Equilibrium Ensembles with Generative Deep Learning*. Science (2025)

構造データ、MDの集団、実験の安定性情報を段階的に活用する。Lewis et al., Science (2025)。

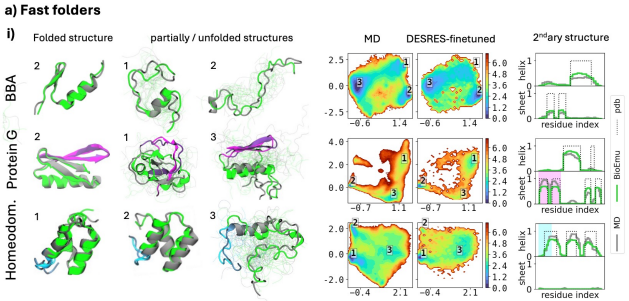
生命情報工学特論

BioEmuは学習データの役割を分けて使う

AFDBの構造は配列と構造の対応を、MDは一つの配列が取り得る集団を与える。
実験の安定性情報も学習に使い、計算だけの偏りを補う。
同じ「生成」でも、正規化flowと拡散モデルでは密度評価の仕組みが異なる。BGの重み式を、そのままBioEmuへ適用できるとは限らない。

配列とAFDB構造
↓
MDの構造集団
↓
実験の安定性データ
↓
近似平衡分布を学習

BioEmuの適用例



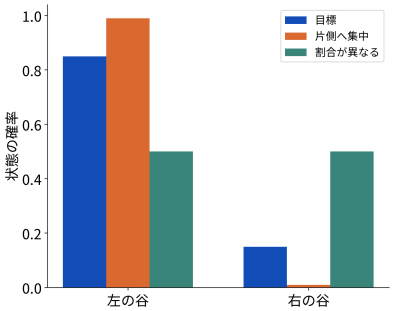
S. Lewis et al., *Scalable Emulation of Protein Equilibrium Ensembles with Generative Deep Learning*. Science (2025)

参照MDとBioEmuの構造分布の比較。分布が合う例であり、遷移速度を再現した図ではない。Lewis et al. (2025)。

生命情報工学特論

多様性と、正しい存在割合を分けて評価する

異なる形が出たことだけでは、自由エネルギー差は分からない。
二つの状態A・Bの確率がpA・pBなら、その比から自由エネルギー差を求める。
構造生成モデルの割合を用いるには、目的の条件で分布の妥当性を検証する必要がある。

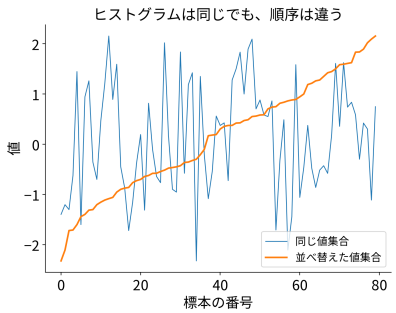


$$F_B - F_A = -k_B T \log(p_B / p_A)$$

生命情報工学特論

構造集団から、時間の順序は復元できない

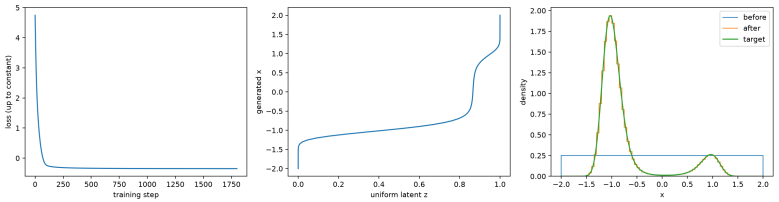
右の二つの系列は同じ値の集合で、ヒストグラムも同じ。
しかし隣り合う値の関係は異なる。
平衡分布は存在割合を与えるが、遷移速度・経路・時間相関には動力学の情報が必要。
拡散モデルの生成ステップも、物理時間ではない。



生命情報工学特論

演習の模型は、一様乱数を単調な折れ線で変換する

xの区間[−2,2]を80個に分ける。各区間の確率piをsoftmaxで正に保つ。
潜在区間の長さpiを、座標区間の幅Δxへ写す。傾きはΔx/pi、密度はpi/Δx。
目標分布も同じ有限区間で正規化する。タンパク質モデルの再現ではなく、原理の実装例。

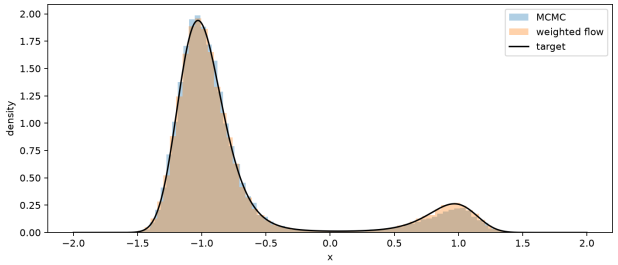


$$x = x_i + (z - c_i)\frac{\Delta x}{p_i}, \quad q(x) = \frac{p_i}{\Delta x}$$

生命情報工学特論

学習前後の密度と、補正後の割合を比較する

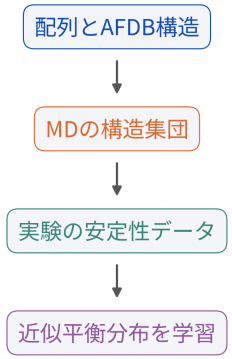
学習前は座標区間で一様。学習後は二つの谷へ確率が集まる。
有限個の区間を使うため、密度は階段状になる。
生成密度とエネルギーから重みを計算し、右の谷の割合を理論積分と比べる。
右図は今回のNotebookの実行結果。



生命情報工学特論

計算を速くする代わりに、学習と検証へ仕事を移す

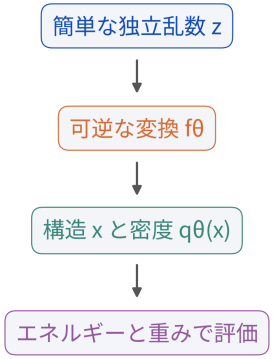
MDは運動方程式をその都度解く。生成モデルは事前の学習を経て標本を作る。
生成一回の速さだけでなく、学習データの作成・学習・補正・適用範囲の検証を含めて考える。
新しい配列や条件へ使うときは、分布の誤差を再確認する。



生命情報工学特論

まとめ：変換・密度・学習・補正をつなぐ

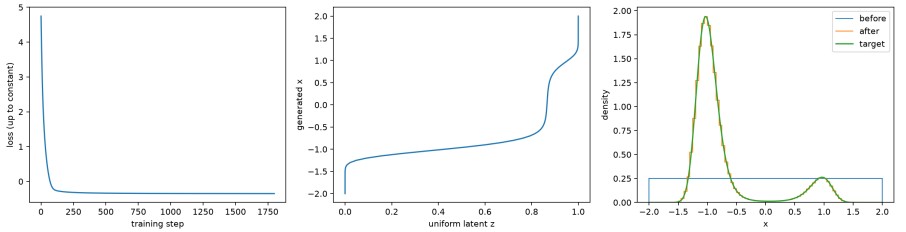
可逆変換では、ヤコビ行列式から生成密度を評価できる。
BGはデータとエネルギーを使い、目標の平衡分布へ近づける。
重みの補正は、十分に重なる分布の間で有効。
BioEmuも構造集団を生成するが、生成順から物理時間は得られない。



生命情報工学特論

演習：小さな生成モデルを学習する

20分・採点なし。13_演習.ipynbを使う。
1　正の区間確率と、可逆な折れ線の関係を見る。
2　エネルギーと密度の損失を学習し、前後の分布を比較。
3　重み補正後の右の谷の割合を、理論・MCMCと比べる。
4　区間数を変え、近似の細かさを観察して結果を保存する。

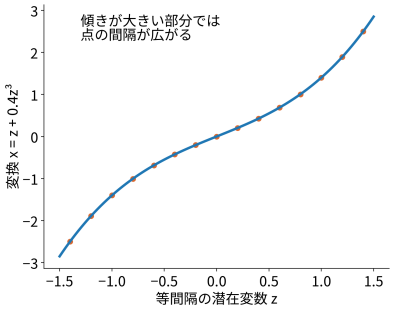


付録：導出と補足資料

ここからは本編の補足です。
導出の途中式、計算条件、研究例の詳細を示します。
本編の各手法の前提と対応させて読んでください。

変数変換の式を、微小領域の確率から導く

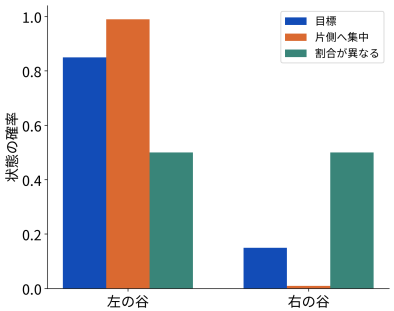
微小領域dzを変換すると、体積は|det J|dzになる。
その領域の確率が保存されることから、密度変換の式が得られる。
可逆性があればxからzを一意に戻せる。
向きに依存しない体積を扱うため絶対値を用いる。



$$p_Z(z)dz = q_X(f(z))|\det J|dz$$

KLの二つの向きを、平均する分布から区別する

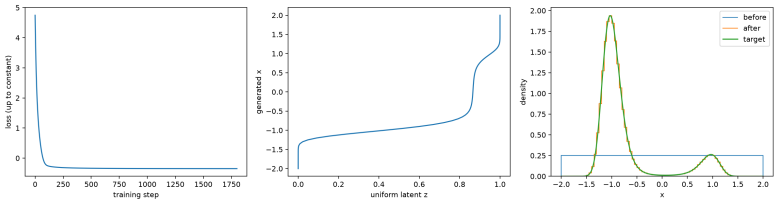
データからの学習はp側から標本を取る。
エネルギー学習は生成q側から標本を取る。
いずれもp=qで最小だが、有限なモデルや標本では学習中の挙動が違う。
KLは距離のように使うが、対称ではない。



$$D_{\mathrm{KL}}(p\|q) = \mathbb{E}_p \log(p/q), \quad D_{\mathrm{KL}}(q\|p) = \mathbb{E}_q \log(q/p)$$

演習の区間損失は、区間内の積分で計算する

区間iではq=pi/Δxが一定。したがってlog qも一定。
平均エネルギーŪiは区間内のUの積分を幅で割る。
この模型では多項式を厳密に積分でき、学習中の標本誤差を避けられる。
有限区間・区分一定密度による近似は残る。



$$L = \sum_i p_i \left[\beta \bar{U}_i + \log \frac{p_i}{\Delta x} \right], \quad \bar{U}_i = \frac{1}{\Delta x} \int_{x_i}^{x_{i+1}} U(x)dx$$

再重み付けは、確率密度の比で導く

観測量の積分へ1を掛ける

$$\langle A\rangle_0 = \int A(x)\pi_0(x)\,dx$$

$$= \int A(x)\frac{\pi_0(x)}{\pi_B(x)}\pi_B(x)\,dx$$

$$\frac{\pi_0(x)}{\pi_B(x)} = \frac{Z_B}{Z_0}e^{\beta B(x)}$$

$$\langle A\rangle_0 = \frac{\langle Ae^{\beta B}\rangle_B}{\langle e^{\beta B}\rangle_B}$$

分母はA=1の同じ式を用いて未知のZ_B/Z_0を除いたもの。

なぜ正の指数で補正するか

バイアスでエネルギーを上げた配置は、標本中では少なくなる。補正はその配置の重みを増やすので、指数は+βBとなる。

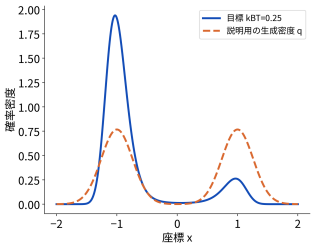
$$w_n = e^{\beta B(x_n)},\quad \widehat{A} = \frac{\sum_n w_n A(x_n)}{\sum_n w_n}$$

数値例：訪れた回数と、元の割合は違う

AとBを同数観測し、加えたバイアスがそれぞれ0とk_BT ln 3なら、補正重みは1と3。元の割合は1:3となる。

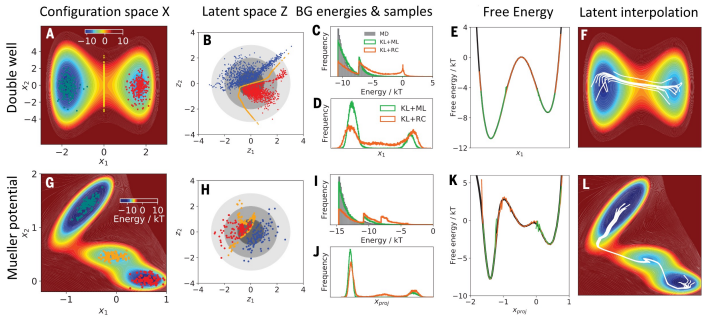
$$N_{\mathrm{eff}}^{(w)} = \frac{(\sum_n w_n)^2}{\sum_n w_n^2}$$

一つの重みが支配すると有効な情報が減る。この式は重みの偏りの指標であり、時間相関は別に扱う。



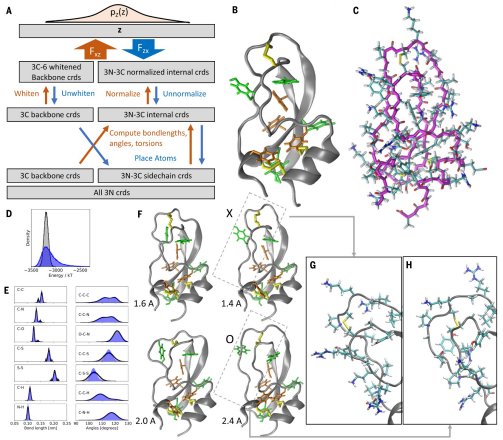
式の意味を示す模式図・数値例

Boltzmann generatorの適用例



F. Noé, S. Olsson, J. Köhler, and H. Wu, Boltzmann generators: Sampling equilibrium states of many-body systems with deep learning, Science **365**, eaaw1147 (2019).

Boltzmann generatorの適用例



F. Noé, S. Olsson, J. Köhler, and H. Wu, Boltzmann generators: Sampling equilibrium states of many-body systems with deep learning, Science **365**, eaaw1147 (2019).

生命情報工学特論

原著・実装と、授業の模型

Boltzmann generators：Noé, Olsson, Köhler & Wu, Science 365, eaaw1147 (2019)。DOI:10.1126/science.aaw1147
BioEmu：Lewis et al., Science (2025)。DOI:10.1126/science.adv9817
公式実装：github.com/microsoft/bioemu
授業の1次元折れ線モデルは、原著の考え方を単純化した実装。原著モデルの性能評価とは区別する。