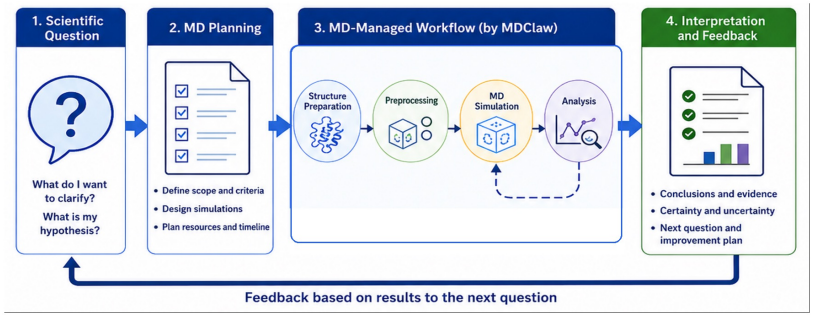
# AI Scientist研究とMDエージェント

研究の手順を記録し、
計算と評価を繰り返す

**松永 康佑**
埼玉大学 大学院理工学研究科
理化学研究所 計算科学研究センター








# 研究の手順を記録し、計算と評価を繰り返す

研究の手順を記録し、

計算と評価を繰り返す。

自然言語の仮説を計算手順へ落とし、出力を検証して次の計算へ進む。

データの量だけでなく、条件の統一・多様性・失敗の記録が研究の質を決める。

研究の問い・仮説
↓
計算を計画して実行
↓
出力と失敗を記録
↓
根拠を評価して次へ





# 研究の自動化をデータと検証から考える

1　AI Scientistの提案と外部の検証
2　自動データ取得と計算条件の統一
3　転移学習とデータ量・多様性
4　MDClawのskills・CLI・計算履歴
5　教員デモ：入力から証拠までをたどる

研究の問い・仮説
↓
計算を計画して実行
↓
出力と失敗を記録
↓
根拠を評価して次へ





# AI Scientistの提案は、外部の評価と組み合わせる

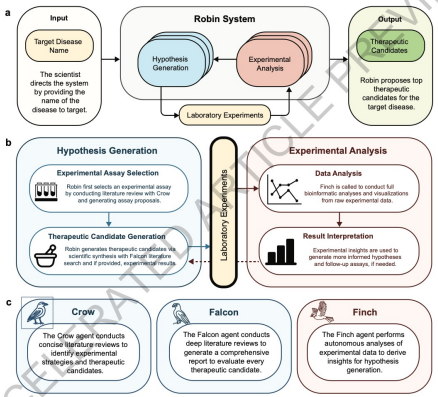
| 研究 | AIが担う作業 | 検証の進め方 |
|---|---|---|
| **Robin** | 文献探索とデータ解析から、仮説と実験候補を提案する。 | 人が候補を検討し、実験結果を次の仮説へ戻す。 |
| | Ghareeb et al., Nature (2026). DOI:10.1038/s41586-026-10652-y | |
| **Co-Scientist** | 複数のエージェントで仮説を生成・批判・順位付け・改良する。 | 研究者が目標と候補を選び、実験で確かめる。 |
| | Gottweis et al., Nature (2026). DOI:10.1038/s41586-026-10644-y | |
| **ERA** | 定量的な評価値を使い、探索しながら科学計算コードを作る。 | データと計算による評価を、コードの改良へ戻す。 |
| | Aygun et al., Nature (2026). DOI:10.1038/s41586-026-10658-6 | |

## Robin：文献と実験データから、仮説を更新する

CrowとFalconが文献を探索し、Finchが実験データと関連情報を解析する。

候補を実験で確かめ、その結果を次の仮説に戻す。

AIの提案だけで研究を閉じず、研究者や実験系による評価を入れる。




Ghareeb et al., Nature (2026). DOI:10.1038/s41586-026-10652-y





## もっともらしい説明を、検証できる仮説へ変える

例：「変異で安定になる」を、そのまま計算の入力にはできない。

何を安定性と呼ぶか、何と比べるか、温度や溶媒は何かを決める。

仮説から観測量・比較条件・判定方法へ落とす段階で、研究者の判断が必要になる。

計算が成功したことと、仮説が支持されたことを分ける。

研究の問い・仮説
↓
計算を計画して実行
↓
出力と失敗を記録
↓
根拠を評価して次へ





## 実験で見えにくい過程を、計算で調べる

AIの提案
文献を調べる
仮説と計画
→
研究者・実験
評価・測定
→
観測の限界
短寿命の状態や動き
→
MD計算
構造集団と機構

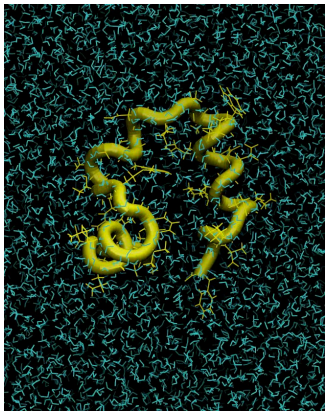
実験で試しにくい条件を計算で調べ、仮説と観測量を結ぶ。

計算もモデルに基づくため、力場・条件・サンプリングの妥当性を確かめる。





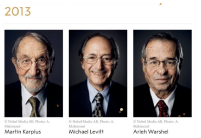
## 分子動力学は、原子の運動から構造集団を調べる



原子に働く力を計算し、運動方程式を数値的に解く。

座標の時間変化から、構造の分布や動きを調べる。

実験で直接見えにくい過程も、モデルと測定を対応させて考察する。



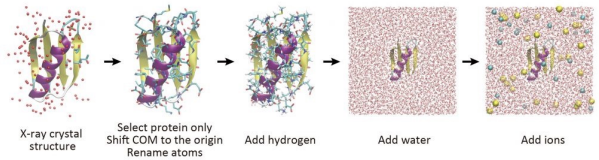

2013年ノーベル化学賞の紹介図（nobelprize.org）

## MDの準備では、分子ごとに判断する点が異なる

変異・修飾・補因子・リガンド・膜・プロトン化状態によって、準備の分岐が変わる。

力場、欠損原子、電荷、水和などを、対象と目的に合わせて選ぶ。

固定した条件分岐だけでは扱いにくい例外もある。入力を検査し、結果を確かめ、必要なら計画を修正する。




図：GENESIS tutorial。化学状態・モデル・入力の選択を、結果と一緒に記録する。





## 計算データを増やすには、条件も同時に揃える

異なる構造を同じ規則で準備し、同じ観測量を取り出す。

構造ID、配列、プロトン化状態、力場、水モデル、温度、乱数、計算長を保存する。

成功したものだけを残すと、難しい系が消えた偏ったデータ集合になる。失敗理由も残す。

入力と設定を読む
↓
成果物を検査する
↓
失敗の理由を調べる
↓
再試行か条件変更かを決める





## ナノボディを同じ条件で計算し、学習データを作る

**対象一覧の例（SAbDab：抗体構造のデータベース）**

| pdb | Hchain | Lchain | model | antigen_chain | antigen_type | antigen_het_name | antigen_name |
|---|---|---|---|---|---|---|---|
| 8g2y | N | NA | 0 | A \| B | protein \| protein | NA \| NA | minig alpha s/q chimera \| guanine nucleotide-binding protein g(l)/g(s)/g(t) subunitbeta-1 |
| 8bb7 | D | NA | 0 | B | protein | NA | plexin-b1 |
| 8bb7 | C | NA | 0 | A | protein | NA | plexin-b1 |
| 8bf4 | D | NA | 0 | F | protein | NA | plexin-b1 |
| 8bf4 | E | NA | 0 | F | protein | NA | plexin-b1 |
| 8bf4 | A | NA | 0 | C | protein | NA | plexin-b1 |
| 8bf4 | B | NA | 0 | C | protein | NA | plexin-b1 |
| 7xk9 | B | NA | 0 | A | protein | NA | endolysin,beta-2 adrenergic receptor |



依頼例：一覧の各ナノボディを100 nsずつ計算する。

構造ID、鎖、残す成分、計算条件と完了基準を明示する。

対象一覧の一部だけを拡大表示。図：既存発表資料。





## 転移学習では、計算データも使って共通の表現を学ぶ

タンパク質言語モデルが配列の表現を作る。

少数の実験Tmと、計算による安定性の補助ラベルを別の出力で学習する。

計算値を実験値と同一視するのではなく、共通の表現を介して実験予測を助ける。

最終評価には学習に使っていない実験配列を使う。

大量の配列で事前学習
↓
計算ラベル＋少数の実験値
↓
共有表現とタスク別の出力
↓
未学習配列でTmを評価

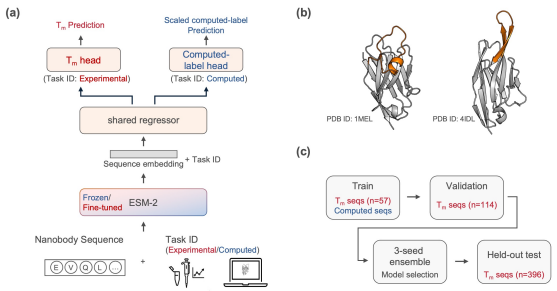
# ナノボディの融解温度を、計算ラベルも使って予測する

Tm：熱変性の中点に対応する融解温度。

ESM2：配列を数値表現に変えるタンパク質言語モデル。

FEP：自由エネルギー摂動法。変異に伴う自由エネルギー差を計算する。

実験Tmは学習57配列、モデル選択114配列、最終評価396配列。




村上さんの研究：Murakami et al., bioRxiv (2026). DOI:10.64898/2026.07.30.741744





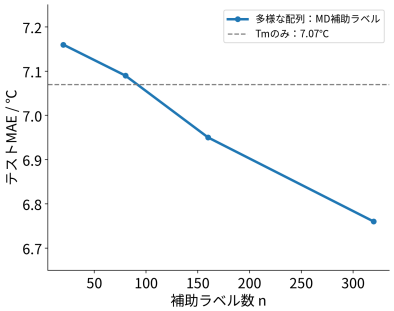
# 同じラベル数でも、どの配列を計算するかが効く

同じMD由来のラベルでも、少数構造の変異走査と、多様なナノボディ集合を比較する。

多様な集合では、ラベル数20→320で微調整モデルの平均絶対誤差（MAE）が7.16→6.76°Cへ下がった。

変異走査では単調な改善にならなかった。量だけでなく、覆う配列の広さが重要。

原稿Fig. 2の条件。右の再描画は本文の数値に基づく。

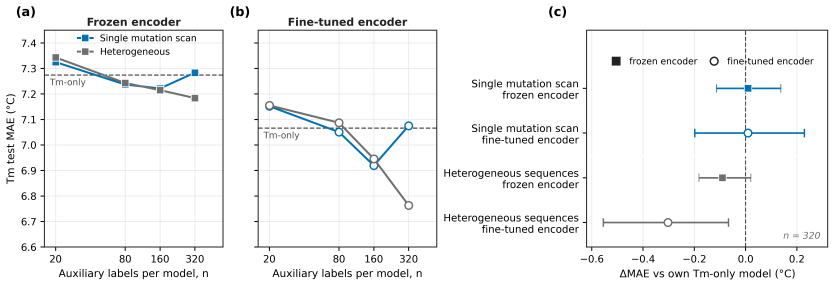







# 原著Fig. 2：データ設計によって増量の効果が違う

左・中央：ラベル数と、凍結／微調整したモデルの誤差。
右：同じラベル数320で、それぞれのTmのみの基準からの変化。
誤差が低いほどよい。異なる学習条件の基準値を混ぜない。
この範囲の結果から、無限に増やせば改善すると外挿しない。

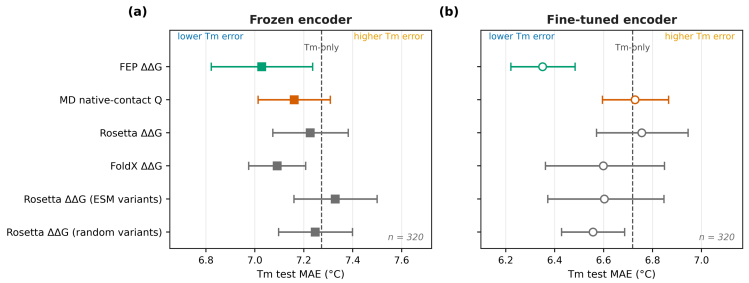







# 原著Fig. 3：何を計算するかも予測に影響する

同じ変異配列に対し、FEP・MD接触率・Rosetta・FoldXの補助ラベルを比較。
この比較ではFEP補助の微調整モデルのMAEが6.35°C。Tmのみは6.72°C。
「この予測に有用だった」ことと、「実験ΔΔGを最も正確に再現した」ことは別。



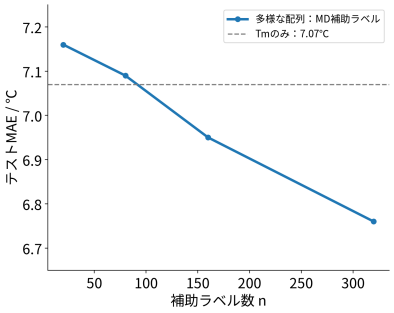
## スケーリングの議論では、量・質・評価を分ける

データ数Nを増やすと誤差が減る経験的な関係は、対象・範囲・学習条件に依存する。

重複や偏りの強いデータを増やしても、未知の配列への誤差は減らないことがある。

類縁配列や条件が訓練とテストをまたぐ影響も点検する。

自動化は、比較可能なデータを狙って増やすために使う。







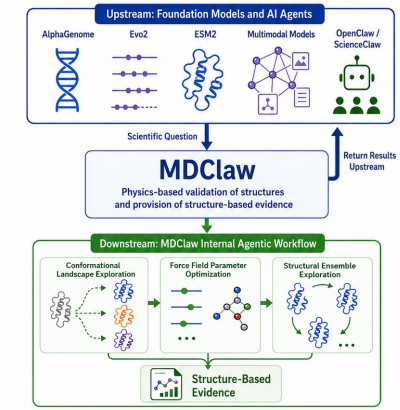

## MDClaw：研究の問いを、計算による検証につなぐ

上流：言語モデルや生成モデルが、仮説や構造候補を出す。

MDClaw：問いを計算計画へ落とし、準備・実行・解析を記録する。

結果：構造に基づく根拠と不確実性を、次の問いへ戻す。

図は開発の目標像。個別機能の実装・検証状況とは区別する。








## MDClawは、手順書・操作ツール・計算履歴を組み合わせる

研究の問いから計画、系の準備、MD、解析、結果の確認へ進む。

Skillsは手順と判断基準を記した文書。CLIは引数を受けて操作を実行するコマンド。

計算の入力・出力・失敗をDAGとして記録し、異なるエージェントから同じ操作を呼び出せるようにする。

対象の化学状態に応じた準備は必要。実行成功だけで科学的妥当性を保証しない。

MDClaw：github.com/matsunagalab/mdclaw／紹介資料の時点と、現在の実装を区別する。





## Skillsが判断を助け、CLIが実行と記録を担う

| | | |
|---|---|---|
| md-study<br>問いを観測量と計算計画へ | md-prepare<br>構造の取得・準備・水和・力場設定 | md-equilibration<br>段階的に系を緩和する |
| md-production<br>本計算を区切って実行・再開する | md-analyze<br>軌道を解析し、根拠を示す | hpc-run<br>SLURMを介して計算機で実行する |

人が読む手順書と、機械が読む実行結果を対応させる。

# エージェントは、手順書を読んでツールを呼ぶ

| | |
|---|---|
| name | md-prepare |
| description | Molecular dynamics simulation preparation using MDClaw CLI tools. Covers structure acquisition, protein/nucleic/ligand selection, structure cleaning, solvation, and topology generation. |

## MD Prepare

You are a computational biophysics expert helping users set up MD simulations using the MDClaw CLI tools.

Read `skills/common/preamble.md`, `skills/common/tool-output.md`, `skills/common/defaults.md`, `skills/common/node-cli-patterns.md`, `skills/common/run-loop.md`, `skills/common/autonomous-checklist.md`, and `skills/common/guardrail-codes.md` before acting.

① 対象のSkillを読む

② 必要な入力と前提を確かめる

③ 引数を指定してCLIを呼ぶ

④ 戻り値と成果物を読む

⑤ 次の操作か、修正が必要かを判断する

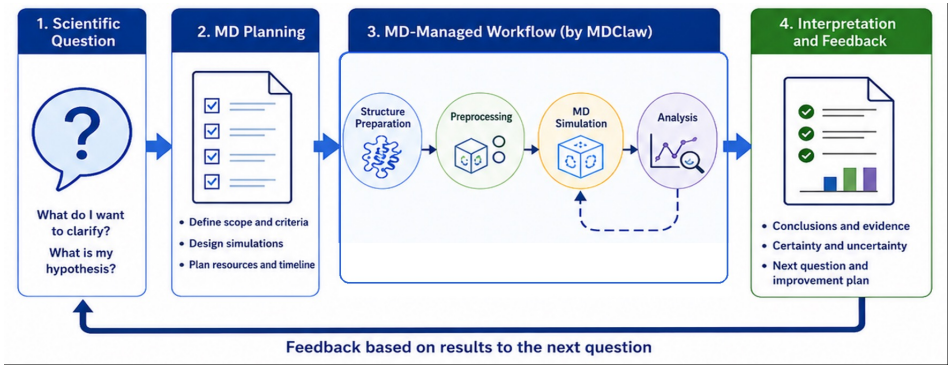
md-prepareの記述例。手順書自体も版を持つため、使用した版を記録する。

出典：github.com/matsunagalab/mdclaw/blob/main/skills/md-prepare/SKILL.md





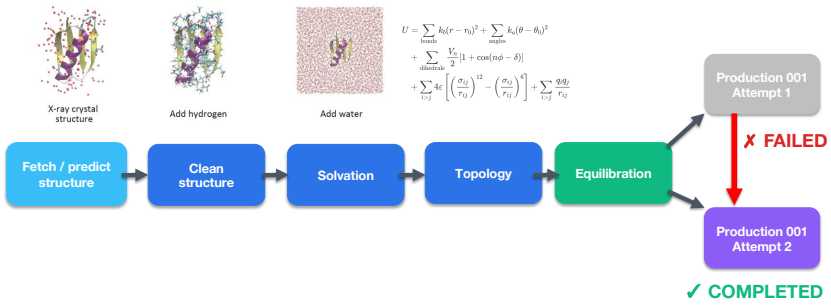
# 問い・計画・計算・解釈を、成果物でつなぐ




DAG（循環のない有向グラフ）は、入力から出力への依存関係を表す。



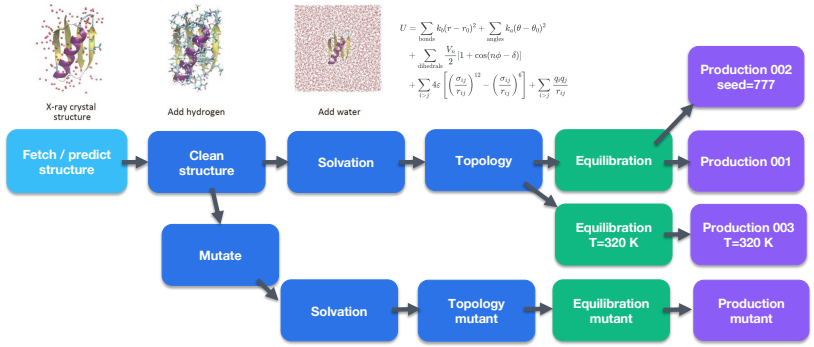
# 失敗した実行を残し、条件を確かめて再試行する




同じ条件の再試行は同じノードの別Attemptとして残す。条件を変える場合は新しいノードや分岐にする。



# 乱数・温度・変異など、変更した条件を分岐に残す




乱数、温度、変異などを変えた比較は別の分岐として保存する。共通の入力と変更した条件を区別する。

## 再実行では、完了済みの根拠を使って続きへ進む

inspect_jobで状態と成果物を読む。
explain_nodeで次の段階の入力条件を確認する。

trace_failureで失敗した段階と理由を追う。

ファイルが存在するだけで完了とせず、正しい入力に対応した出力かを検査する。

2026年10月11日のローカルREADMEにある操作の役割。

入力と設定を読む
↓
成果物を検査する
↓
失敗の理由を調べる
↓
再試行か条件変更かを決める





## 実行前の検査で、不整合と運用上の制約を伝える

検査結果を構造化する
対象項目／理由／重要度
実際の値と期待する値
修正候補／エラーコード

次の段階への入力を明確にする
準備：化学状態と判断を記録
力場設定：相互作用を定義
以後の計算：登録された出力を読む

**例：forcefield_water_blocked　ff19SB + TIP3P → 規定では ff19SB + OPC**

この組合せを止めるのは、当該ワークフローの運用規約。科学的にその組合せが絶対に使えない、という意味ではない。





## MDPrepBenchは、準備結果を再計算して評価する

対象と化学状態
公開構造の欠損や不整合を扱う。
指定したリガンド・イオン・修飾・膜・プロトン化状態を保つ。

提出物と記録
構造、設定、出典、判定の根拠を残す。
文章だけでなく、再読込できるファイルを提出する。

独立した点検
成分と残基状態を再確認する。
OpenMMで設定を読み直し、エネルギーを再計算する。

**最小化が終了したことだけで、準備が正しいとは判定しない。**





## 生成した構造を、成分と配置から点検する

**P02：タンパク質＋AP5**



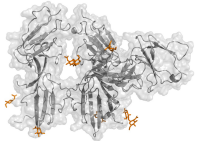
リガンドを保持しているか

**P06：カルモジュリン＋$Ca^{2+}$**



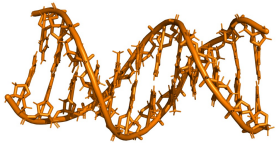
イオンの位置は妥当か

**P14：糖タンパク質**



糖鎖などの成分が残っているか

**P17：DNA二重鎖**



両方の鎖と配置が保たれているか

## 25課題の比較では、Skillsを含む条件の得点が高かった

| model / harness | skills+CLIs | CLIs-only | free |
|---|---|---|---|
| Haiku 4.5 / claude-code | 22/25 | 7/25 | 5/25 |
| DeepSeek-v4-flash / pi | 20/25 | 7/25 | 13/25 |

Haikuの合格数：Skills＋CLIは22/25、CLIのみは7/25、自由な操作は5/25。

この比較条件では、手順書を伴う構成が有利だった。すべてのモデルや課題へ一般化しない。

2026年6月発表時の25課題による比較。現在の版・別の課題集合の性能とは区別する。





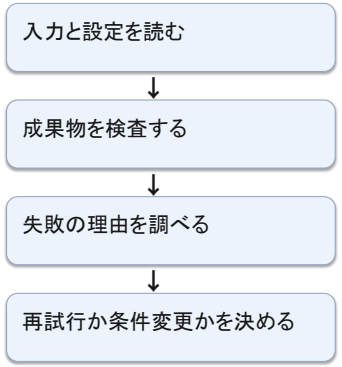
## ベンチマーク結果は、条件と失敗例まで読む

課題集合、入力、モデル版、制限時間、計算環境、採点基準を揃える。

途中で停止した実行や、提出物がない実行を完了した評価と混ぜない。

成功率に加え、どの化学状態や段階で失敗するかを調べる。

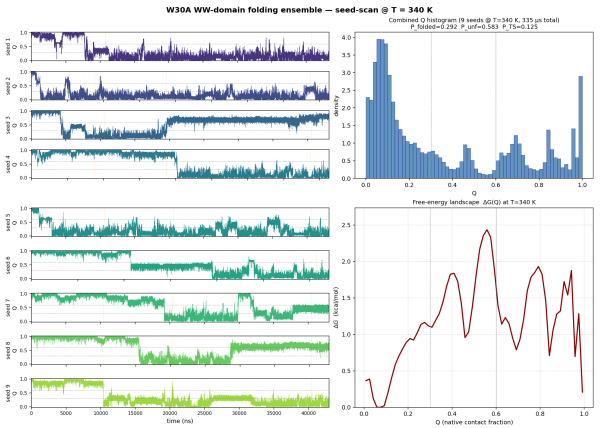
過去の25課題の点数から、現在の任意の系の成功率は予測できない。








## 折り畳み温度を探すには、状態と収束を定義する




利用例：9 GPUでWWドメインを調べる。

左：時刻に沿った天然接触率Q。

右上：Qの分布。

右下：Qに沿った自由エネルギー。

温度ごとの割合と反復を比較する。一つの短い軌道では転移温度は決まらない。





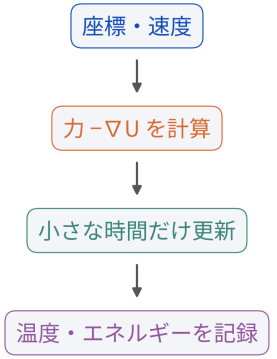
## 教員デモ：計算の入力から根拠までをたどる

題材は第11回と同じ水中ペプチドの短い計算。

最初に条件・出力を指定した依頼文を読み、どの段階に対応するかを確認する。

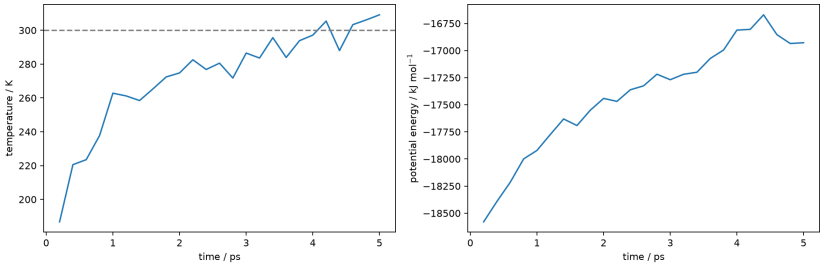
次に保存された構造・温度・エネルギー・実行条件を開く。

新しい大規模計算ではなく、既存の短い実行の記録とMDClawのDAGの読み方を示す。



## デモで見るもの：説明と成果物が一致するか

「300 Kで動かした」という説明なら、積分器の設定と温度ログを見る。
「5 ps」という説明なら、2 fs×2500ステップとの一致を見る。
「構造が安定」という説明には、計算長・反復・観測量の根拠が必要。
下は第11回Notebookの実行例。5 psでは昇温途中であり、平衡分布の例ではない。







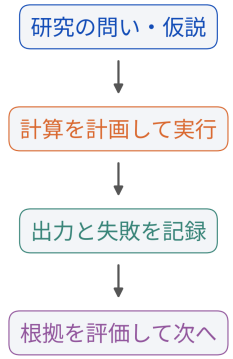

## 次の計算は、残っている不確実性から決める

温度は合うが構造が動かない：単に短い可能性がある。

反復ごとの割合が違う：探索や緩和が足りない可能性がある。

モデル間で結果が違う：力場や観測モデルの仮定を点検する。

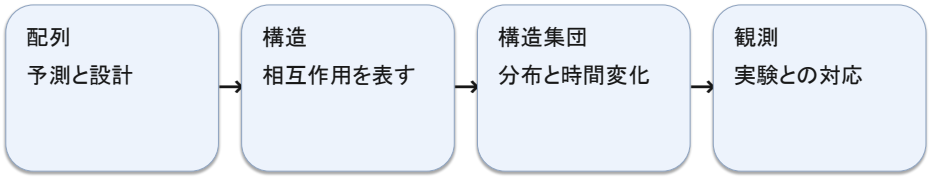
追加するデータが、どの不確実性を減らすかを先に決める。








## 配列・構造・分布・観測をつなぎ、判断する




配列から構造を予測し、目的の構造に合う配列を設計する。

相互作用から構造の分布と動きを計算し、観測を通じてモデルを確かめる。

エージェントは計算と記録をつなぐ。判断の根拠は、条件のそろったデータと検証に置く。





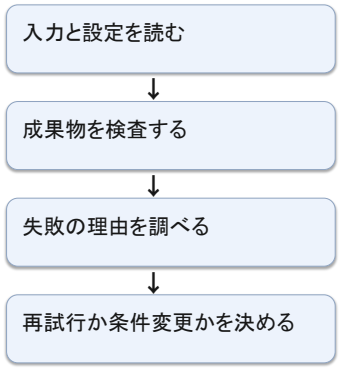
## まとめ：自動化するほど、根拠を追える記録が要る

AI Scientistは仮説や手順を広げる。計算・実験が検証の手掛かりを与える。

転移学習ではデータ数に加え、配列の多様性とラベルの意味が重要。

MDClawでは計画・操作・成果物・失敗をつなぎ、同じ条件で比較できる形に残す。

実行成功を、そのまま科学的結論へ置き換えない。



# 付録：導出と補足資料

ここからは本編の補足です。
導出の途中式、計算条件、研究例の詳細を示します。
本編の各手法の前提と対応させて読んでください。





# 準備課題 P01〜P13：対象と化学状態を指定する

| | | |
|---|---|---|
| P01 | Simple monomer | 2LZM; clean one protein chain for explicit-water MD. |
| P02 | Chain + ligand | 1AKE; include chain A and AP5 despite chain ambiguity. |
| P03 | Ligand pose | 181L; preserve T4L L99A plus benzene crystal pose. |
| P04 | Ligand filtering | 3PWB; keep requested ligands, exclude irrelevant heterogens. |
| P05 | Charged cofactor | 1DAP; retain and document NDP/NADPH-like cofactors. |
| P06 | Supported ions | 1CLL; retain four Ca2+ ions. |
| P07 | Ion triage | 4RBQ; prepare RNA while preserving designated K+ ions. |
| P08 | Point mutation | 2LZM; branch WT to L99A without numbering drift. |
| P09 | Multi-mutant | 2LZM; apply L99A and M102Q together. |
| P10 | Disulfides | 5PTI; record BPTI disulfides and exclude deuterium. |
| P11 | Protonation | 2LZM; preserve explicit A:11 GLH protonation. |
| P12 | Deposited PTM | 5K9P; restore deposited SEP and source record. |
| P13 | Requested PTM | 1UBQ; convert Ser20 to SEP on request. |

各行は課題番号・対象の種類・守る条件。課題間で必要な準備が異なる点を読む。





# 準備課題 P14〜P25：膜・核酸・モデル条件を指定する

| | | |
|---|---|---|
| P14 | Glycan | 6YA2; preserve N-linked glycans as glycans. |
| P15 | DNA | 5MVQ; prepare DNA without protein defaults. |
| P16 | RNA | 4RBQ; prepare RNA with RNA-compatible metadata. |
| P17 | DNA duplex | 1BNA; preserve both DNA chains and neutralization record. |
| P18 | Membrane | 2LOP; honor POPC:POPE:CHL1 = 2:1:1. |
| P19 | Candidate selection | 2K39; select specified NMR model before prep. |
| P20 | Terminal capping | 5AWL; honor ACE/NME caps. |
| P21 | PDB cleanup | 4Q5T; handle MSE, altloc, numbering, missing residues. |
| P22 | FF/water fidelity | 2LZM; honor ff19SB plus OPC. |
| P23 | Implicit solvent | 5AWL; avoid explicit water when implicit is requested. |
| P24 | Biological assembly | 1STP / 2MS2; generate assembly 1 and map chains. |
| P25 | KCl concentration | 5AWL; honor 0.30 M KCl and neutrality. |

各行は課題番号・対象の種類・守る条件。課題間で必要な準備が異なる点を読む。





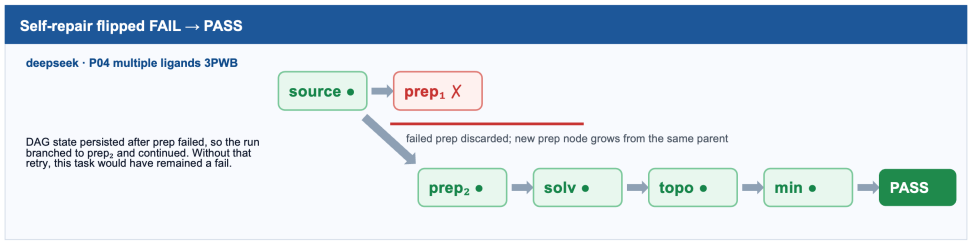
# 依頼文の例：対象・除外対象・提出物を明記する

Use this prompt as the task statement. Retrieve public sources as needed, and do not read `truth/` or `scorer/` if those directories exist.
Task: Simple monomer preparation: retrieve T4 lysozyme chain A, clean it, prepare an explicit-water-compatible topology, and report that no unintended ligands were retained.
Public source anchors: PDB 2LZM.
Your submission directory must contain:
- `manifest.json`
- `metrics.json`
- `provenance.json`
- `evidence_report.json`
- `prepared_structure.pdb`

P01はT4リゾチーム鎖Aの準備。参照元と、混入させない成分・提出ファイルを指定する。

## 失敗後の修正と再試行で、合格した例

**記録から、失敗点と修正後の結果をたどる**




この例では、失敗した準備から別の準備へ進み、入力・水和・力場・最小化を再確認している。





## 基本の利用例：問いと計算条件を、記録に変える

**実行**

一つの系を準備し、計算の依存関係を記録する。

**計画**

観測量・計算条件・判定基準を明確にする。

**解析**

軌道を解析し、不確実性とともに答える。

**変異の比較**

共通の準備から分岐し、変更した条件を残す。

**成分の指定**

リガンドやイオンを保持し、化学状態を記録する。





## 応用の利用例：異なる準備と計算を、分岐に残す

**修飾の準備**

記録された修飾や、指定された化学状態を準備する。

**膜の準備**

膜と水を含む系として準備する。

**構造候補**

生成モデルの候補を、初期構造として比較する。

**計算の延長**

本計算を区切り、再開のつながりを記録する。

**評価課題**

依頼文・提出物・採点結果を対応させる。





## 問い・比較条件・出力・解釈を、一つずつ対応させる

問い
変異で分子の動きが変わるか

→

計画
野生型と変異体
観測量・判定基準

→

実行
準備 → 平衡化
本計算 → 解析

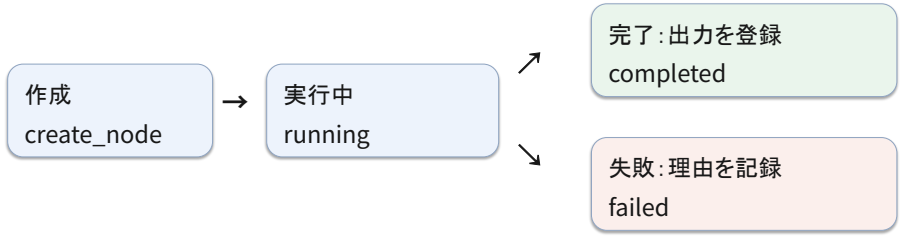
→

解釈
差の向き・大きさ
誤差・次の計算

文章による回答だけでなく、構造・設定・軌道・解析結果を対応させる。

比較では、原子や残基の対応と、共通条件・変更条件を明示する。

## 実行中のノードは、完了か失敗のいずれかへ進む




完了した記録は根拠として保存し、後からの所見は追記する。

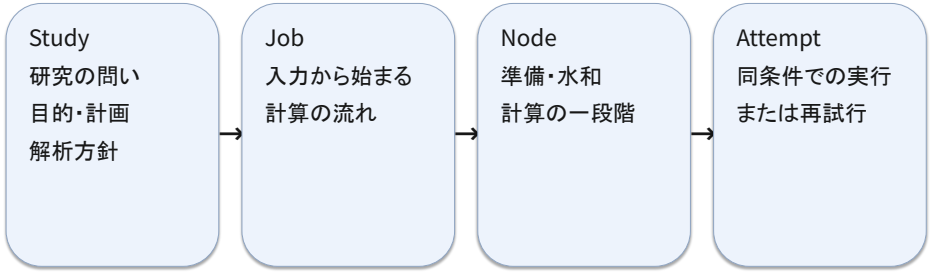
同じ条件の再試行は、同じノードの新しいAttempt（試行）として残す。

条件を変える場合は、新しいノードや分岐として区別する。





## 問い・一連の計算・段階・試行を分けて記録する

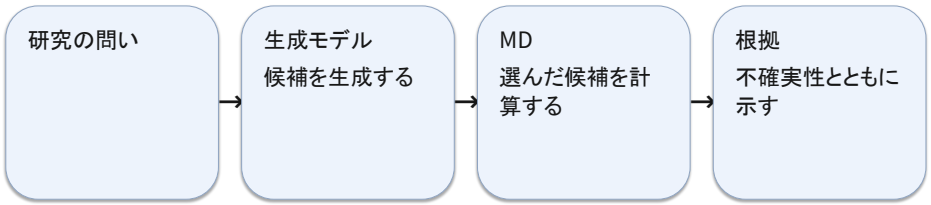



「研究全体」と「同じ条件での再試行」を混同せず、どこを変更したかを追えるようにする。





## 今後の構想：生成モデルで候補を絞り、MDで確かめる




候補構造、初期構造集団、追加の探索が必要な領域を選ぶために、生成モデルを使う構想。

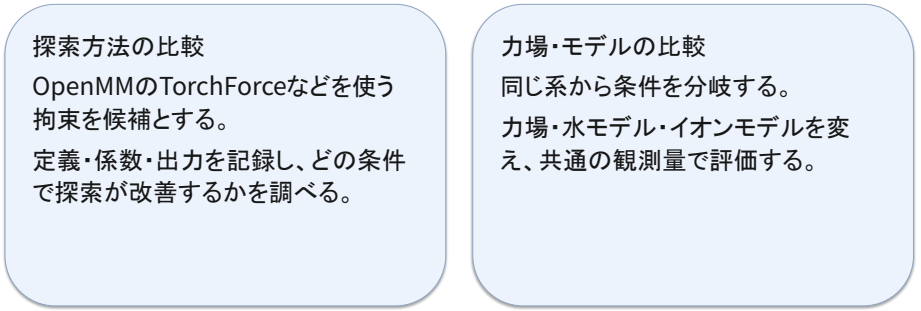
MDを重点的に使う対象を選び、その選択と結果を記録する。

この図全体の自動実行が実装・検証済みであることを示すものではない。





## 今後の構想：探索方法と力場の選択を、比較可能にする




検討中の方向性。分岐を記録できることと、最適な条件を自動で発見できることは別。

## 既存の科学計算ソフトウェアを、記録付きで呼び出す

入力・知識：PDB、UniProt、PubChemなど。

準備：PDBFixer、PROPKA、RDKitなど。

水和・膜：Packmolなど。

力場・計算：AmberTools、OpenMMなど。

解析・可視化：MDTraj、PyMOLなど。

実行環境：コンテナやSLURMなど。




エージェントが物理計算を置き換えるのではなく、既存の道具を呼び、条件と結果を記録する。





## 実行前の検査で、不整合と運用上の制約を伝える

検査結果を構造化する
対象項目／理由／重要度
実際の値と期待する値
修正候補／エラーコード

次の段階への入力を明確にする
準備：化学状態と判断を記録
力場設定：相互作用を定義
以後の計算：登録された出力を読む

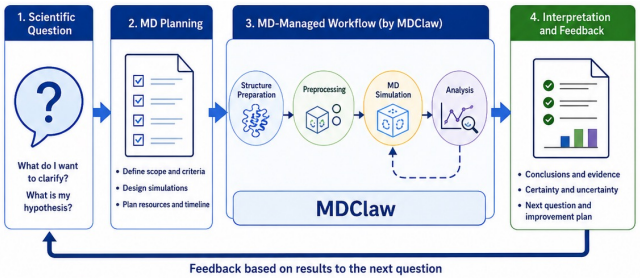
**例：forcefield_water_blocked　ff19SB + TIP3P → 規定では ff19SB + OPC**

この組合せを止めるのは、当該ワークフローの運用規約。科学的にその組合せが絶対に使えない、という意味ではない。





## 記録を読む：問いから成果物までの対応を確かめる




問い：何を比べたか。

計画：観測量と判定基準は何か。

計算：どの入力と設定を使ったか。

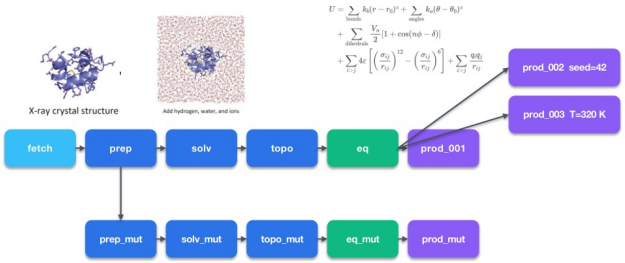
解釈：どの成果物が結論を支えるか。

各段階の記録を照合し、説明だけで判断しない。





## 記録を読む：共通の入力と、変更した条件をたどる




分岐の前：共有する構造と準備。

分岐の後：乱数・温度・変異などの変更。

比較の前：観測量、原子の対応、計算長を確認する。

温度も配列も違う結果を、同条件の反復として混ぜない。

## 記録を読む：失敗の理由と、次の試行の条件を確かめる

試行1：エラーで停止

同じ条件 → 同じノードの別試行

条件を変更 → 新しいノードや分岐

失敗例：計算中に非数が生じて停止し、保存状態から再開する。

まず、止まった段階・エラー・最後の有効な出力を確認する。

同じ条件での再試行か、乱数や設定を変えた分岐かを区別する。

再開後の成功は、前の失敗の原因が解明されたことを意味しない。





## 参考文献とソフトウェア

**AI Scientist**

Robin：Ghareeb et al. DOI:10.1038/s41586-026-10652-y
Co-Scientist：Gottweis et al. DOI:10.1038/s41586-026-10644-y
ERA：Aygun et al. DOI:10.1038/s41586-026-10658-6

**転移学習**

Murakami et al., bioRxiv (2026)
DOI:10.64898/2026.07.30.741744
ナノボディの融解温度予測。図1〜3を使用。

**MDClaw**

github.com/matsunagalab/mdclaw
計算手順・操作ツール・成果物の記録を参照する。