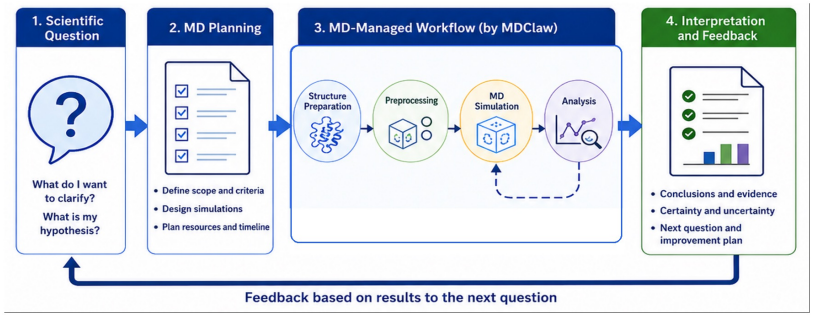
AI Scientist研究とMDエージェント

研究の手順を記録し、
計算と評価を繰り返す

松永 康佑
埼玉大学 大学院理工学研究科
理化学研究所 計算科学研究センター



研究の手順を記録し、計算と評価を繰り返す

研究の手順を記録し、

計算と評価を繰り返す。

自然言語の仮説を計算手順へ落とし、出力を検証して次の計算へ進む。

データの量だけでなく、条件の統一・多様性・失敗の記録が研究の質を決める。

研究の問い・仮説
↓
計算を計画して実行
↓
出力と失敗を記録
↓
根拠を評価して次へ

研究の自動化をデータと検証から考える

1　AI Scientistの提案と外部の検証
2　自動データ取得と計算条件の統一
3　転移学習とデータ量・多様性
4　MDClawのskills・CLI・計算履歴
5　教員デモ：入力から証拠までをたどる

研究の問い・仮説
↓
計算を計画して実行
↓
出力と失敗を記録
↓
根拠を評価して次へ

AI Scientistの提案は、外部の評価と組み合わせる

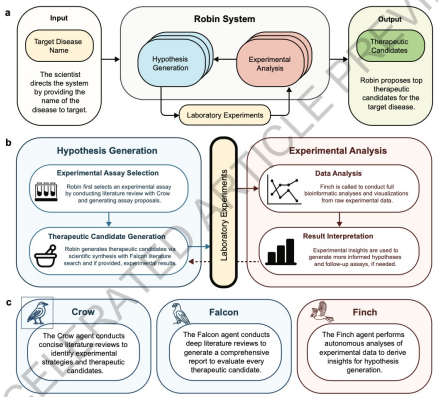
研究	AIが担う作業	検証の進め方
Robin	文献探索とデータ解析から、仮説と実験候補を提案する。	人が候補を検討し、実験結果を次の仮説へ戻す。
	Ghareeb et al., Nature (2026). DOI:10.1038/s41586-026-10652-y	
Co-Scientist	複数のエージェントで仮説を生成・批判・順位付け・改良する。	研究者が目標と候補を選び、実験で確かめる。
	Gottweis et al., Nature (2026). DOI:10.1038/s41586-026-10644-y	
ERA	定量的な評価値を使い、探索しながら科学計算コードを作る。	データと計算による評価を、コードの改良へ戻す。
	Aygun et al., Nature (2026). DOI:10.1038/s41586-026-10658-6	

Robin：文献と実験データから、仮説を更新する

CrowとFalconが文献を探索し、Finchが実験データと関連情報を解析する。

候補を実験で確かめ、その結果を次の仮説に戻す。

AIの提案だけで研究を閉じず、研究者や実験系による評価を入れる。



Ghareeb et al., Nature (2026). DOI:10.1038/s41586-026-10652-y

もっともらしい説明を、検証できる仮説へ変える

例：「変異で安定になる」を、そのまま計算の入力にはできない。

何を安定性と呼ぶか、何と比べるか、温度や溶媒は何かを決める。

仮説から観測量・比較条件・判定方法へ落とす段階で、研究者の判断が必要になる。

計算が成功したことと、仮説が支持されたことを分ける。

研究の問い・仮説
↓
計算を計画して実行
↓
出力と失敗を記録
↓
根拠を評価して次へ

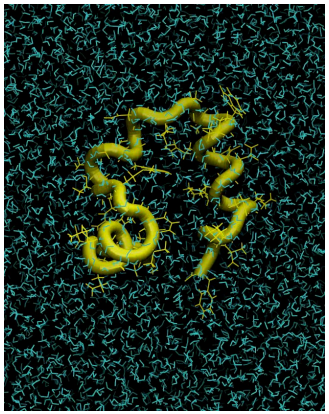
実験で見えにくい過程を、計算で調べる

AIの提案
文献を調べる
仮説と計画
→
研究者・実験
評価・測定
→
観測の限界
短寿命の状態や動き
→
MD計算
構造アンサンブルと機構

実験で試しにくい条件を計算で調べ、仮説と観測量を結ぶ。

計算もモデルに基づくため、力場・条件・サンプリングの妥当性を確かめる。

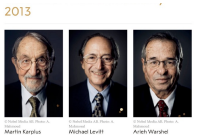
分子動力学は、原子の運動から構造アンサンブルを調べる



原子に働く力を計算し、運動方程式を数値的に解く。

座標の時間変化から、構造の分布や動きを調べる。

実験で直接見えにくい過程も、モデルと測定を対応させて考察する。



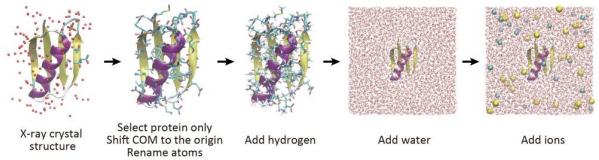
2013年ノーベル化学賞の紹介図（nobelprize.org）

MDの準備では、分子ごとに判断する点が異なる

変異・修飾・補因子・リガンド・膜・プロトン化状態によって、準備の分岐が変わる。

力場、欠損原子、電荷、水和などを、対象と目的に合わせて選ぶ。

固定した条件分岐だけでは扱いにくい例外もある。入力を検査し、結果を確かめ、必要なら計画を修正する。



図：GENESIS tutorial。化学状態・モデル・入力の選択を、結果と一緒に記録する。

計算データを増やすには、条件も同時に揃える

異なる構造を同じ規則で準備し、同じ観測量を取り出す。

構造ID、配列、プロトン化状態、力場、水モデル、温度、乱数、計算長を保存する。

成功したものだけを残すと、難しい系が消えた偏ったデータ集合になる。失敗理由も残す。

入力と設定を読む
↓
成果物を検査する
↓
失敗の理由を調べる
↓
再試行か条件変更かを決める

ナノボディを同じ条件で計算し、学習データを作る

対象一覧の例（SAbDab：抗体構造のデータベース）

pdb	Hchain	Lchain	model	antigen_chain	antigen_type	antigen_het_name	antigen_name
8g2y	N	NA	0	A | B	protein | protein	NA | NA	minig alpha s/q chimera | guanine nucleotide-binding protein g(l)/g(s)/g(t) subunitbeta-1
8bb7	D	NA	0	B	protein	NA	plexin-b1
8bb7	C	NA	0	A	protein	NA	plexin-b1
8bf4	D	NA	0	F	protein	NA	plexin-b1
8bf4	E	NA	0	F	protein	NA	plexin-b1
8bf4	A	NA	0	C	protein	NA	plexin-b1
8bf4	B	NA	0	C	protein	NA	plexin-b1
7xk9	B	NA	0	A	protein	NA	endolysin,beta-2 adrenergic receptor



依頼例：一覧の各ナノボディを100 nsずつ計算する。

構造ID、鎖、残す成分、計算条件と完了基準を明示する。

対象一覧の一部だけを拡大表示。図：既存発表資料。

転移学習では、計算データも使って共通の表現を学ぶ

タンパク質言語モデルが配列の表現を作る。

少数の実験Tmと、計算による安定性の補助ラベルを別の出力で学習する。

計算値を実験値と同一視するのではなく、共通の表現を介して実験予測を助ける。

最終評価には学習に使っていない実験配列を使う。

大量の配列で事前学習
↓
計算ラベル＋少数の実験値
↓
共有表現とタスク別の出力
↓
未学習配列でTmを評価

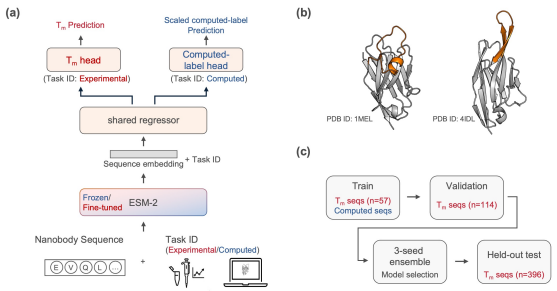
ナノボディの融解温度を、計算ラベルも使って予測する

Tm：熱変性の中点に対応する融解温度。

ESM2：配列を数値表現に変えるタンパク質言語モデル。

FEP：自由エネルギー摂動法。変異に伴う自由エネルギー差を計算する。

実験Tmは学習57配列、モデル選択114配列、最終評価396配列。



村上さんの研究：Murakami et al., bioRxiv (2026). DOI:10.64898/2026.07.30.741744

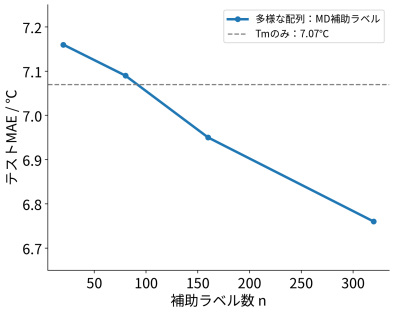
同じラベル数でも、どの配列を計算するかが効く

同じMD由来のラベルでも、少数構造の変異走査と、多様なナノボディ集合を比較する。

多様な集合では、ラベル数20→320で微調整モデルの平均絶対誤差（MAE）が7.16→6.76°Cへ下がった。

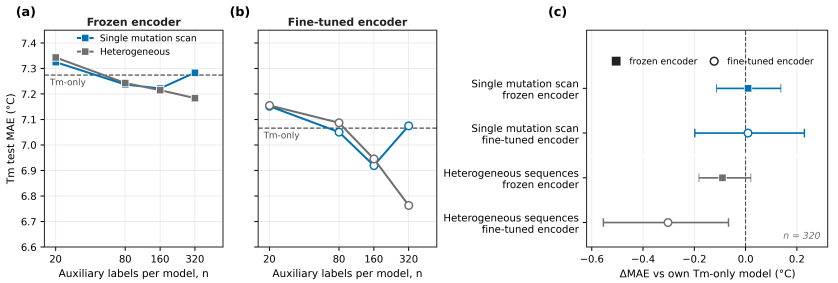
変異走査では単調な改善にならなかった。量だけでなく、覆う配列の広さが重要。

原稿Fig. 2の条件。右の再描画は本文の数値に基づく。



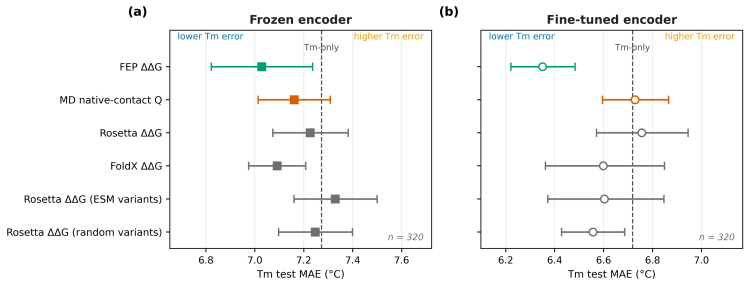
原著Fig. 2：データ設計によって増量の効果が違う

左・中央：ラベル数と、凍結／微調整したモデルの誤差。
右：同じラベル数320で、それぞれのTmのみの基準からの変化。
誤差が低いほどよい。異なる学習条件の基準値を混ぜない。
この範囲の結果から、無限に増やせば改善すると外挿しない。



原著Fig. 3：何を計算するかも予測に影響する

同じ変異配列に対し、FEP・MD接触率・Rosetta・FoldXの補助ラベルを比較。
この比較ではFEP補助の微調整モデルのMAEが6.35°C。Tmのみは6.72°C。
「この予測に有用だった」ことと、「実験ΔΔGを最も正確に再現した」ことは別。



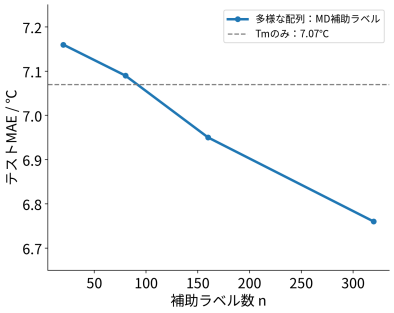
スケーリングの議論では、量・質・評価を分ける

データ数Nを増やすと誤差が減る経験的な関係は、対象・範囲・学習条件に依存する。

重複や偏りの強いデータを増やしても、未知の配列への誤差は減らないことがある。

類縁配列や条件が訓練とテストをまたぐ影響も点検する。

自動化は、比較可能なデータを狙って増やすために使う。



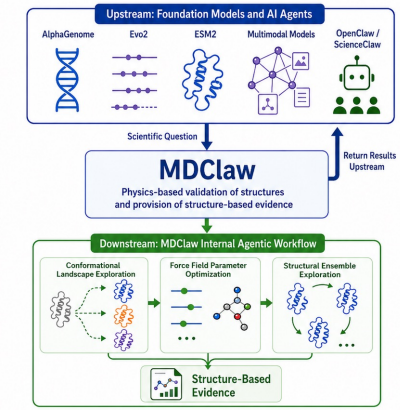
MDClaw：研究の問いを、計算による検証につなぐ

上流：言語モデルや生成モデルが、仮説や構造候補を出す。

MDClaw：問いを計算計画へ落とし、準備・実行・解析を記録する。

結果：構造に基づく根拠と不確実性を、次の問いへ戻す。

図は開発の目標像。個別機能の実装・検証状況とは区別する。



MDClawは、手順書・操作ツール・計算履歴を組み合わせる

研究の問いから計画、系の準備、MD、解析、結果の確認へ進む。

Skillsは手順と判断基準を記した文書。CLIは引数を受けて操作を実行するコマンド。

計算の入力・出力・失敗をDAGとして記録し、異なるエージェントから同じ操作を呼び出せるようにする。

対象の化学状態に応じた準備は必要。実行成功だけで科学的妥当性を保証しない。

MDClaw：github.com/matsunagalab/mdclaw／紹介資料の時点と、現在の実装を区別する。

Skillsが判断を助け、CLIが実行と記録を担う

md-study 問いを観測量と計算計画へ	md-prepare 構造の取得・準備・水和・力場設定	md-equilibration 段階的に系を緩和する
md-production 本計算を区切って実行・再開する	md-analyze 軌道を解析し、根拠を示す	hpc-run SLURMを介して計算機で実行する

人が読む手順書と、機械が読む実行結果を対応させる。

エージェントは、手順書を読んでツールを呼ぶ

name	md-prepare
description	Molecular dynamics simulation preparation using MDClaw CLI tools. Covers structure acquisition, protein/nucleic/ligand selection, structure cleaning, solvation, and topology generation.

MD Prepare

You are a computational biophysics expert helping users set up MD simulations using the MDClaw CLI tools.

Read `skills/common/preamble.md`, `skills/common/tool-output.md`, `skills/common/defaults.md`, `skills/common/node-cli-patterns.md`, `skills/common/run-loop.md`, `skills/common/autonomous-checklist.md`, and `skills/common/guardrail-codes.md` before acting.

① 対象のSkillを読む

② 必要な入力と前提を確かめる

③ 引数を指定してCLIを呼ぶ

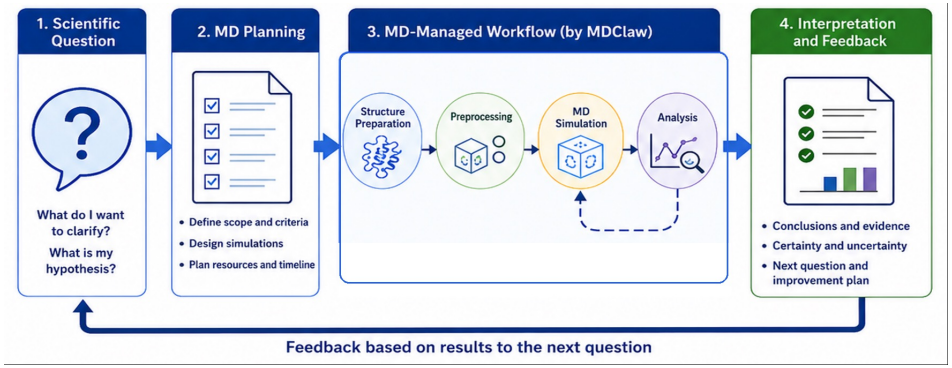
④ 戻り値と成果物を読む

⑤ 次の操作か、修正が必要かを判断する

md-prepareの記述例。手順書自体も版を持つため、使用した版を記録する。

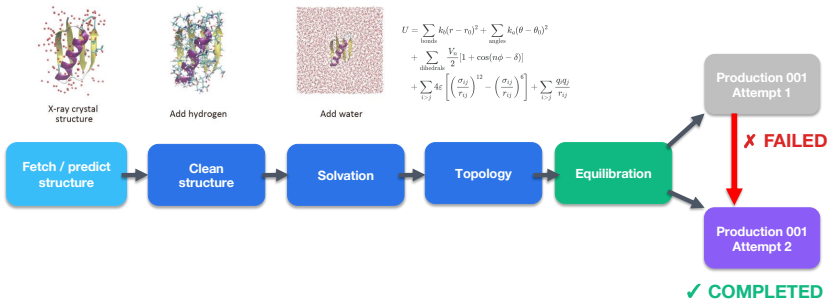
出典：github.com/matsunagalab/mdclaw/blob/main/skills/md-prepare/SKILL.md

問い・計画・計算・解釈を、成果物でつなぐ



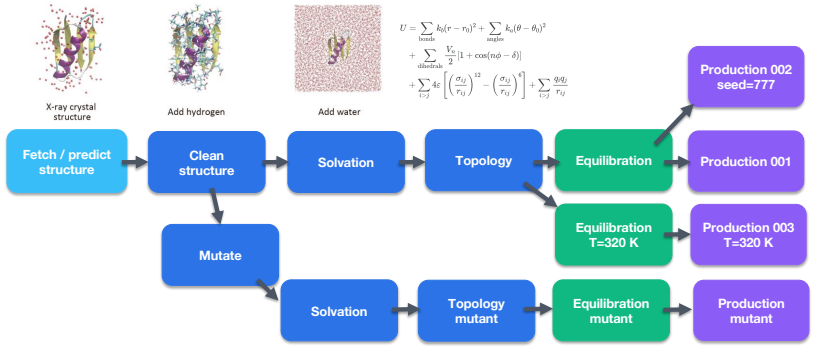
DAG（循環のない有向グラフ）は、入力から出力への依存関係を表す。

失敗した実行を残し、条件を確かめて再試行する



同じ条件の再試行は同じノードの別Attemptとして残す。条件を変える場合は新しいノードや分岐にする。

乱数・温度・変異など、変更した条件を分岐に残す



乱数、温度、変異などを変えた比較は別の分岐として保存する。共通の入力と変更した条件を区別する。

再実行では、完了済みの根拠を使って続きへ進む

inspect_jobで状態と成果物を読む。
explain_nodeで次の段階の入力条件を確認する。

trace_failureで失敗した段階と理由を追う。

ファイルが存在するだけで完了とせず、正しい入力に対応した出力かを検査する。

2026年10月11日のローカルREADMEにある操作の役割。

入力と設定を読む
↓
成果物を検査する
↓
失敗の理由を調べる
↓
再試行か条件変更かを決める

実行前の検査で、不整合と運用上の制約を伝える

検査結果を構造化する
対象項目／理由／重要度
実際の値と期待する値
修正候補／エラーコード

次の段階への入力を明確にする
準備：化学状態と判断を記録
力場設定：相互作用を定義
以後の計算：登録された出力を読む

例：forcefield_water_blocked　ff19SB + TIP3P → 規定では ff19SB + OPC

この組合せを止めるのは、当該ワークフローの運用規約。科学的にその組合せが絶対に使えない、という意味ではない。

MDPrepBenchは、準備結果を再計算して評価する

対象と化学状態
公開構造の欠損や不整合を扱う。
指定したリガンド・イオン・修飾・膜・プロトン化状態を保つ。

提出物と記録
構造、設定、出典、判定の根拠を残す。
文章だけでなく、再読込できるファイルを提出する。

独立した点検
成分と残基状態を再確認する。
OpenMMで設定を読み直し、エネルギーを再計算する。

最小化が終了したことだけで、準備が正しいとは判定しない。

生成した構造を、成分と配置から点検する

P02：タンパク質＋AP5



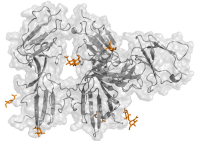
リガンドを保持しているか

P06：カルモジュリン＋Ca^{2+}



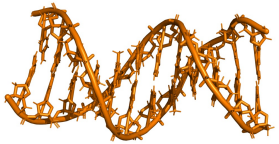
イオンの位置は妥当か

P14：糖タンパク質



糖鎖などの成分が残っているか

P17：DNA二重鎖



両方の鎖と配置が保たれているか

25課題の比較では、Skillsを含む条件の得点が高かった

model / harness	skills+CLIs	CLIs-only	free
Haiku 4.5 / claude-code	22/25	7/25	5/25
DeepSeek-v4-flash / pi	20/25	7/25	13/25

Haikuの合格数：Skills＋CLIは22/25、CLIのみは7/25、自由な操作は5/25。

この比較条件では、手順書を伴う構成が有利だった。すべてのモデルや課題へ一般化しない。

2026年6月発表時の25課題による比較。現在の版・別の課題集合の性能とは区別する。

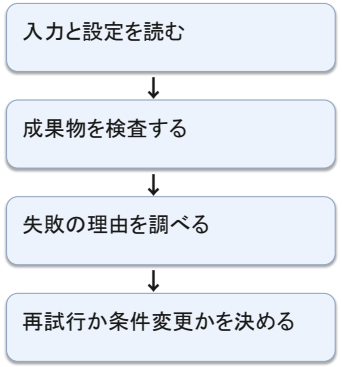
ベンチマーク結果は、条件と失敗例まで読む

課題集合、入力、モデル版、制限時間、計算環境、採点基準を揃える。

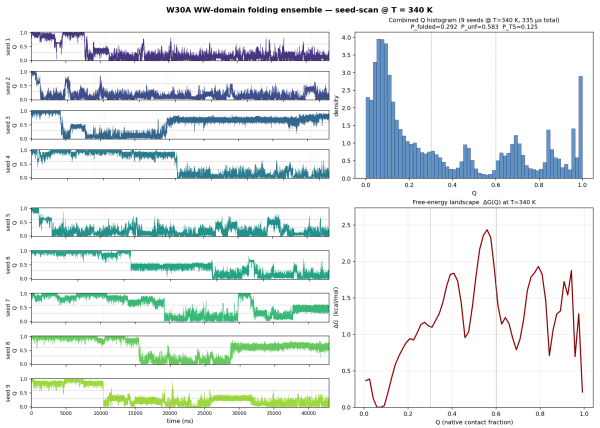
途中で停止した実行や、提出物がない実行を完了した評価と混ぜない。

成功率に加え、どの化学状態や段階で失敗するかを調べる。

過去の25課題の点数から、現在の任意の系の成功率は予測できない。



折り畳み温度を探すには、状態と収束を定義する



利用例：9 GPUでWWドメインを調べる。

左：時刻に沿った天然接触率Q。

右上：Qの分布。

右下：Qに沿った自由エネルギー。

温度ごとの割合と反復を比較する。一つの短い軌道では転移温度は決まらない。

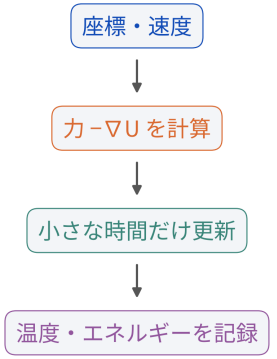
教員デモ：計算の入力から根拠までをたどる

題材は第11回と同じ水中ペプチドの短い計算。

最初に条件・出力を指定した依頼文を読み、どの段階に対応するかを確認する。

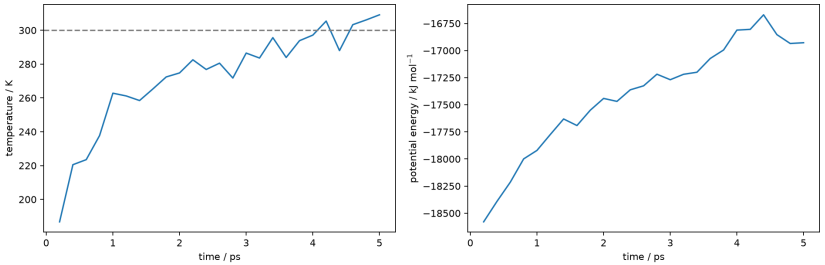
次に保存された構造・温度・エネルギー・実行条件を開く。

新しい大規模計算ではなく、既存の短い実行の記録とMDClawのDAGの読み方を示す。



デモで見るもの：説明と成果物が一致するか

「300 Kで動かした」という説明なら、積分器の設定と温度ログを見る。
「5 ps」という説明なら、2 fs×2500ステップとの一致を見る。
「構造が安定」という説明には、計算長・反復・観測量の根拠が必要。
下は第11回Notebookの実行例。5 psでは昇温途中であり、平衡分布の例ではない。



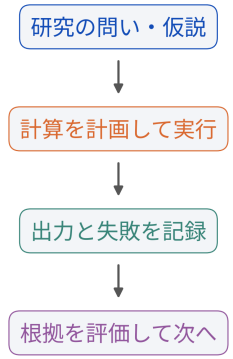
次の計算は、残っている不確実性から決める

温度は合うが構造が動かない：単に短い可能性がある。

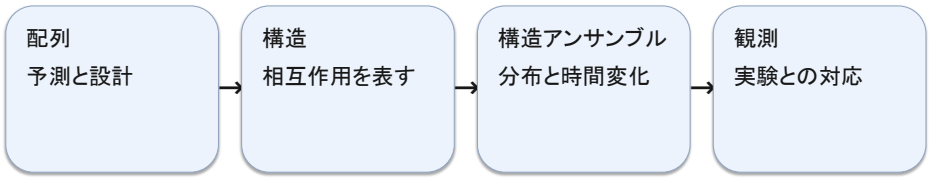
反復ごとの割合が違う：探索や緩和が足りない可能性がある。

モデル間で結果が違う：力場や観測モデルの仮定を点検する。

追加するデータが、どの不確実性を減らすかを先に決める。



配列・構造・分布・観測をつなぎ、判断する



配列から構造を予測し、目的の構造に合う配列を設計する。

相互作用から構造の分布と動きを計算し、観測を通じてモデルを確かめる。

エージェントは計算と記録をつなぐ。判断の根拠は、条件のそろったデータと検証に置く。

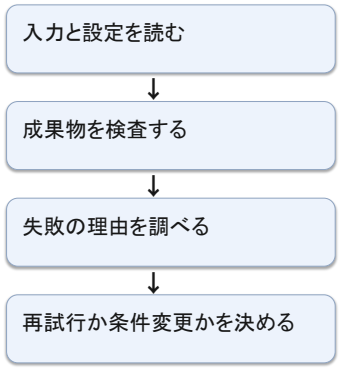
まとめ：自動化するほど、根拠を追える記録が要る

AI Scientistは仮説や手順を広げる。計算・実験が検証の手掛かりを与える。

転移学習ではデータ数に加え、配列の多様性とラベルの意味が重要。

MDClawでは計画・操作・成果物・失敗をつなぎ、同じ条件で比較できる形に残す。

実行成功を、そのまま科学的結論へ置き換えない。



付録：導出と補足資料

ここからは本編の補足です。
導出の途中式、計算条件、研究例の詳細を示します。
本編の各手法の前提と対応させて読んでください。

準備課題 P01〜P13：対象と化学状態を指定する

P01	Simple monomer	2LZM; clean one protein chain for explicit-water MD.
P02	Chain + ligand	1AKE; include chain A and AP5 despite chain ambiguity.
P03	Ligand pose	181L; preserve T4L L99A plus benzene crystal pose.
P04	Ligand filtering	3PWB; keep requested ligands, exclude irrelevant heterogens.
P05	Charged cofactor	1DAP; retain and document NDP/NADPH-like cofactors.
P06	Supported ions	1CLL; retain four Ca2+ ions.
P07	Ion triage	4RBQ; prepare RNA while preserving designated K+ ions.
P08	Point mutation	2LZM; branch WT to L99A without numbering drift.
P09	Multi-mutant	2LZM; apply L99A and M102Q together.
P10	Disulfides	5PTI; record BPTI disulfides and exclude deuterium.
P11	Protonation	2LZM; preserve explicit A:11 GLH protonation.
P12	Deposited PTM	5K9P; restore deposited SEP and source record.
P13	Requested PTM	1UBQ; convert Ser20 to SEP on request.

各行は課題番号・対象の種類・守る条件。課題間で必要な準備が異なる点を読む。

準備課題 P14〜P25：膜・核酸・モデル条件を指定する

P14	Glycan	6YA2; preserve N-linked glycans as glycans.
P15	DNA	5MVQ; prepare DNA without protein defaults.
P16	RNA	4RBQ; prepare RNA with RNA-compatible metadata.
P17	DNA duplex	1BNA; preserve both DNA chains and neutralization record.
P18	Membrane	2LOP; honor POPC:POPE:CHL1 = 2:1:1.
P19	Candidate selection	2K39; select specified NMR model before prep.
P20	Terminal capping	5AWL; honor ACE/NME caps.
P21	PDB cleanup	4Q5T; handle MSE, altloc, numbering, missing residues.
P22	FF/water fidelity	2LZM; honor ff19SB plus OPC.
P23	Implicit solvent	5AWL; avoid explicit water when implicit is requested.
P24	Biological assembly	1STP / 2MS2; generate assembly 1 and map chains.
P25	KCl concentration	5AWL; honor 0.30 M KCl and neutrality.

各行は課題番号・対象の種類・守る条件。課題間で必要な準備が異なる点を読む。

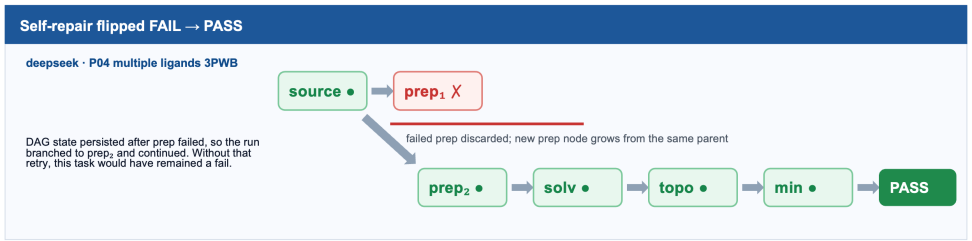
依頼文の例：対象・除外対象・提出物を明記する

Use this prompt as the task statement. Retrieve public sources as needed, and do not read `truth/` or `scorer/` if those directories exist.
Task: Simple monomer preparation: retrieve T4 lysozyme chain A, clean it, prepare an explicit-water-compatible topology, and report that no unintended ligands were retained.
Public source anchors: PDB 2LZM.
Your submission directory must contain:
- `manifest.json`
- `metrics.json`
- `provenance.json`
- `evidence_report.json`
- `prepared_structure.pdb`

P01はT4リゾチーム鎖Aの準備。参照元と、混入させない成分・提出ファイルを指定する。

失敗後の修正と再試行で、合格した例

記録から、失敗点と修正後の結果をたどる



この例では、失敗した準備から別の準備へ進み、入力・水和・力場・最小化を再確認している。

基本の利用例：問いと計算条件を、記録に変える

実行

一つの系を準備し、計算の依存関係を記録する。

計画

観測量・計算条件・判定基準を明確にする。

解析

軌道を解析し、不確実性とともに答える。

変異の比較

共通の準備から分岐し、変更した条件を残す。

成分の指定

リガンドやイオンを保持し、化学状態を記録する。

応用の利用例：異なる準備と計算を、分岐に残す

修飾の準備

記録された修飾や、指定された化学状態を準備する。

膜の準備

膜と水を含む系として準備する。

構造候補

生成モデルの候補を、初期構造として比較する。

計算の延長

本計算を区切り、再開のつながりを記録する。

評価課題

依頼文・提出物・採点結果を対応させる。

問い・比較条件・出力・解釈を、一つずつ対応させる

問い
変異で分子の動きが変わるか

→

計画
野生型と変異体
観測量・判定基準

→

実行
準備 → 平衡化
本計算 → 解析

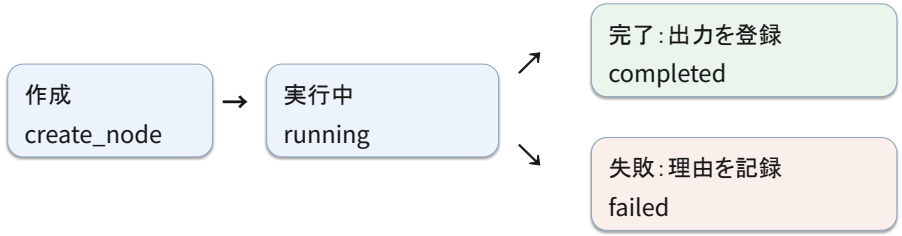
→

解釈
差の向き・大きさ
誤差・次の計算

文章による回答だけでなく、構造・設定・軌道・解析結果を対応させる。

比較では、原子や残基の対応と、共通条件・変更条件を明示する。

実行中のノードは、完了か失敗のいずれかへ進む

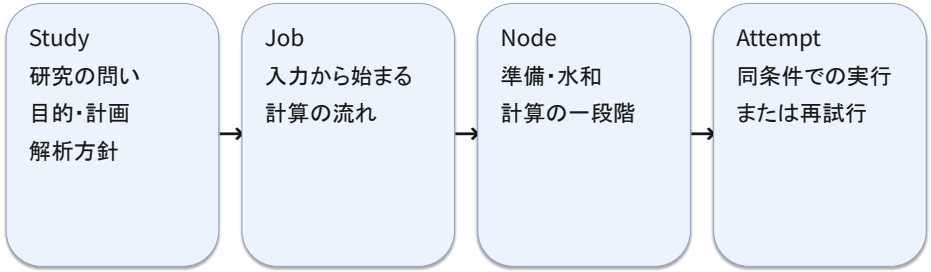


完了した記録は根拠として保存し、後からの所見は追記する。

同じ条件の再試行は、同じノードの新しいAttempt（試行）として残す。

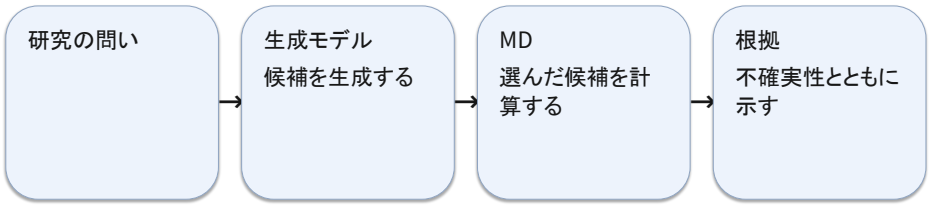
条件を変える場合は、新しいノードや分岐として区別する。

問い・一連の計算・段階・試行を分けて記録する



「研究全体」と「同じ条件での再試行」を混同せず、どこを変更したかを追えるようにする。

今後の構想：生成モデルで候補を絞り、MDで確かめる

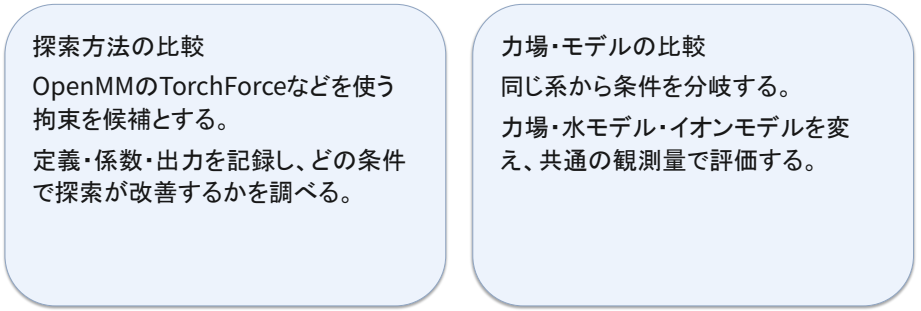


候補構造、初期構造アンサンブル、追加の探索が必要な領域を選ぶために、生成モデルを使う構想。

MDを重点的に使う対象を選び、その選択と結果を記録する。

この図全体の自動実行が実装・検証済みであることを示すものではない。

今後の構想：探索方法と力場の選択を、比較可能にする



検討中の方向性。分岐を記録できることと、最適な条件を自動で発見できることは別。

既存の科学計算ソフトウェアを、記録付きで呼び出す

入力・知識：PDB、UniProt、PubChemなど。

準備：PDBFixer、PROPKA、RDKitなど。

水和・膜：Packmolなど。

力場・計算：AmberTools、OpenMMなど。

解析・可視化：MDTraj、PyMOLなど。

実行環境：コンテナやSLURMなど。



エージェントが物理計算を置き換えるのではなく、既存の道具を呼び、条件と結果を記録する。

実行前の検査で、不整合と運用上の制約を伝える

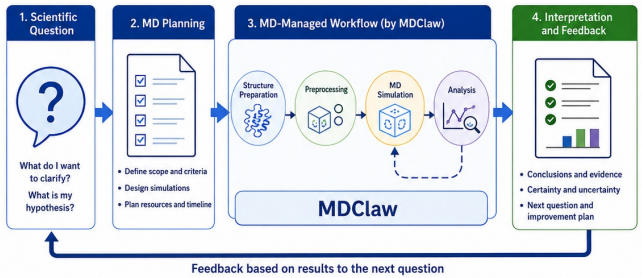
検査結果を構造化する
対象項目／理由／重要度
実際の値と期待する値
修正候補／エラーコード

次の段階への入力を明確にする
準備：化学状態と判断を記録
力場設定：相互作用を定義
以後の計算：登録された出力を読む

例：forcefield_water_blocked　ff19SB + TIP3P → 規定では ff19SB + OPC

この組合せを止めるのは、当該ワークフローの運用規約。科学的にその組合せが絶対に使えない、という意味ではない。

記録を読む：問いから成果物までの対応を確かめる



問い：何を比べたか。

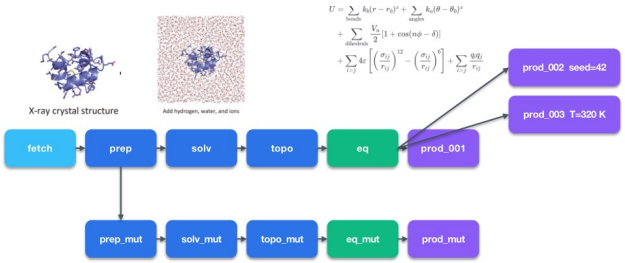
計画：観測量と判定基準は何か。

計算：どの入力と設定を使ったか。

解釈：どの成果物が結論を支えるか。

各段階の記録を照合し、説明だけで判断しない。

記録を読む：共通の入力と、変更した条件をたどる



分岐の前：共有する構造と準備。

分岐の後：乱数・温度・変異などの変更。

比較の前：観測量、原子の対応、計算長を確認する。

温度も配列も違う結果を、同条件の反復として混ぜない。

記録を読む：失敗の理由と、次の試行の条件を確かめる

試行1：エラーで停止

同じ条件 → 同じノードの別試行

条件を変更 → 新しいノードや分岐

失敗例：計算中に非数が生じて停止し、保存状態から再開する。

まず、止まった段階・エラー・最後の有効な出力を確認する。

同じ条件での再試行か、乱数や設定を変えた分岐かを区別する。

再開後の成功は、前の失敗の原因が解明されたことを意味しない。

参考文献とソフトウェア

AI Scientist

Robin：Ghareeb et al. DOI:10.1038/s41586-026-10652-y
Co-Scientist：Gottweis et al. DOI:10.1038/s41586-026-10644-y
ERA：Aygun et al. DOI:10.1038/s41586-026-10658-6

転移学習

Murakami et al., bioRxiv (2026)
DOI:10.64898/2026.07.30.741744
ナノボディの融解温度予測。図1〜3を使用。

MDClaw

github.com/matsunagalab/mdclaw
計算手順・操作ツール・成果物の記録を参照する。